Séries temporais

À mão

Os seis blocos da lista (Q1–Q16) linha a linha, na notação dos slides e do caderno

---

Caderno de estudo · parte 1: ARMA, ARIMA e SARIMA

Prof. Guilherme Pereira · Econometria II (PPGEco/UFES)

Gerado em 28/10/2026 a partir de `github.com/fcarva/series-temporais` (commit `9a22eb5`). Material autoral: enunciados parafraseados, demonstrações próprias, números conferidos em R contra os scripts do repositório.

Sumário

I Bloco 1 à mão: Q1 a Q4 **1**

1 Cap. 1 à mão — Q1 a Q4 linha a linha **2**

II Bloco 2 à mão: Q5 a Q8 **7**

2 Cap. 2 à mão — Q5 a Q8 linha a linha **8**

III Bloco 3 à mão: Q9 a Q12 **15**

3 Cap. 3 à mão — Q9 a Q12 linha a linha **16**

IV Bloco 4 à mão: Q13 e Q14 **23**

4 Cap. 4 à mão — Q13 e Q14 linha a linha **24**

V Bloco 5 à mão: Q15 **29**

5 Cap. 5 à mão — Q15 linha a linha **30**

VI Bloco 6 à mão: Q16 **35**

6 Cap. 6 à mão — Q16 linha a linha **36**

VII Apêndice: Q2 e Q6 completas **41**

7 Demonstrações à mão — Q2 e Q6, linha a linha **42**

Parte I

Bloco 1 à mão: Q1 a Q4

Cap. 1 à mão — Q1 a Q4 linha a linha

Cap. 1 à mão: Q1 a Q4, linha a linha

← capítulo 1 · ← apostila · cap. 2 à mão

Versão de **caderno** do bloco 1 da lista: cada passagem numerada, uma operação por linha e o motivo entre colchetes. A numeração é contínua do início ao fim. Os símbolos são os dos slides; a lista usa u_t ou a_t para o choque, e aqui ele é u_t ou ε_t, conforme o enunciado.

Legenda:

- [RB]: ruído branco;
- [F2]: série geométrica;
- [F3]: soma de Gauss;
- [F4]: linearidade da esperança, inclusive em soma finita;
- [F5]: covariância de combinações lineares;
- [estac.]: os momentos não dependem da data;
- [caus.]: o choque de hoje não se correlaciona com o passado;
- [(n)]: usando a linha (n).

As ferramentas estão na caixa de ferramentas.

Q1 · Passeio com drift e valor inicial 10

Enunciado (lista, Q1). $y_t = c + y_{t-1} + u_t$, com $y_0 = 10$ e u_t ruído branco. Pede-se $E(y_t)$, $\mathrm{Var}(y_t)$ e $\mathrm{Cov}(y_t, y_{t-k})$, e se o processo é estacionário. A lista escreve $RB(0, \sigma)$; leia como variância σ^2.

Nos slides: é o passeio com drift da AU01, p. 29, com $\alpha_1 = c$ e $y_0 = 10$.

(1)	$y_s - y_{s-1} = c + u_s$	[modelo]
(2)	$\sum_{s=1}^{t}(y_s - y_{s-1}) = y_t - y_0$	[telescópica]
(3)	$y_t = 10 + ct + \sum_{s=1}^{t} u_s$	[(1), (2), $y_0 = 10$]
(4)	$E(y_t) = 10 + ct + \sum_{s=1}^{t} E(u_s)$	[F4, soma finita]
(5)	$= 10 + ct$	[RB]
(6)	$y_t - E(y_t) = \sum_{s=1}^{t} u_s$	[(3) − (5)]
(7)	$\mathrm{Var}(y_t) = E\Big(\big(\sum_{i=1}^{t} u_i\big)^2\Big) = \sum_{i=1}^{t}\sum_{j=1}^{t} E(u_i u_j)$	[(6), F4]
(8)	$= \sum_{i=1}^{t} E(u_i^2) = t\sigma^2$	[RB: só $i = j$]
(9)	$\mathrm{Cov}(y_t, y_{t-k}) = E\big(\sum_{i=1}^{t} u_i \sum_{j=1}^{t-k} u_j\big)$	[(6) em t e $t-k$]
(10)	$= \sum_{j=1}^{t-k} E(u_j^2) = (t-k)\,\sigma^2$	[RB: só os pares comuns]
(11)	$\mathrm{Corr}(y_t, y_{t-k}) = \dfrac{(t-k)\sigma^2}{\sqrt{t\sigma^2\,(t-k)\sigma^2}} = \sqrt{\dfrac{t-k}{t}}$	[(8), (10)]
(12)	$\mathrm{Var}(y_t) = t\sigma^2$ depende de $t \Rightarrow$ não estacionário	[AU01 p. 25]

$$E(y_t) = 10 + ct, \qquad \mathrm{Var}(y_t) = t\sigma^2, \qquad \mathrm{Cov}(y_t, y_{t-k}) = (t-k)\sigma^2 \ : \ \text{não estacionário}$$

Mesmo com $c = 0$, quando a média fica constante em 10, a variância cresce: a conclusão não depende do drift. E a correlação (11) vai a 1 para k fixo e t grande: com $t = 100$ e $k = 10$, $\sqrt{0{,}9} = 0{,}95$. É a FAC que decai devagar, assinatura da raiz unitária.

Erro do caderno (19/08): $E(XY) = E(X)E(Y)$ **escrito sem condição**

Essa regra só vale para variáveis **não correlacionadas**, e $\sigma^2 = E(X^2)$ só vale com média zero. Em (8), o que zera os termos com $i \neq j$ é a hipótese de ruído branco, $E(u_i u_j) = 0$, e não uma regra geral da esperança.

Q2 · Drift e tendência: o esqueleto, com a demonstração completa ao lado

A Q2 está demonstrada por inteiro na folha da Q2 e da Q6, em 38 linhas, inclusive a esperança do somatório parcela por parcela. O esqueleto, nos slides, com $Y_t = \alpha_1 + Y_{t-1} + \alpha_2 t + \varepsilon_t$ e $Y_0 = 0$:

(13)	$Y_t = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum_{s=1}^{t} \varepsilon_s$	[telescópica, F3]
(14)	$E(Y_t) = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$	[F4, soma finita; RB]
(15)	$\mathrm{Var}(Y_t) = t\sigma^2, \qquad \mathrm{Cov}(Y_t, Y_{t-k}) = (t-k)\sigma^2$	[RB: só $i = j$]
(16)	comparado ao drift puro: só a média muda (reta → parábola)	[(14), (15)]
(17)	$\Delta Y_t = \alpha_1 + \alpha_2 t + \varepsilon_t$: ainda tem tendência; regredir em t	[diferença + regressão]
(18)	$\Delta^2 Y_t = \alpha_2 + (1-L)\varepsilon_t$: MA com raiz $z = 1$, não invertível	[evitar]

Q3 · Soma de dois processos não correlacionados

Enunciado (lista, Q3). São dados dois processos estacionários e não correlacionados:

- z_{1t}, com $\gamma_0 = 0{,}5$, $\gamma_1 = 0{,}2$ e zero depois;
- z_{2t}, com $\gamma_0 = 2{,}30$, $\gamma_1 = -1{,}43$, $\gamma_2 = 0{,}30$ e zero depois.

Seja $z_{3t} = z_{1t} + 2z_{2t}$. Pede-se a autocovariância de z_3, se ele é estacionário e a sua classe ARMA.

Notação para as covariâncias cruzadas: $C_{12}(k) = \mathrm{Cov}(z_{1t}, z_{2,t-k})$ e $C_{21}(k) = \mathrm{Cov}(z_{2t}, z_{1,t-k})$.

(19)	$E(z_{3t}) = E(z_{1t}) + 2E(z_{2t}) = \mu_1 + 2\mu_2$	[F4: constante]
(20)	$\gamma_3(k) = \mathrm{Cov}\left(z_{1t} + 2z_{2t},\ z_{1,t-k} + 2z_{2,t-k}\right)$	[definição]
(21)	$= \gamma_1(k) + 2C_{12}(k) + 2C_{21}(k) + 4\gamma_2(k)$	[F5]
(22)	$= \gamma_1(k) + 4\,\gamma_2(k)$	[não correlacionados]
(23)	$\gamma_3(0) = 0{,}5 + 4(2{,}30) = 0{,}5 + 9{,}2 = 9{,}7$	[(22), $k = 0$]
(24)	$\gamma_3(1) = 0{,}2 + 4(-1{,}43) = 0{,}2 - 5{,}72 = -5{,}52$	[(22), $k = 1$]
(25)	$\gamma_3(2) = 0 + 4(0{,}30) = 1{,}2$	[(22), $k = 2$]
(26)	$\gamma_3(k) = 0 + 4 \cdot 0 = 0, \quad k \geq 3$	[(22)]
(27)	média const., $\gamma_3(0) < \infty$, $\gamma_3(k) = f(k) \Rightarrow$ estacionário	[AU01 p. 25]
(28)	$\rho_1 = \dfrac{-5{,}52}{9{,}7} = -0{,}5691; \qquad \rho_2 = \dfrac{1{,}2}{9{,}7} = 0{,}1237; \qquad \rho_k = 0,\ k \geq 3$	[$\div\gamma_3(0)$]
(29)	FAC corta depois de 2 $\Rightarrow$ MA(2)	[AU02 p. 51–52]
(30)	z_3 só contém choques de t a $t-2$ de cada parcela	[MA(max{1, 2})]

$$\boxed{\gamma_3(k) = \gamma_1(k) + 4\gamma_2(k) = (9{,}7;\ -5{,}52;\ 1{,}2;\ 0; \ldots) \ :\ \text{estacionário, MA(2)}}$$

Quem são z_1 e z_2? O enunciado não pede, mas a conta mostra que os números são consistentes:

(31)	$z_1 \ :\ \rho_1 = \dfrac{0{,}2}{0{,}5} = 0{,}4 = \dfrac{\theta}{1+\theta^2} \ \Rightarrow\ 0{,}4\theta^2 - \theta + 0{,}4 = 0$	[MA(1), D2.1]
(32)	$\Delta = 0{,}36;\ \theta = \frac{1 \pm 0{,}6}{0{,}8} \in \{2;\ 0{,}5\} \Rightarrow \theta = 0{,}5,\ \sigma^2 = \frac{0{,}2}{0{,}5} = 0{,}4$	[F1; invertível]
(33)	$z_2 \ :\ \sigma^2 = 1,\ \theta_2 = 0{,}3,\ \theta_1(1+\theta_2) = -1{,}43 \Rightarrow \theta_1 = -1{,}1$	[γ_1, γ_2 do MA(2)]
(34)	confere: $\gamma_0 = 1 + 1{,}21 + 0{,}09 = 2{,}30;\ \ 1 - 1{,}1z + 0{,}3z^2 = 0 \Rightarrow z \in \{2;\ 1{,}667\}$	[invertível]

Q4 · Teorema de Wold

Enunciado (lista, Q4). São três itens:

- (a) enunciar o teorema e discutir o componente determinístico;
- (b) mostrar que o AR(1) estacionário satisfaz a decomposição e identificar os ψ_j;
- (c) explicar por que a invertibilidade do MA é necessária para um AR(∞) convergente.

(a) O enunciado, para y_t estacionário de 2ª ordem com média zero (HAMILTON, cap. 4; AU02, p. 15–18):

(35) $y_t = \sum_{j\geq 0} \psi_j \varepsilon_{t-j} + \kappa_t$ [decomposição]

(36) $\psi_0 = 1, \qquad \sum_{j\geq 0} \psi_j^2 < \infty$ [condições]

(37) $\varepsilon_t = y_t - \hat{E}(y_t \mid y_{t-1}, y_{t-2}, \dots)$ [erro da melhor previsão linear]

(38) $E(\varepsilon_t) = 0, \;\; E(\varepsilon_t^2) = \sigma^2, \;\; E(\varepsilon_t \varepsilon_s) = 0 \; (s \neq t)$ [$\varepsilon_t \perp$ passado]

(39) $E(\kappa_t \varepsilon_s) = 0$ para todos t, s [ortogonalidade]

(40) κ_t previsto sem erro; ex.: $\kappa_t = a\cos\lambda t + b\sin\lambda t$ [determinístico]

O componente determinístico **não** é uma tendência: uma tendência faria a média depender de t, e o processo não seria estacionário. É a parte que o passado prevê com erro zero. Nos ARMA estacionários, $\kappa_t = 0$: são **puramente não determinísticos**.

(b) AR(1): $y_t = \phi y_{t-1} + \varepsilon_t$, com $|\phi| < 1$.

> **Erro do caderno (19/08): y_2 do AR(1) recursivo sem o y_0**
>
> O caderno escreveu $y_2 = \phi^2 + \phi\varepsilon_1 + \varepsilon_2$. Pela linha (42), com $t = 2$ e $n = 2$, o certo é $y_2 = \phi^2 y_0 + \phi\varepsilon_1 + \varepsilon_2$. A fórmula final do caderno, $y_t = \phi^t y_0 + \sum \phi^{t-i}\varepsilon_i$, está certa.

(41) $y_t = \phi(\phi y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \phi^2 y_{t-2} + \phi\varepsilon_{t-1} + \varepsilon_t$ [modelo em $t-1$]

(42) $y_t = \phi^n y_{t-n} + \sum_{j=0}^{n-1} \phi^j \varepsilon_{t-j}$ [n substituições]

(43) $E\Big(\big(y_t - \sum_{j=0}^{n-1} \phi^j \varepsilon_{t-j}\big)^2\Big) = \phi^{2n}\gamma_0 \;\to\; 0$ [(42), estac., $|\phi| < 1$]

(44) $y_t = \sum_{j\geq 0} \phi^j \varepsilon_{t-j} \;\Rightarrow\; \psi_j = \phi^j, \; \psi_0 = 1$ [limite em média quadrática]

(45) $\sum_{j\geq 0} \psi_j^2 = \sum_{j\geq 0} \phi^{2j} = \frac{1}{1-\phi^2} < \infty$ [F2, razão ϕ^2]

(46) $\hat{E}(y_t \mid y_{t-1}, \dots) = \phi y_{t-1} \;\Rightarrow$ inovação $= \varepsilon_t, \;\; \kappa_t = 0$ [caus.]

$$\boxed{\text{AR(1)} = \text{Wold com } \psi_j = \phi^j, \; \sum \psi_j^2 = \frac{1}{1-\phi^2} < \infty, \; \kappa_t = 0}$$

(c) Invertibilidade e o AR(∞), no MA(1) dos slides, $y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$ (AU02, p. 30–34):

> **Erro do caderno (03/09): $+\theta_1^2\varepsilon_{t-2}$ no lugar de $-\theta_1^2\varepsilon_{t-2}$**
>
> Ao substituir $\varepsilon_{t-1} = y_{t-1} - \theta_1\varepsilon_{t-2}$, o sinal troca. Os pesos de (48) alternam: $+, -, +, \dots$

(47) $\varepsilon_t = y_t - \theta_1 \varepsilon_{t-1}$ [isola o choque]

(48) $\varepsilon_t = \sum_{j=0}^{n-1} (-\theta_1)^j y_{t-j} + (-\theta_1)^n \varepsilon_{t-n}$ [n vezes]

(49) $E\big(((-\theta_1)^n \varepsilon_{t-n})^2\big) = \theta_1^{2n}\sigma^2 \to 0 \iff |\theta_1| < 1$ [RB]

(50) $y_t = \sum_{j\geq 1} \pi_j y_{t-j} + \varepsilon_t, \qquad \pi_j = -(-\theta_1)^j$ [(48), AU02 p. 23]

(51) $\sum |\pi_j| < \infty \iff |\theta_1| < 1$; senão o AR(∞) não converge [F2; AU02 p. 32]

(52) θ_1 e $1/\theta_1$: mesma FAC; só o invertível dá a inovação (37) [AU02 p. 34]

$$\boxed{\text{AR}(\infty) \text{ convergente} \iff \text{raízes de } \theta(z) \text{ fora do círculo} \iff \varepsilon_t \text{ é função do passado de } y}$$

Em (52), com $|\theta_1| > 1$, o choque ε_t do modelo só pode ser escrito com valores **futuros** de y. Ele não é a "notícia" de Wold, que é sempre função do passado. Por isso a invertibilidade é a condição para o choque do modelo coincidir com a inovação.

Versão para a prova

Q1:

1. Some de 1 a t (telescópica): $y_t = 10 + ct + \sum u_s$.
2. $E = 10 + ct$ [F4, RB]; Var $= t\sigma^2$; Cov $= (t-k)\sigma^2$ [RB: pares comuns].
3. A variância depende de t, logo o processo não é estacionário.

Q2: linhas (13)–(18), ou a folha completa.

Q3:

1. $\gamma_3(k) = \gamma_1(k) + 4\gamma_2(k)$, porque os cruzados zeram e a constante sai **ao quadrado**.
2. Os valores: 9,7; −5,52; 1,2; 0.
3. Estacionário, e MA(2), porque a FAC corta em 2.

Q4:

1. Enuncie (35)–(40) e diga que κ_t é o previsível sem erro, não uma tendência.
2. AR(1): substituição recursiva, resto $\phi^{2n}\gamma_0 \to 0$, $\psi_j = \phi^j$.
3. MA(1): $\pi_j = -(-\theta_1)^j$, somável se e só se $|\theta_1| < 1$.

Conferência

Q1, com $c = 0{,}5$, $\sigma^2 = 1$, $t = 20$ e $k = 5$: $E = 20$, Var $= 20$, Cov $= 15$, Corr $= 0{,}866$. Em 40 mil trajetórias simuladas: 20,01; 19,98; 14,99.

Q3:

- $\gamma_3 = (9{,}7;\ -5{,}52;\ 1{,}2;\ 0)$, $\rho_1 = -0{,}5691$ e $\rho_2 = 0{,}1237$;
- simulando z_1 e z_2 com os parâmetros de (32)–(33), com 200 mil observações, as autocovariâncias de z_3 saem 9,73; −5,56; 1,23; −0,01;
- as autocovariâncias de z_1 e z_2 reconstruídas pelo R conferem com o enunciado: 0,5 e 0,2; 2,30, −1,43 e 0,30.

Q4, com $\phi = 0{,}5$:

- $\psi_4 = 0{,}0625$ e $\sum \psi_j^2 = 1{,}3333$;
- na reconstrução do MA(1), o peso de y_{t-4} é 0,0625 com $\theta_1 = 0{,}5$ e 16 com $\theta_1 = 2$.

Parte II

Bloco 2 à mão: Q5 a Q8

Cap. 2 à mão — Q5 a Q8 linha a linha

Cap. 2 à mão: Q5 a Q8, linha a linha

← capítulo 2 · ← apostila

Esta é a versão de **caderno** do bloco 2 da lista, no mesmo formato da folha da Q2 e da Q6: cada passagem numerada, uma operação por linha e o motivo entre colchetes. Os símbolos são os dos slides: L, ε_t, ϕ_1, e θ_1 com sinal positivo. A tradução para a lista vem em cada questão. A numeração das linhas é contínua do início ao fim, para que "[(19)]" aponte sempre para a mesma linha.

Legenda:

- [RB]: ruído branco, $E(\varepsilon_t) = 0$, $E(\varepsilon_t^2) = \sigma^2$ e $E(\varepsilon_t \varepsilon_s) = 0$ se $t \neq s$;
-
- [F2]: série geométrica;
- [F3]: soma de Gauss;
- [F4]: linearidade da esperança;
- [F7]: igualar coeficientes;
- [F8]: multiplicar polinômios;
- [estac.]: os momentos não dependem da data;
- [caus.]: o choque de hoje não se correlaciona com o passado de y;
- [(n)]: usando a linha (n).

As ferramentas estão demonstradas na caixa de ferramentas.

Q5 · Três modelos: operador, classificação, raízes e pesos

Enunciado (lista, Q5). Três modelos em $\tilde{z}_t$ e a_t:

- (1) um AR(1) com coeficiente 0,5;
- (2) um MA(2) com −1,3 e +0,4;
- (3) os dois juntos.

Pede-se:

- escrever cada um com o operador de retardo e classificá-lo como ARMA(p, q);
- verificar estacionariedade e invertibilidade;
- obter $\psi_1, \ldots, \psi_4$ e $\pi_1, \ldots, \pi_4$.

Nos slides: $a_t = \varepsilon_t$ e $B = L$. Os pesos ψ_j e π_j **não dependem** da convenção do MA, porque $\tilde{z}_t = \sum \psi_j \varepsilon_{t-j}$ e $\tilde{z}_t = \sum \pi_j \tilde{z}_{t-j} + \varepsilon_t$ são as mesmas equações nas duas notações (AU02, p. 16 e 19).

Modelo (1): $\tilde{z}_t - 0{,}5\tilde{z}_{t-1} = \varepsilon_t$

(1)	$\tilde{z}_t - 0{,}5\,\tilde{z}_{t-1} = \varepsilon_t$	[lista]
(2)	$(1 - 0{,}5L)\,\tilde{z}_t = \varepsilon_t$	[operador de defasagem: $L\tilde{z}_t = \tilde{z}_{t-1}$]
(3)	$\phi(L) = 1 - 0{,}5L$ (grau 1), $\theta(L) = 1$ (grau 0) $\Rightarrow$ ARMA(1, 0)	[classifica]
(4)	$1 - 0{,}5z = 0 \Rightarrow z = 2$	[raiz do AR]
(5)	$\lvert z\rvert = 2 > 1 \Rightarrow$ estacionário	[AU02 p. 27]
(6)	não há polinômio MA $\Rightarrow$ invertível	[AU02 p. 36]
(7)	$\Psi(L) = (1 - 0{,}5L)^{-1} = \sum_{j\geq 0} 0{,}5^j L^j$	[F2, $\lvert 0{,}5\rvert < 1$]
(8)	$\psi_1 = 0{,}5;\ \psi_2 = 0{,}25;\ \psi_3 = 0{,}125;\ \psi_4 = 0{,}0625$	[$\psi_j = 0{,}5^j$]
(9)	$\pi(L) = 1 - 0{,}5L \Rightarrow \pi_1 = 0{,}5,\ \pi_2 = \pi_3 = \pi_4 = 0$	[já está na forma AR]

AR(1) : estacionário ($z = 2$) e invertível; $\psi_j = 0{,}5^j$; $\pi_1 = 0{,}5,\ \pi_{j\geq 2} = 0$

Modelo (2): $\tilde{z}_t = \varepsilon_t - 1{,}3\varepsilon_{t-1} + 0{,}4\varepsilon_{t-2}$

(10)	$\tilde{z}_t = \varepsilon_t - 1{,}3\,\varepsilon_{t-1} + 0{,}4\,\varepsilon_{t-2}$	[lista]
(11)	$\tilde{z}_t = (1 - 1{,}3L + 0{,}4L^2)\,\varepsilon_t,\quad \theta_1 = -1{,}3,\ \theta_2 = 0{,}4$	[slides: $\theta(L) = 1 + \theta_1 L + \theta_2 L^2$]
(12)	$\phi(L) = 1,\ \theta(L)$ de grau 2 $\Rightarrow$ ARMA(0, 2)	[classifica]
(13)	$\sum\lvert\psi_j\rvert = 1 + 1{,}3 + 0{,}4 = 2{,}7 < \infty \Rightarrow$ estacionário	[AU02 p. 29: MA finito]
(14)	$\theta(z) = 0 \iff 0{,}4z^2 - 1{,}3z + 1 = 0 :\quad a = 0{,}4,\ b = -1{,}3,\ c = 1$	[F1, forma padrão]
(15)	$\Delta = b^2 - 4ac = (-1{,}3)^2 - 4(0{,}4)(1) = 1{,}69 - 1{,}60 = 0{,}09$	[F1]
(16)	$z = \dfrac{-b \pm \sqrt{\Delta}}{2a} = \dfrac{1{,}3 \pm 0{,}3}{0{,}8} \Rightarrow z_1 = 2,\ z_2 = 1{,}25$	[F1, $\sqrt{0{,}09} = 0{,}3$]
(17)	$z_1 + z_2 = 3{,}25 = -b/a;\qquad z_1 z_2 = 2{,}5 = c/a$	[Vieta: confere]
(18)	$\lvert 2\rvert > 1$ e $\lvert 1{,}25\rvert > 1 \Rightarrow$ invertível	[AU02 p. 33]
(19)	$1 - 1{,}3L + 0{,}4L^2 = (1 - 0{,}5L)(1 - 0{,}8L)$	[F8: $1 - 0{,}8L - 0{,}5L + 0{,}4L^2$]
(20)	$\psi_1 = -1{,}3;\ \psi_2 = 0{,}4;\ \psi_3 = \psi_4 = 0$	[o MA já é a forma MA(∞)]

Pesos π, igualando coeficientes. Escreva $\theta(L)^{-1} = 1 + c_1 L + c_2 L^2 + \cdots$ e exija $\theta(L)^{-1}\theta(L) = 1$, potência por potência:

(21)	$(1 + c_1 L + c_2 L^2 + c_3 L^3 + \cdots)(1 - 1{,}3L + 0{,}4L^2) = 1$	[F7]
(22)	L^1 : $c_1 - 1{,}3 = 0 \Rightarrow c_1 = 1{,}3$	[coeficiente de L]
(23)	L^2 : $c_2 - 1{,}3c_1 + 0{,}4 = 0 \Rightarrow c_2 = 1{,}69 - 0{,}4 = 1{,}29$	[(22)]
(24)	L^3 : $c_3 - 1{,}3c_2 + 0{,}4c_1 = 0 \Rightarrow c_3 = 1{,}677 - 0{,}52 = 1{,}157$	[(22), (23)]
(25)	L^4 : $c_4 - 1{,}3c_3 + 0{,}4c_2 = 0 \Rightarrow c_4 = 1{,}5041 - 0{,}516 = 0{,}9881$	[(23), (24)]
(26)	$\pi(L) = \theta(L)^{-1} = 1 - \pi_1 L - \pi_2 L^2 - \cdots \Rightarrow \pi_j = -c_j$	[AU02 p. 19–20]
(27)	$\pi_1 = -1{,}3;\ \pi_2 = -1{,}29;\ \pi_3 = -1{,}157;\ \pi_4 = -0{,}9881$	[(22)–(26)]

MA(2) : estacionário; invertível ($z = 2;\ 1{,}25$); π_j decaem devagar, à taxa $1/1{,}25 = 0{,}8$

Modelo (3): $\tilde{z}_t - 0{,}5\tilde{z}_{t-1} = \varepsilon_t - 1{,}3\varepsilon_{t-1} + 0{,}4\varepsilon_{t-2}$

(28)	$(1-0{,}5L)\,\tilde{z}_t = (1-1{,}3L+0{,}4L^2)\,\varepsilon_t$	[lista em L]
(29)	$(1-0{,}5L)\,\tilde{z}_t = (1-0{,}5L)(1-0{,}8L)\,\varepsilon_t$	[(19)]
(30)	$\tilde{z}_t = (1-0{,}8L)\,\varepsilon_t$	[$\times(1-0{,}5L)^{-1}$, F2]
(31)	parece ARMA(1,2), mas é MA(1) = ARMA(0, 1)	[fator comum]
(32)	estacionário: MA finito	[AU02 p. 29]
(33)	$1-0{,}8z=0 \;\Rightarrow\; z=1{,}25>1 \;\Rightarrow$ invertível	[AU02 p. 33]
(34)	$\psi_1 = -0{,}8;\;\; \psi_j = 0,\; j \geq 2$	[(30)]

Conferência dos ψ pelo modelo inteiro, sem cancelar nada: exija $\Psi(L)(1-0{,}5L) = 1-1{,}3L+0{,}4L^2$ potência por potência.

(35)	$L^1 :\; \psi_1 - 0{,}5 = -1{,}3 \;\Rightarrow\; \psi_1 = -0{,}8$	[F7]
(36)	$L^2 :\; \psi_2 - 0{,}5\psi_1 = 0{,}4 \;\Rightarrow\; \psi_2 = 0{,}4 - 0{,}4 = 0$	[F7, (35)]
(37)	$\pi_j = -(-\theta_1)^j$ com $\theta_1 = -0{,}8 \;\Rightarrow\; \pi_j = -0{,}8^{\,j}$	[AU02 p. 23]
(38)	$\pi_1 = -0{,}8;\; \pi_2 = -0{,}64;\; \pi_3 = -0{,}512;\; \pi_4 = -0{,}4096$	[(37)]

fator comum $(1-0{,}5L)$: o modelo (3) é o MA(1) $\tilde{z}_t = \varepsilon_t - 0{,}8\varepsilon_{t-1}$ (lista: $\theta = 0{,}8$)

Como enxergar o fator comum sem fatorar: a raiz do AR, $z = 2$, aparece também entre as raízes do MA, $\{2;\; 1{,}25\}$.

Q6 · ARMA(1,1): o roteiro, com a demonstração completa ao lado

A Q6 está demonstrada por inteiro, em 43 linhas, na folha da Q2 e da Q6, com os nove termos de γ_0 na ordem do slide. Aqui fica o esqueleto, para conferir que nenhum passo foi esquecido. O modelo é $y_t - \mu = \phi_1(y_{t-1}-\mu) + \varepsilon_t + \theta_1\varepsilon_{t-1}$, com $\theta_1 = -\theta^{\text{lista}}$.

(39)	$E\big((y_t-\mu)\varepsilon_t\big) = \sigma^2, \quad E\big((y_{t+1}-\mu)\varepsilon_t\big) = (\phi_1+\theta_1)\sigma^2$	[momentos auxiliares]
(40)	$\gamma_0 = \phi_1^2\gamma_0 + 2\theta_1\phi_1\sigma^2 + \sigma^2 + \theta_1^2\sigma^2$	[nove termos, quatro zeros]
(41)	$\gamma_0 = \dfrac{\sigma^2(2\theta_1\phi_1 + 1 + \theta_1^2)}{1-\phi_1^2}$	[isola, AU02 p. 83]
(42)	$\gamma_1 = \phi_1\gamma_0 + \theta_1\sigma^2 = \dfrac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1-\phi_1^2}\,\sigma^2$	[$\times(y_{t-1}-\mu)$, AU02 p. 84]
(43)	$\gamma_k = \phi_1\gamma_{k-1} = \phi_1^{k-1}\gamma_1, \quad k \geq 2$	[caus.; indução]
(44)	$\rho_k = \phi_1^{k-1}\rho_1, \quad k \geq 1$	[$\div\gamma_0$]
(45)	$\psi_j = (\phi_1+\theta_1)\,\phi_1^{j-1}; \qquad \pi_j = (\phi_1+\theta_1)(-\theta_1)^{j-1}$	[F7, F2]
(46)	lista: $\psi_j = (\phi-\theta)\phi^{j-1}; \qquad \pi_j = (\phi-\theta)\theta^{j-1}$	[$\theta_1 = -\theta$]

Q7 · AR(2): Yule-Walker, ρ_1, ρ_2 e γ_0

Enunciado (lista, Q7). Para $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$:

- escrever as equações de Yule-Walker e obter ρ_1 e ρ_2 em função de ϕ_1 e ϕ_2;
- obter a variância γ_0.

Nos slides: a mesma notação (AU02, p. 66–69), com média zero.

> **Erro do caderno (03/09): o sinal de ϕ_2 ao montar o polinômio**
>
> No exemplo $\phi_1 = 1{,}5$ e $\phi_2 = -0{,}6$, o polinômio virou $1 - 1{,}5B - 0{,}6B^2$. O certo é $1 - \phi_1 B - \phi_2 B^2 = 1 - 1{,}5B + 0{,}6B^2$, porque $-\phi_2 B^2 = -(-0{,}6)B^2$. Daí o Δ do caderno saiu errado e os módulos 0,6 e 0,52 também; o certo é $\sqrt{0{,}6} = 0{,}7746$.

(47) $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t, \quad E(y_t) = 0$ [modelo]

(48) $E(\varepsilon_t\, y_{t-k}) = 0, \quad k \geq 1$ [caus.]

(49) $E(\varepsilon_t\, y_t) = 0 + 0 + E(\varepsilon_t^2) = \sigma^2$ [F4; (48) zera dois termos]

(50) $\times\, y_{t-1}\ :\ \ \gamma_1 = \phi_1\gamma_0 + \phi_2\gamma_1$ [$E(y_{t-2}y_{t-1}) = \gamma_1$, (48)]

(51) $\times\, y_{t-2}\ :\ \ \gamma_2 = \phi_1\gamma_1 + \phi_2\gamma_0$ [(48)]

(52) $\rho_1 = \phi_1 + \phi_2\rho_1; \qquad \rho_2 = \phi_1\rho_1 + \phi_2$ [$\div\gamma_0$: Yule-Walker, AU02 p. 68–69]

(53) $\rho_1(1-\phi_2) = \phi_1 \ \Rightarrow\ \rho_1 = \dfrac{\phi_1}{1-\phi_2}$ [(52)]

(54) $\rho_2 = \dfrac{\phi_1^2}{1-\phi_2} + \phi_2 = \dfrac{\phi_1^2 + \phi_2 - \phi_2^2}{1-\phi_2}$ [(53); denominador comum]

(55) $\times\, y_t\ :\ \ \gamma_0 = \phi_1\gamma_1 + \phi_2\gamma_2 + \sigma^2$ [(49)]

(56) $\gamma_0 = \dfrac{\sigma^2}{1 - \phi_1\rho_1 - \phi_2\rho_2}$ [(55) $\div\,\gamma_0$, isola]

(57) $1 - \phi_1\rho_1 - \phi_2\rho_2 = \dfrac{(1-\phi_2) - \phi_1^2 - \phi_2(\phi_1^2 + \phi_2 - \phi_2^2)}{1-\phi_2}$ [(53), (54)]

(58) $\text{numerador} = (1-\phi_2)(1-\phi_2^2) - \phi_1^2(1+\phi_2)$ [agrupa]

(59) $\qquad\qquad = (1+\phi_2)\big[(1-\phi_2)^2 - \phi_1^2\big]$ [$1-\phi_2^2 = (1-\phi_2)(1+\phi_2)$]

(60) $\gamma_0 = \dfrac{(1-\phi_2)\,\sigma^2}{(1+\phi_2)\big[(1-\phi_2)^2 - \phi_1^2\big]}$ [(56)–(59)]

(61) $(1-\phi_2)^2 - \phi_1^2 = (1-\phi_2-\phi_1)(1-\phi_2+\phi_1)$ [diferença de quadrados]

(62) $\gamma_0 > 0 \iff 1+\phi_2 > 0,\ \ \phi_1+\phi_2 < 1,\ \ \phi_2 - \phi_1 < 1$ [o triângulo, AU02 p. 41]

$$\boxed{\rho_1 = \frac{\phi_1}{1-\phi_2}, \qquad \rho_2 = \frac{\phi_1^2 + \phi_2 - \phi_2^2}{1-\phi_2}, \qquad \gamma_0 = \frac{(1-\phi_2)\,\sigma^2}{(1+\phi_2)\big[(1-\phi_2)^2 - \phi_1^2\big]}}$$

Em (56), divide-se (55) por γ_0: $1 = \phi_1\rho_1 + \phi_2\rho_2 + \sigma^2/\gamma_0$. Em (58), $(1-\phi_2) - \phi_2^2(1-\phi_2) = (1-\phi_2)(1-\phi_2^2)$. Em (62), os três fatores de (60)–(61) são exatamente as três desigualdades do triângulo de estacionariedade. A variância só existe, e é positiva, dentro dele.

Com o exemplo do caderno, $\phi_1 = 1{,}5$ e $\phi_2 = -0{,}6$:

- $\rho_1 = 1{,}5/1{,}6 = 0{,}9375$ e $\rho_2 = 0{,}80625$;
- os fatores são $1+\phi_2 = 0{,}4$, $1-\phi_2-\phi_1 = 0{,}1$ e $1-\phi_2+\phi_1 = 3{,}1$, todos positivos;

- $\gamma_0 = 12{,}9032\,\sigma^2$. A variância é grande porque o fator 0,1 está perto de zero: o processo está perto da borda do triângulo.

Q8 · Verdadeiro ou falso, com demonstração

Enunciado (lista, Q8). São dois modelos, e cinco afirmativas para julgar com demonstração:

- **(I)** $Y_t = \alpha Y_{t-1} + u_t + \beta u_{t-1}$, com $0 < \alpha < 1$;
- **(II)** $Z_t = c + Z_{t-1} + \theta t + \varepsilon_t$.

Nos slides: a Q8 **já usa o sinal positivo**. O (I) é o ARMA(1,1) da AU02, p. 81, com $\phi_1 = \alpha$ e $\theta_1 = \beta$. O (II) é o passeio com drift e tendência da AU01, p. 30, com $\alpha_1 = c$ e $\alpha_2 = \theta$. Mantenho as letras da lista, e $\gamma_h = E(Y_t Y_{t+h})$.

Momentos auxiliares do (I):

$$
\begin{aligned}
&(63)\quad E(Y_{t-1}u_t) = 0 && \text{[caus.]}\\
&(64)\quad E(Y_t u_t) = \alpha E(Y_{t-1}u_t) + E(u_t^2) + \beta E(u_{t-1}u_t) = \sigma^2 && \text{[F4, (63), RB]}\\
&(65)\quad E(Y_t u_{t-1}) = \alpha E(Y_{t-1}u_{t-1}) + E(u_t u_{t-1}) + \beta E(u_{t-1}^2) = (\alpha+\beta)\sigma^2 && \text{[(64) em } t-1,\ \text{RB]}
\end{aligned}
$$

Afirmativa 1: $\gamma_0 = \alpha\gamma_1 + \sigma^2 + \beta(\alpha+\beta)\sigma^2$.

$$
\begin{aligned}
&(66)\quad \gamma_0 = E(Y_t Y_t) = \alpha E(Y_{t-1}Y_t) + E(u_t Y_t) + \beta E(u_{t-1}Y_t) && \text{[modelo} \times Y_t\text{]}\\
&(67)\quad = \alpha\gamma_1 + \sigma^2 + \beta(\alpha+\beta)\sigma^2 \ \Rightarrow\ \textbf{VERDADEIRA} && \text{[(64), (65)]}
\end{aligned}
$$

Afirmativa 2: $\gamma_1 = \alpha(\gamma_0 + \sigma^2) + \beta\sigma^2$.

$$
\begin{aligned}
&(68)\quad \gamma_1 = E(Y_{t+1}Y_t) = \alpha E(Y_t Y_t) + E(u_{t+1}Y_t) + \beta E(u_t Y_t) && \text{[modelo em } t+1,\ \times Y_t\text{]}\\
&(69)\quad = \alpha\gamma_0 + 0 + \beta\sigma^2 && \text{[caus.: } u_{t+1} \text{ é futuro; (64)]}\\
&(70)\quad \text{afirmativa} - \text{certo} = \alpha\sigma^2 \neq 0 \ \Rightarrow\ \textbf{FALSA} && [\alpha > 0]
\end{aligned}
$$

Afirmativa 3: $\rho_h = \frac{(\beta+\alpha)(1+\alpha\beta)}{1+2\alpha\beta+\beta^2}$ para todo h.

$$
\begin{aligned}
&(71)\quad \gamma_0 = \frac{1+2\alpha\beta+\beta^2}{1-\alpha^2}\sigma^2, \quad \gamma_1 = \frac{(1+\alpha\beta)(\alpha+\beta)}{1-\alpha^2}\sigma^2 && \text{[(67), (69)]}\\
&(72)\quad \rho_1 = \frac{(\alpha+\beta)(1+\alpha\beta)}{1+2\alpha\beta+\beta^2} && \text{[(71)]}\\
&(73)\quad \gamma_h = \alpha\gamma_{h-1},\ h \geq 2 \ \Rightarrow\ \rho_h = \alpha^{h-1}\rho_1 && \text{[caus.; (43)]}\\
&(74)\quad \text{a expressão só vale em } h = 1;\ \text{para } h \geq 2 \text{ falta } \alpha^{h-1} \ \Rightarrow\ \textbf{FALSA} && \text{[(72), (73)]}
\end{aligned}
$$

Em (71), resolve-se o sistema formado por (67) e (69), como na Q6.

Afirmativa 4: $Z_t = ct + \frac{\theta}{2}t^2 + Z_0 + \sum_{j=1}^{t}\varepsilon_j$.

$$
\begin{aligned}
&(75)\quad Z_s - Z_{s-1} = c + \theta s + \varepsilon_s && \text{[modelo]}\\
&(76)\quad Z_t - Z_0 = ct + \theta\textstyle\sum_{s=1}^{t} s + \sum_{s=1}^{t}\varepsilon_s && \text{[soma de 1 a } t,\ \text{telescópica]}\\
&(77)\quad Z_t = Z_0 + ct + \theta\frac{t(t+1)}{2} + \textstyle\sum_{j=1}^{t}\varepsilon_j && \text{[F3]}\\
&(78)\quad \theta\frac{t(t+1)}{2} = \frac{\theta}{2}t^2 + \frac{\theta}{2}t \neq \frac{\theta}{2}t^2 \ \Rightarrow\ \textbf{FALSA} && \text{[falta } \theta t/2\text{]}
\end{aligned}
$$

Afirmativa 5: $V(Z_t) = (c + \theta t)\sigma^2$.

$$V(Z_t) = V\Big(\sum_{j=1}^{t} \varepsilon_j\Big) \qquad [(77):\ Z_0,\ ct,\ \theta t(t+1)/2 \text{ são constantes}] \tag{79}$$

$$= \sum_{j=1}^{t} V(\varepsilon_j) = t\sigma^2 \neq (c + \theta t)\sigma^2 \ \Rightarrow\ \textbf{FALSA} \qquad [\text{RB: sem covariâncias}] \tag{80}$$

Gabarito da Q8: V, F, F, F, F

Versão para a prova

Q5, para cada modelo, quatro linhas:

1. Escreva em L e diga o grau de $\phi(L)$ e de $\theta(L)$.
2. Calcule as raízes: $\phi(z)$ para a estacionariedade e $\theta(z)$ para a invertibilidade, com Bhaskara e Vieta.
3. Obtenha os ψ por $\Psi(L)\phi(L) = \theta(L)$ e os π por $\pi(L)\theta(L) = \phi(L)$, potência por potência.
4. **Procure raiz repetida dos dois lados**: no modelo (3), o fator $(1 - 0{,}5L)$ cancela, e sobra um MA(1).

Q6: as linhas (39)–(46), ou a versão de 10 itens da folha da Q6.

Q7:

1. Multiplique por y_{t-1} e y_{t-2} e divida por γ_0: $\rho_1 = \phi_1/(1 - \phi_2)$ e $\rho_2 = \phi_1\rho_1 + \phi_2$.
2. Multiplique por y_t: $\gamma_0 = \sigma^2/(1 - \phi_1\rho_1 - \phi_2\rho_2)$.
3. Simplifique até (60).
4. Feche com o triângulo.

Q8:

1. Escreva os dois momentos auxiliares.
2. Em cada item, a conta que leva à expressão certa e a comparação com a afirmativa.
3. Gabarito V, F, F, F, F. **Sem conta, V ou F vale zero.**

Conferência

Todos os números desta folha vêm do R e são conferidos por dois caminhos.

Q5:

- as raízes 2 e 1,25 saem iguais pelo `polyroot`;
- os π_j do modelo (2) por (22)–(27) coincidem com os do helper do repositório, com diferença 0;
- os ψ_j do modelo (3) escrito inteiro e os do MA(1) cancelado coincidem até $j = 20$, com diferença 0.

Q7: $\gamma_0 = 12{,}9032$ pela fórmula (60), por (56) e pela autocovariância do R.

Q8, com $\alpha = 0{,}6$, $\beta = 0{,}3$ e $\sigma^2 = 1$:

- $\gamma_0 = 2{,}265625$, e o lado direito da afirmativa 1 dá o mesmo;
- $\gamma_1 = 1{,}659375$, contra os 2,259375 da afirmativa 2;
- $\rho_1 = 0{,}7324$ e $\rho_2 = 0{,}4394$;
- com $c = 1$, $\theta = 0{,}5$ e $t = 4$: $E(Z_4) = 9$, contra 8 da afirmativa 4, e $V(Z_4) = 4$, contra 3 da afirmativa 5.

Parte III

Bloco 3 à mão: Q9 a Q12

Cap. 3 à mão — Q9 a Q12 linha a linha

Cap. 3 à mão: Q9 a Q12, linha a linha

← capítulo 3 · ← apostila · cap. 2 à mão

Versão de **caderno** do bloco 3 da lista: cada passagem numerada, uma operação por linha e o motivo entre colchetes. A numeração é contínua. Os símbolos são os dos slides; o MA, inclusive o sazonal, usa o sinal positivo, com $\theta_1 = -\theta^{\text{lista}}$ e $\Theta_1 = -\Theta^{\text{lista}}$. O lado AR é igual nas duas notações.

Legenda:

- [RB]: ruído branco;
- [F2]: série geométrica;
- [F4]: linearidade da esperança;
- [F5]: covariância de combinações lineares;
- [F7]: igualar coeficientes;
- [F8]: multiplicar polinômios;
- [F9]: esperança condicional na previsão (o que é conhecido fica, choque futuro é zero, y futuro vira previsão);
- [caus.]: o choque de hoje não se correlaciona com o passado;
- [(n)]: usando a linha (n).

Q9 · Sobrediferenciar um AR(1) estacionário

Enunciado (lista, Q9). $y_t = \phi y_{t-1} + \varepsilon_t$, com $|\phi| < 1$, e $w_t = \Delta y_t$. Pede-se:

- (a) mostrar que $w_t = -(1-\phi)y_{t-1} + \varepsilon_t$ e que $(1-\phi B)w_t = (1-B)\varepsilon_t$, identificando os polinômios;
- (b) mostrar que o MA tem raiz unitária e discutir o AR(∞);
- (c) discutir por que diferenciar uma série estacionária é prejudicial.

(1)	$w_t = y_t - y_{t-1} = \phi y_{t-1} + \varepsilon_t - y_{t-1}$	[modelo]
(2)	$w_t = -(1-\phi)\, y_{t-1} + \varepsilon_t$	[agrupa y_{t-1}]
(3)	$y_t = (1-\phi L)^{-1}\varepsilon_t = \sum_{j\geq 0} \phi^j \varepsilon_{t-j}$	[MA(∞), F2, $\|\phi\| < 1$]
(4)	$w_t = (1-L)\, y_t = (1-L)(1-\phi L)^{-1}\varepsilon_t$	[(3)]
(5)	$(1-\phi L)\, w_t = (1-L)\, \varepsilon_t$	[$\times(1-\phi L)$]
(6)	$\phi(L) = 1-\phi L$; $\theta(L) = 1 - L$ ($\theta_1 = -1$; lista: $\theta = 1$) $\Rightarrow$ ARMA(1,1)	[identifica]
(7)	$\theta(z) = 1 - z = 0 \Rightarrow z = 1$, $\|z\| = 1$	[raiz sobre o círculo]
(8)	a raiz não está fora do círculo $\Rightarrow$ não invertível	[AU02 p. 33]
(9)	$\pi(L) = \dfrac{1-\phi L}{1-L} = (1-\phi L)(1 + L + L^2 + \cdots)$	[F2 com razão 1: formal]
(10)	$= 1 + (1-\phi)L + (1-\phi)L^2 + \cdots \Rightarrow \pi_j = -(1-\phi)$, $j \geq 1$	[F7]
(11)	$\sum_j \|\pi_j\| = \sum_j (1-\phi) = \infty \Rightarrow$ sem AR(∞) convergente	[(10)]
(12)	$\gamma_w(0) = E\big((y_t - y_{t-1})^2\big) = 2\gamma_0 - 2\gamma_1 = 2\gamma_0(1-\phi)$	[F5, $\gamma_1 = \phi\gamma_0$]
(13)	$\gamma_w(1) = 2\gamma_1 - \gamma_0 - \gamma_2 = -\gamma_0(1-\phi)^2$	[F5, $\gamma_2 = \phi^2\gamma_0$]
(14)	$\rho_w(1) = -\frac{1-\phi}{2} \in \big(-\frac{1}{2}, 0\big)$	[(13) ÷ (12)]
(15)	$\gamma_w(0) = \dfrac{2\sigma^2}{1+\phi} > \gamma_0 = \dfrac{\sigma^2}{1-\phi^2} \iff 2(1-\phi) > 1 \iff \phi < \frac{1}{2}$	[(12), γ_0 do AR(1)]

$$\boxed{(1-\phi L)\, w_t = (1-L)\, \varepsilon_t \ :\ \text{MA com raiz } z = 1,\ \text{não invertível, sem AR(}\infty\text{)};\quad \rho_w(1) = -\tfrac{1-\phi}{2}}$$

(c) Por que é prejudicial.

(16)	estimação: $\hat{\theta}_1$ encosta em -1	[raiz no círculo]
(17)	com $\varepsilon_0 = 0$, o erro do chute pesa $(-\theta_1)^t = 1$ para sempre	[MV condicional]
(18)	modelo em diferenças: $\mathrm{Var}(e_{T+h})$ cresce com h	[choque permanente]
(19)	o verdadeiro é estacionário: $\mathrm{Var}(e_{T+h}) \to \gamma_0$, limitada	[cap. 5, D5.3]
(20)	com $\phi < \frac{1}{2}$, a variância da série aumenta: acrescenta-se ruído	[(15)]

Q10 · ARIMA, tendência determinística e sobrediferenciação

Enunciado (lista, Q10). São cinco itens:

- (a) ARIMA$(p,1,q)$ na diferença é um ARMA(p,q);
- (b) expandir o ARIMA(1,1,1);
- (c) raiz unitária × tendência determinística;

- (d) diferenciar uma série com tendência só determinística;
- (e) por que a regressão em t é preferível.

(21) $\phi(L)\,(1-L)\,y_t = \theta(L)\,\varepsilon_t$ [ARIMA$(p,1,q)$]
(22) $w_t \equiv (1-L)\,y_t \;\Rightarrow\; \phi(L)\,w_t = \theta(L)\,\varepsilon_t$ [substitui]
(23) raízes de $\phi(z), \theta(z)$ fora do círculo $\Rightarrow w_t \sim$ ARMA(p,q) [AU02 p. 27, 33]

(b) ARIMA(1,1,1), na lista: $(1-\phi B)(1-B)y_t = (1-\theta B)a_t$.

(24) $(1-\phi B)(1-B) = 1 - B - \phi B + \phi B^2 = 1 - (1+\phi)B + \phi B^2$ [F8]
(25) $y_t - (1+\phi)\,y_{t-1} + \phi\,y_{t-2} = a_t - \theta\,a_{t-1}$ [aplica a y_t]
(26) $y_t = (1+\phi)\,y_{t-1} - \phi\,y_{t-2} + a_t - \theta\,a_{t-1}$ [isola y_t]
(27) soma dos coeficientes AR $= (1+\phi) - \phi = 1 \;\Rightarrow\; \phi(1) = 0$: raiz unitária [confere]

(c), (d) e (e): TS × DS.

(28) TS: $y_t = \alpha + \beta t + u_t$ (u_t estac.); $\partial y_{t+h}/\partial u_t = \psi_h \to 0$ [transitório]
(29) DS: $y_t = y_0 + \beta t + \sum_{s=1}^{t} u_s$; $\partial y_{t+h}/\partial u_t = 1$ [choque permanente]
(30) Var(y_t) : TS constante; DS cresce com t [AU01 p. 28–30]
(31) (d): $\Delta y_t = \beta + u_t - u_{t-1} = \beta + (1-L)\,u_t$ [(28) em t e $t-1$]
(32) $\gamma_0 = 2\sigma^2,\ \gamma_1 = -\sigma^2,\ \rho_1 = -\frac{1}{2};\ \theta(z) = 1 - z \Rightarrow z = 1$ [u_t RB; não invertível]
(33) (e): MQO de y_t em $(1,t)$: $\hat{u}_t = y_t - \hat{\alpha} - \hat{\beta} t$ estima u_t [MQO]
(34) $\hat{u}_t$ herda o ARMA de u_t, sem o fator $(1-L)$ [(31) evitado]

DS → diferença; TS → regressão em t; Δ(TS) cria $(1-L)$ no MA: sobrediferenciação

Q11 · SAR(1)$_4$ e o multiplicativo

Enunciado (lista, Q11). $y_t = \Phi_1 y_{t-4} + \varepsilon_t$, com $|\Phi_1| < 1$. Pede-se:

- (a) $\gamma_0, \gamma_4, \gamma_8, \gamma_k$ nos múltiplos de 4 e o que acontece fora deles;
- (b) a FAC e a FACP, comparadas com o AR(1);
- (c) o SARIMA$(1,0,0)(1,0,0)_4$ escrito como AR(5) restrito.

(35)	$\gamma_0 = E\big((\Phi_1 y_{t-4} + \varepsilon_t)^2\big) = \Phi_1^2\gamma_0 + 2\Phi_1 E(y_{t-4}\varepsilon_t) + \sigma^2$	[F4]
(36)	$\gamma_0 = \Phi_1^2\gamma_0 + 0 + \sigma^2 \;\Rightarrow\; \gamma_0 = \dfrac{\sigma^2}{1-\Phi_1^2}$	[caus.; isola]
(37)	$\gamma_k = E(y_t y_{t-k}) = \Phi_1\gamma_{k-4} + E(\varepsilon_t y_{t-k}) = \Phi_1\gamma_{k-4}, \;\; k \geq 1$	[caus.]
(38)	$\gamma_4 = \Phi_1\gamma_0, \quad \gamma_8 = \Phi_1\gamma_4 = \Phi_1^2\gamma_0, \quad \gamma_{4j} = \Phi_1^j\gamma_0$	[(37), indução]
(39)	$k=2:\ \gamma_2 = \Phi_1\gamma_{-2} = \Phi_1\gamma_2 \;\Rightarrow\; (1-\Phi_1)\gamma_2 = 0 \;\Rightarrow\; \gamma_2 = 0$	[$\gamma_{-k} = \gamma_k$]
(40)	$k = 1$ e $3:\ \gamma_1 = \Phi_1\gamma_3,\ \gamma_3 = \Phi_1\gamma_1 \;\Rightarrow\; (1-\Phi_1^2)\gamma_1 = 0$	[(37)]
(41)	$\gamma_1 = \gamma_3 = 0,$ e por (37) os zeros se propagam a $5, 6, 7, 9, \ldots$	[$\lvert\Phi_1\rvert < 1$]
(42)	FAC: $\rho_{4j} = \Phi_1^j$; $\rho_k = 0$ fora dos múltiplos de 4	[(38)–(41)]
(43)	FACP: $\phi_{44} = \Phi_1$ e $\phi_{kk} = 0$ para $k \neq 4$	[AU02 p. 93]
(44)	comparação: o AR(1) "esticado" por 4; o AR(1) tem $\rho_k = \phi^k$ em todo k	[cap. 2, D2.4]

(c) O multiplicativo: $(1-\phi L)(1-\Phi L^4)\, y_t = \varepsilon_t$.

(45)	$(1-\phi L)(1-\Phi L^4) = 1 - \phi L - \Phi L^4 + \phi\Phi L^5$	[F8: quatro produtos]
(46)	$y_t = \phi\, y_{t-1} + \Phi\, y_{t-4} - \phi\Phi\, y_{t-5} + \varepsilon_t$	[isola y_t]
(47)	AR(5): $\phi_1 = \phi,\ \phi_2 = \phi_3 = 0,\ \phi_4 = \Phi,\ \phi_5 = -\phi\Phi$	[compara]
(48)	restrições: $\phi_2 = 0,\ \phi_3 = 0,\ \phi_5 = -\phi_1\phi_4$; livres: $5 - 3 = 2$	[parcimônia]

$\gamma_{4j} = \Phi_1^j\gamma_0,\ \gamma_k = 0$ fora dos múltiplos;	$(1-\phi L)(1-\Phi L^4) =$ AR(5) com $\phi_2 = \phi_3 = 0,\ \phi_5 = -\phi_1\phi_4$

Q12 · SARIMA$(1,1,0)(0,1,1)_4$: modelo, perdas, previsão e diagnóstico

Enunciado (lista, Q12). Série trimestral com SARIMA$(1,1,0)(0,1,1)_4$. Pede-se:

- (a) o modelo em B;
- (b) as observações perdidas;
- (c) as previsões em $h = 1, 2, 4, 5$ e a propagação da sazonalidade;
- (d) o diagnóstico de resíduos.

Nos slides: $(1-\phi L)(1-L)(1-L^4)\, y_t = (1+\Theta_1 L^4)\, \varepsilon_t$, com $\Theta_1 = -\Theta^{\text{lista}}$. Na lista: $(1-\phi B)(1-B)(1-B^4)y_t = (1-\Theta B^4)a_t$.

(49) $(1-\phi L)(1-L) = 1-(1+\phi)L+\phi L^2$ [F8]

(50) $\big(1-(1+\phi)L+\phi L^2\big)(1-L^4) = 1-(1+\phi)L+\phi L^2-L^4+(1+\phi)L^5-\phi L^6$ [F8]

(51) $y_t = (1+\phi)y_{t-1}-\phi y_{t-2}+y_{t-4}-(1+\phi)y_{t-5}+\phi y_{t-6}+\varepsilon_t+\Theta_1\varepsilon_{t-4}$ [isola y_t]

(52) $w_t = (1-L)(1-L^4)\,y_t = y_t-y_{t-1}-y_{t-4}+y_{t-5}$ [F8]

(53) w_t precisa de y_{t-5} : o primeiro é w_6; perdem-se $d+sD = 1+4 = 5$ [(52)]

(c) Previsões. Escreva (51) na data $T+h$ e aplique [F9]. Notação: $\hat{y}(h) = \hat{y}_{T+h/T}$.

(54) $\hat{y}(1) = (1+\phi)y_T-\phi y_{T-1}+y_{T-3}-(1+\phi)y_{T-4}+\phi y_{T-5}+\Theta_1\varepsilon_{T-3}$ [$\varepsilon_{T+1}\to 0$]

(55) $\hat{y}(2) = (1+\phi)\hat{y}(1)-\phi y_T+y_{T-2}-(1+\phi)y_{T-3}+\phi y_{T-4}+\Theta_1\varepsilon_{T-2}$ [F9]

(56) $\hat{y}(3) = (1+\phi)\hat{y}(2)-\phi\hat{y}(1)+y_{T-1}-(1+\phi)y_{T-2}+\phi y_{T-3}+\Theta_1\varepsilon_{T-1}$ [intermediário]

(57) $\hat{y}(4) = (1+\phi)\hat{y}(3)-\phi\hat{y}(2)+y_T-(1+\phi)y_{T-1}+\phi y_{T-2}+\Theta_1\varepsilon_T$ [último choque]

(58) $\hat{y}(5) = (1+\phi)\hat{y}(4)-\phi\hat{y}(3)+\hat{y}(1)-(1+\phi)y_T+\phi y_{T-1}$ [o MA some]

(59) $h\geq 5$: $(1-\phi L)(1-L)(1-L^4)\,\hat{y}(h) = 0$ [só a parte AR generalizada]

(60) raízes: 1 (dupla), -1, $\pm i$, $1/\phi$ [$z^4=1$ e $1-\phi z=0$]

A sazonalidade se propaga pelo termo y_{T+h-4}, ou $\hat{y}(h-4)$, que copia o mesmo trimestre do ano anterior. O MA sazonal corrige esse desenho com os quatro últimos choques e **some a partir de** $h = 5$. Por (60), a função de previsão de longo prazo é tendência linear, mais padrão sazonal fixo de período 4, mais um termo ϕ^h que se apaga.

(d) Diagnóstico de resíduos (AU03):

(61) gráficos: resíduos padronizados, histograma, QQ-plot, FAC [AU03 p. 10]

(62) $LB(K) = T(T+2)\sum_{i=1}^{K}\frac{\hat{\rho}_i^2}{T-i}\sim\chi^2_{K-p-q-P-Q} = \chi^2_{K-2}$ [AU03 p. 15]

(63) pico nas defasagens 4 ou 8: parte sazonal mal especificada [sazonal]

(64) $JB = \frac{n}{6}\hat{S}^2+\frac{n}{24}(\widehat{K}-3)^2\sim\chi^2_2$ [Jarque-Bera]

(65) ARCH-LM e FAC de $\hat{\varepsilon}_t^2$ [AU03 p. 19–22]

(66) estabilidade: Chow numa data escolhida antes, CUSUM [AU03 p. 25–31]

(67) $\widehat{\Theta}_1\approx -1\Rightarrow$ sobrediferenciação sazonal: usar dummies com $D=0$ [(7)–(8) na escala 4]

(68) Breusch-Godfrey: $\hat{\varepsilon}_t$ nas próprias defasagens, $nR^2\sim\chi^2_m$ [AU03 p. 18]

A linha (64) é o teste de Jarque-Bera da AU03, p. 11–14.

Versão para a prova

Q9:

1. $w_t = -(1-\phi)y_{t-1}+\varepsilon_t$.
2. Aplique $(1-L)$ aos dois lados de $(1-\phi L)y_t = \varepsilon_t$: $(1-\phi L)w_t = (1-L)\varepsilon_t$.
3. A raiz do MA é $z=1$: não invertível, $\pi_j = -(1-\phi)$ não somáveis, sem AR(∞).
4. A assinatura é $\rho_w(1) = -(1-\phi)/2$.
5. Custos: estimação na fronteira, previsão com variância que cresce e, se $\phi<\frac{1}{2}$, mais variância.

Q10:

1. $\phi(L)w_t = \theta(L)\varepsilon_t$.
2. $y_t = (1+\phi)y_{t-1} - \phi y_{t-2} + a_t - \theta a_{t-1}$, com a soma dos coeficientes AR igual a 1.
3. TS tem choque transitório, DS permanente.
4. A diferença de uma TS é $\beta + (1-L)u_t$, não invertível. O certo é regredir em t.

Q11:

1. $\gamma_0 = \sigma^2/(1-\Phi_1^2)$ e $\gamma_{4j} = \Phi_1^j \gamma_0$.
2. Prove $\gamma_1 = \gamma_2 = \gamma_3 = 0$ pelas linhas (39)–(41).
3. A FACP tem um pico só, em 4.
4. Multiplicativo: AR(5) com $\phi_2 = \phi_3 = 0$ e $\phi_5 = -\phi_1\phi_4$.

Q12:

1. Expanda em duas etapas, (49)–(51).
2. Perdem-se 5 observações.
3. As previsões vêm de (54)–(58): o MA some em $h = 5$, e y_{T+h-4} propaga a sazonalidade.
4. Diagnóstico: as linhas (61)–(68).

Conferência

Q9 e Q10:

- $\rho_w(1)$ é $-0{,}40$, $-0{,}25$ e $-0{,}05$ para $\phi = 0{,}2$, $0{,}5$ e $0{,}9$, com $-0{,}25$ conferido pelo `ARMAacf`;
- Var(w) é 1,6667, 1,3333 e 1,0526, contra os 1,0417, 1,3333 e 5,2632 de Var(y), o que confirma o limiar $\phi = \frac{1}{2}$ de (15);
- a diferença de um ruído branco tem $\rho_1 = -0{,}5$;
- na Q10(b), com $\phi = 0{,}5$ e $\theta = 0{,}3$, os coeficientes AR são 1,5 e $-0{,}5$, e somam 1.

Q11, com $\Phi_1 = 0{,}6$:

- $\gamma_0 = 1{,}5625$, $\gamma_4 = 0{,}9375$ e $\gamma_8 = 0{,}5625$;
- pelo R, $\rho_1 = 0$, $\rho_4 = 0{,}6$ e $\rho_8 = 0{,}36$;
- o multiplicativo com $\phi = 0{,}5$ dá $\phi_5 = -0{,}3$.

Q12, com $\phi = 0{,}4$ e $\Theta^{\text{lista}} = 0{,}6$:

- os coeficientes de y_{t-1} a y_{t-6} são 1,4; $-0{,}4$; 0; 1; $-1{,}4$; 0,4;
- as previsões de (54)–(58), aplicadas a uma série simulada com os resíduos do modelo, coincidem com o `predict` do R em $h = 1$ a 5, com diferença máxima da ordem de 10^{-13};
- perdem-se 5 observações.

Parte IV

Bloco 4 à mão: Q13 e Q14

Cap. 4 à mão — Q13 e Q14 linha a linha

Cap. 4 à mão: Q13 e Q14, linha a linha

← capítulo 4 · ← apostila · cap. 3 à mão

Versão de **caderno** do bloco 4 da lista: cada passagem numerada, uma operação por linha e o motivo entre colchetes. A numeração é contínua. Os símbolos são os dos slides: ϕ_1, ε_t, $\ln L$, T observações.

Legenda:

- [RB]: ruído branco;
- [F4]: linearidade da esperança;
- [CPO]: condição de primeira ordem, a derivada igual a zero;
- [(n)]: usando a linha (n).

Q13 · AR(1): log-verossimilhança condicional e MQO

Enunciado (lista, Q13). Para $y_t = \phi y_{t-1} + \varepsilon_t$, com $\varepsilon_t \sim N(0, \sigma^2)$: escrever a log-verossimilhança condicional em y_1 e obter o estimador de MQO de ϕ.

Nos slides: AU02, p. 77–80, com $\phi = \phi_1$ e sem constante.

(1) $y_t \mid y_{t-1} \sim N(\phi y_{t-1},\ \sigma^2)$ [ε_t normal]

(2) $f(y_t \mid y_{t-1}) = (2\pi\sigma^2)^{-1/2} \exp\Big(- \dfrac{(y_t - \phi y_{t-1})^2}{2\sigma^2} \Big)$ [densidade normal]

(3) $f(y_2, \dots, y_T \mid y_1) = \prod_{t=2}^{T} f(y_t \mid y_{t-1})$ [fatoração, AU02 p. 80]

(4) $\ln L = \sum_{t=2}^{T} \ln f(y_t \mid y_{t-1})$ [ln do produto]

(5) $\ln f(y_t \mid y_{t-1}) = -\frac{1}{2}\ln(2\pi) - \frac{1}{2}\ln\sigma^2 - \dfrac{(y_t - \phi y_{t-1})^2}{2\sigma^2}$ [ln de (2)]

(6) $\ln L(\phi, \sigma^2 \mid y_1) = -\frac{T-1}{2}\ln(2\pi) - \frac{T-1}{2}\ln\sigma^2 - \dfrac{S(\phi)}{2\sigma^2}$ [$T-1$ termos]

(7) $S(\phi) \equiv \sum_{t=2}^{T} (y_t - \phi y_{t-1})^2$ [soma de quadrados]

(8) $\dfrac{\partial \ln L}{\partial \phi} = -\dfrac{1}{2\sigma^2} S'(\phi)$ [só S depende de ϕ]

(9) $S'(\phi) = \sum_{t=2}^{T} 2(y_t - \phi y_{t-1})(-y_{t-1})$ [regra da cadeia]

(10) $\dfrac{\partial \ln L}{\partial \phi} = \dfrac{1}{\sigma^2} \sum_{t=2}^{T} (y_t - \phi y_{t-1})\, y_{t-1} = 0$ [CPO]

(11) $\sum_{t=2}^{T} y_t y_{t-1} - \phi \sum_{t=2}^{T} y_{t-1}^2 = 0$ [distributiva]

(12) $\hat{\phi} = \dfrac{\sum_{t=2}^{T} y_t y_{t-1}}{\sum_{t=2}^{T} y_{t-1}^2}$ [isola]

(13) é o MQO de y_t em y_{t-1} : $\min_{\phi} S(\phi)$ [(6) : $\max \ln L \iff \min S$]

(14) $\dfrac{\partial^2 \ln L}{\partial \phi^2} = -\dfrac{1}{\sigma^2} \sum_{t=2}^{T} y_{t-1}^2 < 0$ [é máximo]

(15) $\dfrac{\partial \ln L}{\partial \sigma^2} = -\dfrac{T-1}{2\sigma^2} + \dfrac{S(\hat{\phi})}{2\sigma^4} = 0$ [CPO em σ^2]

(16) $\hat{\sigma}^2 = \dfrac{S(\hat{\phi})}{T-1} = \dfrac{1}{T-1} \sum_{t=2}^{T} \hat{\varepsilon}_t^2$ [$\times 2\sigma^4$, isola]

(17) $\ln L_{\max} = -\frac{T-1}{2}\big(\ln(2\pi) + \ln \hat{\sigma}^2 + 1 \big)$ [(16) em (6)]

$$\boxed{\ln L(\phi, \sigma^2 \mid y_1) = -\tfrac{T-1}{2}\ln(2\pi\sigma^2) - \tfrac{1}{2\sigma^2}\textstyle\sum_{t=2}^{T}(y_t - \phi y_{t-1})^2; \qquad \hat{\phi} = \dfrac{\sum y_t y_{t-1}}{\sum y_{t-1}^2} = \hat{\phi}_{MQO}}$$

A linha (17) é o elo com a Q14: o $\ln L$ maximizado depende dos dados só pela variância dos resíduos, e é ele que entra no AIC e no BIC.

Além do que se pede: a exata e o Yule-Walker.

(18) $\ln L_{ex} = \ln f(y_1) + \ln L_{cond}, \quad y_1 \sim N\big(0,\ \sigma^2/(1-\phi^2)\big)$ [AU02 p. 78]

(19) $\ln f(y_1) = -\frac{1}{2}\ln(2\pi) - \frac{1}{2}\ln\sigma^2 + \frac{1}{2}\ln(1-\phi^2) - \dfrac{(1-\phi^2)y_1^2}{2\sigma^2}$ [densidade de y_1]

(20) a CPO ganha $-\dfrac{\phi}{1-\phi^2} + \dfrac{\phi\, y_1^2}{\sigma^2}$: não linear em ϕ [solução numérica]

(21) $\hat{\phi}_{YW} = \hat{\rho}_1 = \dfrac{\sum_{t=2}^{T} y_t y_{t-1}}{\sum_{t=1}^{T} y_t^2}$ [AU02 p. 70–71]

(22) os três diferem em $O(1/T)$ e são assintoticamente equivalentes [AU02 p. 80]

Q14 · AIC e BIC de três modelos

Enunciado (lista, Q14). Ajustaram-se um ARMA(1,1), um ARMA(2,0) e um ARMA(0,2) a $T = 150$ observações. As log-verossimilhanças maximizadas são $-210{,}3$, $-212{,}8$ e $-214{,}1$; os modelos têm média zero, e k inclui a variância. Pede-se:

- (a) o AIC e o BIC de cada modelo e o escolhido por cada critério;
- (b) a diferença de penalidade e as implicações assintóticas.

(a) As contas, com as fórmulas da AU02, p. 98–99:

(23)	$k = p + q + 1 = 3$ nos três modelos	[AR/MA + σ^2]
(24)	$-2\ln L$: 420,6; 425,6; 428,2	[$-2 \times \ln L$]
(25)	$AIC = \dfrac{-2\ln L + 2k}{T}, \qquad 2k = 6$	[AU02 p. 98]
(26)	$AIC_{(1,1)} = \dfrac{420{,}6 + 6}{150} = \dfrac{426{,}6}{150} = 2{,}8440$	[(24), (25)]
(27)	$AIC_{(2,0)} = \dfrac{425{,}6 + 6}{150} = \dfrac{431{,}6}{150} = 2{,}8773$	[(24), (25)]
(28)	$AIC_{(0,2)} = \dfrac{428{,}2 + 6}{150} = \dfrac{434{,}2}{150} = 2{,}8947$	[(24), (25)]
(29)	$BIC = \dfrac{-2\ln L + k\ln T}{T}, \qquad k\ln T = 3(5{,}0106) = 15{,}0319$	[AU02 p. 99]
(30)	$BIC_{(1,1)} = \dfrac{420{,}6 + 15{,}0319}{150} = \dfrac{435{,}632}{150} = 2{,}9042$	[(24), (29)]
(31)	$BIC_{(2,0)} = \dfrac{440{,}632}{150} = 2{,}9375$	[(24), (29)]
(32)	$BIC_{(0,2)} = \dfrac{443{,}232}{150} = 2{,}9549$	[(24), (29)]
(33)	menor AIC e menor BIC: ARMA(1,1)	[regra: o menor vence]
(34)	k igual $\Rightarrow$ multa igual $\Rightarrow$ a ordem é a de $-2\ln L$	[(23)]

$AIC = (2{,}8440;\ 2{,}8773;\ 2{,}8947), \quad BIC = (2{,}9042;\ 2{,}9375;\ 2{,}9549)$: os dois escolhem o ARMA(1,1)

No R, sem dividir por T, os valores são $AIC = 426{,}6$, 431,6 e 434,2, e $BIC = 435{,}63$, 440,63 e 443,23, com a mesma ordem.

(b) Penalidade e propriedades assintóticas, comparando um modelo com k parâmetros com outro de $k + 1$ que o contém, com $LR = 2(\ln L_{k+1} - \ln L_k)$:

(35)	multa por parâmetro: AIC 2; BIC $\ln T = 5{,}01$ com $T = 150$	[(25), (29)]
(36)	$\ln T > 2 \iff T > e^2 \approx 7{,}4$	[BIC mais duro]
(37)	$AIC_{k+1} < AIC_k \iff -2\ln L_{k+1} + 2 < -2\ln L_k \iff LR > 2$	[rearranja]
(38)	$BIC_{k+1} < BIC_k \iff LR > \ln T$	[idem, multa $\ln T$]
(39)	se o menor é o verdadeiro: $LR \xrightarrow{d} \chi^2(1)$	[teste LR]
(40)	$P(\text{AIC superajusta}) \to P(\chi^2(1) > 2) = 0{,}157$	[não vai a zero]
(41)	$P(\text{BIC superajusta}) = P(LR > \ln T) \to 0$	[$\ln T \to \infty$: consistente]
(42)	falta parâmetro não nulo: $LR \sim T$ vence as multas	[nenhum subajusta]
(43)	verdadeiro fora da lista: o AIC minimiza o EQM de previsão	[eficiência]

AIC: multa 2, eficiente, superajusta com prob. 0,157;	BIC: multa $\ln T$, consistente

A conclusão para escrever na prova: **BIC para identificar** a estrutura, quando se supõe que o modelo verdadeiro está entre os candidatos, e **AIC para prever**. Na Q14 os dois concordam, porque os modelos têm o mesmo k.

Versão para a prova

Q13:

1. Escreva $y_t \mid y_{t-1} \sim N(\phi y_{t-1}, \sigma^2)$ e a densidade.
2. Some os logs de $t = 2$ a T, linha (6).
3. A CPO em ϕ dá $\hat{\phi} = \sum y_t y_{t-1} / \sum y_{t-1}^2$, que é o MQO, porque maximizar $\ln L$ é minimizar $S(\phi)$.
4. A CPO em σ^2 dá $\hat{\sigma}^2 = S/(T-1)$.

Q14:

1. $k = 3$ e $-2 \ln L = 420{,}6$; $425{,}6$; $428{,}2$.
2. AIC: some 6 e divida por 150.
3. BIC: some 15,03 e divida por 150.
4. O menor vence: ARMA(1,1) nos dois.
5. Explique as multas, 2 contra $\ln T$, e as linhas (37)–(41).

Conferência

Q13, numa série simulada com $\phi = 0{,}6$ e $T = 200$:

- a fórmula (12) dá 0,6537, igual ao `lm`;
- o Yule-Walker (21) dá 0,6487, igual ao `ar.yw`;
- a exata dá 0,6620;
- $\hat{\sigma}^2 = 1{,}0491$.

Q14:

- as parcelas são 420,6, 425,6, 428,2 e $3 \ln 150 = 15{,}0319$;
- a diferença de AIC entre o segundo e o primeiro modelo, sem dividir por T, é 5;
- numa simulação de mil séries, o AIC superajusta 15,7% das vezes com $T = 150$ e 12,4% com $T = 2000$, perto dos 0,157 teóricos; o BIC, 3,2% e 0,6%.

Parte V

Bloco 5 à mão: Q15

Cap. 5 à mão — Q15 linha a linha

Cap. 5 à mão: Q15, linha a linha

← capítulo 5 · ← apostila · cap. 4 à mão

Versão de **caderno** do bloco 5 da lista: cada passagem numerada, uma operação por linha e o motivo entre colchetes. A notação é a dos slides: Ω_T, $\hat{y}_{T+h/T}$, $\theta_1 = -\theta^{\text{lista}}$. Para encurtar, $E_T(\cdot) \equiv E(\cdot \mid \Omega_T)$ e $\text{Var}_T(\cdot) \equiv \text{Var}(\cdot \mid \Omega_T)$.

Legenda:

- [RB]: ruído branco;
- [F2]: série geométrica;
- [F4]: linearidade da esperança;
- [F9]: as três regras da previsão: o que é conhecido em T fica, choque futuro vira zero, y futuro vira a previsão;
- [inv.]: invertibilidade, ou seja, ε_T é calculável a partir de $y_T, y_{T-1}, \ldots$;
- [(n)]: usando a linha (n).

Q15 · Previsão de um ARMA(p, q) estacionário e invertível

Enunciado (lista, Q15). Para um ARMA(p, q) estacionário e invertível:

- (a) o previsor de mínimo EQM é a esperança condicional;
- (b) as previsões de um e de dois passos do ARMA(1,1);
- (c) o erro de previsão é um MA($h-1$), com variância em função dos ψ_j;
- (d) o intervalo de 95% com erros gaussianos;
- (e) no ARIMA(0,1,1), a previsão de longo prazo é constante (suavização exponencial), e qual é a constante de suavização.

(a) A esperança condicional minimiza o EQM

Seja g qualquer previsor construído com Ω_T, $y \equiv y_{T+h}$ e $m \equiv E_T(y)$.

(1)	$E_T\big((y-g)^2\big) = E_T\big((y-m+m-g)^2\big)$	[soma e subtrai m]
(2)	$\quad = E_T\big((y-m)^2\big) + 2E_T\big((y-m)(m-g)\big) + E_T\big((m-g)^2\big)$	[quadrado, F4]
(3)	$E_T\big((y-m)(m-g)\big) = (m-g)\,E_T(y-m)$	[$m-g$ conhecido em T]
(4)	$E_T(y-m) = m-m = 0$	[definição de m]
(5)	$E_T\big((m-g)^2\big) = (m-g)^2$	[conhecido em T]
(6)	$E_T\big((y-g)^2\big) = \text{Var}_T(y) + (m-g)^2$	[(2)–(5)]
(7)	$E_T\big((y-g)^2\big) \geq \text{Var}_T(y)$, com igualdade $\iff g = m$	[$(m-g)^2 \geq 0$]

$$\boxed{\hat{y}_{T+h/T} = E(y_{T+h} \mid \Omega_T) \text{ minimiza o EQM}}$$

(b) ARMA(1,1): um e dois passos

Modelo: $y_t = c + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$ (AU02, p. 85).

Erro do caderno (26/08): a previsão do MA(2) misturou os horizontes e pôs θ_2 nos dois lugares

O caderno trocou $E(y_t \mid \Omega_{t-1})$ por $E(y_{t+2} \mid \Omega_t)$ na mesma linha. A defesa é sempre escrever o modelo **na data futura** antes de tirar a esperança, como em (8) e (11), e só então aplicar as regras [F9].

(8)	$y_{T+1} = c + \phi_1 y_T + \varepsilon_{T+1} + \theta_1 \varepsilon_T$	[modelo em $T+1$]
(9)	$\hat{y}_{T+1/T} = c + \phi_1 y_T + E_T(\varepsilon_{T+1}) + \theta_1 E_T(\varepsilon_T)$	[F4]
(10)	$= c + \phi_1 y_T + 0 + \theta_1 \varepsilon_T$	[F9; inv.]
(11)	$y_{T+2} = c + \phi_1 y_{T+1} + \varepsilon_{T+2} + \theta_1 \varepsilon_{T+1}$	[modelo em $T+2$]
(12)	$\hat{y}_{T+2/T} = c + \phi_1 \hat{y}_{T+1/T} + 0 + 0$	[F9: os dois choques são futuros]
(13)	$\hat{y}_{T+h/T} = c + \phi_1 \hat{y}_{T+h-1/T}, \quad h \geq 2$	[mesma conta]
(14)	$\hat{y}_{T+h/T} - \mu = \phi_1^{h-1}\big(\hat{y}_{T+1/T} - \mu\big) \to 0$	[$c = (1-\phi_1)\mu$; $\lvert\phi_1\rvert < 1$]
(15)	lista ($\mu = 0$) : $\hat{z}_{T+1\lvert T} = \phi z_T - \theta a_T$; $\hat{z}_{T+2\lvert T} = \phi\, \hat{z}_{T+1\lvert T}$	[$\theta_1 = -\theta$]

$$\boxed{\hat{y}_{T+1/T} = c + \phi_1 y_T + \theta_1 \varepsilon_T, \qquad \hat{y}_{T+2/T} = c + \phi_1 \hat{y}_{T+1/T}}$$

(c) O erro de previsão é um MA($h-1$)

Pela forma de Wold, $y_t = \mu + \sum_{j \geq 0} \psi_j \varepsilon_{t-j}$, com $\psi_0 = 1$:

(16)	$y_{T+h} = \mu + \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j} + \sum_{j \geq h} \psi_j \varepsilon_{T+h-j}$	[separa futuro e passado]
(17)	$\hat{y}_{T+h/T} = \mu + 0 + \sum_{j \geq h} \psi_j \varepsilon_{T+h-j}$	[F9; inv.]
(18)	$e_{T+h/T} = y_{T+h} - \hat{y}_{T+h/T} = \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j}$	[(16) − (17)]
(19)	(18) envolve h choques futuros, defasagens 0 a $h-1$: MA($h-1$)	[forma]
(20)	$E(e_{T+h/T}) = \sum_{j=0}^{h-1} \psi_j E(\varepsilon_{T+h-j}) = 0$	[F4, soma finita; RB]
(21)	$\mathrm{Var}(e_{T+h/T}) = \sum_{i=0}^{h-1} \sum_{j=0}^{h-1} \psi_i \psi_j E(\varepsilon_{T+h-i} \varepsilon_{T+h-j})$	[F4]
(22)	$= \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$	[RB: só $i = j$]
(23)	$h \to \infty$: $\mathrm{Var}(e_{T+h/T}) \to \sigma^2 \sum_{j \geq 0} \psi_j^2 = \gamma_0$	[processo linear]
(24)	ARMA(1,1): $\psi_1 = \phi_1 + \theta_1 \;\Rightarrow\; \mathrm{Var}(e_{T+2/T}) = \sigma^2\big(1 + (\phi_1 + \theta_1)^2\big)$	[(22), $h = 2$]
(25)	$\psi_2 = \phi_1(\phi_1 + \theta_1) \;\Rightarrow\; \mathrm{Var}(e_{T+3/T}) = \sigma^2\big(1 + \psi_1^2 + \psi_2^2\big)$	[(22), $h = 3$]
(26)	MA(q) : $\psi_j = 0$ para $j > q \;\Rightarrow\; \mathrm{Var}(e_{T+h/T}) = \gamma_0$ para $h > q$	[(22), AU02 p. 57]

$$\boxed{e_{T+h/T} = \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j} \;\; (\mathrm{MA}(h-1)), \qquad \mathrm{Var}(e_{T+h/T}) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2}$$

(d) Intervalo de 95%

(27) $\varepsilon_t \sim N(0,\sigma^2) \Rightarrow e_{T+h/T} \sim N\big(0,\ \sigma^2 \sum_{j=0}^{h-1} \psi_j^2\big)$ [soma de normais]

(28) $P\big(|e_{T+h/T}| \le 1{,}96\,\sigma_h\big) = 0{,}95, \quad \sigma_h \equiv \sigma\sqrt{\sum_{j=0}^{h-1} \psi_j^2}$ [normal padrão]

(29) $y_{T+h} \in \big[\hat{y}_{T+h/T} - 1{,}96\,\sigma_h;\ \hat{y}_{T+h/T} + 1{,}96\,\sigma_h\big]$ com prob. 0,95 [$y = \hat{y} + e$]

(30) $\mathrm{Cov}(e_{T+1/T}, e_{T+2/T}) = E\big(\varepsilon_{T+1}(\varepsilon_{T+2} + \psi_1\varepsilon_{T+1})\big) = \psi_1\sigma^2$ [RB]

$$\boxed{\hat{y}_{T+h/T} \pm 1{,}96\,\sigma\sqrt{\sum_{j=0}^{h-1} \psi_j^2}}$$

Em (30): os erros de horizontes diferentes, feitos na mesma origem, são **correlacionados**. Não se pode tratá-los como independentes.

(e) ARIMA(0,1,1) e suavização exponencial

Nos slides, $\Delta y_t = \varepsilon_t + \theta_1\varepsilon_{t-1}$; na lista, $\theta_1 = -\theta$, com $0 < \theta < 1$.

(31) $y_{T+1} = y_T + \varepsilon_{T+1} + \theta_1\varepsilon_T$ [modelo em $T+1$]

(32) $\hat{y}_{T+1/T} = y_T + \theta_1\varepsilon_T$ [F9]

(33) $\varepsilon_T = y_T - \hat{y}_{T/T-1}$ [o choque é o erro de 1 passo]

(34) $\hat{y}_{T+1/T} = (1+\theta_1)\,y_T - \theta_1\,\hat{y}_{T/T-1}$ [(33) em (32)]

(35) $\alpha \equiv 1+\theta_1 = 1-\theta: \quad \hat{y}_{T+1/T} = \alpha\,y_T + (1-\alpha)\,\hat{y}_{T/T-1}$ [$\theta_1 = -\theta$]

(36) $\hat{y}_{T+1/T} = \alpha\sum_{j\ge0}(1-\alpha)^j y_{T-j}$ [(35) iterada]

(37) $\alpha\sum_{j\ge0}(1-\alpha)^j = \alpha\cdot\frac{1}{1-(1-\alpha)} = 1$ [F2: pesos somam 1]

(38) $\hat{y}_{T+h/T} = \hat{y}_{T+h-1/T} + 0 = \cdots = \hat{y}_{T+1/T}, \quad h \ge 2$ [F9: choques futuros]

(39) $y_t = \dfrac{1+\theta_1 L}{1-L}\varepsilon_t: \quad \psi_0 = 1,\ \ \psi_j = 1+\theta_1 = \alpha,\ j \ge 1$ [F2, F7]

(40) $\mathrm{Var}(e_{T+h/T}) = \sigma^2\big(1 + (h-1)\alpha^2\big) \to \infty$ [(22)]

$$\boxed{\hat{y}_{T+h/T} = \alpha\sum_{j\ge0}(1-\alpha)^j y_{T-j} \text{ para todo } h, \qquad \alpha = 1-\theta = 1+\theta_1}$$

A previsão é plana, e a constante de suavização é $\alpha = 1-\theta$. A **incerteza**, porém, cresce linearmente com h, por (40): o leque abre para sempre, porque o processo é I(1).

Versão para a prova

1. **(a)** Some e subtraia m; o termo cruzado zera, e sobra $\mathrm{Var}_T(y) + (m-g)^2$, mínimo em $g = m$.
2. **(b)** Modelo em $T+1$ e $T+2$, regras [F9]: $\hat{y}(1) = c + \phi_1 y_T + \theta_1\varepsilon_T$ e $\hat{y}(2) = c + \phi_1\hat{y}(1)$.
3. **(c)** Separe futuro e passado na forma de Wold: $e = \sum_{j<h}\psi_j\varepsilon_{T+h-j}$, com variância $\sigma^2\sum_{j<h}\psi_j^2$.
4. **(d)** $\hat{y} \pm 1{,}96\,\sigma\sqrt{\sum_{j<h}\psi_j^2}$.
5. **(e)** $\hat{y}(1) = \alpha y_T + (1-\alpha)\hat{y}_{T/T-1}$, com $\alpha = 1-\theta$; previsão plana; variância $\sigma^2(1+(h-1)\alpha^2)$.

Conferência

AR(1) com $\mu = 10$, $\phi_1 = 0{,}8$, $\sigma^2 = 1$ e $y_T = 14$:

- previsões 13,2; 12,56; 12,048;
- variâncias do erro 1; 1,64; 2,0496, com limite 2,7778;
- intervalo em $h = 1$: $[11{,}24;\ 15{,}16]$.

ARMA(1,1) com $\phi_1 = 0{,}8$, $\theta_1 = 0{,}6$, $y_T = 2$ e $\varepsilon_T = 0{,}5$:

- $\hat{y}(1) = 1{,}9$ e $\hat{y}(2) = 1{,}52$;
- variâncias do erro 2,96 em $h = 2$ e 4,2144 em $h = 3$;
- intervalo em $h = 2$: $[-1{,}852;\ 4{,}892]$;
- $\mathrm{Cov}(e_1, e_2) = \psi_1 = 1{,}4$.

Suavização exponencial com $\theta = 0{,}6$:

- $\alpha = 0{,}4$, com pesos 0,4; 0,24; 0,144;
- a recursão (35) coincide com o `predict` do ARIMA(0,1,1) do R, com diferença zero, e a previsão de 3 passos é igual à de 1.

Parte VI

Bloco 6 à mão: Q16

Cap. 6 à mão — Q16 linha a linha

Cap. 6 à mão: Q16, linha a linha

← capítulo 6 · ← apostila · cap. 5 à mão

Versão de **caderno** do bloco 6 da lista: cada passagem numerada, uma operação por linha e o motivo entre colchetes. A notação é a dos slides, com o MA com sinal positivo: $\theta_1 = -\theta^{\text{lista}}$ e $\Theta_1 = -\Theta^{\text{lista}}$.

Legenda:

- [RB]: ruído branco;
- [F8]: multiplicar polinômios;
- [caus.]: o choque de hoje não se correlaciona com o passado;
- [(n)]: usando a linha (n).

Q16 · SARIMA$(1,1,1)(0,1,1)_{12}$ com 240 meses

Enunciado (lista, Q16). Para 240 observações mensais e o modelo SARIMA$(1,1,1)(0,1,1)_{12}$, pede-se:

- (a) o modelo completo com o operador de retardo;
- (b) quantos e quais parâmetros estimar;
- (c) a FAC e a FACP esperadas de $(1-B)(1-B^{12})y_t$;
- (d) o critério para compará-lo com o SARIMA$(2,1,1)(0,1,1)_{12}$.

(a) O modelo

(1)	$(1-\phi L)(1-L)(1-L^{12})\,y_t = (1+\theta_1 L)(1+\Theta_1 L^{12})\,\varepsilon_t$	[SARIMA, AU05]
(2)	$(1+\theta_1 L)(1+\Theta_1 L^{12}) = 1+\theta_1 L+\Theta_1 L^{12}+\theta_1\Theta_1 L^{13}$	[F8]
(3)	$(1-\phi L)(1-L) = 1-(1+\phi)L+\phi L^2$	[F8]
(4)	$(3)\times(1-L^{12}) = 1-(1+\phi)L+\phi L^2-L^{12}+(1+\phi)L^{13}-\phi L^{14}$	[F8]
(5)	$y_t = (1+\phi)y_{t-1}-\phi y_{t-2}+y_{t-12}-(1+\phi)y_{t-13}+\phi y_{t-14}+m_t$	[isola y_t]
(6)	$m_t = \varepsilon_t+\theta_1\varepsilon_{t-1}+\Theta_1\varepsilon_{t-12}+\theta_1\Theta_1\varepsilon_{t-13}$	[(2)]
(7)	$w_t \equiv (1-L)(1-L^{12})y_t = y_t-y_{t-1}-y_{t-12}+y_{t-13}$	[F8]
(8)	$w_t = \phi\, w_{t-1}+m_t$	[(1), (7)]
(9)	lista: $(1-\phi B)(1-B)(1-B^{12})y_t = (1-\theta B)(1-\Theta B^{12})a_t$, cruzado $+\theta\Theta B^{13}$	$[(-\theta)(-\Theta)=+\theta\Theta]$

$$\boxed{(1-\phi L)(1-L)(1-L^{12})\,y_t = (1+\theta_1 L)(1+\Theta_1 L^{12})\,\varepsilon_t}$$

(b) Os parâmetros e as observações

(10) livres: $\phi,\ \theta_1,\ \Theta_1,\ \sigma^2$ [3 polinômios + σ^2]

(11) o coeficiente de ε_{t-13} é $\theta_1\Theta_1$: imposto, não é livre [(2)]

(12) sem constante: com $d = D = 1,\ c \neq 0$ daria tendência quadrática [cap. 3]

(13) w_t precisa de y_{t-13} : perdem-se $d + sD = 1 + 12 = 13$ [(7)]

(14) $T_{ef} = 240 - 13 = 227$ [(13)]

4 parâmetros $(\phi, \theta_1, \Theta_1, \sigma^2)$; 227 observações efetivas

(c) A FAC e a FACP esperadas de w_t

Comece pelo caso $\phi = 0$, o modelo das companhias aéreas, em que $w_t = m_t$, com $\psi_0 = 1$, $\psi_1 = \theta_1$, $\psi_{12} = \Theta_1$, $\psi_{13} = \theta_1\Theta_1$ e os demais zero.

(15) $\gamma_k = \sigma^2 \sum_j \psi_j\psi_{j+k}$ [processo linear, AU02 p. 18]

(16) $\gamma_0 = \sigma^2(1 + \theta_1^2 + \Theta_1^2 + \theta_1^2\Theta_1^2) = \sigma^2(1 + \theta_1^2)(1 + \Theta_1^2)$ [$k = 0$; fatora]

(17) $\gamma_1 = \sigma^2(\psi_0\psi_1 + \psi_{12}\psi_{13}) = \sigma^2\theta_1(1 + \Theta_1^2)$ [$k = 1$]

(18) $\gamma_{11} = \sigma^2\psi_1\psi_{12} = \sigma^2\theta_1\Theta_1$ [$k = 11$]

(19) $\gamma_{12} = \sigma^2(\psi_0\psi_{12} + \psi_1\psi_{13}) = \sigma^2\Theta_1(1 + \theta_1^2)$ [$k = 12$]

(20) $\gamma_{13} = \sigma^2\psi_0\psi_{13} = \sigma^2\theta_1\Theta_1$ [$k = 13$]

(21) $\gamma_k = 0$ para $k \notin \{0, 1, 11, 12, 13\}$ [nenhum par à distância k]

(22) $\rho_1 = \dfrac{\theta_1}{1 + \theta_1^2}, \quad \rho_{12} = \dfrac{\Theta_1}{1 + \Theta_1^2}, \quad \rho_{11} = \rho_{13} = \rho_1\rho_{12}$ [$\div\gamma_0$]

Agora com o AR ($\phi \neq 0$), $w_t = \phi w_{t-1} + m_t$:

(23) $\gamma_k = \phi\gamma_{k-1} + E(m_t w_{t-k})$, e $E(m_t w_{t-k}) = 0$ para $k \geq 14$ [caus.: m_t vai até $t - 13$]

(24) $k \geq 14$: $\gamma_k = \phi\gamma_{k-1}$ [recursão do AR, AU02 p. 87]

(25) defasagens baixas: decaimento à taxa ϕ a partir de ρ_1 [como no ARMA(1,1)]

(26) em torno de 12: pico de Θ_1 com satélites em 11 e 13 [(18)–(20)]

(27) FACP: decai nas defasagens baixas e em torno de 12, 24, … [AU02 p. 95]

FAC: decai à taxa ϕ perto da origem; pico em 12, satélites em 11 e 13; FACP decai

(d) Como comparar com o SARIMA$(2,1,1)(0,1,1)_{12}$

(28)	o rival contém o modelo: $\phi_2 = 0 \;\Rightarrow$ aninhados	[1 restrição]
(29)	$LR = 2\big(\ln L_{(2,1,1)} - \ln L_{(1,1,1)}\big) \xrightarrow{d} \chi^2(1)$	[$H_0 : \phi_2 = 0$]
(30)	rejeita H_0 a 5% se $LR > 3{,}84$	[$\chi^2_{1;0,95}$]
(31)	$BIC = \dfrac{-2\ln L + k \ln T_{ef}}{T_{ef}}$, $\ln 227 = 5{,}42$	[AU02 p. 99]
(32)	o BIC prefere o rival $\iff LR > \ln 227 = 5{,}42$	[cap. 4, (38)]
(33)	mesmo $T_{ef} = 227$ nos dois: d e D iguais	[AU02 p. 99]
(34)	resíduos: $LB(24) \sim \chi^2_\nu$, $\nu = 24 - p - q - P - Q = 21$	[AU03 p. 15]
(35)	rejeita "resíduo branco" se $LB(24) > 32{,}67$	[$\chi^2_{21;0,95}$]
(36)	completam: JB, ARCH-LM, Chow/CUSUM	[AU03 p. 11–31]
(37)	recomendação: BIC (identificação), com o LR como confirmação	[aninhados, mesmo T]

BIC (multa $\ln 227 = 5{,}42$) e LR (crítico 3,84), mesmo $T_{ef} = 227$; LB com $\nu = 21$

O ciclo de Box-Jenkins em que tudo isso se encaixa (AU03, p. 4–7):

(38)	identificar: gráfico, diferenças, FAC e FACP de w_t	[item (c)]
(39)	estimar: MV exata ou condicional	[cap. 4]
(40)	diagnosticar: resíduos, estabilidade, previsão; se falhar, voltar a (38)	[item (d)]
(41)	usar: prever com as regras da esperança condicional	[cap. 5]

Versão para a prova

1. **(a)** Escreva (1) e expanda o MA, (2): o termo cruzado é $\theta_1\Theta_1 L^{13}$, que na lista vira $+\theta\Theta B^{13}$.
2. **(b)** São 4 parâmetros, $\phi, \theta, \Theta, \sigma^2$. Perdem-se 13 observações, e sobram 227.
3. **(c)**
   - pico em 12;
   - satélites em 11 e 13, iguais a $\rho_1\rho_{12}$ no airline;
   - decaimento à taxa ϕ nas defasagens baixas;
   - FACP decaindo.
4. **(d)** BIC e LR, porque os modelos são aninhados e têm o mesmo T, com críticos 3,84 e $\ln 227 = 5{,}42$. O Ljung-Box tem 21 graus de liberdade.

Conferência

O lado AR, com $\phi = 0{,}5$: os coeficientes de y_{t-1}, y_{t-2}, y_{t-12}, y_{t-13} e y_{t-14} em (5) são 1,5; −0,5; 1; −1,5; 0,5. O produto dos polinômios no R confere, com diferença zero.

A FAC. Com $\theta^{\text{lista}} = 0{,}4$ e $\Theta^{\text{lista}} = 0{,}6$, o termo cruzado vale 0,24.

- No airline, (22) dá $\rho_1 = -0{,}3448$, $\rho_{12} = -0{,}4412$ e $\rho_{11} = \rho_{13} = 0{,}1521$, iguais ao `ARMAacf`, com $\rho_2 = 0$.
- Com $\phi = 0{,}5$, $\rho_1 = 0{,}1052$ e $\rho_{12} = -0{,}4411$.

Os testes: $\chi^2_{1;0,95} = 3{,}84$, $\ln 227 = 5{,}42$ e $\chi^2_{21;0,95} = 32{,}67$.

A simulação de 240 meses do modelo verdadeiro:

- o R usou 227 observações;
- $LB(24) = 15{,}39$, com $p = 0{,}80$;
- $LR = 0{,}47$;
- BIC de 651,42 contra 656,38 do rival.

Parte VII

Apêndice: Q2 e Q6 completas

CAPÍTULO 7

Demonstrações à mão — Q2 e Q6, linha a linha

Demonstrações à mão: Q2 e Q6

Esta é a demonstração **como se escreve no caderno**: cada linha numerada, (1), (2), (3)..., uma operação por linha e o motivo entre colchetes à direita. A base é o enunciado da lista, escrito com os **mesmos símbolos dos slides e do caderno**: Y_t, α_1, α_2 e y_0 na Q2 (AU01, p. 28–30); c, μ, ϕ_1, θ_1, ε_t e os desvios $(y_t - \mu)$ na Q6 (AU02, p. 81–84). A única diferença é gráfica: os slides escrevem a esperança com colchetes, e aqui, como no resto do repositório, ela vem com parênteses, $E(\cdot)$. As versões comentadas, com livro, caderno e armadilhas, estão em Q2 e Q6.

Legenda dos colchetes:

- [RB]: ruído branco, $E(\varepsilon_t) = 0$, $E(\varepsilon_t^2) = \sigma^2$ e $E(\varepsilon_i \varepsilon_j) = 0$ se $i \neq j$;
- [lin.]: linearidade da esperança, em que constantes saem e a esperança da soma é a soma das esperanças;
- [F3], [F4]...: ferramentas demonstradas uma vez na caixa de ferramentas: F3 é a soma de Gauss; F4 é a linearidade, $E(a + bX + cY) = a + bE(X) + cE(Y)$ e $E(c) = c$;
- [estac.]: estacionariedade, os momentos não dependem da data: $E(y_t) = \mu$ e $E\big((y_{t-j} - \mu)^2\big) = \gamma_0$ para todo j;
- [caus.]: causalidade, o choque de hoje não se correlaciona com o passado de y;
- [(n)]: usando a linha (n).

Q2 · Passeio com drift e tendência determinística

Enunciado (lista, Q2). Um passeio aleatório recebe, a cada período, um drift constante c e um termo de tendência δt, com valor inicial $y_0 = 0$ e choques ruído branco. Pede-se:

- (a) a solução explícita;
- (b) média, variância e autocovariância;
- (c) a comparação com o passeio só com drift;
- (d) a natureza da tendência e como tirar a não estacionariedade.

Nos slides (AU01, p. 30):

$$Y_t = \alpha_1 + Y_{t-1} + \alpha_2\, t + \varepsilon_t, \qquad \varepsilon_t \sim RB(0, \sigma^2), \qquad Y_0 = 0,$$

com $\alpha_1 = c$ (drift) e $\alpha_2 = \delta$ (tendência). O slide escreve o valor inicial genérico, $Y_0 = y_0$, fixo e não aleatório; a lista fixa $y_0 = 0$. No caderno (19/08), o mesmo modelo aparece como $Y_t = \alpha + Y_{t-1} + \alpha_2 t + \varepsilon_t$, com $\alpha = \alpha_1$.

(a) Solução explícita

Caminho 1 — substituição recursiva.

$$
\begin{aligned}
&(1)\quad Y_1 = \alpha_1 + Y_0 + \alpha_2 \cdot 1 + \varepsilon_1 = \alpha_1 + \alpha_2 + \varepsilon_1 && [Y_0 = 0]\\
&(2)\quad Y_2 = \alpha_1 + Y_1 + 2\alpha_2 + \varepsilon_2 && [\text{modelo}]\\
&(3)\quad \quad = \alpha_1 + (\alpha_1 + \alpha_2 + \varepsilon_1) + 2\alpha_2 + \varepsilon_2 && [(1)]\\
&(4)\quad \quad = 2\alpha_1 + (1+2)\alpha_2 + \varepsilon_1 + \varepsilon_2 &&\\
&(5)\quad Y_3 = \alpha_1 + Y_2 + 3\alpha_2 + \varepsilon_3 = 3\alpha_1 + (1+2+3)\alpha_2 + \varepsilon_1 + \varepsilon_2 + \varepsilon_3 && [(4)]
\end{aligned}
$$

O padrão: cada período soma um α_1, mais um múltiplo de α_2 igual à data, e um choque novo.

$$
(6)\qquad Y_t = \alpha_1 t + \alpha_2(1 + 2 + \cdots + t) + \sum_{s=1}^{t} \varepsilon_s
$$

Prova de (6) por indução.

- **Base,** $t = 1$**:** (6) dá $\alpha_1 + \alpha_2 \cdot 1 + \varepsilon_1$, que é a linha (1). ✓
- **Passo:** suponha (6) válida em t. Então:

$$
\begin{aligned}
&(7)\quad Y_{t+1} = \alpha_1 + Y_t + \alpha_2(t+1) + \varepsilon_{t+1} && [\text{modelo}]\\
&(8)\quad \quad = \alpha_1 + \Big[\alpha_1 t + \alpha_2(1 + \cdots + t) + \sum_{s=1}^{t} \varepsilon_s\Big] + \alpha_2(t+1) + \varepsilon_{t+1} && [\text{hip. de indução}]\\
&(9)\quad \quad = \alpha_1(t+1) + \alpha_2\big(1 + \cdots + t + (t+1)\big) + \sum_{s=1}^{t+1} \varepsilon_s && [\text{agrupando}]
\end{aligned}
$$

que é (6) em $t + 1$. ✓

A soma de Gauss. Seja $S = 1+2+\cdots+t$. Escreva a soma de novo, de trás para frente, $S = t+(t-1)+\cdots+1$, e some as duas linhas coluna a coluna. Cada coluna dá $t + 1$, e são t colunas: $2S = t(t+1)$, logo $S = \frac{t(t+1)}{2}$.

$$
(10)\qquad \boxed{Y_t = \alpha_1\, t + \alpha_2\, \frac{t(t+1)}{2} + \sum_{s=1}^{t} \varepsilon_s}
$$

Caminho 2 — soma telescópica, a conferência. Do modelo, $Y_s - Y_{s-1} = \alpha_1 + \alpha_2 s + \varepsilon_s$. Somando de $s = 1$ a t:

- à esquerda, $(Y_1 - Y_0) + (Y_2 - Y_1) + \cdots + (Y_t - Y_{t-1}) = Y_t - Y_0 = Y_t$, porque os termos do meio se cancelam;
- à direita, $\alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum \varepsilon_s$.

É a mesma (10). **Com y_0 genérico**, a esquerda dá $Y_t - y_0$, e o resultado é $Y_t = y_0 + \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum_{s=1}^{t} \varepsilon_s$: tudo o que vem abaixo vale somando y_0 à média, exatamente como na AU01, p. 30. **Na lista:** $y_t = ct + \delta\frac{t(t+1)}{2} + \sum_{s=1}^{t} u_s$.

(b) Média, variância e autocovariância

Média. Antes de tirar a esperança, separe em (10) o que é número do que é aleatório:

- $a_t \equiv \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$ é um **número**: t é a data, α_1 e α_2 são parâmetros, e nada ali é sorteado;
- $S_t \equiv \sum_{s=1}^{t} \varepsilon_s = \varepsilon_1 + \varepsilon_2 + \cdots + \varepsilon_t$ é a **única parte aleatória**: uma soma de t choques.

Assim, (10) é $Y_t = a_t + S_t$. Linha a linha:

$$
\begin{aligned}
&(11) \quad E(Y_t) = E(a_t + S_t) && \text{[(10)]}\\
&(12) \quad = E(a_t) + E(S_t) && \text{[F4: esperança da soma]}\\
&(13) \quad E(a_t) = a_t && \text{[F4: } E(c) = c,\ a_t \text{ não é aleatório]}\\
&(14) \quad E(S_t) = E(\varepsilon_1 + \varepsilon_2 + \cdots + \varepsilon_t) && \text{[abre o } \textstyle\sum\text{]}\\
&(15) \quad = E(\varepsilon_1) + E(\varepsilon_2 + \cdots + \varepsilon_t) && \text{[F4: } X = \varepsilon_1,\ Y = \text{resto]}\\
&(16) \quad = E(\varepsilon_1) + E(\varepsilon_2) + E(\varepsilon_3 + \cdots + \varepsilon_t) && \text{[F4 de novo]}\\
&(17) \quad = E(\varepsilon_1) + E(\varepsilon_2) + \cdots + E(\varepsilon_t) = \sum_{s=1}^{t} E(\varepsilon_s) && \text{[F4, } t-1 \text{ vezes]}\\
&(18) \quad = \underbrace{0 + 0 + \cdots + 0}_{t \text{ parcelas}} && \text{[RB: } E(\varepsilon_s) = 0\ \forall s\text{]}\\
&(19) \quad = 0\\
&(20) \quad E(Y_t) = a_t + 0 = \alpha_1 t + \alpha_2 \tfrac{t(t+1)}{2} \equiv \mu_t && \text{[(12), (13), (19)]}
\end{aligned}
$$

Por que a esperança pode entrar no Σ (o passo (17)), por indução no número de parcelas n:

- **base,** $n = 1$**:** $E(\varepsilon_1) = E(\varepsilon_1)$ ✓;
- **passo:** se $E\big(\sum_{s=1}^{n} \varepsilon_s\big) = \sum_{s=1}^{n} E(\varepsilon_s)$, então

$$E\Big(\sum_{s=1}^{n+1} \varepsilon_s\Big) = E\Big(\sum_{s=1}^{n} \varepsilon_s + \varepsilon_{n+1}\Big) = E\Big(\sum_{s=1}^{n} \varepsilon_s\Big) + E(\varepsilon_{n+1}) = \sum_{s=1}^{n} E(\varepsilon_s) + E(\varepsilon_{n+1}) = \sum_{s=1}^{n+1} E(\varepsilon_s),$$

usando a F4 com duas parcelas ($X = \sum_{s=1}^{n} \varepsilon_s$ e $Y = \varepsilon_{n+1}$) e depois a hipótese de indução. ✓

Observações:

- **A soma é finita**, com t parcelas, e por isso a troca vale sempre. Numa soma **infinita**, como o MA(∞) da Q6, a troca precisa de $\sum_j |\psi_j| < \infty$.
- **Por que** $E(\varepsilon_s) = 0$**:** é a primeira propriedade do ruído branco, $\varepsilon_t \sim RB(0, \sigma^2)$ (AU01, p. 31). Vale para **cada** data s, e por isso todas as t parcelas de (18) são zero.
- **Exemplo com** $t = 3$**:** $E(\varepsilon_1 + \varepsilon_2 + \varepsilon_3) = E(\varepsilon_1) + E(\varepsilon_2) + E(\varepsilon_3) = 0 + 0 + 0 = 0$.
- **Com** y_0 **genérico**, como no slide: $Y_t = y_0 + a_t + S_t$, e $E(y_0) = y_0$ pela F4, porque y_0 é fixo. Então $E(Y_t) = y_0 + \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$, exatamente a AU01, p. 30.
- **Atalho para a prova**, numa linha: $E\big(\sum_{s=1}^{t} \varepsilon_s\big) = \sum_{s=1}^{t} E(\varepsilon_s) = \sum_{s=1}^{t} 0 = 0$ [F4, soma finita; RB].

Desvio em relação à média. Subtraindo (20) de (10):

$$(21) \qquad Y_t - \mu_t = \sum_{s=1}^{t} \varepsilon_s$$

Variância.

$$V(Y_t) = E\big((Y_t - \mu_t)^2\big) = E\Big(\Big(\sum_{i=1}^{t} \varepsilon_i\Big)^2\Big) \quad [(21)] \tag{22}$$

$$= E\Big(\sum_{i=1}^{t}\sum_{j=1}^{t} \varepsilon_i\varepsilon_j\Big) \quad [\text{quadrado da soma}] \tag{23}$$

$$= \sum_{i=1}^{t}\sum_{j=1}^{t} E(\varepsilon_i\varepsilon_j) \quad [\text{lin.}] \tag{24}$$

$$= \sum_{i=1}^{t} E(\varepsilon_i^2) + \sum_{i\neq j} E(\varepsilon_i\varepsilon_j) \quad [\text{separa } i=j] \tag{25}$$

$$= t\sigma^2 + 0 = t\sigma^2 \quad [\text{RB}] \tag{26}$$

Autocovariância, para $0 \le k < t$:

$$\mathrm{Cov}(Y_t, Y_{t-k}) = E\big((Y_t - \mu_t)(Y_{t-k} - \mu_{t-k})\big) \tag{27}$$

$$= E\Big(\Big(\sum_{i=1}^{t} \varepsilon_i\Big)\Big(\sum_{j=1}^{t-k} \varepsilon_j\Big)\Big) \quad [(21) \text{ em } t \text{ e } t-k] \tag{28}$$

$$= \sum_{i=1}^{t}\sum_{j=1}^{t-k} E(\varepsilon_i\varepsilon_j) \quad [\text{lin.}] \tag{29}$$

$$= \sum_{j=1}^{t-k} E(\varepsilon_j^2) \quad [\text{RB: só } i=j] \tag{30}$$

$$= (t-k)\sigma^2 \tag{31}$$

Em (30), os pares com $i = j$ só existem para $j = 1, \dots, t-k$, porque a segunda soma para em $t-k$: são os choques que Y_t e Y_{t-k} têm em comum.

Correlação:

$$\rho(t,k) = \frac{(t-k)\sigma^2}{\sqrt{t\sigma^2 \cdot (t-k)\sigma^2}} = \sqrt{\frac{t-k}{t}} \tag{32}$$

$$\boxed{E(Y_t) = \alpha_1 t + \alpha_2 \tfrac{t(t+1)}{2}, \qquad V(Y_t) = t\sigma^2, \qquad \mathrm{Cov}(Y_t, Y_{t-k}) = (t-k)\sigma^2}$$

Conclusão: média, variância e autocovariância dependem de *t*. **O processo não é estacionário** (AU01, p. 25).

(c) Comparação com o passeio com drift

Repetindo (1)–(31) com $\alpha_2 = 0$, isto é, com $Y_t = \alpha_1 + Y_{t-1} + \varepsilon_t$ e $Y_0 = 0$, obtém-se $Y_t = \alpha_1 t + \sum_{s=1}^{t} \varepsilon_s$, e:

Momento	Só drift ($\alpha_2 = 0$)	Drift e tendência
$E(Y_t)$	$\alpha_1 t$ (reta)	$\alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$ (parábola)
$V(Y_t)$	$t\sigma^2$	$t\sigma^2$
$\mathrm{Cov}(Y_t, Y_{t-k})$	$(t-k)\sigma^2$	$(t-k)\sigma^2$

Só a média muda, pelo termo $\alpha_2 \frac{t(t+1)}{2}$. A parte aleatória, $\sum \varepsilon_s$, é idêntica nos dois, e por isso variância e covariância são iguais.

(d) Natureza da tendência e como removê-la

Decomposição. Por (10):

$$Y_t = \underbrace{\alpha_1 t + \alpha_2 \frac{t(t+1)}{2}}_{\text{tendência determinística}} + \underbrace{\sum_{s=1}^{t} \varepsilon_s}_{\text{tendência estocástica}} \tag{33}$$

- **Os dois processos têm tendência estocástica** (raiz unitária). Por (10), $\partial Y_{t+j}/\partial \varepsilon_t = 1$ para todo $j \geq 0$: o choque é **permanente**.
- **A tendência determinística muda:** é linear com drift e quadrática com drift e tendência (MAT, §1.3, "tendência geral").

Primeira diferença:

$$\Delta Y_t = Y_t - Y_{t-1} = \alpha_1 + \alpha_2 t + \varepsilon_t \quad \text{[modelo]} \tag{34}$$

$$E(\Delta Y_t) = \alpha_1 + \alpha_2 t \quad \text{[lin., RB]} \tag{35}$$

- **Só drift ($\alpha_2 = 0$):** $\Delta Y_t = \alpha_1 + \varepsilon_t$, que é estacionário. Uma diferença basta.
- **Drift e tendência:** por (35), ΔY_t **ainda tem tendência linear** na média. Uma diferença não basta.

Caminho recomendado. Diferenciar uma vez e **tirar a tendência linear de ΔY_t por regressão** em $(1, t)$. Por (34), o resíduo dessa regressão estima ε_t, que é ruído branco.

Caminho a evitar: diferenciar duas vezes.

$$\Delta^2 Y_t = \Delta Y_t - \Delta Y_{t-1} \quad \text{[definição]} \tag{36}$$

$$= (\alpha_1 + \alpha_2 t + \varepsilon_t) - \big(\alpha_1 + \alpha_2 (t-1) + \varepsilon_{t-1}\big) \quad \text{[(34)]} \tag{37}$$

$$= \alpha_2 + \varepsilon_t - \varepsilon_{t-1} = \alpha_2 + (1 - L)\,\varepsilon_t \tag{38}$$

A média fica constante, α_2, mas sobra um MA(1) com $\theta_1 = -1$. O polinômio $\theta(z) = 1 - z$ tem raiz $z = 1$, sobre o círculo: **não invertível** (AU02, p. 33). É a sobrediferenciação da Q9.

Conclusão (implicação prática): tendência estocástica se remove com **diferença**; tendência determinística se remove com **regressão em** *t*. Aqui, uma diferença e depois a regressão de ΔY_t em *t*. A segunda diferença também estacionariza, mas deixa um MA não invertível.

Versão para a prova (Q2)

O mínimo que precisa estar no papel:

1. Some o modelo de 1 a *t* (telescópica) e use $\sum s = \frac{t(t+1)}{2}$: $Y_t = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum_{s=1}^{t} \varepsilon_s$.
2. Com $a_t = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$ fixo: $E(Y_t) = E(a_t) + E\big(\sum \varepsilon_s\big) = a_t + \sum E(\varepsilon_s) = a_t + \sum 0 = a_t$ [F4, soma finita; RB].
3. $Y_t - \mu_t = \sum \varepsilon_s$, logo $V(Y_t) = E\big((\sum \varepsilon_s)^2\big) = t\sigma^2$ [RB: só $i = j$].
4. $\mathrm{Cov}(Y_t, Y_{t-k}) = E\big(\sum_{i \leq t} \varepsilon_i \sum_{j \leq t-k} \varepsilon_j\big) = (t-k)\sigma^2$.
5. Os momentos dependem de *t*: **não estacionário**.
6. Comparação: só a média muda (reta ⟶ parábola); *V* e Cov são iguais.
7. Tendência estocástica $\sum \varepsilon_s$ + determinística quadrática. $\Delta Y_t = \alpha_1 + \alpha_2 t + \varepsilon_t$ ainda tem tendência: regredir ΔY_t em *t*. $\Delta^2 Y_t = \alpha_2 + (1 - L)\varepsilon_t$ não é invertível: evitar.

Conferência (Q2)

Com $\alpha_1 = 1$ e $\alpha_2 = 0{,}2$:

- a recursão dá $E(Y_1) = 1{,}2$, $E(Y_2) = 2{,}6$ e $E(Y_3) = 4{,}2$;
- a fórmula (20) dá os mesmos valores: $2 + 0{,}2 \cdot 3 = 2{,}6$ e $3 + 0{,}2 \cdot 6 = 4{,}2$;
- com 50 mil trajetórias simuladas e $\sigma^2 = 1$: $V(Y_3) \approx 2{,}99$ (fórmula: 3), $\mathrm{Cov}(Y_3, Y_1) \approx 1{,}00$ (fórmula: 1) e $\mathrm{Corr}(Y_3, Y_1) \approx 0{,}58$ (fórmula: $\sqrt{1/3} = 0{,}577$).

Q6 · ARMA(1,1)

Enunciado (lista, Q6). O ARMA(1,1) $z_t - \phi z_{t-1} = a_t - \theta a_{t-1}$, com $|\phi| < 1$ e $|\theta| < 1$, na convenção de Box-Jenkins. Pede-se:

- (a) γ_0, γ_1 e γ_k $(k \geq 2)$;
- (b) ρ_1, e mostrar que $\rho_k = \phi^{k-1}\rho_1$;
- (c) as formas AR(∞) e MA(∞), e para que parâmetros a convergência é mais lenta.

Nos slides (AU02, p. 81–84), com a constante c, como o professor e o caderno escrevem:

$$y_t = c + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}, \qquad \varepsilon_t \sim RB(0, \sigma^2),$$

ou seja, $(1 - \phi_1 L)\, y_t = c + (1 + \theta_1 L)\, \varepsilon_t$. A tradução da lista:

- $y_t = z_t$ e $\varepsilon_t = a_t$;
- $\phi_1 = \phi$ e $\theta_1 = -\theta$, por causa do sinal positivo dos slides;
- a lista não tem constante: $c = 0$, logo $\mu = 0$ e $y_t - \mu = z_t$.

Hipóteses: [RB]; $|\phi_1| < 1$ (estacionário); $|\theta_1| < 1$ (invertível). No fim, cada resultado volta para o sinal da lista.

(0) Média, forma em desvios e momentos auxiliares

Valor esperado (AU02, p. 82):

$$\begin{aligned}
&(1) \quad E(y_t) = c + \phi_1 E(y_{t-1}) + E(\varepsilon_t) + \theta_1 E(\varepsilon_{t-1}) && \text{[lin.]}\\
&(2) \quad \mu = c + \phi_1 \mu + 0 + 0 && \text{[estac., RB]}\\
&(3) \quad \mu(1 - \phi_1) = c \implies \mu = \frac{c}{1 - \phi_1} && [|\phi_1| < 1]
\end{aligned}$$

Forma em desvios. Subtraia μ dos dois lados do modelo e troque c por $(1 - \phi_1)\mu$, que vem de (3):

$$\begin{aligned}
&(4) \quad y_t - \mu = (1 - \phi_1)\mu - \mu + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1} && [(3)]\\
&(5) \quad \qquad = -\phi_1 \mu + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}\\
&(6) \quad y_t - \mu = \phi_1 (y_{t-1} - \mu) + \varepsilon_t + \theta_1 \varepsilon_{t-1} && \text{[evidência]}
\end{aligned}$$

A linha (6) é o "já sabemos que" da AU02, p. 82 e 84. A constante sumiu: todas as contas abaixo usam (6).

Momentos auxiliares (como no caderno, 02/09). Pelo item (c), $y_t - \mu = \sum_{j \geq 0} \psi_j \varepsilon_{t-j}$: o desvio de hoje só contém choques de hoje e do passado.

$$
\begin{aligned}
&(7)\quad E(\varepsilon_t\varepsilon_t) = \sigma^2 && \text{[RB]}\\
&(8)\quad E\big((y_{t-k}-\mu)\,\varepsilon_t\big) = 0 \quad \text{para } k \geq 1 && \text{[caus., RB]}\\
&(9)\quad E\big((y_t-\mu)\,\varepsilon_t\big) = E\big((\phi_1(y_{t-1}-\mu)+\varepsilon_t+\theta_1\varepsilon_{t-1})\,\varepsilon_t\big) && \text{[(6)]}\\
&(10)\quad = \phi_1\cdot 0 + \sigma^2 + \theta_1\cdot 0 = \sigma^2 && \text{[(8), (7), RB]}\\
&(11)\quad E\big((y_{t+1}-\mu)\,\varepsilon_t\big) = E\big((\phi_1(y_t-\mu)+\varepsilon_{t+1}+\theta_1\varepsilon_t)\,\varepsilon_t\big) && \text{[(6) em } t+1\text{]}\\
&(12)\quad = \phi_1\sigma^2 + 0 + \theta_1\sigma^2 = (\phi_1+\theta_1)\,\sigma^2 && \text{[(10), RB, (7)]}
\end{aligned}
$$

Por estacionariedade, (10) vale em qualquer data. Em $t-1$, $E\big((y_{t-1}-\mu)\varepsilon_{t-1}\big) = \sigma^2$, que é o "lembre que" da AU02, p. 83.

(a) γ_0, γ_1 e γ_k

γ_0 (AU02, p. 82–83). Por (6):

$$
(13)\qquad \gamma_0 = E\big((y_t-\mu)^2\big) = E\Big(\big(\phi_1(y_{t-1}-\mu)+\varepsilon_t+\theta_1\varepsilon_{t-1}\big)^2\Big)
$$

O quadrado é o produto do parêntese por ele mesmo: $3\times 3 = 9$ termos, na ordem do slide. Cada termo com a sua esperança:

$$
\begin{aligned}
&(14)\quad E\big(\phi_1^2(y_{t-1}-\mu)^2\big) = \phi_1^2\gamma_0 && \text{[estac.]}\\
&(15)\quad E\big(\phi_1(y_{t-1}-\mu)\,\varepsilon_t\big) = 0 && \text{[(8)]}\\
&(16)\quad E\big(\phi_1(y_{t-1}-\mu)\,\theta_1\varepsilon_{t-1}\big) = \phi_1\theta_1\sigma^2 && \text{[(10) em } t-1\text{]}\\
&(17)\quad E\big(\varepsilon_t\,\phi_1(y_{t-1}-\mu)\big) = 0 && \text{[(8)]}\\
&(18)\quad E(\varepsilon_t^2) = \sigma^2 && \text{[(7)]}\\
&(19)\quad E(\varepsilon_t\,\theta_1\varepsilon_{t-1}) = 0 && \text{[RB]}\\
&(20)\quad E\big(\theta_1\varepsilon_{t-1}\,\phi_1(y_{t-1}-\mu)\big) = \theta_1\phi_1\sigma^2 && \text{[(10) em } t-1\text{]}\\
&(21)\quad E(\theta_1\varepsilon_{t-1}\,\varepsilon_t) = 0 && \text{[RB]}\\
&(22)\quad E(\theta_1^2\varepsilon_{t-1}^2) = \theta_1^2\sigma^2 && \text{[RB]}
\end{aligned}
$$

Somando (14)–(22): os termos (16) e (20) são iguais e dão $2\theta_1\phi_1\sigma^2$; os quatro zeros somem.

$$
\begin{aligned}
&(23)\quad \gamma_0 = \phi_1^2\gamma_0 + 2\theta_1\phi_1\sigma^2 + \sigma^2 + \theta_1^2\sigma^2 && \text{[(14)–(22)]}\\
&(24)\quad \gamma_0 - \phi_1^2\gamma_0 = \sigma^2(2\theta_1\phi_1 + 1 + \theta_1^2) && \text{[passa } \phi_1^2\gamma_0\text{]}\\
&(25)\quad \gamma_0\,(1-\phi_1^2) = \sigma^2(2\theta_1\phi_1 + 1 + \theta_1^2) && \text{[evidência]}
\end{aligned}
$$

$$
(26)\qquad \boxed{\gamma_0 = \frac{\sigma^2(2\theta_1\phi_1 + 1 + \theta_1^2)}{1-\phi_1^2}} \qquad [\,1-\phi_1^2 \neq 0 \text{ porque } |\phi_1| < 1\,]
$$

É a forma da AU02, p. 83. **Atenção ao erro do caderno:** é θ_1^2, ao quadrado, no numerador.

γ_k**, equação geral** (AU02, p. 84). Multiplique (6) por $(y_{t-k}-\mu)$ e tire a esperança:

$$
(27)\qquad \underbrace{E\big((y_t-\mu)(y_{t-k}-\mu)\big)}_{\gamma_k} = \phi_1\,\underbrace{E\big((y_{t-1}-\mu)(y_{t-k}-\mu)\big)}_{\gamma_{k-1}} + E\big(\varepsilon_t(y_{t-k}-\mu)\big) + \theta_1 E\big(\varepsilon_{t-1}(y_{t-k}-\mu)\big)
$$

$k = 1$**:**

$$\text{(28)}\quad \gamma_1 = \phi_1 E\big((y_{t-1}-\mu)^2\big) + E\big(\varepsilon_t(y_{t-1}-\mu)\big) + \theta_1 E\big(\varepsilon_{t-1}(y_{t-1}-\mu)\big) \quad [(27),\ k=1]$$
$$\text{(29)}\quad = \phi_1\gamma_0 + 0 + \theta_1\sigma^2 \quad [\text{estac., (8), (10)}]$$

Substituindo (26) em (29), com tudo sobre o denominador $1-\phi_1^2$:

$$\text{(30)}\quad \gamma_1 = \frac{\phi_1(1+2\phi_1\theta_1+\theta_1^2)+\theta_1(1-\phi_1^2)}{1-\phi_1^2}\,\sigma^2 \quad [(26)]$$
$$\text{(31)}\quad = \frac{\phi_1+2\phi_1^2\theta_1+\phi_1\theta_1^2+\theta_1-\phi_1^2\theta_1}{1-\phi_1^2}\,\sigma^2 \quad [\text{distributiva}]$$
$$\text{(32)}\quad = \frac{\phi_1+\theta_1+\phi_1^2\theta_1+\phi_1\theta_1^2}{1-\phi_1^2}\,\sigma^2 \quad [2\phi_1^2\theta_1-\phi_1^2\theta_1]$$

Fatoração do numerador, conferida por expansão: $(1+\phi_1\theta_1)(\phi_1+\theta_1) = \phi_1+\theta_1+\phi_1^2\theta_1+\phi_1\theta_1^2$ ✓. Logo:

$$\text{(33)}\quad \boxed{\gamma_1 = \phi_1\gamma_0 + \theta_1\sigma^2 = \frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1-\phi_1^2}\,\sigma^2}$$

$k \geq 2$**:** em (27), os dois últimos termos são zero por (8):

- $E\big(\varepsilon_t(y_{t-k}-\mu)\big) = 0$, porque $k \geq 1$;
- $E\big(\varepsilon_{t-1}(y_{t-k}-\mu)\big) = 0$, porque a distância entre $t-1$ e $t-k$ é $k-1 \geq 1$.

Sobra $\gamma_k = \phi_1\gamma_{k-1}$. **Indução:**

- base, $k=2$: $\gamma_2 = \phi_1\gamma_1$;
- passo: se $\gamma_{k-1} = \phi_1^{k-2}\gamma_1$, então $\gamma_k = \phi_1 \cdot \phi_1^{k-2}\gamma_1 = \phi_1^{k-1}\gamma_1$.

$$\text{(34)}\quad \boxed{\gamma_k = \phi_1\,\gamma_{k-1} = \phi_1^{k-1}\gamma_1 \quad (k \geq 2)}$$

Atenção ao erro do caderno: o expoente é $k-1$, não k. Confira com $k=2$: um único ϕ_1.

(b) FAC

$$\text{(35)}\quad \rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)\sigma^2/(1-\phi_1^2)}{(1+2\phi_1\theta_1+\theta_1^2)\sigma^2/(1-\phi_1^2)} \quad [(33),(26)]$$
$$\text{(36)}\quad = \frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1+2\phi_1\theta_1+\theta_1^2} \quad [\text{cancela } \sigma^2 \text{ e } 1-\phi_1^2]$$

$\rho_k = \phi_1^{k-1}\rho_1$ **por indução**, dividindo (34) por γ_0:

- **base,** $k=1$**:** $\phi_1^0\rho_1 = \rho_1$ ✓;
- **passo:** se $\rho_{k-1} = \phi_1^{k-2}\rho_1$, então $\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\phi_1\gamma_{k-1}}{\gamma_0} = \phi_1\rho_{k-1} = \phi_1 \cdot \phi_1^{k-2}\rho_1 = \phi_1^{k-1}\rho_1$ ✓.

$$\text{(37)}\quad \boxed{\rho_k = \phi_1^{k-1}\rho_1 \quad (k \geq 1)}$$

Conclusão: a FAC decai geometricamente, à taxa ϕ_1, mas **a partir de ρ_1, e não de 1**. O MA só altera o primeiro valor.

(c) MA(∞), AR(∞) e a velocidade de convergência

Como na lista, $c = 0$: então $\mu = 0$ e $y_t - \mu = y_t$. Com constante, troque cada y por $y - \mu$, pela forma em desvios (6).

MA(∞), caminho 1 — substituição recursiva.

$$
\begin{aligned}
(38)\quad & y_t = \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1} && \text{[modelo]}\\
(39)\quad & \quad = \phi_1(\phi_1 y_{t-2} + \varepsilon_{t-1} + \theta_1 \varepsilon_{t-2}) + \varepsilon_t + \theta_1 \varepsilon_{t-1} && \text{[modelo em } t-1\text{]}\\
(40)\quad & \quad = \varepsilon_t + (\phi_1 + \theta_1)\varepsilon_{t-1} + \phi_1\theta_1\varepsilon_{t-2} + \phi_1^2 y_{t-2} && \text{[agrupando]}\\
(41)\quad & \quad = \varepsilon_t + (\phi_1 + \theta_1)\varepsilon_{t-1} + \phi_1(\phi_1 + \theta_1)\varepsilon_{t-2} + \phi_1^2\theta_1\varepsilon_{t-3} + \phi_1^3 y_{t-3} && \text{[modelo em } t-2\text{]}
\end{aligned}
$$

Em (41), o coeficiente de ε_{t-2} é $\phi_1\theta_1 + \phi_1^2 = \phi_1(\phi_1 + \theta_1)$. O padrão: o coeficiente de ε_{t-j}, $j \geq 1$, é $(\phi_1 + \theta_1)\phi_1^{j-1}$. Depois de n substituições, o resto é $\phi_1^{n-1}\theta_1\varepsilon_{t-n} + \phi_1^n y_{t-n}$. Ele vai a zero em média quadrática, porque $E(\phi_1^{2n} y_{t-n}^2) = \phi_1^{2n}\gamma_0 \to 0$ quando $|\phi_1| < 1$.

MA(∞), caminho 2 — igualdade de coeficientes. $\Psi(L) = \frac{1+\theta_1 L}{1-\phi_1 L}$ significa $\Psi(L)(1 - \phi_1 L) = 1 + \theta_1 L$. Expandindo o lado esquerdo:

$$
(1 + \psi_1 L + \psi_2 L^2 + \cdots)(1 - \phi_1 L) = 1 + (\psi_1 - \phi_1)L + (\psi_2 - \phi_1\psi_1)L^2 + \cdots + (\psi_j - \phi_1\psi_{j-1})L^j + \cdots
$$

Igualando com $1 + \theta_1 L$, potência por potência:

- L^1: $\psi_1 - \phi_1 = \theta_1$, logo $\psi_1 = \phi_1 + \theta_1$;
- L^j, $j \geq 2$: $\psi_j - \phi_1\psi_{j-1} = 0$, logo $\psi_j = \phi_1\psi_{j-1}$.

$$
(42)\qquad \boxed{\psi_0 = 1, \quad \psi_j = (\phi_1 + \theta_1)\,\phi_1^{j-1}\ (j \geq 1)} \qquad y_t = \varepsilon_t + (\phi_1 + \theta_1)\sum_{j\geq 1}\phi_1^{j-1}\varepsilon_{t-j}
$$

AR(∞). $\pi(L) = \frac{1-\phi_1 L}{1+\theta_1 L}$, com $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots$ (AU02, p. 19).

- Pela série geométrica com razão $-\theta_1 L$, válida porque $|\theta_1| < 1$: $(1 + \theta_1 L)^{-1} = \sum_{j\geq 0}(-\theta_1)^j L^j$.
- Multiplicando por $(1 - \phi_1 L)$, o coeficiente de L^j, $j \geq 1$, é

$$
(-\theta_1)^j - \phi_1(-\theta_1)^{j-1} = (-\theta_1)^{j-1}(-\theta_1 - \phi_1) = -(\phi_1 + \theta_1)(-\theta_1)^{j-1}.
$$

- Comparando com $-\pi_j$:

$$
(43)\qquad \boxed{\pi_j = (\phi_1 + \theta_1)\,(-\theta_1)^{j-1}\ (j \geq 1)} \qquad y_t = \sum_{j\geq 1}\pi_j\, y_{t-j} + \varepsilon_t
$$

Quando cada série converge.

- $\sum_j |\psi_j| = 1 + |\phi_1 + \theta_1|\sum_{j\geq 1}|\phi_1|^{j-1} = 1 + \frac{|\phi_1+\theta_1|}{1-|\phi_1|} < \infty \iff |\phi_1| < 1$, que é a **estacionariedade**.
- $\sum_j |\pi_j| = \frac{|\phi_1+\theta_1|}{1-|\theta_1|} < \infty \iff |\theta_1| < 1$, que é a **invertibilidade**.

Quando a convergência é mais lenta. Os $|\psi_j|$ encolhem por um fator $|\phi_1|$ a cada período. A **meia-vida**, o número de períodos para um peso cair à metade, resolve $|\phi_1|^h = \frac{1}{2}$:

$$
h = \frac{\ln 0{,}5}{\ln|\phi_1|}\ : \qquad \phi_1 = 0{,}5 \Rightarrow h = 1; \qquad \phi_1 = 0{,}9 \Rightarrow h = 6{,}58; \qquad \phi_1 = 0{,}99 \Rightarrow h = 68{,}97.
$$

- **MA(∞) mais lento quando** $|\phi_1| \to 1$: perto da raiz unitária, os choques demoram a morrer.

- **AR(∞) mais lento quando** $|\theta_1| \to 1$: perto da não invertibilidade, é preciso muito passado de y para recuperar ε_t.
- **Caso extremo,** $\phi_1 = -\theta_1$**:** $\psi_j = \pi_j = 0$ para $j \geq 1$, e $y_t = \varepsilon_t$. Os fatores se cancelam: é um fator comum.

De volta ao sinal da lista ($\theta_1 = -\theta$)

	Slides	Lista
γ_0	$\frac{1+2\phi_1\theta_1+\theta_1^2}{1-\phi_1^2}\sigma^2$	$\frac{1-2\phi\theta+\theta^2}{1-\phi^2}\sigma_a^2$
γ_1	$\frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1-\phi_1^2}\sigma^2$	$\frac{(1-\phi\theta)(\phi-\theta)}{1-\phi^2}\sigma_a^2$
ρ_1	$\frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1+2\phi_1\theta_1+\theta_1^2}$	$\frac{(1-\phi\theta)(\phi-\theta)}{1-2\phi\theta+\theta^2}$
ρ_k	$\phi_1^{k-1}\rho_1$	$\phi^{k-1}\rho_1$
ψ_j	$(\phi_1+\theta_1)\phi_1^{j-1}$	$(\phi-\theta)\phi^{j-1}$
π_j	$(\phi_1+\theta_1)(-\theta_1)^{j-1}$	$(\phi-\theta)\theta^{j-1}$

Versão para a prova (Q6)

1. Convenção: sinais dos slides, $\theta_1 = -\theta$.
2. $\mu = \frac{c}{1-\phi_1}$ e a forma em desvios $y_t - \mu = \phi_1(y_{t-1}-\mu) + \varepsilon_t + \theta_1\varepsilon_{t-1}$ (na lista, $c = 0$).
3. Momentos auxiliares: $E(\varepsilon_t\varepsilon_t) = \sigma^2$; $E\big((y_{t-k}-\mu)\varepsilon_t\big) = 0$ para $k \geq 1$; $E\big((y_t-\mu)\varepsilon_t\big) = \sigma^2$; $E\big((y_{t+1}-\mu)\varepsilon_t\big) = (\phi_1+\theta_1)\sigma^2$.
4. $\gamma_0 = E\big((\phi_1(y_{t-1}-\mu) + \varepsilon_t + \theta_1\varepsilon_{t-1})^2\big)$: nove termos, quatro zeros, $\gamma_0 = \phi_1^2\gamma_0 + 2\theta_1\phi_1\sigma^2 + \sigma^2 + \theta_1^2\sigma^2$, logo $\gamma_0 = \frac{\sigma^2(2\theta_1\phi_1+1+\theta_1^2)}{1-\phi_1^2}$.
5. $\gamma_1 = \phi_1\gamma_0 + \theta_1\sigma^2 = \frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1-\phi_1^2}\sigma^2$.
6. $k \geq 2$: $\gamma_k = \phi_1\gamma_{k-1}$, porque os dois choques do modelo são posteriores a y_{t-k}.
7. $\rho_1 = \gamma_1/\gamma_0$; $\rho_k = \phi_1\rho_{k-1} = \phi_1^{k-1}\rho_1$ (indução).
8. $\Psi(L)(1-\phi_1 L) = 1 + \theta_1 L$ dá $\psi_j = (\phi_1+\theta_1)\phi_1^{j-1}$, que converge se $|\phi_1| < 1$.
9. $\pi(L)(1+\theta_1 L) = 1 - \phi_1 L$ dá $\pi_j = (\phi_1+\theta_1)(-\theta_1)^{j-1}$, que converge se $|\theta_1| < 1$.
10. Mais lento: $|\phi_1| \to 1$ para os ψ e $|\theta_1| \to 1$ para os π. Meia-vida $\ln 0{,}5 / \ln|\phi_1|$.
11. Traduzir para a lista com $\theta_1 = -\theta$.

Conferência (Q6)

Com $\phi_1 = 0{,}7$, $\theta_1 = -0{,}4$ (isto é, $\theta^{\text{lista}} = 0{,}4$) e $\sigma^2 = 1$:

- $\gamma_0 = \frac{1-0{,}56+0{,}16}{0{,}51} = 1{,}1765$;
- $\gamma_1 = 0{,}7(1{,}1765) - 0{,}4 = 0{,}4235$;
- $\rho_1 = 0{,}36$ e $\rho_2 = 0{,}252$;
- $\psi_1, \psi_2, \psi_3 = 0{,}3;\ 0{,}21;\ 0{,}147$ e $\pi_1, \pi_2, \pi_3 = 0{,}3;\ 0{,}12;\ 0{,}048$.

A substituição recursiva (42) e a fórmula (43) coincidem com o `ARMAtoMA` do R, com diferença zero.