Séries temporais

À mão — cap. 2

AR, MA e ARMA: Q5 a Q8 linha a linha, na notação dos slides e do caderno

---

Caderno de estudo · parte 1: ARMA, ARIMA e SARIMA

Prof. Guilherme Pereira · Econometria II (PPGEco/UFES)

Gerado em 28/10/2026 a partir de `github.com/fcarva/series-temporais` (commit `ad1330b`). Material autoral: enunciados parafraseados, demonstrações próprias, números conferidos em R contra os scripts do repositório.

Sumário

I Bloco 2 à mão: Q5 a Q8 **1**

1 Cap. 2 à mão — Q5 a Q8 linha a linha **2**

II Apêndice: Q2 e Q6 completas **9**

2 Demonstrações à mão — Q2 e Q6, linha a linha **10**

Parte I

Bloco 2 à mão: Q5 a Q8

Cap. 2 à mão — Q5 a Q8 linha a linha

Cap. 2 à mão: Q5 a Q8, linha a linha

← capítulo 2 · ← apostila

Esta é a versão de **caderno** do bloco 2 da lista, no mesmo formato da folha da Q2 e da Q6: cada passagem numerada, uma operação por linha e o motivo entre colchetes. Os símbolos são os dos slides: L, ε_t, ϕ_1, e θ_1 com sinal positivo. A tradução para a lista vem em cada questão. A numeração das linhas é contínua do início ao fim, para que "[(19)]" aponte sempre para a mesma linha.

Legenda:

- [RB]: ruído branco, $E(\varepsilon_t) = 0$, $E(\varepsilon_t^2) = \sigma^2$ e $E(\varepsilon_t \varepsilon_s) = 0$ se $t \neq s$;
-
- [F2]: série geométrica;
- [F3]: soma de Gauss;
- [F4]: linearidade da esperança;
- [F7]: igualar coeficientes;
- [F8]: multiplicar polinômios;
- [estac.]: os momentos não dependem da data;
- [caus.]: o choque de hoje não se correlaciona com o passado de y;
- [(n)]: usando a linha (n).

As ferramentas estão demonstradas na caixa de ferramentas.

Q5 · Três modelos: operador, classificação, raízes e pesos

Enunciado (lista, Q5). Três modelos em $\tilde{z}_t$ e a_t:

- (1) um AR(1) com coeficiente 0,5;
- (2) um MA(2) com −1,3 e +0,4;
- (3) os dois juntos.

Pede-se:

- escrever cada um com o operador de retardo e classificá-lo como ARMA(p, q);
- verificar estacionariedade e invertibilidade;
- obter $\psi_1, \ldots, \psi_4$ e $\pi_1, \ldots, \pi_4$.

Nos slides: $a_t = \varepsilon_t$ e $B = L$. Os pesos ψ_j e π_j **não dependem** da convenção do MA, porque $\tilde{z}_t = \sum \psi_j \varepsilon_{t-j}$ e $\tilde{z}_t = \sum \pi_j \tilde{z}_{t-j} + \varepsilon_t$ são as mesmas equações nas duas notações (AU02, p. 16 e 19).

Modelo (1): $\tilde{z}_t - 0{,}5\tilde{z}_{t-1} = \varepsilon_t$

(1)	$\tilde{z}_t - 0{,}5\,\tilde{z}_{t-1} = \varepsilon_t$	[lista]
(2)	$(1 - 0{,}5L)\,\tilde{z}_t = \varepsilon_t$	[$L\tilde{z}_t = \tilde{z}_{t-1}$, AU02 p. 11]
(3)	$\phi(L) = 1 - 0{,}5L$ (grau 1), $\theta(L) = 1$ (grau 0) $\Rightarrow$ ARMA$(1,0)$	[classifica]
(4)	$1 - 0{,}5z = 0 \Rightarrow z = 2$	[raiz do AR]
(5)	$\lvert z\rvert = 2 > 1 \Rightarrow$ estacionário	[AU02 p. 27]
(6)	não há polinômio MA $\Rightarrow$ invertível	[AU02 p. 36]
(7)	$\Psi(L) = (1 - 0{,}5L)^{-1} = \sum_{j\geq 0} 0{,}5^j L^j$	[F2, $\lvert 0{,}5\rvert < 1$]
(8)	$\psi_1 = 0{,}5;\ \psi_2 = 0{,}25;\ \psi_3 = 0{,}125;\ \psi_4 = 0{,}0625$	[$\psi_j = 0{,}5^j$]
(9)	$\pi(L) = 1 - 0{,}5L \Rightarrow \pi_1 = 0{,}5,\ \pi_2 = \pi_3 = \pi_4 = 0$	[já está na forma AR]

AR(1) : estacionário ($z = 2$) e invertível; $\psi_j = 0{,}5^j$; $\pi_1 = 0{,}5,\ \pi_{j\geq 2} = 0$

Modelo (2): $\tilde{z}_t = \varepsilon_t - 1{,}3\varepsilon_{t-1} + 0{,}4\varepsilon_{t-2}$

(10)	$\tilde{z}_t = \varepsilon_t - 1{,}3\,\varepsilon_{t-1} + 0{,}4\,\varepsilon_{t-2}$	[lista]
(11)	$\tilde{z}_t = (1 - 1{,}3L + 0{,}4L^2)\,\varepsilon_t$, $\theta_1 = -1{,}3,\ \theta_2 = 0{,}4$	[slides: $\theta(L) = 1 + \theta_1 L + \theta_2 L^2$]
(12)	$\phi(L) = 1$, $\theta(L)$ de grau 2 $\Rightarrow$ ARMA$(0,2)$	[classifica]
(13)	$\sum\lvert\psi_j\rvert = 1 + 1{,}3 + 0{,}4 = 2{,}7 < \infty \Rightarrow$ estacionário	[AU02 p. 29: MA finito]
(14)	$\theta(z) = 0 \iff 0{,}4z^2 - 1{,}3z + 1 = 0$: $a = 0{,}4,\ b = -1{,}3,\ c = 1$	[F1, forma padrão]
(15)	$\Delta = b^2 - 4ac = (-1{,}3)^2 - 4(0{,}4)(1) = 1{,}69 - 1{,}60 = 0{,}09$	[F1]
(16)	$z = \dfrac{-b \pm \sqrt{\Delta}}{2a} = \dfrac{1{,}3 \pm 0{,}3}{0{,}8} \Rightarrow z_1 = 2,\ z_2 = 1{,}25$	[F1, $\sqrt{0{,}09} = 0{,}3$]
(17)	$z_1 + z_2 = 3{,}25 = -b/a$; $\quad z_1 z_2 = 2{,}5 = c/a$	[Vieta: confere]
(18)	$\lvert 2\rvert > 1$ e $\lvert 1{,}25\rvert > 1 \Rightarrow$ invertível	[AU02 p. 33]
(19)	$1 - 1{,}3L + 0{,}4L^2 = (1 - 0{,}5L)(1 - 0{,}8L)$	[F8: $1 - 0{,}8L - 0{,}5L + 0{,}4L^2$]
(20)	$\psi_1 = -1{,}3;\ \psi_2 = 0{,}4;\ \psi_3 = \psi_4 = 0$	[o MA já é a forma MA(∞)]

Pesos π, igualando coeficientes. Escreva $\theta(L)^{-1} = 1 + c_1 L + c_2 L^2 + \cdots$ e exija $\theta(L)^{-1}\theta(L) = 1$, potência por potência:

(21)	$(1 + c_1 L + c_2 L^2 + c_3 L^3 + \cdots)(1 - 1{,}3L + 0{,}4L^2) = 1$	[F7]
(22)	L^1 : $c_1 - 1{,}3 = 0 \Rightarrow c_1 = 1{,}3$	[coeficiente de L]
(23)	L^2 : $c_2 - 1{,}3c_1 + 0{,}4 = 0 \Rightarrow c_2 = 1{,}69 - 0{,}4 = 1{,}29$	[(22)]
(24)	L^3 : $c_3 - 1{,}3c_2 + 0{,}4c_1 = 0 \Rightarrow c_3 = 1{,}677 - 0{,}52 = 1{,}157$	[(22), (23)]
(25)	L^4 : $c_4 - 1{,}3c_3 + 0{,}4c_2 = 0 \Rightarrow c_4 = 1{,}5041 - 0{,}516 = 0{,}9881$	[(23), (24)]
(26)	$\pi(L) = \theta(L)^{-1} = 1 - \pi_1 L - \pi_2 L^2 - \cdots \Rightarrow \pi_j = -c_j$	[AU02 p. 19–20]
(27)	$\pi_1 = -1{,}3;\ \pi_2 = -1{,}29;\ \pi_3 = -1{,}157;\ \pi_4 = -0{,}9881$	[(22)–(26)]

MA(2) : estacionário; invertível ($z = 2;\ 1{,}25$); π_j decaem devagar, à taxa $1/1{,}25 = 0{,}8$

Modelo (3): $\tilde{z}_t - 0{,}5\tilde{z}_{t-1} = \varepsilon_t - 1{,}3\varepsilon_{t-1} + 0{,}4\varepsilon_{t-2}$

(28)	$(1-0{,}5L)\,\tilde{z}_t = (1-1{,}3L+0{,}4L^2)\,\varepsilon_t$	[lista em L]
(29)	$(1-0{,}5L)\,\tilde{z}_t = (1-0{,}5L)(1-0{,}8L)\,\varepsilon_t$	[(19)]
(30)	$\tilde{z}_t = (1-0{,}8L)\,\varepsilon_t$	[$\times(1-0{,}5L)^{-1}$, F2]
(31)	parece ARMA(1,2), mas é MA(1) = ARMA(0, 1)	[fator comum]
(32)	estacionário: MA finito	[AU02 p. 29]
(33)	$1-0{,}8z=0 \;\Rightarrow\; z=1{,}25>1 \;\Rightarrow$ invertível	[AU02 p. 33]
(34)	$\psi_1 = -0{,}8;\;\; \psi_j = 0,\; j \geq 2$	[(30)]

Conferência dos ψ pelo modelo inteiro, sem cancelar nada: exija $\Psi(L)(1-0{,}5L) = 1-1{,}3L+0{,}4L^2$ potência por potência.

(35)	$L^1 :\; \psi_1 - 0{,}5 = -1{,}3 \;\Rightarrow\; \psi_1 = -0{,}8$	[F7]
(36)	$L^2 :\; \psi_2 - 0{,}5\psi_1 = 0{,}4 \;\Rightarrow\; \psi_2 = 0{,}4 - 0{,}4 = 0$	[F7, (35)]
(37)	$\pi_j = -(-\theta_1)^j$ com $\theta_1 = -0{,}8 \;\Rightarrow\; \pi_j = -0{,}8^{\,j}$	[AU02 p. 23]
(38)	$\pi_1 = -0{,}8;\; \pi_2 = -0{,}64;\; \pi_3 = -0{,}512;\; \pi_4 = -0{,}4096$	[(37)]

fator comum $(1-0{,}5L)$: o modelo (3) é o MA(1) $\tilde{z}_t = \varepsilon_t - 0{,}8\varepsilon_{t-1}$ (lista: $\theta = 0{,}8$)

Como enxergar o fator comum sem fatorar: a raiz do AR, $z = 2$, aparece também entre as raízes do MA, $\{2;\; 1{,}25\}$.

Q6 · ARMA(1,1): o roteiro, com a demonstração completa ao lado

A Q6 está demonstrada por inteiro, em 43 linhas, na folha da Q2 e da Q6, com os nove termos de γ_0 na ordem do slide. Aqui fica o esqueleto, para conferir que nenhum passo foi esquecido. O modelo é $y_t - \mu = \phi_1(y_{t-1}-\mu) + \varepsilon_t + \theta_1\varepsilon_{t-1}$, com $\theta_1 = -\theta^{\text{lista}}$.

(39)	$E\big((y_t-\mu)\varepsilon_t\big) = \sigma^2, \quad E\big((y_{t+1}-\mu)\varepsilon_t\big) = (\phi_1+\theta_1)\sigma^2$	[momentos auxiliares]
(40)	$\gamma_0 = \phi_1^2\gamma_0 + 2\theta_1\phi_1\sigma^2 + \sigma^2 + \theta_1^2\sigma^2$	[nove termos, quatro zeros]
(41)	$\gamma_0 = \dfrac{\sigma^2(2\theta_1\phi_1 + 1 + \theta_1^2)}{1-\phi_1^2}$	[isola, AU02 p. 83]
(42)	$\gamma_1 = \phi_1\gamma_0 + \theta_1\sigma^2 = \dfrac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1-\phi_1^2}\,\sigma^2$	[$\times(y_{t-1}-\mu)$, AU02 p. 84]
(43)	$\gamma_k = \phi_1\gamma_{k-1} = \phi_1^{k-1}\gamma_1, \quad k \geq 2$	[caus.; indução]
(44)	$\rho_k = \phi_1^{k-1}\rho_1, \quad k \geq 1$	[$\div\gamma_0$]
(45)	$\psi_j = (\phi_1+\theta_1)\,\phi_1^{j-1}; \qquad \pi_j = (\phi_1+\theta_1)(-\theta_1)^{j-1}$	[F7, F2]
(46)	lista: $\psi_j = (\phi-\theta)\phi^{j-1}; \qquad \pi_j = (\phi-\theta)\theta^{j-1}$	[$\theta_1 = -\theta$]

Q7 · AR(2): Yule-Walker, ρ_1, ρ_2 e γ_0

Enunciado (lista, Q7). Para $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$:

- escrever as equações de Yule-Walker e obter ρ_1 e ρ_2 em função de ϕ_1 e ϕ_2;
- obter a variância γ_0.

Nos slides: a mesma notação (AU02, p. 66–69), com média zero.

(47)	$y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t, \quad E(y_t) = 0$	[modelo]
(48)	$E(\varepsilon_t\, y_{t-k}) = 0, \quad k \geq 1$	[caus.]
(49)	$E(\varepsilon_t\, y_t) = 0 + 0 + E(\varepsilon_t^2) = \sigma^2$	[F4; (48) zera dois termos]
(50)	$\times\, y_{t-1}\ :\ \ \gamma_1 = \phi_1\gamma_0 + \phi_2\gamma_1$	[$E(y_{t-2}y_{t-1}) = \gamma_1$, (48)]
(51)	$\times\, y_{t-2}\ :\ \ \gamma_2 = \phi_1\gamma_1 + \phi_2\gamma_0$	[(48)]
(52)	$\rho_1 = \phi_1 + \phi_2\rho_1; \qquad \rho_2 = \phi_1\rho_1 + \phi_2$	[$\div\gamma_0$: Yule-Walker, AU02 p. 68–69]
(53)	$\rho_1(1-\phi_2) = \phi_1 \ \Rightarrow\ \rho_1 = \dfrac{\phi_1}{1-\phi_2}$	[(52)]
(54)	$\rho_2 = \dfrac{\phi_1^2}{1-\phi_2} + \phi_2 = \dfrac{\phi_1^2 + \phi_2 - \phi_2^2}{1-\phi_2}$	[(53); denominador comum]
(55)	$\times\, y_t\ :\ \ \gamma_0 = \phi_1\gamma_1 + \phi_2\gamma_2 + \sigma^2$	[(49)]
(56)	$\gamma_0 = \dfrac{\sigma^2}{1 - \phi_1\rho_1 - \phi_2\rho_2}$	[(55) $\div\,\gamma_0$, isola]
(57)	$1 - \phi_1\rho_1 - \phi_2\rho_2 = \dfrac{(1-\phi_2) - \phi_1^2 - \phi_2(\phi_1^2 + \phi_2 - \phi_2^2)}{1-\phi_2}$	[(53), (54)]
(58)	numerador $= (1-\phi_2)(1-\phi_2^2) - \phi_1^2(1+\phi_2)$	[agrupa]
(59)	$= (1+\phi_2)\big[(1-\phi_2)^2 - \phi_1^2\big]$	[$1-\phi_2^2 = (1-\phi_2)(1+\phi_2)$]
(60)	$\gamma_0 = \dfrac{(1-\phi_2)\,\sigma^2}{(1+\phi_2)\big[(1-\phi_2)^2 - \phi_1^2\big]}$	[(56)–(59)]
(61)	$(1-\phi_2)^2 - \phi_1^2 = (1-\phi_2-\phi_1)(1-\phi_2+\phi_1)$	[diferença de quadrados]
(62)	$\gamma_0 > 0 \iff 1+\phi_2 > 0,\ \ \phi_1+\phi_2 < 1,\ \ \phi_2-\phi_1 < 1$	[o triângulo, AU02 p. 41]

$$\boxed{\rho_1 = \frac{\phi_1}{1-\phi_2}, \qquad \rho_2 = \frac{\phi_1^2 + \phi_2 - \phi_2^2}{1-\phi_2}, \qquad \gamma_0 = \frac{(1-\phi_2)\,\sigma^2}{(1+\phi_2)\big[(1-\phi_2)^2 - \phi_1^2\big]}}$$

Em (56), divide-se (55) por γ_0: $1 = \phi_1\rho_1 + \phi_2\rho_2 + \sigma^2/\gamma_0$. Em (58), $(1-\phi_2) - \phi_2^2(1-\phi_2) = (1-\phi_2)(1-\phi_2^2)$. Em (62), os três fatores de (60)–(61) são exatamente as três desigualdades do triângulo de estacionariedade. A variância só existe, e é positiva, dentro dele.

Com o exemplo do caderno, $\phi_1 = 1{,}5$ e $\phi_2 = -0{,}6$:

- $\rho_1 = 1{,}5/1{,}6 = 0{,}9375$ e $\rho_2 = 0{,}80625$;
- os fatores são $1+\phi_2 = 0{,}4$, $1-\phi_2-\phi_1 = 0{,}1$ e $1-\phi_2+\phi_1 = 3{,}1$, todos positivos;
- $\gamma_0 = 12{,}9032\,\sigma^2$. A variância é grande porque o fator 0,1 está perto de zero: o processo está perto da borda do triângulo.

Q8 · Verdadeiro ou falso, com demonstração

Enunciado (lista, Q8). São dois modelos, e cinco afirmativas para julgar com demonstração:

- **(I)** $Y_t = \alpha Y_{t-1} + u_t + \beta u_{t-1}$, com $0 < \alpha < 1$;
- **(II)** $Z_t = c + Z_{t-1} + \theta t + \varepsilon_t$.

Nos slides: a Q8 **já usa o sinal positivo**. O (I) é o ARMA(1,1) da AU02, p. 81, com $\phi_1 = \alpha$ e $\theta_1 = \beta$. O (II) é o passeio com drift e tendência da AU01, p. 30, com $\alpha_1 = c$ e $\alpha_2 = \theta$. Mantenho as letras da lista, e $\gamma_h = E(Y_t Y_{t+h})$.

Momentos auxiliares do (I):

$$
\begin{aligned}
&(63)\quad E(Y_{t-1}u_t) = 0 && [\text{caus.}]\\
&(64)\quad E(Y_t u_t) = \alpha E(Y_{t-1}u_t) + E(u_t^2) + \beta E(u_{t-1}u_t) = \sigma^2 && [\text{F4, (63), RB}]\\
&(65)\quad E(Y_t u_{t-1}) = \alpha E(Y_{t-1}u_{t-1}) + E(u_t u_{t-1}) + \beta E(u_{t-1}^2) = (\alpha+\beta)\sigma^2 && [(64)\text{ em } t-1,\ \text{RB}]
\end{aligned}
$$

Afirmativa 1: $\gamma_0 = \alpha\gamma_1 + \sigma^2 + \beta(\alpha+\beta)\sigma^2$.

$$
\begin{aligned}
&(66)\quad \gamma_0 = E(Y_t Y_t) = \alpha E(Y_{t-1}Y_t) + E(u_t Y_t) + \beta E(u_{t-1}Y_t) && [\text{modelo} \times Y_t]\\
&(67)\quad = \alpha\gamma_1 + \sigma^2 + \beta(\alpha+\beta)\sigma^2 \ \Rightarrow\ \textbf{VERDADEIRA} && [(64),(65)]
\end{aligned}
$$

Afirmativa 2: $\gamma_1 = \alpha(\gamma_0 + \sigma^2) + \beta\sigma^2$.

$$
\begin{aligned}
&(68)\quad \gamma_1 = E(Y_{t+1}Y_t) = \alpha E(Y_t Y_t) + E(u_{t+1}Y_t) + \beta E(u_t Y_t) && [\text{modelo em } t+1,\ \times Y_t]\\
&(69)\quad = \alpha\gamma_0 + 0 + \beta\sigma^2 && [\text{caus.: } u_{t+1} \text{ é futuro; (64)}]\\
&(70)\quad \text{afirmativa} - \text{certo} = \alpha\sigma^2 \neq 0 \ \Rightarrow\ \textbf{FALSA} && [\alpha > 0]
\end{aligned}
$$

Afirmativa 3: $\rho_h = \frac{(\beta+\alpha)(1+\alpha\beta)}{1+2\alpha\beta+\beta^2}$ para todo h.

$$
\begin{aligned}
&(71)\quad \gamma_0 = \frac{1+2\alpha\beta+\beta^2}{1-\alpha^2}\sigma^2, \quad \gamma_1 = \frac{(1+\alpha\beta)(\alpha+\beta)}{1-\alpha^2}\sigma^2 && [(67),(69)]\\
&(72)\quad \rho_1 = \frac{(\alpha+\beta)(1+\alpha\beta)}{1+2\alpha\beta+\beta^2} && [(71)]\\
&(73)\quad \gamma_h = \alpha\gamma_{h-1},\ h \geq 2 \ \Rightarrow\ \rho_h = \alpha^{h-1}\rho_1 && [\text{caus.; (43)}]\\
&(74)\quad \text{a expressão só vale em } h=1;\ \text{para } h \geq 2 \text{ falta } \alpha^{h-1} \ \Rightarrow\ \textbf{FALSA} && [(72),(73)]
\end{aligned}
$$

Em (71), resolve-se o sistema formado por (67) e (69), como na Q6.

Afirmativa 4: $Z_t = ct + \frac{\theta}{2}t^2 + Z_0 + \sum_{j=1}^{t}\varepsilon_j$.

$$
\begin{aligned}
&(75)\quad Z_s - Z_{s-1} = c + \theta s + \varepsilon_s && [\text{modelo}]\\
&(76)\quad Z_t - Z_0 = ct + \theta\textstyle\sum_{s=1}^{t} s + \sum_{s=1}^{t}\varepsilon_s && [\text{soma de 1 a } t,\ \text{telescópica}]\\
&(77)\quad Z_t = Z_0 + ct + \theta\frac{t(t+1)}{2} + \textstyle\sum_{j=1}^{t}\varepsilon_j && [\text{F3}]\\
&(78)\quad \theta\frac{t(t+1)}{2} = \frac{\theta}{2}t^2 + \frac{\theta}{2}t \neq \frac{\theta}{2}t^2 \ \Rightarrow\ \textbf{FALSA} && [\text{falta } \theta t/2]
\end{aligned}
$$

Afirmativa 5: $V(Z_t) = (c+\theta t)\sigma^2$.

$$
\begin{aligned}
&(79)\quad V(Z_t) = V\Big(\textstyle\sum_{j=1}^{t}\varepsilon_j\Big) && [(77):\ Z_0,\ ct,\ \theta t(t+1)/2 \text{ são constantes}]\\
&(80)\quad = \textstyle\sum_{j=1}^{t} V(\varepsilon_j) = t\sigma^2 \neq (c+\theta t)\sigma^2 \ \Rightarrow\ \textbf{FALSA} && [\text{RB: sem covariâncias}]
\end{aligned}
$$

Gabarito da Q8: V, F, F, F, F

Versão para a prova

Q5, para cada modelo, quatro linhas:

1. Escreva em L e diga o grau de $\phi(L)$ e de $\theta(L)$.
2. Calcule as raízes: $\phi(z)$ para a estacionariedade e $\theta(z)$ para a invertibilidade, com Bhaskara e Vieta.
3. Obtenha os ψ por $\Psi(L)\phi(L) = \theta(L)$ e os π por $\pi(L)\theta(L) = \phi(L)$, potência por potência.
4. **Procure raiz repetida dos dois lados**: no modelo (3), o fator $(1 - 0{,}5L)$ cancela, e sobra um MA(1).

Q6: as linhas (39)–(46), ou a versão de 10 itens da folha da Q6.

Q7:

1. Multiplique por y_{t-1} e y_{t-2} e divida por γ_0: $\rho_1 = \phi_1/(1 - \phi_2)$ e $\rho_2 = \phi_1\rho_1 + \phi_2$.
2. Multiplique por y_t: $\gamma_0 = \sigma^2/(1 - \phi_1\rho_1 - \phi_2\rho_2)$.
3. Simplifique até (60).
4. Feche com o triângulo.

Q8:

1. Escreva os dois momentos auxiliares.
2. Em cada item, a conta que leva à expressão certa e a comparação com a afirmativa.
3. Gabarito V, F, F, F, F. **Sem conta, V ou F vale zero.**

Conferência

Todos os números desta folha vêm do R e são conferidos por dois caminhos.

Q5:

- as raízes 2 e 1,25 saem iguais pelo `polyroot`;
- os π_j do modelo (2) por (22)–(27) coincidem com os do helper do repositório, com diferença 0;
- os ψ_j do modelo (3) escrito inteiro e os do MA(1) cancelado coincidem até $j = 20$, com diferença 0.

Q7: $\gamma_0 = 12{,}9032$ pela fórmula (60), por (56) e pela autocovariância do R.

Q8, com $\alpha = 0{,}6$, $\beta = 0{,}3$ e $\sigma^2 = 1$:

- $\gamma_0 = 2{,}265625$, e o lado direito da afirmativa 1 dá o mesmo;
- $\gamma_1 = 1{,}659375$, contra os 2,259375 da afirmativa 2;
- $\rho_1 = 0{,}7324$ e $\rho_2 = 0{,}4394$;
- com $c = 1$, $\theta = 0{,}5$ e $t = 4$: $E(Z_4) = 9$, contra 8 da afirmativa 4, e $V(Z_4) = 4$, contra 3 da afirmativa 5.

Parte II

Apêndice: Q2 e Q6 completas

CAPÍTULO 2

Demonstrações à mão — Q2 e Q6, linha a linha

Demonstrações à mão: Q2 e Q6

Esta é a demonstração **como se escreve no caderno**: cada linha numerada, (1), (2), (3)..., uma operação por linha e o motivo entre colchetes à direita. A base é o enunciado da lista, escrito com os **mesmos símbolos dos slides e do caderno**: Y_t, α_1, α_2 e y_0 na Q2 (AU01, p. 28–30); c, μ, ϕ_1, θ_1, ε_t e os desvios $(y_t - \mu)$ na Q6 (AU02, p. 81–84). A única diferença é gráfica: os slides escrevem a esperança com colchetes, e aqui, como no resto do repositório, ela vem com parênteses, $E(\cdot)$. As versões comentadas, com livro, caderno e armadilhas, estão em Q2 e Q6.

Legenda dos colchetes:

- [RB]: ruído branco, $E(\varepsilon_t) = 0$, $E(\varepsilon_t^2) = \sigma^2$ e $E(\varepsilon_i \varepsilon_j) = 0$ se $i \neq j$;
- [lin.]: linearidade da esperança, em que constantes saem e a esperança da soma é a soma das esperanças;
- [F3], [F4]...: ferramentas demonstradas uma vez na caixa de ferramentas: F3 é a soma de Gauss; F4 é a linearidade, $E(a + bX + cY) = a + bE(X) + cE(Y)$ e $E(c) = c$;
- [estac.]: estacionariedade, os momentos não dependem da data: $E(y_t) = \mu$ e $E\big((y_{t-j} - \mu)^2\big) = \gamma_0$ para todo j;
- [caus.]: causalidade, o choque de hoje não se correlaciona com o passado de y;
- [(n)]: usando a linha (n).

Q2 · Passeio com drift e tendência determinística

Enunciado (lista, Q2). Um passeio aleatório recebe, a cada período, um drift constante c e um termo de tendência δt, com valor inicial $y_0 = 0$ e choques ruído branco. Pede-se:

- (a) a solução explícita;
- (b) média, variância e autocovariância;
- (c) a comparação com o passeio só com drift;
- (d) a natureza da tendência e como tirar a não estacionariedade.

Nos slides (AU01, p. 30):

$$Y_t = \alpha_1 + Y_{t-1} + \alpha_2\, t + \varepsilon_t, \qquad \varepsilon_t \sim RB(0, \sigma^2), \qquad Y_0 = 0,$$

com $\alpha_1 = c$ (drift) e $\alpha_2 = \delta$ (tendência). O slide escreve o valor inicial genérico, $Y_0 = y_0$, fixo e não aleatório; a lista fixa $y_0 = 0$. No caderno (19/08), o mesmo modelo aparece como $Y_t = \alpha + Y_{t-1} + \alpha_2 t + \varepsilon_t$, com $\alpha = \alpha_1$.

(a) Solução explícita

Caminho 1 — substituição recursiva.

$$
\begin{aligned}
&(1)\quad Y_1 = \alpha_1 + Y_0 + \alpha_2 \cdot 1 + \varepsilon_1 = \alpha_1 + \alpha_2 + \varepsilon_1 && [Y_0 = 0]\\
&(2)\quad Y_2 = \alpha_1 + Y_1 + 2\alpha_2 + \varepsilon_2 && [\text{modelo}]\\
&(3)\quad \quad = \alpha_1 + (\alpha_1 + \alpha_2 + \varepsilon_1) + 2\alpha_2 + \varepsilon_2 && [(1)]\\
&(4)\quad \quad = 2\alpha_1 + (1+2)\alpha_2 + \varepsilon_1 + \varepsilon_2 &&\\
&(5)\quad Y_3 = \alpha_1 + Y_2 + 3\alpha_2 + \varepsilon_3 = 3\alpha_1 + (1+2+3)\alpha_2 + \varepsilon_1 + \varepsilon_2 + \varepsilon_3 && [(4)]
\end{aligned}
$$

O padrão: cada período soma um α_1, mais um múltiplo de α_2 igual à data, e um choque novo.

$$
(6)\qquad Y_t = \alpha_1 t + \alpha_2(1 + 2 + \cdots + t) + \sum_{s=1}^{t} \varepsilon_s
$$

Prova de (6) por indução.

- **Base,** $t = 1$**:** (6) dá $\alpha_1 + \alpha_2 \cdot 1 + \varepsilon_1$, que é a linha (1). ✓
- **Passo:** suponha (6) válida em t. Então:

$$
\begin{aligned}
&(7)\quad Y_{t+1} = \alpha_1 + Y_t + \alpha_2(t+1) + \varepsilon_{t+1} && [\text{modelo}]\\
&(8)\quad \quad = \alpha_1 + \Big[\alpha_1 t + \alpha_2(1 + \cdots + t) + \sum_{s=1}^{t} \varepsilon_s\Big] + \alpha_2(t+1) + \varepsilon_{t+1} && [\text{hip. de indução}]\\
&(9)\quad \quad = \alpha_1(t+1) + \alpha_2\big(1 + \cdots + t + (t+1)\big) + \sum_{s=1}^{t+1} \varepsilon_s && [\text{agrupando}]
\end{aligned}
$$

que é (6) em $t + 1$. ✓

A soma de Gauss. Seja $S = 1+2+\cdots+t$. Escreva a soma de novo, de trás para frente, $S = t+(t-1)+\cdots+1$, e some as duas linhas coluna a coluna. Cada coluna dá $t + 1$, e são t colunas: $2S = t(t+1)$, logo $S = \frac{t(t+1)}{2}$.

$$
(10)\qquad \boxed{Y_t = \alpha_1\, t + \alpha_2\, \frac{t(t+1)}{2} + \sum_{s=1}^{t} \varepsilon_s}
$$

Caminho 2 — soma telescópica, a conferência. Do modelo, $Y_s - Y_{s-1} = \alpha_1 + \alpha_2 s + \varepsilon_s$. Somando de $s = 1$ a t:

- à esquerda, $(Y_1 - Y_0) + (Y_2 - Y_1) + \cdots + (Y_t - Y_{t-1}) = Y_t - Y_0 = Y_t$, porque os termos do meio se cancelam;
- à direita, $\alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum \varepsilon_s$.

É a mesma (10). **Com y_0 genérico**, a esquerda dá $Y_t - y_0$, e o resultado é $Y_t = y_0 + \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum_{s=1}^{t} \varepsilon_s$: tudo o que vem abaixo vale somando y_0 à média, exatamente como na AU01, p. 30. **Na lista:** $y_t = ct + \delta\frac{t(t+1)}{2} + \sum_{s=1}^{t} u_s$.

(b) Média, variância e autocovariância

Média. Antes de tirar a esperança, separe em (10) o que é número do que é aleatório:

- $a_t \equiv \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$ é um **número**: t é a data, α_1 e α_2 são parâmetros, e nada ali é sorteado;
- $S_t \equiv \sum_{s=1}^{t} \varepsilon_s = \varepsilon_1 + \varepsilon_2 + \cdots + \varepsilon_t$ é a **única parte aleatória**: uma soma de t choques.

Assim, (10) é $Y_t = a_t + S_t$. Linha a linha:

$$
\begin{aligned}
&(11) \quad E(Y_t) = E(a_t + S_t) && \text{[(10)]}\\
&(12) \quad = E(a_t) + E(S_t) && \text{[F4: esperança da soma]}\\
&(13) \quad E(a_t) = a_t && \text{[F4: } E(c) = c,\ a_t \text{ não é aleatório]}\\
&(14) \quad E(S_t) = E(\varepsilon_1 + \varepsilon_2 + \cdots + \varepsilon_t) && \text{[abre o } \textstyle\sum\text{]}\\
&(15) \quad = E(\varepsilon_1) + E(\varepsilon_2 + \cdots + \varepsilon_t) && \text{[F4: } X = \varepsilon_1,\ Y = \text{resto]}\\
&(16) \quad = E(\varepsilon_1) + E(\varepsilon_2) + E(\varepsilon_3 + \cdots + \varepsilon_t) && \text{[F4 de novo]}\\
&(17) \quad = E(\varepsilon_1) + E(\varepsilon_2) + \cdots + E(\varepsilon_t) = \sum_{s=1}^{t} E(\varepsilon_s) && \text{[F4, } t-1 \text{ vezes]}\\
&(18) \quad = \underbrace{0 + 0 + \cdots + 0}_{t \text{ parcelas}} && \text{[RB: } E(\varepsilon_s) = 0\ \forall s\text{]}\\
&(19) \quad = 0\\
&(20) \quad E(Y_t) = a_t + 0 = \alpha_1 t + \alpha_2 \tfrac{t(t+1)}{2} \equiv \mu_t && \text{[(12), (13), (19)]}
\end{aligned}
$$

Por que a esperança pode entrar no Σ (o passo (17)), por indução no número de parcelas n:

- **base,** $n = 1$**:** $E(\varepsilon_1) = E(\varepsilon_1)$ ✓;
- **passo:** se $E\big(\sum_{s=1}^{n} \varepsilon_s\big) = \sum_{s=1}^{n} E(\varepsilon_s)$, então

$$E\Big(\sum_{s=1}^{n+1} \varepsilon_s\Big) = E\Big(\sum_{s=1}^{n} \varepsilon_s + \varepsilon_{n+1}\Big) = E\Big(\sum_{s=1}^{n} \varepsilon_s\Big) + E(\varepsilon_{n+1}) = \sum_{s=1}^{n} E(\varepsilon_s) + E(\varepsilon_{n+1}) = \sum_{s=1}^{n+1} E(\varepsilon_s),$$

usando a F4 com duas parcelas ($X = \sum_{s=1}^{n} \varepsilon_s$ e $Y = \varepsilon_{n+1}$) e depois a hipótese de indução. ✓

Observações:

- **A soma é finita**, com t parcelas, e por isso a troca vale sempre. Numa soma **infinita**, como o MA(∞) da Q6, a troca precisa de $\sum_j |\psi_j| < \infty$.
- **Por que** $E(\varepsilon_s) = 0$**:** é a primeira propriedade do ruído branco, $\varepsilon_t \sim RB(0, \sigma^2)$ (AU01, p. 31). Vale para **cada** data s, e por isso todas as t parcelas de (18) são zero.
- **Exemplo com** $t = 3$**:** $E(\varepsilon_1 + \varepsilon_2 + \varepsilon_3) = E(\varepsilon_1) + E(\varepsilon_2) + E(\varepsilon_3) = 0 + 0 + 0 = 0$.
- **Com** y_0 **genérico**, como no slide: $Y_t = y_0 + a_t + S_t$, e $E(y_0) = y_0$ pela F4, porque y_0 é fixo. Então $E(Y_t) = y_0 + \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$, exatamente a AU01, p. 30.
- **Atalho para a prova**, numa linha: $E\big(\sum_{s=1}^{t} \varepsilon_s\big) = \sum_{s=1}^{t} E(\varepsilon_s) = \sum_{s=1}^{t} 0 = 0$ [F4, soma finita; RB].

Desvio em relação à média. Subtraindo (20) de (10):

$$(21) \qquad Y_t - \mu_t = \sum_{s=1}^{t} \varepsilon_s$$

Variância.

$$V(Y_t) = E\big((Y_t - \mu_t)^2\big) = E\Big(\Big(\sum_{i=1}^{t} \varepsilon_i\Big)^2\Big) \quad [(21)] \tag{22}$$

$$= E\Big(\sum_{i=1}^{t}\sum_{j=1}^{t} \varepsilon_i\varepsilon_j\Big) \quad [\text{quadrado da soma}] \tag{23}$$

$$= \sum_{i=1}^{t}\sum_{j=1}^{t} E(\varepsilon_i\varepsilon_j) \quad [\text{lin.}] \tag{24}$$

$$= \sum_{i=1}^{t} E(\varepsilon_i^2) + \sum_{i\neq j} E(\varepsilon_i\varepsilon_j) \quad [\text{separa } i=j] \tag{25}$$

$$= t\sigma^2 + 0 = t\sigma^2 \quad [\text{RB}] \tag{26}$$

Autocovariância, para $0 \le k < t$:

$$\mathrm{Cov}(Y_t, Y_{t-k}) = E\big((Y_t - \mu_t)(Y_{t-k} - \mu_{t-k})\big) \tag{27}$$

$$= E\Big(\Big(\sum_{i=1}^{t} \varepsilon_i\Big)\Big(\sum_{j=1}^{t-k} \varepsilon_j\Big)\Big) \quad [(21) \text{ em } t \text{ e } t-k] \tag{28}$$

$$= \sum_{i=1}^{t}\sum_{j=1}^{t-k} E(\varepsilon_i\varepsilon_j) \quad [\text{lin.}] \tag{29}$$

$$= \sum_{j=1}^{t-k} E(\varepsilon_j^2) \quad [\text{RB: só } i=j] \tag{30}$$

$$= (t-k)\sigma^2 \tag{31}$$

Em (30), os pares com $i = j$ só existem para $j = 1, \dots, t-k$, porque a segunda soma para em $t-k$: são os choques que Y_t e Y_{t-k} têm em comum.

Correlação:

$$\rho(t,k) = \frac{(t-k)\sigma^2}{\sqrt{t\sigma^2 \cdot (t-k)\sigma^2}} = \sqrt{\frac{t-k}{t}} \tag{32}$$

$$\boxed{E(Y_t) = \alpha_1 t + \alpha_2 \tfrac{t(t+1)}{2}, \qquad V(Y_t) = t\sigma^2, \qquad \mathrm{Cov}(Y_t, Y_{t-k}) = (t-k)\sigma^2}$$

Conclusão: média, variância e autocovariância dependem de *t*. **O processo não é estacionário** (AU01, p. 25).

(c) Comparação com o passeio com drift

Repetindo (1)–(31) com $\alpha_2 = 0$, isto é, com $Y_t = \alpha_1 + Y_{t-1} + \varepsilon_t$ e $Y_0 = 0$, obtém-se $Y_t = \alpha_1 t + \sum_{s=1}^{t} \varepsilon_s$, e:

Momento	Só drift ($\alpha_2 = 0$)	Drift e tendência
$E(Y_t)$	$\alpha_1 t$ (reta)	$\alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$ (parábola)
$V(Y_t)$	$t\sigma^2$	$t\sigma^2$
$\mathrm{Cov}(Y_t, Y_{t-k})$	$(t-k)\sigma^2$	$(t-k)\sigma^2$

Só a média muda, pelo termo $\alpha_2 \frac{t(t+1)}{2}$. A parte aleatória, $\sum \varepsilon_s$, é idêntica nos dois, e por isso variância e covariância são iguais.

(d) Natureza da tendência e como removê-la

Decomposição. Por (10):

$$Y_t = \underbrace{\alpha_1 t + \alpha_2 \frac{t(t+1)}{2}}_{\text{tendência determinística}} + \underbrace{\sum_{s=1}^{t} \varepsilon_s}_{\text{tendência estocástica}} \tag{33}$$

- **Os dois processos têm tendência estocástica** (raiz unitária). Por (10), $\partial Y_{t+j}/\partial \varepsilon_t = 1$ para todo $j \geq 0$: o choque é **permanente**.
- **A tendência determinística muda:** é linear com drift e quadrática com drift e tendência (MAT, §1.3, "tendência geral").

Primeira diferença:

$$\Delta Y_t = Y_t - Y_{t-1} = \alpha_1 + \alpha_2 t + \varepsilon_t \quad \text{[modelo]} \tag{34}$$

$$E(\Delta Y_t) = \alpha_1 + \alpha_2 t \quad \text{[lin., RB]} \tag{35}$$

- **Só drift ($\alpha_2 = 0$):** $\Delta Y_t = \alpha_1 + \varepsilon_t$, que é estacionário. Uma diferença basta.
- **Drift e tendência:** por (35), ΔY_t **ainda tem tendência linear** na média. Uma diferença não basta.

Caminho recomendado. Diferenciar uma vez e **tirar a tendência linear de ΔY_t por regressão** em $(1, t)$. Por (34), o resíduo dessa regressão estima ε_t, que é ruído branco.

Caminho a evitar: diferenciar duas vezes.

$$\Delta^2 Y_t = \Delta Y_t - \Delta Y_{t-1} \quad \text{[definição]} \tag{36}$$

$$= (\alpha_1 + \alpha_2 t + \varepsilon_t) - \big(\alpha_1 + \alpha_2 (t-1) + \varepsilon_{t-1}\big) \quad \text{[(34)]} \tag{37}$$

$$= \alpha_2 + \varepsilon_t - \varepsilon_{t-1} = \alpha_2 + (1 - L)\,\varepsilon_t \tag{38}$$

A média fica constante, α_2, mas sobra um MA(1) com $\theta_1 = -1$. O polinômio $\theta(z) = 1 - z$ tem raiz $z = 1$, sobre o círculo: **não invertível** (AU02, p. 33). É a sobrediferenciação da Q9.

Conclusão (implicação prática): tendência estocástica se remove com **diferença**; tendência determinística se remove com **regressão em** *t*. Aqui, uma diferença e depois a regressão de ΔY_t em *t*. A segunda diferença também estacionariza, mas deixa um MA não invertível.

Versão para a prova (Q2)

O mínimo que precisa estar no papel:

1. Some o modelo de 1 a t (telescópica) e use $\sum s = \frac{t(t+1)}{2}$: $Y_t = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum_{s=1}^{t} \varepsilon_s$.
2. Com $a_t = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$ fixo: $E(Y_t) = E(a_t) + E\big(\sum \varepsilon_s\big) = a_t + \sum E(\varepsilon_s) = a_t + \sum 0 = a_t$ [F4, soma finita; RB].
3. $Y_t - \mu_t = \sum \varepsilon_s$, logo $V(Y_t) = E\big((\sum \varepsilon_s)^2\big) = t\sigma^2$ [RB: só $i = j$].
4. $\mathrm{Cov}(Y_t, Y_{t-k}) = E\big(\sum_{i \leq t} \varepsilon_i \sum_{j \leq t-k} \varepsilon_j\big) = (t-k)\sigma^2$.
5. Os momentos dependem de t: **não estacionário**.
6. Comparação: só a média muda (reta ⟶ parábola); V e Cov são iguais.
7. Tendência estocástica $\sum \varepsilon_s$ + determinística quadrática. $\Delta Y_t = \alpha_1 + \alpha_2 t + \varepsilon_t$ ainda tem tendência: regredir ΔY_t em t. $\Delta^2 Y_t = \alpha_2 + (1 - L)\varepsilon_t$ não é invertível: evitar.

Conferência (Q2)

Com $\alpha_1 = 1$ e $\alpha_2 = 0{,}2$:

- a recursão dá $E(Y_1) = 1{,}2$, $E(Y_2) = 2{,}6$ e $E(Y_3) = 4{,}2$;
- a fórmula (20) dá os mesmos valores: $2 + 0{,}2 \cdot 3 = 2{,}6$ e $3 + 0{,}2 \cdot 6 = 4{,}2$;
- com 50 mil trajetórias simuladas e $\sigma^2 = 1$: $V(Y_3) \approx 2{,}99$ (fórmula: 3), $\mathrm{Cov}(Y_3, Y_1) \approx 1{,}00$ (fórmula: 1) e $\mathrm{Corr}(Y_3, Y_1) \approx 0{,}58$ (fórmula: $\sqrt{1/3} = 0{,}577$).

Q6 · ARMA(1,1)

Enunciado (lista, Q6). O ARMA(1,1) $z_t - \phi z_{t-1} = a_t - \theta a_{t-1}$, com $|\phi| < 1$ e $|\theta| < 1$, na convenção de Box-Jenkins. Pede-se:

- (a) γ_0, γ_1 e γ_k $(k \geq 2)$;
- (b) ρ_1, e mostrar que $\rho_k = \phi^{k-1}\rho_1$;
- (c) as formas AR(∞) e MA(∞), e para que parâmetros a convergência é mais lenta.

Nos slides (AU02, p. 81–84), com a constante c, como o professor e o caderno escrevem:

$$y_t = c + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}, \qquad \varepsilon_t \sim RB(0, \sigma^2),$$

ou seja, $(1 - \phi_1 L)\, y_t = c + (1 + \theta_1 L)\, \varepsilon_t$. A tradução da lista:

- $y_t = z_t$ e $\varepsilon_t = a_t$;
- $\phi_1 = \phi$ e $\theta_1 = -\theta$, por causa do sinal positivo dos slides;
- a lista não tem constante: $c = 0$, logo $\mu = 0$ e $y_t - \mu = z_t$.

Hipóteses: [RB]; $|\phi_1| < 1$ (estacionário); $|\theta_1| < 1$ (invertível). No fim, cada resultado volta para o sinal da lista.

(0) Média, forma em desvios e momentos auxiliares

Valor esperado (AU02, p. 82):

$$\begin{aligned}
&(1) \quad E(y_t) = c + \phi_1 E(y_{t-1}) + E(\varepsilon_t) + \theta_1 E(\varepsilon_{t-1}) && \text{[lin.]}\\
&(2) \quad \mu = c + \phi_1 \mu + 0 + 0 && \text{[estac., RB]}\\
&(3) \quad \mu(1 - \phi_1) = c \implies \mu = \frac{c}{1 - \phi_1} && [|\phi_1| < 1]
\end{aligned}$$

Forma em desvios. Subtraia μ dos dois lados do modelo e troque c por $(1 - \phi_1)\mu$, que vem de (3):

$$\begin{aligned}
&(4) \quad y_t - \mu = (1 - \phi_1)\mu - \mu + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1} && [(3)]\\
&(5) \quad \qquad = -\phi_1 \mu + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}\\
&(6) \quad y_t - \mu = \phi_1 (y_{t-1} - \mu) + \varepsilon_t + \theta_1 \varepsilon_{t-1} && \text{[evidência]}
\end{aligned}$$

A linha (6) é o "já sabemos que" da AU02, p. 82 e 84. A constante sumiu: todas as contas abaixo usam (6).

Momentos auxiliares (como no caderno, 02/09). Pelo item (c), $y_t - \mu = \sum_{j \geq 0} \psi_j \varepsilon_{t-j}$: o desvio de hoje só contém choques de hoje e do passado.

$$
\begin{aligned}
&(7)\quad E(\varepsilon_t\varepsilon_t) = \sigma^2 && \text{[RB]}\\
&(8)\quad E\big((y_{t-k}-\mu)\,\varepsilon_t\big) = 0 \quad \text{para } k \geq 1 && \text{[caus., RB]}\\
&(9)\quad E\big((y_t-\mu)\,\varepsilon_t\big) = E\big((\phi_1(y_{t-1}-\mu)+\varepsilon_t+\theta_1\varepsilon_{t-1})\,\varepsilon_t\big) && \text{[(6)]}\\
&(10)\quad = \phi_1\cdot 0 + \sigma^2 + \theta_1\cdot 0 = \sigma^2 && \text{[(8), (7), RB]}\\
&(11)\quad E\big((y_{t+1}-\mu)\,\varepsilon_t\big) = E\big((\phi_1(y_t-\mu)+\varepsilon_{t+1}+\theta_1\varepsilon_t)\,\varepsilon_t\big) && \text{[(6) em } t+1\text{]}\\
&(12)\quad = \phi_1\sigma^2 + 0 + \theta_1\sigma^2 = (\phi_1+\theta_1)\,\sigma^2 && \text{[(10), RB, (7)]}
\end{aligned}
$$

Por estacionariedade, (10) vale em qualquer data. Em $t-1$, $E\big((y_{t-1}-\mu)\varepsilon_{t-1}\big) = \sigma^2$, que é o "lembre que" da AU02, p. 83.

(a) γ_0, γ_1 e γ_k

γ_0 (AU02, p. 82–83). Por (6):

$$
(13)\qquad \gamma_0 = E\big((y_t-\mu)^2\big) = E\Big(\big(\phi_1(y_{t-1}-\mu)+\varepsilon_t+\theta_1\varepsilon_{t-1}\big)^2\Big)
$$

O quadrado é o produto do parêntese por ele mesmo: $3\times 3 = 9$ termos, na ordem do slide. Cada termo com a sua esperança:

$$
\begin{aligned}
&(14)\quad E\big(\phi_1^2(y_{t-1}-\mu)^2\big) = \phi_1^2\gamma_0 && \text{[estac.]}\\
&(15)\quad E\big(\phi_1(y_{t-1}-\mu)\,\varepsilon_t\big) = 0 && \text{[(8)]}\\
&(16)\quad E\big(\phi_1(y_{t-1}-\mu)\,\theta_1\varepsilon_{t-1}\big) = \phi_1\theta_1\sigma^2 && \text{[(10) em } t-1\text{]}\\
&(17)\quad E\big(\varepsilon_t\,\phi_1(y_{t-1}-\mu)\big) = 0 && \text{[(8)]}\\
&(18)\quad E(\varepsilon_t^2) = \sigma^2 && \text{[(7)]}\\
&(19)\quad E(\varepsilon_t\,\theta_1\varepsilon_{t-1}) = 0 && \text{[RB]}\\
&(20)\quad E\big(\theta_1\varepsilon_{t-1}\,\phi_1(y_{t-1}-\mu)\big) = \theta_1\phi_1\sigma^2 && \text{[(10) em } t-1\text{]}\\
&(21)\quad E(\theta_1\varepsilon_{t-1}\,\varepsilon_t) = 0 && \text{[RB]}\\
&(22)\quad E(\theta_1^2\varepsilon_{t-1}^2) = \theta_1^2\sigma^2 && \text{[RB]}
\end{aligned}
$$

Somando (14)–(22): os termos (16) e (20) são iguais e dão $2\theta_1\phi_1\sigma^2$; os quatro zeros somem.

$$
\begin{aligned}
&(23)\quad \gamma_0 = \phi_1^2\gamma_0 + 2\theta_1\phi_1\sigma^2 + \sigma^2 + \theta_1^2\sigma^2 && \text{[(14)–(22)]}\\
&(24)\quad \gamma_0 - \phi_1^2\gamma_0 = \sigma^2(2\theta_1\phi_1 + 1 + \theta_1^2) && \text{[passa } \phi_1^2\gamma_0\text{]}\\
&(25)\quad \gamma_0\,(1-\phi_1^2) = \sigma^2(2\theta_1\phi_1 + 1 + \theta_1^2) && \text{[evidência]}
\end{aligned}
$$

$$
(26)\qquad \boxed{\gamma_0 = \frac{\sigma^2(2\theta_1\phi_1 + 1 + \theta_1^2)}{1-\phi_1^2}} \qquad [\,1-\phi_1^2 \neq 0 \text{ porque } |\phi_1| < 1\,]
$$

É a forma da AU02, p. 83. **Atenção ao erro do caderno:** é θ_1^2, ao quadrado, no numerador.

γ_k**, equação geral** (AU02, p. 84). Multiplique (6) por $(y_{t-k}-\mu)$ e tire a esperança:

$$
(27)\qquad \underbrace{E\big((y_t-\mu)(y_{t-k}-\mu)\big)}_{\gamma_k} = \phi_1\,\underbrace{E\big((y_{t-1}-\mu)(y_{t-k}-\mu)\big)}_{\gamma_{k-1}} + E\big(\varepsilon_t(y_{t-k}-\mu)\big) + \theta_1 E\big(\varepsilon_{t-1}(y_{t-k}-\mu)\big)
$$

$k = 1$**:**

$$\text{(28)}\quad \gamma_1 = \phi_1 E\big((y_{t-1}-\mu)^2\big) + E\big(\varepsilon_t(y_{t-1}-\mu)\big) + \theta_1 E\big(\varepsilon_{t-1}(y_{t-1}-\mu)\big) \quad [(27),\ k=1]$$
$$\text{(29)}\quad = \phi_1\gamma_0 + 0 + \theta_1\sigma^2 \quad [\text{estac., (8), (10)}]$$

Substituindo (26) em (29), com tudo sobre o denominador $1-\phi_1^2$:

$$\text{(30)}\quad \gamma_1 = \frac{\phi_1(1+2\phi_1\theta_1+\theta_1^2)+\theta_1(1-\phi_1^2)}{1-\phi_1^2}\,\sigma^2 \quad [(26)]$$
$$\text{(31)}\quad = \frac{\phi_1+2\phi_1^2\theta_1+\phi_1\theta_1^2+\theta_1-\phi_1^2\theta_1}{1-\phi_1^2}\,\sigma^2 \quad [\text{distributiva}]$$
$$\text{(32)}\quad = \frac{\phi_1+\theta_1+\phi_1^2\theta_1+\phi_1\theta_1^2}{1-\phi_1^2}\,\sigma^2 \quad [2\phi_1^2\theta_1-\phi_1^2\theta_1]$$

Fatoração do numerador, conferida por expansão: $(1+\phi_1\theta_1)(\phi_1+\theta_1) = \phi_1+\theta_1+\phi_1^2\theta_1+\phi_1\theta_1^2$ ✓. Logo:

$$\text{(33)}\quad \boxed{\gamma_1 = \phi_1\gamma_0 + \theta_1\sigma^2 = \frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1-\phi_1^2}\,\sigma^2}$$

$k \geq 2$**:** em (27), os dois últimos termos são zero por (8):

- $E\big(\varepsilon_t(y_{t-k}-\mu)\big) = 0$, porque $k \geq 1$;
- $E\big(\varepsilon_{t-1}(y_{t-k}-\mu)\big) = 0$, porque a distância entre $t-1$ e $t-k$ é $k-1 \geq 1$.

Sobra $\gamma_k = \phi_1\gamma_{k-1}$. **Indução:**

- base, $k=2$: $\gamma_2 = \phi_1\gamma_1$;
- passo: se $\gamma_{k-1} = \phi_1^{k-2}\gamma_1$, então $\gamma_k = \phi_1 \cdot \phi_1^{k-2}\gamma_1 = \phi_1^{k-1}\gamma_1$.

$$\text{(34)}\quad \boxed{\gamma_k = \phi_1\,\gamma_{k-1} = \phi_1^{k-1}\gamma_1 \quad (k \geq 2)}$$

Atenção ao erro do caderno: o expoente é $k-1$, não k. Confira com $k=2$: um único ϕ_1.

(b) FAC

$$\text{(35)}\quad \rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)\sigma^2/(1-\phi_1^2)}{(1+2\phi_1\theta_1+\theta_1^2)\sigma^2/(1-\phi_1^2)} \quad [(33),(26)]$$
$$\text{(36)}\quad = \frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1+2\phi_1\theta_1+\theta_1^2} \quad [\text{cancela } \sigma^2 \text{ e } 1-\phi_1^2]$$

$\rho_k = \phi_1^{k-1}\rho_1$ **por indução**, dividindo (34) por γ_0:

- **base,** $k=1$**:** $\phi_1^0\rho_1 = \rho_1$ ✓;
- **passo:** se $\rho_{k-1} = \phi_1^{k-2}\rho_1$, então $\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\phi_1\gamma_{k-1}}{\gamma_0} = \phi_1\rho_{k-1} = \phi_1 \cdot \phi_1^{k-2}\rho_1 = \phi_1^{k-1}\rho_1$ ✓.

$$\text{(37)}\quad \boxed{\rho_k = \phi_1^{k-1}\rho_1 \quad (k \geq 1)}$$

Conclusão: a FAC decai geometricamente, à taxa ϕ_1, mas **a partir de ρ_1, e não de 1**. O MA só altera o primeiro valor.

(c) MA(∞), AR(∞) e a velocidade de convergência

Como na lista, $c = 0$: então $\mu = 0$ e $y_t - \mu = y_t$. Com constante, troque cada y por $y - \mu$, pela forma em desvios (6).

MA(∞), caminho 1 — substituição recursiva.

$$
\begin{aligned}
(38)\quad & y_t = \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1} && \text{[modelo]}\\
(39)\quad & \quad = \phi_1(\phi_1 y_{t-2} + \varepsilon_{t-1} + \theta_1 \varepsilon_{t-2}) + \varepsilon_t + \theta_1 \varepsilon_{t-1} && \text{[modelo em } t-1\text{]}\\
(40)\quad & \quad = \varepsilon_t + (\phi_1 + \theta_1)\varepsilon_{t-1} + \phi_1\theta_1\varepsilon_{t-2} + \phi_1^2 y_{t-2} && \text{[agrupando]}\\
(41)\quad & \quad = \varepsilon_t + (\phi_1 + \theta_1)\varepsilon_{t-1} + \phi_1(\phi_1 + \theta_1)\varepsilon_{t-2} + \phi_1^2\theta_1\varepsilon_{t-3} + \phi_1^3 y_{t-3} && \text{[modelo em } t-2\text{]}
\end{aligned}
$$

Em (41), o coeficiente de ε_{t-2} é $\phi_1\theta_1 + \phi_1^2 = \phi_1(\phi_1 + \theta_1)$. O padrão: o coeficiente de ε_{t-j}, $j \geq 1$, é $(\phi_1 + \theta_1)\phi_1^{j-1}$. Depois de n substituições, o resto é $\phi_1^{n-1}\theta_1\varepsilon_{t-n} + \phi_1^n y_{t-n}$. Ele vai a zero em média quadrática, porque $E(\phi_1^{2n} y_{t-n}^2) = \phi_1^{2n}\gamma_0 \to 0$ quando $|\phi_1| < 1$.

MA(∞), caminho 2 — igualdade de coeficientes. $\Psi(L) = \frac{1+\theta_1 L}{1-\phi_1 L}$ significa $\Psi(L)(1 - \phi_1 L) = 1 + \theta_1 L$. Expandindo o lado esquerdo:

$$
(1 + \psi_1 L + \psi_2 L^2 + \cdots)(1 - \phi_1 L) = 1 + (\psi_1 - \phi_1)L + (\psi_2 - \phi_1\psi_1)L^2 + \cdots + (\psi_j - \phi_1\psi_{j-1})L^j + \cdots
$$

Igualando com $1 + \theta_1 L$, potência por potência:

- L^1: $\psi_1 - \phi_1 = \theta_1$, logo $\psi_1 = \phi_1 + \theta_1$;
- L^j, $j \geq 2$: $\psi_j - \phi_1\psi_{j-1} = 0$, logo $\psi_j = \phi_1\psi_{j-1}$.

$$
(42)\qquad \boxed{\psi_0 = 1, \quad \psi_j = (\phi_1 + \theta_1)\,\phi_1^{j-1}\ (j \geq 1)} \qquad y_t = \varepsilon_t + (\phi_1 + \theta_1)\sum_{j\geq 1}\phi_1^{j-1}\varepsilon_{t-j}
$$

AR(∞). $\pi(L) = \frac{1-\phi_1 L}{1+\theta_1 L}$, com $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots$ (AU02, p. 19).

- Pela série geométrica com razão $-\theta_1 L$, válida porque $|\theta_1| < 1$: $(1 + \theta_1 L)^{-1} = \sum_{j\geq 0}(-\theta_1)^j L^j$.
- Multiplicando por $(1 - \phi_1 L)$, o coeficiente de L^j, $j \geq 1$, é

$$
(-\theta_1)^j - \phi_1(-\theta_1)^{j-1} = (-\theta_1)^{j-1}(-\theta_1 - \phi_1) = -(\phi_1 + \theta_1)(-\theta_1)^{j-1}.
$$

- Comparando com $-\pi_j$:

$$
(43)\qquad \boxed{\pi_j = (\phi_1 + \theta_1)\,(-\theta_1)^{j-1}\ (j \geq 1)} \qquad y_t = \sum_{j\geq 1}\pi_j\, y_{t-j} + \varepsilon_t
$$

Quando cada série converge.

- $\sum_j |\psi_j| = 1 + |\phi_1 + \theta_1|\sum_{j\geq 1}|\phi_1|^{j-1} = 1 + \frac{|\phi_1+\theta_1|}{1-|\phi_1|} < \infty \iff |\phi_1| < 1$, que é a **estacionariedade**.
- $\sum_j |\pi_j| = \frac{|\phi_1+\theta_1|}{1-|\theta_1|} < \infty \iff |\theta_1| < 1$, que é a **invertibilidade**.

Quando a convergência é mais lenta. Os $|\psi_j|$ encolhem por um fator $|\phi_1|$ a cada período. A **meia-vida**, o número de períodos para um peso cair à metade, resolve $|\phi_1|^h = \frac{1}{2}$:

$$
h = \frac{\ln 0{,}5}{\ln|\phi_1|}\ : \qquad \phi_1 = 0{,}5 \Rightarrow h = 1; \qquad \phi_1 = 0{,}9 \Rightarrow h = 6{,}58; \qquad \phi_1 = 0{,}99 \Rightarrow h = 68{,}97.
$$

- **MA(∞) mais lento quando** $|\phi_1| \to 1$: perto da raiz unitária, os choques demoram a morrer.

- **AR(∞) mais lento quando** $|\theta_1| \to 1$: perto da não invertibilidade, é preciso muito passado de y para recuperar ε_t.
- **Caso extremo,** $\phi_1 = -\theta_1$**:** $\psi_j = \pi_j = 0$ para $j \geq 1$, e $y_t = \varepsilon_t$. Os fatores se cancelam: é um fator comum.

De volta ao sinal da lista ($\theta_1 = -\theta$)

	Slides	Lista
γ_0	$\frac{1+2\phi_1\theta_1+\theta_1^2}{1-\phi_1^2}\sigma^2$	$\frac{1-2\phi\theta+\theta^2}{1-\phi^2}\sigma_a^2$
γ_1	$\frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1-\phi_1^2}\sigma^2$	$\frac{(1-\phi\theta)(\phi-\theta)}{1-\phi^2}\sigma_a^2$
ρ_1	$\frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1+2\phi_1\theta_1+\theta_1^2}$	$\frac{(1-\phi\theta)(\phi-\theta)}{1-2\phi\theta+\theta^2}$
ρ_k	$\phi_1^{k-1}\rho_1$	$\phi^{k-1}\rho_1$
ψ_j	$(\phi_1+\theta_1)\phi_1^{j-1}$	$(\phi-\theta)\phi^{j-1}$
π_j	$(\phi_1+\theta_1)(-\theta_1)^{j-1}$	$(\phi-\theta)\theta^{j-1}$

Versão para a prova (Q6)

1. Convenção: sinais dos slides, $\theta_1 = -\theta$.
2. $\mu = \frac{c}{1-\phi_1}$ e a forma em desvios $y_t - \mu = \phi_1(y_{t-1}-\mu) + \varepsilon_t + \theta_1\varepsilon_{t-1}$ (na lista, $c = 0$).
3. Momentos auxiliares: $E(\varepsilon_t\varepsilon_t) = \sigma^2$; $E\big((y_{t-k}-\mu)\varepsilon_t\big) = 0$ para $k \geq 1$; $E\big((y_t-\mu)\varepsilon_t\big) = \sigma^2$; $E\big((y_{t+1}-\mu)\varepsilon_t\big) = (\phi_1+\theta_1)\sigma^2$.
4. $\gamma_0 = E\big((\phi_1(y_{t-1}-\mu) + \varepsilon_t + \theta_1\varepsilon_{t-1})^2\big)$: nove termos, quatro zeros, $\gamma_0 = \phi_1^2\gamma_0 + 2\theta_1\phi_1\sigma^2 + \sigma^2 + \theta_1^2\sigma^2$, logo $\gamma_0 = \frac{\sigma^2(2\theta_1\phi_1+1+\theta_1^2)}{1-\phi_1^2}$.
5. $\gamma_1 = \phi_1\gamma_0 + \theta_1\sigma^2 = \frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1-\phi_1^2}\sigma^2$.
6. $k \geq 2$: $\gamma_k = \phi_1\gamma_{k-1}$, porque os dois choques do modelo são posteriores a y_{t-k}.
7. $\rho_1 = \gamma_1/\gamma_0$; $\rho_k = \phi_1\rho_{k-1} = \phi_1^{k-1}\rho_1$ (indução).
8. $\Psi(L)(1-\phi_1 L) = 1 + \theta_1 L$ dá $\psi_j = (\phi_1+\theta_1)\phi_1^{j-1}$, que converge se $|\phi_1| < 1$.
9. $\pi(L)(1+\theta_1 L) = 1 - \phi_1 L$ dá $\pi_j = (\phi_1+\theta_1)(-\theta_1)^{j-1}$, que converge se $|\theta_1| < 1$.
10. Mais lento: $|\phi_1| \to 1$ para os ψ e $|\theta_1| \to 1$ para os π. Meia-vida $\ln 0{,}5 / \ln|\phi_1|$.
11. Traduzir para a lista com $\theta_1 = -\theta$.

Conferência (Q6)

Com $\phi_1 = 0{,}7$, $\theta_1 = -0{,}4$ (isto é, $\theta^{\text{lista}} = 0{,}4$) e $\sigma^2 = 1$:

- $\gamma_0 = \frac{1-0{,}56+0{,}16}{0{,}51} = 1{,}1765$;
- $\gamma_1 = 0{,}7(1{,}1765) - 0{,}4 = 0{,}4235$;
- $\rho_1 = 0{,}36$ e $\rho_2 = 0{,}252$;
- $\psi_1, \psi_2, \psi_3 = 0{,}3;\ 0{,}21;\ 0{,}147$ e $\pi_1, \pi_2, \pi_3 = 0{,}3;\ 0{,}12;\ 0{,}048$.

A substituição recursiva (42) e a fórmula (43) coincidem com o `ARMAtoMA` do R, com diferença zero.