Séries temporais

À mão

Q2 e Q6 demonstradas linha a linha, na notação dos slides e do caderno

---

Caderno de estudo · parte 1: ARMA, ARIMA e SARIMA

Prof. Guilherme Pereira · Econometria II (PPGEco/UFES)

Gerado em 28/10/2026 a partir de `github.com/fcarva/series-temporais` (commit `d2c6c2f`). Material autoral: enunciados parafraseados, demonstrações próprias, números conferidos em R contra os scripts do repositório.

Sumário

I Q2 e Q6 linha a linha **1**

1 Demonstrações à mão — Q2 e Q6, linha a linha **2**

Parte I

Q2 e Q6 linha a linha

CAPÍTULO 1

Demonstrações à mão — Q2 e Q6, linha a linha

Demonstrações à mão: Q2 e Q6

Esta é a demonstração **como se escreve no caderno**: cada linha numerada, (1), (2), (3)..., uma operação por linha e o motivo entre colchetes à direita. A base é o enunciado da lista, escrito com os **mesmos símbolos dos slides e do caderno**: Y_t, α_1, α_2 e y_0 na Q2 (AU01, p. 28–30); c, μ, ϕ_1, θ_1, ε_t e os desvios $(y_t - \mu)$ na Q6 (AU02, p. 81–84). A única diferença é gráfica: os slides escrevem a esperança com colchetes, e aqui, como no resto do repositório, ela vem com parênteses, $E(\cdot)$. As versões comentadas, com livro, caderno e armadilhas, estão em Q2 e Q6.

Legenda dos colchetes:

- [RB]: ruído branco, $E(\varepsilon_t) = 0$, $E(\varepsilon_t^2) = \sigma^2$ e $E(\varepsilon_i \varepsilon_j) = 0$ se $i \neq j$;
- [lin.]: linearidade da esperança, em que constantes saem e a esperança da soma é a soma das esperanças;
- [F3], [F4]...: ferramentas demonstradas uma vez na caixa de ferramentas: F3 é a soma de Gauss; F4 é a linearidade, $E(a + bX + cY) = a + bE(X) + cE(Y)$ e $E(c) = c$;
- [estac.]: estacionariedade, os momentos não dependem da data: $E(y_t) = \mu$ e $E\big((y_{t-j} - \mu)^2\big) = \gamma_0$ para todo j;
- [caus.]: causalidade, o choque de hoje não se correlaciona com o passado de y;
- [(n)]: usando a linha (n).

Q2 · Passeio com drift e tendência determinística

Enunciado (lista, Q2). Um passeio aleatório recebe, a cada período, um drift constante c e um termo de tendência δt, com valor inicial $y_0 = 0$ e choques ruído branco. Pede-se:

- (a) a solução explícita;
- (b) média, variância e autocovariância;
- (c) a comparação com o passeio só com drift;
- (d) a natureza da tendência e como tirar a não estacionariedade.

Nos slides (AU01, p. 30):

$$Y_t = \alpha_1 + Y_{t-1} + \alpha_2\, t + \varepsilon_t, \qquad \varepsilon_t \sim RB(0, \sigma^2), \qquad Y_0 = 0,$$

com $\alpha_1 = c$ (drift) e $\alpha_2 = \delta$ (tendência). O slide escreve o valor inicial genérico, $Y_0 = y_0$, fixo e não aleatório; a lista fixa $y_0 = 0$. No caderno (19/08), o mesmo modelo aparece como $Y_t = \alpha + Y_{t-1} + \alpha_2 t + \varepsilon_t$, com $\alpha = \alpha_1$.

(a) Solução explícita

Caminho 1 — substituição recursiva.

$$
\begin{aligned}
&(1)\quad Y_1 = \alpha_1 + Y_0 + \alpha_2 \cdot 1 + \varepsilon_1 = \alpha_1 + \alpha_2 + \varepsilon_1 && [Y_0 = 0]\\
&(2)\quad Y_2 = \alpha_1 + Y_1 + 2\alpha_2 + \varepsilon_2 && [\text{modelo}]\\
&(3)\quad \quad = \alpha_1 + (\alpha_1 + \alpha_2 + \varepsilon_1) + 2\alpha_2 + \varepsilon_2 && [(1)]\\
&(4)\quad \quad = 2\alpha_1 + (1+2)\alpha_2 + \varepsilon_1 + \varepsilon_2 &&\\
&(5)\quad Y_3 = \alpha_1 + Y_2 + 3\alpha_2 + \varepsilon_3 = 3\alpha_1 + (1+2+3)\alpha_2 + \varepsilon_1 + \varepsilon_2 + \varepsilon_3 && [(4)]
\end{aligned}
$$

O padrão: cada período soma um α_1, mais um múltiplo de α_2 igual à data, e um choque novo.

$$
(6)\qquad Y_t = \alpha_1 t + \alpha_2(1 + 2 + \cdots + t) + \sum_{s=1}^{t} \varepsilon_s
$$

Prova de (6) por indução.

- **Base,** $t = 1$**:** (6) dá $\alpha_1 + \alpha_2 \cdot 1 + \varepsilon_1$, que é a linha (1). ✓
- **Passo:** suponha (6) válida em t. Então:

$$
\begin{aligned}
&(7)\quad Y_{t+1} = \alpha_1 + Y_t + \alpha_2(t+1) + \varepsilon_{t+1} && [\text{modelo}]\\
&(8)\quad \quad = \alpha_1 + \Big[\alpha_1 t + \alpha_2(1 + \cdots + t) + \sum_{s=1}^{t} \varepsilon_s\Big] + \alpha_2(t+1) + \varepsilon_{t+1} && [\text{hip. de indução}]\\
&(9)\quad \quad = \alpha_1(t+1) + \alpha_2\big(1 + \cdots + t + (t+1)\big) + \sum_{s=1}^{t+1} \varepsilon_s && [\text{agrupando}]
\end{aligned}
$$

que é (6) em $t + 1$. ✓

A soma de Gauss. Seja $S = 1+2+\cdots+t$. Escreva a soma de novo, de trás para frente, $S = t+(t-1)+\cdots+1$, e some as duas linhas coluna a coluna. Cada coluna dá $t + 1$, e são t colunas: $2S = t(t+1)$, logo $S = \frac{t(t+1)}{2}$.

$$
(10)\qquad \boxed{Y_t = \alpha_1\, t + \alpha_2\, \frac{t(t+1)}{2} + \sum_{s=1}^{t} \varepsilon_s}
$$

Caminho 2 — soma telescópica, a conferência. Do modelo, $Y_s - Y_{s-1} = \alpha_1 + \alpha_2 s + \varepsilon_s$. Somando de $s = 1$ a t:

- à esquerda, $(Y_1 - Y_0) + (Y_2 - Y_1) + \cdots + (Y_t - Y_{t-1}) = Y_t - Y_0 = Y_t$, porque os termos do meio se cancelam;
- à direita, $\alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum \varepsilon_s$.

É a mesma (10). **Com y_0 genérico**, a esquerda dá $Y_t - y_0$, e o resultado é $Y_t = y_0 + \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum_{s=1}^{t} \varepsilon_s$: tudo o que vem abaixo vale somando y_0 à média, exatamente como na AU01, p. 30. **Na lista:** $y_t = ct + \delta\frac{t(t+1)}{2} + \sum_{s=1}^{t} u_s$.

(b) Média, variância e autocovariância

Média. Antes de tirar a esperança, separe em (10) o que é número do que é aleatório:

- $a_t \equiv \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$ é um **número**: t é a data, α_1 e α_2 são parâmetros, e nada ali é sorteado;
- $S_t \equiv \sum_{s=1}^{t} \varepsilon_s = \varepsilon_1 + \varepsilon_2 + \cdots + \varepsilon_t$ é a **única parte aleatória**: uma soma de t choques.

Assim, (10) é $Y_t = a_t + S_t$. Linha a linha:

$$
\begin{aligned}
&(11) \quad E(Y_t) = E(a_t + S_t) && \text{[(10)]}\\
&(12) \quad = E(a_t) + E(S_t) && \text{[F4: esperança da soma]}\\
&(13) \quad E(a_t) = a_t && \text{[F4: } E(c) = c,\ a_t \text{ não é aleatório]}\\
&(14) \quad E(S_t) = E(\varepsilon_1 + \varepsilon_2 + \cdots + \varepsilon_t) && \text{[abre o } \textstyle\sum\text{]}\\
&(15) \quad = E(\varepsilon_1) + E(\varepsilon_2 + \cdots + \varepsilon_t) && \text{[F4: } X = \varepsilon_1,\ Y = \text{resto]}\\
&(16) \quad = E(\varepsilon_1) + E(\varepsilon_2) + E(\varepsilon_3 + \cdots + \varepsilon_t) && \text{[F4 de novo]}\\
&(17) \quad = E(\varepsilon_1) + E(\varepsilon_2) + \cdots + E(\varepsilon_t) = \sum_{s=1}^{t} E(\varepsilon_s) && \text{[F4, } t-1 \text{ vezes]}\\
&(18) \quad = \underbrace{0 + 0 + \cdots + 0}_{t \text{ parcelas}} && \text{[RB: } E(\varepsilon_s) = 0\ \forall s\text{]}\\
&(19) \quad = 0\\
&(20) \quad E(Y_t) = a_t + 0 = \alpha_1 t + \alpha_2 \tfrac{t(t+1)}{2} \equiv \mu_t && \text{[(12), (13), (19)]}
\end{aligned}
$$

Por que a esperança pode entrar no Σ (o passo (17)), por indução no número de parcelas n:

- **base,** $n = 1$**:** $E(\varepsilon_1) = E(\varepsilon_1)$ ✓;
- **passo:** se $E\big(\sum_{s=1}^{n} \varepsilon_s\big) = \sum_{s=1}^{n} E(\varepsilon_s)$, então

$$E\Big(\sum_{s=1}^{n+1} \varepsilon_s\Big) = E\Big(\sum_{s=1}^{n} \varepsilon_s + \varepsilon_{n+1}\Big) = E\Big(\sum_{s=1}^{n} \varepsilon_s\Big) + E(\varepsilon_{n+1}) = \sum_{s=1}^{n} E(\varepsilon_s) + E(\varepsilon_{n+1}) = \sum_{s=1}^{n+1} E(\varepsilon_s),$$

usando a F4 com duas parcelas ($X = \sum_{s=1}^{n} \varepsilon_s$ e $Y = \varepsilon_{n+1}$) e depois a hipótese de indução. ✓

Observações:

- **A soma é finita**, com t parcelas, e por isso a troca vale sempre. Numa soma **infinita**, como o MA(∞) da Q6, a troca precisa de $\sum_j |\psi_j| < \infty$.
- **Por que** $E(\varepsilon_s) = 0$**:** é a primeira propriedade do ruído branco, $\varepsilon_t \sim RB(0, \sigma^2)$ (AU01, p. 31). Vale para **cada** data s, e por isso todas as t parcelas de (18) são zero.
- **Exemplo com** $t = 3$**:** $E(\varepsilon_1 + \varepsilon_2 + \varepsilon_3) = E(\varepsilon_1) + E(\varepsilon_2) + E(\varepsilon_3) = 0 + 0 + 0 = 0$.
- **Com** y_0 **genérico**, como no slide: $Y_t = y_0 + a_t + S_t$, e $E(y_0) = y_0$ pela F4, porque y_0 é fixo. Então $E(Y_t) = y_0 + \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$, exatamente a AU01, p. 30.
- **Atalho para a prova**, numa linha: $E\big(\sum_{s=1}^{t} \varepsilon_s\big) = \sum_{s=1}^{t} E(\varepsilon_s) = \sum_{s=1}^{t} 0 = 0$ [F4, soma finita; RB].

Desvio em relação à média. Subtraindo (20) de (10):

$$(21) \qquad Y_t - \mu_t = \sum_{s=1}^{t} \varepsilon_s$$

Variância.

$$V(Y_t) = E\big((Y_t - \mu_t)^2\big) = E\Big(\Big(\sum_{i=1}^{t} \varepsilon_i\Big)^2\Big) \quad [(21)] \tag{22}$$

$$= E\Big(\sum_{i=1}^{t}\sum_{j=1}^{t} \varepsilon_i\varepsilon_j\Big) \quad [\text{quadrado da soma}] \tag{23}$$

$$= \sum_{i=1}^{t}\sum_{j=1}^{t} E(\varepsilon_i\varepsilon_j) \quad [\text{lin.}] \tag{24}$$

$$= \sum_{i=1}^{t} E(\varepsilon_i^2) + \sum_{i\neq j} E(\varepsilon_i\varepsilon_j) \quad [\text{separa } i=j] \tag{25}$$

$$= t\sigma^2 + 0 = t\sigma^2 \quad [\text{RB}] \tag{26}$$

Autocovariância, para $0 \le k < t$:

$$\mathrm{Cov}(Y_t, Y_{t-k}) = E\big((Y_t - \mu_t)(Y_{t-k} - \mu_{t-k})\big) \tag{27}$$

$$= E\Big(\Big(\sum_{i=1}^{t} \varepsilon_i\Big)\Big(\sum_{j=1}^{t-k} \varepsilon_j\Big)\Big) \quad [(21) \text{ em } t \text{ e } t-k] \tag{28}$$

$$= \sum_{i=1}^{t}\sum_{j=1}^{t-k} E(\varepsilon_i\varepsilon_j) \quad [\text{lin.}] \tag{29}$$

$$= \sum_{j=1}^{t-k} E(\varepsilon_j^2) \quad [\text{RB: só } i=j] \tag{30}$$

$$= (t-k)\sigma^2 \tag{31}$$

Em (30), os pares com $i = j$ só existem para $j = 1, \dots, t-k$, porque a segunda soma para em $t-k$: são os choques que Y_t e Y_{t-k} têm em comum.

Correlação:

$$\rho(t,k) = \frac{(t-k)\sigma^2}{\sqrt{t\sigma^2 \cdot (t-k)\sigma^2}} = \sqrt{\frac{t-k}{t}} \tag{32}$$

$$\boxed{E(Y_t) = \alpha_1 t + \alpha_2 \tfrac{t(t+1)}{2}, \qquad V(Y_t) = t\sigma^2, \qquad \mathrm{Cov}(Y_t, Y_{t-k}) = (t-k)\sigma^2}$$

Conclusão: média, variância e autocovariância dependem de *t*. **O processo não é estacionário** (AU01, p. 25).

(c) Comparação com o passeio com drift

Repetindo (1)–(31) com $\alpha_2 = 0$, isto é, com $Y_t = \alpha_1 + Y_{t-1} + \varepsilon_t$ e $Y_0 = 0$, obtém-se $Y_t = \alpha_1 t + \sum_{s=1}^{t} \varepsilon_s$, e:

Momento	Só drift ($\alpha_2 = 0$)	Drift e tendência
$E(Y_t)$	$\alpha_1 t$ (reta)	$\alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$ (parábola)
$V(Y_t)$	$t\sigma^2$	$t\sigma^2$
$\mathrm{Cov}(Y_t, Y_{t-k})$	$(t-k)\sigma^2$	$(t-k)\sigma^2$

Só a média muda, pelo termo $\alpha_2 \frac{t(t+1)}{2}$. A parte aleatória, $\sum \varepsilon_s$, é idêntica nos dois, e por isso variância e covariância são iguais.

(d) Natureza da tendência e como removê-la

Decomposição. Por (10):

$$Y_t = \underbrace{\alpha_1 t + \alpha_2 \frac{t(t+1)}{2}}_{\text{tendência determinística}} + \underbrace{\sum_{s=1}^{t} \varepsilon_s}_{\text{tendência estocástica}} \tag{33}$$

- **Os dois processos têm tendência estocástica** (raiz unitária). Por (10), $\partial Y_{t+j}/\partial \varepsilon_t = 1$ para todo $j \geq 0$: o choque é **permanente**.
- **A tendência determinística muda:** é linear com drift e quadrática com drift e tendência (MAT, §1.3, "tendência geral").

Primeira diferença:

$$\Delta Y_t = Y_t - Y_{t-1} = \alpha_1 + \alpha_2 t + \varepsilon_t \quad \text{[modelo]} \tag{34}$$
$$E(\Delta Y_t) = \alpha_1 + \alpha_2 t \quad \text{[lin., RB]} \tag{35}$$

- **Só drift ($\alpha_2 = 0$):** $\Delta Y_t = \alpha_1 + \varepsilon_t$, que é estacionário. Uma diferença basta.
- **Drift e tendência:** por (35), ΔY_t **ainda tem tendência linear** na média. Uma diferença não basta.

Caminho recomendado. Diferenciar uma vez e **tirar a tendência linear de ΔY_t por regressão** em $(1, t)$. Por (34), o resíduo dessa regressão estima ε_t, que é ruído branco.

Caminho a evitar: diferenciar duas vezes.

$$\Delta^2 Y_t = \Delta Y_t - \Delta Y_{t-1} \quad \text{[definição]} \tag{36}$$
$$= (\alpha_1 + \alpha_2 t + \varepsilon_t) - \big(\alpha_1 + \alpha_2 (t-1) + \varepsilon_{t-1}\big) \quad \text{[(34)]} \tag{37}$$
$$= \alpha_2 + \varepsilon_t - \varepsilon_{t-1} = \alpha_2 + (1 - L)\,\varepsilon_t \tag{38}$$

A média fica constante, α_2, mas sobra um MA(1) com $\theta_1 = -1$. O polinômio $\theta(z) = 1 - z$ tem raiz $z = 1$, sobre o círculo: **não invertível** (AU02, p. 33). É a sobrediferenciação da Q9.

Conclusão (implicação prática): tendência estocástica se remove com **diferença**; tendência determinística se remove com **regressão em** *t*. Aqui, uma diferença e depois a regressão de ΔY_t em *t*. A segunda diferença também estacionariza, mas deixa um MA não invertível.

Versão para a prova (Q2)

O mínimo que precisa estar no papel:

1. Some o modelo de 1 a t (telescópica) e use $\sum s = \frac{t(t+1)}{2}$: $Y_t = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum_{s=1}^{t} \varepsilon_s$.
2. Com $a_t = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$ fixo: $E(Y_t) = E(a_t) + E\big(\sum \varepsilon_s\big) = a_t + \sum E(\varepsilon_s) = a_t + \sum 0 = a_t$ [F4, soma finita; RB].
3. $Y_t - \mu_t = \sum \varepsilon_s$, logo $V(Y_t) = E\big((\sum \varepsilon_s)^2\big) = t\sigma^2$ [RB: só $i = j$].
4. $\mathrm{Cov}(Y_t, Y_{t-k}) = E\big(\sum_{i \leq t} \varepsilon_i \sum_{j \leq t-k} \varepsilon_j\big) = (t-k)\sigma^2$.
5. Os momentos dependem de t: **não estacionário**.
6. Comparação: só a média muda (reta ⟶ parábola); V e Cov são iguais.
7. Tendência estocástica $\sum \varepsilon_s$ + determinística quadrática. $\Delta Y_t = \alpha_1 + \alpha_2 t + \varepsilon_t$ ainda tem tendência: regredir ΔY_t em t. $\Delta^2 Y_t = \alpha_2 + (1 - L)\varepsilon_t$ não é invertível: evitar.

Conferência (Q2)

Com $\alpha_1 = 1$ e $\alpha_2 = 0{,}2$:

- a recursão dá $E(Y_1) = 1{,}2$, $E(Y_2) = 2{,}6$ e $E(Y_3) = 4{,}2$;
- a fórmula (20) dá os mesmos valores: $2 + 0{,}2 \cdot 3 = 2{,}6$ e $3 + 0{,}2 \cdot 6 = 4{,}2$;
- com 50 mil trajetórias simuladas e $\sigma^2 = 1$: $V(Y_3) \approx 2{,}99$ (fórmula: 3), $\mathrm{Cov}(Y_3, Y_1) \approx 1{,}00$ (fórmula: 1) e $\mathrm{Corr}(Y_3, Y_1) \approx 0{,}58$ (fórmula: $\sqrt{1/3} = 0{,}577$).

Q6 · ARMA(1,1)

Enunciado (lista, Q6). O ARMA(1,1) $z_t - \phi z_{t-1} = a_t - \theta a_{t-1}$, com $|\phi| < 1$ e $|\theta| < 1$, na convenção de Box-Jenkins. Pede-se:

- (a) γ_0, γ_1 e γ_k $(k \geq 2)$;
- (b) ρ_1, e mostrar que $\rho_k = \phi^{k-1}\rho_1$;
- (c) as formas AR(∞) e MA(∞), e para que parâmetros a convergência é mais lenta.

Nos slides (AU02, p. 81–84), com a constante c, como o professor e o caderno escrevem:

$$y_t = c + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}, \qquad \varepsilon_t \sim RB(0, \sigma^2),$$

ou seja, $(1 - \phi_1 L)\, y_t = c + (1 + \theta_1 L)\, \varepsilon_t$. A tradução da lista:

- $y_t = z_t$ e $\varepsilon_t = a_t$;
- $\phi_1 = \phi$ e $\theta_1 = -\theta$, por causa do sinal positivo dos slides;
- a lista não tem constante: $c = 0$, logo $\mu = 0$ e $y_t - \mu = z_t$.

Hipóteses: [RB]; $|\phi_1| < 1$ (estacionário); $|\theta_1| < 1$ (invertível). No fim, cada resultado volta para o sinal da lista.

(0) Média, forma em desvios e momentos auxiliares

Valor esperado (AU02, p. 82):

$$\begin{aligned}
&(1) \quad E(y_t) = c + \phi_1 E(y_{t-1}) + E(\varepsilon_t) + \theta_1 E(\varepsilon_{t-1}) && \text{[lin.]}\\
&(2) \quad \mu = c + \phi_1 \mu + 0 + 0 && \text{[estac., RB]}\\
&(3) \quad \mu(1 - \phi_1) = c \implies \mu = \frac{c}{1 - \phi_1} && [|\phi_1| < 1]
\end{aligned}$$

Forma em desvios. Subtraia μ dos dois lados do modelo e troque c por $(1 - \phi_1)\mu$, que vem de (3):

$$\begin{aligned}
&(4) \quad y_t - \mu = (1 - \phi_1)\mu - \mu + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1} && [(3)]\\
&(5) \quad \qquad = -\phi_1 \mu + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}\\
&(6) \quad y_t - \mu = \phi_1 (y_{t-1} - \mu) + \varepsilon_t + \theta_1 \varepsilon_{t-1} && \text{[evidência]}
\end{aligned}$$

A linha (6) é o "já sabemos que" da AU02, p. 82 e 84. A constante sumiu: todas as contas abaixo usam (6).

Momentos auxiliares (como no caderno, 02/09). Pelo item (c), $y_t - \mu = \sum_{j \geq 0} \psi_j \varepsilon_{t-j}$: o desvio de hoje só contém choques de hoje e do passado.

$$
\begin{aligned}
&(7)\quad E(\varepsilon_t\varepsilon_t) = \sigma^2 && \text{[RB]}\\
&(8)\quad E\big((y_{t-k}-\mu)\,\varepsilon_t\big) = 0 \quad \text{para } k \geq 1 && \text{[caus., RB]}\\
&(9)\quad E\big((y_t-\mu)\,\varepsilon_t\big) = E\big((\phi_1(y_{t-1}-\mu)+\varepsilon_t+\theta_1\varepsilon_{t-1})\,\varepsilon_t\big) && \text{[(6)]}\\
&(10)\quad = \phi_1\cdot 0 + \sigma^2 + \theta_1\cdot 0 = \sigma^2 && \text{[(8), (7), RB]}\\
&(11)\quad E\big((y_{t+1}-\mu)\,\varepsilon_t\big) = E\big((\phi_1(y_t-\mu)+\varepsilon_{t+1}+\theta_1\varepsilon_t)\,\varepsilon_t\big) && \text{[(6) em } t+1\text{]}\\
&(12)\quad = \phi_1\sigma^2 + 0 + \theta_1\sigma^2 = (\phi_1+\theta_1)\,\sigma^2 && \text{[(10), RB, (7)]}
\end{aligned}
$$

Por estacionariedade, (10) vale em qualquer data. Em $t-1$, $E\big((y_{t-1}-\mu)\varepsilon_{t-1}\big) = \sigma^2$, que é o "lembre que" da AU02, p. 83.

(a) γ_0, γ_1 e γ_k

γ_0 (AU02, p. 82–83). Por (6):

$$
(13)\qquad \gamma_0 = E\big((y_t-\mu)^2\big) = E\Big(\big(\phi_1(y_{t-1}-\mu)+\varepsilon_t+\theta_1\varepsilon_{t-1}\big)^2\Big)
$$

O quadrado é o produto do parêntese por ele mesmo: $3\times 3 = 9$ termos, na ordem do slide. Cada termo com a sua esperança:

$$
\begin{aligned}
&(14)\quad E\big(\phi_1^2(y_{t-1}-\mu)^2\big) = \phi_1^2\gamma_0 && \text{[estac.]}\\
&(15)\quad E\big(\phi_1(y_{t-1}-\mu)\,\varepsilon_t\big) = 0 && \text{[(8)]}\\
&(16)\quad E\big(\phi_1(y_{t-1}-\mu)\,\theta_1\varepsilon_{t-1}\big) = \phi_1\theta_1\sigma^2 && \text{[(10) em } t-1\text{]}\\
&(17)\quad E\big(\varepsilon_t\,\phi_1(y_{t-1}-\mu)\big) = 0 && \text{[(8)]}\\
&(18)\quad E(\varepsilon_t^2) = \sigma^2 && \text{[(7)]}\\
&(19)\quad E(\varepsilon_t\,\theta_1\varepsilon_{t-1}) = 0 && \text{[RB]}\\
&(20)\quad E\big(\theta_1\varepsilon_{t-1}\,\phi_1(y_{t-1}-\mu)\big) = \theta_1\phi_1\sigma^2 && \text{[(10) em } t-1\text{]}\\
&(21)\quad E(\theta_1\varepsilon_{t-1}\,\varepsilon_t) = 0 && \text{[RB]}\\
&(22)\quad E(\theta_1^2\varepsilon_{t-1}^2) = \theta_1^2\sigma^2 && \text{[RB]}
\end{aligned}
$$

Somando (14)–(22): os termos (16) e (20) são iguais e dão $2\theta_1\phi_1\sigma^2$; os quatro zeros somem.

$$
\begin{aligned}
&(23)\quad \gamma_0 = \phi_1^2\gamma_0 + 2\theta_1\phi_1\sigma^2 + \sigma^2 + \theta_1^2\sigma^2 && \text{[(14)–(22)]}\\
&(24)\quad \gamma_0 - \phi_1^2\gamma_0 = \sigma^2(2\theta_1\phi_1 + 1 + \theta_1^2) && \text{[passa } \phi_1^2\gamma_0\text{]}\\
&(25)\quad \gamma_0\,(1-\phi_1^2) = \sigma^2(2\theta_1\phi_1 + 1 + \theta_1^2) && \text{[evidência]}
\end{aligned}
$$

$$
(26)\qquad \boxed{\gamma_0 = \frac{\sigma^2(2\theta_1\phi_1 + 1 + \theta_1^2)}{1-\phi_1^2}} \qquad [\,1-\phi_1^2 \neq 0 \text{ porque } |\phi_1| < 1\,]
$$

É a forma da AU02, p. 83. **Atenção ao erro do caderno:** é θ_1^2, ao quadrado, no numerador.

γ_k**, equação geral** (AU02, p. 84). Multiplique (6) por $(y_{t-k}-\mu)$ e tire a esperança:

$$
(27)\qquad \underbrace{E\big((y_t-\mu)(y_{t-k}-\mu)\big)}_{\gamma_k} = \phi_1\,\underbrace{E\big((y_{t-1}-\mu)(y_{t-k}-\mu)\big)}_{\gamma_{k-1}} + E\big(\varepsilon_t(y_{t-k}-\mu)\big) + \theta_1 E\big(\varepsilon_{t-1}(y_{t-k}-\mu)\big)
$$

$k = 1$**:**

$$\text{(28)}\quad \gamma_1 = \phi_1 E\big((y_{t-1}-\mu)^2\big) + E\big(\varepsilon_t(y_{t-1}-\mu)\big) + \theta_1 E\big(\varepsilon_{t-1}(y_{t-1}-\mu)\big) \quad [(27),\ k=1]$$
$$\text{(29)}\quad = \phi_1\gamma_0 + 0 + \theta_1\sigma^2 \quad [\text{estac., (8), (10)}]$$

Substituindo (26) em (29), com tudo sobre o denominador $1-\phi_1^2$:

$$\text{(30)}\quad \gamma_1 = \frac{\phi_1(1+2\phi_1\theta_1+\theta_1^2)+\theta_1(1-\phi_1^2)}{1-\phi_1^2}\,\sigma^2 \quad [(26)]$$
$$\text{(31)}\quad = \frac{\phi_1+2\phi_1^2\theta_1+\phi_1\theta_1^2+\theta_1-\phi_1^2\theta_1}{1-\phi_1^2}\,\sigma^2 \quad [\text{distributiva}]$$
$$\text{(32)}\quad = \frac{\phi_1+\theta_1+\phi_1^2\theta_1+\phi_1\theta_1^2}{1-\phi_1^2}\,\sigma^2 \quad [2\phi_1^2\theta_1-\phi_1^2\theta_1]$$

Fatoração do numerador, conferida por expansão: $(1+\phi_1\theta_1)(\phi_1+\theta_1) = \phi_1+\theta_1+\phi_1^2\theta_1+\phi_1\theta_1^2$ ✓. Logo:

$$\text{(33)}\quad \boxed{\gamma_1 = \phi_1\gamma_0 + \theta_1\sigma^2 = \frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1-\phi_1^2}\,\sigma^2}$$

$k \geq 2$**:** em (27), os dois últimos termos são zero por (8):

- $E\big(\varepsilon_t(y_{t-k}-\mu)\big) = 0$, porque $k \geq 1$;
- $E\big(\varepsilon_{t-1}(y_{t-k}-\mu)\big) = 0$, porque a distância entre $t-1$ e $t-k$ é $k-1 \geq 1$.

Sobra $\gamma_k = \phi_1\gamma_{k-1}$. **Indução:**

- base, $k=2$: $\gamma_2 = \phi_1\gamma_1$;
- passo: se $\gamma_{k-1} = \phi_1^{k-2}\gamma_1$, então $\gamma_k = \phi_1 \cdot \phi_1^{k-2}\gamma_1 = \phi_1^{k-1}\gamma_1$.

$$\text{(34)}\quad \boxed{\gamma_k = \phi_1\,\gamma_{k-1} = \phi_1^{k-1}\gamma_1 \quad (k \geq 2)}$$

Atenção ao erro do caderno: o expoente é $k-1$, não k. Confira com $k=2$: um único ϕ_1.

(b) FAC

$$\text{(35)}\quad \rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)\sigma^2/(1-\phi_1^2)}{(1+2\phi_1\theta_1+\theta_1^2)\sigma^2/(1-\phi_1^2)} \quad [(33),(26)]$$
$$\text{(36)}\quad = \frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1+2\phi_1\theta_1+\theta_1^2} \quad [\text{cancela } \sigma^2 \text{ e } 1-\phi_1^2]$$

$\rho_k = \phi_1^{k-1}\rho_1$ **por indução**, dividindo (34) por γ_0:

- **base,** $k=1$**:** $\phi_1^0\rho_1 = \rho_1$ ✓;
- **passo:** se $\rho_{k-1} = \phi_1^{k-2}\rho_1$, então $\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\phi_1\gamma_{k-1}}{\gamma_0} = \phi_1\rho_{k-1} = \phi_1\cdot\phi_1^{k-2}\rho_1 = \phi_1^{k-1}\rho_1$ ✓.

$$\text{(37)}\quad \boxed{\rho_k = \phi_1^{k-1}\rho_1 \quad (k \geq 1)}$$

Conclusão: a FAC decai geometricamente, à taxa ϕ_1, mas **a partir de ρ_1, e não de 1**. O MA só altera o primeiro valor.

(c) MA(∞), AR(∞) e a velocidade de convergência

Como na lista, $c = 0$: então $\mu = 0$ e $y_t - \mu = y_t$. Com constante, troque cada y por $y - \mu$, pela forma em desvios (6).

MA(∞), caminho 1 — substituição recursiva.

$$
\begin{aligned}
(38)\quad & y_t = \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1} && \text{[modelo]}\\
(39)\quad & = \phi_1(\phi_1 y_{t-2} + \varepsilon_{t-1} + \theta_1 \varepsilon_{t-2}) + \varepsilon_t + \theta_1 \varepsilon_{t-1} && \text{[modelo em } t-1\text{]}\\
(40)\quad & = \varepsilon_t + (\phi_1 + \theta_1)\varepsilon_{t-1} + \phi_1\theta_1\varepsilon_{t-2} + \phi_1^2 y_{t-2} && \text{[agrupando]}\\
(41)\quad & = \varepsilon_t + (\phi_1 + \theta_1)\varepsilon_{t-1} + \phi_1(\phi_1 + \theta_1)\varepsilon_{t-2} + \phi_1^2\theta_1\varepsilon_{t-3} + \phi_1^3 y_{t-3} && \text{[modelo em } t-2\text{]}
\end{aligned}
$$

Em (41), o coeficiente de ε_{t-2} é $\phi_1\theta_1 + \phi_1^2 = \phi_1(\phi_1 + \theta_1)$. O padrão: o coeficiente de ε_{t-j}, $j \geq 1$, é $(\phi_1 + \theta_1)\phi_1^{j-1}$. Depois de n substituições, o resto é $\phi_1^{n-1}\theta_1\varepsilon_{t-n} + \phi_1^n y_{t-n}$. Ele vai a zero em média quadrática, porque $E(\phi_1^{2n} y_{t-n}^2) = \phi_1^{2n}\gamma_0 \to 0$ quando $|\phi_1| < 1$.

MA(∞), caminho 2 — igualdade de coeficientes. $\Psi(L) = \frac{1+\theta_1 L}{1-\phi_1 L}$ significa $\Psi(L)(1 - \phi_1 L) = 1 + \theta_1 L$. Expandindo o lado esquerdo:

$$(1 + \psi_1 L + \psi_2 L^2 + \cdots)(1 - \phi_1 L) = 1 + (\psi_1 - \phi_1)L + (\psi_2 - \phi_1\psi_1)L^2 + \cdots + (\psi_j - \phi_1\psi_{j-1})L^j + \cdots$$

Igualando com $1 + \theta_1 L$, potência por potência:

- L^1: $\psi_1 - \phi_1 = \theta_1$, logo $\psi_1 = \phi_1 + \theta_1$;
- L^j, $j \geq 2$: $\psi_j - \phi_1\psi_{j-1} = 0$, logo $\psi_j = \phi_1\psi_{j-1}$.

$$(42)\qquad \boxed{\psi_0 = 1, \quad \psi_j = (\phi_1 + \theta_1)\,\phi_1^{j-1}\ (j \geq 1)} \qquad y_t = \varepsilon_t + (\phi_1 + \theta_1)\sum_{j\geq 1}\phi_1^{j-1}\varepsilon_{t-j}$$

AR(∞). $\pi(L) = \frac{1-\phi_1 L}{1+\theta_1 L}$, com $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots$ (AU02, p. 19).

- Pela série geométrica com razão $-\theta_1 L$, válida porque $|\theta_1| < 1$: $(1 + \theta_1 L)^{-1} = \sum_{j\geq 0}(-\theta_1)^j L^j$.
- Multiplicando por $(1 - \phi_1 L)$, o coeficiente de L^j, $j \geq 1$, é

$$(-\theta_1)^j - \phi_1(-\theta_1)^{j-1} = (-\theta_1)^{j-1}(-\theta_1 - \phi_1) = -(\phi_1 + \theta_1)(-\theta_1)^{j-1}.$$

- Comparando com $-\pi_j$:

$$(43)\qquad \boxed{\pi_j = (\phi_1 + \theta_1)\,(-\theta_1)^{j-1}\ (j \geq 1)} \qquad y_t = \sum_{j\geq 1}\pi_j\, y_{t-j} + \varepsilon_t$$

Quando cada série converge.

- $\sum_j |\psi_j| = 1 + |\phi_1 + \theta_1|\sum_{j\geq 1}|\phi_1|^{j-1} = 1 + \frac{|\phi_1+\theta_1|}{1-|\phi_1|} < \infty \iff |\phi_1| < 1$, que é a **estacionariedade**.
- $\sum_j |\pi_j| = \frac{|\phi_1+\theta_1|}{1-|\theta_1|} < \infty \iff |\theta_1| < 1$, que é a **invertibilidade**.

Quando a convergência é mais lenta. Os $|\psi_j|$ encolhem por um fator $|\phi_1|$ a cada período. A **meia-vida**, o número de períodos para um peso cair à metade, resolve $|\phi_1|^h = \frac{1}{2}$:

$$h = \frac{\ln 0{,}5}{\ln|\phi_1|}\ : \qquad \phi_1 = 0{,}5 \Rightarrow h = 1; \qquad \phi_1 = 0{,}9 \Rightarrow h = 6{,}58; \qquad \phi_1 = 0{,}99 \Rightarrow h = 68{,}97.$$

- **MA(∞) mais lento quando** $|\phi_1| \to 1$: perto da raiz unitária, os choques demoram a morrer.

- **AR(∞) mais lento quando** $|\theta_1| \to 1$: perto da não invertibilidade, é preciso muito passado de y para recuperar ε_t.
- **Caso extremo,** $\phi_1 = -\theta_1$**:** $\psi_j = \pi_j = 0$ para $j \geq 1$, e $y_t = \varepsilon_t$. Os fatores se cancelam: é um fator comum.

De volta ao sinal da lista ($\theta_1 = -\theta$)

	Slides	Lista
γ_0	$\frac{1+2\phi_1\theta_1+\theta_1^2}{1-\phi_1^2}\sigma^2$	$\frac{1-2\phi\theta+\theta^2}{1-\phi^2}\sigma_a^2$
γ_1	$\frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1-\phi_1^2}\sigma^2$	$\frac{(1-\phi\theta)(\phi-\theta)}{1-\phi^2}\sigma_a^2$
ρ_1	$\frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1+2\phi_1\theta_1+\theta_1^2}$	$\frac{(1-\phi\theta)(\phi-\theta)}{1-2\phi\theta+\theta^2}$
ρ_k	$\phi_1^{k-1}\rho_1$	$\phi^{k-1}\rho_1$
ψ_j	$(\phi_1+\theta_1)\phi_1^{j-1}$	$(\phi-\theta)\phi^{j-1}$
π_j	$(\phi_1+\theta_1)(-\theta_1)^{j-1}$	$(\phi-\theta)\theta^{j-1}$

Versão para a prova (Q6)

1. Convenção: sinais dos slides, $\theta_1 = -\theta$.
2. $\mu = \frac{c}{1-\phi_1}$ e a forma em desvios $y_t - \mu = \phi_1(y_{t-1}-\mu) + \varepsilon_t + \theta_1\varepsilon_{t-1}$ (na lista, $c = 0$).
3. Momentos auxiliares: $E(\varepsilon_t\varepsilon_t) = \sigma^2$; $E\big((y_{t-k}-\mu)\varepsilon_t\big) = 0$ para $k \geq 1$; $E\big((y_t-\mu)\varepsilon_t\big) = \sigma^2$; $E\big((y_{t+1}-\mu)\varepsilon_t\big) = (\phi_1+\theta_1)\sigma^2$.
4. $\gamma_0 = E\big((\phi_1(y_{t-1}-\mu) + \varepsilon_t + \theta_1\varepsilon_{t-1})^2\big)$: nove termos, quatro zeros, $\gamma_0 = \phi_1^2\gamma_0 + 2\theta_1\phi_1\sigma^2 + \sigma^2 + \theta_1^2\sigma^2$, logo $\gamma_0 = \frac{\sigma^2(2\theta_1\phi_1+1+\theta_1^2)}{1-\phi_1^2}$.
5. $\gamma_1 = \phi_1\gamma_0 + \theta_1\sigma^2 = \frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1-\phi_1^2}\sigma^2$.
6. $k \geq 2$: $\gamma_k = \phi_1\gamma_{k-1}$, porque os dois choques do modelo são posteriores a y_{t-k}.
7. $\rho_1 = \gamma_1/\gamma_0$; $\rho_k = \phi_1\rho_{k-1} = \phi_1^{k-1}\rho_1$ (indução).
8. $\Psi(L)(1-\phi_1 L) = 1 + \theta_1 L$ dá $\psi_j = (\phi_1+\theta_1)\phi_1^{j-1}$, que converge se $|\phi_1| < 1$.
9. $\pi(L)(1+\theta_1 L) = 1 - \phi_1 L$ dá $\pi_j = (\phi_1+\theta_1)(-\theta_1)^{j-1}$, que converge se $|\theta_1| < 1$.
10. Mais lento: $|\phi_1| \to 1$ para os ψ e $|\theta_1| \to 1$ para os π. Meia-vida $\ln 0{,}5 / \ln|\phi_1|$.
11. Traduzir para a lista com $\theta_1 = -\theta$.

Conferência (Q6)

Com $\phi_1 = 0{,}7$, $\theta_1 = -0{,}4$ (isto é, $\theta^{\text{lista}} = 0{,}4$) e $\sigma^2 = 1$:

- $\gamma_0 = \frac{1-0{,}56+0{,}16}{0{,}51} = 1{,}1765$;
- $\gamma_1 = 0{,}7(1{,}1765) - 0{,}4 = 0{,}4235$;
- $\rho_1 = 0{,}36$ e $\rho_2 = 0{,}252$;
- $\psi_1, \psi_2, \psi_3 = 0{,}3;\ 0{,}21;\ 0{,}147$ e $\pi_1, \pi_2, \pi_3 = 0{,}3;\ 0{,}12;\ 0{,}048$.

A substituição recursiva (42) e a fórmula (43) coincidem com o `ARMAtoMA` do R, com diferença zero.