Séries temporais

P1 completa

Teoria, folhas à mão, lista comentada, banco, simulados e formulário, bloco a bloco da lista

---

Caderno de estudo · parte 1: ARMA, ARIMA e SARIMA

Prof. Guilherme Pereira · Econometria II (PPGEco/UFES)

Gerado em 02/11/2026 a partir de `github.com/fcarva/series-temporais` (commit `369811f`). Material autoral: enunciados parafraseados, demonstrações próprias, números conferidos em R contra os scripts do repositório.

Sumário

I Mapa 1

1 Mapa das questões 2

II Como usar este volume 3

2 Prova de 05/11/2026: guia de treino 4

3 Apostila da P1: entender a fundo, na notação do professor 10

4 1. Da lista para os slides 12

5 2. Caixa de ferramentas 13

6 3. O meu caderno e onde ele entra 16

III Bloco 1 — Processos e momentos (Q1–Q4) 17

7 Capítulo 1 · Processos e momentos: o que é estável numa série 18

8 Cap. 1 à mão — Q1 a Q4 linha a linha 28

9 Q2 · Passeio com drift e tendência determinística 33

10 Q1 · Momentos do passeio aleatório com drift 38

11 Q2 · Passeio com drift e tendência determinística 42

12 Q3 · FAC de $z_{3t} = z_{1t} + 2z_{2t}$ 45

13 Q4 · Teorema de Wold 48

14 Bloco 1 — Processos, estacionariedade e momentos 51

15 D01.4 · Estacionariedade fraca, estrita e ergodicidade: três processos que separam os conceitos 53

IV Bloco 2 — AR, MA e ARMA (Q5–Q8) 55

16 Capítulo 2 · AR, MA e ARMA: memória, eco e reconstrução 56

17 Cap. 2 à mão — Q5 a Q8 linha a linha 65

18 Q6 · ARMA(1,1) 71

19 Q5 · Três modelos: operador, classificação, raízes, ψ_j e π_j 76

20 Q6 · ARMA(1,1) **79**

21 Q7 · AR(2): Yule-Walker e variância **83**

22 Q8 · Verdadeiro ou falso, com demonstração **87**

23 Bloco 2 — AR, MA e ARMA **90**

24 D02.4 · Equações de diferenças: a mesma conta da estacionariedade **92**

25 D02.5 · De onde vem a banda $\pm 1{,}96/\sqrt{T}$ e quando ela engana **94**

26 4. A tabela de identificação **95**

V Bloco 3 — Integrados, ARIMA e SARIMA (Q9–Q12) **97**

27 Capítulo 3 · Integrados, ARIMA e SARIMA: a diferença na dose certa **98**

28 Cap. 3 à mão — Q9 a Q12 linha a linha **107**

29 Q9 · Sobrediferenciação: diferenciar um AR(1) que já é estacionário **113**

30 Q10 · ARIMA, raiz unitária e tendência determinística **116**

31 Q11 · SAR(1)$_4$ e o multiplicativo como AR(5) restrito **119**

32 Q12 · SARIMA$(1,1,0)(0,1,1)_4$ trimestral **122**

33 Bloco 3 — Integrados, ARIMA e SARIMA **125**

34 2. Testes de raiz unitária **126**

VI Bloco 4 — Estimação e seleção (Q13–Q14) **129**

35 Capítulo 4 · Estimação e seleção: o detetive e os dois juízes **130**

36 Cap. 4 à mão — Q13 e Q14 linha a linha **138**

37 Q13 · Log-verossimilhança condicional do AR(1) e o estimador de MQO **142**

38 Q14 · AIC e BIC **145**

39 Bloco 4 — Identificação, estimação e diagnóstico **148**

VII Bloco 5 — Previsão (Q15) **149**

40 Capítulo 5 · Previsão: o elástico e o leque **150**

41 Cap. 5 à mão — Q15 linha a linha **160**

42 Q15 · Previsão em ARMA(p,q) **164**

43 Bloco 5 — Previsão **168**

VIII Bloco 6 — Aplicação (Q16) **169**

44 Capítulo 6 · Aplicação: Box-Jenkins de ponta a ponta num SARIMA mensal **170**

45 Cap. 6 à mão — Q16 linha a linha **177**

46 Q16 · SARIMA$(1,1,1)(0,1,1)_{12}$ com 240 observações mensais **181**

47 Bloco 6 — Aplicação **184**

IX Treino: simulados, gabaritos e log de erros **185**

48 Simulado 01 **187**

49 Simulado 02 **189**

50 Simulado 03 **191**

51 Simulado 01 — gabarito **193**

52 Simulado 01: a correção da minha tentativa **200**

53 Simulado 02 — gabarito **203**

54 Simulado 03 — gabarito **209**

55 Log de erros **215**

X Consulta rápida **217**

56 Formulário **218**

Parte I

Mapa

CAPÍTULO 1

Mapa das questões

Cada questão da lista aparece em quatro camadas, nesta ordem dentro do bloco: o capítulo da apostila (teoria, imagens, perguntas), a folha à mão (a demonstração linha a linha), a nota comentada (slide, livro e caderno) e as variações do banco. A tabela dá a página de cada uma.

Questão	Apostila	Folha à mão	Comentada	Banco
Q1	18	28	38	51
Q2	18	28, 33	42	51
Q3	18	28	45	51
Q4	18	28	48	51
Q5	56	65	76	90
Q6	56	65, 71	79	90
Q7	56	65	83	90
Q8	56	65	87	90
Q9	98	107	113	125
Q10	98	107	116	125
Q11	98	107	119	125
Q12	98	107	122	125
Q13	130	138	142	148
Q14	130	138	145	148
Q15	150	160	164	168
Q16	170	177	181	184

Parte II

Como usar este volume

CAPÍTULO 2

Prova de 05/11/2026: guia de treino

O que se sabe da prova: **5 ou 6 questões, de 1h50 a 2h, sem consulta, tiradas da lista** "Processos ARMA, ARIMA e SARIMA" (`LST`). A aposta é **uma questão por bloco da lista**, com números e torções novos. Este guia junta quatro coisas:

1. o mapa de cada bloco para a resolução, a demonstração e o livro;
2. a estratégia de tempo;
3. as lições da P1 de Econometria I, traduzidas para séries temporais;
4. o plano dos 8 dias até a prova.

Arquivo	Para quê
volume único da P1	**o PDF para imprimir**, `caderno_p1_completo.pdf`, na pasta `caderno/pdf/`: os seis blocos (apostila, folha à mão, comentadas, banco), os simulados e os gabaritos, o log e o formulário
apostila	**um capítulo por bloco da lista**: teoria com página do slide, demonstrações linha a linha, exemplo em R, perguntas em cadeia, diálogo e imagens; leia o capítulo antes de fazer as questões do bloco
lista comentada	**as 16 questões da lista, passo a passo, na notação dos slides**, com o caderno corrigido: comece por aqui
Q2 e Q6 à mão	as duas questões escolhidas para treinar no papel, linha a linha, no formato de caderno
banco.md	as 16 questões da lista em **variações** curtas com resposta: o treino diário
simulado_01.md · gabarito	próximo da lista, para calibrar o tempo
simulado_02.md · gabarito	as torções: sinal positivo, AR(2), sazonal trimestral
simulado_03.md · gabarito	integrador: V ou F, previsão numérica de SARIMA, identificação
log_erros.md	registro dos erros com revisão em +1, +3 e +7 dias
prova.R	todos os números dos simulados e do banco (id `pv`)
formulário	todas as fórmulas

1. O mapa da prova

Bloco (questões da lista)	O que pode cair	Resolução e demonstrações	Livros
1. Processos e momentos (Q1–Q4)	momentos de passeio com drift e com tendência; soma de processos e FAC; Wold	01_lista, D01.1–D01.4	ENDERS cap. 4; HAMILTON cap. 3–4; MAT
2. AR, MA e ARMA (Q5–Q8)	raízes, fator comum, ψ_j e π_j; γ_k do ARMA(1,1); Yule-Walker; V ou F	02_lista, D02.1–D02.5	ENDERS cap. 2; HAMILTON cap. 3; BJRL cap. 3
3. Integrados, ARIMA e SARIMA (Q9–Q12)	sobrediferenciação; DS × TS; SAR e AR restrito; previsão de SARIMA	03_lista, D03.1–D03.4	ENDERS cap. 2 e 4; BJRL cap. 4 e 9; MAT
4. Estimação e seleção (Q13–Q14)	MV condicional = MQO; AIC e BIC com k incluindo σ^2	04_lista, D04.1	HAMILTON cap. 5; AU02

Bloco (questões da lista)	O que pode cair	Resolução e demonstrações	Livros
5. Previsão (Q15)	previsor ótimo; erro MA($h-1$); intervalo; SES	05_lista, D05.1	HAMILTON cap. 4; BJRL cap. 5
6. Aplicação (Q16)	escrever o SARIMA, contar parâmetros, FAC de w_t, escolher entre modelos	06_lista	BJRL cap. 9; AU03

Notação: a do professor, que é a da lista

- Operador B; a_t, ε_t, $u_t \sim RB(0, \sigma^2)$; γ_k, ρ_k, ϕ_{kk}; ψ_j, π_j; $y_{T+h|T} = E(y_{T+h} \mid \mathcal{F}_T)$.
- **MA de Box-Jenkins**, $\theta(B) = 1 - \theta_1 B - \cdots$, em quase toda a lista.
- **Sinal positivo**, $1 + \theta_1 L + \cdots$, na Q8 e nos slides (AU02).

Primeira linha de toda resposta com MA: "convenção: BJ" ou "convenção: sinal positivo". Ver CONVENCOES §2.

2. Estratégia no dia

Com 110 minutos e 10 pontos, cada ponto vale **11 minutos**: uma questão de 1,5 merece até 16 minutos, e uma de 2,0, até 22.

1. **Leitura (3 min).** Percorra a prova e marque, em cada questão, a convenção do MA, o T, o s e os valores críticos dados.
2. **Contas curtas primeiro (≈25 min).** AIC e BIC, observações perdidas, raízes, ψ_1 a ψ_3, γ_0 de fórmula pronta, previsões de 1 a 3 passos. São os pontos mais baratos, e foi justamente o que ficou em branco na P1 de Econometria I.
3. **Derivações (≈70 min), da mais curta para a mais longa.** Momentos do passeio → FAC de soma → ARMA(1,1) → previsor ótimo → previsão de SARIMA.
4. **Revisão (10 min).** Sinal do MA, $\psi_0 = 1$, k com σ^2, a frase de conclusão de cada item.
5. **Se faltar tempo:** escreva a fórmula geral e a estrutura da conta. A rubrica dá ponto por passo.

O que cada verbo pede

Verbo	O que precisa aparecer
Calcule	fórmula geral → números → resultado com unidade ou interpretação
Mostre / demonstre	hipóteses usadas, uma justificativa por linha ([RB], estacionariedade, causalidade, LEI) e **a frase final com o que se pediu**
Verifique (estacionariedade, invertibilidade)	raízes ou desigualdades → "estão fora do círculo" → **"logo, é estacionário"**
Discuta / compare	duas ou três consequências concretas: estimação, previsão, inferência
Julgue (V ou F)	a conta que decide; "V" sem conta vale zero
Identifique / proponha	o padrão da FAC e da FACP que leva ao modelo e quantos parâmetros ele tem

3. Os erros da P1 de Econometria I e o equivalente aqui

Na P1 de Econometria I (09/10/2026), os pontos se perderam na **execução**, não no conceito. Ver o log em `econometria/provas/log_erros.md` e o mapa da prova em `econometria/provas/p1_2026_2/README.md`. Cerca de 2,5 pontos ficaram em contas de uma linha deixadas em branco, e mais pontos em demonstrações que pararam antes da conclusão. Cada erro tem um gêmeo nesta prova:

Erro na P1 de Econometria I	Causa	Onde reaparece aqui	Regra para 05/11
Q1, Q3c e Q4b em branco: matriz diagonal, F de uma linha, 340/85	**T** tempo	AIC e BIC (Q14), observações perdidas $d + sD$ (Q12, Q16), raízes de $\phi(z)$ e $\theta(z)$, ψ_1 a ψ_3, $\hat{\phi} = \sum y_t y_{t-1} / \sum y_{t-1}^2$	**fazer primeiro** todo item de 1 a 3 linhas de conta
Q2d: efeito marginal 4,5% sem o termo $2\beta_3 EXP$	**A** número sem fórmula	ρ_1 do MA(1) com o sinal da convenção errada; γ_0 do ARMA(1,1) sem o termo $-2\phi\theta$; $\mathrm{Var}(e_T(h))$ sem $\psi_0 = 1$; k sem σ^2; a^2 em vez de a em γ_{az}	**escrever a fórmula geral e a convenção** antes de pôr números
Q3c: rejeitou H_0 sem calcular F	**E** passo pulado	Ljung-Box sem $\nu = K - p - q - P - Q$; LR sem $2(\ell_1 - \ell_0)$	todo teste em quatro linhas: H_0, estatística e distribuição, decisão, conclusão
Q5: Gauss-Markov parou em $\sigma^2\mathbf{CC}'$	**E** sem conclusão	"verifique se é estacionário" sem a frase final; Wold sem $\sum \psi_j^2 < \infty$; previsor ótimo sem "logo, $g = E(\cdot \mid \mathcal{F}_T)$"; sobrediferenciação sem "raiz no círculo $\Rightarrow$ não invertível $\Rightarrow$ sem AR(∞)"	**reler o verbo** do enunciado e fechar com a frase que ele pede
Q4a: plim em branco por esquecimento	**E** resultado esquecido	ARMA(1,1): os momentos auxiliares $E(z_t a_t)$ e $E(z_t a_{t-1})$	refazer de cabeça D02.2 e Q6 até sair em 8 minutos
(banco B12) covariância zerada sem citar a hipótese	**H** hipótese	FAC da soma sem "não correlacionados"; $E(a_t y_{t-k}) = 0$ sem "causalidade"; série geométrica sem $\lvert\phi\rvert < 1$	uma justificativa entre colchetes por linha

As três armadilhas próprias desta prova

1. **Trocar de convenção no meio da prova.** A lista faz isso na Q8. Na BJ, $\psi_1 = \phi - \theta$; no sinal positivo, $\psi_1 = \phi + \theta$.
2. **Confundir FAC e FACP.** No AR(2), $\phi_{22} = \phi_2$, mas $\rho_2 \neq \phi_2$. No SAR(1)$_s$, a FAC decai em $s, 2s, \ldots$, e a FACP tem um pico só.
3. **Contar errado o que se perde e o que se estima.** Perdem-se $d + sD$ observações. Os parâmetros são $p + q + P + Q + 1$ (o σ^2), mais a constante só se $d = D = 0$ e houver média.

4. O mínimo para saber de cor

Tudo o mais se deriva disto em poucas linhas. Formulário completo em formulario.md.

#	Resultado
1	Passeio com drift: $E = y_0 + ct$, Var $= t\sigma^2$, Cov $= (t-k)\sigma^2$
2	$\sum_{s=1}^{t} s = t(t+1)/2$ (drift com tendência; Q2 e Q8)
3	Processo linear: $\gamma_k = \sigma^2 \sum_j \psi_j \psi_{j+k}$
4	Estacionário $\Leftrightarrow$ raízes de $\phi(z)$ fora do círculo; invertível $\Leftrightarrow$ raízes de $\theta(z)$ fora
5	AR(2): $\phi_1 + \phi_2 < 1$, $\phi_2 - \phi_1 < 1$, $\lvert\phi_2\rvert < 1$
6	MA(1), BJ: $\rho_1 = -\theta/(1+\theta^2)$; com sinal positivo, troque o sinal
7	ARMA(1,1), BJ: $\gamma_0 = \frac{1+\theta^2-2\phi\theta}{1-\phi^2}\sigma^2$, $\rho_1 = \frac{(1-\phi\theta)(\phi-\theta)}{1+\theta^2-2\phi\theta}$, $\rho_k = \phi\rho_{k-1}$
8	Pesos do ARMA(1,1), BJ: $\psi_j = (\phi-\theta)\phi^{j-1}$, $\pi_j = (\phi-\theta)\theta^{j-1}$
9	Yule-Walker: $\rho_k = \sum \phi_i \rho_{k-i}$; $\gamma_0 = \sigma^2/(1 - \sum \phi_i \rho_i)$; $\phi_{22} = \frac{\rho_2 - \rho_1^2}{1-\rho_1^2}$
10	Sobrediferenciação: $\phi(B)\Delta y = (1-B)\theta(B)\varepsilon$; RB diferenciado tem $\rho_1 = -\frac{1}{2}$; AR(1) diferenciado tem $\rho_1 = -\frac{1-\phi}{2}$
11	SAR(1)$_s$: $\rho_{ms} = \Phi^m$, zero fora dos múltiplos; $(1-\phi B)(1-\Phi B^s)$ tem o termo $+\phi\Phi B^{s+1}$
12	Modelo das companhias aéreas: $\rho_1 = \frac{-\theta}{1+\theta^2}$, $\rho_s = \frac{-\Theta}{1+\Theta^2}$, $\rho_{s\pm1} = \frac{\theta\Theta}{(1+\theta^2)(1+\Theta^2)}$
13	MV condicional do AR(1) = MQO: $\hat{\phi} = \sum y_t y_{t-1} / \sum y_{t-1}^2$
14	$AIC = -2\ln L + 2k$, $BIC = -2\ln L + k\ln T$ (a AU02 divide por T); $LR = 2(\ell_1 - \ell_0) \sim \chi^2(r)$
15	Previsão: $e_T(h) = \sum_{j=0}^{h-1} \psi_j a_{T+h-j}$, Var $= \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$, IC: $y_{T+h\lvert T} \pm 1{,}96\sqrt{\text{Var}}$
16	ARIMA(0,1,1) = SES com $\alpha = 1 - \theta$
17	Ljung-Box: $\nu = K - p - q - P - Q$

5. Plano até a prova

Como atacar a lista

1. **Não comece pela Q1. Comece pelo bloco 2 (Q5–Q8).** É o que mais pesa e é a base dos outros: raízes, ψ e π, γ_k, Yule-Walker. A ordem é bloco 2 $\longrightarrow$ 1 $\longrightarrow$ 3 $\longrightarrow$ 5 $\longrightarrow$ 4 $\longrightarrow$ 6, a mesma da apostila.
2. **Por questão, um ciclo de quatro passos**, sem ler a resolução antes:
    1. **Ler e marcar:** a convenção do MA (BJ ou sinal positivo), s, T e o verbo de cada item.
    2. **Tentar sozinho, de 10 a 15 minutos, no papel,** mesmo travando. Pergunte-se qual ferramenta resolve (F1–F9).
    3. **Comparar com a folha à mão, linha a linha.** Ache a **primeira linha** em que você divergiu e anote no log, com o código.
    4. **No dia seguinte, refazer sem olhar**, usando só a "Versão para a prova" da folha como roteiro.
3. **A apostila serve para destravar, não para ler antes.** Quando travar, leia só a pergunta de abertura e a imagem do capítulo. Faça a cadeia socrática **cobrindo as respostas**. A teoria e as demonstrações gerais ficam para depois da tentativa.
4. **Treine os cinco moldes, não as 16 questões.** Se o molde sai de cabeça, a questão sai.

Molde	Questões
(a) somar de 1 a t (telescópica), depois E e Var da soma	Q1, Q2, Q8 (II), Q10 (c, d)
(b) multiplicar pelo passado e tirar a esperança	Q3, Q6, Q7, Q8 (I), Q11
(c) raízes por Bhaskara e pesos por igualdade de coeficientes	Q5, Q6 (c), Q9, Q10 (b), Q11 (c)
(d) esperança condicional com as três regras [F9]	Q12 (c), Q15

Molde	Questões
(e) contas de critério: AIC/BIC, LR, Ljung-Box, $d + sD$, parâmetros	Q14, Q16, Q12 (b)

5. **Q2 e Q6, as questões escolhidas para fazer à mão:** copie a folha completa **uma vez**, depois refaça de cabeça em +1 e +3 dias, cronometrando. Metas: Q2 em até 12 minutos e Q6 em até 15.
6. **O mínimo de cor** (§4): escreva numa folha A4, de memória, a cada dois dias. O que faltar entra no log.
7. **No dia, as lições da P1 de Econometria I** (§3):
   - contas curtas primeiro;
   - fórmula geral e convenção antes dos números;
   - uma justificativa por linha;
   - fechar com a frase que o verbo pede.

O ciclo de 29/10 a 05/11

Cerca de 2h30 a 3h por dia; os simulados levam 1h50 mais 40 minutos de correção. Revisões do log em +1 e +3 dias. No papel, tudo está no volume único `caderno_p1_completo.pdf`, e o mapa das questões na abertura dá as páginas.

Dia	Foco	Tarefas
qui 29/10	bloco 2 (Q5–Q8)	ciclo dos quatro passos em Q5, Q7 e Q8; **copiar a folha completa da Q6**; cadeia socrática do cap. 2
sex 30/10	bloco 1 (Q1–Q4)	ciclo em Q1, Q3 e Q4; **copiar a folha completa da Q2**; Q6 de cabeça, cronometrada (+1)
sáb 31/10	blocos 3 e 5 (Q9–Q12, Q15)	ciclo nas cinco questões; Q2 de cabeça (+1); refazer os erros do log de 29/10 (+1)
dom 01/11	diagnóstico	**Simulado 01** cronometrado, correção pela rubrica e log; blocos 4 e 6 (Q13, Q14, Q16) pelo molde (e)
seg 02/11	correção do S1	refazer S1 Q2 b)–d) com o roteiro de quatro movimentos, sem olhar; refazer S1 Q3 a)–c); **S1 Q4, Q5 b)–d) e Q6 a)–b) em 30 minutos, só conta**; ler a correção do S1
ter 03/11	treino	**Simulado 02 em modo prova** (3 min de leitura, 25 min de contas curtas de todas as questões, depois as derivações); correção e log; à noite, a Q6 da lista de cabeça, em até 15 minutos
qua 04/11	leve	S1 Q2 inteira de cabeça (+3); do Simulado 03, **só** Q3 c), Q4 b)–c) e Q5 a)–b), que são contas; mínimo de cor; armadilhas (§3); dormir cedo
qui 05/11	**prova**	15 minutos antes: o roteiro de quatro movimentos do ARMA, o mínimo de cor e a ordem contas curtas → derivações → revisão

O Simulado 01 foi feito em 01/11, e a correção mostra onde os pontos foram embora. O Simulado 03 completo saiu do plano: não há tempo, e cansaria na véspera.

Se sobrar tempo num dia, use o banco do bloco do dia: cada questão tem uma variação curta com resposta.

Os três simulados

Cada simulado tem 6 questões (uma por bloco), soma 10,0 pontos e cabe em 1h50 com 10 minutos de revisão. Os números não se repetem entre simulados nem com o banco.

Bloco	Simulado 01	Simulado 02	Simulado 03
1. Processos	passeio sem drift e soma de processos	processo harmônico; MA(1) com par não invertível	TS × DS
2. ARMA	ARMA(1,1), BJ	AR(2) completo	V ou F do ARMA(1,1) com sinal positivo
3. ARIMA e SARIMA	AR(1) sobrediferenciado	$\text{SAR}(1)_4$, AR(5) restrito, ARIMA(1,1,1)	previsão numérica do $\text{SARIMA}(1,1,0)(0,1,1)_4$
4. Estimação	AIC/BIC com $T = 200$; MV condicional	AIC/BIC da AU02, LR, MV exata	AIC, BIC e LR entre SARIMA
5. Previsão	AR(1) com média e o previsor ótimo	ARMA(1,1) com sinal positivo; SES	MA(2): previsão e memória
6. Aplicação	modelo das companhias aéreas	$\text{SARIMA}(1,0,0)(0,1,1)_{12}$ e Ljung-Box	identificação pela FAC amostral

CAPÍTULO 3

Apostila da P1: entender a fundo, na notação do professor

A prova de 05/11 tem de 5 a 6 questões teóricas tiradas da lista "Processos ARMA, ARIMA e SARIMA". Esta apostila reúne, **um capítulo por bloco da lista**:

- a aula, com a página do slide;
- o livro, pelo capítulo;
- as demonstrações completas, linha a linha;
- um exemplo com números conferidos em R.

Ela acrescenta duas coisas que o material não tem: **perguntas em cadeia e um diálogo** (o lado socrático) e **imagens** (metáforas e analogias), cada uma com o ponto onde deixa de valer.

Capítulo	Questões	Aulas	Ideia central
1 · Processos e momentos	Q1–Q4	AU01, MAT, EQD, AU02 p. 15–23	o que é "estável" numa série: momentos, passeio, Wold
2 · AR, MA e ARMA	Q5–Q8	AU02	memória (AR), eco (MA) e a reconstrução dos choques (invertibilidade)
3 · Integrados, ARIMA e SARIMA	Q9–Q12	AU01 p. 28–30, MAT, AU05	raiz unitária, diferença na dose certa, sazonalidade
4 · Estimação e seleção	Q13–Q14	AU02 p. 58–99	verossimilhança, Yule-Walker, AIC e BIC
5 · Previsão	Q15	AU02 p. 44–57 e 72–85, AU03	a previsão como esperança condicional e o erro que cresce
6 · Aplicação: SARIMA mensal	Q16	AU02 p. 96–99, AU03	Box-Jenkins de ponta a ponta

Como estudar um capítulo

As nove seções têm sempre a mesma ordem, e a ordem é o método:

1. **Pergunta de abertura.** Responda de cabeça, mesmo errado. É o "não sei" que faz o resto grudar.
2. **A imagem.** A metáfora do tema e, numa caixa, **onde a analogia quebra**. Os limites da imagem ensinam tanto quanto ela.
3. **Teoria.** Os resultados, com a página da aula. É o que se cita na prova.
4. **Demonstrações.** Copie no papel, linha a linha. Cada capítulo tem a sua **folha à mão**, com as questões do bloco em linhas numeradas e justificadas: cap. 1 · cap. 2 · cap. 3 · cap. 4 · cap. 5 · cap. 6. Depois refaça sem olhar.
5. **Exemplo.** Os números que dão corpo à fórmula, todos conferidos em R.
6. **Cadeia socrática.** Cubra a caixa de resposta e responda primeiro. Cada pergunta prepara a seguinte.
7. **Diálogo.** O erro mais comum do tema, encenado: o aluno erra, e o professor conduz por perguntas.
8. **Na prova.** As questões da lista, as armadilhas e um checklist de 30 segundos.
9. **No material do professor.** O roteiro de releitura dos slides, na ordem, e o livro.

Ordem sugerida até 05/11, pelo peso na prova: cap. 2, depois 1, 3, 5, 4 e 6. A cada capítulo, faça as questões correspondentes da lista comentada e, no fim, os simulados.

Notação

Tudo segue os **slides**: L, $\varepsilon_t \sim RB(0, \sigma^2)$, $\phi(L) = 1 - \phi_1 L - \cdots$, $\theta(L) = 1 + \theta_1 L + \cdots$ (sinal positivo), Ω_t e $\hat{y}_{t+k/t}$. Cada capítulo termina a teoria com a **tradução para a lista**, que usa B e o sinal de Box-Jenkins: $\theta_1 = -\theta^{\text{lista}}$. A esperança vem com parênteses, $E(\cdot)$, como no resto do repositório; os slides usam colchetes.

As justificativas entre colchetes nas demonstrações:

- [RB]: ruído branco;
- [F4]: linearidade da esperança;
-
-

As ferramentas F1–F9 (Bhaskara, série geométrica, soma de Gauss…) estão demonstradas na caixa de ferramentas.

De onde vêm as imagens e as perguntas

A didática foi calibrada pelo melhor material aberto de séries temporais: Hyndman e Athanasopoulos, Penn State, Duke, Northwestern, MIT e as discussões clássicas do Cross Validated. O registro do que inspirou cada seção está em fontes.md. **O conteúdo, a notação e as páginas citadas são sempre os do professor**: as fontes externas só ajudaram a escolher as imagens e a ordem das perguntas.

Os números estão em apostila.R (id `ap`) e são conferidos pelo build. O loop do autoestudo mede cada capítulo pela régua da apostila.

CAPÍTULO 4

1. Da lista para os slides

A lista e os slides usam convenções diferentes para o MA. **A prova sai da lista**, então cada nota começa traduzindo o enunciado e termina escrevendo o resultado também no sinal da lista.

Objeto	Slides (AU01–AU03)	Lista
Operador de defasagem	L, com $L^i y_t = y_{t-i}$ (AU02, p. 11)	B
Ruído branco	$\varepsilon_t \sim RB(0, \sigma^2)$	a_t, ε_t ou u_t
Polinômio AR	$\phi_p(L) = 1 - \phi_1 L - \cdots - \phi_p L^p$ (AU02, p. 12)	igual, com B
Polinômio MA	$\theta_q(L) = 1 + \theta_1 L + \cdots + \theta_q L^q$, **sinal positivo** (AU02, p. 13)	$\theta(B) = 1 - \theta_1 B - \cdots$, **sinal negativo** (exceto Q8)
Pesos MA(∞)	$y_t = \mu + \Psi(L)\varepsilon_t$, com $\psi_0 = 1$ (AU02, p. 16)	ψ_j
Pesos AR(∞)	$\pi(L)\tilde{y}_t = \varepsilon_t$, com $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots$ (AU02, p. 19)	igual
Passeio com drift e tendência	$Y_t = \alpha_1 + Y_{t-1} + \alpha_2 t + \varepsilon_t$ (AU01, p. 30)	$y_t = c + \delta t + y_{t-1} + u_t$
Informação até t	Ω_t	$\mathscr{F}_T$
Previsão e erro	$\hat{y}_{t+k/t} = E(y_{t+k} \mid \Omega_t)$; $e_{t+k/t} = y_{t+k} - \hat{y}_{t+k/t}$ (AU02, p. 72–75)	$y_{T+h\|T}$; $e_T(h)$
Variância	$V(\cdot)$	Var(·)

A regra de tradução do MA

Se a lista escreve $a_t - \theta a_{t-1}$, nos slides isso é $\varepsilon_t + \theta^s \varepsilon_{t-1}$ com

$$\theta^s = -\theta^{\text{lista}}.$$

Toda fórmula dos slides vira a da lista trocando $\theta \to -\theta$. Exemplo: $\rho_1 = \frac{\theta}{1+\theta^2}$ (slides, AU02, p. 47) vira $\rho_1 = \frac{-\theta}{1+\theta^2}$ (lista).

CAPÍTULO 5

2. Caixa de ferramentas

Ferramentas que aparecem em quase toda questão, demonstradas **uma vez** aqui. Nas notas, cada passo cita a ferramenta pelo id: F1, [F2]…

F1 · Bhaskara, as raízes e o módulo

Enunciado. As raízes de $az^2 + bz + c = 0$, com $a \neq 0$, são

$$z = \frac{-b \pm \sqrt{\Delta}}{2a}, \qquad \Delta = b^2 - 4ac.$$

Demonstração (completar o quadrado).

1. Divida tudo por a: $z^2 + \frac{b}{a}z + \frac{c}{a} = 0$.
2. Some e subtraia $\left(\frac{b}{2a}\right)^2$: $\left(z + \frac{b}{2a}\right)^2 - \frac{b^2}{4a^2} + \frac{c}{a} = 0$.
3. Isole o quadrado: $\left(z + \frac{b}{2a}\right)^2 = \frac{b^2-4ac}{4a^2} = \frac{\Delta}{4a^2}$.
4. Tire a raiz dos dois lados: $z + \frac{b}{2a} = \pm\frac{\sqrt{\Delta}}{2a}$, logo $z = \frac{-b\pm\sqrt{\Delta}}{2a}$.

Três casos.

- $\Delta > 0$: duas raízes reais distintas.
- $\Delta = 0$: uma raiz real dupla, $z = -b/(2a)$.
- $\Delta < 0$: duas raízes complexas conjugadas, $z = \frac{-b}{2a} \pm i\frac{\sqrt{-\Delta}}{2a}$, com $i = \sqrt{-1}$.

Módulo de um complexo. Para $z = h + vi$, $|z| = \sqrt{h^2 + v^2}$. As duas conjugadas $h \pm vi$ têm **o mesmo módulo**.

Atalho (Vieta). O produto das raízes é $z_1 z_2 = c/a$. Para conjugadas, $z_1 z_2 = |z|^2$, logo $|z| = \sqrt{c/a}$.

Para que serve. Estacionariedade (raízes de $\phi(z)$) e invertibilidade (raízes de $\theta(z)$) exigem $|z| > 1$ (AU02, p. 27 e 33). Na revisão de equações a diferenças (EQD, p. 24–26), a mesma fórmula aparece para a equação característica $b^2 + a_1 b + a_2 = 0$.

> **Raízes z ou autovalores λ? Fora ou dentro?**
>
> AU02, p. 28: as raízes de $\phi(z) = 1 - \phi_1 z - \phi_2 z^2$ devem ficar **fora** do círculo, $|z| > 1$. As raízes de $\lambda^2 - \phi_1\lambda - \phi_2 = 0$, que são os autovalores da matriz F (p. 40), devem ficar **dentro**, $|\lambda| < 1$. São a mesma condição, porque $\lambda = 1/z$. Escreva sempre qual das duas você está usando.

F2 · Série geométrica

Para $r \neq 1$, $S_n = \sum_{j=0}^{n-1} r^j = \frac{1-r^n}{1-r}$.

Demonstração.

1. $S_n = 1 + r + \cdots + r^{n-1}$.
2. $rS_n = r + r^2 + \cdots + r^n$.
3. Subtraindo, os termos do meio cancelam: $S_n - rS_n = 1 - r^n$, logo $S_n = \frac{1-r^n}{1-r}$.
4. Se $|r| < 1$, então $r^n \to 0$ e $\sum_{j\geq 0} r^j = \frac{1}{1-r}$. Se $|r| \geq 1$, a série não converge.

É o que permite escrever $(1-\phi L)^{-1} = 1+\phi L+\phi^2 L^2+\cdots$ quando $|\phi|<1$ (AU02, p. 11 e 21) e $\sum \phi^{2j} = \frac{1}{1-\phi^2}$.

F3 · Soma dos primeiros inteiros

$\sum_{s=1}^{t} s = \frac{t(t+1)}{2}$.

Demonstração (Gauss). Escreva a soma duas vezes, uma em ordem crescente e outra em decrescente, e some coluna a coluna. Cada coluna dá $t+1$, e são t colunas: $2S = t(t+1)$. Aparece na tendência do passeio com drift e tendência (Q2 e Q8). Exemplo: $\sum_{s=1}^{10} s = 55$.

F4 · Linearidade da esperança

$E(a+bX+cY) = a+bE(X)+cE(Y)$ para constantes a, b e c. Constantes saem da esperança: $E(c) = c$. Para uma soma **finita**, $E\big(\sum_{s=1}^{t} X_s\big) = \sum_{s=1}^{t} E(X_s)$: é a F4 aplicada $t-1$ vezes, com a prova por indução na folha à mão da Q2. **Não** vale $E(XY) = E(X)E(Y)$ em geral. Isso só vale quando X e Y são não correlacionados.

F5 · Variância e covariância de combinações lineares

- $V(aX+bY) = a^2V(X)+b^2V(Y)+2ab\,\mathrm{Cov}(X,Y)$.
- $\mathrm{Cov}\left(\sum_i a_iX_i, \sum_j b_jY_j\right) = \sum_i\sum_j a_ib_j\,\mathrm{Cov}(X_i,Y_j)$.

Com ruído branco, $E(\varepsilon_i\varepsilon_j) = \sigma^2$ se $i=j$ e 0 se $i\neq j$. Num produto de duas somas de choques, **só sobrevivem os termos com o mesmo índice**. A constante sai **ao quadrado** da variância.

F6 · Causalidade: o choque de hoje não conversa com o passado

Num processo estacionário escrito como $y_t = \mu + \sum_{j\geq 0}\psi_j\varepsilon_{t-j}$, o valor y_{t-k} só depende de $\varepsilon_{t-k}, \varepsilon_{t-k-1}, \ldots$ Logo:

$$E\big(\varepsilon_t(y_{t-k}-\mu)\big) = 0 \;\; (k\geq 1), \qquad E\big(\varepsilon_t(y_t-\mu)\big) = \psi_0\sigma^2 = \sigma^2, \qquad E\big(\varepsilon_{t-1}(y_t-\mu)\big) = \psi_1\sigma^2.$$

No ARMA(1,1) dos slides, $\psi_1 = \phi_1+\theta_1$. É o "momento auxiliar" da AU02, p. 83, e do meu caderno de 02/09.

F7 · Igualar coeficientes (inverter um polinômio em L)

Se $\Psi(L)\phi(L) = \theta(L)$, os coeficientes de cada potência L^j são iguais dos dois lados. Isso dá os ψ_j por recursão:

$$\psi_j = \phi_1\psi_{j-1}+\cdots+\phi_p\psi_{j-p}+\theta_j \qquad (\psi_0 = 1;\ \psi_{\text{negativo}} = 0;\ \theta_j = 0 \text{ se } j>q).$$

Os π_j saem do mesmo jeito, de $\pi(L)\theta(L) = \phi(L)$.

F8 · Multiplicar polinômios em L

Distributiva termo a termo, somando expoentes: $L^a\cdot L^b = L^{a+b}$. Exemplo:

$$(1-\phi L)(1-L) = 1-L-\phi L+\phi L^2 = 1-(1+\phi)L+\phi L^2.$$

F9 · Esperança condicional na previsão

Com a informação Ω_t (AU02, p. 54 e 72):

- o que é conhecido em t sai como está: $E(y_{t-j} \mid \Omega_t) = y_{t-j}$ e $E(\varepsilon_{t-j} \mid \Omega_t) = \varepsilon_{t-j}$ para $j \geq 0$;
- choque futuro tem esperança zero: $E(\varepsilon_{t+j} \mid \Omega_t) = 0$ para $j \geq 1$;
- y futuro vira a própria previsão: $E(y_{t+j} \mid \Omega_t) = \hat{y}_{t+j/t}$.

A **lei das expectativas iteradas** (LEI), $E\big(E(X \mid \Omega_t)\big) = E(X)$, fecha a prova do previsor ótimo (Q15).

3. O meu caderno e onde ele entra

As fotos do caderno (aulas de 13/08 a 10/09) ficam em `materiais/caderno/`, fora do git: o repositório é público. Cada nota transcreve o trecho que importa na seção "Do meu caderno". Quando o caderno tem erro, a nota mostra a correção.

Aula	Conteúdo no caderno	Questão
13/08	introdução, o que é série temporal, FAC e FACP, Spanos (1999)	Q3, Q4
19/08	momentos do passeio aleatório (média, variância, covariância)	Q1
19/08	passeio com drift e tendência; solução recursiva do AR(1); estável × instável	Q2, Q4
19/08	multiplicador dinâmico (demanda por moeda de Goldfeld)	Q4, Q6
20/08	notação em L; processo linear geral; pesos π; momentos condicionais × incondicionais	Q4, Q5
20/08	MA(1): média, variância e covariâncias condicionais e incondicionais	Q3, Q5
26/08	MA(2) e MA(q); previsão do MA; intervalo e EQM; verossimilhança do MA(1)	Q3, Q13, Q15
26/08	AR(1): média, variância com a decomposição A + B + C	Q4, Q9
02/09	ARMA(1,1): momentos auxiliares, γ_0, γ_k	Q6
02/09	AR(1) e AR(2): Yule-Walker; previsão do AR(1) e erro	Q7, Q15
03/09	condição de estacionariedade do AR(2); exemplo com Bhaskara e raízes complexas	Q7
03/09	MA(1) $\longrightarrow$ AR(∞); ARMA(1,2); par $\theta = 0{,}5$ e $\theta = 2$; forma F do AR(p)	Q4, Q5, Q7
09/09	desenho da FAC e da FACP do AR(2) e do MA(2); estabilidade e quebra estrutural	Q12, Q16
10/09	previsão iterada × direta; métricas (MAPE, MAD, RMSE, MASE)	Q15

Os erros do caderno que precisam ser desaprendidos

1. **19/08, AR(1) recursivo:** $y_2 = \phi^2 + \phi\varepsilon_1 + \varepsilon_2$. Falta o y_0; o certo é $\phi^2 y_0$. Na linha seguinte aparece y_0^2 no lugar de y_0. A fórmula final $y_t = \phi^t y_0 + \sum \phi^{t-i}\varepsilon_i$ está certa. Ver Q4.
2. **19/08:** "$E(XY) = E(X)E(Y)$" e "$\sigma^2 = E(X^2)$" valem só com X e Y não correlacionados e com média zero, respectivamente [F4]. Ver Q1.
3. **26/08, MA(2):** a esperança condicional mistura $E(y_t \mid \Omega_{t-1})$ com $E(y_{t+2} \mid \Omega_t)$, e há θ_3 no lugar de θ_2. Ver Q15.
4. **02/09, ARMA(1,1):** $\gamma_0 = \frac{\sigma^2(\theta_1+1+2\theta_1\phi_1)}{1-\phi_1^2}$ perdeu o quadrado, porque o certo é θ_1^2. Também $\gamma_k = \phi_1^k\gamma_1$ está errado; o certo é $\phi_1^{k-1}\gamma_1$. Ver Q6.
5. **03/09, AR(2)** $y_t = 1{,}5y_{t-1} - 0{,}6y_{t-2} + a_t$**:** o polinômio virou $1 - 1{,}5B - 0{,}6B^2$, quando o certo é $1 - 1{,}5B + 0{,}6B^2$. Daí Δ saiu com o sinal trocado, e os "módulos" 0,6 e 0,52 estão errados. As duas raízes conjugadas têm o mesmo módulo, $\sqrt{0{,}6} = 0{,}7746$. Ver Q7.
6. **03/09, MA(1) $\longrightarrow$ AR(∞):** apareceu $+\theta_1^2\varepsilon_{t-2}$; o certo é $-\theta_1^2\varepsilon_{t-2}$, e os sinais alternam (AU02, p. 31). Ver Q4.

As referências "(32/83)" e "(35/83)" do caderno são da versão antiga dos slides. Na versão atual da AU02 (99 páginas), o EQM do MA(1) está na p. 57 e a verossimilhança condicional do MA(1) nas p. 58–59.

Parte III

Bloco 1 — Processos e momentos (Q1–Q4)

Capítulo 1 · Processos e momentos: o que é estável numa série

← apostila · próximo: cap. 2 · questões da lista: Q1 a Q4

Pergunta de abertura

Só existe **um** PIB brasileiro de 1996 a 2026: uma única história, que não se repete. Mesmo assim, falamos da "média" e da "variância" do crescimento, como se tivéssemos visto muitas histórias. **Com que direito se calcula a média de algo que aconteceu uma vez só?** E, se a resposta envolve "supor que o futuro se parece com o passado", **em que sentido exatamente ele se parece?**

A AU01 responde com dois conceitos, um para cada metade da pergunta (p. 23–27):

- **estacionariedade:** o futuro se parece com o passado nos momentos;
- **ergodicidade:** uma única história basta para aprender esses momentos.

O resto do capítulo é o que acontece quando eles falham, no passeio aleatório, e o que se ganha quando valem, com o Teorema de Wold.

A imagem

O processo é uma máquina de histórias; a série é uma história que saiu dela (AU01, p. 22–23). Imagine universos paralelos. Em cada um, a mesma máquina gera uma trajetória diferente do PIB. Nós moramos em um só deles e vemos uma só trajetória. $E(y_t)$ é a média **entre universos** numa data fixa, não a média ao longo do tempo.

Estacionariedade é um rio de nível estável. A água que passa muda o tempo todo: cada gota é nova, como cada choque. Mas, em qualquer trecho que você olhe:

- o nível médio é o mesmo;
- a agitação é a mesma;
- a semelhança entre dois pontos depende só da **distância** entre eles, não de onde estão.

São exatamente as três condições da AU01, p. 25: μ constante, γ_0 constante e γ_k dependendo só de k.

Ergodicidade é poder trocar o "entre universos" pelo "ao longo do tempo". Caminhar rio abaixo e anotar o nível equivale a fotografar mil rios paralelos no mesmo instante. Com ergodicidade, a média temporal da nossa única série converge para a média entre universos (AU01, p. 27).

O passeio aleatório é um barquinho sem correnteza que o traga de volta. Cada onda, que é o choque, empurra o barquinho e o deixa onde parou. Não há força que o puxe para um ponto fixo, e a "sorte" passada fica **grudada** na posição. Com drift, o rio está inclinado: o barquinho desce, em média, α_1 por período, mas continua sendo empurrado sem volta.

Wold diz que toda série estacionária é uma soma de notícias passadas. Tire de y_t tudo o que o passado de y permitia prever. O que sobra é a **notícia** de hoje, ε_t, o erro de previsão um passo à frente. Wold garante que a série inteira é uma soma ponderada das notícias de hoje e de antes, $\sum \psi_j \varepsilon_{t-j}$, mais uma parte que o passado prevê **sem erro nenhum**.

Onde a analogia quebra

- **O rio estável pode não ser ergódico.** Suponha que, ao nascer, cada rio recebeu um nível sorteado uma única vez, e depois só oscila em torno dele: $y_t = Z + \varepsilon_t$. Cada rio é perfeitamente estacionário, mas caminhar ao longo do **seu** rio ensina o seu Z, nunca a média entre rios. O exemplo deste capítulo mostra os números.
- **As "notícias" de Wold não são independentes, só não correlacionadas.** Wold é uma afirmação sobre previsão **linear**. O processo pode ter estrutura não linear, por exemplo na variância, que o ε_t de Wold não captura.
- **O barquinho sugere um objeto físico com inércia**, mas o passeio não "acelera": a variância cresce linearmente, $t\sigma^2$, e o desvio padrão só com $\sqrt{t}$.

Teoria

O que se procura numa série (AU01, p. 8): dinâmica, tendência, sazonalidade e ciclos, não linearidade e variância que muda. Esta lista trata de modelos **univariados**, em que só o passado da própria série explica o presente, e não dos multivariados, que trazem outras variáveis (AU01, p. 17–18).

Processo estocástico (AU01, p. 21–23): uma coleção $\{y_t\}$ de variáveis aleatórias indexadas pelo tempo. A série observada é **uma** realização dele.

Estacionariedade de 2ª ordem, ou fraca (AU01, p. 25). Para todo t:

$$E(y_t) = \mu, \qquad \mathrm{Var}(y_t) = \gamma_0 < \infty, \qquad E\big((y_t - \mu)(y_{t-k} - \mu)\big) = \gamma_k \text{ (só depende de } k).$$

Estacionariedade estrita (AU01, p. 26): a distribuição conjunta de $(y_{t_1}, \ldots, y_{t_k})$ não muda com um deslocamento h das datas.

- Estrita com variância finita implica fraca.
- A volta só vale sob normalidade.

Ergodicidade (AU01, p. 27): $\bar{y} = \frac{1}{T}\sum y_t \to \mu$ (na média) e a autocovariância amostral converge para γ_k (no 2º momento).

Ruído branco (AU01, p. 31): $E(\varepsilon_t) = 0$, $\mathrm{Var}(\varepsilon_t) = \sigma^2$, $E(\varepsilon_t \varepsilon_{t-k}) = 0$ para $k \neq 0$.

Passeio aleatório e variações (AU01, p. 28–30). Com valor inicial fixo y_0:

Modelo	$E(Y_t)$	$\mathrm{Var}(Y_t)$	$\mathrm{Cov}(Y_t, Y_{t-k})$
$Y_t = Y_{t-1} + \varepsilon_t$	y_0	$t\sigma^2$	$(t-k)\sigma^2$
$Y_t = \alpha_1 + Y_{t-1} + \varepsilon_t$ (drift)	$y_0 + \alpha_1 t$	$t\sigma^2$	$(t-k)\sigma^2$
$Y_t = \alpha_1 + Y_{t-1} + \alpha_2 t + \varepsilon_t$	$y_0 + \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$	$t\sigma^2$	$(t-k)\sigma^2$

Os três **não são estacionários**: a variância cresce com t. Os dois últimos têm também a média dependendo de t, uma **tendência determinística**, linear ou quadrática, somada à **tendência estocástica** $\sum \varepsilon_s$.

FAC (AU01, p. 35): sob estacionariedade, $\rho_k = \gamma_k / \gamma_0$, com $\gamma_k = \gamma_{-k}$.

Combinação de processos (lista, Q3). Se x_t e w_t são estacionários e não correlacionados em todas as defasagens, então $z_t = ax_t + bw_t$ é estacionário e $\gamma_z(k) = a^2\gamma_x(k) + b^2\gamma_w(k)$.

Processo linear geral (AU02, p. 15–18):

$$y_t = \mu + \sum_{j \geq 0} \psi_j \varepsilon_{t-j}, \quad \psi_0 = 1, \quad \sum_{j \geq 0} \psi_j^2 < \infty \implies \gamma_k = \sigma^2 \sum_{j \geq 0} \psi_j \psi_{j+k}.$$

Teorema de Wold (HAMILTON, cap. 4; lista, Q4). Todo processo estacionário de 2ª ordem, com média zero, escreve-se como

$$y_t = \sum_{j\geq 0} \psi_j \varepsilon_{t-j} + \kappa_t, \qquad \psi_0 = 1, \ \sum_{j\geq 0} \psi_j^2 < \infty,$$

em que:

- $\varepsilon_t = y_t - \hat{E}(y_t \mid y_{t-1}, y_{t-2}, \dots)$ é o erro da **melhor previsão linear** um passo à frente, e por isso é ruído branco;
- κ_t é o componente **determinístico**, previsto sem erro pelo passado de y, como uma senoide de amplitude sorteada uma vez;
- κ_t não se correlaciona com nenhum ε_s.

O processo é **puramente não determinístico** quando $\kappa_t = 0$. É o caso dos ARMA estacionários, e a lista supõe isso.

Demonstrações

O formato é o da folha à mão. A Q2 (drift e tendência) está demonstrada lá por inteiro, inclusive a esperança do somatório.

D1.1 · Passeio com drift: os momentos dependem de t (Q1)

Modelo: $y_t = c + y_{t-1} + u_t$, com y_0 fixo e $u_t \sim RB(0, \sigma^2)$ (AU01, p. 29). O caso sem drift, $c = 0$ e $y_0 = 0$, é feito passo a passo na AU01, p. 45–47.

(1) $y_t - y_{t-1} = c + u_t$ [modelo]

(2) $\sum_{s=1}^{t} (y_s - y_{s-1}) = y_t - y_0$ [telescópica]

(3) $y_t = y_0 + ct + \sum_{s=1}^{t} u_s$ [(1), (2)]

(4) $E(y_t) = y_0 + ct + \sum_{s=1}^{t} E(u_s) = y_0 + ct$ [F4, soma finita; RB]

(5) $\mathrm{Var}(y_t) = E\Big(\Big(\sum_{s=1}^{t} u_s\Big)^2\Big) = \sum_{s=1}^{t} E(u_s^2) = t\sigma^2$ [RB: só $i = j$]

(6) $\mathrm{Cov}(y_t, y_{t-k}) = E\Big(\sum_{i=1}^{t} u_i \sum_{j=1}^{t-k} u_j\Big) = \sum_{j=1}^{t-k} E(u_j^2) = (t-k)\sigma^2$ [RB]

(7) $\mathrm{Corr}(y_t, y_{t-k}) = \dfrac{(t-k)\sigma^2}{\sqrt{t\sigma^2 (t-k)\sigma^2}} = \sqrt{\dfrac{t-k}{t}}$ [(5), (6)]

$$\boxed{E(y_t) = y_0 + ct, \qquad \mathrm{Var}(y_t) = t\sigma^2, \qquad \mathrm{Cov}(y_t, y_{t-k}) = (t-k)\sigma^2 \implies \text{não estacionário}}$$

Em (7), para k fixo e t grande, a correlação vai a 1: **a FAC de um passeio decai devagar, quase linearmente**. É a assinatura visual da raiz unitária, retomada no cap. 3.

D1.2 · Soma de processos não correlacionados (Q3)

$z_t = x_t + b\,w_t$, com x e w estacionários, médias μ_x e μ_w, e $\mathrm{Cov}(x_t, w_s) = 0$ para todos t, s.

(1)	$E(z_t) = \mu_x + b\,\mu_w$	[F4: constante]
(2)	$z_t - E(z_t) = (x_t - \mu_x) + b\,(w_t - \mu_w)$	[(1)]
(3)	$\gamma_z(k) = E\Big(\big((x_t - \mu_x) + b(w_t - \mu_w)\big)\big((x_{t-k} - \mu_x) + b(w_{t-k} - \mu_w)\big)\Big)$	[(2)]
(4)	$\quad = \gamma_x(k) + b\,\mathrm{Cov}(x_t, w_{t-k}) + b\,\mathrm{Cov}(w_t, x_{t-k}) + b^2\gamma_w(k)$	[F4: quatro produtos]
(5)	$\quad = \gamma_x(k) + 0 + 0 + b^2\gamma_w(k)$	[não correlacionados]
(6)	com $b = 2$: $\gamma_{z_3}(k) = \gamma_{z_1}(k) + 4\,\gamma_{z_2}(k)$	[Q3]

$$\boxed{\gamma_z(k) = \gamma_x(k) + b^2\gamma_w(k) \;:\; \text{a constante sai ao quadrado; a FAC de } z \text{ corta onde corta a mais longa}}$$

Como γ_{z_1} corta depois de 1 e γ_{z_2} depois de 2, γ_{z_3} corta depois de 2. Um processo cuja FAC zera a partir de 3 é um **MA(2)**.

D1.3 · Processo linear: $\gamma_k = \sigma^2 \sum \psi_j\psi_{j+k}$

Com $y_t - \mu = \sum_{i\geq 0} \psi_i\varepsilon_{t-i}$ (AU02, p. 18):

(1)	$\gamma_k = E\Big(\sum_{i\geq 0}\psi_i\varepsilon_{t-i}\sum_{l\geq 0}\psi_l\varepsilon_{t-k-l}\Big)$	[definição]
(2)	$\quad = \sum_{i\geq 0}\sum_{l\geq 0}\psi_i\psi_l\,E(\varepsilon_{t-i}\varepsilon_{t-k-l})$	[F4; troca vale com $\sum\psi^2 < \infty$]
(3)	$E(\varepsilon_{t-i}\varepsilon_{t-k-l}) = \sigma^2$ se $i = k + l$, e 0 se não	[RB]
(4)	$\gamma_k = \sigma^2\sum_{l\geq 0}\psi_{k+l}\psi_l$	[só $i = k + l$]
(5)	$\gamma_0 = \sigma^2\sum_{l\geq 0}\psi_l^2$	[$k = 0$]
(6)	MA(2) com $\psi = (1;\ 0{,}7;\ 0{,}6)$: $\gamma_1 = \sigma^2(1\cdot 0{,}7 + 0{,}7\cdot 0{,}6) = 1{,}12\,\sigma^2$	[(4)]

$$\boxed{\gamma_k = \sigma^2\sum_{j\geq 0}\psi_j\psi_{j+k}}$$

A condição $\sum\psi_j^2 < \infty$ é exatamente o que faz (5) ser finito: é a "somabilidade" da AU02, p. 17.

D1.4 · Wold do AR(1): os ψ_j explícitos (Q4b)

$y_t = \phi y_{t-1} + \varepsilon_t$, com $|\phi| < 1$ (AU02, p. 21 e 25).

(1) $y_t = \phi(\phi y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \phi^2 y_{t-2} + \phi\varepsilon_{t-1} + \varepsilon_t$ [modelo em $t-1$]

(2) $y_t = \phi^n y_{t-n} + \sum_{j=0}^{n-1} \phi^j \varepsilon_{t-j}$ [n substituições]

(3) $E\Big(\Big(y_t - \sum_{j=0}^{n-1} \phi^j \varepsilon_{t-j}\Big)^2\Big) = \phi^{2n} E(y_{t-n}^2) = \phi^{2n}\gamma_0$ [(2), estac.]

(4) $\phi^{2n}\gamma_0 \to 0$ quando $n \to \infty$ [$|\phi| < 1$]

(5) $y_t = \sum_{j\geq 0} \phi^j \varepsilon_{t-j}$ [limite em média quadrática]

(6) $\sum_{j\geq 0} \psi_j^2 = \sum_{j\geq 0} \phi^{2j} = \dfrac{1}{1-\phi^2} < \infty$ [F2: geométrica, razão ϕ^2]

$$\boxed{\psi_j = \phi^j, \quad \psi_0 = 1, \quad \sum \psi_j^2 = \frac{1}{1-\phi^2} < \infty \ : \ \text{o AR(1) é um Wold com } \kappa_t = 0}$$

Os ε_t são mesmo as inovações de Wold: como $y_{t-1}, y_{t-2}, \ldots$ só contêm choques até $t-1$, a melhor previsão linear de y_t é ϕy_{t-1}, e o erro é ε_t. A parte determinística é nula, porque nada em y_t é previsível sem erro.

D1.5 · Estacionário, mas não ergódico

$y_t = Z + \varepsilon_t$, com $Z \sim (0, \sigma_Z^2)$ sorteado **uma vez**, independente de $\{\varepsilon_t\}$.

(1) $E(y_t) = E(Z) + E(\varepsilon_t) = 0$ [F4]

(2) $\gamma_0 = E\big((Z+\varepsilon_t)^2\big) = \sigma_Z^2 + 2E(Z\varepsilon_t) + \sigma^2 = \sigma_Z^2 + \sigma^2$ [independência]

(3) $\gamma_k = E\big((Z+\varepsilon_t)(Z+\varepsilon_{t-k})\big) = \sigma_Z^2, \quad k \geq 1$ [RB, independência]

(4) (1)–(3) não dependem de $t \implies$ estacionário [AU01, p. 25]

(5) $\bar{y} = \dfrac{1}{T}\sum_{t=1}^{T}(Z + \varepsilon_t) = Z + \dfrac{1}{T}\sum_{t=1}^{T}\varepsilon_t$ [numa trajetória]

(6) $\bar{y} \to Z \neq 0 = \mu$ [lei dos grandes números em ε]

$$\boxed{\text{estacionário, mas } \bar{y} \to Z, \text{ não } \mu \ : \ \text{não é ergódico na média}}$$

A pista está em (3): $\gamma_k = \sigma_Z^2$ **não vai a zero**. Uma condição suficiente para a ergodicidade na média é $\gamma_k \to 0$, ou, mais precisamente, $\sum|\gamma_k| < \infty$. Os ARMA estacionários a cumprem.

D1.6 · Como ler o correlograma: FAC, FACP e a banda (AU01, p. 35–49)

A FAC e a FACP são a "assinatura", ou o DNA, de um processo (AU01, p. 36 e 43): medem a memória e a dependência de y_t em relação às próprias defasagens. A ideia de identificação é comparar o correlograma dos dados, o gráfico das AU01, p. 38 e 42, com as assinaturas teóricas.

(1)	$\rho_k = \dfrac{\mathrm{Cov}(y_t, y_{t-k})}{\sqrt{\mathrm{Var}(y_t)\,\mathrm{Var}(y_{t-k})}} = \dfrac{\gamma_k}{\gamma_0}$	[AU01 p. 37; estac.]
(2)	$\lvert\rho_k\rvert \leq 1$	[Cauchy-Schwarz; AU01 p. 39]
(3)	sob RB: $\hat{\rho}_k \approx N(0, 1/T) \;\Rightarrow$ banda $\pm\, 1{,}96/\sqrt{T}$	[AU01 p. 39]
(4)	$\phi_{kk} = \mathrm{Corr}(y_t, y_{t-k} \mid y_{t-1}, \ldots, y_{t-k+1})$	[AU01 p. 40–41]
(5)	$k = 1 \;:\; \phi_{11} = \rho_1$	[regressão de y_t em y_{t-1}]
(6)	$k = 2 \;:\; \rho_1 = \phi_{21} + \phi_{22}\rho_1, \qquad \rho_2 = \phi_{21}\rho_1 + \phi_{22}$	[AU02 p. 92]
(7)	$\phi_{21} = \rho_1(1 - \phi_{22})$	[1ª equação]
(8)	$\rho_2 = \rho_1^2(1 - \phi_{22}) + \phi_{22} \;\Rightarrow\; \phi_{22}(1 - \rho_1^2) = \rho_2 - \rho_1^2$	[(7) na 2ª]
(9)	$\phi_{22} = \dfrac{\rho_2 - \rho_1^2}{1 - \rho_1^2}$	[isola]
(10)	AR(1) : $\rho_2 = \rho_1^2 \;\Rightarrow\; \phi_{22} = 0$: a FACP corta	[AU02 p. 94]
(11)	MA(1) : $\rho_2 = 0 \;\Rightarrow\; \phi_{22} = -\dfrac{\rho_1^2}{1 - \rho_1^2} \neq 0$: a FACP decai	[AU02 p. 95]
(12)	passeio: $\rho(t, k) = \sqrt{(t-k)/t} \to 1$ para k fixo	[D1.1; AU01 p. 48]

$\phi_{22} = \dfrac{\rho_2 - \rho_1^2}{1 - \rho_1^2}$; banda $\pm\, 1{,}96/\sqrt{T}$; passeio: FAC perto de 1 que cai devagar

Em (3), a derivação da banda está no aprofundamento do bloco 2. Em (4), ϕ_{kk} é o último coeficiente de um AR(k) ajustado (AU02, p. 90), e por isso (6) usa o Yule-Walker do AR(2). A FAC "carrega" os efeitos intermediários; a FACP os remove (AU01, p. 39–41). Por isso:

- o AR(p) tem FAC que decai e FACP que corta em p;
- o MA(q), o contrário.

Números:

- no MA(1) com $\theta_1 = 0{,}5$, $\rho_1 = 0{,}4$, e (11) dá $\phi_{22} = -0{,}16/0{,}84 = -0{,}1905$, igual ao `ARMAacf`;
- no AR(1) com $\phi = 0{,}7$, $\phi_{22} = 0$;
- numa simulação com $T = 200$, banda $\pm 0{,}139$, como na AU01, p. 49:
  - a FAC amostral do passeio vale 0,970, 0,876 e 0,763 nas defasagens 1, 5 e 10: decai quase em linha reta;
  - a do AR(1) com $\phi = 0{,}7$ vale 0,639, 0,290 e −0,082, contra os teóricos 0,7, 0,168 e 0,028: cai rápido e entra na banda.

Exemplo

Três experimentos numéricos, todos do R.

1. O passeio da Q1, com $y_0 = 10$, $c = 0{,}5$ e $\sigma^2 = 1$, em $t = 20$ e $k = 5$:

Momento	Fórmula (D1.1)	40 mil trajetórias simuladas
$E(y_{20})$	$10 + 0{,}5 \cdot 20 = 20$	20,01
$\mathrm{Var}(y_{20})$	$20\sigma^2 = 20$	19,98
$\mathrm{Cov}(y_{20}, y_{15})$	$15\sigma^2 = 15$	14,99
$\mathrm{Corr}(y_{20}, y_{15})$	$\sqrt{15/20} = 0{,}866$	

2. A soma da Q3. Com $\gamma_{z_1} = (0{,}5;\ 0{,}2;\ 0)$ e $\gamma_{z_2} = (2{,}30;\ -1{,}43;\ 0{,}30;\ 0)$, a D1.2 dá:

- $\gamma_0 = 0{,}5 + 4(2{,}30) = 9{,}7$;
- $\gamma_1 = 0{,}2 + 4(-1{,}43) = -5{,}52$;
- $\gamma_2 = 0 + 4(0{,}30) = 1{,}2$;
- $\gamma_3 = 0$.

Daí $\rho_1 = -0{,}5691$ e $\rho_2 = 0{,}1237$: a FAC corta depois de 2, então z_3 é **MA(2)**.

3. Wold e o processo linear.

- AR(1) com $\phi = 0{,}5$: os pesos são $\psi_1 = 0{,}5$, ..., $\psi_4 = 0{,}0625$, e $\sum \psi_j^2 = 1/(1 - 0{,}25) = 1{,}3333$. A soma de 200 termos no R dá o mesmo valor.
- MA(2) com $\psi = (1;\ 0{,}7;\ 0{,}6)$: a D1.3 dá $\gamma_1 = 1{,}12\,\sigma^2$, $\gamma_2 = 0{,}6\,\sigma^2$ e $\rho_1 = 0{,}6054$, igual ao `ARMAacf`.

4. O rio sorteado da D1.5. Três trajetórias de $y_t = Z + \varepsilon_t$, cada uma com 5 000 períodos:

Trajetória	Z sorteado	média temporal $\bar{y}$
1	2,287	2,290
2	−1,197	−1,197
3	−0,694	−0,668

Cada média temporal acerta o **seu** Z, não o $\mu = 0$ do processo. Já a média **entre** 20 mil trajetórias numa data fixa dá −0,007, perto de zero. É a diferença entre "ao longo do tempo" e "entre universos".

Cadeia socrática

P1. O ruído branco é estacionário? E é ergódico?

> **Resposta**
>
> Sim aos dois. Média 0, variância σ^2 e $\gamma_k = 0$ para $k \neq 0$: nada depende de t. E, como γ_k é zero fora da origem, a média temporal converge para 0 (AU01, p. 31).

P2. Se uma série tem média constante, ela é estacionária?

> **Resposta**
>
> Não necessariamente. O passeio sem drift tem $E(Y_t) = y_0$, constante, mas $\mathrm{Var}(Y_t) = t\sigma^2$ cresce. Estacionariedade de 2ª ordem exige as **três** condições (AU01, p. 25 e 28).

P3. Por que, no passeio, $\mathrm{Cov}(Y_t, Y_{t-k})$ depende de t, e não só de k?

Resposta

Porque a covariância conta os choques que as duas datas têm em comum, que são $t - k$. Duas datas com a mesma distância k, mas mais tarde na amostra, compartilham mais choques. No rio estável, isso não acontece: só a distância importa.

P4. Um ciclo forte e irregular, como a população de linces que sobe e desce a cada ~10 anos, é estacionário?

Resposta

Pode ser. Um ciclo **aperiódico**, sem data fixa para os picos, é compatível com momentos constantes: um AR(2) com raízes complexas faz isso (cap. 2, D2.5). Não estacionário é o que tem tendência na média ou variância que cresce, não o que oscila.

P5. O que é exatamente o ε_t do Teorema de Wold?

Resposta

O erro da melhor previsão **linear** de y_t feita com $y_{t-1}, y_{t-2}, \ldots$, a "notícia" de hoje. Por construção, ele não se correlaciona com nada do passado, inclusive com os ε anteriores, e por isso é RB.

P6. Wold diz que todo processo estacionário **é** um MA(∞). Então para que servem o AR e o ARMA?

Resposta

Para resumir com poucos parâmetros. Um MA(∞) tem infinitos ψ_j. O AR(1) os gera todos com um único número, $\psi_j = \phi^j$, e o ARMA(p, q) com $p + q$. Wold justifica a classe; o ARMA a torna estimável (AU02, p. 43).

P7. Por que a Q4(c) diz que, sem invertibilidade, não há AR(∞) convergente?

Resposta

Porque os pesos da forma AR(∞) de um MA(1) são $\pi_j = -(-\theta_1)^j$. Com $|\theta_1| \geq 1$, eles não diminuem, e a soma $\sum \pi_j y_{t-j}$ não converge (cap. 2, D2.2).

P8. Um processo pode ser estritamente estacionário e **não** fracamente estacionário?

Resposta

Sim, se a variância for infinita. Uma sequência i.i.d. de Cauchy tem a mesma distribuição em todas as datas, o que a torna estritamente estacionária, mas não tem média nem variância. A estacionariedade estrita só implica a fraca quando os momentos existem (AU01, p. 26).

Diálogo

Sobre o erro de achar que "estacionário" quer dizer "sem tendência visível".

Aluno: O passeio sem drift não tem tendência, $E(Y_t) = y_0$. Então ele é estacionário.

Professor: O que a definição da AU01, p. 25, pede?

Aluno: Média constante, variância constante e covariância dependendo só da distância.

Professor: E a variância do passeio?

Aluno: $t\sigma^2$... Cresce com o tempo. Então não é estacionário. Mas no gráfico ele não "sobe".

Professor: Simule mil trajetórias e sobreponha. O que acontece com o leque?

Aluno: Ele abre: em $t = 100$, as trajetórias estão muito mais espalhadas que em $t = 10$. Cada trajetória sozinha não sobe, mas o conjunto se espalha.

Professor: Então "tendência" não é a única forma de não estacionariedade. E a recíproca: uma série que oscila muito, em ciclos largos, é necessariamente não estacionária?

Aluno: Pelo exemplo dos linces, não. Se os ciclos não têm data marcada e a amplitude não cresce, os momentos podem ser constantes.

Professor: Qual é a regra, então?

Aluno: Não julgar pelo "formato" do gráfico. Calcular os três momentos e ver se algum depende de *t*. No passeio, quem denuncia é a variância.

Na prova

A folha de caderno do bloco está em a_mao_cap1.md: Q1 a Q4 (a Q2 em esqueleto, com a folha completa ao lado) em 52 linhas numeradas, cada uma com a justificativa, mais a versão para a prova e a conferência em R.

Questão	O que este capítulo dá	Resolução completa
Q1	momentos do passeio com drift e $y_0 = 10$; não estacionário	Q1
Q2	drift e tendência: solução, momentos, natureza da tendência	Q2 e a folha à mão
Q3	autocovariância de $z_1 + 2z_2$, estacionariedade e classe MA(2)	Q3
Q4	enunciado de Wold, componente determinístico, AR(1) e invertibilidade	Q4

Armadilhas:

- na Q1, esquecer o $y_0 = 10$ na média;
- na Q3, usar $2\gamma_{z_2}$ em vez de $4\gamma_{z_2}$: a constante sai **ao quadrado**;
- confundir "não depende de *t*" com "não depende de *k*";
- dizer que o componente determinístico de Wold é uma "tendência linear". Ele é o que o passado prevê sem erro, e uma tendência faria a média depender de *t*;
- no caderno, y_2 do AR(1) recursivo saiu sem o y_0 (ver Q4).

Checklist de 30 segundos:

1. Testei as **três** condições de estacionariedade, não só a média?
2. Usei y_0 do enunciado?
3. Cada esperança com a justificativa: [F4], [RB]?
4. Na soma de processos, constantes ao quadrado e produtos cruzados zerados **com** o motivo?
5. Fechei com a frase pedida ("logo, não é estacionário")?

No material do professor

Roteiro de releitura:

- AU01, p. 21–23: processo estocástico × série observada;
- AU01, p. 24–27: estacionariedade fraca e estrita, ergodicidade;
- AU01, p. 28–31: passeio, drift, drift e tendência, ruído branco;
- AU01, p. 32–35: AR, MA e as definições de FAC;
- AU02, p. 15–23: processo linear geral e os pesos ψ e π;

- MAT, §1: tendência determinística × estocástica, que liga com o cap. 3.

Livros:

- **HAMILTON**, cap. 3 (estacionariedade, ergodicidade, processo linear) e cap. 4.8 (Teorema de Wold);
- **ENDERS**, cap. 2: estacionariedade e FAC no nível do curso;
- **BJRL**, cap. 2: autocovariância e FAC.

Na lista comentada: Q1 · Q2 · Q3 · Q4 · ferramentas F2, F3, F4 e F5.

Cap. 1 à mão — Q1 a Q4 linha a linha

Cap. 1 à mão: Q1 a Q4, linha a linha

← capítulo 1 · ← apostila · cap. 2 à mão

Versão de **caderno** do bloco 1 da lista: cada passagem numerada, uma operação por linha e o motivo entre colchetes. A numeração é contínua do início ao fim. Os símbolos são os dos slides; a lista usa u_t ou a_t para o choque, e aqui ele é u_t ou ε_t, conforme o enunciado.

Legenda:

- [RB]: ruído branco;
- [F2]: série geométrica;
- [F3]: soma de Gauss;
- [F4]: linearidade da esperança, inclusive em soma finita;
- [F5]: covariância de combinações lineares;
- estac.: os momentos não dependem da data;
- caus.: o choque de hoje não se correlaciona com o passado;
- [(n)]: usando a linha (n).

As ferramentas estão na caixa de ferramentas.

Q1 · Passeio com drift e valor inicial 10

Enunciado (lista, Q1). $y_t = c + y_{t-1} + u_t$, com $y_0 = 10$ e u_t ruído branco. Pede-se $E(y_t)$, $\mathrm{Var}(y_t)$ e $\mathrm{Cov}(y_t, y_{t-k})$, e se o processo é estacionário. A lista escreve $RB(0, \sigma)$; leia como variância σ^2.

Nos slides: é o passeio com drift da AU01, p. 29, com $\alpha_1 = c$ e $y_0 = 10$.

(1)	$y_s - y_{s-1} = c + u_s$	[modelo]
(2)	$\sum_{s=1}^{t}(y_s - y_{s-1}) = y_t - y_0$	[telescópica]
(3)	$y_t = 10 + ct + \sum_{s=1}^{t} u_s$	[(1), (2), $y_0 = 10$]
(4)	$E(y_t) = 10 + ct + \sum_{s=1}^{t} E(u_s)$	[F4, soma finita]
(5)	$= 10 + ct$	[RB]
(6)	$y_t - E(y_t) = \sum_{s=1}^{t} u_s$	[(3) − (5)]
(7)	$\mathrm{Var}(y_t) = E\Big(\big(\sum_{i=1}^{t} u_i\big)^2\Big) = \sum_{i=1}^{t}\sum_{j=1}^{t} E(u_i u_j)$	[(6), F4]
(8)	$= \sum_{i=1}^{t} E(u_i^2) = t\sigma^2$	[RB: só $i = j$]
(9)	$\mathrm{Cov}(y_t, y_{t-k}) = E\big(\sum_{i=1}^{t} u_i \sum_{j=1}^{t-k} u_j\big)$	[(6) em t e $t-k$]
(10)	$= \sum_{j=1}^{t-k} E(u_j^2) = (t-k)\,\sigma^2$	[RB: só os pares comuns]
(11)	$\mathrm{Corr}(y_t, y_{t-k}) = \dfrac{(t-k)\sigma^2}{\sqrt{t\sigma^2\,(t-k)\sigma^2}} = \sqrt{\dfrac{t-k}{t}}$	[(8), (10)]
(12)	$\mathrm{Var}(y_t) = t\sigma^2$ depende de $t \Rightarrow$ não estacionário	[AU01 p. 25]

$$E(y_t) = 10 + ct, \qquad \mathrm{Var}(y_t) = t\sigma^2, \qquad \mathrm{Cov}(y_t, y_{t-k}) = (t-k)\sigma^2 \ : \ \text{não estacionário}$$

Mesmo com $c = 0$, quando a média fica constante em 10, a variância cresce: a conclusão não depende do drift. E a correlação (11) vai a 1 para k fixo e t grande: com $t = 100$ e $k = 10$, $\sqrt{0{,}9} = 0{,}95$. É a FAC que decai devagar, assinatura da raiz unitária.

Erro do caderno (19/08): $E(XY) = E(X)E(Y)$ **escrito sem condição**

Essa regra só vale para variáveis **não correlacionadas**, e $\sigma^2 = E(X^2)$ só vale com média zero. Em (8), o que zera os termos com $i \neq j$ é a hipótese de ruído branco, $E(u_i u_j) = 0$, e não uma regra geral da esperança.

Q2 · Drift e tendência: o esqueleto, com a demonstração completa ao lado

A Q2 está demonstrada por inteiro na folha da Q2 e da Q6, em 38 linhas, inclusive a esperança do somatório parcela por parcela. O esqueleto, nos slides, com $Y_t = \alpha_1 + Y_{t-1} + \alpha_2 t + \varepsilon_t$ e $Y_0 = 0$:

(13)	$Y_t = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum_{s=1}^{t} \varepsilon_s$	[telescópica, F3]
(14)	$E(Y_t) = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$	[F4, soma finita; RB]
(15)	$\mathrm{Var}(Y_t) = t\sigma^2, \qquad \mathrm{Cov}(Y_t, Y_{t-k}) = (t-k)\sigma^2$	[RB: só $i = j$]
(16)	comparado ao drift puro: só a média muda (reta → parábola)	[(14), (15)]
(17)	$\Delta Y_t = \alpha_1 + \alpha_2 t + \varepsilon_t$: ainda tem tendência; regredir em t	[diferença + regressão]
(18)	$\Delta^2 Y_t = \alpha_2 + (1-L)\varepsilon_t$: MA com raiz $z = 1$, não invertível	[evitar]

Q3 · Soma de dois processos não correlacionados

Enunciado (lista, Q3). São dados dois processos estacionários e não correlacionados:

- z_{1t}, com $\gamma_0 = 0{,}5$, $\gamma_1 = 0{,}2$ e zero depois;
- z_{2t}, com $\gamma_0 = 2{,}30$, $\gamma_1 = -1{,}43$, $\gamma_2 = 0{,}30$ e zero depois.

Seja $z_{3t} = z_{1t} + 2z_{2t}$. Pede-se a autocovariância de z_3, se ele é estacionário e a sua classe ARMA.

Notação para as covariâncias cruzadas: $C_{12}(k) = \mathrm{Cov}(z_{1t}, z_{2,t-k})$ e $C_{21}(k) = \mathrm{Cov}(z_{2t}, z_{1,t-k})$.

(19)	$E(z_{3t}) = E(z_{1t}) + 2E(z_{2t}) = \mu_1 + 2\mu_2$	[F4: constante]
(20)	$\gamma_3(k) = \mathrm{Cov}\left(z_{1t} + 2z_{2t},\ z_{1,t-k} + 2z_{2,t-k}\right)$	[definição]
(21)	$= \gamma_1(k) + 2C_{12}(k) + 2C_{21}(k) + 4\gamma_2(k)$	[F5]
(22)	$= \gamma_1(k) + 4\,\gamma_2(k)$	[não correlacionados]
(23)	$\gamma_3(0) = 0{,}5 + 4(2{,}30) = 0{,}5 + 9{,}2 = 9{,}7$	[(22), $k = 0$]
(24)	$\gamma_3(1) = 0{,}2 + 4(-1{,}43) = 0{,}2 - 5{,}72 = -5{,}52$	[(22), $k = 1$]
(25)	$\gamma_3(2) = 0 + 4(0{,}30) = 1{,}2$	[(22), $k = 2$]
(26)	$\gamma_3(k) = 0 + 4 \cdot 0 = 0, \quad k \geq 3$	[(22)]
(27)	média const., $\gamma_3(0) < \infty$, $\gamma_3(k) = f(k) \Rightarrow$ estacionário	[AU01 p. 25]
(28)	$\rho_1 = \dfrac{-5{,}52}{9{,}7} = -0{,}5691; \qquad \rho_2 = \dfrac{1{,}2}{9{,}7} = 0{,}1237; \qquad \rho_k = 0,\ k \geq 3$	[$\div\gamma_3(0)$]
(29)	FAC corta depois de 2 $\Rightarrow$ MA(2)	[AU02 p. 51–52]
(30)	z_3 só contém choques de t a $t-2$ de cada parcela	[MA(max{1, 2})]

$$\boxed{\gamma_3(k) = \gamma_1(k) + 4\gamma_2(k) = (9{,}7;\ -5{,}52;\ 1{,}2;\ 0; \ldots) \ :\ \text{estacionário, MA(2)}}$$

Quem são z_1 e z_2? O enunciado não pede, mas a conta mostra que os números são consistentes:

(31)	$z_1 \ :\ \rho_1 = \dfrac{0{,}2}{0{,}5} = 0{,}4 = \dfrac{\theta}{1+\theta^2} \ \Rightarrow\ 0{,}4\theta^2 - \theta + 0{,}4 = 0$	[MA(1), D2.1]
(32)	$\Delta = 0{,}36;\ \theta = \frac{1 \pm 0{,}6}{0{,}8} \in \{2;\ 0{,}5\} \Rightarrow \theta = 0{,}5,\ \sigma^2 = \frac{0{,}2}{0{,}5} = 0{,}4$	[F1; invertível]
(33)	$z_2 \ :\ \sigma^2 = 1,\ \theta_2 = 0{,}3,\ \theta_1(1+\theta_2) = -1{,}43 \Rightarrow \theta_1 = -1{,}1$	[γ_1, γ_2 do MA(2)]
(34)	confere: $\gamma_0 = 1 + 1{,}21 + 0{,}09 = 2{,}30;\ \ 1 - 1{,}1z + 0{,}3z^2 = 0 \Rightarrow z \in \{2;\ 1{,}667\}$	[invertível]

Q4 · Teorema de Wold

Enunciado (lista, Q4). São três itens:

- (a) enunciar o teorema e discutir o componente determinístico;
- (b) mostrar que o AR(1) estacionário satisfaz a decomposição e identificar os ψ_j;
- (c) explicar por que a invertibilidade do MA é necessária para um AR(∞) convergente.

(a) O enunciado, para y_t estacionário de 2ª ordem com média zero (HAMILTON, cap. 4; AU02, p. 15–18):

(35) $y_t = \sum_{j\geq 0} \psi_j \varepsilon_{t-j} + \kappa_t$ [decomposição]

(36) $\psi_0 = 1, \quad \sum_{j\geq 0} \psi_j^2 < \infty$ [condições]

(37) $\varepsilon_t = y_t - \hat{E}(y_t \mid y_{t-1}, y_{t-2}, \dots)$ [erro da melhor previsão linear]

(38) $E(\varepsilon_t) = 0, \;\; E(\varepsilon_t^2) = \sigma^2, \;\; E(\varepsilon_t \varepsilon_s) = 0 \; (s \neq t)$ [$\varepsilon_t \perp$ passado]

(39) $E(\kappa_t \varepsilon_s) = 0$ para todos t, s [ortogonalidade]

(40) κ_t previsto sem erro; ex.: $\kappa_t = a\cos\lambda t + b\sin\lambda t$ [determinístico]

O componente determinístico **não** é uma tendência: uma tendência faria a média depender de t, e o processo não seria estacionário. É a parte que o passado prevê com erro zero. Nos ARMA estacionários, $\kappa_t = 0$: são **puramente não determinísticos**.

(b) AR(1): $y_t = \phi y_{t-1} + \varepsilon_t$, com $|\phi| < 1$.

> **Erro do caderno (19/08): y_2 do AR(1) recursivo sem o y_0**
>
> O caderno escreveu $y_2 = \phi^2 + \phi\varepsilon_1 + \varepsilon_2$. Pela linha (42), com $t = 2$ e $n = 2$, o certo é $y_2 = \phi^2 y_0 + \phi\varepsilon_1 + \varepsilon_2$. A fórmula final do caderno, $y_t = \phi^t y_0 + \sum \phi^{t-i}\varepsilon_i$, está certa.

(41) $y_t = \phi(\phi y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \phi^2 y_{t-2} + \phi\varepsilon_{t-1} + \varepsilon_t$ [modelo em $t-1$]

(42) $y_t = \phi^n y_{t-n} + \sum_{j=0}^{n-1} \phi^j \varepsilon_{t-j}$ [n substituições]

(43) $E\Big(\big(y_t - \sum_{j=0}^{n-1} \phi^j \varepsilon_{t-j}\big)^2\Big) = \phi^{2n}\gamma_0 \;\to\; 0$ [(42), estac., $|\phi| < 1$]

(44) $y_t = \sum_{j\geq 0} \phi^j \varepsilon_{t-j} \;\Rightarrow\; \psi_j = \phi^j, \; \psi_0 = 1$ [limite em média quadrática]

(45) $\sum_{j\geq 0} \psi_j^2 = \sum_{j\geq 0} \phi^{2j} = \frac{1}{1-\phi^2} < \infty$ [F2, razão ϕ^2]

(46) $\hat{E}(y_t \mid y_{t-1}, \dots) = \phi y_{t-1} \;\Rightarrow$ inovação $= \varepsilon_t, \;\; \kappa_t = 0$ [caus.]

$$\boxed{\text{AR(1)} = \text{Wold com } \psi_j = \phi^j, \; \sum \psi_j^2 = \frac{1}{1-\phi^2} < \infty, \; \kappa_t = 0}$$

(c) Invertibilidade e o AR(∞), no MA(1) dos slides, $y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$ (AU02, p. 30–34):

> **Erro do caderno (03/09): $+\theta_1^2\varepsilon_{t-2}$ no lugar de $-\theta_1^2\varepsilon_{t-2}$**
>
> Ao substituir $\varepsilon_{t-1} = y_{t-1} - \theta_1\varepsilon_{t-2}$, o sinal troca. Os pesos de (48) alternam: $+, -, +, \dots$

(47) $\varepsilon_t = y_t - \theta_1 \varepsilon_{t-1}$ [isola o choque]

(48) $\varepsilon_t = \sum_{j=0}^{n-1} (-\theta_1)^j y_{t-j} + (-\theta_1)^n \varepsilon_{t-n}$ [n vezes]

(49) $E\big(((-\theta_1)^n \varepsilon_{t-n})^2\big) = \theta_1^{2n}\sigma^2 \to 0 \iff |\theta_1| < 1$ [RB]

(50) $y_t = \sum_{j\geq 1} \pi_j y_{t-j} + \varepsilon_t, \qquad \pi_j = -(-\theta_1)^j$ [(48), AU02 p. 23]

(51) $\sum|\pi_j| < \infty \iff |\theta_1| < 1$; senão o AR(∞) não converge [F2; AU02 p. 32]

(52) θ_1 e $1/\theta_1$: mesma FAC; só o invertível dá a inovação (37) [AU02 p. 34]

$$\boxed{\text{AR}(\infty) \text{ convergente} \iff \text{raízes de } \theta(z) \text{ fora do círculo} \iff \varepsilon_t \text{ é função do passado de } y}$$

Em (52), com $|\theta_1| > 1$, o choque ε_t do modelo só pode ser escrito com valores **futuros** de y. Ele não é a "notícia" de Wold, que é sempre função do passado. Por isso a invertibilidade é a condição para o choque do modelo coincidir com a inovação.

Versão para a prova

Q1:

1. Some de 1 a t (telescópica): $y_t = 10 + ct + \sum u_s$.
2. $E = 10 + ct$ [F4, RB]; Var $= t\sigma^2$; Cov $= (t-k)\sigma^2$ [RB: pares comuns].
3. A variância depende de t, logo o processo não é estacionário.

Q2: linhas (13)–(18), ou a folha completa.

Q3:

1. $\gamma_3(k) = \gamma_1(k) + 4\gamma_2(k)$, porque os cruzados zeram e a constante sai **ao quadrado**.
2. Os valores: 9,7; −5,52; 1,2; 0.
3. Estacionário, e MA(2), porque a FAC corta em 2.

Q4:

1. Enuncie (35)–(40) e diga que κ_t é o previsível sem erro, não uma tendência.
2. AR(1): substituição recursiva, resto $\phi^{2n}\gamma_0 \to 0$, $\psi_j = \phi^j$.
3. MA(1): $\pi_j = -(-\theta_1)^j$, somável se e só se $|\theta_1| < 1$.

Conferência

Q1, com $c = 0{,}5$, $\sigma^2 = 1$, $t = 20$ e $k = 5$: $E = 20$, Var $= 20$, Cov $= 15$, Corr $= 0{,}866$. Em 40 mil trajetórias simuladas: 20,01; 19,98; 14,99.

Q3:

- $\gamma_3 = (9{,}7;\ -5{,}52;\ 1{,}2;\ 0)$, $\rho_1 = -0{,}5691$ e $\rho_2 = 0{,}1237$;
- simulando z_1 e z_2 com os parâmetros de (32)–(33), com 200 mil observações, as autocovariâncias de z_3 saem 9,73; −5,56; 1,23; −0,01;
- as autocovariâncias de z_1 e z_2 reconstruídas pelo R conferem com o enunciado: 0,5 e 0,2; 2,30, −1,43 e 0,30.

Q4, com $\phi = 0{,}5$:

- $\psi_4 = 0{,}0625$ e $\sum \psi_j^2 = 1{,}3333$;
- na reconstrução do MA(1), o peso de y_{t-4} é 0,0625 com $\theta_1 = 0{,}5$ e 16 com $\theta_1 = 2$.

CAPÍTULO 9

Q2 · Passeio com drift e tendência determinística

Enunciado (lista, Q2). Um passeio aleatório recebe, a cada período, um drift constante c e um termo de tendência δt, com valor inicial $y_0 = 0$ e choques ruído branco. Pede-se:

- (a) a solução explícita;
- (b) média, variância e autocovariância;
- (c) a comparação com o passeio só com drift;
- (d) a natureza da tendência e como tirar a não estacionariedade.

Nos slides (AU01, p. 30):

$$Y_t = \alpha_1 + Y_{t-1} + \alpha_2\, t + \varepsilon_t, \qquad \varepsilon_t \sim RB(0, \sigma^2), \qquad Y_0 = 0,$$

com $\alpha_1 = c$ (drift) e $\alpha_2 = \delta$ (tendência). O slide escreve o valor inicial genérico, $Y_0 = y_0$, fixo e não aleatório; a lista fixa $y_0 = 0$. No caderno (19/08), o mesmo modelo aparece como $Y_t = \alpha + Y_{t-1} + \alpha_2 t + \varepsilon_t$, com $\alpha = \alpha_1$.

(a) Solução explícita

Caminho 1 — substituição recursiva.

$$\begin{aligned}
&(1) \quad Y_1 = \alpha_1 + Y_0 + \alpha_2 \cdot 1 + \varepsilon_1 = \alpha_1 + \alpha_2 + \varepsilon_1 && [Y_0 = 0]\\
&(2) \quad Y_2 = \alpha_1 + Y_1 + 2\alpha_2 + \varepsilon_2 && [\text{modelo}]\\
&(3) \quad \quad = \alpha_1 + (\alpha_1 + \alpha_2 + \varepsilon_1) + 2\alpha_2 + \varepsilon_2 && [(1)]\\
&(4) \quad \quad = 2\alpha_1 + (1+2)\alpha_2 + \varepsilon_1 + \varepsilon_2 &&\\
&(5) \quad Y_3 = \alpha_1 + Y_2 + 3\alpha_2 + \varepsilon_3 = 3\alpha_1 + (1+2+3)\alpha_2 + \varepsilon_1 + \varepsilon_2 + \varepsilon_3 && [(4)]
\end{aligned}$$

O padrão: cada período soma um α_1, mais um múltiplo de α_2 igual à data, e um choque novo.

$$(6) \qquad Y_t = \alpha_1 t + \alpha_2(1 + 2 + \cdots + t) + \sum_{s=1}^{t} \varepsilon_s$$

Prova de (6) por indução.

- **Base,** $t = 1$**:** (6) dá $\alpha_1 + \alpha_2 \cdot 1 + \varepsilon_1$, que é a linha (1). ✓
- **Passo:** suponha (6) válida em t. Então:

$$\begin{aligned}
&(7) \quad Y_{t+1} = \alpha_1 + Y_t + \alpha_2(t+1) + \varepsilon_{t+1} && [\text{modelo}]\\
&(8) \quad \quad = \alpha_1 + \Big[\alpha_1 t + \alpha_2(1 + \cdots + t) + \sum_{s=1}^{t} \varepsilon_s\Big] + \alpha_2(t+1) + \varepsilon_{t+1} && [\text{hip. de indução}]\\
&(9) \quad \quad = \alpha_1(t+1) + \alpha_2\big(1 + \cdots + t + (t+1)\big) + \sum_{s=1}^{t+1} \varepsilon_s && [\text{agrupando}]
\end{aligned}$$

que é (6) em $t + 1$. ✓

A soma de Gauss. Seja $S = 1 + 2 + \cdots + t$. Escreva a soma de novo, de trás para frente, $S = t + (t-1) + \cdots + 1$, e some as duas linhas coluna a coluna. Cada coluna dá $t + 1$, e são t colunas: $2S = t(t+1)$, logo $S = \frac{t(t+1)}{2}$.

$$\boxed{Y_t = \alpha_1\, t + \alpha_2\, \frac{t(t+1)}{2} + \sum_{s=1}^{t} \varepsilon_s} \tag{10}$$

Caminho 2 — soma telescópica, a conferência. Do modelo, $Y_s - Y_{s-1} = \alpha_1 + \alpha_2 s + \varepsilon_s$. Somando de $s = 1$ a t:

- à esquerda, $(Y_1 - Y_0) + (Y_2 - Y_1) + \cdots + (Y_t - Y_{t-1}) = Y_t - Y_0 = Y_t$, porque os termos do meio se cancelam;
- à direita, $\alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum \varepsilon_s$.

É a mesma (10). **Com y_0 genérico**, a esquerda dá $Y_t - y_0$, e o resultado é $Y_t = y_0 + \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum_{s=1}^{t} \varepsilon_s$: tudo o que vem abaixo vale somando y_0 à média, exatamente como na AU01, p. 30. **Na lista:** $y_t = ct + \delta \frac{t(t+1)}{2} + \sum_{s=1}^{t} u_s$.

(b) Média, variância e autocovariância

Média. Antes de tirar a esperança, separe em (10) o que é número do que é aleatório:

- $a_t \equiv \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$ é um **número**: t é a data, α_1 e α_2 são parâmetros, e nada ali é sorteado;
- $S_t \equiv \sum_{s=1}^{t} \varepsilon_s = \varepsilon_1 + \varepsilon_2 + \cdots + \varepsilon_t$ é a **única parte aleatória**: uma soma de t choques.

Assim, (10) é $Y_t = a_t + S_t$. Linha a linha:

(11)	$E(Y_t) = E(a_t + S_t)$	[(10)]
(12)	$= E(a_t) + E(S_t)$	[F4: esperança da soma]
(13)	$E(a_t) = a_t$	[F4: $E(c) = c$, a_t não é aleatório]
(14)	$E(S_t) = E(\varepsilon_1 + \varepsilon_2 + \cdots + \varepsilon_t)$	[abre o $\sum$]
(15)	$= E(\varepsilon_1) + E(\varepsilon_2 + \cdots + \varepsilon_t)$	[F4: $X = \varepsilon_1$, $Y =$ resto]
(16)	$= E(\varepsilon_1) + E(\varepsilon_2) + E(\varepsilon_3 + \cdots + \varepsilon_t)$	[F4 de novo]
(17)	$= E(\varepsilon_1) + E(\varepsilon_2) + \cdots + E(\varepsilon_t) = \sum_{s=1}^{t} E(\varepsilon_s)$	[F4, $t-1$ vezes]
(18)	$= \underbrace{0 + 0 + \cdots + 0}_{t \text{ parcelas}}$	[RB: $E(\varepsilon_s) = 0\ \forall s$]
(19)	$= 0$	
(20)	$E(Y_t) = a_t + 0 = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} \equiv \mu_t$	[(12), (13), (19)]

Por que a esperança pode entrar no Σ (o passo (17)), por indução no número de parcelas n:

- **base,** $n = 1$**:** $E(\varepsilon_1) = E(\varepsilon_1)$ ✓;
- **passo:** se $E\big(\sum_{s=1}^{n} \varepsilon_s\big) = \sum_{s=1}^{n} E(\varepsilon_s)$, então

$$E\Big(\sum_{s=1}^{n+1} \varepsilon_s\Big) = E\Big(\sum_{s=1}^{n} \varepsilon_s + \varepsilon_{n+1}\Big) = E\Big(\sum_{s=1}^{n} \varepsilon_s\Big) + E(\varepsilon_{n+1}) = \sum_{s=1}^{n} E(\varepsilon_s) + E(\varepsilon_{n+1}) = \sum_{s=1}^{n+1} E(\varepsilon_s),$$

usando a F4 com duas parcelas ($X = \sum_{s=1}^{n} \varepsilon_s$ e $Y = \varepsilon_{n+1}$) e depois a hipótese de indução. ✓

Observações:

- **A soma é finita**, com t parcelas, e por isso a troca vale sempre. Numa soma **infinita**, como o MA(∞) da Q6, a troca precisa de $\sum_j |\psi_j| < \infty$.

- **Por que $E(\varepsilon_s) = 0$:** é a primeira propriedade do ruído branco, $\varepsilon_t \sim RB(0, \sigma^2)$ (AU01, p. 31). Vale para **cada** data s, e por isso todas as t parcelas de (18) são zero.
- **Exemplo com $t = 3$:** $E(\varepsilon_1 + \varepsilon_2 + \varepsilon_3) = E(\varepsilon_1) + E(\varepsilon_2) + E(\varepsilon_3) = 0 + 0 + 0 = 0$.
- **Com y_0 genérico**, como no slide: $Y_t = y_0 + a_t + S_t$, e $E(y_0) = y_0$ pela F4, porque y_0 é fixo. Então $E(Y_t) = y_0 + \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$, exatamente a AU01, p. 30.
- **Atalho para a prova**, numa linha: $E\big(\sum_{s=1}^{t} \varepsilon_s\big) = \sum_{s=1}^{t} E(\varepsilon_s) = \sum_{s=1}^{t} 0 = 0$ [F4, soma finita; RB].

Desvio em relação à média. Subtraindo (20) de (10):

$$Y_t - \mu_t = \sum_{s=1}^{t} \varepsilon_s \tag{21}$$

Variância.

$$V(Y_t) = E\big((Y_t - \mu_t)^2\big) = E\Big(\Big(\sum_{i=1}^{t} \varepsilon_i\Big)^2\Big) \quad [(21)] \tag{22}$$

$$= E\Big(\sum_{i=1}^{t}\sum_{j=1}^{t} \varepsilon_i \varepsilon_j\Big) \quad [\text{quadrado da soma}] \tag{23}$$

$$= \sum_{i=1}^{t}\sum_{j=1}^{t} E(\varepsilon_i \varepsilon_j) \quad [\text{lin.}] \tag{24}$$

$$= \sum_{i=1}^{t} E(\varepsilon_i^2) + \sum_{i \neq j} E(\varepsilon_i \varepsilon_j) \quad [\text{separa } i = j] \tag{25}$$

$$= t\sigma^2 + 0 = t\sigma^2 \quad [\text{RB}] \tag{26}$$

Autocovariância, para $0 \leq k < t$:

$$\mathrm{Cov}(Y_t, Y_{t-k}) = E\big((Y_t - \mu_t)(Y_{t-k} - \mu_{t-k})\big) \tag{27}$$

$$= E\Big(\Big(\sum_{i=1}^{t} \varepsilon_i\Big)\Big(\sum_{j=1}^{t-k} \varepsilon_j\Big)\Big) \quad [(21) \text{ em } t \text{ e } t-k] \tag{28}$$

$$= \sum_{i=1}^{t}\sum_{j=1}^{t-k} E(\varepsilon_i \varepsilon_j) \quad [\text{lin.}] \tag{29}$$

$$= \sum_{j=1}^{t-k} E(\varepsilon_j^2) \quad [\text{RB: só } i = j] \tag{30}$$

$$= (t-k)\sigma^2 \tag{31}$$

Em (30), os pares com $i = j$ só existem para $j = 1, \ldots, t-k$, porque a segunda soma para em $t-k$: são os choques que Y_t e Y_{t-k} têm em comum.

Correlação:

$$\rho(t,k) = \frac{(t-k)\sigma^2}{\sqrt{t\sigma^2 \cdot (t-k)\sigma^2}} = \sqrt{\frac{t-k}{t}} \tag{32}$$

$$\boxed{E(Y_t) = \alpha_1 t + \alpha_2 \tfrac{t(t+1)}{2}, \qquad V(Y_t) = t\sigma^2, \qquad \mathrm{Cov}(Y_t, Y_{t-k}) = (t-k)\sigma^2}$$

Conclusão: média, variância e autocovariância dependem de t. **O processo não é estacionário** (AU01, p. 25).

(c) Comparação com o passeio com drift

Repetindo (1)–(31) com $\alpha_2 = 0$, isto é, com $Y_t = \alpha_1 + Y_{t-1} + \varepsilon_t$ e $Y_0 = 0$, obtém-se $Y_t = \alpha_1 t + \sum_{s=1}^{t} \varepsilon_s$, e:

Momento	Só drift ($\alpha_2 = 0$)	Drift e tendência
$E(Y_t)$	$\alpha_1 t$ (reta)	$\alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$ (parábola)
$V(Y_t)$	$t\sigma^2$	$t\sigma^2$
$\mathrm{Cov}(Y_t, Y_{t-k})$	$(t-k)\sigma^2$	$(t-k)\sigma^2$

Só a média muda, pelo termo $\alpha_2 \frac{t(t+1)}{2}$. A parte aleatória, $\sum \varepsilon_s$, é idêntica nos dois, e por isso variância e covariância são iguais.

(d) Natureza da tendência e como removê-la

Decomposição. Por (10):

$$Y_t = \underbrace{\alpha_1 t + \alpha_2 \frac{t(t+1)}{2}}_{\text{tendência determinística}} + \underbrace{\sum_{s=1}^{t} \varepsilon_s}_{\text{tendência estocástica}} \tag{33}$$

- **Os dois processos têm tendência estocástica** (raiz unitária). Por (10), $\partial Y_{t+j}/\partial \varepsilon_t = 1$ para todo $j \geq 0$: o choque é **permanente**.
- **A tendência determinística muda:** é linear com drift e quadrática com drift e tendência (MAT, §1.3, "tendência geral").

Primeira diferença:

$$\Delta Y_t = Y_t - Y_{t-1} = \alpha_1 + \alpha_2 t + \varepsilon_t \quad \text{[modelo]} \tag{34}$$

$$E(\Delta Y_t) = \alpha_1 + \alpha_2 t \quad \text{[lin., RB]} \tag{35}$$

- **Só drift ($\alpha_2 = 0$):** $\Delta Y_t = \alpha_1 + \varepsilon_t$, que é estacionário. Uma diferença basta.
- **Drift e tendência:** por (35), ΔY_t **ainda tem tendência linear** na média. Uma diferença não basta.

Caminho recomendado. Diferenciar uma vez e **tirar a tendência linear de ΔY_t por regressão** em $(1, t)$. Por (34), o resíduo dessa regressão estima ε_t, que é ruído branco.

Caminho a evitar: diferenciar duas vezes.

$$\Delta^2 Y_t = \Delta Y_t - \Delta Y_{t-1} \quad \text{[definição]} \tag{36}$$

$$= (\alpha_1 + \alpha_2 t + \varepsilon_t) - \big(\alpha_1 + \alpha_2 (t-1) + \varepsilon_{t-1}\big) \quad \text{[(34)]} \tag{37}$$

$$= \alpha_2 + \varepsilon_t - \varepsilon_{t-1} = \alpha_2 + (1 - L)\,\varepsilon_t \tag{38}$$

A média fica constante, α_2, mas sobra um MA(1) com $\theta_1 = -1$. O polinômio $\theta(z) = 1 - z$ tem raiz $z = 1$, sobre o círculo: **não invertível** (AU02, p. 33). É a sobrediferenciação da Q9.

Conclusão (implicação prática): tendência estocástica se remove com **diferença**; tendência determinística se remove com **regressão em** *t*. Aqui, uma diferença e depois a regressão de ΔY_t em *t*. A segunda diferença também estacionariza, mas deixa um MA não invertível.

Versão para a prova (Q2)

O mínimo que precisa estar no papel:

1. Some o modelo de 1 a t (telescópica) e use $\sum s = \frac{t(t+1)}{2}$: $Y_t = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum_{s=1}^{t} \varepsilon_s$.
2. Com $a_t = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$ fixo: $E(Y_t) = E(a_t) + E\big(\sum \varepsilon_s\big) = a_t + \sum E(\varepsilon_s) = a_t + \sum 0 = a_t$ [F4, soma finita; RB].
3. $Y_t - \mu_t = \sum \varepsilon_s$, logo $V(Y_t) = E\big((\sum \varepsilon_s)^2\big) = t\sigma^2$ [RB: só $i = j$].
4. $\mathrm{Cov}(Y_t, Y_{t-k}) = E\big(\sum_{i\le t} \varepsilon_i \sum_{j\le t-k} \varepsilon_j\big) = (t-k)\sigma^2$.
5. Os momentos dependem de t: **não estacionário**.
6. Comparação: só a média muda (reta ⟶ parábola); V e Cov são iguais.
7. Tendência estocástica $\sum \varepsilon_s$ + determinística quadrática. $\Delta Y_t = \alpha_1 + \alpha_2 t + \varepsilon_t$ ainda tem tendência: regredir ΔY_t em t. $\Delta^2 Y_t = \alpha_2 + (1-L)\varepsilon_t$ não é invertível: evitar.

Conferência (Q2)

Com $\alpha_1 = 1$ e $\alpha_2 = 0{,}2$:

- a recursão dá $E(Y_1) = 1{,}2$, $E(Y_2) = 2{,}6$ e $E(Y_3) = 4{,}2$;
- a fórmula (20) dá os mesmos valores: $2 + 0{,}2 \cdot 3 = 2{,}6$ e $3 + 0{,}2 \cdot 6 = 4{,}2$;
- com 50 mil trajetórias simuladas e $\sigma^2 = 1$: $V(Y_3) \approx 2{,}99$ (fórmula: 3), $\mathrm{Cov}(Y_3, Y_1) \approx 1{,}00$ (fórmula: 1) e $\mathrm{Corr}(Y_3, Y_1) \approx 0{,}58$ (fórmula: $\sqrt{1/3} = 0{,}577$).

Q1 · Momentos do passeio aleatório com drift

← índice · resolução curta em 01_lista · próxima: Q2

O que a questão pede

Para um passeio aleatório com drift c, valor inicial $y_0 = 10$ e choques ruído branco:

- **calcular** a média, a variância e a autocovariância de ordem k;
- **dizer** se o processo é estacionário.

Da lista para os slides

Lista	Slides (AU01, p. 29)
$y_t = c + y_{t-1} + u_t$, $u_t \sim RB(0, \sigma^2)$, $y_0 = 10$	$Y_t = \alpha_1 + Y_{t-1} + \varepsilon_t$, $\varepsilon_t \sim RB(0, \sigma^2)$, $\alpha_1 = c$

Não há MA: nada muda de sinal. Abaixo, c é o drift e ε_t é o choque.

Ferramentas

- **Slides:** AU01, p. 28–29 (propriedades do passeio, com e sem drift) e p. 45–48 (as contas do passeio sem drift, que a Q1 generaliza); AU01, p. 25 (definição de estacionariedade de 2ª ordem).
- **Caixa:** [F4] linearidade da esperança; [F5] variância de soma de choques.
- **Livro:** MAT, §1.8 (média e variância do passeio com deslocamento); ENDERS, cap. 4 (passeio aleatório com drift).

Demonstração minuciosa

Passo 1 — Solução recursiva

Substitua para trás, um período de cada vez:

- $t = 1$: $y_1 = c + y_0 + \varepsilon_1$.
- $t = 2$: $y_2 = c + y_1 + \varepsilon_2 = c + (c + y_0 + \varepsilon_1) + \varepsilon_2 = y_0 + 2c + \varepsilon_1 + \varepsilon_2$.
- $t = 3$: $y_3 = c + y_2 + \varepsilon_3 = y_0 + 3c + \varepsilon_1 + \varepsilon_2 + \varepsilon_3$.

O padrão: cada período soma um c e um choque novo. Por indução, se $y_{t-1} = y_0 + c(t-1) + \sum_{i=1}^{t-1} \varepsilon_i$, então

$$y_t = c + y_{t-1} + \varepsilon_t = y_0 + c(t-1) + c + \sum_{i=1}^{t-1} \varepsilon_i + \varepsilon_t \quad \Longrightarrow \quad \boxed{y_t = y_0 + ct + \sum_{i=1}^{t} \varepsilon_i}$$

Com $y_0 = 10$: $y_t = 10 + ct + \sum_{i=1}^{t} \varepsilon_i$.

Passo 2 — Média

$$\begin{aligned} E(y_t) &= E\Big(10 + ct + \sum_{i=1}^{t} \varepsilon_i\Big) && \text{[Passo 1]} \\ &= 10 + ct + \sum_{i=1}^{t} E(\varepsilon_i) && \text{[F4]} \\ &= 10 + ct && \text{[RB]} \end{aligned}$$

Por quê: [F4] constantes saem da esperança, e a esperança da soma é a soma das esperanças; [RB] $E(\varepsilon_i) = 0$ para todo i.

$$\boxed{E(y_t) = 10 + ct = \mu_t}$$

A média depende de t sempre que $c \neq 0$: é uma **reta** (tendência determinística linear, AU01, p. 29).

Passo 3 — Variância

Primeiro o desvio em relação à média: $y_t - \mu_t = (10 + ct + \sum \varepsilon_i) - (10 + ct) = \sum_{i=1}^{t} \varepsilon_i$. Então:

$$\begin{aligned} V(y_t) &= E\big((y_t - \mu_t)^2\big) = E\Big(\Big(\sum_{i=1}^{t} \varepsilon_i\Big)^2\Big) \\ &= E\Big(\sum_{i=1}^{t}\sum_{j=1}^{t} \varepsilon_i \varepsilon_j\Big) && \text{[(i)]} \\ &= \sum_{i=1}^{t}\sum_{j=1}^{t} E(\varepsilon_i \varepsilon_j) && \text{[F4]} \\ &= \sum_{i=1}^{t} E(\varepsilon_i^2) + \sum_{i \neq j} E(\varepsilon_i \varepsilon_j) && \text{[(ii)]} \\ &= t\sigma^2 + 0 && \text{[RB]} \end{aligned}$$

Por quê:

- (i) o quadrado de uma soma é a soma dupla dos produtos, $\big(\sum_i a_i\big)^2 = \sum_i \sum_j a_i a_j$;
- (ii) separam-se os pares com $i = j$ dos pares com $i \neq j$;
- [RB] $E(\varepsilon_i^2) = \sigma^2$, e $E(\varepsilon_i \varepsilon_j) = 0$ se $i \neq j$.

$$\boxed{V(y_t) = t\sigma^2}$$

O $y_0 = 10$ é **fixo**, com variância zero, e por isso não aparece. O drift também não aparece: constante não tem variância.

Passo 4 — Autocovariância de ordem k ($0 \le k < t$)

$$\begin{aligned}
\gamma_{t,k} &= E\big((y_t - \mu_t)(y_{t-k} - \mu_{t-k})\big) \\
&= E\Big(\Big(\sum_{i=1}^{t} \varepsilon_i\Big)\Big(\sum_{j=1}^{t-k} \varepsilon_j\Big)\Big) && \text{[Passo 1]} \\
&= \sum_{i=1}^{t}\sum_{j=1}^{t-k} E(\varepsilon_i \varepsilon_j) && \text{[F5]} \\
&= \sum_{j=1}^{t-k} E(\varepsilon_j^2) && \text{[só } i = j\text{]} \\
&= (t-k)\sigma^2 && \text{[RB]}
\end{aligned}$$

Por quê "só $i = j$": pelo ruído branco, $E(\varepsilon_i \varepsilon_j) = 0$ quando $i \neq j$. Os pares com o mesmo índice só existem para $j = 1, \dots, t-k$, porque a segunda soma para em $t-k$.

$$\boxed{\operatorname{Cov}(y_t, y_{t-k}) = (t-k)\sigma^2}$$

A intuição: y_t e y_{t-k} compartilham os $t-k$ choques mais antigos. Os k choques mais novos só estão em y_t.

Passo 5 — É estacionário?

A definição (AU01, p. 25) exige três coisas constantes no tempo: média, variância e autocovariância. Aqui:

1. $E(y_t) = 10 + ct$ depende de t (se $c \neq 0$);
2. $V(y_t) = t\sigma^2$ depende de t **mesmo com** $c = 0$;
3. $\operatorname{Cov}(y_t, y_{t-k}) = (t-k)\sigma^2$ depende de t, e não só de k.

Conclusão: o processo não é estacionário, porque as três condições falham.

A correlação reforça (AU01, p. 48): $\rho(t,k) = \frac{(t-k)\sigma^2}{\sqrt{t\sigma^2 (t-k)\sigma^2}} = \sqrt{\frac{t-k}{t}} \to 1$ quando t cresce. A FAC amostral decai devagar, e é esse o primeiro sinal de raiz unitária (AU01, p. 50).

Como tornar estacionário: $\Delta y_t = y_t - y_{t-1} = c + \varepsilon_t$, com média c, variância σ^2 e covariâncias nulas. Uma diferença basta: $y_t \sim I(1)$.

Conferência por simulação

Com $c = 1$, $\sigma^2 = 1$ e 20 mil trajetórias, em $t = 30$:

- média teórica $10 + 30 = 40$; simulada 40,01;
- variância teórica 30; simulada 29,95;
- $\operatorname{Cov}(y_{30}, y_{20})$ teórica $(30 - 10) = 20$; simulada 19,99.

Do meu caderno (19/08)

O caderno faz o passeio **sem drift**, $y_t = y_{t-1} + \varepsilon_t$ com $y_0 = 0$:

- solução recursiva escrita linha a linha, $y_1 = y_0 + \varepsilon_1$, $y_2 = y_0 + \varepsilon_1 + \varepsilon_2$, até $y_t = y_0 + \sum_{i=1}^{t} \varepsilon_i$;
- $E(y_t) = y_0 = 0$;
- $V(y_t) = E\big((y_0 + \sum \varepsilon_i - y_0)^2\big)$, deixada no meio da conta;
- a covariância, $E\big((\varepsilon_1 + \cdots + \varepsilon_t)(\varepsilon_1 + \cdots + \varepsilon_{t-k})\big) = E(\varepsilon_1^2 + \cdots + \varepsilon_{t-k}^2) = (t-k)\sigma^2$: certa, e é exatamente o Passo 4.

Duas anotações do caderno que só valem com hipótese

- "$E(XY) = E(X)E(Y)$" vale **só** se X e Y forem não correlacionados [F4]. Aqui serve para $E(\varepsilon_i\varepsilon_j) = 0$ com $i \neq j$, mas não para $E(\varepsilon_i^2)$, que é σ^2 e não $E(\varepsilon_i)^2 = 0$.
- "$\sigma^2 = E(X^2)$" vale **só** com média zero: em geral $V(X) = E(X^2) - E(X)^2$, e é isso que a expansão $E(X^2) - 2E(X)\mu + \mu^2$ do caderno mostra.

Na prova, escreva a hipótese ao lado do sinal de igual.

O que o livro acrescenta

MAT (§1.8) escreve o mesmo processo como **tendência determinística mais tendência estocástica**: $Y_t = \underbrace{Y_0 + at}_{\text{determinística}} + \underbrace{\sum_{i=1}^{t} \varepsilon_i}_{\text{estocástica}}$. A média vem toda da primeira parte, e a variância, toda da segunda. É o caso particular mais simples de processo **diferença estacionária** (DS), e a ponte para a Q2 e a Q10.

Armadilhas e variações

- **Covariância com t no lugar de $t - k$.** Os choques comuns são os de y_{t-k}, o mais curto.
- **Esquecer de dizer por que não é estacionário.** "Não é estacionário" sem citar a condição que falha é a conclusão sem justificativa, o erro da Q5 da P1 de Econometria I (log).
- **Variações:** y_0 aleatório, Δy_t e a correlação $\sqrt{(t-k)/t}$ estão no banco e no Simulado 01, Q1.

CAPÍTULO 11

Q2 · Passeio com drift e tendência determinística

← índice · anterior: Q1 · próxima: Q3 · resolução curta em 01_lista · versão de caderno, linha a linha, em à mão

O que a questão pede

Para $y_t = c + \delta t + y_{t-1} + u_t$, com $y_0 = 0$:

- **(a) derivar** a solução explícita;
- **(b) calcular** média, variância e autocovariância;
- **(c) comparar** com o passeio com drift da Q1;
- **(d) discutir** a natureza da tendência e como remover a não estacionariedade.

Da lista para os slides

Lista	Slides (AU01, p. 30)
$y_t = c + \delta t + y_{t-1} + u_t$, $y_0 = 0$	$Y_t = \alpha_1 + Y_{t-1} + \alpha_2 t + \varepsilon_t$ (“RW + drift + trend”)

Tradução: $\alpha_1 = c$ e $\alpha_2 = \delta$. Uso a notação do slide.

Ferramentas

- **Slides:** AU01, p. 30 (o resultado pronto, sem a conta); MAT, §1.1–1.3 (tendência determinística e estocástica, tendência geral) e o Quadro 1 (p. 20).
- **Caixa:** [F3] soma dos inteiros; [F4]; [F5].
- **Livro:** ENDERS, cap. 4 (modelos com tendência).

Demonstração minuciosa

(a) Solução explícita

Escreva $Y_t - Y_{t-1} = \alpha_1 + \alpha_2 t + \varepsilon_t$ e some de $s = 1$ até $s = t$:

$$\sum_{s=1}^{t}(Y_s - Y_{s-1}) = \sum_{s=1}^{t}\alpha_1 + \sum_{s=1}^{t}\alpha_2 s + \sum_{s=1}^{t}\varepsilon_s.$$

1. O lado esquerdo é **telescópico**: $(Y_1 - Y_0) + (Y_2 - Y_1) + \cdots + (Y_t - Y_{t-1}) = Y_t - Y_0$, porque cada termo intermediário aparece uma vez com + e outra com −.
2. $\sum_{s=1}^{t}\alpha_1 = \alpha_1 t$, porque são t parcelas iguais.
3. $\sum_{s=1}^{t}\alpha_2 s = \alpha_2 \sum_{s=1}^{t} s = \alpha_2 \frac{t(t+1)}{2}$ [F3].
4. Com $Y_0 = 0$:

$$\boxed{Y_t = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum_{s=1}^{t}\varepsilon_s}$$

Conferência para $t = 2$: pela recursão, $Y_1 = \alpha_1 + \alpha_2 + \varepsilon_1$ e $Y_2 = \alpha_1 + 2\alpha_2 + Y_1 + \varepsilon_2 = 2\alpha_1 + 3\alpha_2 + \varepsilon_1 + \varepsilon_2$. Pela fórmula, $2\alpha_1 + \alpha_2 \cdot \frac{2 \cdot 3}{2} + \varepsilon_1 + \varepsilon_2 = 2\alpha_1 + 3\alpha_2 + \varepsilon_1 + \varepsilon_2$. Bate.

(b) Momentos

- **Média.** $E(Y_t) = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum E(\varepsilon_s) = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$ [F4, RB]. É uma **parábola** em t.
- **Desvio.** $Y_t - E(Y_t) = \sum_{s=1}^{t} \varepsilon_s$, exatamente o mesmo da Q1.
- **Variância.** Repetindo o Passo 3 da Q1: $V(Y_t) = t\sigma^2$.
- **Covariância.** Repetindo o Passo 4: $\text{Cov}(Y_t, Y_{t-k}) = (t-k)\sigma^2$.

$$\boxed{E(Y_t) = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}, \qquad V(Y_t) = t\sigma^2, \qquad \text{Cov}(Y_t, Y_{t-k}) = (t-k)\sigma^2}$$

Na lista: $E(y_t) = ct + \delta \frac{t(t+1)}{2}$.

(c) Comparação com o passeio com drift

	Drift (Q1)	Drift e tendência (Q2)
Média	linear: $y_0 + \alpha_1 t$	quadrática: $\alpha_1 t + \alpha_2 t(t+1)/2$
Variância	$t\sigma^2$	$t\sigma^2$
Autocovariância	$(t-k)\sigma^2$	$(t-k)\sigma^2$

Só a média muda. A parte aleatória, $\sum \varepsilon_s$, é a mesma nos dois, e é ela que gera a variância.

(d) A natureza da tendência e como removê-la

Os dois processos têm **duas tendências ao mesmo tempo** (MAT, §1.3, "tendência geral"):

- uma **estocástica**, $\sum \varepsilon_s$: cada choque fica para sempre no nível;
- uma **determinística**: linear na Q1, quadrática na Q2.

Como remover:

1. **Q1:** uma diferença basta, $\Delta Y_t = \alpha_1 + \varepsilon_t$, que é estacionário.
2. **Q2:** uma diferença **não basta**, porque $\Delta Y_t = \alpha_1 + \alpha_2 t + \varepsilon_t$ ainda tem tendência linear na média. Há dois caminhos:
   - **diferenciar e tirar a tendência por regressão:** regredir ΔY_t em 1 e t e trabalhar com o resíduo, que é ε_t;
   - **diferenciar duas vezes:** $\Delta^2 Y_t = \Delta(\alpha_1 + \alpha_2 t + \varepsilon_t) = \alpha_2 + \varepsilon_t - \varepsilon_{t-1}$. A média fica constante, mas sobra um MA(1) com raiz unitária, $\theta = -1$ nos slides: não invertível (ver Q9).

Implicação prática: use o primeiro caminho. A diferença extra cria um MA não invertível, e o modelo fica difícil de estimar e de prever (Q9 e Q10).

Conferência numérica

Com $\alpha_1 = 1$, $\alpha_2 = 0{,}2$ e $t = 30$: $E(Y_{30}) = 30 + 0{,}2 \cdot \frac{30 \cdot 31}{2} = 30 + 0{,}2 \cdot 465 = 123$. A simulação, com 20 mil trajetórias, dá 123,01. E $\sum_{s=1}^{10} s = 55$.

Do meu caderno (19/08)

"Random Walk: $Y_t = \alpha + Y_{t-1} + \varepsilon_t$; $Y_t = \alpha + Y_{t-1} + \alpha_2 t + \varepsilon_t$, termo de **tendência determinística**", com a palavra "sustentada" e a ligação "teste de **raiz unitária**". É o slide da AU01, p. 30, sem a conta. A demonstração do item (a) acima é a que faltou no caderno: somar a equação de 1 a t e usar a soma telescópica.

O que o livro acrescenta

MAT, Quadro 1 (p. 20), classifica os quatro casos:

- estacionário;
- raiz unitária pura;
- tendência estacionária (TS);
- diferença estacionária (DS).

A Q2 é um DS **com** tendência determinística extra. A regra geral do texto: **tendência estocástica se tira com diferença, e tendência determinística se tira com regressão em** *t*. Diferenciar uma tendência determinística, ou regredir um passeio em *t*, é o erro dos dois lados (Q10).

Armadilhas e variações

- **Escrever** $\alpha_2 t^2/2$ em vez de $\alpha_2 t(t+1)/2$: é a afirmativa 4 da Q8, que é falsa por isso. Escreva a soma de Gauss [F3] antes.
- **Dizer que a variância muda com a tendência.** Termos determinísticos não têm variância.
- **Variações:** números no banco.

CAPÍTULO 12

Q3 · FAC de $z_{3t} = z_{1t} + 2z_{2t}$

← índice · anterior: Q2 · próxima: Q4 · resolução curta em 01_lista

O que a questão pede

Dois processos estacionários e **não correlacionados entre si**:

- z_1: $\gamma_0 = 0{,}5$, $\gamma_1 = 0{,}2$ e zero depois;
- z_2: $\gamma_0 = 2{,}30$, $\gamma_1 = -1{,}43$, $\gamma_2 = 0{,}30$ e zero depois.

Pede-se:

- **(a) calcular** a autocovariância de $z_3 = z_1 + 2z_2$;
- **(b) verificar** se z_3 é estacionário;
- **(c) classificar** z_3 como ARMA(p, q) pela FAC.

Da lista para os slides

Não há operador nem MA escrito: a notação é a mesma. Uso $\gamma_k^{(1)}$, $\gamma_k^{(2)}$ e $\gamma_k^{(3)}$ para as autocovariâncias de z_1, z_2 e z_3.

Ferramentas

- **Slides:** AU01, p. 25 (estacionariedade) e p. 35 (autocovariância); AU02, p. 51–52 (FAC do MA(q): zero depois de q).
- **Caixa:** [F5] covariância de combinações lineares.
- **Livro:** HAMILTON, cap. 4 (soma de processos ARMA); ENDERS, cap. 2 (FAC de MA(q)).

Demonstração minuciosa

(a) A autocovariância de z_3

Com médias μ_1 e μ_2, a média de z_3 é $\mu_3 = \mu_1 + 2\mu_2$ [F4], e o desvio é $z_{3t} - \mu_3 = (z_{1t} - \mu_1) + 2(z_{2t} - \mu_2)$. Então:

$$
\begin{aligned}
\gamma_k^{(3)} &= \operatorname{Cov}(z_{3t}, z_{3,t-k}) \\
&= \operatorname{Cov}\left(z_{1t} + 2z_{2t},\ z_{1,t-k} + 2z_{2,t-k}\right) \\
&= \operatorname{Cov}(z_{1t}, z_{1,t-k}) + 2\operatorname{Cov}(z_{1t}, z_{2,t-k}) && \text{[F5]} \\
&\quad + 2\operatorname{Cov}(z_{2t}, z_{1,t-k}) + 4\operatorname{Cov}(z_{2t}, z_{2,t-k}) \\
&= \gamma_k^{(1)} + 0 + 0 + 4\gamma_k^{(2)} && \text{[(i)]}
\end{aligned}
$$

Por quê:

- [F5] a covariância é bilinear: distribuindo, saem quatro termos;
- (i) z_1 e z_2 são não correlacionados, então as duas covariâncias cruzadas valem zero.

$$\boxed{\gamma_k^{(3)} = \gamma_k^{(1)} + 4\gamma_k^{(2)}}$$

O fator 2 entra **ao quadrado**, porque multiplica os dois lados da covariância. Agora, defasagem por defasagem:

- $k = 0$: $\gamma_0^{(3)} = 0{,}5 + 4(2{,}30) = 0{,}5 + 9{,}2 = 9{,}70$.
- $k = 1$: $\gamma_1^{(3)} = 0{,}2 + 4(-1{,}43) = 0{,}2 - 5{,}72 = -5{,}52$.
- $k = 2$: $\gamma_2^{(3)} = 0 + 4(0{,}30) = 1{,}20$.
- $k \geq 3$: $\gamma_k^{(3)} = 0 + 0 = 0$.

As autocorrelações são $\rho_1 = -5{,}52/9{,}70 = -0{,}5691$ e $\rho_2 = 1{,}20/9{,}70 = 0{,}1237$.

(b) Estacionariedade

Pelas três condições da AU01, p. 25:

1. $E(z_{3t}) = \mu_1 + 2\mu_2$ não depende de t, porque μ_1 e μ_2 não dependem [F4, estacionariedade de z_1 e z_2];
2. $V(z_{3t}) = \gamma_0^{(3)} = 9{,}70$ é finita e constante;
3. $\gamma_k^{(3)}$ depende só de k, porque $\gamma_k^{(1)}$ e $\gamma_k^{(2)}$ dependem só de k.

$$\boxed{z_3 \text{ é estacionário de segunda ordem.}}$$

(c) Classe ARMA

A FAC de z_3 é **diferente de zero até a defasagem 2 e zero daí em diante**. Pela AU02, p. 51: num MA(q), $\gamma_k = 0$ para todo $k > q$, e só o MA tem esse **corte**. A FAC de um AR ou de um ARMA decai sem nunca zerar.

$$\boxed{z_3 \sim \text{MA}(2) = \text{ARMA}(0, 2)}$$

Faz sentido: z_1 tem FAC que corta em 1 (é um MA(1)), z_2 tem FAC que corta em 2 (é um MA(2)), e a soma não pode ter memória mais longa que a parcela mais longa.

Do meu caderno (20/08 e 26/08)

O caderno calcula a FAC do MA(1) e do MA(2) na notação dos slides, que é a ferramenta do item (c):

- MA(1), $y_t = \varepsilon_t + \theta\varepsilon_{t-1}$: $\gamma_1 = E\big((\varepsilon_t + \theta\varepsilon_{t-1})(\varepsilon_{t-1} + \theta\varepsilon_{t-2})\big)$. Dos quatro produtos, só $\theta\varepsilon_{t-1}^2$ tem os índices iguais, logo $\gamma_1 = \theta\sigma^2$ e $\gamma_k = 0$ para $k \geq 2$. **Certo.**
- MA(2): $\gamma_1 = \theta_1\sigma^2 + \theta_1\theta_2\sigma^2 = (\theta_1 + \theta_1\theta_2)\sigma^2$. **Certo** (AU02, p. 51, com $\theta_0 = 1$).
- O γ_2 ficou pela metade. Completando: $\gamma_2 = E\big((\varepsilon_t + \theta_1\varepsilon_{t-1} + \theta_2\varepsilon_{t-2})(\varepsilon_{t-2} + \theta_1\varepsilon_{t-3} + \theta_2\varepsilon_{t-4})\big)$. O único par com o mesmo índice é $\theta_2\varepsilon_{t-2} \cdot \varepsilon_{t-2}$, logo $\gamma_2 = \theta_2\sigma^2$ e $\gamma_k = 0$ para $k \geq 3$.

O que o livro acrescenta

HAMILTON (cap. 4) prova o caso geral: a soma de um MA(q_1) com um MA(q_2) não correlacionados é um MA($\max(q_1, q_2)$). Os parâmetros do MA resultante não são a soma dos parâmetros: eles se acham igualando as autocovariâncias, como no item (a).

Armadilhas e variações

- $2\gamma^{(2)}$ **em vez de** $4\gamma^{(2)}$**.** É o erro mais comum desta questão.
- **Esquecer de citar "não correlacionados"** ao zerar os termos cruzados. Sem a hipótese, faltam $2[\gamma_{12}(k) + \gamma_{21}(k)]$.
- **Variações:** $z_1 - z_2$ e $3z_1 + z_2$ no banco; $2x + w$ no Simulado 01, Q1c.

Q4 · Teorema de Wold

← índice · anterior: Q3 · próxima: Q5 · resolução curta em 01_lista

O que a questão pede

- **(a) Enunciar** o Teorema de Wold e discutir o componente determinístico.
- **(b) Mostrar** que o AR(1) estacionário satisfaz a decomposição e identificar os ψ_j.
- **(c) Explicar** por que a invertibilidade do MA é necessária para um AR(∞) convergente.

Da lista para os slides

Lista	Slides
$y_t = \sum_{j\geq 0} \psi_j \varepsilon_{t-j}$, $\psi_0 = 1$, $\sum \psi_j^2 < \infty$	processo linear geral $y_t = \mu + \Psi(L)\varepsilon_t$ (AU02, p. 15–18)
AR(1) $y_t = \phi y_{t-1} + \varepsilon_t$	$(1 - \phi L)y_t = \varepsilon_t$ (AU02, p. 21)
MA(1) para o item (c)	$y_t = (1 + \theta L)\varepsilon_t$, sinal positivo (AU02, p. 22)

Ferramentas

- **Slides:** AU02, p. 4–6 (solução recursiva e multiplicador dinâmico), p. 15–20 (processo linear, $\Psi(L)$ e $\pi(L)$), p. 21 (AR(1) $\longrightarrow \Psi$), p. 22–23 e 31–32 (MA(1) $\longrightarrow \pi$), p. 34 (identificação).
- **Caixa:** [F2] série geométrica; [F5]; [F7].
- **Livro:** HAMILTON, cap. 4 (decomposição de Wold) e cap. 2 (inverter $1 - \phi L$); ENDERS, cap. 1 (solução de equações a diferenças).

Demonstração minuciosa

(a) O enunciado

Teorema de Wold

Todo processo $\{y_t\}$ **estacionário de segunda ordem**, com média zero, pode ser escrito como

$$y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} + \kappa_t,$$

em que:

1. $\psi_0 = 1$ e $\sum_{j\geq 0} \psi_j^2 < \infty$;
2. $\varepsilon_t \sim RB(0, \sigma^2)$ é o **erro de previsão linear um passo à frente**: $\varepsilon_t = y_t - \hat{E}(y_t \mid y_{t-1}, y_{t-2}, \dots)$;
3. κ_t é **determinístico**: pode ser previsto sem erro, por uma função linear do passado remoto de y;
4. κ_t e ε_s são não correlacionados para todo t e todo s.

O componente determinístico. É a parte de y_t que não vem de choque nenhum. Exemplos:

- uma constante, $\kappa_t = \mu$, que é por isso que o slide escreve $y_t = \mu + \Psi(L)\varepsilon_t$;
- um ciclo de amplitude aleatória sorteada uma vez, $\kappa_t = A\cos(\omega t) + B\sin(\omega t)$, que é estacionário, mas, conhecidos dois valores, é previsto sem erro para sempre (ver o Simulado 02, Q1).

Um processo com $\kappa_t = 0$ é **puramente não determinístico**: é o caso dos ARMA estacionários.

Por que $\sum \psi_j^2 < \infty$. Pela AU02, p. 18, $\gamma_0 = \sigma^2 \sum \psi_j^2$. A variância só existe, finita, se a soma converge. É a estacionariedade escrita nos pesos (AU02, p. 17: "square summable").

(b) O AR(1) satisfaz Wold

Caminho 1: substituição recursiva (AU02, p. 4, e meu caderno de 19/08). Partindo de $y_t = \phi y_{t-1} + \varepsilon_t$:

- $y_t = \phi(\phi y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \phi^2 y_{t-2} + \phi\varepsilon_{t-1} + \varepsilon_t$;
- $y_t = \phi^2(\phi y_{t-3} + \varepsilon_{t-2}) + \phi\varepsilon_{t-1} + \varepsilon_t = \phi^3 y_{t-3} + \phi^2\varepsilon_{t-2} + \phi\varepsilon_{t-1} + \varepsilon_t$;
- depois de n substituições: $y_t = \phi^n y_{t-n} + \sum_{j=0}^{n-1} \phi^j \varepsilon_{t-j}$.

O resto vai a zero. O erro de truncar a soma em n termos é $\phi^n y_{t-n}$, e

$$E\Big(\Big(y_t - \sum_{j=0}^{n-1} \phi^j \varepsilon_{t-j}\Big)^2\Big) = E\big(\phi^{2n} y_{t-n}^2\big) = \phi^{2n}\gamma_0 \xrightarrow[n\to\infty]{} 0 \quad \text{se } |\phi| < 1.$$

Usei que $E(y_{t-n}^2) = \gamma_0$ é constante, por estacionariedade, e que $\phi^{2n} \to 0$. Logo, em média quadrática:

$$\boxed{y_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}, \qquad \psi_j = \phi^j}$$

Caminho 2: operador (AU02, p. 21). $(1 - \phi L)y_t = \varepsilon_t \Rightarrow y_t = (1 - \phi L)^{-1}\varepsilon_t$. Pela série geométrica com $r = \phi L$ [F2], $(1 - \phi L)^{-1} = 1 + \phi L + \phi^2 L^2 + \cdots$, que só converge se $|\phi| < 1$. Comparando com $\Psi(L) = 1 + \psi_1 L + \psi_2 L^2 + \cdots$, coeficiente a coeficiente [F7]: $\psi_j = \phi^j$.

Conferindo as condições de Wold.

1. $\psi_0 = \phi^0 = 1$. ✓
2. $\sum_{j\geq 0} \psi_j^2 = \sum_{j\geq 0} (\phi^2)^j = \frac{1}{1-\phi^2} < \infty$, porque $\phi^2 < 1$ [F2]. ✓ Com $\phi = 0{,}5$: $\sum \psi_j^2 = 1{,}3333$, e $\psi_3 = 0{,}125$.
3. ε_t é RB e é o erro de previsão um passo à frente: $y_t - E(y_t \mid y_{t-1}, \dots) = y_t - \phi y_{t-1} = \varepsilon_t$. ✓
4. $\kappa_t = 0$: o AR(1) de média zero é puramente não determinístico. ✓

Leitura econômica. $\psi_j = \phi^j = \partial y_{t+j}/\partial \varepsilon_t$ é o **multiplicador dinâmico** (AU02, p. 6): o efeito de um choque de hoje daqui a j períodos. Com $|\phi| < 1$, ele some (AU02, p. 26: com $\phi = 0{,}5$, os pesos são 1; 0,5; 0,25; 0,125...).

(c) Por que a invertibilidade é necessária

Tome o MA(1) dos slides, $y_t = (1 + \theta L)\varepsilon_t$. Para escrever um AR(∞), é preciso **recuperar ε_t a partir de $y_t, y_{t-1}, \dots$** (AU02, p. 30).

Por substituição (AU02, p. 31). De $\varepsilon_t = y_t - \theta\varepsilon_{t-1}$:

- $\varepsilon_t = y_t - \theta(y_{t-1} - \theta\varepsilon_{t-2}) = y_t - \theta y_{t-1} + \theta^2\varepsilon_{t-2}$;
- e assim por diante: $\varepsilon_t = y_t - \theta y_{t-1} + \theta^2 y_{t-2} - \theta^3 y_{t-3} + \cdots + (-\theta)^n \varepsilon_{t-n}$.

Pelo operador. $(1 + \theta L)^{-1}$ é a série geométrica com $r = -\theta L$ [F2], logo $(1 + \theta L)^{-1} = \sum_j (-\theta)^j L^j$. Comparando com $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots$, sai $\pi_j = -(-\theta)^j$ (AU02, p. 23).

A condição. O resto $(-\theta)^n \varepsilon_{t-n}$ só some se $|\theta| < 1$. Com $\theta = 0{,}5$, os pesos são 1; −0,5; 0,25; −0,125..., que convergem. Com $\theta = 2$, são 1; −2; 4; −8..., que explodem (AU02, p. 32). Em geral, as raízes de $\theta_q(z) = 1 + \theta_1 z + \cdots + \theta_q z^q$ devem ficar fora do círculo unitário (AU02, p. 33).

$$\boxed{|\theta| < 1 \iff \sum_{j\geq 1} |\pi_j| = \sum_{j\geq 1} |\theta|^j < \infty}$$

Conclusão: sem invertibilidade, a série $\sum_j \pi_j y_{t-j}$ não converge. Então ε_t não pode ser recuperado do passado observado, e **não existe representação AR(∞)**.

Segunda razão: identificação (AU02, p. 34, e meu caderno de 03/09). $\theta = 0{,}5$ com $\sigma^2 = 4$ e $\theta = 2$ com $\sigma^2 = 1$ dão a mesma FAC: $\gamma_0 = (1+\theta^2)\sigma^2 = 5$ e $\gamma_1 = \theta\sigma^2 = 2$ nos dois casos, logo $\rho_1 = 0{,}4$. Nenhuma amostra separa os dois. Exigir $|\theta| < 1$ escolhe um deles, aquele em que ε_t é o erro de previsão do Teorema de Wold.

Do meu caderno

19/08, AR(1) recursivo. O caderno escreve:

- $y_1 = \phi y_0 + \varepsilon_1$;
- $y_2 = \phi(\phi y_0 + \varepsilon_1) + \varepsilon_2 = \phi^2 + \phi\varepsilon_1 + \varepsilon_2$;
- $y_3 = \phi(\phi y_0^2 + \phi\varepsilon_1 + \varepsilon_2) + \varepsilon_3$;
- e conclui $y_t = \phi^t y_0 + \phi^{t-1}\varepsilon_1 + \cdots + \varepsilon_t$, com as notas "$|\phi| < 1$ estável, regulador da memória, esquecer os choques passados" e "$|\phi| \geq 1$ instável".

Duas correções

- $y_2 = \phi^2 \mathbf{y_0} + \phi\varepsilon_1 + \varepsilon_2$: faltou o y_0. Na linha de y_3, o certo é $\phi(\phi^2 y_0 + \phi\varepsilon_1 + \varepsilon_2)$, e não ϕy_0^2. A fórmula final está certa.
- "$|\phi| \geq 1$ instável" junta dois casos que a AU02, p. 10 e 26, separa. Com $|\phi| = 1$, o processo é um passeio aleatório: cada choque fica para sempre, mas não explode. Com $|\phi| > 1$, o processo é explosivo: choques antigos pesam mais.

19/08, multiplicador dinâmico. Em $y_t = \phi y_{t-1} + \beta X_t + u_t$, o caderno chega a $\partial y_{t+j}/\partial X_t = \phi^j \beta$, que está certo; na demanda por moeda de Goldfeld, dois períodos à frente dá $0{,}72^2 \times 0{,}19 = 0{,}098$ (AU02, p. 7). Na linha de y_{t+1}, o último termo deveria ser u_{t+1}, e não u_{t-1}.

03/09, MA(1) → AR(∞). O caderno faz $y_t = \theta_1(y_{t-1} - \theta_1\varepsilon_{t-2}) + \varepsilon_t$ e escreve $+\theta_1^2\varepsilon_{t-2}$. O certo é $y_t = \theta_1 y_{t-1} - \theta_1^2\varepsilon_{t-2} + \varepsilon_t$: o sinal alterna a cada substituição, como no item (c). E $\varepsilon_{t-1} = y_{t-1} - \theta_1\varepsilon_{t-2}$, não ε_{t+2}.

O que o livro acrescenta

HAMILTON (cap. 4) usa o Teorema de Wold para justificar toda a modelagem Box-Jenkins. Qualquer processo estacionário é um MA(∞), e o ARMA(p,q) é só uma forma **parcimoniosa** de aproximar o polinômio infinito $\Psi(L)$ pela razão $\theta(L)/\phi(L)$ (AU02, p. 43).

Armadilhas e variações

- **Enunciar Wold sem "estacionário de segunda ordem"** ou sem $\sum \psi_j^2 < \infty$: são as duas hipóteses que valem ponto.
- **Confundir as duas condições:** estacionariedade é sobre o AR e garante MA(∞); invertibilidade é sobre o MA e garante AR(∞) (AU02, p. 36).
- **Variações:** π_j do MA(1) da lista, que tem sinal de Box-Jenkins, no banco.

CAPÍTULO 14

Bloco 1 — Processos, estacionariedade e momentos

Q1 · Momentos do passeio com drift

Ideia: escrever y_t como soma dos choques e tirar os momentos termo a termo. Resolução em 01_lista, D01.1 · ENDERS cap. 4 · AU01.

Variação A. Mesmo processo, $y_t = c + y_{t-1} + u_t$, mas com y_0 **aleatório**, de variância σ_0^2 e não correlacionado com os u. **Resposta.** $\text{Var}(y_t) = \sigma_0^2 + t\sigma^2$ e $\text{Cov}(y_t, y_{t-k}) = \sigma_0^2 + (t-k)\sigma^2$. Continua não estacionário: a variância ainda cresce com t.

Variação B. Calcule os momentos de Δy_t. **Resposta.** $\Delta y_t = c + u_t$: $E = c$, $\text{Var} = \sigma^2$ e $\text{Cov} = 0$ para $k \geq 1$. Estacionário, porque uma diferença basta: $y \sim I(1)$.

Q2 · Drift e tendência determinística

Ideia: a tendência δt dentro da equação vira uma tendência **quadrática** no nível. Resolução em 01_lista · MAT · ENDERS cap. 4.

Variação A. Com $c = 1$, $\delta = 0{,}2$ e $y_0 = 0$, quanto vale $E(y_{10})$? **Resposta.** $E(y_t) = ct + \delta t(t+1)/2$, logo $E(y_{10}) = 10 + 0{,}2 \cdot 55 = 21$. **Escreva a soma $\sum_{s=1}^{t} s = t(t+1)/2$ antes do número.**

Variação B. Qual operação torna o processo estacionário? **Resposta.** $\Delta y_t = c + \delta t + u_t$ ainda tem tendência linear. Ou se tira a tendência de Δy_t por regressão, ou se diferencia de novo: $\Delta^2 y_t = \delta + u_t - u_{t-1}$, que é estacionário, mas tem MA não invertível. A primeira opção é a preferível (lista, Q2d).

Q3 · Soma de processos estacionários

Ideia: $\gamma_{az_1+bz_2}(k) = a^2\gamma_1(k) + b^2\gamma_2(k)$ quando não há correlação cruzada. A FAC que corta em q indica um MA(q). Resolução em 01_lista.

Variação A. Com as FAC da lista, calcule a de $z_1 - z_2$. **Resposta.** O sinal some ao quadrado: $\gamma_0 = 0{,}5 + 2{,}30 = 2{,}8$, $\gamma_1 = 0{,}2 - 1{,}43 = -1{,}23$, $\gamma_2 = 0{,}3$ e zero depois. É um MA(2).

Variação B. E de $3z_1 + z_2$? **Resposta.** $\gamma_0 = 9(0{,}5) + 2{,}30 = 6{,}8$, $\gamma_1 = 9(0{,}2) - 1{,}43 = 0{,}37$, $\gamma_2 = 0{,}30$. Também é um MA(2).

Variação C. E se z_1 e z_2 fossem correlacionados? **Resposta.** Entram as covariâncias cruzadas $ab[\gamma_{12}(k) + \gamma_{21}(k)]$. Sem elas, a conta não fecha: por isso o enunciado sempre diz "não correlacionados". **Cite essa hipótese na primeira linha.**

Q4 · Teorema de Wold

Ideia: todo processo estacionário é a soma de uma parte linear nos choques, com $\psi_0 = 1$ e $\sum \psi_j^2 < \infty$, e uma parte determinística. Resolução em 01_lista e D01.3 · HAMILTON cap. 4.

Variação A. Escreva o MA(1) $y_t = (1 - \theta B)a_t$ como AR(∞), com $\theta = 0{,}5$. **Resposta.** $(1-\theta B)^{-1} = \sum_j \theta^j B^j$, logo $y_t = -\sum_{j\geq 1} \theta^j y_{t-j} + a_t$, isto é, $\pi_j = -\theta^j$: $-0{,}5$; $-0{,}25$; $-0{,}125$. Com $\theta = 2$, a série diverge: sem invertibilidade, não há AR(∞).

Variação B. Por que exigir $\sum \psi_j^2 < \infty$? **Resposta.** Porque $\text{Var}(y_t) = \sigma^2 \sum \psi_j^2$ precisa ser finita. É a condição de estacionariedade fraca escrita nos pesos.

Variação C. Dê um exemplo de componente determinístico. **Resposta.** $A\cos(\omega t) + B\sin(\omega t)$, com A e B aleatórios fixados no início: é estacionário e perfeitamente previsível. Ver o Simulado 02, Q1.

D01.4 · Estacionariedade fraca, estrita e ergodicidade: três processos que separam os conceitos

O que se quer provar

Os conceitos são diferentes, e cada um pode valer sem o outro:

- (a) um processo pode ter estacionariedade fraca sem ter estacionariedade estrita;
- (b) um processo estritamente estacionário pode não ser ergódico;
- (c) o AR(1) estacionário é ergódico para a média, com $\text{Var}(\bar{y}) \approx \frac{\gamma_0}{T} \cdot \frac{1+\phi}{1-\phi}$.

Passo a passo.

1. **(a) Fraca sem estrita.** Tome y_t independentes, com $y_t \sim N(0,1)$ em t par e $y_t \sim U(-\sqrt{3}, \sqrt{3})$ em t ímpar.
   - A média é 0 e a variância é 1 nos dois casos, porque a uniforme em $(-a, a)$ tem variância $a^2/3 = 1$. Além disso, $\gamma_k = 0$ para $k \neq 0$. Os três momentos da definição fraca não dependem de t.
   - A distribuição muda com t: a curtose é 3 na normal e 1,8 na uniforme. A estacionariedade estrita falha.
   - Na simulação, as variâncias dão 0,996 e 1,001, e as curtoses, 3,03 e 1,80.
2. **(b) Estacionário sem ser ergódico.** Tome $y_t = Z + \varepsilon_t$, com $Z \sim N(0,1)$ sorteado **uma vez** por realização e independente de $\varepsilon_t \sim RB(0,1)$.
   - A distribuição conjunta não depende de t, então o processo é estritamente estacionário, com $\mu = 0$ e $\gamma_k = 1$ para todo $k \neq 0$.
   - Mas $\bar{y} = Z + \bar{\varepsilon} \to Z$, e não 0. Uma realização longa só revela o seu próprio Z.
   - O sinal é que γ_k não vai a zero. Na simulação, com 2000 realizações, o desvio-padrão de $\bar{y}$ entre realizações não cai com T: 1,02 com $T = 100$ e 1,02 com $T = 1000$.
3. **(c) O AR(1) é ergódico.** $\text{Var}(\bar{y}) = \frac{1}{T^2}\sum_{s,t}\gamma_{t-s} = \frac{\gamma_0}{T}\big(1 + 2\sum_{k=1}^{T-1}(1-\frac{k}{T})\phi^k\big) \to \frac{\gamma_0}{T} \cdot \frac{1+\phi}{1-\phi}$. Ela vai a zero com T, porque $\sum_k |\gamma_k| < \infty$.
   - Com $\phi = 0{,}8$ e $\sigma^2 = 1$, o desvio-padrão teórico de $\bar{y}$ é 0,50 com $T = 100$ e 0,158 com $T = 1000$. A simulação dá 0,493 e 0,159.
   - O fator $(1+\phi)/(1-\phi) = 9$ diz que 1000 observações de um AR(1) com $\phi = 0{,}8$ valem, para estimar a média, cerca de 111 observações independentes.

estrita (com 2º momento) ⇒ fraca; nenhuma das duas ⇒ ergódica; $\sum_k \lvert\gamma_k\rvert < \infty \Rightarrow \bar{y} \xrightarrow{p} \mu$

A condição suficiente $\gamma_k \to 0$ depressa (somabilidade) vale para todo ARMA estacionário. Por isso a ergodicidade quase nunca é discutida nas aplicações: ela vem de graça com as raízes fora do círculo (D02.1). O caso (b) é o que ela exclui, e (c) mostra o preço da persistência.

Como o professor pode torcer

- Perguntar se o ruído branco é estritamente estacionário. Só se for i.i.d.: a definição de RB fixa apenas dois momentos.
- Dar um processo gaussiano estacionário de 2ª ordem: aí fraca e estrita coincidem.

> - Perguntar por que se pode estimar a FAC com uma só série: a ergodicidade, garantida pela somabilidade das autocovariâncias.

Parte IV

Bloco 2 — AR, MA e ARMA (Q5–Q8)

Capítulo 2 · AR, MA e ARMA: memória, eco e reconstrução

← apostila · anterior: cap. 1 · próximo: cap. 3 · questões da lista: Q5 a Q8

Pergunta de abertura

O Banco Central sobe os juros hoje, e a inflação reage. **Daqui a dois anos, esse choque ainda está na inflação, ou já se dissolveu?** E a pergunta inversa: nós só vemos a série da inflação, nunca os choques. **Olhando só para a série, dá para descobrir quais choques a produziram?**

O próprio professor abre o tema com essas duas perguntas (AU02, p. 24):

- a primeira é a **estacionariedade**, uma propriedade do lado AR;
- a segunda é a **invertibilidade**, uma propriedade do lado MA.

O capítulo inteiro é a resposta a elas. Guarde as duas: toda condição técnica que aparecer abaixo, "raízes fora do círculo unitário" por exemplo, é só uma forma precisa de responder "sim" a uma delas.

A imagem

O MA é um eco numa sala. Você grita uma vez, que é o choque ε_t. A sala devolve o grito q vezes, cada vez com um volume θ_j, e depois fica em silêncio absoluto. Por isso a FAC de um MA(q) **corta** depois da defasagem q: quem está a mais de q períodos de distância não divide nenhum grito com você.

O AR é uma mola com atrito. Puxe a mola, que é o choque, e solte. A cada período, sobra uma fração ϕ_1 do desvio da posição de equilíbrio:

- com $\phi_1 = 0{,}5$, metade do desvio sobrevive a cada passo e a mola volta rápido;
- com $\phi_1 = 0{,}99$, ela quase não perde força;
- com $\phi_1 = 1$, **a mola quebrou**: o desvio nunca diminui, e você tem um passeio aleatório.

A FAC **decai** geometricamente, mas nunca chega a zero, porque o choque de hoje carrega um pouco de todos os anteriores.

O AR(2) com raízes complexas é um balanço empurrado. O balanço vai e volta, com amplitude cada vez menor. O período de ida e volta sai das raízes do polinômio, e o "atrito" é o módulo delas.

A invertibilidade é reconstruir as notas ouvindo a gravação. A gravação, y_t, mistura cada nota, ε_t, com o eco da nota anterior. Para recuperar a nota de hoje, desconte o eco, mas o eco depende da nota de ontem, que você também precisa recuperar, e assim por diante. Com $|\theta_1| < 1$, cada correção pesa menos que a anterior e o processo converge. Com $|\theta_1| > 1$, as gravações antigas pesam **mais** que as recentes, e a reconstrução explode.

O fator comum é uma fração que se simplifica. Em $\frac{6}{9}$, o 3 de cima cancela com o 3 de baixo e sobra $\frac{2}{3}$. Em $(1 - 0{,}5L)\, y_t = (1 - 0{,}5L)\, \varepsilon_t$, o mesmo fator cancela e sobra $y_t = \varepsilon_t$: o "ARMA(1,1)" era ruído branco disfarçado.

> **Onde a analogia quebra**
>
> - O eco real decai suavemente. O "eco" do MA pode ser **mais alto na segunda volta que na primeira** ($\theta_2 > \theta_1$) e para **exatamente** em q, sem cauda nenhuma.
> - A mola real com atrito nunca troca de lado a cada período. Um AR(1) com $\phi_1 < 0$ troca: o desvio muda de sinal a cada passo, e a FAC alterna $+, -, +, -$.

> - Na música, um MA não invertível ainda é um processo **legítimo e estacionário**. Ele tem exatamente a mesma FAC que o seu par invertível (AU02, p. 34). A invertibilidade não é uma lei física: é uma **escolha de representação**, a única em que os choques podem ser lidos a partir do passado observado.

Teoria

Toda a notação é a dos slides. A **tradução para a lista** está na última tabela desta seção.

Operador de defasagem (AU02, p. 11–14). $L^j y_t = y_{t-j}$. Os modelos viram polinômios em L:

$$\phi(L) = 1 - \phi_1 L - \cdots - \phi_p L^p, \qquad \theta(L) = 1 + \theta_1 L + \cdots + \theta_q L^q, \qquad \phi(L)\, y_t = c + \theta(L)\, \varepsilon_t.$$

Processo linear geral (AU02, p. 15–20). $y_t = \mu + \Psi(L)\varepsilon_t = \mu + \sum_{j\geq 0} \psi_j \varepsilon_{t-j}$, com $\psi_0 = 1$.

- Se $\sum \psi_j^2 < \infty$, as autocovariâncias existem e valem $\gamma_k = \sigma^2 \sum_{j\geq 0} \psi_j \psi_{j+k}$ (AU02, p. 18).
- A forma AR(∞) é $\pi(L)\tilde{y}_t = \varepsilon_t$, com $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots = \Psi(L)^{-1}$ (AU02, p. 19–20).

MA(q) (AU02, p. 29 e 49–52). A soma é finita, então **todo MA(q) é estacionário**, para quaisquer θ. Com $\theta_0 = 1$:

$$\gamma_k = \begin{cases} \sigma^2 \sum_{j=0}^{q-k} \theta_j \theta_{j+k}, & k = 0, 1, \ldots, q, \\ 0, & k > q, \end{cases}$$

e a FAC **trunca** depois de q. No MA(1), $|\rho_1| \leq \frac{1}{2}$ (AU02, p. 35).

Invertibilidade (AU02, p. 22–23 e 30–36). O MA é invertível quando as raízes de $\theta(z) = 1+\theta_1 z+\cdots+\theta_q z^q = 0$ estão **fora** do círculo unitário. No MA(1), isso é $|\theta_1| < 1$, e os pesos são $\pi_j = -(-\theta_1)^j$. Os parâmetros θ e $1/\theta$ geram a mesma FAC (AU02, p. 34). A invertibilidade escolhe, entre os dois, aquele em que ε_t é recuperável. No MA(q), a condição também pode ser checada pelos autovalores de uma matriz companheira com $-\theta_1, \ldots, -\theta_q$ na primeira linha, como a matriz F do AR (AU02, p. 42).

AR(p) (AU02, p. 25–28 e 37–41). O AR é estacionário quando as raízes de $\phi(z) = 1 - \phi_1 z - \cdots - \phi_p z^p = 0$ estão fora do círculo unitário, ou seja, quando $|z_i| > 1$. Há duas formas equivalentes de escrever a mesma condição (AU02, p. 28):

- as raízes $\lambda_i = 1/z_i$ de $\lambda^p - \phi_1 \lambda^{p-1} - \cdots - \phi_p = 0$ estão **dentro** do círculo, $|\lambda_i| < 1$;
- os autovalores da matriz F são menores que 1 em módulo.

No AR(2), a condição vira o **triângulo** (AU02, p. 41): $\phi_1 + \phi_2 < 1$, $\phi_2 - \phi_1 < 1$ e $|\phi_2| < 1$.

Yule-Walker e FACP (AU02, p. 68–70 e 90–95).

- A FAC do AR(p) obedece $\rho_k = \phi_1 \rho_{k-1} + \cdots + \phi_p \rho_{k-p}$ para $k \geq 1$.
- A FACP, ϕ_{kk}, é o último coeficiente de um AR(k) ajustado. Ela **corta** depois de p no AR(p) e **decai** no MA, porque um MA invertível é um AR(∞).

ARMA(p, q) (AU02, p. 43 e 81–87).

- $\Psi(L) = \theta(L)/\phi(L)$.
- Para $k \geq q + 1$, a FAC segue a recursão do AR. As q primeiras são "contaminadas" pelo MA.
- Se $\phi(L)$ e $\theta(L)$ têm uma raiz em comum, ela cancela: é o **fator comum**, e o modelo está superparametrizado.

	FAC	FACP
AR(p)	decai (geométrica ou senoidal amortecida)	**corta** depois de p
MA(q)	**corta** depois de q	decai
ARMA(p,q)	decai a partir de q	decai a partir de p

Da lista para os slides. A lista usa B e o sinal de Box-Jenkins, exceto na Q8. Se o modelo for ARMA, troque θ^{lista} por $-\theta_1$ antes de usar qualquer fórmula desta seção.

	Slides	Lista (Q5–Q7)
defasagem	L	B
MA(1)	$y_t = \varepsilon_t + \theta_1\varepsilon_{t-1}$	$\tilde{z}_t = a_t - \theta a_{t-1}$, logo $\theta_1 = -\theta$
ARMA(1,1), ψ_j	$(\phi_1 + \theta_1)\phi_1^{j-1}$	$(\phi - \theta)\phi^{j-1}$
MA(1), ρ_1	$\frac{\theta_1}{1+\theta_1^2}$	$\frac{-\theta}{1+\theta^2}$

Demonstrações

O formato é o da folha à mão: uma operação por linha e o motivo entre colchetes.

- [RB]: ruído branco;
- [F4]: linearidade da esperança;
-
- caus.: o choque de hoje não se correlaciona com o passado de y.

O ARMA(1,1) completo, com γ_0 de nove termos, já está demonstrado na folha à mão e não se repete aqui.

D2.1 · MA(1): momentos e a FAC que corta em 1

Modelo: $y_t = c + \varepsilon_t + \theta_1\varepsilon_{t-1}$ (AU02, p. 45–47).

(1)	$E(y_t) = E(c) + E(\varepsilon_t) + \theta_1 E(\varepsilon_{t-1})$	[F4]
(2)	$= c + 0 + 0 \equiv \mu$	[RB]
(3)	$y_t - \mu = \varepsilon_t + \theta_1\varepsilon_{t-1}$	[(2)]
(4)	$\gamma_0 = E\big((\varepsilon_t + \theta_1\varepsilon_{t-1})^2\big) = E(\varepsilon_t^2) + 2\theta_1 E(\varepsilon_t\varepsilon_{t-1}) + \theta_1^2 E(\varepsilon_{t-1}^2)$	[(3), F4]
(5)	$= \sigma^2 + 0 + \theta_1^2\sigma^2 = (1+\theta_1^2)\,\sigma^2$	[RB]
(6)	$\gamma_1 = E\big((\varepsilon_t + \theta_1\varepsilon_{t-1})(\varepsilon_{t-1} + \theta_1\varepsilon_{t-2})\big)$	[(3) em t e $t-1$]
(7)	$= E(\varepsilon_t\varepsilon_{t-1}) + \theta_1 E(\varepsilon_t\varepsilon_{t-2}) + \theta_1 E(\varepsilon_{t-1}^2) + \theta_1^2 E(\varepsilon_{t-1}\varepsilon_{t-2})$	[F4]
(8)	$= 0 + 0 + \theta_1\sigma^2 + 0 = \theta_1\sigma^2$	[RB]
(9)	$\gamma_k = E\big((\varepsilon_t + \theta_1\varepsilon_{t-1})(\varepsilon_{t-k} + \theta_1\varepsilon_{t-k-1})\big), \quad k \geq 2$	[(3)]
(10)	$= 0$	[RB: datas t, $t-1$ contra $t-k$, $t-k-1$]

Em (10), como $k \geq 2$, a data mais recente do segundo parêntese, $t-k$, é anterior à mais antiga do primeiro, $t-1$. Nenhum choque aparece nos dois: todos os produtos têm datas diferentes.

$$\boxed{\gamma_0 = (1+\theta_1^2)\sigma^2, \qquad \rho_1 = \frac{\theta_1}{1+\theta_1^2}, \qquad \rho_k = 0 \ (k \geq 2)}$$

Conclusão: nada depende de t, então o MA(1) é estacionário **para qualquer** θ_1. A FAC corta em 1.

D2.2 · MA(1) → AR(∞): quando os choques são recuperáveis

Em desvios, $y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$ (AU02, p. 31). Isole o choque de hoje e substitua o de ontem, repetidamente:

$$
\begin{aligned}
&(1)\quad \varepsilon_t = y_t - \theta_1 \varepsilon_{t-1} && \text{[isola } \varepsilon_t\text{]}\\
&(2)\quad \varepsilon_{t-1} = y_{t-1} - \theta_1 \varepsilon_{t-2} && \text{[(1) em } t-1\text{]}\\
&(3)\quad \varepsilon_t = y_t - \theta_1 y_{t-1} + \theta_1^2 \varepsilon_{t-2} && \text{[(2) em (1)]}\\
&(4)\quad \varepsilon_t = y_t - \theta_1 y_{t-1} + \theta_1^2 y_{t-2} - \theta_1^3 \varepsilon_{t-3} && \text{[(1) em } t-2\text{]}\\
&(5)\quad \varepsilon_t = \sum_{j=0}^{n-1} (-\theta_1)^j y_{t-j} + (-\theta_1)^n \varepsilon_{t-n} && \text{[após } n \text{ passos]}\\
&(6)\quad E\big(((-\theta_1)^n \varepsilon_{t-n})^2\big) = \theta_1^{2n}\sigma^2 \xrightarrow[n\to\infty]{} 0 \iff |\theta_1| < 1 && \text{[RB]}\\
&(7)\quad y_t = \sum_{j\geq 1} \pi_j y_{t-j} + \varepsilon_t, \qquad \pi_j = -(-\theta_1)^j && \text{[(5), (6)]}
\end{aligned}
$$

Em (7), passe a soma de (5), sem o termo $j = 0$, para o outro lado: $y_t = \varepsilon_t - \sum_{j\geq 1}(-\theta_1)^j y_{t-j}$. Os sinais alternam: $\pi_1 = \theta_1$, $\pi_2 = -\theta_1^2$, $\pi_3 = \theta_1^3$ (AU02, p. 23).

MA(1) invertível $\iff$ $\lvert\theta_1\rvert < 1$ $\iff$ a raiz de $1 + \theta_1 z = 0$, $z = -1/\theta_1$, está fora do círculo

D2.3 · θ_1 e $1/\theta_1$ têm a mesma FAC, e $|\rho_1| \leq \frac{1}{2}$

Compare o MA(1) com (θ_1, σ^2) e o MA(1) com $(1/\theta_1,\ \theta_1^2\sigma^2)$ (AU02, p. 34–35).

$$
\begin{aligned}
&(1)\quad \rho_1(1/\theta_1) = \frac{1/\theta_1}{1 + 1/\theta_1^2} && \text{[D2.1]}\\
&(2)\quad = \frac{(1/\theta_1)\cdot\theta_1^2}{(1 + 1/\theta_1^2)\cdot\theta_1^2} = \frac{\theta_1}{\theta_1^2 + 1} = \rho_1(\theta_1) && \text{[multiplica por } \theta_1^2\text{]}\\
&(3)\quad \gamma_0 \ :\ \big(1 + 1/\theta_1^2\big)\theta_1^2\sigma^2 = (\theta_1^2 + 1)\,\sigma^2 && \text{[igual ao do par]}\\
&(4)\quad \gamma_1 \ :\ (1/\theta_1)\,\theta_1^2\sigma^2 = \theta_1\sigma^2 && \text{[igual ao do par]}\\
&(5)\quad \gamma_k = 0 \text{ nos dois, para } k \geq 2 && \text{[D2.1]}\\
&(6)\quad (1 - |\theta_1|)^2 \geq 0 && \text{[quadrado]}\\
&(7)\quad 1 - 2|\theta_1| + \theta_1^2 \geq 0 \implies 1 + \theta_1^2 \geq 2|\theta_1| && \text{[expande]}\\
&(8)\quad |\rho_1| = \frac{|\theta_1|}{1 + \theta_1^2} \leq \frac{|\theta_1|}{2|\theta_1|} = \frac{1}{2} && \text{[(7)]}
\end{aligned}
$$

(θ_1, σ^2) e $(1/\theta_1, \theta_1^2\sigma^2)$ são indistinguíveis nos dados; $\qquad$ $\lvert\rho_1\rvert \leq \frac{1}{2}$, com igualdade em $\lvert\theta_1\rvert = 1$

Conclusão: nenhuma amostra, por maior que seja, separa os dois. A invertibilidade é a regra que escolhe um deles. E se a FAC amostral mostra $\hat{\rho}_1 = 0{,}8$ e depois zero, **não** é um MA(1).

D2.4 · AR(1): média, variância e FAC

Modelo: $y_t = c + \phi_1 y_{t-1} + \varepsilon_t$, com $|\phi_1| < 1$ (AU02, p. 62–64).

(1)	$E(y_t) = c + \phi_1 E(y_{t-1}) + E(\varepsilon_t)$	[F4]
(2)	$\mu = c + \phi_1 \mu \implies \mu = \dfrac{c}{1-\phi_1}$	[estac., RB]
(3)	$y_t - \mu = \phi_1 (y_{t-1} - \mu) + \varepsilon_t$	$[c = (1-\phi_1)\mu]$
(4)	$\gamma_0 = \phi_1^2 E\big((y_{t-1}-\mu)^2\big) + 2\phi_1 E\big((y_{t-1}-\mu)\varepsilon_t\big) + E(\varepsilon_t^2)$	$[(3)^2,$ F4]
(5)	$\gamma_0 = \phi_1^2 \gamma_0 + 0 + \sigma^2$	[estac., caus., RB]
(6)	$\gamma_0 = \dfrac{\sigma^2}{1-\phi_1^2}$	[isola]
(7)	$\gamma_k = \phi_1 E\big((y_{t-1}-\mu)(y_{t-k}-\mu)\big) + E\big(\varepsilon_t (y_{t-k}-\mu)\big)$	$[(3) \times (y_{t-k}-\mu)]$
(8)	$\gamma_k = \phi_1 \gamma_{k-1} + 0, \quad k \geq 1$	[caus.]

Por indução em (8): $\gamma_1 = \phi_1 \gamma_0$, $\gamma_2 = \phi_1 \gamma_1 = \phi_1^2 \gamma_0$, …

$$\boxed{\mu = \frac{c}{1-\phi_1}, \qquad \gamma_0 = \frac{\sigma^2}{1-\phi_1^2}, \qquad \rho_k = \phi_1^k}$$

Compare com o ARMA(1,1), em que $\rho_k = \phi_1^{k-1}\rho_1$: lá o expoente é $k-1$, porque a recursão só começa em $k = 2$.

D2.5 · AR(2): raízes por Bhaskara, ciclo e Yule-Walker

Modelo: $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$ (AU02, p. 27 e 68; EQD). O exemplo é o do caderno de 03/09, $\phi_1 = 1{,}5$ e $\phi_2 = -0{,}6$.

Raízes. $\phi(z) = 1 - \phi_1 z - \phi_2 z^2 = 0$. Na ordem de Bhaskara, $az^2 + bz + c = 0$ com $a = -\phi_2$, $b = -\phi_1$ e $c = 1$.

(1)	$\Delta = b^2 - 4ac = \phi_1^2 + 4\phi_2$	$[a = -\phi_2,\ b = -\phi_1,\ c = 1]$
(2)	$\Delta = (1{,}5)^2 + 4(-0{,}6) = 2{,}25 - 2{,}4 = -0{,}15 < 0$	[raízes complexas]
(3)	$z = \dfrac{-b \pm \sqrt{\Delta}}{2a} = \dfrac{1{,}5 \pm i\sqrt{0{,}15}}{1{,}2} = 1{,}25 \pm 0{,}3227\, i$	[Bhaskara]
(4)	$\lvert z\rvert^2 = 1{,}25^2 + 0{,}3227^2 = 1{,}6667 = \dfrac{c}{a} = \dfrac{1}{0{,}6}$	[produto das conjugadas]
(5)	$\lvert z\rvert = 1{,}2910 > 1 \implies$ estacionário; $\quad \lvert\lambda\rvert = \dfrac{1}{\lvert z\rvert} = \sqrt{0{,}6} = 0{,}7746$	[AU02, p. 27–28]

Confira pelo triângulo: $\phi_1 + \phi_2 = 0{,}9 < 1$; $\phi_2 - \phi_1 = -2{,}1 < 1$; $|\phi_2| = 0{,}6 < 1$. ✓

O período do ciclo. As raízes inversas resolvem $\lambda^2 - \phi_1 \lambda - \phi_2 = 0$. Escreva-as como $\lambda = r e^{\pm i\omega}$.

(6)	$\lambda_1 \lambda_2 = -\phi_2 \implies r^2 = -\phi_2, \quad r = \sqrt{-\phi_2}$	[produto das raízes]
(7)	$\lambda_1 + \lambda_2 = \phi_1 \implies 2r\cos\omega = \phi_1$	[soma das raízes]
(8)	$\cos\omega = \dfrac{\phi_1}{2\sqrt{-\phi_2}} = \dfrac{1{,}5}{2(0{,}7746)} = 0{,}9682$	[(6), (7)]
(9)	período $= \dfrac{2\pi}{\omega} = \dfrac{2\pi}{\arccos(0{,}9682)} = 24{,}87$ períodos	[uma volta $= 2\pi$]

Yule-Walker. Multiplique o modelo por y_{t-k} e tire a esperança:

$$\text{(10)}\quad \gamma_1 = \phi_1\gamma_0 + \phi_2\gamma_1 \implies \rho_1 = \phi_1 + \phi_2\rho_1 \qquad [k=1,\ \div\gamma_0]$$

$$\text{(11)}\quad \rho_1 = \frac{\phi_1}{1-\phi_2} = \frac{1{,}5}{1{,}6} = 0{,}9375 \qquad [\text{isola}]$$

$$\text{(12)}\quad \rho_2 = \phi_1\rho_1 + \phi_2 = 1{,}5(0{,}9375) - 0{,}6 = 0{,}80625 \qquad [k=2]$$

$$|z| = \sqrt{1/0{,}6} = 1{,}291 > 1, \qquad \rho_1 = \frac{\phi_1}{1-\phi_2}, \qquad \rho_2 = \phi_1\rho_1 + \phi_2, \qquad \text{ciclo de } \approx 25 \text{ períodos}$$

O erro do caderno nesta conta

No caderno, o polinômio virou $1 - 1{,}5B - 0{,}6B^2$. O sinal de ϕ_2 entra **trocado**: $-\phi_2 B^2 = -(-0{,}6)B^2 = +0{,}6B^2$. Daí o Δ saiu com sinal errado e os módulos 0,6 e 0,52 também. O módulo certo das raízes inversas é $\sqrt{0{,}6} = 0{,}7746$, igual para as duas conjugadas.

Exemplo

Quatro processos, uma tabela. Todos os números vêm do R. Os dois primeiros são os mesmos da AU02, p. 34. O AR(2) é o do caderno, e o ARMA(1,1) é o da AU02, p. 86.

Processo (slides)	O que olhar	Resultado
MA(1), $\theta_1 = 0{,}5$, $\sigma^2 = 4$	γ_0, γ_1, ρ_1	5; 2; 0,4
MA(1), $\theta_1 = 2$, $\sigma^2 = 1$	γ_0, γ_1, ρ_1	5; 2; 0,4: **idênticos**
reconstrução de ε_t	peso de y_{t-4}, $(-\theta_1)^4$	0,0625 com $\theta_1 = 0{,}5$; **16** com $\theta_1 = 2$
AR(1), $\phi_1 = 0{,}8$, $\sigma^2 = 1$	γ_0; ρ_5; meia-vida	2,7778; 0,3277; 3,11 períodos
AR(2), $\phi_1 = 1{,}5$, $\phi_2 = -0{,}6$	Δ; $\lvert z\rvert$; ρ_1; ρ_2; ciclo	−0,15; 1,2910; 0,9375; 0,8063; 24,87
ARMA(1,1), $\phi_1 = 0{,}8$, $\theta_1 = 0{,}6$	ψ_1, ψ_2, ψ_3; ρ_1	1,4; 1,12; 0,896; 0,8931

Como ler a tabela:

1. **O par MA(1).** As duas linhas têm a mesma FAC, e a diferença máxima calculada pelo `ARMAacf` é zero. Mas a terceira linha mostra a diferença que importa: com $\theta_1 = 2$, a observação de quatro períodos atrás pesa 16 vezes na reconstrução do choque de hoje. **Só o par invertível é útil.**
2. **O AR(1).** Com $\phi_1 = 0{,}8$, um choque perde metade da força em pouco mais de 3 períodos, porque $\ln 0{,}5 / \ln 0{,}8 = 3{,}11$. Depois de 5 períodos, sobra $0{,}8^5 = 0{,}33$ dele.
3. **O AR(2).** A memória é longa, com $\rho_1 = 0{,}94$, e oscila: o balanço completa uma volta a cada ~25 períodos e perde amplitude à taxa $|\lambda| = 0{,}77$ por período.
4. **O ARMA(1,1).** Os pesos começam em $\psi_1 = \phi_1 + \theta_1 = 1{,}4$, maior que 1, porque o MA soma um eco ao primeiro passo. Depois decaem à taxa 0,8 do AR.

Cadeia socrática

Tente responder antes de ler a caixa. Cada pergunta prepara a seguinte.

P1. Num MA(3), pode haver correlação entre y_t e y_{t-4}?

Resposta

Não. y_t contém os choques de t a $t-3$, e y_{t-4} contém os de $t-4$ a $t-7$. Eles não dividem nenhum choque, e o RB zera todos os produtos cruzados: $\gamma_4 = 0$. É o eco que parou.

P2. Então, se a FAC amostral mostra $\hat{\rho}_1 = 0{,}8$ e zero depois, o processo é um MA(1)?

Resposta

Não pode ser. No MA(1), $|\rho_1| \leq \frac{1}{2}$ (D2.3). Um corte em 1 com $\hat{\rho}_1 = 0{,}8$ indica outro modelo, ou um problema na amostra (AU02, p. 35).

P3. Por que o MA(q) é estacionário para quaisquer θ, mas o AR(p) precisa de condição?

Resposta

O MA(q) é uma soma **finita** de choques: a variância é $\sigma^2 \sum \theta_j^2$, sempre finita. O AR é uma soma **infinita** de choques passados, com pesos ψ_j. Ela só converge se os pesos encolhem, e é aí que entram as raízes fora do círculo (AU02, p. 29).

P4. E se, no AR(1), $\phi_1 = 1$?

Resposta

Então $\psi_j = 1^j = 1$ para todo j: todo choque antigo pesa o mesmo que o de hoje e nunca some. $\gamma_0 = \sigma^2/(1-1)$ não existe. É o passeio aleatório da Q2: **a mola quebrou** (AU02, p. 26).

P5. E com $\phi_1 = -0{,}8$, como fica a FAC?

Resposta

$\rho_k = (-0{,}8)^k$: $-0{,}8$; $0{,}64$; $-0{,}512\ldots$ O sinal alterna e o módulo decai. Um desvio para cima hoje tende a virar um desvio para baixo amanhã.

P6. Por que a FACP de um AR(2) é zero a partir da defasagem 3?

Resposta

ϕ_{33} é o último coeficiente de um AR(3) ajustado a um processo que é AR(2). Depois de controlar por y_{t-1} e y_{t-2}, a defasagem y_{t-3} não traz informação nova, e o coeficiente dela é zero (AU02, p. 93–94).

P7. Se $\theta_1 = 2$ gera um processo estacionário com a mesma FAC de $\theta_1 = 0{,}5$, por que proibir o 2?

Resposta

Por dois motivos (AU02, p. 30–34):

- **reconstrução:** com $\theta_1 = 2$, o peso de y_{t-j} na recuperação de ε_t é $(-2)^j$ e explode, então não dá para prever, porque a previsão precisa de ε_t;
- **identificação:** os dois modelos são indistinguíveis nos dados, e sem uma regra a verossimilhança teria dois máximos iguais.

P8. No ARMA(1,1), por que $\rho_k = \phi_1^{k-1}\rho_1$ e não ϕ_1^k?

Resposta

Porque a recursão $\gamma_k = \phi_1 \gamma_{k-1}$ só vale a partir de $k = 2$. Em $k = 1$, o termo $\theta_1 E(\varepsilon_{t-1} y_{t-1}) = \theta_1 \sigma^2$ ainda aparece. O MA "contamina" só o primeiro valor, e o decaimento parte de ρ_1, não de $\rho_0 = 1$.

P9. Que modelo é $(1 - 0{,}5L)\, y_t = (1 - 0{,}5L)\, \varepsilon_t$?

Resposta

Ruído branco. O fator $(1 - 0{,}5L)$ aparece dos dois lados e cancela, como o 3 em $6/9$. Pela fórmula, $\psi_1 = \phi_1 + \theta_1 = 0{,}5 + (-0{,}5) = 0$, e todos os outros pesos também são zero. Estimar um ARMA(1,1) aqui dá parâmetros instáveis: é o **fator comum**.

P10. No AR(2), o que muda quando $\Delta < 0$?

Resposta

As raízes ficam complexas, e a FAC vira uma **senoide amortecida**: o balanço. A estacionariedade ainda exige módulo fora do círculo, $|z| = \sqrt{-1/\phi_2} > 1$, o que equivale a $|\phi_2| < 1$ no caso complexo. O período do ciclo é $2\pi / \arccos\left(\phi_1 / (2\sqrt{-\phi_2})\right)$.

Diálogo

Sobre o erro que mais cai nesta parte: misturar o sinal da lista com o dos slides.

Aluno: Na Q5, o modelo é $\tilde{z}_t = a_t - 1{,}3a_{t-1} + 0{,}4a_{t-2}$. Pela fórmula dos slides, $\theta_1 = 1{,}3$, e o MA não é invertível, porque $1{,}3 > 1$.

Professor: Que fórmula você usou para concluir que não é invertível?

Aluno: $|\theta_1| < 1$. A que vale no MA(1).

Professor: E esse modelo é um MA(1)?

Aluno: Não, é MA(2)... Então eu preciso das raízes de $\theta(z)$.

Professor: Isso. E qual é o $\theta(z)$, escrito com cuidado?

Aluno: Nos slides o sinal é positivo, $\theta(z) = 1 + \theta_1 z + \theta_2 z^2$. Como a lista tem $-1{,}3$ e $+0{,}4$, fica $\theta_1 = -1{,}3$ e $\theta_2 = 0{,}4$. Então $\theta(z) = 1 - 1{,}3z + 0{,}4z^2$.

Professor: Agora as raízes.

Aluno: $\Delta = 1{,}69 - 1{,}6 = 0{,}09$, e $z = \frac{1{,}3 \pm 0{,}3}{0{,}8}$, que dá 2 e 1,25. As duas estão fora do círculo. É invertível!

Professor: Então o "1,3 maior que 1" não provava nada. Num MA(2), um coeficiente maior que 1 é compatível com a invertibilidade. O que decide são as **raízes**. Qual é a regra que você leva para a prova?

Aluno: Primeiro, traduzir o sinal: $\theta^{\text{lista}} = -\theta_1$. Segundo, montar o polinômio inteiro. Terceiro, aplicar Bhaskara e olhar o módulo das raízes. O atalho $|\theta_1| < 1$ só vale no MA(1).

Professor: E o mesmo vale para o AR(2) do seu caderno: o erro lá foi o sinal de ϕ_2, não a conta de Bhaskara.

Na prova

A folha de caderno do bloco está em a_mao_cap2.md: Q5, Q7 e Q8 em 80 linhas numeradas, cada uma com a justificativa, mais o esqueleto da Q6, a versão para a prova e a conferência em R. É o que se copia no papel para treinar.

Questão	O que este capítulo dá	Resolução completa
Q5	escrever em B, classificar, estacionariedade e invertibilidade pelas raízes, pesos ψ_j e π_j	Q5
Q6	ARMA(1,1): γ_k, $\rho_k = \phi_1^{k-1}\rho_1$, MA($\infty$) e AR($\infty$)	Q6 e a folha à mão
Q7	AR(2): Yule-Walker, ρ_1, ρ_2, γ_0	Q7
Q8 (I)	ARMA(1,1) no sinal positivo, julgamento V/F	Q8

Armadilhas (do log de erros e do caderno):

- usar $|\theta_1| < 1$ num MA(2), em vez das raízes;
- trocar o sinal de ϕ_2 ao montar $\phi(z)$;
- escrever $\gamma_k = \phi_1^k \gamma_1$ no ARMA(1,1), quando o certo é $\phi_1^{k-1}\gamma_1$;
- perder o quadrado de θ_1^2 em γ_0;
- concluir "MA(1)" por um corte em 1 com $\hat{\rho}_1 > 0{,}5$.

Checklist de 30 segundos, antes de entregar:

1. Escrevi qual convenção de sinal estou usando?
2. Montei o polinômio **inteiro** antes de falar de raízes?
3. Estacionariedade pelo $\phi(z)$ e invertibilidade pelo $\theta(z)$, separadamente?
4. Cada esperança tem a justificativa ([RB], caus., estac.)?
5. O resultado final está traduzido para o sinal da lista?

No material do professor

Roteiro de releitura, na ordem deste capítulo:

- AU02, p. 11–14: operador L;
- AU02, p. 15–23: processo linear geral, Ψ, π, e os exemplos AR(1) e MA(1);
- AU02, p. 24: as duas perguntas da abertura;
- AU02, p. 25–29: memória do AR e estacionariedade do MA;
- AU02, p. 30–36: invertibilidade, o par θ e $1/\theta$, e a dualidade AR $\leftrightarrow$ MA;
- AU02, p. 37–41: matriz F e triângulo do AR(2);
- AU02, p. 45–53: momentos do MA(1) e do MA(q);
- AU02, p. 61–71: AR(1), AR(p) e Yule-Walker;
- AU02, p. 81–87: ARMA(1,1) e ARMA(p, q);
- AU02, p. 90–97: FACP e identificação.

A EQD dá a base de equações de diferenças de 2ª ordem para o caso complexo.

Livros:

- **ENDERS**, cap. 2: ARMA e FAC no nível do curso, com as raízes características bem explicadas;
- **HAMILTON**, cap. 3: o rigor do processo linear e da invertibilidade;
- **BJRL**, cap. 3: a convenção de sinal da lista e a FAC dos modelos mistos.

Na lista comentada: Q5 · Q6 · Q7 · Q8 · caixa de ferramentas F1 (Bhaskara), F2 (série geométrica), F7 (igualar coeficientes).

CAPÍTULO 17

Cap. 2 à mão — Q5 a Q8 linha a linha

Cap. 2 à mão: Q5 a Q8, linha a linha

← capítulo 2 · ← apostila

Esta é a versão de **caderno** do bloco 2 da lista, no mesmo formato da folha da Q2 e da Q6: cada passagem numerada, uma operação por linha e o motivo entre colchetes. Os símbolos são os dos slides: L, ε_t, ϕ_1, e θ_1 com sinal positivo. A tradução para a lista vem em cada questão. A numeração das linhas é contínua do início ao fim, para que "[(19)]" aponte sempre para a mesma linha.

Legenda:

- [RB]: ruído branco, $E(\varepsilon_t) = 0$, $E(\varepsilon_t^2) = \sigma^2$ e $E(\varepsilon_t \varepsilon_s) = 0$ se $t \neq s$;
-
- [F2]: série geométrica;
- [F3]: soma de Gauss;
- [F4]: linearidade da esperança;
- [F7]: igualar coeficientes;
- [F8]: multiplicar polinômios;
- estac.: os momentos não dependem da data;
- caus.: o choque de hoje não se correlaciona com o passado de y;
- [(n)]: usando a linha (n).

As ferramentas estão demonstradas na caixa de ferramentas.

Q5 · Três modelos: operador, classificação, raízes e pesos

Enunciado (lista, Q5). Três modelos em $\tilde{z}_t$ e a_t:

- (1) um AR(1) com coeficiente 0,5;
- (2) um MA(2) com −1,3 e +0,4;
- (3) os dois juntos.

Pede-se:

- escrever cada um com o operador de retardo e classificá-lo como ARMA(p, q);
- verificar estacionariedade e invertibilidade;
- obter $\psi_1, \ldots, \psi_4$ e $\pi_1, \ldots, \pi_4$.

Nos slides: $a_t = \varepsilon_t$ e $B = L$. Os pesos ψ_j e π_j **não dependem** da convenção do MA, porque $\tilde{z}_t = \sum \psi_j \varepsilon_{t-j}$ e $\tilde{z}_t = \sum \pi_j \tilde{z}_{t-j} + \varepsilon_t$ são as mesmas equações nas duas notações (AU02, p. 16 e 19).

Modelo (1): $\tilde{z}_t - 0{,}5\tilde{z}_{t-1} = \varepsilon_t$

(1)	$\tilde{z}_t - 0{,}5\,\tilde{z}_{t-1} = \varepsilon_t$	[lista]
(2)	$(1 - 0{,}5L)\,\tilde{z}_t = \varepsilon_t$	[operador de defasagem: $L\tilde{z}_t = \tilde{z}_{t-1}$]
(3)	$\phi(L) = 1 - 0{,}5L$ (grau 1), $\theta(L) = 1$ (grau 0) $\Rightarrow$ ARMA(1, 0)	[classifica]
(4)	$1 - 0{,}5z = 0 \Rightarrow z = 2$	[raiz do AR]
(5)	$\lvert z\rvert = 2 > 1 \Rightarrow$ estacionário	[AU02 p. 27]
(6)	não há polinômio MA $\Rightarrow$ invertível	[AU02 p. 36]
(7)	$\Psi(L) = (1 - 0{,}5L)^{-1} = \sum_{j\geq 0} 0{,}5^j L^j$	[F2, $\lvert 0{,}5\rvert < 1$]
(8)	$\psi_1 = 0{,}5;\ \psi_2 = 0{,}25;\ \psi_3 = 0{,}125;\ \psi_4 = 0{,}0625$	[$\psi_j = 0{,}5^j$]
(9)	$\pi(L) = 1 - 0{,}5L \Rightarrow \pi_1 = 0{,}5,\ \pi_2 = \pi_3 = \pi_4 = 0$	[já está na forma AR]

AR(1) : estacionário ($z = 2$) e invertível; $\psi_j = 0{,}5^j$; $\pi_1 = 0{,}5,\ \pi_{j\geq 2} = 0$

Modelo (2): $\tilde{z}_t = \varepsilon_t - 1{,}3\varepsilon_{t-1} + 0{,}4\varepsilon_{t-2}$

(10)	$\tilde{z}_t = \varepsilon_t - 1{,}3\,\varepsilon_{t-1} + 0{,}4\,\varepsilon_{t-2}$	[lista]
(11)	$\tilde{z}_t = (1 - 1{,}3L + 0{,}4L^2)\,\varepsilon_t, \quad \theta_1 = -1{,}3,\ \theta_2 = 0{,}4$	[slides: $\theta(L) = 1 + \theta_1 L + \theta_2 L^2$]
(12)	$\phi(L) = 1$, $\theta(L)$ de grau 2 $\Rightarrow$ ARMA(0, 2)	[classifica]
(13)	$\sum\lvert\psi_j\rvert = 1 + 1{,}3 + 0{,}4 = 2{,}7 < \infty \Rightarrow$ estacionário	[AU02 p. 29: MA finito]
(14)	$\theta(z) = 0 \iff 0{,}4z^2 - 1{,}3z + 1 = 0$: $a = 0{,}4,\ b = -1{,}3,\ c = 1$	[F1, forma padrão]
(15)	$\Delta = b^2 - 4ac = (-1{,}3)^2 - 4(0{,}4)(1) = 1{,}69 - 1{,}60 = 0{,}09$	[F1]
(16)	$z = \dfrac{-b \pm \sqrt{\Delta}}{2a} = \dfrac{1{,}3 \pm 0{,}3}{0{,}8} \Rightarrow z_1 = 2,\ z_2 = 1{,}25$	[F1, $\sqrt{0{,}09} = 0{,}3$]
(17)	$z_1 + z_2 = 3{,}25 = -b/a; \qquad z_1 z_2 = 2{,}5 = c/a$	[Vieta: confere]
(18)	$\lvert 2\rvert > 1$ e $\lvert 1{,}25\rvert > 1 \Rightarrow$ invertível	[AU02 p. 33]
(19)	$1 - 1{,}3L + 0{,}4L^2 = (1 - 0{,}5L)(1 - 0{,}8L)$	[F8: $1 - 0{,}8L - 0{,}5L + 0{,}4L^2$]
(20)	$\psi_1 = -1{,}3;\ \psi_2 = 0{,}4;\ \psi_3 = \psi_4 = 0$	[o MA já é a forma MA(∞)]

Pesos π, igualando coeficientes. Escreva $\theta(L)^{-1} = 1 + c_1 L + c_2 L^2 + \cdots$ e exija $\theta(L)^{-1}\theta(L) = 1$, potência por potência:

(21)	$(1 + c_1 L + c_2 L^2 + c_3 L^3 + \cdots)(1 - 1{,}3L + 0{,}4L^2) = 1$	[F7]
(22)	L^1 : $c_1 - 1{,}3 = 0 \Rightarrow c_1 = 1{,}3$	[coeficiente de L]
(23)	L^2 : $c_2 - 1{,}3c_1 + 0{,}4 = 0 \Rightarrow c_2 = 1{,}69 - 0{,}4 = 1{,}29$	[(22)]
(24)	L^3 : $c_3 - 1{,}3c_2 + 0{,}4c_1 = 0 \Rightarrow c_3 = 1{,}677 - 0{,}52 = 1{,}157$	[(22), (23)]
(25)	L^4 : $c_4 - 1{,}3c_3 + 0{,}4c_2 = 0 \Rightarrow c_4 = 1{,}5041 - 0{,}516 = 0{,}9881$	[(23), (24)]
(26)	$\pi(L) = \theta(L)^{-1} = 1 - \pi_1 L - \pi_2 L^2 - \cdots \Rightarrow \pi_j = -c_j$	[AU02 p. 19–20]
(27)	$\pi_1 = -1{,}3;\ \pi_2 = -1{,}29;\ \pi_3 = -1{,}157;\ \pi_4 = -0{,}9881$	[(22)–(26)]

MA(2) : estacionário; invertível ($z = 2;\ 1{,}25$); π_j decaem devagar, à taxa $1/1{,}25 = 0{,}8$

Modelo (3): $\tilde{z}_t - 0{,}5\tilde{z}_{t-1} = \varepsilon_t - 1{,}3\varepsilon_{t-1} + 0{,}4\varepsilon_{t-2}$

(28)	$(1-0{,}5L)\,\tilde{z}_t = (1-1{,}3L+0{,}4L^2)\,\varepsilon_t$	[lista em L]
(29)	$(1-0{,}5L)\,\tilde{z}_t = (1-0{,}5L)(1-0{,}8L)\,\varepsilon_t$	[(19)]
(30)	$\tilde{z}_t = (1-0{,}8L)\,\varepsilon_t$	[$\times(1-0{,}5L)^{-1}$, F2]
(31)	parece ARMA(1,2), mas é MA(1) = ARMA(0, 1)	[fator comum]
(32)	estacionário: MA finito	[AU02 p. 29]
(33)	$1-0{,}8z=0 \;\Rightarrow\; z=1{,}25>1 \;\Rightarrow$ invertível	[AU02 p. 33]
(34)	$\psi_1=-0{,}8;\;\; \psi_j=0,\; j\geq 2$	[(30)]

Conferência dos ψ pelo modelo inteiro, sem cancelar nada: exija $\Psi(L)(1-0{,}5L) = 1-1{,}3L+0{,}4L^2$ potência por potência.

(35)	$L^1 :\; \psi_1 - 0{,}5 = -1{,}3 \;\Rightarrow\; \psi_1 = -0{,}8$	[F7]
(36)	$L^2 :\; \psi_2 - 0{,}5\psi_1 = 0{,}4 \;\Rightarrow\; \psi_2 = 0{,}4 - 0{,}4 = 0$	[F7, (35)]
(37)	$\pi_j = -(-\theta_1)^j$ com $\theta_1=-0{,}8 \;\Rightarrow\; \pi_j = -0{,}8^{\,j}$	[AU02 p. 23]
(38)	$\pi_1=-0{,}8;\; \pi_2=-0{,}64;\; \pi_3=-0{,}512;\; \pi_4=-0{,}4096$	[(37)]

fator comum $(1-0{,}5L)$: o modelo (3) é o MA(1) $\tilde{z}_t = \varepsilon_t - 0{,}8\varepsilon_{t-1}$ (lista: $\theta = 0{,}8$)

Como enxergar o fator comum sem fatorar: a raiz do AR, $z=2$, aparece também entre as raízes do MA, $\{2;\ 1{,}25\}$.

Q6 · ARMA(1,1): o roteiro, com a demonstração completa ao lado

A Q6 está demonstrada por inteiro, em 43 linhas, na folha da Q2 e da Q6, com os nove termos de γ_0 na ordem do slide. Aqui fica o esqueleto, para conferir que nenhum passo foi esquecido. O modelo é $y_t - \mu = \phi_1(y_{t-1}-\mu) + \varepsilon_t + \theta_1\varepsilon_{t-1}$, com $\theta_1 = -\theta^{\text{lista}}$.

(39)	$E\big((y_t-\mu)\varepsilon_t\big)=\sigma^2, \quad E\big((y_{t+1}-\mu)\varepsilon_t\big)=(\phi_1+\theta_1)\sigma^2$	[momentos auxiliares]
(40)	$\gamma_0 = \phi_1^2\gamma_0 + 2\theta_1\phi_1\sigma^2 + \sigma^2 + \theta_1^2\sigma^2$	[nove termos, quatro zeros]
(41)	$\gamma_0 = \dfrac{\sigma^2(2\theta_1\phi_1+1+\theta_1^2)}{1-\phi_1^2}$	[isola, AU02 p. 83]
(42)	$\gamma_1 = \phi_1\gamma_0 + \theta_1\sigma^2 = \dfrac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1-\phi_1^2}\,\sigma^2$	[$\times(y_{t-1}-\mu)$, AU02 p. 84]
(43)	$\gamma_k = \phi_1\gamma_{k-1} = \phi_1^{k-1}\gamma_1, \quad k\geq 2$	[caus.; indução]
(44)	$\rho_k = \phi_1^{k-1}\rho_1, \quad k\geq 1$	[$\div\gamma_0$]
(45)	$\psi_j = (\phi_1+\theta_1)\,\phi_1^{j-1}; \qquad \pi_j = (\phi_1+\theta_1)(-\theta_1)^{j-1}$	[F7, F2]
(46)	lista: $\psi_j = (\phi-\theta)\phi^{j-1}; \qquad \pi_j = (\phi-\theta)\theta^{j-1}$	[$\theta_1=-\theta$]

Q7 · AR(2): Yule-Walker, ρ_1, ρ_2 e γ_0

Enunciado (lista, Q7). Para $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$:

- escrever as equações de Yule-Walker e obter ρ_1 e ρ_2 em função de ϕ_1 e ϕ_2;
- obter a variância γ_0.

Nos slides: a mesma notação (AU02, p. 66–69), com média zero.

> **Erro do caderno (03/09): o sinal de ϕ_2 ao montar o polinômio**
>
> No exemplo $\phi_1 = 1{,}5$ e $\phi_2 = -0{,}6$, o polinômio virou $1 - 1{,}5B - 0{,}6B^2$. O certo é $1 - \phi_1 B - \phi_2 B^2 = 1 - 1{,}5B + 0{,}6B^2$, porque $-\phi_2 B^2 = -(-0{,}6)B^2$. Daí o Δ do caderno saiu errado e os módulos 0,6 e 0,52 também; o certo é $\sqrt{0{,}6} = 0{,}7746$.

(47) $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t, \quad E(y_t) = 0$ [modelo]

(48) $E(\varepsilon_t\, y_{t-k}) = 0, \quad k \geq 1$ [caus.]

(49) $E(\varepsilon_t\, y_t) = 0 + 0 + E(\varepsilon_t^2) = \sigma^2$ [F4; (48) zera dois termos]

(50) $\times\, y_{t-1}: \quad \gamma_1 = \phi_1 \gamma_0 + \phi_2 \gamma_1$ [$E(y_{t-2}y_{t-1}) = \gamma_1$, (48)]

(51) $\times\, y_{t-2}: \quad \gamma_2 = \phi_1 \gamma_1 + \phi_2 \gamma_0$ [(48)]

(52) $\rho_1 = \phi_1 + \phi_2 \rho_1; \qquad \rho_2 = \phi_1 \rho_1 + \phi_2$ [$\div \gamma_0$: Yule-Walker, AU02 p. 68–69]

(53) $\rho_1(1 - \phi_2) = \phi_1 \;\Rightarrow\; \rho_1 = \dfrac{\phi_1}{1 - \phi_2}$ [(52)]

(54) $\rho_2 = \dfrac{\phi_1^2}{1 - \phi_2} + \phi_2 = \dfrac{\phi_1^2 + \phi_2 - \phi_2^2}{1 - \phi_2}$ [(53); denominador comum]

(55) $\times\, y_t: \quad \gamma_0 = \phi_1 \gamma_1 + \phi_2 \gamma_2 + \sigma^2$ [(49)]

(56) $\gamma_0 = \dfrac{\sigma^2}{1 - \phi_1 \rho_1 - \phi_2 \rho_2}$ [(55) $\div\, \gamma_0$, isola]

(57) $1 - \phi_1 \rho_1 - \phi_2 \rho_2 = \dfrac{(1 - \phi_2) - \phi_1^2 - \phi_2(\phi_1^2 + \phi_2 - \phi_2^2)}{1 - \phi_2}$ [(53), (54)]

(58) $\text{numerador} = (1 - \phi_2)(1 - \phi_2^2) - \phi_1^2(1 + \phi_2)$ [agrupa]

(59) $\qquad\qquad = (1 + \phi_2)\big[(1 - \phi_2)^2 - \phi_1^2\big]$ [$1 - \phi_2^2 = (1 - \phi_2)(1 + \phi_2)$]

(60) $\gamma_0 = \dfrac{(1 - \phi_2)\,\sigma^2}{(1 + \phi_2)\big[(1 - \phi_2)^2 - \phi_1^2\big]}$ [(56)–(59)]

(61) $(1 - \phi_2)^2 - \phi_1^2 = (1 - \phi_2 - \phi_1)(1 - \phi_2 + \phi_1)$ [diferença de quadrados]

(62) $\gamma_0 > 0 \iff 1 + \phi_2 > 0, \;\; \phi_1 + \phi_2 < 1, \;\; \phi_2 - \phi_1 < 1$ [o triângulo, AU02 p. 41]

$$\boxed{\rho_1 = \frac{\phi_1}{1 - \phi_2}, \qquad \rho_2 = \frac{\phi_1^2 + \phi_2 - \phi_2^2}{1 - \phi_2}, \qquad \gamma_0 = \frac{(1 - \phi_2)\,\sigma^2}{(1 + \phi_2)\big[(1 - \phi_2)^2 - \phi_1^2\big]}}$$

Em (56), divide-se (55) por γ_0: $1 = \phi_1 \rho_1 + \phi_2 \rho_2 + \sigma^2/\gamma_0$. Em (58), $(1 - \phi_2) - \phi_2^2(1 - \phi_2) = (1 - \phi_2)(1 - \phi_2^2)$. Em (62), os três fatores de (60)–(61) são exatamente as três desigualdades do triângulo de estacionariedade. A variância só existe, e é positiva, dentro dele.

Com o exemplo do caderno, $\phi_1 = 1{,}5$ e $\phi_2 = -0{,}6$:

- $\rho_1 = 1{,}5/1{,}6 = 0{,}9375$ e $\rho_2 = 0{,}80625$;
- os fatores são $1 + \phi_2 = 0{,}4$, $1 - \phi_2 - \phi_1 = 0{,}1$ e $1 - \phi_2 + \phi_1 = 3{,}1$, todos positivos;

- $\gamma_0 = 12{,}9032\,\sigma^2$. A variância é grande porque o fator 0,1 está perto de zero: o processo está perto da borda do triângulo.

Q8 · Verdadeiro ou falso, com demonstração

Enunciado (lista, Q8). São dois modelos, e cinco afirmativas para julgar com demonstração:

- **(I)** $Y_t = \alpha Y_{t-1} + u_t + \beta u_{t-1}$, com $0 < \alpha < 1$;
- **(II)** $Z_t = c + Z_{t-1} + \theta t + \varepsilon_t$.

Nos slides: a Q8 **já usa o sinal positivo**. O (I) é o ARMA(1,1) da AU02, p. 81, com $\phi_1 = \alpha$ e $\theta_1 = \beta$. O (II) é o passeio com drift e tendência da AU01, p. 30, com $\alpha_1 = c$ e $\alpha_2 = \theta$. Mantenho as letras da lista, e $\gamma_h = E(Y_t Y_{t+h})$.

Momentos auxiliares do (I):

$$
\begin{aligned}
&(63)\quad E(Y_{t-1}u_t) = 0 && [\text{caus.}]\\
&(64)\quad E(Y_t u_t) = \alpha E(Y_{t-1}u_t) + E(u_t^2) + \beta E(u_{t-1}u_t) = \sigma^2 && [\text{F4, (63), RB}]\\
&(65)\quad E(Y_t u_{t-1}) = \alpha E(Y_{t-1}u_{t-1}) + E(u_t u_{t-1}) + \beta E(u_{t-1}^2) = (\alpha+\beta)\sigma^2 && [(64)\text{ em } t-1,\ \text{RB}]
\end{aligned}
$$

Afirmativa 1: $\gamma_0 = \alpha\gamma_1 + \sigma^2 + \beta(\alpha+\beta)\sigma^2$.

$$
\begin{aligned}
&(66)\quad \gamma_0 = E(Y_t Y_t) = \alpha E(Y_{t-1}Y_t) + E(u_t Y_t) + \beta E(u_{t-1}Y_t) && [\text{modelo} \times Y_t]\\
&(67)\quad = \alpha\gamma_1 + \sigma^2 + \beta(\alpha+\beta)\sigma^2 \ \Rightarrow\ \textbf{VERDADEIRA} && [(64), (65)]
\end{aligned}
$$

Afirmativa 2: $\gamma_1 = \alpha(\gamma_0 + \sigma^2) + \beta\sigma^2$.

$$
\begin{aligned}
&(68)\quad \gamma_1 = E(Y_{t+1}Y_t) = \alpha E(Y_t Y_t) + E(u_{t+1}Y_t) + \beta E(u_t Y_t) && [\text{modelo em } t+1,\ \times Y_t]\\
&(69)\quad = \alpha\gamma_0 + 0 + \beta\sigma^2 && [\text{caus.: } u_{t+1} \text{ é futuro; (64)}]\\
&(70)\quad \text{afirmativa} - \text{certo} = \alpha\sigma^2 \neq 0 \ \Rightarrow\ \textbf{FALSA} && [\alpha > 0]
\end{aligned}
$$

Afirmativa 3: $\rho_h = \frac{(\beta+\alpha)(1+\alpha\beta)}{1+2\alpha\beta+\beta^2}$ para todo h.

$$
\begin{aligned}
&(71)\quad \gamma_0 = \frac{1+2\alpha\beta+\beta^2}{1-\alpha^2}\sigma^2, \quad \gamma_1 = \frac{(1+\alpha\beta)(\alpha+\beta)}{1-\alpha^2}\sigma^2 && [(67), (69)]\\
&(72)\quad \rho_1 = \frac{(\alpha+\beta)(1+\alpha\beta)}{1+2\alpha\beta+\beta^2} && [(71)]\\
&(73)\quad \gamma_h = \alpha\gamma_{h-1},\ h \geq 2 \ \Rightarrow\ \rho_h = \alpha^{h-1}\rho_1 && [\text{caus.; (43)}]\\
&(74)\quad \text{a expressão só vale em } h = 1;\ \text{para } h \geq 2 \text{ falta } \alpha^{h-1} \ \Rightarrow\ \textbf{FALSA} && [(72), (73)]
\end{aligned}
$$

Em (71), resolve-se o sistema formado por (67) e (69), como na Q6.

Afirmativa 4: $Z_t = ct + \frac{\theta}{2}t^2 + Z_0 + \sum_{j=1}^{t}\varepsilon_j$.

$$
\begin{aligned}
&(75)\quad Z_s - Z_{s-1} = c + \theta s + \varepsilon_s && [\text{modelo}]\\
&(76)\quad Z_t - Z_0 = ct + \theta\textstyle\sum_{s=1}^{t} s + \sum_{s=1}^{t}\varepsilon_s && [\text{soma de 1 a } t,\ \text{telescópica}]\\
&(77)\quad Z_t = Z_0 + ct + \theta\frac{t(t+1)}{2} + \textstyle\sum_{j=1}^{t}\varepsilon_j && [\text{F3}]\\
&(78)\quad \theta\frac{t(t+1)}{2} = \frac{\theta}{2}t^2 + \frac{\theta}{2}t \neq \frac{\theta}{2}t^2 \ \Rightarrow\ \textbf{FALSA} && [\text{falta } \theta t/2]
\end{aligned}
$$

Afirmativa 5: $V(Z_t) = (c + \theta t)\sigma^2$.

$$V(Z_t) = V\Big(\sum_{j=1}^{t} \varepsilon_j\Big) \qquad [(77):\ Z_0,\ ct,\ \theta t(t+1)/2 \text{ são constantes}] \tag{79}$$

$$= \sum_{j=1}^{t} V(\varepsilon_j) = t\sigma^2 \neq (c + \theta t)\sigma^2 \ \Rightarrow\ \textbf{FALSA} \qquad [\text{RB: sem covariâncias}] \tag{80}$$

Gabarito da Q8: V, F, F, F, F

Versão para a prova

Q5, para cada modelo, quatro linhas:

1. Escreva em L e diga o grau de $\phi(L)$ e de $\theta(L)$.
2. Calcule as raízes: $\phi(z)$ para a estacionariedade e $\theta(z)$ para a invertibilidade, com Bhaskara e Vieta.
3. Obtenha os ψ por $\Psi(L)\phi(L) = \theta(L)$ e os π por $\pi(L)\theta(L) = \phi(L)$, potência por potência.
4. **Procure raiz repetida dos dois lados**: no modelo (3), o fator $(1 - 0{,}5L)$ cancela, e sobra um MA(1).

Q6: as linhas (39)–(46), ou a versão de 10 itens da folha da Q6.

Q7:

1. Multiplique por y_{t-1} e y_{t-2} e divida por γ_0: $\rho_1 = \phi_1/(1 - \phi_2)$ e $\rho_2 = \phi_1\rho_1 + \phi_2$.
2. Multiplique por y_t: $\gamma_0 = \sigma^2/(1 - \phi_1\rho_1 - \phi_2\rho_2)$.
3. Simplifique até (60).
4. Feche com o triângulo.

Q8:

1. Escreva os dois momentos auxiliares.
2. Em cada item, a conta que leva à expressão certa e a comparação com a afirmativa.
3. Gabarito V, F, F, F, F. **Sem conta, V ou F vale zero.**

Conferência

Todos os números desta folha vêm do R e são conferidos por dois caminhos.

Q5:

- as raízes 2 e 1,25 saem iguais pelo `polyroot`;
- os π_j do modelo (2) por (22)–(27) coincidem com os do helper do repositório, com diferença 0;
- os ψ_j do modelo (3) escrito inteiro e os do MA(1) cancelado coincidem até $j = 20$, com diferença 0.

Q7: $\gamma_0 = 12{,}9032$ pela fórmula (60), por (56) e pela autocovariância do R.

Q8, com $\alpha = 0{,}6$, $\beta = 0{,}3$ e $\sigma^2 = 1$:

- $\gamma_0 = 2{,}265625$, e o lado direito da afirmativa 1 dá o mesmo;
- $\gamma_1 = 1{,}659375$, contra os 2,259375 da afirmativa 2;
- $\rho_1 = 0{,}7324$ e $\rho_2 = 0{,}4394$;
- com $c = 1$, $\theta = 0{,}5$ e $t = 4$: $E(Z_4) = 9$, contra 8 da afirmativa 4, e $V(Z_4) = 4$, contra 3 da afirmativa 5.

Q6 · ARMA(1,1)

Enunciado (lista, Q6). O ARMA(1,1) $z_t - \phi z_{t-1} = a_t - \theta a_{t-1}$, com $|\phi| < 1$ e $|\theta| < 1$, na convenção de Box-Jenkins. Pede-se:

- (a) γ_0, γ_1 e γ_k $(k \geq 2)$;
- (b) ρ_1, e mostrar que $\rho_k = \phi^{k-1}\rho_1$;
- (c) as formas AR(∞) e MA(∞), e para que parâmetros a convergência é mais lenta.

Nos slides (AU02, p. 81–84), com a constante c, como o professor e o caderno escrevem:

$$y_t = c + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}, \qquad \varepsilon_t \sim RB(0, \sigma^2),$$

ou seja, $(1 - \phi_1 L)\, y_t = c + (1 + \theta_1 L)\, \varepsilon_t$. A tradução da lista:

- $y_t = z_t$ e $\varepsilon_t = a_t$;
- $\phi_1 = \phi$ e $\theta_1 = -\theta$, por causa do sinal positivo dos slides;
- a lista não tem constante: $c = 0$, logo $\mu = 0$ e $y_t - \mu = z_t$.

Hipóteses: [RB]; $|\phi_1| < 1$ (estacionário); $|\theta_1| < 1$ (invertível). No fim, cada resultado volta para o sinal da lista.

(0) Média, forma em desvios e momentos auxiliares

Valor esperado (AU02, p. 82):

$$\begin{aligned}
&(1) \quad E(y_t) = c + \phi_1 E(y_{t-1}) + E(\varepsilon_t) + \theta_1 E(\varepsilon_{t-1}) && \text{[lin.]}\\
&(2) \quad \mu = c + \phi_1 \mu + 0 + 0 && \text{[estac., RB]}\\
&(3) \quad \mu(1 - \phi_1) = c \implies \mu = \frac{c}{1 - \phi_1} && [|\phi_1| < 1]
\end{aligned}$$

Forma em desvios. Subtraia μ dos dois lados do modelo e troque c por $(1 - \phi_1)\mu$, que vem de (3):

$$\begin{aligned}
&(4) \quad y_t - \mu = (1 - \phi_1)\mu - \mu + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1} && \text{[(3)]}\\
&(5) \quad \qquad = -\phi_1 \mu + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}\\
&(6) \quad y_t - \mu = \phi_1 (y_{t-1} - \mu) + \varepsilon_t + \theta_1 \varepsilon_{t-1} && \text{[evidência]}
\end{aligned}$$

A linha (6) é o "já sabemos que" da AU02, p. 82 e 84. A constante sumiu: todas as contas abaixo usam (6).

Momentos auxiliares (como no caderno, 02/09). Pelo item (c), $y_t - \mu = \sum_{j \geq 0} \psi_j \varepsilon_{t-j}$: o desvio de hoje só contém choques de hoje e do passado.

$$\begin{aligned}
&(7) \quad E(\varepsilon_t \varepsilon_t) = \sigma^2 && \text{[RB]}\\
&(8) \quad E\big((y_{t-k} - \mu)\, \varepsilon_t\big) = 0 \quad \text{para } k \geq 1 && \text{[caus., RB]}\\
&(9) \quad E\big((y_t - \mu)\, \varepsilon_t\big) = E\big((\phi_1 (y_{t-1} - \mu) + \varepsilon_t + \theta_1 \varepsilon_{t-1})\, \varepsilon_t\big) && \text{[(6)]}\\
&(10) \quad \qquad = \phi_1 \cdot 0 + \sigma^2 + \theta_1 \cdot 0 = \sigma^2 && \text{[(8), (7), RB]}\\
&(11) \quad E\big((y_{t+1} - \mu)\, \varepsilon_t\big) = E\big((\phi_1 (y_t - \mu) + \varepsilon_{t+1} + \theta_1 \varepsilon_t)\, \varepsilon_t\big) && \text{[(6) em } t+1\text{]}\\
&(12) \quad \qquad = \phi_1 \sigma^2 + 0 + \theta_1 \sigma^2 = (\phi_1 + \theta_1)\, \sigma^2 && \text{[(10), RB, (7)]}
\end{aligned}$$

Por estacionariedade, (10) vale em qualquer data. Em $t-1$, $E\big((y_{t-1}-\mu)\varepsilon_{t-1}\big)=\sigma^2$, que é o "lembre que" da AU02, p. 83.

(a) γ_0, γ_1 e γ_k

γ_0 (AU02, p. 82–83). Por (6):

$$(13)\qquad \gamma_0 = E\big((y_t-\mu)^2\big) = E\Big(\big(\phi_1(y_{t-1}-\mu)+\varepsilon_t+\theta_1\varepsilon_{t-1}\big)^2\Big)$$

O quadrado é o produto do parêntese por ele mesmo: $3\times 3=9$ termos, na ordem do slide. Cada termo com a sua esperança:

$$\begin{aligned}
&(14)\quad E\big(\phi_1^2(y_{t-1}-\mu)^2\big)=\phi_1^2\gamma_0 && \text{[estac.]}\\
&(15)\quad E\big(\phi_1(y_{t-1}-\mu)\,\varepsilon_t\big)=0 && \text{[(8)]}\\
&(16)\quad E\big(\phi_1(y_{t-1}-\mu)\,\theta_1\varepsilon_{t-1}\big)=\phi_1\theta_1\sigma^2 && \text{[(10) em } t-1\text{]}\\
&(17)\quad E\big(\varepsilon_t\,\phi_1(y_{t-1}-\mu)\big)=0 && \text{[(8)]}\\
&(18)\quad E(\varepsilon_t^2)=\sigma^2 && \text{[(7)]}\\
&(19)\quad E(\varepsilon_t\,\theta_1\varepsilon_{t-1})=0 && \text{[RB]}\\
&(20)\quad E\big(\theta_1\varepsilon_{t-1}\,\phi_1(y_{t-1}-\mu)\big)=\theta_1\phi_1\sigma^2 && \text{[(10) em } t-1\text{]}\\
&(21)\quad E(\theta_1\varepsilon_{t-1}\,\varepsilon_t)=0 && \text{[RB]}\\
&(22)\quad E(\theta_1^2\varepsilon_{t-1}^2)=\theta_1^2\sigma^2 && \text{[RB]}
\end{aligned}$$

Somando (14)–(22): os termos (16) e (20) são iguais e dão $2\theta_1\phi_1\sigma^2$; os quatro zeros somem.

$$\begin{aligned}
&(23)\quad \gamma_0=\phi_1^2\gamma_0+2\theta_1\phi_1\sigma^2+\sigma^2+\theta_1^2\sigma^2 && \text{[(14)–(22)]}\\
&(24)\quad \gamma_0-\phi_1^2\gamma_0=\sigma^2(2\theta_1\phi_1+1+\theta_1^2) && \text{[passa } \phi_1^2\gamma_0\text{]}\\
&(25)\quad \gamma_0\,(1-\phi_1^2)=\sigma^2(2\theta_1\phi_1+1+\theta_1^2) && \text{[evidência]}
\end{aligned}$$

$$(26)\qquad \boxed{\gamma_0=\frac{\sigma^2(2\theta_1\phi_1+1+\theta_1^2)}{1-\phi_1^2}} \qquad [\,1-\phi_1^2\neq 0 \text{ porque } |\phi_1|<1\,]$$

É a forma da AU02, p. 83. **Atenção ao erro do caderno:** é θ_1^2, ao quadrado, no numerador.

γ_k, **equação geral** (AU02, p. 84). Multiplique (6) por $(y_{t-k}-\mu)$ e tire a esperança:

$$(27)\qquad \underbrace{E\big((y_t-\mu)(y_{t-k}-\mu)\big)}_{\gamma_k}=\phi_1\underbrace{E\big((y_{t-1}-\mu)(y_{t-k}-\mu)\big)}_{\gamma_{k-1}}+E\big(\varepsilon_t(y_{t-k}-\mu)\big)+\theta_1E\big(\varepsilon_{t-1}(y_{t-k}-\mu)\big)$$

$k=1$**:**

$$\begin{aligned}
&(28)\quad \gamma_1=\phi_1E\big((y_{t-1}-\mu)^2\big)+E\big(\varepsilon_t(y_{t-1}-\mu)\big)+\theta_1E\big(\varepsilon_{t-1}(y_{t-1}-\mu)\big) && \text{[(27), } k=1\text{]}\\
&(29)\quad =\phi_1\gamma_0+0+\theta_1\sigma^2 && \text{[estac., (8), (10)]}
\end{aligned}$$

Substituindo (26) em (29), com tudo sobre o denominador $1-\phi_1^2$:

$$\gamma_1 = \frac{\phi_1(1 + 2\phi_1\theta_1 + \theta_1^2) + \theta_1(1 - \phi_1^2)}{1 - \phi_1^2}\,\sigma^2 \quad [(26)] \tag{30}$$

$$= \frac{\phi_1 + 2\phi_1^2\theta_1 + \phi_1\theta_1^2 + \theta_1 - \phi_1^2\theta_1}{1 - \phi_1^2}\,\sigma^2 \quad [\text{distributiva}] \tag{31}$$

$$= \frac{\phi_1 + \theta_1 + \phi_1^2\theta_1 + \phi_1\theta_1^2}{1 - \phi_1^2}\,\sigma^2 \quad [2\phi_1^2\theta_1 - \phi_1^2\theta_1] \tag{32}$$

Fatoração do numerador, conferida por expansão: $(1 + \phi_1\theta_1)(\phi_1 + \theta_1) = \phi_1 + \theta_1 + \phi_1^2\theta_1 + \phi_1\theta_1^2$ ✓. Logo:

$$\boxed{\gamma_1 = \phi_1\gamma_0 + \theta_1\sigma^2 = \frac{(1 + \phi_1\theta_1)(\phi_1 + \theta_1)}{1 - \phi_1^2}\,\sigma^2} \tag{33}$$

$k \geq 2$**:** em (27), os dois últimos termos são zero por (8):

- $E\big(\varepsilon_t(y_{t-k} - \mu)\big) = 0$, porque $k \geq 1$;
- $E\big(\varepsilon_{t-1}(y_{t-k} - \mu)\big) = 0$, porque a distância entre $t-1$ e $t-k$ é $k-1 \geq 1$.

Sobra $\gamma_k = \phi_1\gamma_{k-1}$. **Indução:**

- base, $k = 2$: $\gamma_2 = \phi_1\gamma_1$;
- passo: se $\gamma_{k-1} = \phi_1^{k-2}\gamma_1$, então $\gamma_k = \phi_1 \cdot \phi_1^{k-2}\gamma_1 = \phi_1^{k-1}\gamma_1$.

$$\boxed{\gamma_k = \phi_1\,\gamma_{k-1} = \phi_1^{k-1}\gamma_1 \quad (k \geq 2)} \tag{34}$$

Atenção ao erro do caderno: o expoente é $k-1$, não k. Confira com $k = 2$: um único ϕ_1.

(b) FAC

$$\rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{(1 + \phi_1\theta_1)(\phi_1 + \theta_1)\sigma^2/(1 - \phi_1^2)}{(1 + 2\phi_1\theta_1 + \theta_1^2)\sigma^2/(1 - \phi_1^2)} \quad [(33), (26)] \tag{35}$$

$$= \frac{(1 + \phi_1\theta_1)(\phi_1 + \theta_1)}{1 + 2\phi_1\theta_1 + \theta_1^2} \quad [\text{cancela } \sigma^2 \text{ e } 1 - \phi_1^2] \tag{36}$$

$\rho_k = \phi_1^{k-1}\rho_1$ **por indução**, dividindo (34) por γ_0:

- **base,** $k = 1$**:** $\phi_1^0\rho_1 = \rho_1$ ✓;
- **passo:** se $\rho_{k-1} = \phi_1^{k-2}\rho_1$, então $\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\phi_1\gamma_{k-1}}{\gamma_0} = \phi_1\rho_{k-1} = \phi_1 \cdot \phi_1^{k-2}\rho_1 = \phi_1^{k-1}\rho_1$ ✓.

$$\boxed{\rho_k = \phi_1^{k-1}\rho_1 \quad (k \geq 1)} \tag{37}$$

Conclusão: a FAC decai geometricamente, à taxa ϕ_1, mas **a partir de ρ_1, e não de 1**. O MA só altera o primeiro valor.

(c) MA(∞), AR(∞) e a velocidade de convergência

Como na lista, $c = 0$: então $\mu = 0$ e $y_t - \mu = y_t$. Com constante, troque cada y por $y - \mu$, pela forma em desvios (6).

MA(∞), caminho 1 — substituição recursiva.

$$
\begin{aligned}
(38)\quad & y_t = \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1} && \text{[modelo]}\\
(39)\quad & = \phi_1(\phi_1 y_{t-2} + \varepsilon_{t-1} + \theta_1 \varepsilon_{t-2}) + \varepsilon_t + \theta_1 \varepsilon_{t-1} && \text{[modelo em } t-1\text{]}\\
(40)\quad & = \varepsilon_t + (\phi_1 + \theta_1)\varepsilon_{t-1} + \phi_1\theta_1\varepsilon_{t-2} + \phi_1^2 y_{t-2} && \text{[agrupando]}\\
(41)\quad & = \varepsilon_t + (\phi_1 + \theta_1)\varepsilon_{t-1} + \phi_1(\phi_1 + \theta_1)\varepsilon_{t-2} + \phi_1^2\theta_1\varepsilon_{t-3} + \phi_1^3 y_{t-3} && \text{[modelo em } t-2\text{]}
\end{aligned}
$$

Em (41), o coeficiente de ε_{t-2} é $\phi_1\theta_1 + \phi_1^2 = \phi_1(\phi_1 + \theta_1)$. O padrão: o coeficiente de ε_{t-j}, $j \geq 1$, é $(\phi_1 + \theta_1)\phi_1^{j-1}$. Depois de n substituições, o resto é $\phi_1^{n-1}\theta_1\varepsilon_{t-n} + \phi_1^n y_{t-n}$. Ele vai a zero em média quadrática, porque $E(\phi_1^{2n} y_{t-n}^2) = \phi_1^{2n}\gamma_0 \to 0$ quando $|\phi_1| < 1$.

MA(∞), caminho 2 — igualdade de coeficientes. $\Psi(L) = \frac{1+\theta_1 L}{1-\phi_1 L}$ significa $\Psi(L)(1 - \phi_1 L) = 1 + \theta_1 L$. Expandindo o lado esquerdo:

$$
(1 + \psi_1 L + \psi_2 L^2 + \cdots)(1 - \phi_1 L) = 1 + (\psi_1 - \phi_1)L + (\psi_2 - \phi_1\psi_1)L^2 + \cdots + (\psi_j - \phi_1\psi_{j-1})L^j + \cdots
$$

Igualando com $1 + \theta_1 L$, potência por potência:

- L^1: $\psi_1 - \phi_1 = \theta_1$, logo $\psi_1 = \phi_1 + \theta_1$;
- L^j, $j \geq 2$: $\psi_j - \phi_1\psi_{j-1} = 0$, logo $\psi_j = \phi_1\psi_{j-1}$.

$$
(42)\qquad \boxed{\psi_0 = 1, \quad \psi_j = (\phi_1 + \theta_1)\,\phi_1^{j-1}\ (j \geq 1)} \qquad y_t = \varepsilon_t + (\phi_1 + \theta_1)\sum_{j\geq 1}\phi_1^{j-1}\varepsilon_{t-j}
$$

AR(∞). $\pi(L) = \frac{1-\phi_1 L}{1+\theta_1 L}$, com $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots$ (AU02, p. 19).

- Pela série geométrica com razão $-\theta_1 L$, válida porque $|\theta_1| < 1$: $(1 + \theta_1 L)^{-1} = \sum_{j\geq 0}(-\theta_1)^j L^j$.
- Multiplicando por $(1 - \phi_1 L)$, o coeficiente de L^j, $j \geq 1$, é

$$
(-\theta_1)^j - \phi_1(-\theta_1)^{j-1} = (-\theta_1)^{j-1}(-\theta_1 - \phi_1) = -(\phi_1 + \theta_1)(-\theta_1)^{j-1}.
$$

- Comparando com $-\pi_j$:

$$
(43)\qquad \boxed{\pi_j = (\phi_1 + \theta_1)\,(-\theta_1)^{j-1}\ (j \geq 1)} \qquad y_t = \sum_{j\geq 1}\pi_j\, y_{t-j} + \varepsilon_t
$$

Quando cada série converge.

- $\sum_j |\psi_j| = 1 + |\phi_1 + \theta_1| \sum_{j\geq 1}|\phi_1|^{j-1} = 1 + \frac{|\phi_1+\theta_1|}{1-|\phi_1|} < \infty \iff |\phi_1| < 1$, que é a **estacionariedade**.
- $\sum_j |\pi_j| = \frac{|\phi_1+\theta_1|}{1-|\theta_1|} < \infty \iff |\theta_1| < 1$, que é a **invertibilidade**.

Quando a convergência é mais lenta. Os $|\psi_j|$ encolhem por um fator $|\phi_1|$ a cada período. A **meia-vida**, o número de períodos para um peso cair à metade, resolve $|\phi_1|^h = \frac{1}{2}$:

$$
h = \frac{\ln 0{,}5}{\ln|\phi_1|}\ : \qquad \phi_1 = 0{,}5 \Rightarrow h = 1; \qquad \phi_1 = 0{,}9 \Rightarrow h = 6{,}58; \qquad \phi_1 = 0{,}99 \Rightarrow h = 68{,}97.
$$

- **MA(∞) mais lento quando** $|\phi_1| \to 1$: perto da raiz unitária, os choques demoram a morrer.

- **AR(∞) mais lento quando** $|\theta_1| \to 1$: perto da não invertibilidade, é preciso muito passado de y para recuperar ε_t.
- **Caso extremo,** $\phi_1 = -\theta_1$**:** $\psi_j = \pi_j = 0$ para $j \geq 1$, e $y_t = \varepsilon_t$. Os fatores se cancelam: é um fator comum.

De volta ao sinal da lista ($\theta_1 = -\theta$)

	Slides	Lista
γ_0	$\frac{1+2\phi_1\theta_1+\theta_1^2}{1-\phi_1^2}\sigma^2$	$\frac{1-2\phi\theta+\theta^2}{1-\phi^2}\sigma_a^2$
γ_1	$\frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1-\phi_1^2}\sigma^2$	$\frac{(1-\phi\theta)(\phi-\theta)}{1-\phi^2}\sigma_a^2$
ρ_1	$\frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1+2\phi_1\theta_1+\theta_1^2}$	$\frac{(1-\phi\theta)(\phi-\theta)}{1-2\phi\theta+\theta^2}$
ρ_k	$\phi_1^{k-1}\rho_1$	$\phi^{k-1}\rho_1$
ψ_j	$(\phi_1+\theta_1)\phi_1^{j-1}$	$(\phi-\theta)\phi^{j-1}$
π_j	$(\phi_1+\theta_1)(-\theta_1)^{j-1}$	$(\phi-\theta)\theta^{j-1}$

Versão para a prova (Q6)

1. Convenção: sinais dos slides, $\theta_1 = -\theta$.
2. $\mu = \frac{c}{1-\phi_1}$ e a forma em desvios $y_t - \mu = \phi_1(y_{t-1}-\mu) + \varepsilon_t + \theta_1\varepsilon_{t-1}$ (na lista, $c = 0$).
3. Momentos auxiliares: $E(\varepsilon_t\varepsilon_t) = \sigma^2$; $E\big((y_{t-k}-\mu)\varepsilon_t\big) = 0$ para $k \geq 1$; $E\big((y_t-\mu)\varepsilon_t\big) = \sigma^2$; $E\big((y_{t+1}-\mu)\varepsilon_t\big) = (\phi_1+\theta_1)\sigma^2$.
4. $\gamma_0 = E\big((\phi_1(y_{t-1}-\mu) + \varepsilon_t + \theta_1\varepsilon_{t-1})^2\big)$: nove termos, quatro zeros, $\gamma_0 = \phi_1^2\gamma_0 + 2\theta_1\phi_1\sigma^2 + \sigma^2 + \theta_1^2\sigma^2$, logo $\gamma_0 = \frac{\sigma^2(2\theta_1\phi_1+1+\theta_1^2)}{1-\phi_1^2}$.
5. $\gamma_1 = \phi_1\gamma_0 + \theta_1\sigma^2 = \frac{(1+\phi_1\theta_1)(\phi_1+\theta_1)}{1-\phi_1^2}\sigma^2$.
6. $k \geq 2$: $\gamma_k = \phi_1\gamma_{k-1}$, porque os dois choques do modelo são posteriores a y_{t-k}.
7. $\rho_1 = \gamma_1/\gamma_0$; $\rho_k = \phi_1\rho_{k-1} = \phi_1^{k-1}\rho_1$ (indução).
8. $\Psi(L)(1-\phi_1 L) = 1 + \theta_1 L$ dá $\psi_j = (\phi_1+\theta_1)\phi_1^{j-1}$, que converge se $|\phi_1| < 1$.
9. $\pi(L)(1+\theta_1 L) = 1 - \phi_1 L$ dá $\pi_j = (\phi_1+\theta_1)(-\theta_1)^{j-1}$, que converge se $|\theta_1| < 1$.
10. Mais lento: $|\phi_1| \to 1$ para os ψ e $|\theta_1| \to 1$ para os π. Meia-vida $\ln 0{,}5 / \ln|\phi_1|$.
11. Traduzir para a lista com $\theta_1 = -\theta$.

Conferência (Q6)

Com $\phi_1 = 0{,}7$, $\theta_1 = -0{,}4$ (isto é, $\theta^{\text{lista}} = 0{,}4$) e $\sigma^2 = 1$:

- $\gamma_0 = \frac{1-0{,}56+0{,}16}{0{,}51} = 1{,}1765$;
- $\gamma_1 = 0{,}7(1{,}1765) - 0{,}4 = 0{,}4235$;
- $\rho_1 = 0{,}36$ e $\rho_2 = 0{,}252$;
- $\psi_1, \psi_2, \psi_3 = 0{,}3;\ 0{,}21;\ 0{,}147$ e $\pi_1, \pi_2, \pi_3 = 0{,}3;\ 0{,}12;\ 0{,}048$.

A substituição recursiva (42) e a fórmula (43) coincidem com o `ARMAtoMA` do R, com diferença zero.

Q5 · Três modelos: operador, classificação, raízes, ψ_j e π_j

← índice · anterior: Q4 · próxima: Q6 · resolução curta em 02_lista

O que a questão pede

Para três modelos:

- **escrever** com o operador de defasagem;
- **classificar** como ARMA(p, q);
- **verificar** a estacionariedade e a invertibilidade;
- **obter** os quatro primeiros pesos ψ_j e π_j.

Da lista para os slides

A lista usa $\tilde{z}_t$ (desvio da média), a_t e o MA com **sinal negativo**. Nos slides, o MA tem sinal positivo, então cada θ da lista troca de sinal [regra do README].

Modelo	Lista	Slides
(1)	$\tilde{z}_t - 0{,}5\tilde{z}_{t-1} = a_t$	$(1 - 0{,}5L)\tilde{z}_t = \varepsilon_t$
(2)	$\tilde{z}_t = a_t - 1{,}3a_{t-1} + 0{,}4a_{t-2}$	$\tilde{z}_t = (1 + \theta_1 L + \theta_2 L^2)\varepsilon_t$ com $\theta_1 = -1{,}3$, $\theta_2 = 0{,}4$
(3)	$\tilde{z}_t - 0{,}5\tilde{z}_{t-1} = a_t - 1{,}3a_{t-1} + 0{,}4a_{t-2}$	$(1 - 0{,}5L)\tilde{z}_t = (1 - 1{,}3L + 0{,}4L^2)\varepsilon_t$

Os **pesos** ψ_j e π_j não dependem da convenção do MA: $\tilde{z}_t = \sum \psi_j \varepsilon_{t-j}$ e $\tilde{z}_t = \sum \pi_j \tilde{z}_{t-j} + \varepsilon_t$ são iguais na lista e nos slides (AU02, p. 16 e 19).

Ferramentas

- **Slides:** AU02, p. 12–14 (escrever em L); p. 21 (AR(1) $\longrightarrow \psi$); p. 22–23 (MA(1) $\longrightarrow \pi_j = -(-\theta)^j$); p. 27 (raízes do AR fora do círculo); p. 29 (todo MA é estacionário); p. 33 (raízes do MA fora do círculo).
- **Caixa:** F1 Bhaskara; [F2] série geométrica; [F7] igualar coeficientes; [F8] multiplicar polinômios.
- **Livro:** HAMILTON, cap. 2 e 3; BJRL, cap. 3 (os mesmos três tipos de modelo, na convenção da lista).

Demonstração minuciosa

Modelo (1): $(1 - 0{,}5L)\tilde{z}_t = \varepsilon_t$

Classificação. O AR tem grau 1 e o MA tem grau 0: **AR(1) = ARMA(1,0)**.

Estacionariedade (AU02, p. 27). $\phi(z) = 1 - 0{,}5z = 0 \Rightarrow z = 1/0{,}5 = 2$. Como $|2| > 1$, a raiz está fora do círculo: **estacionário**.

Invertibilidade. Não há polinômio MA: todo AR puro é invertível (AU02, p. 36).

Pesos ψ (AU02, p. 21). $\Psi(L) = (1 - 0{,}5L)^{-1} = \sum_j 0{,}5^j L^j$ [F2, válido porque $|0{,}5| < 1$]:

$$\psi_1 = 0{,}5; \quad \psi_2 = 0{,}25; \quad \psi_3 = 0{,}125; \quad \psi_4 = 0{,}0625.$$

Pesos π. O modelo já está na forma AR: $\pi(L) = 1 - 0{,}5L$, logo $\pi_1 = 0{,}5$ e $\pi_2 = \pi_3 = \pi_4 = 0$.

Modelo (2): $\tilde{z}_t = (1 - 1{,}3L + 0{,}4L^2)\varepsilon_t$

Classificação. Não há AR, e o MA tem grau 2: **MA(2) = ARMA(0,2)**.

Estacionariedade. Todo MA(q) é estacionário, porque é uma soma finita de choques, com $\sum|\psi_j| = 1 + 1{,}3 + 0{,}4 < \infty$ (AU02, p. 29).

Invertibilidade: Bhaskara em detalhe F1. A condição é que as raízes de $\theta(z) = 1 - 1{,}3z + 0{,}4z^2$ fiquem fora do círculo (AU02, p. 33).

1. **Ponha na forma padrão:** $0{,}4z^2 - 1{,}3z + 1 = 0$, ou seja, $a = 0{,}4$, $b = -1{,}3$ e $c = 1$.
2. **Discriminante:** $\Delta = b^2 - 4ac = (-1{,}3)^2 - 4(0{,}4)(1) = 1{,}69 - 1{,}60 = 0{,}09$.
3. **Raiz do discriminante:** $\sqrt{0{,}09} = 0{,}3$, positivo, então são duas raízes reais.
4. **Raízes:** $z = \frac{-b \pm \sqrt{\Delta}}{2a} = \frac{1{,}3 \pm 0{,}3}{2(0{,}4)} = \frac{1{,}3 \pm 0{,}3}{0{,}8}$, logo
   - $z_1 = \frac{1{,}6}{0{,}8} = 2$;
   - $z_2 = \frac{1{,}0}{0{,}8} = 1{,}25$.
5. **Conferência de Vieta:** soma $z_1 + z_2 = 3{,}25 = -b/a = 1{,}3/0{,}4$ ✓; produto $z_1 z_2 = 2{,}5 = c/a = 1/0{,}4$ ✓.
6. **Conclusão:** $|2| > 1$ e $|1{,}25| > 1$, então o processo é **invertível**.

Fatoração (útil no modelo 3). Raízes 2 e 1,25 correspondem aos fatores $(1 - z/2)$ e $(1 - z/1{,}25)$:

$$1 - 1{,}3L + 0{,}4L^2 = (1 - 0{,}5L)(1 - 0{,}8L).$$

Conferindo por [F8]: $(1 - 0{,}5L)(1 - 0{,}8L) = 1 - 0{,}8L - 0{,}5L + 0{,}4L^2 = 1 - 1{,}3L + 0{,}4L^2$ ✓.

Pesos ψ. O MA já é a forma MA(∞), truncada: $\psi_1 = -1{,}3$, $\psi_2 = 0{,}4$ e $\psi_3 = \psi_4 = 0$.

Pesos π: igualar coeficientes [F7]. Escreva $\theta(L)^{-1} = 1 + c_1 L + c_2 L^2 + \cdots$. Como $\pi(L) = \theta(L)^{-1}$ e $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots$, vale $\pi_j = -c_j$. Exigindo $(1 + c_1 L + c_2 L^2 + \cdots)(1 - 1{,}3L + 0{,}4L^2) = 1$, potência por potência:

Potência	Equação	c_j
L^1	$c_1 - 1{,}3 = 0$	$c_1 = 1{,}3$
L^2	$c_2 - 1{,}3c_1 + 0{,}4 = 0$	$c_2 = 1{,}3(1{,}3) - 0{,}4 = 1{,}69 - 0{,}4 = 1{,}29$
L^3	$c_3 - 1{,}3c_2 + 0{,}4c_1 = 0$	$c_3 = 1{,}3(1{,}29) - 0{,}4(1{,}3) = 1{,}677 - 0{,}52 = 1{,}157$
L^4	$c_4 - 1{,}3c_3 + 0{,}4c_2 = 0$	$c_4 = 1{,}3(1{,}157) - 0{,}4(1{,}29) = 1{,}5041 - 0{,}516 = 0{,}9881$

$$\boxed{\pi_1 = -1{,}3; \quad \pi_2 = -1{,}29; \quad \pi_3 = -1{,}157; \quad \pi_4 = -0{,}9881}$$

Os pesos decaem **devagar**, à taxa $1/1{,}25 = 0{,}8$ por período, porque a raiz 1,25 está perto do círculo unitário. O `ARMAtoMA` do R dá os mesmos valores, com diferença zero.

Modelo (3): $(1 - 0{,}5L)\tilde{z}_t = (1 - 1{,}3L + 0{,}4L^2)\varepsilon_t$

Aparência: ARMA(1,2). Mas a fatoração do modelo (2) mostra um **fator comum**:

$$(1 - 0{,}5L)\tilde{z}_t = (1 - 0{,}5L)(1 - 0{,}8L)\varepsilon_t.$$

Como $|0{,}5| < 1$, $(1 - 0{,}5L)$ é inversível [F2]. Multiplicando os dois lados por $(1 - 0{,}5L)^{-1}$:

$$\boxed{\tilde{z}_t = (1 - 0{,}8L)\varepsilon_t \;:\; \text{MA}(1) = \text{ARMA}(0,1)}$$

Na lista: $\tilde{z}_t = a_t - 0{,}8a_{t-1}$, isto é, $\theta = 0{,}8$ na convenção de Box-Jenkins.

Como enxergar sem fatorar. A raiz do AR, $z = 2$, aparece também entre as raízes do MA, $\{2;\ 1{,}25\}$. Raiz repetida dos dois lados é sinal de fator comum.

- **Estacionário:** é um MA finito.
- **Invertível:** $1 - 0{,}8z = 0 \Rightarrow z = 1{,}25 > 1$.
- **Pesos ψ:** $\psi_1 = -0{,}8$ e $\psi_j = 0$ para $j \geq 2$.
- **Pesos π:** pela AU02, p. 23, $\pi_j = -(-\theta)^j$ com $\theta = -0{,}8$ nos slides, logo $\pi_j = -(0{,}8)^j$:

$$\pi_1 = -0{,}8; \quad \pi_2 = -0{,}64; \quad \pi_3 = -0{,}512; \quad \pi_4 = -0{,}4096.$$

Os ψ_j do modelo (3) escrito "inteiro" e os do MA(1) cancelado coincidem até $j = 20$, com diferença zero no R.

Do meu caderno (03/09)

O caderno escreve um ARMA(1,2) já na notação dos slides: $y_t - \phi_1 B y_t = \theta_1 B\varepsilon_t + \theta_2 B^2\varepsilon_t + \varepsilon_t$, logo $(1 - \phi_1 B)y_t = (1 + \theta_1 B + \theta_2 B^2)\varepsilon_t$. Depois as duas condições: $1 - \phi_1 z = 0$ com $|z| > 1$ (estacionariedade) e $1 + \theta_1 z + \theta_2 z^2 = 0$ com $|z| > 1$ (invertibilidade). O método está certo. No caderno, o polinômio do MA saiu como "$1 + \theta_2 zb + \theta_2 zb^2$"; o certo é $1 + \theta_1 z + \theta_2 z^2$. O caderno usa B com o sinal positivo dos slides: na prova, diga qual convenção está usando.

O que o livro acrescenta

BJRL (cap. 3) e HAMILTON (cap. 3) insistem no **fator comum**: um ARMA(p, q) com fator comum não é identificado. Infinitos pares (ϕ, θ) geram a mesma série, e a estimação fica instável, com erros-padrão enormes e $\hat{\phi} \approx -\hat{\theta}$ nos slides. A regra prática é sempre fatorar antes de classificar.

Armadilhas e variações

- **Bhaskara com o sinal de b trocado.** Em $0{,}4z^2 - 1{,}3z + 1$, $b = -1{,}3$ e $-b = +1{,}3$.
- **Classificar o modelo (3) como ARMA(1,2)** sem fatorar: perde o item inteiro.
- **π_j com o sinal errado.** $\pi(L) = 1 - \pi_1 L - \cdots$ tem o sinal de menos na definição (AU02, p. 19).
- **Variações:** $(1 - 0{,}8L + 0{,}15L^2)$, que também tem fator comum, $1 - 2{,}5L + L^2$, que não é invertível, e $1 - 1{,}2L + 0{,}2L^2$, que tem raiz unitária, no banco.

CAPÍTULO 20

Q6 · ARMA(1,1)

← índice · anterior: Q5 · próxima: Q7 · resolução curta em 02_lista · versão de caderno, linha a linha, em à mão

O que a questão pede

Para o ARMA(1,1) estacionário e invertível:

- **(a) calcular** γ_0, γ_1 e γ_k ($k \geq 2$);
- **(b) obter** ρ_1 e **mostrar** que $\rho_k = \phi^{k-1}\rho_1$;
- **(c) mostrar** as formas AR(∞) e MA(∞) e dizer quando a convergência é mais lenta.

Da lista para os slides

Lista (Box-Jenkins)	Slides (AU02, p. 81)
$z_t - \phi z_{t-1} = a_t - \theta a_{t-1}$	$(z_t - \mu) = \phi_1(z_{t-1} - \mu) + \varepsilon_t + \theta_1 \varepsilon_{t-1}$

Nos slides, $\theta_1 = -\theta$ (lista) e $\phi_1 = \phi$. Abaixo, escrevo ϕ e θ **na convenção dos slides** e uso $\tilde{z}_t = z_t - \mu$. Cada resultado final aparece também na forma da lista.

Ferramentas

- **Slides:** AU02, p. 82–83 (γ_0 com a expansão do quadrado), p. 84 (γ_k), p. 87 (o ARMA(p, q) geral); AU02, p. 43 ($\Psi = \Theta/\Phi$).
- **Caixa:** [F4]; [F5]; [F6] momentos auxiliares; [F7] igualar coeficientes.
- **Livro:** HAMILTON, cap. 3 (ARMA(1,1)); BJRL, cap. 3 (as mesmas fórmulas na convenção da lista); ENDERS, cap. 2.

Demonstração minuciosa

Passo 0 — Os dois momentos auxiliares [F6]

Todo o resto depende destes dois:

- $E(\varepsilon_t \tilde{z}_t) = E\big(\varepsilon_t(\phi\tilde{z}_{t-1} + \varepsilon_t + \theta\varepsilon_{t-1})\big) = \phi \cdot 0 + \sigma^2 + \theta \cdot 0 = \sigma^2$. Os zeros vêm de: $\tilde{z}_{t-1}$ não depende de ε_t (causalidade), e $E(\varepsilon_t \varepsilon_{t-1}) = 0$ (RB).
- $E(\varepsilon_{t-1}\tilde{z}_t) = E\big(\varepsilon_{t-1}(\phi\tilde{z}_{t-1} + \varepsilon_t + \theta\varepsilon_{t-1})\big) = \phi E(\varepsilon_{t-1}\tilde{z}_{t-1}) + 0 + \theta\sigma^2 = \phi\sigma^2 + \theta\sigma^2 = (\phi + \theta)\sigma^2$. Usei o primeiro momento, deslocado um período.

(a) γ_0 — expandindo o quadrado (AU02, p. 82–83)

$\gamma_0 = E(\tilde{z}_t^2) = E\big((\phi\tilde{z}_{t-1} + \varepsilon_t + \theta\varepsilon_{t-1})^2\big)$. Pelo quadrado de três parcelas, $(A + B + C)^2 = A^2 + B^2 + C^2 + 2AB + 2AC + 2BC$:

Termo	Esperança	Por quê
$A^2 = \phi^2 \tilde{z}_{t-1}^2$	$\phi^2 \gamma_0$	estacionariedade: $E(\tilde{z}_{t-1}^2) = \gamma_0$
$B^2 = \varepsilon_t^2$	σ^2	RB
$C^2 = \theta^2 \varepsilon_{t-1}^2$	$\theta^2 \sigma^2$	RB
$2AB = 2\phi \tilde{z}_{t-1} \varepsilon_t$	0	causalidade [F6]
$2AC = 2\phi\theta \tilde{z}_{t-1} \varepsilon_{t-1}$	$2\phi\theta\sigma^2$	primeiro momento auxiliar, deslocado
$2BC = 2\theta \varepsilon_t \varepsilon_{t-1}$	0	RB

Somando: $\gamma_0 = \phi^2 \gamma_0 + \sigma^2 + \theta^2 \sigma^2 + 2\phi\theta\sigma^2$. Passe $\phi^2 \gamma_0$ para a esquerda e divida por $1 - \phi^2$ (que é diferente de zero, porque $|\phi| < 1$):

$$\boxed{\gamma_0 = \frac{1 + 2\phi\theta + \theta^2}{1 - \phi^2} \sigma^2} \qquad \text{(lista: } \gamma_0 = \tfrac{1+\theta^2-2\phi\theta}{1-\phi^2}\sigma^2\text{)}$$

(a) γ_1 (AU02, p. 84)

Multiplique o modelo por $\tilde{z}_{t-1}$ e tire a esperança:

$$\gamma_1 = \phi E(\tilde{z}_{t-1}^2) + E(\varepsilon_t \tilde{z}_{t-1}) + \theta E(\varepsilon_{t-1} \tilde{z}_{t-1}) = \phi\gamma_0 + 0 + \theta\sigma^2.$$

Substituindo γ_0 e pondo tudo sobre $1 - \phi^2$:

$$\gamma_1 = \frac{\phi(1 + 2\phi\theta + \theta^2) + \theta(1 - \phi^2)}{1 - \phi^2}\sigma^2 = \frac{\phi + 2\phi^2\theta + \phi\theta^2 + \theta - \phi^2\theta}{1 - \phi^2}\sigma^2 = \frac{\phi + \theta + \phi^2\theta + \phi\theta^2}{1 - \phi^2}\sigma^2.$$

O numerador fatora: $(1 + \phi\theta)(\phi + \theta) = \phi + \theta + \phi^2\theta + \phi\theta^2$ ✓ [F8]. Logo

$$\boxed{\gamma_1 = \frac{(1 + \phi\theta)(\phi + \theta)}{1 - \phi^2}\sigma^2} \qquad \text{(lista: } \gamma_1 = \tfrac{(1-\phi\theta)(\phi-\theta)}{1-\phi^2}\sigma^2\text{)}$$

(a) γ_k para $k \geq 2$

Multiplique por $\tilde{z}_{t-k}$:

$$\gamma_k = \phi\gamma_{k-1} + E(\varepsilon_t \tilde{z}_{t-k}) + \theta E(\varepsilon_{t-1} \tilde{z}_{t-k}).$$

Com $k \geq 2$, $\tilde{z}_{t-k}$ só depende de choques até $t - k \leq t - 2$, anteriores a $t - 1$ e a t: as duas esperanças são zero [F6]. Logo:

$$\boxed{\gamma_k = \phi\gamma_{k-1} \quad (k \geq 2) \qquad \Longrightarrow \qquad \gamma_k = \phi^{k-1}\gamma_1}$$

A última passagem é por indução: $\gamma_2 = \phi\gamma_1$, $\gamma_3 = \phi\gamma_2 = \phi^2\gamma_1$, e assim por diante.

(b) FAC

Dividindo por γ_0, o σ^2 e o $1-\phi^2$ cancelam:

$$\boxed{\rho_1 = \frac{(1+\phi\theta)(\phi+\theta)}{1+2\phi\theta+\theta^2}, \qquad \rho_k = \phi\rho_{k-1} = \phi^{k-1}\rho_1 \;\; (k \geq 1)}$$

Na lista: $\rho_1 = \frac{(1-\phi\theta)(\phi-\theta)}{1+\theta^2-2\phi\theta}$.

Leitura: a FAC do ARMA(1,1) **decai geometricamente como a de um AR(1), mas a partir de ρ_1, e não de 1**. O MA só mexe no primeiro valor (AU02, p. 87: para $k \geq q+1$, vale a recursão do AR).

Números, com $\phi = 0{,}7$ e $\theta^{\text{lista}} = 0{,}4$, isto é, $\theta = -0{,}4$ nos slides, e $\sigma^2 = 1$:

- $\gamma_0 = \frac{1+2(0{,}7)(-0{,}4)+0{,}16}{1-0{,}49} = \frac{1-0{,}56+0{,}16}{0{,}51} = \frac{0{,}60}{0{,}51} = 1{,}1765$;
- $\gamma_1 = 0{,}7(1{,}1765) - 0{,}4 = 0{,}4235$;
- $\rho_1 = 0{,}36$, $\rho_2 = 0{,}252$, $\rho_3 = 0{,}1764$: cada um é 0,7 vezes o anterior.

(c) MA(∞) e AR(∞)

MA(∞) [F7]. $\Psi(L) = \frac{1+\theta L}{1-\phi L}$, então $\Psi(L)(1-\phi L) = 1+\theta L$. Igualando as potências:

- L^1: $\psi_1 - \phi = \theta$, logo $\psi_1 = \phi + \theta$;
- L^j, $j \geq 2$: $\psi_j - \phi\psi_{j-1} = 0$, logo $\psi_j = \phi\psi_{j-1}$.

$$\boxed{\psi_j = (\phi+\theta)\phi^{j-1}} \qquad \text{(lista: } (\phi-\theta)\phi^{j-1}\text{)}$$

AR(∞). $\pi(L) = \frac{1-\phi L}{1+\theta L}$, então $\pi(L)(1+\theta L) = 1-\phi L$, com $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots$:

- L^1: $\theta - \pi_1 = -\phi$, logo $\pi_1 = \phi + \theta$;
- L^j, $j \geq 2$: $-\pi_j - \theta\pi_{j-1} = 0$, logo $\pi_j = -\theta\pi_{j-1}$.

$$\boxed{\pi_j = (\phi+\theta)(-\theta)^{j-1}} \qquad \text{(lista: } (\phi-\theta)\theta^{j-1}\text{)}$$

Com os mesmos números: $\psi_1, \psi_2, \psi_3 = 0{,}3;\ 0{,}21;\ 0{,}147$ e $\pi_1, \pi_2, \pi_3 = 0{,}3;\ 0{,}12;\ 0{,}048$.

Quando a convergência é mais lenta.

- Os ψ_j decaem como $|\phi|^j$: **mais devagar quanto mais perto de 1 estiver** $|\phi|$. Com $\phi = 0{,}95$, são precisos 80 pesos até $|\psi_j| < 0{,}01$; com $\phi = 0{,}3$, bastam 3.
- Os π_j decaem como $|\theta|^j$: mais devagar quanto mais perto de 1 estiver $|\theta|$, isto é, perto da não invertibilidade.

Do meu caderno (02/09)

O caderno segue exatamente o roteiro da AU02, p. 81–84:

- $E(y_t \mid \Omega_{t-1}) = c + \phi_1 y_{t-1} + \theta_1 \varepsilon_{t-1}$ e $V(y_t \mid \Omega_{t-1}) = \sigma^2$, certos;
- $\mu = c/(1-\phi_1)$, certo;
- os momentos auxiliares $E(\varepsilon_t\varepsilon_t) = \sigma^2$, $E((y_t-\mu)\varepsilon_t)$, $E((y_{t+1}-\mu)\varepsilon_t)$, certos.

Dois erros do caderno nesta questão

1. Na linha certa, $\gamma_0 = \phi_1^2\gamma_0 + \theta_1^2\sigma^2 + \sigma^2 + 2\phi_1\theta_1\sigma^2$, o θ_1 está ao quadrado. Duas linhas depois, o resultado final aparece como $\gamma_0 = \frac{\sigma^2(\theta_1+1+2\theta_1\phi_1)}{1-\phi_1^2}$: **o quadrado sumiu**. Com $\phi = 0{,}7$ e $\theta = -0{,}4$, a fórmula do caderno dá 0,0784, quando o certo é 1,1765.
2. "$\gamma_k = \phi_1^k\gamma_1$ para $k \geq 2$" está errado: o certo é $\gamma_k = \phi_1^{k-1}\gamma_1$. Confira com $k = 2$: $\gamma_2 = \phi_1\gamma_1$, um único ϕ_1.

É o erro "A, álgebra" do log: a linha intermediária estava certa, e o erro entrou ao copiar.

O que o livro acrescenta

BJRL (cap. 3) mostra o ARMA(1,1) como o caso em que **nem a FAC nem a FACP cortam**: as duas decaem. É por isso que ele é tão usado como "modelo de bolso" quando a identificação pela FAC e pela FACP fica ambígua (AU02, p. 96–97).

Armadilhas e variações

- **Misturar as convenções:** usar $\phi - \theta$ (lista) numa conta feita com o sinal dos slides.
- **Esquecer o termo cruzado** $2\phi\theta\sigma^2$ em γ_0: é ele que exige o segundo momento auxiliar.
- **Variações:** $\phi = 0{,}9$ e $\theta = 0{,}5$; $\phi = \theta$, que é ruído branco; e a versão com sinal positivo, no banco. Simulados: S01, Q2 e S03, Q2.

CAPÍTULO 21

Q7 · AR(2): Yule-Walker e variância

← índice · anterior: Q6 · próxima: Q8 · resolução curta em 02_lista

O que a questão pede

Para $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$:

- **(a) escrever** as equações de Yule-Walker e **resolvê-las** para ρ_1 e ρ_2;
- **(b) calcular** a variância γ_0.

Acrescento o que a prova costuma pedir junto: a **condição de estacionariedade** pelas raízes, com Bhaskara, e o exemplo numérico do meu caderno, refeito.

Da lista para os slides

Mesma notação: $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$, ou $(1 - \phi_1 L - \phi_2 L^2) y_t = \varepsilon_t$ (AU02, p. 12). Não há MA.

Ferramentas

- **Slides:** AU02, p. 68–69 (Yule-Walker), p. 27–28 (raízes z × autovalores λ), p. 37–41 (forma F e as três desigualdades do AR(2)), p. 92 (FACP); EQD, p. 24–26 (equação característica de segunda ordem e os três casos de raízes).
- **Caixa:** F1 Bhaskara e módulo de complexos; [F6] causalidade.
- **Livro:** ENDERS, cap. 1 (equação de segunda ordem, raízes complexas e ciclos) e cap. 2; HAMILTON, cap. 1–3.

Demonstração minuciosa

(a) Yule-Walker (AU02, p. 68)

Multiplique o modelo por y_{t-k}, com $k \geq 1$, e tire a esperança. Com média zero, $E(y_t y_{t-k}) = \gamma_k$:

$$\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} + \underbrace{E(\varepsilon_t y_{t-k})}_{=0 \text{ [F6]}} \quad (k \geq 1).$$

Divida por γ_0:

$$\boxed{\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} \quad (k \geq 1)}$$

Use $\rho_0 = 1$ e a simetria $\rho_{-k} = \rho_k$:

- $k = 1$**:** $\rho_1 = \phi_1 \rho_0 + \phi_2 \rho_{-1} = \phi_1 + \phi_2 \rho_1$. Passando $\phi_2 \rho_1$ para a esquerda, $\rho_1(1 - \phi_2) = \phi_1$, e

$$\boxed{\rho_1 = \frac{\phi_1}{1 - \phi_2}}$$

- $k = 2$**:** $\rho_2 = \phi_1 \rho_1 + \phi_2 \rho_0 = \phi_1 \rho_1 + \phi_2$. Substituindo ρ_1:

$$\boxed{\rho_2 = \frac{\phi_1^2}{1-\phi_2} + \phi_2 = \frac{\phi_1^2 + \phi_2(1-\phi_2)}{1-\phi_2}}$$

(b) Variância γ_0

Multiplique o modelo por y_t, o caso $k = 0$:

$$\gamma_0 = \phi_1\gamma_1 + \phi_2\gamma_2 + E(\varepsilon_t y_t) = \phi_1\gamma_1 + \phi_2\gamma_2 + \sigma^2.$$

Usei $E(\varepsilon_t y_t) = \psi_0\sigma^2 = \sigma^2$ [F6]. Troque $\gamma_k = \rho_k\gamma_0$ e isole γ_0:

$$\gamma_0(1 - \phi_1\rho_1 - \phi_2\rho_2) = \sigma^2 \quad \Longrightarrow \quad \boxed{\gamma_0 = \frac{\sigma^2}{1 - \phi_1\rho_1 - \phi_2\rho_2}}$$

Forma fechada. Substitua ρ_1 e ρ_2 no denominador. Tudo sobre $1-\phi_2$:

$$1 - \phi_1\rho_1 - \phi_2\rho_2 = \frac{(1-\phi_2) - \phi_1^2 - \phi_2\phi_1^2 - \phi_2^2(1-\phi_2)}{1-\phi_2}.$$

Agrupando o numerador:

- $(1-\phi_2) - \phi_2^2(1-\phi_2) = (1-\phi_2)(1-\phi_2^2) = (1-\phi_2)(1-\phi_2)(1+\phi_2) = (1+\phi_2)(1-\phi_2)^2$;
- $-\phi_1^2 - \phi_2\phi_1^2 = -\phi_1^2(1+\phi_2)$.

Logo o numerador é $(1+\phi_2)\big[(1-\phi_2)^2 - \phi_1^2\big]$ e

$$\boxed{\gamma_0 = \frac{(1-\phi_2)\,\sigma^2}{(1+\phi_2)\big[(1-\phi_2)^2 - \phi_1^2\big]}}$$

Números, com $\phi_1 = 0{,}6$, $\phi_2 = 0{,}2$ e $\sigma^2 = 1$:

- $\rho_1 = 0{,}6/0{,}8 = 0{,}75$;
- $\rho_2 = 0{,}6(0{,}75) + 0{,}2 = 0{,}65$;
- $\gamma_0 = \frac{0{,}8}{1{,}2\,(0{,}64-0{,}36)} = \frac{0{,}8}{0{,}336} = 2{,}381$. Pela outra forma, $1/(1-0{,}45-0{,}13) = 1/0{,}42 = 2{,}381$ ✓.

Complemento — estacionariedade pelas raízes, com Bhaskara

A condição é que as raízes de $\phi(z) = 1 - \phi_1 z - \phi_2 z^2$ fiquem fora do círculo (AU02, p. 27). Com os números acima:

1. $1 - 0{,}6z - 0{,}2z^2 = 0$. Multiplicando por -1: $0{,}2z^2 + 0{,}6z - 1 = 0$, ou seja, $a = 0{,}2$, $b = 0{,}6$ e $c = -1$.
2. $\Delta = 0{,}6^2 - 4(0{,}2)(-1) = 0{,}36 + 0{,}80 = 1{,}16$.
3. $z = \frac{-0{,}6 \pm \sqrt{1{,}16}}{0{,}4} = \frac{-0{,}6 \pm 1{,}0770}{0{,}4}$, logo $z_1 = 1{,}1926$ e $z_2 = -4{,}1926$.
4. As duas têm módulo maior que 1: **estacionário**.

Na prova, há um atalho: as três desigualdades da AU02, p. 41. Aqui, $\phi_1 + \phi_2 = 0{,}8 < 1$, $\phi_2 - \phi_1 = -0{,}4 < 1$ e $|\phi_2| = 0{,}2 < 1$.

Do meu caderno (02/09 e 03/09) — o exemplo refeito

02/09. O caderno escreve o AR(2) em desvios, multiplica por $(y_{t-k} - \mu)$ e chega a $\gamma_k = \phi_1\gamma_{k-1} + \phi_2\gamma_{k-2}$, com $\gamma_1 = \phi_1\gamma_0 + \phi_2\gamma_1$, $\gamma_2 = \phi_1\gamma_1 + \phi_2\gamma_0$ e $\gamma_0 = \phi_1\gamma_1 + \phi_2\gamma_2 + \sigma^2$. Tudo certo: são as equações acima, antes de dividir por γ_0. O caderno também tem a FACP, $\rho_1 = \phi_1 + \phi_2\rho_1$ e $\rho_2 = \phi_1\rho_1 + \phi_2$ (AU02, p. 92 e 94), e a forma F do AR(2) com $\det(F - \lambda I) = \lambda^2 - \phi_1\lambda - \phi_2$, também certas.

03/09. O exemplo $y_t = 1{,}5y_{t-1} - 0{,}6y_{t-2} + a_t$, com Bhaskara. **O caderno erra o sinal logo no primeiro passo.** Refazendo do zero:

1. **Passe todos os termos em y para a esquerda:** $y_t - 1{,}5y_{t-1} + 0{,}6y_{t-2} = a_t$, logo $(1 - 1{,}5L + 0{,}6L^2)y_t = a_t$.

   Os coeficientes são $\phi_1 = 1{,}5$ e $\phi_2 = -0{,}6$, e no polinômio entra $-\phi_2 L^2 = +0{,}6L^2$. O caderno escreveu $-0{,}6B^2$.
2. **Equação característica**, a dos autovalores λ (AU02, p. 28): $\lambda^2 - \phi_1\lambda - \phi_2 = 0$, ou seja, $\lambda^2 - 1{,}5\lambda + 0{,}6 = 0$. O caderno escreveu $-0{,}6$.
3. **Discriminante:** $\Delta = (-1{,}5)^2 - 4(1)(0{,}6) = 2{,}25 - 2{,}40 = -0{,}15$. É negativo, então as raízes são complexas (EQD, p. 25, caso 3).
4. **Raiz de um número negativo:** $\sqrt{-0{,}15} = i\sqrt{0{,}15} = 0{,}3873\,i$.
5. **Raízes:** $\lambda = \frac{1{,}5 \pm 0{,}3873\,i}{2} = 0{,}75 \pm 0{,}1936\,i$.
6. **Módulo** F1: $|\lambda| = \sqrt{0{,}75^2 + 0{,}1936^2} = \sqrt{0{,}5625 + 0{,}0375} = \sqrt{0{,}6} = 0{,}7746$.
   - As **duas** conjugadas têm o mesmo módulo, 0,7746.
   - Atalho de Vieta: $|\lambda|^2 = c/a = 0{,}6$.
7. **Conclusão:** $|\lambda| = 0{,}7746 < 1$, dentro do círculo, o que equivale a $|z| = 1/0{,}7746 = 1{,}2910 > 1$, fora (AU02, p. 28). **Estacionário.** O maior autovalor da matriz F, calculado no R, é 0,7746 ✓.
8. **Conferência pelas desigualdades:** $\phi_1 + \phi_2 = 0{,}9 < 1$, $\phi_2 - \phi_1 = -2{,}1 < 1$ e $|\phi_2| = 0{,}6 < 1$ ✓.
9. **O que as raízes complexas significam:** a FAC e as respostas a choques são uma **senoide amortecida**. O processo tem um pseudociclo que encolhe à taxa 0,7746 por período.

> **O que o caderno errou neste exemplo**
>
> - **Sinal do polinômio:** escreveu $1 - 1{,}5B - 0{,}6B^2$ e $\lambda^2 - 1{,}5\lambda - 0{,}6$. Com esse sinal, Δ seria $2{,}25 + 2{,}4 = 4{,}65$, positivo, e as raízes seriam reais.
> - **Δ:** escreveu $\Delta = 0{,}15$, positivo, e logo depois $\sqrt{-0{,}15}$. O certo é $\Delta = -0{,}15$.
> - **Parte imaginária:** escreveu $\frac{1{,}5 \pm 0{,}15i}{2}$, quando o certo é $\frac{1{,}5 \pm \sqrt{0{,}15}\,i}{2}$. Ainda assim, chegou a $0{,}75 \pm 0{,}19i$, que está certo.
> - **Módulos:** escreveu $\lambda_1 = \sqrt{0{,}75^2 + 0{,}19^2} \approx 0{,}6$, mas 0,6 é o **quadrado** do módulo; o módulo é 0,7746. E escreveu $\lambda_2 = \sqrt{0{,}75 - 0{,}19^2} \approx 0{,}52$, uma fórmula que não existe (daria 0,8449). As conjugadas têm o mesmo módulo.
>
> A conclusão "estacionário" estava certa por acaso. Numa prova que pede o módulo, perdem-se os pontos da conta.

O que o livro acrescenta

ENDERS (cap. 1) e a revisão EQD (p. 25) dão a leitura das raízes complexas: escrevendo $\lambda = r(\cos\omega \pm i\sin\omega)$, o módulo r diz se o ciclo amortece ($r < 1$) ou explode, e ω dá o período, $2\pi/\omega$. No exemplo, $\cos\omega = 0{,}75/0{,}7746$, logo $\omega \approx 0{,}2527$ rad, e o período é de $2\pi/\omega \approx 24{,}87$ observações.

Armadilhas e variações

- **Confundir z e λ:** "raízes fora" vale para z, "dentro" vale para λ. Diga qual está usando.
- $\rho_2 = \phi_2$**:** errado. Quem é igual a ϕ_2 é a **FACP** em 2, ϕ_{22} (AU02, p. 92).
- **Variações:** $\phi = (1;\ -0{,}5)$, com raízes complexas e ciclo de 8 períodos, no banco; $\phi = (0{,}5;\ 0{,}3)$ completo no Simulado 02, Q2.

CAPÍTULO 22

Q8 · Verdadeiro ou falso, com demonstração

← índice · anterior: Q7 · próxima: Q9 · resolução curta em 02_lista

O que a questão pede

Julgar cinco afirmativas, **com demonstração**, sobre dois modelos:

- **(I)** ARMA(1,1), com $\gamma_h = E(Y_t Y_{t+h})$;
- **(II)** passeio com drift c e tendência θt.

Da lista para os slides

A Q8 é a única questão da lista que **já usa o sinal positivo dos slides**:

Lista	Slides
(I) $Y_t = \alpha Y_{t-1} + u_t + \beta u_{t-1}$, $0 < \alpha < 1$, Y_0 fixo	$y_t = \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$ (AU02, p. 81), com $\phi_1 = \alpha$ e $\theta_1 = \beta$
(II) $Z_t = c + Z_{t-1} + \theta t + \varepsilon_t$	$Y_t = \alpha_1 + Y_{t-1} + \alpha_2 t + \varepsilon_t$ (AU01, p. 30), com $\alpha_1 = c$ e $\alpha_2 = \theta$

Mantenho as letras da lista, α e β, porque é nelas que as afirmativas estão escritas. Como Y_0 é fixo, o processo (I) só é estacionário depois que o efeito do valor inicial, $\alpha^t Y_0$, some. As afirmativas tratam dos momentos estacionários.

Ferramentas

- **Slides:** AU02, p. 83–84 (γ_0 e γ_1 do ARMA(1,1) com sinal positivo); AU01, p. 30.
- **Caixa:** [F3]; [F6] momentos auxiliares $E(Y_t u_t) = \sigma^2$ e $E(Y_t u_{t-1}) = (\alpha + \beta)\sigma^2$.
- **Livro:** HAMILTON, cap. 3.

Os momentos auxiliares (valem para 1 a 3)

- $E(Y_t u_t) = E\big((\alpha Y_{t-1} + u_t + \beta u_{t-1}) u_t\big) = 0 + \sigma^2 + 0 = \sigma^2$.
- $E(Y_t u_{t-1}) = E\big((\alpha Y_{t-1} + u_t + \beta u_{t-1}) u_{t-1}\big) = \alpha\sigma^2 + 0 + \beta\sigma^2 = (\alpha + \beta)\sigma^2$.

As cinco afirmativas

1. $\gamma_0 = \alpha\gamma_1 + \sigma^2 + \beta(\alpha+\beta)\sigma^2$ — VERDADEIRA

Multiplique o modelo por Y_t e tire a esperança:

$$\gamma_0 = E(Y_tY_t) = \alpha E(Y_{t-1}Y_t) + E(u_tY_t) + \beta E(u_{t-1}Y_t) = \alpha\gamma_1 + \sigma^2 + \beta(\alpha+\beta)\sigma^2.$$

$E(Y_{t-1}Y_t) = \gamma_1$ pela definição $\gamma_h = E(Y_tY_{t+h})$, e os outros dois termos são os momentos auxiliares. **É exatamente a afirmativa.**

Com $\alpha = 0{,}6$, $\beta = 0{,}3$ e $\sigma^2 = 1$: $\gamma_0 = 2{,}265625$, e o lado direito dá $0{,}6(1{,}659375) + 1 + 0{,}3(0{,}9) = 2{,}265625$ ✓.

2. $\gamma_1 = \alpha(\gamma_0 + \sigma^2) + \beta\sigma^2$ — FALSA

Multiplique o modelo de Y_{t+1} por Y_t:

$$\gamma_1 = E(Y_{t+1}Y_t) = \alpha E(Y_tY_t) + E(u_{t+1}Y_t) + \beta E(u_tY_t) = \alpha\gamma_0 + 0 + \beta\sigma^2.$$

O zero vem de u_{t+1}, que é futuro em relação a Y_t [F6]. Logo $\gamma_1 = \alpha\gamma_0 + \beta\sigma^2$ (AU02, p. 84). A afirmativa tem um $\alpha\sigma^2$ **a mais**. Com os números: o certo é 1,659375, e a afirmativa dá 2,259375.

3. $\rho_h = \frac{(\beta+\alpha)(1+\alpha\beta)}{1+2\alpha\beta+\beta^2}$ — FALSA (só vale para $h = 1$)

Resolvendo o sistema das afirmativas 1 e 2 (a versão corrigida da 2), como na Q6:

$$\gamma_0 = \frac{1+2\alpha\beta+\beta^2}{1-\alpha^2}\sigma^2, \qquad \gamma_1 = \frac{(1+\alpha\beta)(\alpha+\beta)}{1-\alpha^2}\sigma^2 \quad\Longrightarrow\quad \rho_1 = \frac{(\alpha+\beta)(1+\alpha\beta)}{1+2\alpha\beta+\beta^2}.$$

Para $h \geq 2$, porém, $\gamma_h = \alpha\gamma_{h-1}$, porque os choques de Y_{t+h} não se cruzam com Y_t. Logo $\rho_h = \alpha^{h-1}\rho_1$, que **muda com** h. A afirmativa escreve uma expressão que não depende de h. Com os números: $\rho_1 = 0{,}7324$, que coincide com a expressão, mas $\rho_2 = 0{,}4394 \neq 0{,}7324$.

4. $Z_t = ct + \frac{\theta}{2}t^2 + Z_0 + \sum_{j=1}^{t}\varepsilon_j$ — FALSA

Somando a equação de 1 a t, como na Q2:

$$Z_t = Z_0 + ct + \theta\sum_{s=1}^{t} s + \sum_{j=1}^{t}\varepsilon_j = Z_0 + ct + \theta\frac{t(t+1)}{2} + \sum_{j=1}^{t}\varepsilon_j \quad \text{[F3]}.$$

A afirmativa troca $\frac{t(t+1)}{2} = \frac{t^2}{2} + \frac{t}{2}$ por $\frac{t^2}{2}$: falta $\frac{\theta t}{2}$. Com $c = 1$, $\theta = 0{,}5$ e $Z_0 = 0$: $E(Z_4) = 4 + 0{,}5 \cdot 10 = 9$, enquanto a afirmativa dá $4 + 0{,}25 \cdot 16 = 8$.

5. $V(Z_t) = (c + \theta t)\sigma^2$ — FALSA

Pela afirmativa 4 corrigida, a única parte aleatória é $\sum_{j=1}^{t}\varepsilon_j$, e Z_0, ct e $\theta t(t+1)/2$ são constantes. Logo $V(Z_t) = V\big(\sum\varepsilon_j\big) = t\sigma^2$ [F5]. **Drift e tendência não têm variância.**

Gabarito: V, F, F, F, F.

Do meu caderno (02/09)

Os momentos auxiliares desta questão são os do caderno: "$E((y_t - \mu)\varepsilon_t) = \sigma^2$" e "$E((y_{t+1} - \mu)\varepsilon_t) = \phi_1\sigma^2$". O caderno os escreve para o **AR(1)**. No ARMA(1,1), o segundo vira $(\phi_1 + \theta_1)\sigma^2$, por causa do termo MA. Ver a correção do γ_0 do caderno na Q6.

Armadilhas e variações

- **Responder V ou F sem a conta.** Vale zero quando o enunciado diz "com demonstração". É a lição da Q5 da P1 de Econometria I: a conclusão é a última linha, não a única.
- **Achar que a Q8 está na convenção da lista.** Ela está na dos slides: $+\beta$.
- **Variações:** o mesmo V ou F com outros itens (os π_j com sinal alternado e a invertibilidade dependendo de β) no Simulado 03, Q2; $E(Z_4)$ no banco.

Bloco 2 — AR, MA e ARMA

Q5 · Classificar, raízes e pesos

Ideia: fatorar os polinômios, olhar as raízes e **procurar fator comum**. Resolução em 02_lista · ENDERS cap. 2 · BJRL cap. 3.

Variação A. $(1 - 0{,}8B + 0{,}15B^2)z_t = (1 - 0{,}3B)a_t$. **Resposta.** $1 - 0{,}8B + 0{,}15B^2 = (1 - 0{,}5B)(1 - 0{,}3B)$, com raízes 2 e 3,3333. O fator $(1 - 0{,}3B)$ cancela: é um **AR(1)** com $\phi = 0{,}5$, disfarçado de ARMA(2,1).

Variação B. $z_t = (1 - 2{,}5B + B^2)a_t$. **Resposta.** $(1 - 0{,}5B)(1 - 2B)$, com raízes 2 e 0,5. A raiz 0,5 está **dentro** do círculo: o MA(2) é estacionário, mas **não invertível**.

Variação C. $(1 - 1{,}2B + 0{,}2B^2)z_t = a_t$. **Resposta.** $(1 - B)(1 - 0{,}2B)$, com raízes 1 e 5. Há **raiz unitária**: não é estacionário. É um ARIMA(1,1,0), com $(1 - 0{,}2B)\Delta z_t = a_t$.

Q6 · ARMA(1,1)

Ideia: dois momentos auxiliares, $E(z_t a_t)$ e $E(z_t a_{t-1})$, e um sistema 2×2 para γ_0 e γ_1. Resolução em 02_lista · HAMILTON cap. 3.

Variação A. BJ, com $\phi = 0{,}9$ e $\theta = 0{,}5$. **Resposta.** $\rho_1 = \frac{(1-\phi\theta)(\phi-\theta)}{1+\theta^2-2\phi\theta} = \frac{0{,}55 \cdot 0{,}4}{0{,}35} = 0{,}6286$ e $\rho_2 = 0{,}5657$. A FAC decai devagar porque ϕ está perto de 1.

Variação B. E se $\phi = \theta$? **Resposta.** Os fatores cancelam: $z_t = a_t$, e $\rho_1 = 0$. É ruído branco. Na estimação, isso aparece como $\hat{\phi} \approx \hat{\theta}$ com erros-padrão enormes.

Variação C. Mesmas fórmulas na convenção de sinal positivo? **Resposta.** Troque $\theta \to -\theta$: $\gamma_0 = \frac{1+2\phi\theta+\theta^2}{1-\phi^2}\sigma^2$ e $\psi_j = (\phi + \theta)\phi^{j-1}$. Ver o Simulado 03, Q2.

Q7 · AR(2) e Yule-Walker

Ideia: $\rho_k = \phi_1\rho_{k-1} + \phi_2\rho_{k-2}$ e $\gamma_0 = \sigma^2/(1 - \phi_1\rho_1 - \phi_2\rho_2)$. Resolução em 02_lista e D02.3 · ENDERS cap. 2.

Variação A. $\phi_1 = 1$ e $\phi_2 = -0{,}5$. **Resposta.**

- $\rho_1 = 1/1{,}5 = 0{,}6667$ e $\rho_2 = 0{,}6667 - 0{,}5 = 0{,}1667$.
- $\gamma_0 = \frac{1{,}5}{0{,}5\,(2{,}25-1)} = 2{,}4$.
- As raízes são complexas, com módulo $1{,}4142 > 1$: o processo é estacionário, e a FAC é uma **senoide amortecida**.
- $\cos\omega = \phi_1/(2\sqrt{-\phi_2}) = 0{,}7071$, logo $\omega = \pi/4$, e o ciclo tem período de **8** períodos (D02.4).

Variação B. Como se reconhece um AR(2) na FACP? **Resposta.** $\phi_{11} = \rho_1$, $\phi_{22} = (\rho_2 - \rho_1^2)/(1 - \rho_1^2) = \phi_2$, e $\phi_{kk} = 0$ para $k \geq 3$.

Q8 · Verdadeiro ou falso

Ideia: cada afirmativa pede a conta. **A Q8 usa sinal positivo.** Resolução em 02_lista.

Variação A. No modelo (II), com $c = 1$, $\theta = 0{,}5$ e $Z_0 = 0$, quanto vale $E(Z_4)$? Confira a afirmativa 4 da lista. **Resposta.** $Z_t = Z_0 + ct + \theta\sum_{s=1}^{t} s + \sum \varepsilon_j$, logo $E(Z_4) = 4 + 0{,}5 \cdot 10 = 9$. A fórmula da afirmativa, com $\frac{\theta}{2}t^2$, dá 8: **falsa**, porque $\sum s = t(t+1)/2$, e não $t^2/2$.

Variação B. A variância do modelo (II) depende de c ou de θ? **Resposta.** Não: $\text{Var}(Z_t) = t\sigma^2$. Constantes e tendências determinísticas não têm variância (afirmativa 5: falsa).

D02.4 · Equações de diferenças: a mesma conta da estacionariedade

O que se quer provar

A parte determinística de um AR é uma equação de diferenças (revisão EQD; Chiang e Wainwright, caps. 17–18).

- Na equação de diferenças de primeira ordem $y_{t+1} + ay_t = c$, a solução converge se e somente se $|a| < 1$.
- Na de segunda ordem, $y_{t+2} + a_1 y_{t+1} + a_2 y_t = c$, a solução converge se e somente se as raízes da equação característica $b^2 + a_1 b + a_2 = 0$ têm $|b| < 1$. Essas raízes são as **inversas** das raízes de $\phi(z)$, então a condição é a de D02.1.

Passo a passo.

1. **Solução geral = particular + homogênea.** A particular é qualquer solução da equação completa. A homogênea resolve a equação com $c = 0$ e carrega a constante que a condição inicial fixa.
2. **Primeira ordem, particular.** Tente $y_t = k$: $k + ak = c$, então $y_p = c/(1 + a)$ se $a \neq -1$. Se $a = -1$, tente $y_t = kt$: $k(t + 1) - kt = c$, então $y_p = ct$, que é a tendência linear do passeio com drift.
3. **Primeira ordem, homogênea.** Tente $y_t = Ab^t$: $Ab^{t+1} + aAb^t = 0$, então $b = -a$. Com y_0 dado, $A = y_0 - y_p$:
$$y_t = \left(y_0 - \tfrac{c}{1+a}\right)(-a)^t + \tfrac{c}{1+a}.$$
O método iterativo, substituir $y_1, y_2, \ldots$ um a um, chega na mesma fórmula.
4. **Estabilidade.** O termo Ab^t some se e somente se $|b| < 1$. Com $b < 0$, a trajetória oscila; com $b > 0$, é monótona.
5. **Segunda ordem.** A particular é $y_p = c/(1 + a_1 + a_2)$. A homogênea tenta Ab^t e chega à equação característica $b^2 + a_1 b + a_2 = 0$. Com raízes distintas, $y_t = A_1 b_1^t + A_2 b_2^t + y_p$.
   - Se o discriminante $a_1^2 - 4a_2$ for negativo, as raízes são complexas, $b = r(\cos\omega \pm i \sin\omega)$, e a solução é r^t vezes uma combinação de $\cos\omega t$ e $\sin\omega t$: um **ciclo amortecido** se $r < 1$.
6. **A ligação com o AR(2).** $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2}$ é a equação de segunda ordem com $a_1 = -\phi_1$ e $a_2 = -\phi_2$. A equação característica é $b^2 - \phi_1 b - \phi_2 = 0$. Dividindo $\phi(z) = 1 - \phi_1 z - \phi_2 z^2 = 0$ por z^2 e trocando $b = 1/z$, obtém-se a mesma equação. Então $|b| < 1 \iff |z| > 1$.

$$\boxed{\begin{array}{l} y_t = \left(y_0 - \dfrac{c}{1+a}\right)(-a)^t + \dfrac{c}{1+a} \text{ converge } \iff |a| < 1 \\ 2^{\text{a}} \text{ ordem: } |b_i| < 1 \iff \text{raízes de } \phi(z) \text{ fora do círculo} \end{array}}$$

Dois exemplos (conferidos em 02_arma.R):

- **Primeira ordem.** $y_{t+1} - 0{,}5y_t = 3$ com $y_0 = 10$. Aqui $y_p = 6$, $b = 0{,}5$ e $A = 4$, então $y_t = 4 \cdot 0{,}5^t + 6$. A trajetória converge monotonamente para 6. Em $t = 3$, a fórmula e a iteração dão 6,5.
- **Segunda ordem, o AR(2) com ciclo.** $y_t = y_{t-1} - 0{,}5y_{t-2}$. O discriminante é $\phi_1^2 + 4\phi_2 = -1 < 0$, então as raízes são complexas:
  - $b = 0{,}5 \pm 0{,}5i$, com módulo $r = 0{,}707$ e ângulo $\omega = 0{,}785$ $(\pi/4)$;
  - o ciclo tem período $2\pi/\omega = 8$ períodos e amortece, porque $r < 1$;
  - as raízes de $\phi(z)$ têm módulo $1/r = 1{,}414 > 1$, a mesma conclusão por D02.1.

  Com termo constante 2, o equilíbrio é $y_p = 2/(1 - \phi_1 - \phi_2) = 4$. É a média $\mu = c/\phi(1)$ do AR.

Como o professor pode torcer

- Escrever a equação "para a frente" ($y_{t+1} + a y_t = c$) num exercício e "para trás" ($y_t = \phi y_{t-1} + c$) no outro: $a = -\phi$, e a condição é a mesma.
- Pedir o caso $a = -1$: não há equilíbrio. A solução particular é ct, a raiz unitária do passeio com drift (D01.1).
- Pedir o período do ciclo de um AR(2) com raízes complexas: $2\pi/\omega$, com $\cos\omega = \phi_1/(2\sqrt{-\phi_2})$.

D02.5 · De onde vem a banda $\pm 1{,}96/\sqrt{T}$ e quando ela engana

O que se quer provar

- Para um ruído branco, $\hat{\rho}_k$ é aproximadamente $N(0, 1/T)$, e daí vem a banda de 95%, $\pm 1{,}96/\sqrt{T}$.
- Para um MA(q) e $k > q$, a fórmula de Bartlett dá $\mathrm{Var}(\hat{\rho}_k) \approx \frac{1}{T}\big(1 + 2\sum_{j=1}^{q} \rho_j^2\big)$. Com ela, a banda do ruído branco fica **estreita demais** a partir da defasagem $q + 1$.

Passo a passo.

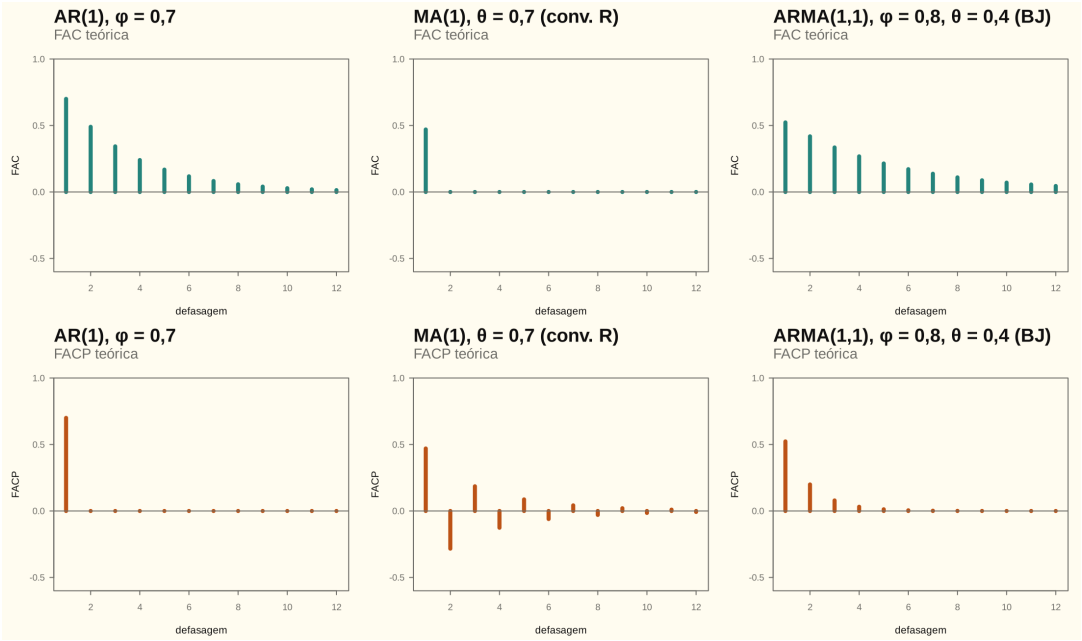
1. **A fórmula de Bartlett.** Para um processo linear com $\sum|\psi_j| < \infty$, $\sqrt{T}(\hat{\rho}_k - \rho_k)$ é assintoticamente normal, com variância $\sum_j \big(\rho_{j+k} + \rho_{j-k} - 2\rho_j\rho_k\big)^2$.
2. **Ruído branco.** $\rho_j = 0$ para $j \neq 0$. Na soma só sobra $j = \pm k$, com $\rho_0 = 1$, e a variância é 1. Então $\hat{\rho}_k \approx N(0, 1/T)$.
3. **MA(q) e $k > q$.** $\rho_k = 0$, e a soma vira $\sum_j \rho_{j-k}^2 = \sum_{|i|\le q} \rho_i^2 = 1 + 2\sum_{j=1}^{q} \rho_j^2$.
4. **A simulação**, com $T = 200$ e 5000 réplicas:
   - **ruído branco:** o desvio-padrão de $\hat{\rho}_1$ dá 0,0699, contra $1/\sqrt{T} = 0{,}0707$. A banda rejeita 4,8% das vezes, perto dos 5% nominais;
   - **MA(1) com** $\theta = 0{,}5$ (sinal do R), $\rho_1 = 0{,}4$: o desvio-padrão de $\hat{\rho}_2$ dá 0,0800, contra 0,0812 por Bartlett. A banda **ingênua** acusa um pico espúrio em $k = 2$ em 8,2% das vezes. A de Bartlett, em 4,5%.

$$\mathrm{Var}(\hat{\rho}_k) \approx \frac{1}{T}\Big(1 + 2\sum_{j=1}^{q} \rho_j^2\Big), \quad k > q; \qquad \text{ruído branco: } \pm 1{,}96/\sqrt{T}$$

O que isso muda na prática. A banda que o R desenha no `acf` é a do ruído branco. Ela serve para a pergunta "a série é ruído branco?". Também serve para os resíduos (Questão 5 do INPC) e para a FACP de um AR, cuja variância depois de p é mesmo $1/T$. Para decidir onde a FAC de um MA corta, porém, um pico pouco acima da banda depois de q não prova nada: a banda certa é mais larga. No INPC, a FAC em $k = 13$ (0,123) fica pouco acima de 0,109, e é por isso que a decisão sobre o grupo 11-12-13 veio dos critérios de informação, e não só do correlograma.

4. A tabela de identificação

Processo	FAC	FACP
AR(p)	decai (exponencial ou senoide amortecida)	**corta** após p
MA(q)	**corta** após q	decai
ARMA(p, q)	decai a partir de q	decai a partir de p
SAR(P)$_s$	decai nas defasagens $s, 2s, \ldots$	corta após Ps
SMA(Q)$_s$	corta após Qs	decai nas defasagens $s, 2s, \ldots$



Como o professor pode torcer

- Dar um ARMA com fator comum (Q5, modelo 3): reduza antes de classificar.
- Pedir os π_j com o MA na convenção de sinal positivo: refaça a recursão, porque os sinais alternam.
- Pedir o "processo resultante" de somas de processos (Q3): MA + MA independentes dão MA(max q).

Parte V

Bloco 3 — Integrados, ARIMA e SARIMA (Q9–Q12)

Capítulo 3 · Integrados, ARIMA e SARIMA: a diferença na dose certa

← apostila · anterior: cap. 2 · próximo: cap. 4 · questões da lista: Q9 a Q12

Pergunta de abertura

O PIB cresce há décadas. Para modelá-lo com um ARMA, você precisa de uma série estacionária. Há dois caminhos:

- **tirar a diferença**, Δy_t;
- **regredir em** t e usar o resíduo.

Os dois dão o mesmo resultado? E se, na dúvida, você diferenciar uma vez a mais, "por segurança", **o que se perde?**

A resposta depende de uma pergunta que veio do cap. 2: **o choque de hoje some ou fica para sempre?**

- Se fica, a tendência é **estocástica** e o remédio é a diferença.
- Se some, e a série só oscila em torno de uma reta, a tendência é **determinística** e o remédio é a regressão.

Errar o remédio, em qualquer das duas direções, tem custo (MAT, p. 1–16; lista, Q9 e Q10).

A imagem

A tendência determinística é um trem num trilho. O trem balança, sai um pouco do eixo, mas o trilho o traz de volta: os desvios são transitórios. Saber em que ponto do trilho o trem está daqui a dez anos é fácil, e a incerteza não cresce com o horizonte.

A tendência estocástica é um barco à deriva com vento a favor. O vento, que é o drift, empurra para frente em média. Cada onda, que é o choque, desloca o barco, e **ninguém o traz de volta**: o desvio fica incorporado à rota. A incerteza sobre a posição daqui a dez anos cresce com o horizonte, exatamente como $\text{Var}(y_t) = t\sigma^2$ do cap. 1.

A diferença é um remédio, e a dose importa.

- **Subdose** (não diferenciar uma série com raiz unitária): a doença continua, e a FAC decai devagar, quase em linha reta.
- **Sobredose** (diferenciar o que já era estacionário): aparece um efeito colateral, um MA com raiz **exatamente** em $z = 1$. A assinatura é $\hat{\rho}_1$ negativo, perto de $-0{,}5$.

Uma regra prática das notas de identificação de Duke: nunca mais de duas diferenças no total, contando a sazonal.

A diferença sazonal compara com o mesmo mês do ano anterior. Em vez de "quanto mudou desde o mês passado", $(1 - L^{12})y_t$ pergunta "quanto mudou desde o mesmo mês do ano passado". O padrão de dezembro é comparado com dezembro, e a sazonalidade some se for estável.

O SAR é a memória de calendário. Num SAR$(1)_4$ trimestral, o primeiro trimestre lembra o primeiro trimestre do ano anterior, e só ele. **O multiplicativo são duas engrenagens acopladas:** uma gira a cada período (o ϕ) e outra a cada ano (o Φ). Quando se encaixam, aparece um dente a mais, o termo $\phi\Phi L^5$, e com ele os picos "satélites" em volta da defasagem sazonal.

Onde a analogia quebra

- **A sobredose não "adoece" a série.** Δy_t de um AR(1) estacionário **continua estacionária**. O custo é outro: um MA não invertível, sem AR(∞), com estimação e previsão piores. O efeito colateral é de eficiência, não de estacionariedade.
- **O trilho pode ser elástico demais para se ver.** Um processo TS com desvios AR(1) de $\phi = 0{,}98$ volta ao trilho tão devagar que, numa amostra curta, é praticamente indistinguível de um passeio. É por isso que os testes de raiz unitária têm pouco poder (MAT, §2).
- **"Comparar com o ano anterior" só limpa sazonalidade estável.** Se o padrão sazonal muda ao longo dos anos, a diferença sazonal não basta, e o que sobra precisa de termos SAR/SMA.

Teoria

Processo integrado (MAT, p. 8–9). $y_t \sim I(d)$ se é preciso diferenciar d vezes para obter um processo estacionário e invertível. **ARIMA(p, d, q)** quer dizer que $w_t = (1 - L)^d y_t$ é ARMA(p, q):

$$\phi(L)(1 - L)^d \, y_t = c + \theta(L) \, \varepsilon_t, \qquad \phi(z) \neq 0 \text{ e } \theta(z) \neq 0 \text{ para } |z| \leq 1.$$

Como $\phi(L)(1 - L)^d$ tem d raízes **exatamente** em $z = 1$, as "raízes unitárias", o nível não é estacionário, mas a diferença é.

Tendência estacionária (TS) × diferença estacionária (DS) (MAT, p. 1–16; AU01, p. 28–30):

	TS: $y_t = \alpha + \beta t + u_t$, u_t estacionário	DS: $\Delta y_t = \beta + u_t$, u_t estacionário
tendência	determinística	estocástica: $\sum u_s$
efeito de um choque	transitório	**permanente**
variância do erro de previsão	limitada	cresce com o horizonte
como estacionarizar	regredir em t	diferenciar
erro se trocar	diferenciar dá MA não invertível	regredir em t deixa um passeio no resíduo

A **decomposição de Beveridge-Nelson** (MAT, p. 11) separa um processo DS em uma tendência estocástica, que é um passeio, e um ciclo estacionário.

Sobrediferenciação (lista, Q9 e Q10). Diferenciar um processo já estacionário cria um MA com o fator $(1 - L)$, de raiz $z = 1$ (AU02, p. 33):

- o processo continua estacionário, mas **não é invertível**;
- some a forma AR(∞) convergente (AU02, p. 30–31);
- a variância pode aumentar;
- a previsão piora.

SAR, SMA e SARIMA (AU05; BJRL, cap. 9). Com período s:

$$\phi(L) \, \Phi(L^s) \, (1 - L)^d (1 - L^s)^D \, y_t = c + \theta(L) \, \Theta(L^s) \, \varepsilon_t, \qquad \text{SARIMA}(p, d, q)(P, D, Q)_s.$$

- A diferença sazonal, $(1 - L^s) \, y_t = y_t - y_{t-s}$, compara cada período com o mesmo período do ano anterior. O polinômio $1 - z^s$ tem as s raízes da unidade, todas com módulo 1, e por isso ela remove uma sazonalidade estável, do tipo "passeio sazonal".

- O **SAR(1)**$_s$, $y_t = \Phi_1 y_{t-s} + \varepsilon_t$, tem FAC não nula **só** nas defasagens múltiplas de s: $\rho_{js} = \Phi_1^j$.
- No **multiplicativo**, o produto dos polinômios cria termos cruzados, como $\phi\Phi L^{s+1}$, com coeficientes **restritos**.
- As diferenças $(1-L)^d(1-L^s)^D$ consomem $d + sD$ observações.

Na lista, troque L por B. O MA usa o sinal de Box-Jenkins, $\Theta^{\text{lista}} = -\Theta_1$, e o lado AR não muda.

Demonstrações

D3.1 · Diferenciar um AR(1) estacionário cria uma raiz unitária no MA (Q9)

$y_t = \phi y_{t-1} + \varepsilon_t$, com $|\phi| < 1$, e $w_t = \Delta y_t = y_t - y_{t-1}$.

(1)	$w_t = y_t - y_{t-1} = \phi y_{t-1} + \varepsilon_t - y_{t-1}$	[modelo]
(2)	$w_t = -(1-\phi)\, y_{t-1} + \varepsilon_t$	[agrupa y_{t-1}]
(3)	$(1-\phi L)\, y_t = \varepsilon_t$	[modelo em L]
(4)	$(1-L)(1-\phi L)\, y_t = (1-L)\, \varepsilon_t$	[aplica $(1-L)$ aos dois lados]
(5)	$(1-\phi L)\,(1-L) y_t = (1-L)\, \varepsilon_t$	[polinômios comutam]
(6)	$(1-\phi L)\, w_t = (1-L)\, \varepsilon_t$	[$w_t = (1-L)y_t$]
(7)	$\theta(z) = 1 - z = 0 \implies z = 1,\ \lvert z\rvert = 1$	[raiz no círculo]
(8)	$(1-L)^{-1} = 1 + L + L^2 + \cdots$	[F2 com razão 1]

Em (8), a série geométrica de razão 1 tem todos os pesos iguais a 1, e eles não encolhem. Os π_j de w_t não são somáveis, e **não existe AR(∞) convergente**. Os choques não podem ser recuperados do passado de w.

A assinatura na FAC. Com γ_k de y e $\gamma_k = \phi^k \gamma_0$:

(9)	$\gamma_w(0) = E\big((y_t - y_{t-1})^2\big) = 2\gamma_0 - 2\gamma_1 = 2\gamma_0(1-\phi)$	[F5]
(10)	$\gamma_w(1) = E\big((y_t - y_{t-1})(y_{t-1} - y_{t-2})\big) = 2\gamma_1 - \gamma_0 - \gamma_2 = -\gamma_0(1-\phi)^2$	[F5, $\gamma_k = \phi^k\gamma_0$]
(11)	$\rho_w(1) = \dfrac{-\gamma_0(1-\phi)^2}{2\gamma_0(1-\phi)} = -\dfrac{1-\phi}{2}$	[(10) ÷ (9)]

$$\boxed{(1-\phi L)\, w_t = (1-L)\, \varepsilon_t \ :\ \text{ARMA(1,1) com MA não invertível;} \qquad \rho_w(1) = -\tfrac{1-\phi}{2} \in (-1, 0)}$$

Com $\phi = 0$, ou seja, diferenciando um ruído branco, $\rho_w(1) = -0{,}5$ **exatamente**: é a assinatura clássica da sobrediferenciação.

D3.2 · Diferenciar uma tendência determinística (Q10d)

$y_t = \alpha + \beta t + u_t$, com $u_t \sim RB(0, \sigma^2)$.

(1)	$y_{t-1} = \alpha + \beta(t-1) + u_{t-1}$	[modelo em $t-1$]
(2)	$\Delta y_t = \beta t - \beta(t-1) + u_t - u_{t-1}$	[subtrai]
(3)	$\Delta y_t = \beta + u_t - u_{t-1} = \beta + (1-L)\, u_t$	[simplifica]
(4)	$\gamma_0 = E\big((u_t - u_{t-1})^2\big) = 2\sigma^2$	[RB]
(5)	$\gamma_1 = E\big((u_t - u_{t-1})(u_{t-1} - u_{t-2})\big) = -\sigma^2$	[RB: só u_{t-1}^2]
(6)	$\rho_1 = -\frac{1}{2}, \qquad \theta(z) = 1 - z \Rightarrow z = 1$	[não invertível]

$$\boxed{\Delta(\text{TS}) = \beta + (1-L)u_t \ : \ \text{estacionário, mas com MA não invertível; o certo é regredir } y_t \text{ em } (1,t)}$$

Pela regressão, o resíduo estima u_t diretamente, sem criar estrutura falsa. É o mesmo argumento da Q2(d), demonstrado na folha à mão.

D3.3 · ARIMA(1,1,1): a equação de diferenças (Q10b)

Nos slides: $(1-\phi_1 L)(1-L)\,y_t = (1+\theta_1 L)\,\varepsilon_t$.

(1)	$(1-\phi_1 L)(1-L) = 1 - L - \phi_1 L + \phi_1 L^2$	[F8: termo a termo]
(2)	$= 1 - (1+\phi_1)L + \phi_1 L^2$	[agrupa]
(3)	$y_t - (1+\phi_1)y_{t-1} + \phi_1 y_{t-2} = \varepsilon_t + \theta_1 \varepsilon_{t-1}$	[aplica a y_t]
(4)	$y_t = (1+\phi_1)y_{t-1} - \phi_1 y_{t-2} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$	[isola y_t]
(5)	raízes do lado AR: $1-\phi_1 z = 0 \Rightarrow z = 1/\phi_1$; $\quad 1 - z = 0 \Rightarrow z = 1$	[uma raiz unitária]
(6)	na lista: $\theta_1 = -\theta \ \Rightarrow \ y_t = (1+\phi)y_{t-1} - \phi y_{t-2} + a_t - \theta a_{t-1}$	[tradução]

$$\boxed{y_t = (1+\phi_1)\,y_{t-1} - \phi_1\,y_{t-2} + \varepsilon_t + \theta_1 \varepsilon_{t-1}}$$

Olhando para (4), parece um "AR(2)". Mas a soma dos coeficientes, $(1+\phi_1) - \phi_1 = 1$, é a marca de uma raiz unitária: $\phi(1) = 0$.

D3.4 · SAR(1)$_4$: a FAC só vive nos múltiplos de 4 (Q11a)

$y_t = \Phi_1 y_{t-4} + \varepsilon_t$, com $|\Phi_1| < 1$. Multiplique por y_{t-k} e tire a esperança.

(1)	$\gamma_0 = \Phi_1^2 \gamma_0 + \sigma^2 \implies \gamma_0 = \dfrac{\sigma^2}{1-\Phi_1^2}$	[como no AR(1), cap. 2]
(2)	$\gamma_k = \Phi_1 \gamma_{k-4}, \quad k \geq 1$	[caus.]
(3)	$\gamma_4 = \Phi_1 \gamma_0, \qquad \gamma_8 = \Phi_1 \gamma_4 = \Phi_1^2 \gamma_0$	[(2)]
(4)	$k=2: \ \gamma_2 = \Phi_1 \gamma_{-2} = \Phi_1 \gamma_2 \implies (1-\Phi_1)\gamma_2 = 0 \implies \gamma_2 = 0$	[$\gamma_{-k} = \gamma_k$]
(5)	$k=1: \ \gamma_1 = \Phi_1 \gamma_3; \qquad k=3: \ \gamma_3 = \Phi_1 \gamma_1$	[(2)]
(6)	$\gamma_1 = \Phi_1^2 \gamma_1 \implies (1-\Phi_1^2)\gamma_1 = 0 \implies \gamma_1 = \gamma_3 = 0$	[(5)]

Por (2), os zeros de $k = 1, 2, 3$ se propagam para $5, 6, 7, 9, \ldots$

$$\boxed{\gamma_{4j} = \Phi_1^j \gamma_0, \qquad \gamma_k = 0 \text{ se } k \text{ não é múltiplo de } 4}$$

FAC: decai geometricamente só nos múltiplos de 4, igual a um AR(1) "esticado". **FACP:** um único pico, em 4, e zero no resto.

D3.5 · O multiplicativo é um AR(5) restrito (Q11c)

$(1-\phi L)(1-\Phi L^4)\,y_t = \varepsilon_t$.

(1)	$(1-\phi L)(1-\Phi L^4) = 1\cdot 1 + 1\cdot(-\Phi L^4) + (-\phi L)\cdot 1 + (-\phi L)(-\Phi L^4)$	[F8: quatro produtos]
(2)	$= 1 - \phi L - \Phi L^4 + \phi\Phi L^5$	[simplifica]
(3)	$y_t = \phi\, y_{t-1} + \Phi\, y_{t-4} - \phi\Phi\, y_{t-5} + \varepsilon_t$	[isola y_t]
(4)	AR(5) : $\phi_1 = \phi,\ \phi_2 = 0,\ \phi_3 = 0,\ \phi_4 = \Phi,\ \phi_5 = -\phi\Phi$	[compara]
(5)	restrições: $\phi_2 = \phi_3 = 0$ e $\phi_5 = -\phi_1\phi_4$	[3 restrições]
(6)	parâmetros livres: $5 - 3 = 2,\ (\phi, \Phi)$	[parcimônia]

$$\boxed{(1-\phi L)(1-\Phi L^4) = 1 - \phi L - \Phi L^4 + \phi\Phi L^5 \ :\quad \phi_2 = \phi_3 = 0,\ \ \phi_5 = -\phi_1\phi_4}$$

O termo $\phi\Phi L^5$ é o "dente a mais" das engrenagens. É ele que cria os satélites na FAC em volta da defasagem 4.

D3.6 · Beveridge-Nelson e o mapa dos testes de raiz unitária (MAT §1.6 e §2)

Beveridge-Nelson (MAT, p. 11 e apêndice A). Todo processo I(1) é a soma de uma tendência estocástica, um passeio, com um ciclo estacionário. A conta no ARIMA(0,1,1) dos slides, $\Delta y_t = \mu + \varepsilon_t + \theta_1\varepsilon_{t-1}$, com y_0 e $\varepsilon_0 = 0$:

(1)	$\Delta y_t = \mu + \psi(L)\,\varepsilon_t, \qquad \psi(L) = 1 + \theta_1 L$	[modelo]
(2)	$\psi(L) = \psi(1) + (1-L)\,\psi^*(L)$	[divide $\psi(L) - \psi(1)$ por $(1-L)$]
(3)	$1 + \theta_1 L = (1+\theta_1) + (1-L)(-\theta_1)$	[confere: $1 + \theta_1 - \theta_1 + \theta_1 L$]
(4)	$y_t = y_0 + \mu t + \psi(1)\sum_{s=1}^{t}\varepsilon_s + \psi^*(L)\varepsilon_t - \psi^*(L)\varepsilon_0$	[soma de 1 a t; $(1-L)$ telescopa]
(5)	$\underbrace{y_0 + \mu t + (1+\theta_1)\sum_{s=1}^{t}\varepsilon_s}_{\text{tendência (passeio)}} + \underbrace{(-\theta_1)\,\varepsilon_t}_{\text{ciclo}}$	[(3), (4), $\varepsilon_0 = 0$]
(6)	$\psi(1) = 1 + \theta_1$: a fração de um choque que fica para sempre	[persistência]
(7)	$\theta_1 \to -1 \ \Rightarrow\ \psi(1) \to 0$: nada é permanente, e y_t é TS	[sobrediferenciação, D3.1]

$$\boxed{y_t = \underbrace{y_0 + \mu t + \psi(1)\sum \varepsilon_s}_{\text{tendência estocástica}} + \underbrace{\psi^*(L)\varepsilon_t}_{\text{ciclo}}, \qquad \psi(1) = \text{persistência}}$$

Com $\theta_1 = -0{,}6$, $\psi(1) = 0{,}4$: 40% de cada choque é permanente, e o resto se desfaz no período seguinte. Numa série simulada de 5 000 períodos, a tendência mais o ciclo de (5) reconstroem y_t com diferença da ordem de 10^{-13}. A identidade (3) confere com diferença zero.

O mapa dos testes (MAT §2; AU04). Todos partem da mesma regressão; o que muda é como tratam o erro e os termos determinísticos.

(8)	$y_t = \rho\, y_{t-1} + u_t \;\Rightarrow\; \Delta y_t = \gamma\, y_{t-1} + u_t,\;\; \gamma = \rho - 1;\;\; H_0 : \gamma = 0$	[MAT §2.1, p. 17]
(9)	DF: $\tau = \hat{\gamma}/ep(\hat{\gamma})$, críticos não padrão, três especificações	[MAT §2.2, p. 19–23]
(10)	ADF: acrescenta $\sum_{i=1}^{k} \delta_i \Delta y_{t-i}$ para branquear u_t	[MAT p. 24–28]
(11)	PP: corrige τ pela variância de longo prazo, sem defasagens	[MAT §2.3, p. 29]
(12)	DF-GLS: tira os determinísticos por MQG antes; mais poder	[MAT §2.4, p. 32]
(13)	ERS ponto ótimo: o teste mais poderoso contra uma alternativa fixada	[MAT §2.5, p. 35]
(14)	KPSS: nula invertida (estacionariedade), para cruzar com o ADF	[AU04]
(15)	raiz unitária sazonal: HEGY, OCSB, Canova-Hansen	[MAT §2.6; AU05]

Em (15), o MAT, p. 38, estende o ADF para a frequência sazonal. A ligação com a lista: na Q10, decidir entre TS e DS é exatamente o que esses testes fazem. Com ϕ perto de 1, nenhum deles tem muito poder (D03.3 no aprofundamento deste bloco). Por isso a regra prática é cruzar um teste de nula "raiz unitária" com um de nula "estacionário".

Exemplo

1. Quanto custa diferenciar um AR(1) estacionário. Valores do R para $w_t = \Delta y_t$, com $\sigma^2 = 1$, a partir de (9)–(11) da D3.1:

ϕ	Var(y_t)	Var(w_t)	$\rho_w(1)$	leitura
0,2	1,0417	1,6667	−0,40	a variância **aumenta** 60%: sobredose clara
0,5	1,3333	1,3333	−0,25	empata
0,9	5,2632	1,0526	−0,05	parece "melhorar", mas o MA tem raiz unitária

- O caso $\phi = 0$ (ruído branco diferenciado) dá $\rho_w(1) = -0{,}5$, conferido com o `ARMAacf`.
- Com $\phi = 0{,}5$, o `ARMAacf(ar = 0.5, ma = -1)` confirma −0,25.

A regra de Duke ("a ordem certa de diferenciação costuma ser a de menor desvio padrão") acerta com $\phi = 0{,}2$ e engana com $\phi = 0{,}9$. Por isso o critério final é a raiz do MA, não a variância.

2. SAR(1)$_4$ com $\Phi_1 = 0{,}6$.

- $\gamma_0 = 1/(1 - 0{,}36) = 1{,}5625$;
- $\gamma_4 = 0{,}9375$;
- $\gamma_8 = 0{,}5625$.

No R, $\rho_1 = 0$, $\rho_4 = 0{,}6$ e $\rho_8 = 0{,}36$: a FAC só vive nos múltiplos de 4.

3. Multiplicativo com $\phi = 0{,}5$ e $\Phi = 0{,}6$. Vira o AR(5) $y_t = 0{,}5y_{t-1} + 0{,}6y_{t-4} - 0{,}3y_{t-5} + \varepsilon_t$.

4. Observações perdidas com $d = D = 1$:

- trimestral (Q12): $1 + 4 = 5$;
- mensal (Q16): $1 + 12 = 13$.

Cadeia socrática

P1. Se Δy_t é estacionário, y_t é necessariamente um passeio aleatório?

Resposta

Não. y_t é I(1), mas Δy_t pode ser qualquer ARMA estacionário e invertível. O passeio é o caso particular em que Δy_t é ruído branco. Um ARIMA(1,1,1) também tem Δy_t estacionário (D3.3).

P2. A série tem tendência linear clara. Diferenciar resolve?

Resposta

Torna estacionário nos dois casos, TS ou DS. Mas, se a tendência é determinística, diferenciar cria um MA com raiz unitária (D3.2). O remédio certo para TS é a regressão em *t*. "Torna estacionário" não basta: precisa ser estacionário **e invertível**.

P3. Como reconhecer a sobrediferenciação pela FAC?

Resposta

$\hat{\rho}_1$ negativo e forte, perto de $-0{,}5$, e a FAC cortando depois disso, que é a cara de um MA(1) com $\theta_1 \approx -1$. Na estimação, $\hat{\theta}_1$ encosta em -1. Pela regra de Duke, uma raiz unitária no MA pede **uma diferença a menos**.

P4. E a subdiferenciação?

Resposta

FAC com correlações positivas que decaem muito devagar, quase em linha reta (cap. 1, D1.1: Corr $= \sqrt{(t-k)/t}$). No AR estimado, a soma dos coeficientes fica perto de 1, como em D3.3, em que $(1+\phi_1) - \phi_1 = 1$.

P5. Por que, num SAR(1)$_4$, $\gamma_1 = 0$, se o processo tem memória?

Resposta

Porque a memória é de **calendário**: y_t depende de y_{t-4}, que depende de y_{t-8}... A cadeia nunca passa por y_{t-1}. Formalmente, $\gamma_1 = \Phi_1^2 \gamma_1$ força $\gamma_1 = 0$ (D3.4).

P6. No SARIMA(1,0,0)(1,0,0)$_4$, de onde vem o coeficiente de y_{t-5}?

Resposta

Do produto dos dois polinômios: $(-\phi L)(-\Phi L^4) = \phi\Phi L^5$. Ninguém o escolheu: ele é **imposto**, $\phi_5 = -\phi_1\phi_4$. É isso que faz o multiplicativo ser parcimonioso, com 2 parâmetros no lugar de 5.

P7. Quantas observações a Q12 perde, e por quê?

Resposta

Cinco. $(1-L)(1-L^4)y_t = y_t - y_{t-1} - y_{t-4} + y_{t-5}$ precisa de y_{t-5}. O primeiro w calculável é w_6. Em geral, perdem-se $d + sD$.

P8. "Raiz unitária" e "não estacionário" são sinônimos?

Resposta

Não. Toda raiz unitária no AR gera não estacionariedade, mas uma série TS também é não estacionária, porque a média depende de *t*, e não tem raiz unitária. E uma raiz unitária no **MA** não torna o processo não estacionário: torna-o não invertível (D3.1).

Diálogo

Sobre "diferenciar por segurança".

Aluno: Na dúvida, eu diferencio. Se a série já era estacionária, diferenciar não estraga nada: continua estacionária.

Professor: Continua estacionária, sim. E invertível?

Aluno: ... Pela D3.1, aparece $(1 - L)$ no MA, com raiz em $z = 1$. Então não é invertível.

Professor: E o que você perde sem a invertibilidade?

Aluno: A forma AR(∞). Sem ela, não dá para recuperar os ε_t a partir dos dados... e a previsão precisa deles.

Professor: Algo mais? Olhe a variância na tabela do exemplo.

Aluno: Com $\phi = 0{,}2$, a variância de Δy é 1,67, contra 1,04 do nível. Eu acrescentei ruído.

Professor: Então "por segurança" tem um preço. Qual seria a regra?

Aluno: Diferenciar só com evidência de raiz unitária: FAC lenta e um teste. Depois de diferenciar, olhar $\hat{\rho}_1$: se estiver perto de $-0{,}5$, ou se o $\hat{\theta}_1$ encostar em -1, voltar uma diferença.

Professor: E se a tendência for determinística?

Aluno: Aí não diferencio: regrido em *t*. Diferenciar uma TS também cria o $(1 - L)$ no MA (D3.2).

Na prova

A folha de caderno do bloco está em a_mao_cap3.md: Q9 a Q12 em 67 linhas numeradas, cada uma com a justificativa, mais a versão para a prova e a conferência em R.

Questão	O que este capítulo dá	Resolução completa
Q9	sobrediferenciação do AR(1): $(1 - \phi B)w_t = (1 - B)\varepsilon_t$, raiz $z = 1$, sem AR(∞)	Q9
Q10	ARIMA ⟶ ARMA na diferença; ARIMA(1,1,1) expandido; TS × DS; regressão × diferença	Q10
Q11	SAR(1)$_4$: γ_{4j}, zeros fora dos múltiplos; multiplicativo como AR(5) restrito	Q11
Q12	SARIMA(1,1,0)(0,1,1)$_4$: modelo, 5 perdas, previsão, diagnóstico	Q12

Armadilhas:

- dizer que a sobrediferenciação "torna a série não estacionária": ela torna **não invertível**;
- na Q11(a), esquecer de **provar** que $\gamma_1 = \gamma_2 = \gamma_3 = 0$ (D3.4, linhas 4–6);
- contar 5 parâmetros livres no AR(5) restrito: são 2;
- na Q10(b), errar o sinal de $\phi_1 L^2$ na expansão;
- confundir "tem tendência" com "tem raiz unitária".

Checklist de 30 segundos:

1. Disse **qual** tendência (determinística ou estocástica) e o remédio correspondente?
2. Mostrei a raiz do MA ($z = 1$) quando falei de sobrediferenciação?
3. Expandi os polinômios termo a termo (F8)?
4. Contei as observações perdidas com $d + sD$?
5. Traduzi o sinal do MA sazonal para a lista ($\Theta^{\text{lista}} = -\Theta_1$)?

No material do professor

Roteiro de releitura:

- AU01, p. 28–30: passeio, drift e tendência;
- MAT, p. 1–9: tendência determinística, estocástica, processo integrado e raiz unitária;
- MAT, p. 11–16: Beveridge-Nelson, diferença estacionária, memória e os quatro processos;
- AU02, p. 30–36: invertibilidade, a razão pela qual $(1 - L)$ no MA é um problema;
- MAT, p. 38: ADF com sazonalidade;
- AU05: ARIMA e SARIMA, com a notação $(p, d, q)(P, D, Q)_s$.

Livros:

- **BJRL**, cap. 4 (ARIMA) e cap. 9 (sazonais multiplicativos);
- **ENDERS**, cap. 4: tendências e raiz unitária;
- **HAMILTON**, cap. 15: processos com tendência, TS × DS.

Na lista comentada: Q9 · Q10 · Q11 · Q12 · ferramentas F2 e F8.

CAPÍTULO 28

Cap. 3 à mão — Q9 a Q12 linha a linha

Cap. 3 à mão: Q9 a Q12, linha a linha

⟵ capítulo 3 · ⟵ apostila · cap. 2 à mão

Versão de **caderno** do bloco 3 da lista: cada passagem numerada, uma operação por linha e o motivo entre colchetes. A numeração é contínua. Os símbolos são os dos slides; o MA, inclusive o sazonal, usa o sinal positivo, com $\theta_1 = -\theta^{\text{lista}}$ e $\Theta_1 = -\Theta^{\text{lista}}$. O lado AR é igual nas duas notações.

Legenda:

- [RB]: ruído branco;
- [F2]: série geométrica;
- [F4]: linearidade da esperança;
- [F5]: covariância de combinações lineares;
- [F7]: igualar coeficientes;
- [F8]: multiplicar polinômios;
- [F9]: esperança condicional na previsão (o que é conhecido fica, choque futuro é zero, *y* futuro vira previsão);
- caus.: o choque de hoje não se correlaciona com o passado;
- [(n)]: usando a linha (n).

Q9 · Sobrediferenciar um AR(1) estacionário

Enunciado (lista, Q9). $y_t = \phi y_{t-1} + \varepsilon_t$, com $|\phi| < 1$, e $w_t = \Delta y_t$. Pede-se:

- (a) mostrar que $w_t = -(1-\phi)y_{t-1} + \varepsilon_t$ e que $(1-\phi B)w_t = (1-B)\varepsilon_t$, identificando os polinômios;
- (b) mostrar que o MA tem raiz unitária e discutir o AR(∞);
- (c) discutir por que diferenciar uma série estacionária é prejudicial.

(1) $w_t = y_t - y_{t-1} = \phi y_{t-1} + \varepsilon_t - y_{t-1}$ [modelo]

(2) $w_t = -(1-\phi)\, y_{t-1} + \varepsilon_t$ [agrupa y_{t-1}]

(3) $y_t = (1-\phi L)^{-1}\varepsilon_t = \sum_{j\geq 0} \phi^j \varepsilon_{t-j}$ [MA(∞), F2, $|\phi| < 1$]

(4) $w_t = (1-L)\, y_t = (1-L)(1-\phi L)^{-1}\varepsilon_t$ [(3)]

(5) $(1-\phi L)\, w_t = (1-L)\, \varepsilon_t$ [$\times(1-\phi L)$]

(6) $\phi(L) = 1-\phi L;\ \ \theta(L) = 1 - L\ (\theta_1 = -1;$ lista: $\theta = 1) \ \Rightarrow$ ARMA(1,1) [identifica]

(7) $\theta(z) = 1 - z = 0 \ \Rightarrow\ z = 1,\ |z| = 1$ [raiz sobre o círculo]

(8) a raiz não está fora do círculo $\Rightarrow$ não invertível [AU02 p. 33]

(9) $\pi(L) = \dfrac{1-\phi L}{1-L} = (1-\phi L)(1 + L + L^2 + \cdots)$ [F2 com razão 1: formal]

(10) $\quad = 1 + (1-\phi)L + (1-\phi)L^2 + \cdots \ \Rightarrow\ \pi_j = -(1-\phi),\ j \geq 1$ [F7]

(11) $\sum_j |\pi_j| = \sum_j (1-\phi) = \infty \ \Rightarrow$ sem AR(∞) convergente [(10)]

(12) $\gamma_w(0) = E\big((y_t - y_{t-1})^2\big) = 2\gamma_0 - 2\gamma_1 = 2\gamma_0(1-\phi)$ [F5, $\gamma_1 = \phi\gamma_0$]

(13) $\gamma_w(1) = 2\gamma_1 - \gamma_0 - \gamma_2 = -\gamma_0(1-\phi)^2$ [F5, $\gamma_2 = \phi^2\gamma_0$]

(14) $\rho_w(1) = -\frac{1-\phi}{2} \in \big(-\frac{1}{2}, 0\big)$ [(13) ÷ (12)]

(15) $\gamma_w(0) = \dfrac{2\sigma^2}{1+\phi} > \gamma_0 = \dfrac{\sigma^2}{1-\phi^2} \iff 2(1-\phi) > 1 \iff \phi < \frac{1}{2}$ [(12), γ_0 do AR(1)]

$$\boxed{(1-\phi L)\, w_t = (1-L)\, \varepsilon_t \ :\ \text{MA com raiz } z = 1,\ \text{não invertível, sem AR}(\infty); \quad \rho_w(1) = -\frac{1-\phi}{2}}$$

(c) Por que é prejudicial.

(16) estimação: $\hat{\theta}_1$ encosta em -1 [raiz no círculo]

(17) com $\varepsilon_0 = 0$, o erro do chute pesa $(-\theta_1)^t = 1$ para sempre [MV condicional]

(18) modelo em diferenças: $\mathrm{Var}(e_{T+h})$ cresce com h [choque permanente]

(19) o verdadeiro é estacionário: $\mathrm{Var}(e_{T+h}) \to \gamma_0$, limitada [cap. 5, D5.3]

(20) com $\phi < \frac{1}{2}$, a variância da série aumenta: acrescenta-se ruído [(15)]

Q10 · ARIMA, tendência determinística e sobrediferenciação

Enunciado (lista, Q10). São cinco itens:

- (a) ARIMA$(p,1,q)$ na diferença é um ARMA(p,q);
- (b) expandir o ARIMA(1,1,1);
- (c) raiz unitária × tendência determinística;

- (d) diferenciar uma série com tendência só determinística;
- (e) por que a regressão em t é preferível.

(21) $\phi(L)\,(1-L)\,y_t = \theta(L)\,\varepsilon_t$ [ARIMA$(p,1,q)$]
(22) $w_t \equiv (1-L)\,y_t \;\Rightarrow\; \phi(L)\,w_t = \theta(L)\,\varepsilon_t$ [substitui]
(23) raízes de $\phi(z), \theta(z)$ fora do círculo $\Rightarrow w_t \sim$ ARMA(p,q) [AU02 p. 27, 33]

(b) ARIMA(1,1,1), na lista: $(1-\phi B)(1-B)y_t = (1-\theta B)a_t$.

(24) $(1-\phi B)(1-B) = 1 - B - \phi B + \phi B^2 = 1 - (1+\phi)B + \phi B^2$ [F8]
(25) $y_t - (1+\phi)\,y_{t-1} + \phi\,y_{t-2} = a_t - \theta\,a_{t-1}$ [aplica a y_t]
(26) $y_t = (1+\phi)\,y_{t-1} - \phi\,y_{t-2} + a_t - \theta\,a_{t-1}$ [isola y_t]
(27) soma dos coeficientes AR $= (1+\phi) - \phi = 1 \;\Rightarrow\; \phi(1) = 0$: raiz unitária [confere]

(c), (d) e (e): TS × DS.

(28) TS: $y_t = \alpha + \beta t + u_t$ (u_t estac.); $\partial y_{t+h}/\partial u_t = \psi_h \to 0$ [transitório]
(29) DS: $y_t = y_0 + \beta t + \sum_{s=1}^{t} u_s$; $\partial y_{t+h}/\partial u_t = 1$ [choque permanente]
(30) Var(y_t) : TS constante; DS cresce com t [AU01 p. 28–30]
(31) (d): $\Delta y_t = \beta + u_t - u_{t-1} = \beta + (1-L)\,u_t$ [(28) em t e $t-1$]
(32) $\gamma_0 = 2\sigma^2,\ \gamma_1 = -\sigma^2,\ \rho_1 = -\frac{1}{2};\ \theta(z) = 1 - z \Rightarrow z = 1$ [u_t RB; não invertível]
(33) (e): MQO de y_t em $(1,t)$: $\hat{u}_t = y_t - \hat{\alpha} - \hat{\beta} t$ estima u_t [MQO]
(34) $\hat{u}_t$ herda o ARMA de u_t, sem o fator $(1-L)$ [(31) evitado]

DS → diferença; TS → regressão em t; Δ(TS) cria $(1-L)$ no MA: sobrediferenciação

---

Q11 · SAR(1)$_4$ e o multiplicativo

Enunciado (lista, Q11). $y_t = \Phi_1 y_{t-4} + \varepsilon_t$, com $|\Phi_1| < 1$. Pede-se:

- (a) $\gamma_0, \gamma_4, \gamma_8, \gamma_k$ nos múltiplos de 4 e o que acontece fora deles;
- (b) a FAC e a FACP, comparadas com o AR(1);
- (c) o SARIMA$(1,0,0)(1,0,0)_4$ escrito como AR(5) restrito.

(35) $\gamma_0 = E\big((\Phi_1 y_{t-4} + \varepsilon_t)^2\big) = \Phi_1^2\gamma_0 + 2\Phi_1 E(y_{t-4}\varepsilon_t) + \sigma^2$ [F4]

(36) $\gamma_0 = \Phi_1^2\gamma_0 + 0 + \sigma^2 \;\Rightarrow\; \gamma_0 = \dfrac{\sigma^2}{1-\Phi_1^2}$ [caus.; isola]

(37) $\gamma_k = E(y_t y_{t-k}) = \Phi_1\gamma_{k-4} + E(\varepsilon_t y_{t-k}) = \Phi_1\gamma_{k-4}, \;\; k \geq 1$ [caus.]

(38) $\gamma_4 = \Phi_1\gamma_0, \quad \gamma_8 = \Phi_1\gamma_4 = \Phi_1^2\gamma_0, \quad \gamma_{4j} = \Phi_1^j\gamma_0$ [(37), indução]

(39) $k = 2: \;\; \gamma_2 = \Phi_1\gamma_{-2} = \Phi_1\gamma_2 \;\Rightarrow\; (1-\Phi_1)\gamma_2 = 0 \;\Rightarrow\; \gamma_2 = 0$ [$\gamma_{-k} = \gamma_k$]

(40) $k = 1$ e $3: \;\; \gamma_1 = \Phi_1\gamma_3, \; \gamma_3 = \Phi_1\gamma_1 \;\Rightarrow\; (1-\Phi_1^2)\gamma_1 = 0$ [(37)]

(41) $\gamma_1 = \gamma_3 = 0,$ e por (37) os zeros se propagam a $5, 6, 7, 9, \ldots$ [$|\Phi_1| < 1$]

(42) FAC: $\rho_{4j} = \Phi_1^j$; $\rho_k = 0$ fora dos múltiplos de 4 [(38)–(41)]

(43) FACP: $\phi_{44} = \Phi_1$ e $\phi_{kk} = 0$ para $k \neq 4$ [AU02 p. 93]

(44) comparação: o AR(1) "esticado" por 4; o AR(1) tem $\rho_k = \phi^k$ em todo k [cap. 2, D2.4]

(c) O multiplicativo: $(1-\phi L)(1-\Phi L^4)\, y_t = \varepsilon_t$.

(45) $(1-\phi L)(1-\Phi L^4) = 1 - \phi L - \Phi L^4 + \phi\Phi L^5$ [F8: quatro produtos]

(46) $y_t = \phi\, y_{t-1} + \Phi\, y_{t-4} - \phi\Phi\, y_{t-5} + \varepsilon_t$ [isola y_t]

(47) AR(5): $\phi_1 = \phi, \; \phi_2 = \phi_3 = 0, \; \phi_4 = \Phi, \; \phi_5 = -\phi\Phi$ [compara]

(48) restrições: $\phi_2 = 0, \; \phi_3 = 0, \; \phi_5 = -\phi_1\phi_4$; livres: $5 - 3 = 2$ [parcimônia]

$\gamma_{4j} = \Phi_1^j\gamma_0, \; \gamma_k = 0$ fora dos múltiplos; $\qquad (1-\phi L)(1-\Phi L^4) =$ AR(5) com $\phi_2 = \phi_3 = 0, \; \phi_5 = -\phi_1\phi_4$

Q12 · SARIMA$(1,1,0)(0,1,1)_4$: modelo, perdas, previsão e diagnóstico

Enunciado (lista, Q12). Série trimestral com SARIMA$(1,1,0)(0,1,1)_4$. Pede-se:

- (a) o modelo em B;
- (b) as observações perdidas;
- (c) as previsões em $h = 1, 2, 4, 5$ e a propagação da sazonalidade;
- (d) o diagnóstico de resíduos.

Nos slides: $(1-\phi L)(1-L)(1-L^4)\, y_t = (1+\Theta_1 L^4)\, \varepsilon_t$, com $\Theta_1 = -\Theta^{\text{lista}}$. Na lista: $(1-\phi B)(1-B)(1-B^4)y_t = (1-\Theta B^4)a_t$.

(49) $(1-\phi L)(1-L) = 1-(1+\phi)L+\phi L^2$ [F8]

(50) $\big(1-(1+\phi)L+\phi L^2\big)(1-L^4) = 1-(1+\phi)L+\phi L^2-L^4+(1+\phi)L^5-\phi L^6$ [F8]

(51) $y_t = (1+\phi)y_{t-1}-\phi y_{t-2}+y_{t-4}-(1+\phi)y_{t-5}+\phi y_{t-6}+\varepsilon_t+\Theta_1\varepsilon_{t-4}$ [isola y_t]

(52) $w_t = (1-L)(1-L^4)\,y_t = y_t-y_{t-1}-y_{t-4}+y_{t-5}$ [F8]

(53) w_t precisa de y_{t-5} : o primeiro é w_6; perdem-se $d+sD = 1+4 = 5$ [(52)]

(c) Previsões. Escreva (51) na data $T+h$ e aplique [F9]. Notação: $\hat{y}(h) = \hat{y}_{T+h/T}$.

(54) $\hat{y}(1) = (1+\phi)y_T-\phi y_{T-1}+y_{T-3}-(1+\phi)y_{T-4}+\phi y_{T-5}+\Theta_1\varepsilon_{T-3}$ [$\varepsilon_{T+1}\to 0$]

(55) $\hat{y}(2) = (1+\phi)\hat{y}(1)-\phi y_T+y_{T-2}-(1+\phi)y_{T-3}+\phi y_{T-4}+\Theta_1\varepsilon_{T-2}$ [F9]

(56) $\hat{y}(3) = (1+\phi)\hat{y}(2)-\phi\hat{y}(1)+y_{T-1}-(1+\phi)y_{T-2}+\phi y_{T-3}+\Theta_1\varepsilon_{T-1}$ [intermediário]

(57) $\hat{y}(4) = (1+\phi)\hat{y}(3)-\phi\hat{y}(2)+y_T-(1+\phi)y_{T-1}+\phi y_{T-2}+\Theta_1\varepsilon_T$ [último choque]

(58) $\hat{y}(5) = (1+\phi)\hat{y}(4)-\phi\hat{y}(3)+\hat{y}(1)-(1+\phi)y_T+\phi y_{T-1}$ [o MA some]

(59) $h\geq 5$: $(1-\phi L)(1-L)(1-L^4)\,\hat{y}(h) = 0$ [só a parte AR generalizada]

(60) raízes: 1 (dupla), -1, $\pm i$, $1/\phi$ [$z^4=1$ e $1-\phi z=0$]

A sazonalidade se propaga pelo termo y_{T+h-4}, ou $\hat{y}(h-4)$, que copia o mesmo trimestre do ano anterior. O MA sazonal corrige esse desenho com os quatro últimos choques e **some a partir de** $h=5$. Por (60), a função de previsão de longo prazo é tendência linear, mais padrão sazonal fixo de período 4, mais um termo ϕ^h que se apaga.

(d) Diagnóstico de resíduos (AU03):

(61) gráficos: resíduos padronizados, histograma, QQ-plot, FAC [AU03 p. 10]

(62) $LB(K) = T(T+2)\sum_{i=1}^{K}\frac{\hat{\rho}_i^2}{T-i} \sim \chi^2_{K-p-q-P-Q} = \chi^2_{K-2}$ [AU03 p. 15]

(63) pico nas defasagens 4 ou 8: parte sazonal mal especificada [sazonal]

(64) $JB = \frac{n}{6}\hat{S}^2+\frac{n}{24}(\widehat{K}-3)^2 \sim \chi^2_2$ [Jarque-Bera]

(65) ARCH-LM e FAC de $\hat{\varepsilon}_t^2$ [AU03 p. 19–22]

(66) estabilidade: Chow numa data escolhida antes, CUSUM [AU03 p. 25–31]

(67) $\widehat{\Theta}_1 \approx -1 \Rightarrow$ sobrediferenciação sazonal: usar dummies com $D=0$ [(7)–(8) na escala 4]

(68) Breusch-Godfrey: $\hat{\varepsilon}_t$ nas próprias defasagens, $nR^2 \sim \chi^2_m$ [AU03 p. 18]

A linha (64) é o teste de Jarque-Bera da AU03, p. 11–14.

Versão para a prova

Q9:

1. $w_t = -(1-\phi)y_{t-1}+\varepsilon_t$.
2. Aplique $(1-L)$ aos dois lados de $(1-\phi L)y_t = \varepsilon_t$: $(1-\phi L)w_t = (1-L)\varepsilon_t$.
3. A raiz do MA é $z=1$: não invertível, $\pi_j = -(1-\phi)$ não somáveis, sem AR(∞).
4. A assinatura é $\rho_w(1) = -(1-\phi)/2$.
5. Custos: estimação na fronteira, previsão com variância que cresce e, se $\phi < \frac{1}{2}$, mais variância.

Q10:

1. $\phi(L)w_t = \theta(L)\varepsilon_t$.
2. $y_t = (1+\phi)y_{t-1} - \phi y_{t-2} + a_t - \theta a_{t-1}$, com a soma dos coeficientes AR igual a 1.
3. TS tem choque transitório, DS permanente.
4. A diferença de uma TS é $\beta + (1-L)u_t$, não invertível. O certo é regredir em t.

Q11:

1. $\gamma_0 = \sigma^2/(1-\Phi_1^2)$ e $\gamma_{4j} = \Phi_1^j \gamma_0$.
2. Prove $\gamma_1 = \gamma_2 = \gamma_3 = 0$ pelas linhas (39)–(41).
3. A FACP tem um pico só, em 4.
4. Multiplicativo: AR(5) com $\phi_2 = \phi_3 = 0$ e $\phi_5 = -\phi_1\phi_4$.

Q12:

1. Expanda em duas etapas, (49)–(51).
2. Perdem-se 5 observações.
3. As previsões vêm de (54)–(58): o MA some em $h = 5$, e y_{T+h-4} propaga a sazonalidade.
4. Diagnóstico: as linhas (61)–(68).

Conferência

Q9 e Q10:

- $\rho_w(1)$ é $-0{,}40$, $-0{,}25$ e $-0{,}05$ para $\phi = 0{,}2$, $0{,}5$ e $0{,}9$, com $-0{,}25$ conferido pelo `ARMAacf`;
- $\text{Var}(w)$ é 1,6667, 1,3333 e 1,0526, contra os 1,0417, 1,3333 e 5,2632 de $\text{Var}(y)$, o que confirma o limiar $\phi = \frac{1}{2}$ de (15);
- a diferença de um ruído branco tem $\rho_1 = -0{,}5$;
- na Q10(b), com $\phi = 0{,}5$ e $\theta = 0{,}3$, os coeficientes AR são 1,5 e $-0{,}5$, e somam 1.

Q11, com $\Phi_1 = 0{,}6$:

- $\gamma_0 = 1{,}5625$, $\gamma_4 = 0{,}9375$ e $\gamma_8 = 0{,}5625$;
- pelo R, $\rho_1 = 0$, $\rho_4 = 0{,}6$ e $\rho_8 = 0{,}36$;
- o multiplicativo com $\phi = 0{,}5$ dá $\phi_5 = -0{,}3$.

Q12, com $\phi = 0{,}4$ e $\Theta^{\text{lista}} = 0{,}6$:

- os coeficientes de y_{t-1} a y_{t-6} são 1,4; $-0{,}4$; 0; 1; $-1{,}4$; 0,4;
- as previsões de (54)–(58), aplicadas a uma série simulada com os resíduos do modelo, coincidem com o `predict` do R em $h = 1$ a 5, com diferença máxima da ordem de 10^{-13};
- perdem-se 5 observações.

CAPÍTULO 29

Q9 · Sobrediferenciação: diferenciar um AR(1) que já é estacionário

← índice · anterior: Q8 · próxima: Q10 · resolução curta em 03_lista · demonstração D03.2 em 03_teoria

O que a questão pede

Para $y_t = \phi y_{t-1} + \varepsilon_t$ com $|\phi| < 1$ e $w_t = \Delta y_t$:

- **(a) mostrar** que $w_t = -(1-\phi)y_{t-1} + \varepsilon_t$ e que $(1-\phi L)w_t = (1-L)\varepsilon_t$, identificando os polinômios;
- **(b) mostrar** que o MA de w_t tem raiz unitária e dizer o que isso implica para o AR(∞);
- **(c) discutir** por que diferenciar uma série estacionária prejudica a previsão e a estimação.

Da lista para os slides

Mesmo modelo, com L no lugar de B. O MA de w_t é $1 - L$: nos slides, $1 + \theta L$ com $\theta = -1$; na lista, $1 - \theta B$ com $\theta = 1$.

Ferramentas

- **Slides:** AU02, p. 21 (AR(1) como MA(∞)), p. 22–23 (π_j do MA(1) e a condição $|\theta| < 1$), p. 33 (raízes do MA), p. 63 (variância do AR(1)).
- **Caixa:** [F2]; [F5]; [F8].
- **Livro:** MAT, §1.4–1.5 (processo integrado; raiz unitária no MA é não invertibilidade); BJRL, cap. 4; ENDERS, cap. 4.

Demonstração minuciosa

(a) As duas formas de w_t

Primeira forma. Substitua o modelo em $w_t = y_t - y_{t-1}$:

$$w_t = (\phi y_{t-1} + \varepsilon_t) - y_{t-1} = (\phi - 1)y_{t-1} + \varepsilon_t = \boxed{-(1-\phi)y_{t-1} + \varepsilon_t}$$

Segunda forma. O AR(1) em operador é $(1-\phi L)y_t = \varepsilon_t$. Aplique $(1-L)$ aos dois lados:

$$(1-L)(1-\phi L)y_t = (1-L)\varepsilon_t.$$

Os polinômios em L comutam, porque o produto [F8] dá $1 - (1+\phi)L + \phi L^2$ nas duas ordens. Então $(1-\phi L)\underbrace{(1-L)y_t}_{w_t} = (1-L)\varepsilon_t$, ou seja,

$$\boxed{(1-\phi L)\, w_t = (1-L)\, \varepsilon_t}$$

Pela forma MA(∞), como pede a lista: $y_t = \Psi(L)\varepsilon_t$ com $\Psi(L) = (1-\phi L)^{-1}$, logo $w_t = (1-L)y_t = (1-L)\Psi(L)\varepsilon_t = \frac{1-L}{1-\phi L}\varepsilon_t$. Multiplicando por $(1-\phi L)$, obtém-se a mesma equação.

Polinômios:

- AR: $\phi(L) = 1 - \phi L$, o mesmo de y;
- MA: $\theta(L) = 1 - L$, um ARMA(1,1) com $\theta = -1$ nos slides.

(b) A raiz unitária do MA

$\theta(z) = 1 - z = 0 \Rightarrow z = 1$, e $|z| = 1$ não é maior que 1: a raiz está **sobre** o círculo unitário. Pela AU02, p. 33, o processo **não é invertível**.

O que acontece com o AR(∞). $\pi(L) = \frac{1-\phi L}{1-L}$. A expansão de $(1-L)^{-1} = 1 + L + L^2 + \cdots$ é a série geométrica com razão de módulo 1, que **não converge** [F2]. Mesmo assim, formalmente:

$$\pi(L) = (1 - \phi L)(1 + L + L^2 + \cdots) = 1 + (1 - \phi)L + (1 - \phi)L^2 + \cdots$$

Como $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots$, vale $\pi_j = -(1 - \phi)$ **para todo** j: os pesos não decaem. Com $\phi = 0{,}6$, $\pi_5 = -0{,}4$, igual a π_1. Então:

$$\boxed{\pi_j = -(1-\phi) \text{ para todo } j \implies \sum_{j \geq 1} |\pi_j| = \infty}$$

Conclusão: não existe representação AR(∞) convergente, e ε_t não pode ser recuperado de $w_t, w_{t-1}, \ldots$

(c) Por que sobrediferenciar prejudica

Os momentos mostram o estrago. Use $\gamma_k = \phi^k \gamma_0$ e $\gamma_0 = \sigma^2/(1-\phi^2)$ (AU02, p. 63):

- **Variância:** $V(w_t) = V(y_t) + V(y_{t-1}) - 2\,\mathrm{Cov}(y_t, y_{t-1}) = 2\gamma_0 - 2\gamma_1 = 2\gamma_0(1-\phi)$ [F5]. Como $1 - \phi^2 = (1-\phi)(1+\phi)$, fica $V(w_t) = \frac{2\sigma^2}{1+\phi}$.
- **Autocovariância:** $\mathrm{Cov}(w_t, w_{t-1}) = \mathrm{Cov}(y_t - y_{t-1},\ y_{t-1} - y_{t-2}) = \gamma_1 - \gamma_2 - \gamma_0 + \gamma_1 = \gamma_0(2\phi - 1 - \phi^2) = -\gamma_0(1-\phi)^2$.
- **Autocorrelação:** $\rho_1(w) = \frac{-\gamma_0(1-\phi)^2}{2\gamma_0(1-\phi)} = -\frac{1-\phi}{2}$.

Com $\phi = 0{,}6$ e $\sigma^2 = 1$: $V(y) = 1{,}5625$, $V(w) = 1{,}25$ e $\rho_1(w) = -0{,}2$. A FAC de w ganha um **pico negativo em 1**: é a assinatura da sobrediferenciação. Se y fosse ruído branco, seria $\rho_1 = -0{,}5$.

Consequências para a estimação:

1. O MA verdadeiro está na fronteira, $\theta = -1$. A MV tende a empilhar estimativas em $|\hat{\theta}| = 1$ (o "pile-up" de D03.2), e os erros-padrão e testes deixam de ter a distribuição usual.
2. A verossimilhança condicional, que reconstrói ε_t por recursão (AU02, p. 59), **não esquece o valor inicial** quando $|\theta| = 1$, e os resíduos ficam contaminados.
3. Estima-se um parâmetro a mais, o MA, que não existia no processo verdadeiro: perde-se parcimônia.

Consequências para a previsão:

1. O modelo em diferença trata y como I(1): a previsão de y_{T+h} **não volta à média**, quando o verdadeiro $\hat{y}_{T+h} \to \mu$.
2. A variância do erro cresce **sem limite** com h, quando a verdadeira converge para γ_0: os intervalos ficam largos demais.
3. Perde-se a informação sobre o **nível** da série.

Regra: só diferencie com evidência de raiz unitária, com ADF e KPSS juntos (AU04; MAT §2).

Do meu caderno (26/08)

O caderno calcula γ_0 do AR(1) com a decomposição **A + B + C**: $E\big((\phi_1(y_{t-1}-\mu)+\varepsilon_t)^2\big)$. É a conta que dá o γ_0 usado no item (c). Completando o que ficou aberto:

- **(A)** $\phi_1^2 E\big((y_{t-1}-\mu)^2\big) = \phi_1^2\gamma_0$: certo, por estacionariedade;
- **(B)** $2\phi_1 E\big((y_{t-1}-\mu)\varepsilon_t\big)$: o caderno abre $y_{t-1}-\mu = \phi_1(y_{t-2}-\mu)+\varepsilon_{t-1}$ e para. A conclusão é $B=0$, porque y_{t-1} só tem choques até $t-1$, e nenhum se correlaciona com ε_t [F6];
- **(C)** $E(\varepsilon_t^2)=\sigma^2$: certo.

Logo $\gamma_0 = \phi_1^2\gamma_0 + \sigma^2$, e $\gamma_0 = \sigma^2/(1-\phi_1^2)$, como na AU02, p. 63. A anotação "$E(\varepsilon_t^2) \neq E(\varepsilon_t)^2$" também está certa: a primeira vale σ^2, e a segunda, 0.

O que o livro acrescenta

MAT (§1.5) observa que um ARIMA pode ter raiz unitária no **MA**, e não só no AR, e que nesse caso o modelo é não invertível. A Q9 é exatamente isso. É também a base do teste KPSS: sob a hipótese de estacionariedade, a diferença tem uma raiz unitária no MA.

Armadilhas e variações

- **Dizer "não invertível" sem a cadeia completa:** raiz $z=1 \Rightarrow \pi_j$ não decaem $\Rightarrow$ não há AR(∞). As três partes valem ponto.
- **Variância:** escrever $V(w)=2\sigma^2$, que só vale se y for ruído branco.
- **Variações:** ruído branco diferenciado e $\phi = 0{,}9$ no banco; $\phi = 0{,}5$ completo no Simulado 01, Q3.

Q10 · ARIMA, raiz unitária e tendência determinística

← índice · anterior: Q9 · próxima: Q11 · resolução curta em 03_lista

O que a questão pede

- **(a) Mostrar** que, se $y_t \sim$ ARIMA(p,1,q), então $\Delta y_t \sim$ ARMA(p, q).
- **(b) Expandir** o ARIMA(1,1,1) numa equação de diferenças para y_t.
- **(c) Discutir** a diferença entre raiz unitária e tendência determinística.
- **(d) Dizer** o que resulta de diferenciar uma série que só tem tendência determinística, e se isso é adequado.
- **(e) Explicar** por que tirar a tendência por regressão é preferível, ligando com a sobrediferenciação.

Da lista para os slides

Lista	Slides
$(1-\phi B)(1-B)y_t = (1-\theta B)a_t$	$(1-\phi L)(1-L)y_t = (1+\theta^s L)\varepsilon_t$, com $\theta^s = -\theta$
tendência determinística $\alpha + \beta t$	$TD_t = a + bt$ (MAT, §1.1)

Ferramentas

- **Slides:** AU01, p. 28–30 (passeio, drift e tendência); MAT, §1.1–1.4 e Quadro 1 (p. 20).
- **Caixa:** [F8] multiplicar polinômios; [F5].
- **Livro:** ENDERS, cap. 4 (DS × TS); MAT, decomposição de Beveridge-Nelson (§1.6).

Demonstração minuciosa

(a) A diferença de um ARIMA(p,1,q) é um ARMA(p, q)

Por definição, $y_t \sim$ ARIMA(p,1,q) significa $\phi(L)(1-L)y_t = \theta(L)\varepsilon_t$, com $\phi(z)$ e $\theta(z)$ com todas as raízes fora do círculo (MAT, §1.4). Defina $w_t = (1-L)y_t = \Delta y_t$. Substituindo:

$$\phi(L)\, w_t = \theta(L)\, \varepsilon_t.$$

É um ARMA(p, q) para w_t: estacionário, porque as raízes de ϕ estão fora, e invertível, porque as de θ estão fora. **A raiz unitária está toda no fator** $(1-L)$, que a diferença remove. ■

(b) Expansão do ARIMA(1,1,1)

Multiplique o lado AR termo a termo [F8]:

$$(1-\phi L)(1-L) = 1\cdot 1 - 1\cdot L - \phi L\cdot 1 + \phi L\cdot L = 1-(1+\phi)L+\phi L^2.$$

Então $\left(1-(1+\phi)L+\phi L^2\right)y_t = (1+\theta^s L)\varepsilon_t$. Aplicando os operadores:

$$y_t - (1+\phi)y_{t-1} + \phi y_{t-2} = \varepsilon_t + \theta^s \varepsilon_{t-1}$$

$$\boxed{y_t = (1+\phi)y_{t-1} - \phi y_{t-2} + \varepsilon_t + \theta^s \varepsilon_{t-1}} \qquad \text{(lista: } \cdots + a_t - \theta a_{t-1}\text{)}$$

A marca da raiz unitária: os coeficientes AR somam $(1+\phi)+(-\phi) = 1$. Com $\phi = 0{,}4$, os coeficientes são 1,4 e −0,4. O polinômio $1 - 1{,}4z + 0{,}4z^2$ tem raiz $z = 1$: vale $1 - 1{,}4 + 0{,}4 = 0$.

(c) Raiz unitária × tendência determinística

	Raiz unitária (DS)	Tendência determinística (TS)
Modelo	$y_t = \beta + y_{t-1} + u_t$	$y_t = \alpha + \beta t + u_t$, com u_t estacionário
Solução	$y_t = y_0 + \beta t + \sum_{i\le t} u_i$	$y_t = \alpha + \beta t + u_t$
Efeito de um choque	**permanente**: entra na soma para sempre	**transitório**: some à velocidade de u_t
Variância	cresce com t	constante em torno da reta
Intervalo de previsão	alarga sem limite com h	fica limitado
Como estacionarizar	**diferenciar**	**regredir em** t e ficar com o resíduo

As duas séries **parecem iguais no gráfico**: crescem ao longo de uma reta. O que muda é o que acontece depois de um choque. MAT (Quadro 1) chama a primeira de "diferença estacionária" e a segunda de "tendência estacionária".

(d) Diferenciar uma série TS

Com $y_t = \alpha + \beta t + u_t$:

$$\Delta y_t = (\alpha+\beta t+u_t) - (\alpha+\beta(t-1)+u_{t-1}) = \beta + u_t - u_{t-1} = \beta + (1-L)u_t.$$

- Se u_t é ruído branco: $\Delta y_t = \beta + \varepsilon_t - \varepsilon_{t-1}$, um MA(1) com $\theta^s = -1$, **não invertível**, com $\rho_1 = \frac{-1}{1+1} = -0{,}5$.
- Se u_t é AR(1): $(1-\phi L)(\Delta y_t - \beta) = (1-L)\varepsilon_t$, exatamente a Q9.

$$\boxed{\Delta y_t = \beta + (1-L)\,u_t}$$

Conclusão: não é adequado. Diferenciar uma TS cria o fator $(1-L)$, uma raiz unitária, no MA. É a sobrediferenciação.

(e) Por que tirar a tendência por regressão é preferível (para uma TS)

1. **Mantém o modelo invertível:** o resíduo u_t é um ARMA estacionário comum, sem raiz no MA.
2. **Estimação regular:** sem parâmetro na fronteira, a inferência usual vale (Q9c).
3. **Previsão correta:** a previsão volta para a reta $\alpha + \beta(T + h)$, e os intervalos ficam limitados. O modelo diferenciado erraria nas duas coisas.
4. **Ligação com a sobrediferenciação:** a diferença é o remédio **para a raiz unitária**. Usada numa série sem raiz unitária, ela "sobra" e vira o fator $(1 - L)$ no MA.

O erro simétrico também existe: tirar a tendência por regressão de uma série DS deixa uma **raiz unitária no resíduo**, e a regressão em *t* fica espúria. **Quem decide é o teste:** ADF com constante e tendência (MAT, §2; AU04).

Do meu caderno (19/08)

"Passeio com drift: $Y_t = \alpha + Y_{t-1} + \varepsilon_t$"; "$+\alpha_2 t$: termo de tendência determinística"; "teste de **raiz unitária**"; "$|\phi| < 1$ estável; $|\phi| \geq 1$ instável"; "tendência estocástica: ϕ". Essa última anotação resume a questão: **tendência estocástica é** $\phi = 1$, a raiz unitária, e não uma função de *t*.

O que o livro acrescenta

MAT (§1.6) apresenta a **decomposição de Beveridge-Nelson**: todo processo I(1) é a soma de uma tendência estocástica (um passeio aleatório) com um componente estacionário. A raiz unitária não é "uma tendência mais forte". É outro tipo de não estacionariedade.

Armadilhas e variações

- **Na (b), esquecer de trocar o sinal do MA** ao passar dos slides para a lista.
- **Na (d), parar em "$\Delta y_t = \beta + u_t - u_{t-1}$"** sem dizer que o resultado é não invertível e, portanto, inadequado. O verbo é "esse procedimento é adequado?".
- **Variações:** a expansão do ARIMA(2,1,0) e a TS com ruído branco no banco; TS × DS com números no Simulado 03, Q1.

CAPÍTULO 31

Q11 · SAR(1)$_4$ e o multiplicativo como AR(5) restrito

← índice · anterior: Q10 · próxima: Q12 · resolução curta em 03_lista

O que a questão pede

Para $y_t = \Phi y_{t-4} + \varepsilon_t$ com $|\Phi| < 1$:

- **(a) calcular** γ_0, γ_4, γ_8 e γ_{4m}, e dizer quanto vale γ_k fora dos múltiplos de 4;
- **(b) descrever** a FAC e a FACP e comparar com o AR(1);
- **(c) escrever** $(1-\phi L)(1-\Phi L^4)y_t = \varepsilon_t$ como AR(5) e dar as restrições.

Da lista para os slides

Mesma notação, com L no lugar de B. O SAR(1)$_4$ é um AR(4) com $\phi_1 = \phi_2 = \phi_3 = 0$ e $\phi_4 = \Phi$. Assim, as ferramentas do AR(p) dos slides valem diretamente.

Ferramentas

- **Slides:** AU02, p. 63–64 (γ_0 e γ_k do AR(1), cujo método se repete aqui), p. 68 (Yule-Walker do AR(p)), p. 90–93 (FACP e o corte do AR); AU05 (sazonalidade).
- **Caixa:** [F6]; [F8].
- **Livro:** BJRL, cap. 9 (modelos sazonais multiplicativos); ENDERS, cap. 2 (sazonalidade).

Demonstração minuciosa

(a) Autocovariâncias

γ_0. Eleve ao quadrado e tire a esperança:

$$\gamma_0 = E\big((\Phi y_{t-4} + \varepsilon_t)^2\big) = \Phi^2 E(y_{t-4}^2) + 2\Phi \underbrace{E(y_{t-4}\varepsilon_t)}_{0\ [F6]} + E(\varepsilon_t^2) = \Phi^2\gamma_0 + \sigma^2,$$

$$\boxed{\gamma_0 = \frac{\sigma^2}{1-\Phi^2}}$$

γ_k, $k \geq 1$. Multiplique por y_{t-k}: $\gamma_k = \Phi\gamma_{k-4} + E(\varepsilon_t y_{t-k}) = \Phi\gamma_{k-4}$, com $\gamma_{-j} = \gamma_j$.

Múltiplos de 4:

- $\gamma_4 = \Phi\gamma_0$;
- $\gamma_8 = \Phi\gamma_4 = \Phi^2\gamma_0$;
- por indução, $\gamma_{4m} = \Phi^m\gamma_0$.

$$\boxed{\gamma_{4m} = \Phi^m \frac{\sigma^2}{1-\Phi^2}, \qquad \rho_{4m} = \Phi^m}$$

Fora dos múltiplos:

- $k = 1$: $\gamma_1 = \Phi\gamma_{-3} = \Phi\gamma_3$.
- $k = 3$: $\gamma_3 = \Phi\gamma_{-1} = \Phi\gamma_1$.
- Substituindo uma na outra: $\gamma_1 = \Phi^2\gamma_1$, ou $\gamma_1(1 - \Phi^2) = 0$. Como $\Phi^2 \neq 1$, $\gamma_1 = 0$, e daí $\gamma_3 = 0$.
- $k = 2$: $\gamma_2 = \Phi\gamma_{-2} = \Phi\gamma_2$, ou $\gamma_2(1 - \Phi) = 0$, logo $\gamma_2 = 0$.
- Para $k \geq 5$ fora dos múltiplos, $\gamma_k = \Phi\gamma_{k-4}$ cai num desses zeros.

$$\boxed{\gamma_k = 0 \text{ se } k \text{ não é múltiplo de 4}}$$

Números, com $\Phi = 0{,}7$ e $\sigma^2 = 1$: $\gamma_0 = 1/0{,}51 = 1{,}9608$, $\rho_4 = 0{,}7$, $\rho_8 = 0{,}49$, e $\rho_1 = \rho_2 = \rho_3 = 0$.

(b) FAC e FACP

	AR(1), ϕ	SAR(1)$_4$, Φ
FAC	ϕ^k em **todas** as defasagens, decaindo	Φ^m **só em** 4, 8, 12, ...; zero no resto
FACP	um pico, em 1 ($\phi_{11} = \phi$)	um pico, em 4 ($\phi_{44} = \Phi$); zero no resto

O SAR(1)$_4$ é o **AR(1) "esticado"**: a dependência pula de ano em ano, de trimestre para o mesmo trimestre. Pela AU02, p. 93, a FACP de um AR(p) corta depois de p. Aqui, o AR(4) tem $\phi_4 = \Phi$ e os outros zeros, então $\phi_{44} = 0{,}7$ e $\phi_{88} = 0$.

(c) O multiplicativo como AR(5) restrito

Multiplique termo a termo [F8]:

$$(1 - \phi L)(1 - \Phi L^4) = 1 - \Phi L^4 - \phi L + \phi\Phi L^5 = 1 - \phi L - \Phi L^4 + \phi\Phi L^5.$$

Então $y_t - \phi y_{t-1} - \Phi y_{t-4} + \phi\Phi y_{t-5} = \varepsilon_t$, ou

$$\boxed{y_t = \phi y_{t-1} + 0 \cdot y_{t-2} + 0 \cdot y_{t-3} + \Phi y_{t-4} - \phi\Phi\, y_{t-5} + \varepsilon_t}$$

Comparando com o AR(5) livre, $y_t = \sum_{i=1}^{5} \phi_i y_{t-i} + \varepsilon_t$, são **três restrições**:

$$\phi_2 = 0, \qquad \phi_3 = 0, \qquad \phi_5 = -\phi_1\phi_4.$$

O AR(5) livre tem 5 coeficientes; o multiplicativo tem 2. Com $\phi = 0{,}4$ e $\Phi = 0{,}7$: $\phi_1 = 0{,}4$, $\phi_4 = 0{,}7$ e $\phi_5 = -0{,}28 = -(0{,}4)(0{,}7)$.

Do meu caderno

O caderno não tem aula de sazonalidade antes de 10/09. A ferramenta usada aqui é a do AR(1) de 26/08: multiplicar por $(y_{t-k} - \mu)$, tirar a esperança e obter $\gamma_k = \phi_1\gamma_{k-1}$ ("$\gamma_1 = \phi_1\gamma_0$, $\gamma_2 = \phi_1\gamma_1$, $\gamma_3 = \phi_1\gamma_2$"). Para o SAR, troque o passo 1 pelo passo 4: $\gamma_k = \Phi\gamma_{k-4}$.

O que o livro acrescenta

BJRL (cap. 9) justifica a forma **multiplicativa**. O fator $(1 - \Phi L^4)$ liga cada trimestre ao mesmo trimestre do ano anterior, e o fator $(1 - \phi L)$ liga trimestres vizinhos. O termo $\phi\Phi L^5$ é a **interação** dos dois. Por isso a FAC do multiplicativo deixa de ser zero fora dos múltiplos de 4: o fator $(1 - \phi L)$ espalha a dependência para as defasagens vizinhas, e a FACP passa a ter valores relevantes em 1, 4 e 5.

Armadilhas e variações

- **Na (a), dizer "$\gamma_1 = \Phi^{1/4}\gamma_0$"** ou outra interpolação: fora dos múltiplos, é zero, e a prova vem do sistema $\gamma_1 = \Phi\gamma_3$, $\gamma_3 = \Phi\gamma_1$.
- **Contar 2 restrições** em vez de 3: os dois zeros e o produto.
- **Variações:** SAR(1)$_{12}$ e o MA(13) restrito do SMA no banco; $\Phi = 0{,}6$ e o AR(5) com $(0{,}5;\ 0{,}6)$ no Simulado 02, Q3.

CAPÍTULO 32

Q12 · SARIMA$(1,1,0)(0,1,1)_4$ trimestral

← índice · anterior: Q11 · próxima: Q13 · resolução curta em 03_lista

O que a questão pede

- **(a) Escrever** o modelo em B.
- **(b) Dizer** quantas observações se perdem com $(1-B)(1-B^4)$, e por quê.
- **(c) Derivar** $y_{T+h|T}$ para $h = 1, 2, 4, 5$ e mostrar como a sazonalidade se propaga.
- **(d) Discutir** o diagnóstico de resíduos.

Da lista para os slides

Lista	Slides
$(1-\phi B)(1-B)(1-B^4)y_t = (1-\Theta B^4)a_t$	$(1-\phi L)(1-L)(1-L^4)y_t = (1+\Theta^s L^4)\varepsilon_t$, com $\Theta^s = -\Theta$
$y_{T+h\|T}$, $\mathscr{F}_T$	$\hat{y}_{T+h/T} = E(y_{T+h} \mid \Omega_T)$ (AU02, p. 72)

Ferramentas

- **Slides:** AU02, p. 72–75 (previsão recursiva e erro do AR), p. 85 (previsão do ARMA(1,1): o MA some depois de q passos); AU03, p. 9–19 (diagnóstico: gráficos, Jarque-Bera, Ljung-Box, Breusch-Godfrey, ARCH); AU05 (SARIMA).
- **Caixa:** [F8] multiplicar polinômios; [F9] esperança condicional na previsão.
- **Livro:** BJRL, cap. 5 (previsão) e cap. 9 (sazonais); ENDERS, cap. 2.

Demonstração minuciosa

(a) O modelo

$$\boxed{(1-\phi L)(1-L)(1-L^4)\,y_t = (1+\Theta^s L^4)\,\varepsilon_t}$$ (lista: $(1-\phi B)(1-B)(1-B^4)y_t = (1-\Theta B^4)a_t$)

Expandindo o lado AR [F8], em duas etapas:

1. $(1-\phi L)(1-L) = 1 - L - \phi L + \phi L^2 = 1 - (1+\phi)L + \phi L^2$.
2. Multiplicando por $(1-L^4)$, cada termo do primeiro fator vezes 1 e vezes $-L^4$:

$$\big(1-(1+\phi)L+\phi L^2\big)(1-L^4) = 1-(1+\phi)L+\phi L^2 - L^4 + (1+\phi)L^5 - \phi L^6.$$

Passando para a forma de equação, todos os y defasados à direita:

$$\boxed{y_t = (1+\phi)y_{t-1} - \phi y_{t-2} + y_{t-4} - (1+\phi)y_{t-5} + \phi y_{t-6} + \varepsilon_t + \Theta^s \varepsilon_{t-4}}$$

Com $\phi = 0{,}4$, os coeficientes de y_{t-1} a y_{t-6} são 1,4; −0,4; 0; 1; −1,4; 0,4.

(b) Observações perdidas: 5

$w_t = (1-L)(1-L^4)y_t = (1-L-L^4+L^5)y_t = y_t - y_{t-1} - y_{t-4} + y_{t-5}$.

- Para calcular w_t, é preciso ter y_{t-5}.
- Com dados $y_1, \dots, y_T$, o primeiro w calculável é w_6, que usa y_1.
- Sobram $T-5$ valores de w.

$$\boxed{d + sD = 1 + 4 \cdot 1 = 5 \text{ observações perdidas}}$$

(c) Equações de previsão

Escreva o modelo na data $T+h$ e aplique as três regras de [F9]: o que é conhecido fica, y futuro vira a previsão, e choque futuro vira zero. Notação: $\hat{y}(h) = \hat{y}_{T+h/T}$.

$h = 1$. Os índices: $y_{T+1-1} = y_T$, y_{T-1}, y_{T-3}, y_{T-4}, y_{T-5} e $\varepsilon_{T+1-4} = \varepsilon_{T-3}$, todos conhecidos. E ε_{T+1} vira 0.

$$\hat{y}(1) = (1+\phi)y_T - \phi y_{T-1} + y_{T-3} - (1+\phi)y_{T-4} + \phi y_{T-5} + \Theta^s \varepsilon_{T-3}$$

$h = 2$. Agora y_{T+1} é futuro e vira $\hat{y}(1)$; ε_{T-2} é conhecido.

$$\hat{y}(2) = (1+\phi)\hat{y}(1) - \phi y_T + y_{T-2} - (1+\phi)y_{T-3} + \phi y_{T-4} + \Theta^s \varepsilon_{T-2}$$

$h = 3$, que não é pedido, mas $h = 4$ e $h = 5$ usam:

$$\hat{y}(3) = (1+\phi)\hat{y}(2) - \phi\hat{y}(1) + y_{T-1} - (1+\phi)y_{T-2} + \phi y_{T-3} + \Theta^s \varepsilon_{T-1}$$

$h = 4$. O último choque conhecido, ε_T, entra aqui.

$$\hat{y}(4) = (1+\phi)\hat{y}(3) - \phi\hat{y}(2) + y_T - (1+\phi)y_{T-1} + \phi y_{T-2} + \Theta^s \varepsilon_T$$

$h = 5$. O termo MA seria ε_{T+1}, futuro, e **some**. O y_{T+1}, que aparece como y_{t-4}, vira $\hat{y}(1)$.

$$\hat{y}(5) = (1+\phi)\hat{y}(4) - \phi\hat{y}(3) + \hat{y}(1) - (1+\phi)y_T + \phi y_{T-1}$$

Essas fórmulas foram conferidas contra o `predict()` do R numa série simulada com $\phi = 0{,}4$ e $\Theta^s = -0{,}6$: diferença máxima da ordem de 10^{-15}.

Como a sazonalidade se propaga.

1. O termo y_{T+h-4}, ou $\hat{y}(h-4)$, traz o **mesmo trimestre do ano anterior**: o desenho sazonal é copiado para frente.
2. O MA sazonal corrige esse desenho com os quatro últimos choques, ε_{T-3} a ε_T, e **para em** $h = 4$.
3. Para $h \geq 5$, as previsões obedecem à equação homogênea $(1-\phi L)(1-L)(1-L^4)\hat{y}(h) = 0$. As raízes são 1 (dupla: uma do $1-L$ e outra do $1-L^4$), -1, $\pm i$ (as outras três raízes de $z^4 = 1$) e $1/\phi$. A função de previsão é, portanto, **tendência linear + padrão sazonal fixo de período 4 + termo ϕ^h que some**.

(d) Diagnóstico de resíduos (AU03)

1. **Gráficos** (AU03, p. 10): resíduos padronizados no tempo (quebras, *outliers*, variância mudando), histograma, QQ-plot e FAC dos resíduos. **Olhe as defasagens 4 e 8**: um pico ali indica a parte sazonal mal especificada.
2. **Ljung-Box** (AU03, p. 15): $H_0 : \rho_1 = \cdots = \rho_K = 0$ nos erros, com $LB(K) = T(T+2)\sum_{i=1}^{K} \frac{\hat{\rho}_i^2}{T-i} \sim \chi^2_\nu$ e $\nu = K - p - q - P - Q = K - 2$ aqui.
3. **Breusch-Godfrey** (AU03, p. 18): alternativa do tipo LM, com $nR^2 \sim \chi^2_m$.
4. **Normalidade, Jarque-Bera** (AU03, p. 11–14): $JB = \frac{n}{6}\hat{S}^2 + \frac{n}{24}(\widehat{K} - 3)^2 \sim \chi^2_2$, com H_0: $S = 0$ e $K = 3$.
5. **Heterocedasticidade condicional** (AU03, p. 19): FAC de $\hat{\varepsilon}_t^2$ e teste ARCH-LM.
6. **Estabilidade:** Chow numa data escolhida *a priori* e CUSUM (análise recursiva).
7. **Invertibilidade:** $\widehat{\Theta}$ perto de 1 sugere **sobrediferenciação sazonal**, ou seja, sazonalidade determinística. A alternativa é usar dummies trimestrais com $D = 0$.

Do meu caderno (09/09)

O caderno desenha a FAC e a FACP do AR(2) e do MA(2), as "assinaturas" que se procuram nos resíduos, e anota "análise de **estabilidade** dos parâmetros" e "**quebra estrutural**", os itens 6 e 7 acima. Em 10/09 vêm a previsão iterada e as métricas, ligadas à Q15.

O que o livro acrescenta

BJRL (cap. 5) dá a regra geral que esta questão aplica: **as previsões de um ARIMA(p, d, q) obedecem, a partir de $h > q$, à parte autorregressiva generalizada** $\phi(L)(1-L)^d$. A forma da função de previsão de longo prazo é lida nas raízes desse polinômio. O MA só ajusta o "ponto de partida".

Armadilhas e variações

- **Índices.** O erro mais comum é trocar y_{T-3} por y_{T-4} em $\hat{y}(1)$. Escreva primeiro a equação na data t, depois troque t por $T + h$.
- **Dizer que o MA some em $h = 2$.** Ele é **sazonal**, de defasagem 4, e some só em $h = 5$.
- **Variações:** o mesmo modelo com números, com previsões de $h = 1$ a 5, no Simulado 03, Q3; o SARIMA$(0,1,1)(0,1,1)_4$ no banco.

CAPÍTULO 33

Bloco 3 — Integrados, ARIMA e SARIMA

Q9 · Sobrediferenciação

Ideia: $\phi(B)\Delta y_t = (1-B)\theta(B)\varepsilon_t$. O MA ganha raiz unitária. Resolução em 03_lista e D03.2 · BJRL cap. 4.

Variação A. Diferencie um ruído branco. **Resposta.** $\Delta y_t = \varepsilon_t - \varepsilon_{t-1}$, com $\rho_1 = -0{,}5$, o valor-limite de um MA(1), e Var $= 2\sigma^2$: a variância **dobra**.

Variação B. AR(1) com $\phi = 0{,}9$. **Resposta.** $\rho_1(\Delta y) = -(1-\phi)/2 = -0{,}05$. Quase não aparece na FAC: com ϕ perto de 1, a sobrediferenciação é difícil de ver, e o teste de raiz unitária tem pouco poder (D03.3).

Q10 · ARIMA × tendência determinística

Ideia: DS se diferencia; TS se regride em *t*. Resolução em 03_lista · MAT · ENDERS cap. 4.

Variação A. $y_t = \alpha + \beta t + u_t$, com u_t ruído branco, foi diferenciado. **Resposta.** $\Delta y_t = \beta + u_t - u_{t-1}$: um MA(1) com $\theta = 1$, não invertível, com $\rho_1 = -0{,}5$. O procedimento não é adequado.

Variação B. Expanda o ARIMA(2,1,0) $(1-\phi_1 B - \phi_2 B^2)(1-B)y_t = a_t$. **Resposta.** $y_t = (1+\phi_1)y_{t-1} + (\phi_2 - \phi_1)y_{t-2} - \phi_2 y_{t-3} + a_t$. Os coeficientes somam 1: é a raiz unitária.

Q11 · SAR e o AR restrito

Ideia: o SAR(1)$_s$ é um AR(1) "em anos". O multiplicativo gera termos cruzados. Resolução em 03_lista · BJRL cap. 9.

Variação A. SAR(1)$_{12}$ com $\Phi = 0{,}5$ e $\sigma^2 = 1$. **Resposta.** $\gamma_0 = 1/(1-0{,}25) = 1{,}3333$, $\rho_{12} = 0{,}5$, $\rho_{24} = 0{,}25$, e zero fora dos múltiplos de 12. A FACP tem um pico só, em 12.

Variação B. Escreva SARIMA$(0,0,1)(0,0,1)_{12}$ como MA restrito. **Resposta.** $(1-\theta B)(1-\Theta B^{12}) = 1 - \theta B - \Theta B^{12} + \theta\Theta B^{13}$. É um MA(13) com restrições: dez coeficientes nulos e $\theta_{13} = -\theta\Theta$ na convenção BJ.

Q12 · Previsão do SARIMA trimestral

Ideia: expandir, tirar $E(\cdot \mid \mathcal{F}_T)$ termo a termo e ver em que h o MA some. Resolução em 03_lista · BJRL cap. 5 e 9.

Variação A. SARIMA$(0,1,1)(0,1,1)_4$: equações de previsão. **Resposta.**

- $y_t = y_{t-1} + y_{t-4} - y_{t-5} + a_t - \theta a_{t-1} - \Theta a_{t-4} + \theta\Theta a_{t-5}$.
- $\hat{y}(1) = y_T + y_{T-3} - y_{T-4} - \theta\hat{a}_T - \Theta\hat{a}_{T-3} + \theta\Theta\hat{a}_{T-4}$.
- O MA some a partir de $h = 6$.
- Perdem-se 5 observações.

Variação B. E com $s = 12$, $d = 1$ e $D = 1$? **Resposta.** Perdem-se 13 observações. No modelo com MA(1)×SMA(1), os resíduos entram até $h = 13$.

---

2. Testes de raiz unitária

Regressão de Dickey-Fuller aumentada:

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^{k} \delta_i \Delta y_{t-i} + e_t.$$

O teste é $H_0 : \gamma = 0$ (raiz unitária) vs. $H_1 : \gamma < 0$, pela estatística $\tau = \hat{\gamma}/ep(\hat{\gamma})$.

Os críticos não são os da *t* de Student

Sob H_0, τ tem a distribuição de Dickey-Fuller, que é assimétrica e depende de haver constante e/ou tendência. Os críticos de 5% são −1,95 (sem determinísticos), −2,86 (constante) e −3,41 (constante e tendência), com pequenas variações por T.
A especificação certa importa. Use **tendência** se a série tem tendência sob a alternativa; caso contrário, o teste perde poder.

D03.3 · A distribuição de Dickey-Fuller e o baixo poder do teste (Monte Carlo)

O que se quer provar

Sob $H_0 : \gamma = 0$, a estatística τ não é normal nem *t*: ela fica deslocada para a esquerda, e mais ainda quanto mais termos determinísticos houver (AU04). Sob a alternativa estacionária com ϕ perto de 1, o teste quase não rejeita em amostras do tamanho usual.

Passo a passo.

1. **Por que a distribuição muda.** Sob H_0, y_{t-1} é um passeio aleatório, e a variância amostral dele cresce como T^2, não como T. O numerador e o denominador de $\hat{\gamma}$ convergem para funcionais do movimento browniano, e não para uma normal. Com constante, y_{t-1} entra centrado na média, que puxa $\hat{\gamma}$ para baixo. Com tendência, o efeito se repete.
2. **A simulação.** Simulamos 10000 passeios aleatórios de $T = 100$ e rodamos a regressão de DF:

Especificação	Quantil de 5% de τ	Média de τ	Rejeições com −1,645 (normal)
sem determinísticos, τ	−1,93	−0,41	9,0%
constante, τ_μ	−2,88	−1,52	45,3%
constante e tendência, τ_τ	−3,46	−2,19	77,2%

   Os quantis batem com os críticos tabelados acima. Usar o crítico da normal por engano faz o teste rejeitar uma raiz unitária **verdadeira** em quase metade das vezes com constante, e em três de cada quatro com tendência.
3. **O poder.** Agora o processo verdadeiro é um AR(1) estacionário. Mostramos a porcentagem de rejeições a 5% do DF com constante, em 2000 réplicas, com o crítico exato da simulação:

ϕ	0,80	0,90	0,95	0,99
$T = 100$	87,7%	32,4%	12,6%	5,9%
$T = 400$	100%	100%	86,1%	10,3%

Com $\phi = 0{,}95$ e oito anos e meio de dados mensais, o teste acerta só uma vez em oito. Com $\phi = 0{,}99$, não se distingue de um palpite: o poder fica perto do tamanho de 5%.

τ sob H_0 segue Dickey-Fuller, não $N(0,1)$; não rejeitar $H_0 \neq$ aceitar a raiz unitária

O que isso muda na prática. É o motivo para cruzar o ADF com o KPSS, cuja nula é a estacionariedade (Mattos, MAT, sobre o poder). No INPC, Questão 2d, o ADF do log do índice dá $p = 0{,}075$. Sozinho, ele seria ambíguo, mas o PP e o KPSS decidem. Mais dados ajudam muito mais que mais defasagens: passar de $T = 100$ a $T = 400$ leva o poder com $\phi = 0{,}95$ de 12,6% a 86,1%.

D03.4 · Uma quebra estrutural de nível imita uma raiz unitária (Perron, 1989)

> **O que se quer provar**
>
> Uma série estacionária em torno de um nível que **muda uma vez** pode fazer o ADF não rejeitar a raiz unitária. O teste confunde o salto permanente com acúmulo de choques. Incluir a quebra na regressão auxiliar devolve o poder (AU04; MAT, conclusão).

Passo a passo.

1. **O processo.** $y_t = \delta\, DU_t + u_t$, com $DU_t = \mathbf{1}\{t > T/2\}$ e $u_t = 0{,}8u_{t-1} + \varepsilon_t$. É I(0) em cada metade: os choques morrem. Só o nível médio muda, uma vez, de 0 para δ. O desvio-padrão de u_t é $1/\sqrt{1 - 0{,}64} = 1{,}67$.
2. **Por que o ADF erra.** A regressão de DF com constante supõe **uma** média. Diante do salto, o melhor ajuste é pôr $\hat{\gamma}$ perto de zero: um processo que "não volta" explica a mudança de patamar melhor que um que volta a uma média única e errada. O teste fica viesado para a não rejeição.
3. **A correção.** Pôr a dummy na regressão: $\Delta y_t = a + d\, DU_t + \gamma y_{t-1} + e_t$. Os críticos mudam. Eles dependem da posição da quebra; aqui foram simulados sob H_0, com o passeio aleatório, e o de 5% dá −3,36, mais negativo que o −2,88 do DF com constante.
4. **A simulação**, com $T = 200$, quebra na metade, 2000 réplicas, rejeições a 5%:

Salto δ	0	3	6	10
DF com constante, ignorando a quebra	100%	93,8%	5,4%	0%
DF com a dummy de nível	100%	100%	99,95%	100%

Com um salto de 6, cerca de 3,6 desvios-padrão de u_t, o ADF comum rejeita só 5,4% das vezes, o mesmo que faria se houvesse raiz unitária de verdade. Com a dummy, rejeita quase sempre.

quebra de nível ignorada ⇒ ADF viesado para "raiz unitária" data conhecida: dummy na regressão e crítico próprio

Quando a data da quebra não é conhecida e é escolhida pelos dados, os críticos mudam de novo. É o caso de Zivot e Andrews (1992), que procuram a quebra que mais favorece a alternativa.

A ligação com o INPC. No relatório, o Chow indica quebra em mar/2020, e mesmo assim o ADF da variação mensal rejeita com folga a raiz unitária (Questão 2). Isso é coerente com esta seção: uma quebra **enfraquece** o teste, mas ali a evidência de estacionariedade é forte o bastante para sobreviver a ela. Se o ADF não tivesse rejeitado, a quebra seria o primeiro suspeito, antes de concluir por $d = 1$.

KPSS: as hipóteses são invertidas, com H_0 = estacionária (em nível ou em tendência). A leitura padrão é cruzar os dois: ADF não rejeita e KPSS rejeita aponta I(1); ADF rejeita e KPSS não rejeita aponta I(0).

Parte VI

Bloco 4 — Estimação e seleção (Q13–Q14)

Capítulo 4 · Estimação e seleção: o detetive e os dois juízes

← apostila · anterior: cap. 3 · próximo: cap. 5 · questões da lista: Q13 e Q14

Pergunta de abertura

Você ajustou três modelos à mesma série de 150 observações, e um deles tem a maior log-verossimilhança. **Ele é o melhor?** Agora acrescente parâmetros: um AR(20) sempre terá verossimilhança maior ou igual à de um AR(1), porque contém o AR(1) como caso particular. **Então "maior verossimilhança" não pode ser o critério sozinho. O que falta?**

E, antes disso, uma pergunta sobre como se chega aos números: **por que o MQO de y_t contra y_{t-1} dá exatamente o estimador de máxima verossimilhança do AR(1)?** E por que, para um MA(1), não existe fórmula fechada (AU02, p. 60 e 80)?

A imagem

A máxima verossimilhança é um detetive. A cena do crime são os dados, e os suspeitos são os valores possíveis dos parâmetros. O detetive pergunta, para cada suspeito: "se tivesse sido você, quão provável seria esta cena?". E escolhe aquele sob o qual a cena é **menos surpreendente**. É isso que maximizar $L(\Theta) = f(y_1, \dots, y_T; \Theta)$ quer dizer.

Condicional × exata é por onde começar a contar a história.

- A versão **condicional** começa no segundo capítulo: trata y_1 como dado e explica só como cada observação nasceu da anterior.
- A versão **exata** também explica o primeiro capítulo, perguntando quão provável era y_1 sob o processo estacionário (AU02, p. 78–80).

Com muitos capítulos, o primeiro pesa pouco, e as duas concordam.

Yule-Walker é copiar as correlações. Em vez de perguntar qual parâmetro torna os dados mais prováveis, ele pergunta: qual parâmetro faz o modelo **reproduzir as correlações que eu medi**? No AR(1), isso é $\hat{\phi} = \hat{\rho}_1$, um método de momentos.

AIC e BIC são dois juízes de um concurso que cobram multa por parâmetro. Os dois dão nota pelo ajuste, $-2 \ln L$, e descontam uma multa por parâmetro:

- **o AIC cobra multa fixa, 2 por parâmetro**. Ele quer o modelo que vai **prever melhor** a próxima observação;
- **o BIC cobra** $\ln T$ **por parâmetro**, uma multa que cresce com o tamanho da amostra. Ele quer **acertar qual é o modelo verdadeiro**.

Com $T = 150$, a multa do BIC já é $\ln 150 = 5{,}01$, duas vezes e meia a do AIC.

> **Onde a analogia quebra**
>
> - **O detetive não dá a probabilidade de o suspeito ser culpado.** $L(\Theta)$ é a probabilidade dos **dados** dado o parâmetro, não a do parâmetro dado os dados. Dizer "o modelo A tem 70% de chance de ser o certo" não sai da verossimilhança.

- **O juiz BIC só é infalível se o culpado está na fila.** A consistência do BIC supõe que o modelo verdadeiro está entre os candidatos. Se nenhum está, o que importa é prever bem, e aí o AIC é o que tem a propriedade ótima, a eficiência.
- **A multa não é uma regra de rejeição com nível fixo.** Entre dois modelos aninhados que diferem por um parâmetro, o AIC equivale a um teste da razão de verossimilhança com valor crítico 2. Isso dá um "nível" de 15,7%, que **não cai** com T. É por isso que o AIC superajusta para sempre (D4.4).

Teoria

Verossimilhança e fatoração (AU02, p. 77). A densidade conjunta se fatora em condicionais sucessivas:

$$f(y_T, \dots, y_1; \Phi) = f(y_1; \Phi) \prod_{t=2}^{T} f(y_t \mid y_{t-1}, \dots, y_1; \Phi), \qquad \widehat{\Phi} = \arg\max_{\Phi} \ln L(\Phi).$$

AR(1), exata e condicional (AU02, p. 78–80).

- Na **exata**, $y_1 \sim N\big(\frac{\phi_0}{1-\phi_1}, \frac{\sigma^2}{1-\phi_1^2}\big)$, a distribuição incondicional, entra na conta.
- Na **condicional**, y_1 é tratado como fixo.
- As duas são consistentes e assintoticamente equivalentes. A exata é melhor em amostras pequenas e perto da fronteira $|\phi_1| \to 1$.
- No AR, a condicional normal **coincide com o MQO** (D4.1).

MA(1) e ARMA (AU02, p. 58–60 e 88–89). A condicional fixa $\varepsilon_0 = 0$ e reconstrói os choques pela recursão $\varepsilon_t = y_t - \theta_0 - \theta_1 \varepsilon_{t-1}$. A log-verossimilhança é

$$\ln L(\Theta) = -\frac{T}{2}\ln(2\pi) - \frac{T}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}\sum_{t=1}^{T}\varepsilon_t^2.$$

Como cada ε_t depende de θ_1 de forma **não linear**, através de toda a recursão, **não há solução analítica**, e a maximização é numérica. A exata usa o filtro de Kalman (AU02, p. 60).

Yule-Walker (AU02, p. 68–71). O estimador troca as ρ_k teóricas pelas amostrais e resolve $\widehat{R}\widehat{\Phi} = \hat{r}$. No AR(1), $\hat{\phi}_{YW} = \hat{\rho}_1$.

Critérios de informação (AU02, p. 98–99). Com k parâmetros, **incluindo a variância** (como pede a Q14), e T fixo:

$$AIC = \frac{-2\ln L(\widehat{\Theta}) + 2k}{T}, \qquad BIC = \frac{-2\ln L(\widehat{\Theta}) + k\ln T}{T}, \qquad \text{escolhe-se o menor.}$$

- O R reporta as versões **sem** a divisão por T. Com o mesmo T, a ordenação é a mesma.
- **Nunca** compare modelos estimados com T diferentes (AU02, p. 99).

Consistência × eficiência.

- **BIC: consistente.** Se o modelo verdadeiro está entre os candidatos, P(BIC escolhe o verdadeiro) $\to 1$, porque a multa $\ln T \to \infty$ elimina os modelos grandes demais.
- **AIC: eficiente.** Não é consistente, porque superajusta com probabilidade que não vai a zero. Mas minimiza o erro de previsão quando o verdadeiro é complexo demais para estar na lista.

Demonstrações

D4.1 · AR(1): log-verossimilhança condicional e o MQO (Q13)

$y_t = \phi y_{t-1} + \varepsilon_t$, com $\varepsilon_t \sim N(0, \sigma^2)$, condicionando em y_1.

(1) $y_t \mid y_{t-1} \sim N(\phi y_{t-1}, \sigma^2)$ [ε_t normal]

(2) $f(y_t \mid y_{t-1}) = \dfrac{1}{\sqrt{2\pi\sigma^2}} \exp\Big(- \dfrac{(y_t - \phi y_{t-1})^2}{2\sigma^2} \Big)$ [densidade normal]

(3) $\ln L(\phi, \sigma^2 \mid y_1) = \displaystyle\sum_{t=2}^{T} \ln f(y_t \mid y_{t-1})$ [fatoração, AU02 p. 80]

(4) $= -\dfrac{T-1}{2}\ln(2\pi) - \dfrac{T-1}{2}\ln\sigma^2 - \dfrac{1}{2\sigma^2}\displaystyle\sum_{t=2}^{T}(y_t - \phi y_{t-1})^2$ [(2) em (3)]

(5) $\dfrac{\partial \ln L}{\partial \phi} = \dfrac{1}{\sigma^2}\displaystyle\sum_{t=2}^{T}(y_t - \phi y_{t-1})\, y_{t-1} = 0$ [CPO em ϕ]

(6) $\displaystyle\sum_{t=2}^{T} y_t y_{t-1} = \hat{\phi}\sum_{t=2}^{T} y_{t-1}^2$ [distributiva]

(7) $\hat{\phi} = \dfrac{\sum_{t=2}^{T} y_t y_{t-1}}{\sum_{t=2}^{T} y_{t-1}^2}$ [isola]

(8) $\dfrac{\partial \ln L}{\partial \sigma^2} = -\dfrac{T-1}{2\sigma^2} + \dfrac{1}{2\sigma^4}\displaystyle\sum_{t=2}^{T}\hat{\varepsilon}_t^2 = 0$ [CPO em σ^2]

(9) $\hat{\sigma}^2 = \dfrac{1}{T-1}\displaystyle\sum_{t=2}^{T}\hat{\varepsilon}_t^2$ [multiplica por $2\sigma^4$]

$$\boxed{\hat{\phi}_{MV\,cond} = \frac{\sum_{t=2}^{T} y_t y_{t-1}}{\sum_{t=2}^{T} y_{t-1}^2} = \hat{\phi}_{MQO}}$$

Em (5), só o último termo de (4) depende de ϕ. Por que coincidem: em (4), para qualquer σ^2 fixo, maximizar $\ln L$ em ϕ é **minimizar** $\sum(y_t - \phi y_{t-1})^2$, que é exatamente o problema do MQO.

D4.2 · A verossimilhança exata acrescenta o primeiro capítulo

Com média zero, $y_1 \sim N\big(0, \sigma^2/(1-\phi^2)\big)$ (AU02, p. 78–79).

(1) $\ln f(y_1) = -\dfrac{1}{2}\ln(2\pi) - \dfrac{1}{2}\ln\dfrac{\sigma^2}{1-\phi^2} - \dfrac{(1-\phi^2)\,y_1^2}{2\sigma^2}$ [densidade de y_1]

(2) $\ln L_{exata} = \ln f(y_1) + \ln L_{cond}$ [fatoração completa]

(3) $\dfrac{\partial \ln f(y_1)}{\partial \phi} = -\dfrac{\phi}{1-\phi^2} + \dfrac{\phi\, y_1^2}{\sigma^2}$ [derivada; $\partial\ln(1-\phi^2)/\partial\phi = -2\phi/(1-\phi^2)$]

(4) CPO: $\dfrac{1}{\sigma^2}\displaystyle\sum_{t=2}^{T}(y_t - \phi y_{t-1})y_{t-1} - \dfrac{\phi}{1-\phi^2} + \dfrac{\phi\, y_1^2}{\sigma^2} = 0$ [(2), (3), D4.1(5)]

(5) o termo $\dfrac{\phi}{1-\phi^2}$ torna (4) não linear em ϕ [sem fórmula fechada]

(6) (1) é um termo só, contra $T-1$ termos em $\ln L_{cond}$ [peso $O(1/T)$]

$$\boxed{\ln L_{exata} = \ln f(y_1) + \ln L_{cond} \ : \ \text{solução numérica, assintoticamente igual à condicional}}$$

Em (1), $-\frac{1}{2}\ln\frac{\sigma^2}{1-\phi^2} = -\frac{1}{2}\ln\sigma^2 + \frac{1}{2}\ln(1-\phi^2)$, e o último termo vai a $-\infty$ quando $|\phi| \to 1$. A verossimilhança exata **pune** estimativas na fronteira, e o termo $-\frac{\phi}{1-\phi^2}$ em (4) empurra $\hat{\phi}$ para dentro da região estacionária. É por isso que a exata se comporta melhor perto da fronteira (AU02, p. 80).

D4.3 · Yule-Walker no AR(1) e a diferença para o MQO

(1)	$\rho_1 = \phi$	[cap. 2, D2.4]
(2)	$\hat{\rho}_1 = \dfrac{\hat{\gamma}_1}{\hat{\gamma}_0} = \dfrac{\frac{1}{T}\sum_{t=2}^{T} y_t y_{t-1}}{\frac{1}{T}\sum_{t=1}^{T} y_t^2}$	[AU02, p. 71, média zero]
(3)	$\hat{\phi}_{YW} = \hat{\rho}_1 = \dfrac{\sum_{t=2}^{T} y_t y_{t-1}}{\sum_{t=1}^{T} y_t^2}$	[troca teórico por amostral]
(4)	MQO: denominador $\displaystyle\sum_{t=2}^{T} y_{t-1}^2 = \sum_{t=1}^{T-1} y_t^2$	[D4.1(7)]
(5)	YW: denominador $\displaystyle\sum_{t=1}^{T} y_t^2 = \sum_{t=1}^{T-1} y_t^2 + y_T^2$	[um termo a mais]
(6)	$\lvert\hat{\phi}_{YW}\rvert \le \lvert\hat{\phi}_{MQO}\rvert$	[denominador maior]

$$\boxed{\hat{\phi}_{YW} = \hat{\rho}_1 \ : \ \text{mesmo numerador do MQO, denominador com } y_T^2 \text{ a mais; diferença } O(1/T)}$$

D4.4 · Por que o BIC é consistente e o AIC não

Compare o modelo pequeno, verdadeiro e com k parâmetros, com um grande, que tem $k+1$ e contém o pequeno. Seja $LR = 2(\ln L_{grande} - \ln L_{pequeno}) \ge 0$.

(1)	$AIC_{grande} < AIC_{pequeno} \iff -2\ln L_g + 2(k+1) < -2\ln L_p + 2k$	[definição, sem $\div T$]
(2)	$\iff LR > 2$	[rearranja]
(3)	$BIC_{grande} < BIC_{pequeno} \iff LR > \ln T$	[mesma conta, multa $\ln T$]
(4)	sob o modelo pequeno verdadeiro: $LR \xrightarrow{d} \chi^2(1)$	[teste LR, 1 restrição]
(5)	$P(\text{AIC superajusta}) \to P\big(\chi^2(1) > 2\big) = 0{,}157 > 0$	[(2), (4)]
(6)	$P(\text{BIC superajusta}) = P(LR > \ln T) \to 0$	[$\ln T \to \infty$, $LR = O_p(1)$]

$$\boxed{\text{AIC} \equiv \text{teste LR com crítico fixo 2 (nível} \approx 15{,}7\%); \qquad \text{BIC} \equiv \text{crítico } \ln T \to \infty \ : \ \text{consistente}}$$

Escolher um modelo pequeno demais, ao contrário, é punido pelos **dois**: o LR cresce como T quando o parâmetro omitido é diferente de zero, e vence qualquer multa.

Exemplo

1. Os três estimadores do AR(1), numa série simulada com $\phi = 0{,}6$ e $T = 200$:

Estimador	Fórmula	$\hat{\phi}$
MQO (= MV condicional)	D4.1(7)	0,6537 (o `lm` dá o mesmo)
Yule-Walker	D4.3(3)	0,6487 (o `ar.yw` dá o mesmo)
MV exata	numérica	0,6620

Os três diferem só na terceira casa: são assintoticamente equivalentes. O YW fica abaixo do MQO, como previsto em D4.3(6). A variância estimada pelo MQO é $\hat{\sigma}^2 = 1{,}0491$.

2. A Q14, com $T = 150$, $k = 3$ nos três modelos e $\ln 150 = 5{,}0106$:

Modelo	$\ln L$	AIC (slides)	BIC (slides)	AIC (R)	BIC (R)
ARMA(1,1)	−210,3	**2,8440**	**2,9042**	426,6	435,63
ARMA(2,0)	−212,8	2,8773	2,9375	431,6	440,63
ARMA(0,2)	−214,1	2,8947	2,9549	434,2	443,23

Os dois escolhem o ARMA(1,1). Com o **mesmo** k, a multa é igual para os três, e decide só a verossimilhança. A diferença entre AIC e BIC só pesaria se os modelos tivessem números diferentes de parâmetros.

3. Os dois juízes em ação, em mil simulações de um AR(1) verdadeiro com $\phi = 0{,}5$, comparado com um AR(2):

T	AIC escolhe o AR(2)	BIC escolhe o AR(2)
150	15,7%	3,2%
2000	12,4%	0,6%

A teoria da D4.4 prevê, para o AIC, $P(\chi^2(1) > 2) = 0{,}1573$ **em qualquer** T, e a simulação confirma: o AIC não melhora com mais dados. O BIC vai a zero.

Cadeia socrática

P1. Na D4.1, por que a CPO em ϕ não depende de σ^2?

> **Resposta**
>
> Porque σ^2 só multiplica a soma de quadrados, e a CPO iguala essa derivada a zero: o fator $1/\sigma^2$ sai. É por isso que $\hat{\phi}$ sai antes, pelo MQO, e $\hat{\sigma}^2$ vem depois, dos resíduos.

P2. No MA(1), por que a mesma conta não tem fórmula fechada?

> **Resposta**
>
> Porque $\varepsilon_t = y_t - \theta_0 - \theta_1 \varepsilon_{t-1}$ depende de θ_1 através de **toda** a recursão: ε_t é um polinômio de grau $t-1$ em θ_1. A soma de quadrados não é quadrática em θ_1, e a CPO não se resolve à mão (AU02, p. 60).

P3. Por que o MA precisa ser invertível para a verossimilhança condicional funcionar bem?

Resposta

Porque a recursão parte de um chute, $\varepsilon_0 = 0$. O erro desse chute se propaga com peso $(-\theta_1)^t$: some se $|\theta_1| < 1$ e explode se não. Além disso, sem a restrição, θ e $1/\theta$ dão verossimilhanças iguais, e o máximo não é único (cap. 2, D2.3).

P4. Se a exata e a condicional são assintoticamente equivalentes, quando a diferença importa?

Resposta

Em amostras pequenas e com $|\phi|$ perto de 1. Aí y_1 carrega muita informação, porque a variância incondicional $\sigma^2/(1-\phi^2)$ é enorme, e a exata a aproveita (D4.2).

P5. Na Q14, AIC e BIC concordaram. Isso sempre acontece?

Resposta

Não. Concordaram porque os três modelos têm o mesmo $k = 3$, e as multas se cancelam. Com k diferentes, o BIC, de multa $\ln 150 \approx 5$, tende a escolher o menor modelo, e o AIC, de multa 2, o maior.

P6. Se o AIC superajusta para sempre, por que alguém o usaria?

Resposta

Porque superajustar com **um parâmetro a mais, de valor perto de zero** custa pouco na previsão, e subajustar custa muito. Quando o processo verdadeiro é um ARMA de ordem infinita, ou não está na lista, não há "modelo verdadeiro" a acertar, e o AIC é o que minimiza o erro de previsão: a eficiência.

P7. Posso comparar o AIC de um ARMA(1,1) em y_t com o de um ARMA(1,1) em Δy_t?

Resposta

Não. As séries são diferentes, e o T efetivo também, porque se perde uma observação. A verossimilhança de uma série não é comparável com a de outra. A regra da AU02, p. 99, é: mesmo T, mesma variável dependente.

P8. O k da Q14 inclui σ^2. E se eu esquecer de incluí-lo?

Resposta

Todos os modelos perdem 1 em k, e a **ordenação não muda**: a multa cai igual para todos. Mas o valor numérico do AIC e do BIC muda, e numa prova de conta isso é erro. Siga o enunciado: $k = p + q + 1$ com média zero e $p + q + 2$ com média (AU02, p. 99).

Diálogo

Sobre "o BIC é melhor porque é consistente".

Aluno: O BIC é consistente, e o AIC não. Então o BIC é sempre melhor.

Professor: Consistente para quê, exatamente?

Aluno: Para escolher o modelo verdadeiro quando T cresce.

Professor: E qual é a hipótese escondida nessa frase?

Aluno: ... Que o modelo verdadeiro está entre os candidatos.

Professor: A inflação brasileira é exatamente um ARMA(1,1)?

Aluno: Provavelmente não. É algo mais complicado, e o ARMA é uma aproximação.

Professor: Então o que significa "acertar o modelo verdadeiro" nesse caso?

Aluno: Nada: não tem verdadeiro na lista. Aí a pergunta útil é qual aproxima melhor para prever.

Professor: E qual critério tem a propriedade ótima para isso?

Aluno: O AIC, a eficiência. Então a regra não é "um é melhor". É: se o objetivo é **identificar** a estrutura, uso o BIC; se é **prever**, o AIC. E, se os dois concordam, como na Q14, a escolha é robusta.

Professor: E na prova, se o enunciado só pede "qual cada um seleciona"?

Aluno: Calculo os dois com o mesmo T, digo o vencedor de cada um e, na discussão, explico as multas, 2 contra $\ln T$, e as propriedades assintóticas.

Na prova

A folha de caderno do bloco está em a_mao_cap4.md: Q13 e Q14 em 43 linhas numeradas, cada uma com a justificativa, mais a versão para a prova e a conferência em R.

Questão	O que este capítulo dá	Resolução completa
Q13	log-verossimilhança condicional do AR(1) e o MQO de ϕ	Q13
Q14	AIC e BIC de três modelos com $T = 150$; consistência × eficiência	Q14

Armadilhas:

- na Q13, somar de $t = 1$, quando a condicional começa em $t = 2$ e tem $T - 1$ termos;
- esquecer de derivar $\hat{\sigma}^2$ ou dividir por T em vez de $T - 1$, quando se condiciona em y_1;
- na Q14, usar $k = 2$ em vez de 3, ignorando a variância, ou trocar o sinal de $\ln L$: o menor critério vence;
- dizer que "o BIC sempre escolhe o modelo menor": ele **tende** a escolher, e só quando os k diferem.

Checklist de 30 segundos:

1. A condicional começa em $t = 2$?
2. Escrevi as duas CPOs, para ϕ e para σ^2?
3. Calculei AIC e BIC com o mesmo T e o mesmo k do enunciado?
4. Disse "menor vence" e qual foi o escolhido por **cada** critério?
5. Expliquei $2 \times \ln T$ e consistência × eficiência, com a hipótese de o verdadeiro estar na lista?

No material do professor

Roteiro de releitura:

- AU02, p. 58–60: verossimilhança condicional do MA(1) e o método exato;
- AU02, p. 68–71: Yule-Walker e a FAC amostral;
- AU02, p. 77–80: MV exata e condicional do AR(1);
- AU02, p. 88–89: verossimilhança condicional do ARMA(1,1);
- AU02, p. 96–99: identificação e critérios de informação.

Livros:

- **HAMILTON**, cap. 5: a verossimilhança exata e condicional do AR e do MA, com todas as contas;

- **ENDERS**, cap. 2: critérios de informação no nível do curso;
- **BJRL**, cap. 7: estimação e a convenção de sinal da lista.

Na lista comentada: Q13 · Q14.

Cap. 4 à mão — Q13 e Q14 linha a linha

Cap. 4 à mão: Q13 e Q14, linha a linha

← capítulo 4 · ← apostila · cap. 3 à mão

Versão de **caderno** do bloco 4 da lista: cada passagem numerada, uma operação por linha e o motivo entre colchetes. A numeração é contínua. Os símbolos são os dos slides: ϕ_1, ε_t, $\ln L$, T observações.

Legenda:

- [RB]: ruído branco;
- [F4]: linearidade da esperança;
- [CPO]: condição de primeira ordem, a derivada igual a zero;
- [(n)]: usando a linha (n).

Q13 · AR(1): log-verossimilhança condicional e MQO

Enunciado (lista, Q13). Para $y_t = \phi y_{t-1} + \varepsilon_t$, com $\varepsilon_t \sim N(0, \sigma^2)$: escrever a log-verossimilhança condicional em y_1 e obter o estimador de MQO de ϕ.

Nos slides: AU02, p. 77–80, com $\phi = \phi_1$ e sem constante.

(1) $y_t \mid y_{t-1} \sim N(\phi y_{t-1},\ \sigma^2)$ [ε_t normal]

(2) $f(y_t \mid y_{t-1}) = (2\pi\sigma^2)^{-1/2} \exp\Big(- \dfrac{(y_t - \phi y_{t-1})^2}{2\sigma^2} \Big)$ [densidade normal]

(3) $f(y_2, \dots, y_T \mid y_1) = \prod_{t=2}^{T} f(y_t \mid y_{t-1})$ [fatoração, AU02 p. 80]

(4) $\ln L = \sum_{t=2}^{T} \ln f(y_t \mid y_{t-1})$ [ln do produto]

(5) $\ln f(y_t \mid y_{t-1}) = -\frac{1}{2}\ln(2\pi) - \frac{1}{2}\ln\sigma^2 - \dfrac{(y_t - \phi y_{t-1})^2}{2\sigma^2}$ [ln de (2)]

(6) $\ln L(\phi, \sigma^2 \mid y_1) = -\frac{T-1}{2}\ln(2\pi) - \frac{T-1}{2}\ln\sigma^2 - \dfrac{S(\phi)}{2\sigma^2}$ [$T-1$ termos]

(7) $S(\phi) \equiv \sum_{t=2}^{T} (y_t - \phi y_{t-1})^2$ [soma de quadrados]

(8) $\dfrac{\partial \ln L}{\partial \phi} = -\dfrac{1}{2\sigma^2} S'(\phi)$ [só S depende de ϕ]

(9) $S'(\phi) = \sum_{t=2}^{T} 2(y_t - \phi y_{t-1})(-y_{t-1})$ [regra da cadeia]

(10) $\dfrac{\partial \ln L}{\partial \phi} = \dfrac{1}{\sigma^2} \sum_{t=2}^{T} (y_t - \phi y_{t-1})\, y_{t-1} = 0$ [CPO]

(11) $\sum_{t=2}^{T} y_t y_{t-1} - \phi \sum_{t=2}^{T} y_{t-1}^2 = 0$ [distributiva]

(12) $\hat{\phi} = \dfrac{\sum_{t=2}^{T} y_t y_{t-1}}{\sum_{t=2}^{T} y_{t-1}^2}$ [isola]

(13) é o MQO de y_t em y_{t-1} : $\min_{\phi} S(\phi)$ [(6) : $\max \ln L \iff \min S$]

(14) $\dfrac{\partial^2 \ln L}{\partial \phi^2} = -\dfrac{1}{\sigma^2} \sum_{t=2}^{T} y_{t-1}^2 < 0$ [é máximo]

(15) $\dfrac{\partial \ln L}{\partial \sigma^2} = -\dfrac{T-1}{2\sigma^2} + \dfrac{S(\hat{\phi})}{2\sigma^4} = 0$ [CPO em σ^2]

(16) $\hat{\sigma}^2 = \dfrac{S(\hat{\phi})}{T-1} = \dfrac{1}{T-1} \sum_{t=2}^{T} \hat{\varepsilon}_t^2$ [$\times 2\sigma^4$, isola]

(17) $\ln L_{\max} = -\frac{T-1}{2}\big(\ln(2\pi) + \ln \hat{\sigma}^2 + 1 \big)$ [(16) em (6)]

$$\boxed{\ln L(\phi, \sigma^2 \mid y_1) = -\tfrac{T-1}{2}\ln(2\pi\sigma^2) - \tfrac{1}{2\sigma^2}\textstyle\sum_{t=2}^{T}(y_t - \phi y_{t-1})^2; \qquad \hat{\phi} = \dfrac{\sum y_t y_{t-1}}{\sum y_{t-1}^2} = \hat{\phi}_{MQO}}$$

A linha (17) é o elo com a Q14: o $\ln L$ maximizado depende dos dados só pela variância dos resíduos, e é ele que entra no AIC e no BIC.

Além do que se pede: a exata e o Yule-Walker.

(18) $\ln L_{ex} = \ln f(y_1) + \ln L_{cond}, \quad y_1 \sim N\big(0,\ \sigma^2/(1-\phi^2)\big)$ [AU02 p. 78]

(19) $\ln f(y_1) = -\frac{1}{2}\ln(2\pi) - \frac{1}{2}\ln\sigma^2 + \frac{1}{2}\ln(1-\phi^2) - \dfrac{(1-\phi^2)y_1^2}{2\sigma^2}$ [densidade de y_1]

(20) a CPO ganha $-\dfrac{\phi}{1-\phi^2} + \dfrac{\phi\, y_1^2}{\sigma^2}$: não linear em ϕ [solução numérica]

(21) $\hat{\phi}_{YW} = \hat{\rho}_1 = \dfrac{\sum_{t=2}^{T} y_t y_{t-1}}{\sum_{t=1}^{T} y_t^2}$ [AU02 p. 70–71]

(22) os três diferem em $O(1/T)$ e são assintoticamente equivalentes [AU02 p. 80]

Q14 · AIC e BIC de três modelos

Enunciado (lista, Q14). Ajustaram-se um ARMA(1,1), um ARMA(2,0) e um ARMA(0,2) a $T = 150$ observações. As log-verossimilhanças maximizadas são $-210{,}3$, $-212{,}8$ e $-214{,}1$; os modelos têm média zero, e k inclui a variância. Pede-se:

- (a) o AIC e o BIC de cada modelo e o escolhido por cada critério;
- (b) a diferença de penalidade e as implicações assintóticas.

(a) As contas, com as fórmulas da AU02, p. 98–99:

(23)	$k = p + q + 1 = 3$ nos três modelos	[AR/MA + σ^2]
(24)	$-2\ln L$: 420,6; 425,6; 428,2	[$-2 \times \ln L$]
(25)	$AIC = \dfrac{-2\ln L + 2k}{T}, \qquad 2k = 6$	[AU02 p. 98]
(26)	$AIC_{(1,1)} = \dfrac{420{,}6 + 6}{150} = \dfrac{426{,}6}{150} = 2{,}8440$	[(24), (25)]
(27)	$AIC_{(2,0)} = \dfrac{425{,}6 + 6}{150} = \dfrac{431{,}6}{150} = 2{,}8773$	[(24), (25)]
(28)	$AIC_{(0,2)} = \dfrac{428{,}2 + 6}{150} = \dfrac{434{,}2}{150} = 2{,}8947$	[(24), (25)]
(29)	$BIC = \dfrac{-2\ln L + k\ln T}{T}, \qquad k\ln T = 3(5{,}0106) = 15{,}0319$	[AU02 p. 99]
(30)	$BIC_{(1,1)} = \dfrac{420{,}6 + 15{,}0319}{150} = \dfrac{435{,}632}{150} = 2{,}9042$	[(24), (29)]
(31)	$BIC_{(2,0)} = \dfrac{440{,}632}{150} = 2{,}9375$	[(24), (29)]
(32)	$BIC_{(0,2)} = \dfrac{443{,}232}{150} = 2{,}9549$	[(24), (29)]
(33)	menor AIC e menor BIC: ARMA(1,1)	[regra: o menor vence]
(34)	k igual $\Rightarrow$ multa igual $\Rightarrow$ a ordem é a de $-2\ln L$	[(23)]

$AIC = (2{,}8440;\ 2{,}8773;\ 2{,}8947), \quad BIC = (2{,}9042;\ 2{,}9375;\ 2{,}9549)$: os dois escolhem o ARMA(1,1)

No R, sem dividir por T, os valores são $AIC = 426{,}6$, 431,6 e 434,2, e $BIC = 435{,}63$, 440,63 e 443,23, com a mesma ordem.

(b) Penalidade e propriedades assintóticas, comparando um modelo com k parâmetros com outro de $k + 1$ que o contém, com $LR = 2(\ln L_{k+1} - \ln L_k)$:

(35)	multa por parâmetro: AIC 2; BIC $\ln T = 5{,}01$ com $T = 150$	[(25), (29)]
(36)	$\ln T > 2 \iff T > e^2 \approx 7{,}4$	[BIC mais duro]
(37)	$AIC_{k+1} < AIC_k \iff -2\ln L_{k+1} + 2 < -2\ln L_k \iff LR > 2$	[rearranja]
(38)	$BIC_{k+1} < BIC_k \iff LR > \ln T$	[idem, multa $\ln T$]
(39)	se o menor é o verdadeiro: $LR \xrightarrow{d} \chi^2(1)$	[teste LR]
(40)	$P(\text{AIC superajusta}) \to P(\chi^2(1) > 2) = 0{,}157$	[não vai a zero]
(41)	$P(\text{BIC superajusta}) = P(LR > \ln T) \to 0$	[$\ln T \to \infty$: consistente]
(42)	falta parâmetro não nulo: $LR \sim T$ vence as multas	[nenhum subajusta]
(43)	verdadeiro fora da lista: o AIC minimiza o EQM de previsão	[eficiência]

AIC: multa 2, eficiente, superajusta com prob. 0,157;	BIC: multa $\ln T$, consistente

A conclusão para escrever na prova: **BIC para identificar** a estrutura, quando se supõe que o modelo verdadeiro está entre os candidatos, e **AIC para prever**. Na Q14 os dois concordam, porque os modelos têm o mesmo k.

Versão para a prova

Q13:

1. Escreva $y_t \mid y_{t-1} \sim N(\phi y_{t-1}, \sigma^2)$ e a densidade.
2. Some os logs de $t = 2$ a T, linha (6).
3. A CPO em ϕ dá $\hat{\phi} = \sum y_t y_{t-1} / \sum y_{t-1}^2$, que é o MQO, porque maximizar $\ln L$ é minimizar $S(\phi)$.
4. A CPO em σ^2 dá $\hat{\sigma}^2 = S/(T-1)$.

Q14:

1. $k = 3$ e $-2 \ln L = 420{,}6$; $425{,}6$; $428{,}2$.
2. AIC: some 6 e divida por 150.
3. BIC: some 15,03 e divida por 150.
4. O menor vence: ARMA(1,1) nos dois.
5. Explique as multas, 2 contra $\ln T$, e as linhas (37)–(41).

Conferência

Q13, numa série simulada com $\phi = 0{,}6$ e $T = 200$:

- a fórmula (12) dá 0,6537, igual ao `lm`;
- o Yule-Walker (21) dá 0,6487, igual ao `ar.yw`;
- a exata dá 0,6620;
- $\hat{\sigma}^2 = 1{,}0491$.

Q14:

- as parcelas são 420,6, 425,6, 428,2 e $3 \ln 150 = 15{,}0319$;
- a diferença de AIC entre o segundo e o primeiro modelo, sem dividir por T, é 5;
- numa simulação de mil séries, o AIC superajusta 15,7% das vezes com $T = 150$ e 12,4% com $T = 2000$, perto dos 0,157 teóricos; o BIC, 3,2% e 0,6%.

Q13 · Log-verossimilhança condicional do AR(1) e o estimador de MQO

← índice · anterior: Q12 · próxima: Q14 · resolução curta em 04_lista, D04.1

O que a questão pede

Para $y_t = \phi y_{t-1} + \varepsilon_t$ com $\varepsilon_t \sim N(0, \sigma^2)$: **escrever** a log-verossimilhança condicional em y_1 e **obter** o estimador $\hat{\phi}$, mostrando que é o de MQO.

Da lista para os slides

Mesmo modelo. A AU02 escreve o AR(1) com intercepto, $y_t = \phi_0 + \phi_1 y_{t-1} + \varepsilon_t$ (p. 78). A lista não tem intercepto, então tome $\phi_0 = 0$ e $\phi_1 = \phi$.

Ferramentas

- **Slides:** AU02, p. 76–77 (verossimilhança fatorada em densidades condicionais), p. 78–79 (MV exata, com a densidade de y_1), p. 80 (MV condicional ≡ MQO; os dois métodos são assintoticamente equivalentes).
- **Livro:** HAMILTON, cap. 5 (MV exata e condicional do AR(1)); TSAY, cap. 2.

Demonstração minuciosa

Passo 1 — A densidade de cada observação, dado o passado

Dado y_{t-1}, o único termo aleatório de $y_t = \phi y_{t-1} + \varepsilon_t$ é $\varepsilon_t \sim N(0, \sigma^2)$. Logo $y_t \mid y_{t-1} \sim N(\phi y_{t-1}, \sigma^2)$:

$$f(y_t \mid y_{t-1}; \phi, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_t - \phi y_{t-1})^2}{2\sigma^2}\right), \qquad t = 2, \dots, T.$$

Passo 2 — A verossimilhança condicional em y_1

A densidade conjunta se fatora numa cadeia de condicionais (AU02, p. 77):

$$f(y_T, \dots, y_1) = f(y_1) \prod_{t=2}^{T} f(y_t \mid y_{t-1}, \dots, y_1) = f(y_1) \prod_{t=2}^{T} f(y_t \mid y_{t-1}).$$

A última igualdade vale porque, num AR(1), só o último valor importa. **Condicionar em** y_1 é tratar y_1 como fixo e descartar $f(y_1)$ (AU02, p. 80):

$$L_c(\phi, \sigma^2) = \prod_{t=2}^{T} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_t - \phi y_{t-1})^2}{2\sigma^2}\right).$$

Passo 3 — O logaritmo

O log transforma produto em soma; $\ln \frac{1}{\sqrt{2\pi\sigma^2}} = -\frac{1}{2}\ln(2\pi) - \frac{1}{2}\ln\sigma^2$, e $\ln e^x = x$. São $T-1$ parcelas:

$$\boxed{\ell_c(\phi, \sigma^2) = -\frac{T-1}{2}\ln(2\pi) - \frac{T-1}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}\sum_{t=2}^{T}(y_t - \phi y_{t-1})^2}$$

Passo 4 — Maximizar em ϕ é minimizar a soma dos quadrados

Só o último termo depende de ϕ, e ele entra com sinal negativo. Logo:

$$\arg\max_{\phi}\ \ell_c = \arg\min_{\phi}\ S(\phi), \qquad S(\phi) = \sum_{t=2}^{T}(y_t - \phi y_{t-1})^2.$$

$S(\phi)$ é exatamente a soma dos quadrados dos resíduos da regressão de y_t em y_{t-1}, sem intercepto: **é o problema do MQO.**

Passo 5 — Condição de primeira ordem

Pela regra da cadeia, $\frac{d}{d\phi}(y_t - \phi y_{t-1})^2 = 2(y_t - \phi y_{t-1})(-y_{t-1})$. Então:

$$\frac{dS}{d\phi} = -2\sum_{t=2}^{T} y_{t-1}(y_t - \phi y_{t-1}) = 0 \implies \sum_{t=2}^{T} y_t y_{t-1} - \phi\sum_{t=2}^{T} y_{t-1}^2 = 0$$

$$\boxed{\hat{\phi} = \frac{\sum_{t=2}^{T} y_t y_{t-1}}{\sum_{t=2}^{T} y_{t-1}^2}}$$

Segunda ordem: $\frac{d^2S}{d\phi^2} = 2\sum y_{t-1}^2 > 0$, então é um mínimo de S e um máximo de ℓ_c.

Passo 6 — A variância

Derive em σ^2, tratando σ^2 como variável:

$$\frac{\partial \ell_c}{\partial \sigma^2} = -\frac{T-1}{2\sigma^2} + \frac{S(\phi)}{2\sigma^4} = 0 \implies \boxed{\hat{\sigma}^2 = \frac{S(\hat{\phi})}{T-1} = \frac{1}{T-1}\sum_{t=2}^{T}(y_t - \hat{\phi} y_{t-1})^2}$$

Conferência no R: numa série simulada com $T = 301$, o máximo numérico da log-verossimilhança e a fórmula de MQO diferem em menos de 10^{-10}, e o `lm()` sem intercepto dá o mesmo valor, com diferença da ordem de 10^{-16}.

Exata × condicional (AU02, p. 78–80)

A MV **exata** acrescenta $\ln f(y_1)$, com $y_1 \sim N\big(0, \sigma^2/(1-\phi^2)\big)$, que é a distribuição incondicional:

$$\ell = \ell_c - \frac{1}{2}\ln(2\pi) - \frac{1}{2}\ln\frac{\sigma^2}{1-\phi^2} - \frac{(1-\phi^2)y_1^2}{2\sigma^2}.$$

Esse termo não é quadrático em ϕ: a exata **não tem forma fechada** e exige otimização numérica. Mas é **uma** parcela contra $T-1$, e os dois estimadores são consistentes e assintoticamente equivalentes. A exata só vale a pena em amostra pequena ou com ϕ perto de 1.

Do meu caderno (26/08 e 10/09)

- **26/08, "Verossimilhança (testar no R)":** $y_t = \theta_0 + \varepsilon_t + \theta_1\varepsilon_{t-1}$, $\Theta = (\theta_0, \theta_1, \sigma^2)$, $y_t \mid \varepsilon_{t-1} \sim N(\theta_0 + \theta_1\varepsilon_{t-1}, \sigma^2)$ e a densidade normal. É a verossimilhança **condicional do MA(1)** (AU02, p. 58–59). A diferença para o AR: no MA, os ε_t precisam ser reconstruídos por recursão a partir de $\varepsilon_0 = 0$, e não há forma fechada. No AR, o condicional é MQO.
- **26/08, AR(1) condicional:** $E(y_t \mid \Omega_{t-1}) = c + \phi_1 y_{t-1}$ e $V(y_t \mid \Omega_{t-1}) = \sigma^2$: são a média e a variância da densidade do Passo 1.
- **10/09:** "Estimação: $y_t = \phi y_{t-1} + u_t \rightarrow \min_\phi \sum u_t^2$": é o Passo 4 em uma linha.

O que o livro acrescenta

HAMILTON (cap. 5) mostra que, com intercepto, a MV condicional do AR(p) é o MQO de y_t em $(1, y_{t-1}, \ldots, y_{t-p})$, e que $\hat{\sigma}^2$ divide por $T - p$ (o número de parcelas). O estimador é **viesado** em amostra finita, porque y_{t-1} não é estritamente exógeno, mas é **consistente**.

Armadilhas e variações

- **Somar de $t = 1$:** a soma condicional começa em $t = 2$, porque y_0 não existe na amostra.
- **Dividir por T** em $\hat{\sigma}^2$: o número de parcelas é $T - 1$.
- **Não dizer por que é MQO:** a frase "maximizar ℓ_c em ϕ equivale a minimizar $S(\phi)$, porque o único termo com ϕ entra com sinal negativo" é a que vale o ponto.
- **Variações:** a conta com somas dadas, $\hat{\phi} = 84/120$, no Simulado 01, Q4b; exata × condicional no Simulado 02, Q4c.

CAPÍTULO 38

Q14 · AIC e BIC

← índice · anterior: Q13 · próxima: Q15 · resolução curta em 04_lista

O que a questão pede

Com $T = 150$ e três modelos de média zero, ARMA(1,1), ARMA(2,0) e ARMA(0,2), com $\ln L = -210{,}3;\ -212{,}8;\ -214{,}1$, e k **incluindo a variância do erro**:

- **(a) calcular** AIC e BIC e indicar o modelo escolhido por cada um;
- **(b) explicar** a diferença de penalidade e as propriedades assintóticas (consistência × eficiência).

Da lista para os slides

A AU02 (p. 98–99) define os critérios **divididos por** T:

$$AIC = \frac{-2\ln L(\Theta)}{T} + \frac{2k}{T}, \qquad BIC = \frac{-2\ln L(\Theta)}{T} + \frac{k\ln T}{T}.$$

O R e a maior parte dos livros não dividem por T. **Com o mesmo T para todos os modelos, a ordenação é idêntica.** Faço as duas versões, porque a prova pode pedir a do slide.

Contagem de k. A AU02, p. 99, diz que um ARMA(p,q) **com média** tem $p+q+1$ parâmetros, o "+1" sendo a média. A lista manda contar σ^2, e os modelos têm média zero. Aqui as duas contagens coincidem: são dois coeficientes mais um, ou seja, $k = 3$ nos três modelos. O que importa é **usar a mesma regra para todos**.

Ferramentas

- **Slides:** AU02, p. 97 (parcimônia), p. 98–99 (AIC, BIC, mesmo T, menor é melhor).
- **Livro:** TSAY, cap. 2 (critérios de informação); BJRL, cap. 6.

Demonstração minuciosa

(a) As contas

Passo 1 — o termo de ajuste, $-2\ln L$:

- ARMA(1,1): $-2(-210{,}3) = 420{,}6$;
- ARMA(2,0): $-2(-212{,}8) = 425{,}6$;
- ARMA(0,2): $-2(-214{,}1) = 428{,}2$.

Passo 2 — as penalidades, com $k = 3$:

- AIC: $2k = 6$;
- BIC: $k\ln T = 3\ln 150 = 3(5{,}0106) = 15{,}0319$.

Passo 3 — somar:

Modelo	$-2\ln L$	AIC	BIC	AIC/T (AU02)	BIC/T (AU02)
ARMA(1,1)	420,6	**426,6**	**435,632**	**2,8440**	**2,9042**
ARMA(2,0)	425,6	431,6	440,632	2,8773	2,9375
ARMA(0,2)	428,2	434,2	443,232	2,8947	2,9549

Conclusão: AIC e BIC escolhem o ARMA(1,1).

Como os três têm o mesmo k, a penalidade é igual para todos, e a escolha é decidida só pelo ajuste: o maior $\ln L$ ganha.

(b) Penalidades e propriedades assintóticas

A diferença de penalidade. Cada parâmetro a mais custa:

- **2** no AIC, sempre;
- $\ln T$ no BIC. Com $T = 150$, $\ln T = 5{,}01$.

Como $\ln T > 2$ sempre que $T \geq 8$, **o BIC pune mais e escolhe modelos menores**.

Consistência (BIC). Se o modelo verdadeiro está entre os candidatos, a probabilidade de o BIC escolhê-lo vai a 1 quando $T \to \infty$. A penalidade $k \ln T$ cresce sem limite e acaba eliminando qualquer parâmetro supérfluo, cujo ganho de ajuste é limitado.

Eficiência (AIC). O AIC **não é consistente**: mesmo com $T \to \infty$, ele escolhe um modelo grande demais com probabilidade positiva, porque a penalidade fixa, 2, não cresce. Em compensação, é **assintoticamente eficiente**: quando o modelo verdadeiro **não** está entre os candidatos (o caso realista), ele escolhe o que minimiza o erro de previsão esperado.

Na prática:

- para **identificar a ordem verdadeira**, use o BIC;
- para **prever**, use o AIC;
- quando discordam, olhe os resíduos dos dois (AU03) e o desempenho fora da amostra.

Do meu caderno (10/09)

O caderno anota as **métricas de previsão** (MAPE, MAD, RMSE, MASE) e a separação **treino/validação**: a avaliação fora da amostra que desempata quando AIC e BIC discordam (AU03).

O que o livro acrescenta

TSAY (cap. 2) observa que, em séries financeiras curtas, o BIC tende a escolher modelos muito parcimoniosos. Ele recomenda olhar os dois critérios **e** o Ljung-Box dos resíduos de cada candidato, antes de decidir.

Armadilhas e variações

- **Esquecer σ^2 em k:** se a lista manda contar, conte. Aqui não muda a escolha, porque é a mesma para todos, mas muda o **valor** pedido.
- **Comparar modelos estimados com T diferentes:** proibido (AU02, p. 99). Em SARIMA, o número de observações efetivas muda com d e D.
- **Dizer "o BIC é melhor":** depende do objetivo. A resposta precisa ter consistência × eficiência.

- **Variações:** AIC e BIC discordando com $T = 200$ no Simulado 01, Q4; a versão da AU02 com LR no Simulado 02, Q4; $T = 100$ no banco.

Bloco 4 — Identificação, estimação e diagnóstico

Q13 · MV condicional do AR(1)

Ideia: condicionar em y_1 transforma a MV em MQO. Resolução em 04_lista, D04.1 · HAMILTON cap. 5.

Variação A. Com constante, $y_t = c + \phi y_{t-1} + \varepsilon_t$. **Resposta.** $(\hat{c}, \hat{\phi})$ saem do MQO de y_t em $(1, y_{t-1})$, e $\hat{\sigma}^2 = SQR/(T-1)$. A média estimada é $\hat{\mu} = \hat{c}/(1-\hat{\phi})$.

Variação B. O estimador é não viesado? **Resposta.** Não: y_{t-1} não é estritamente exógeno, e há o viés de Hurwicz, de cerca de $-2\phi/T$ sem constante e $-(1+3\phi)/T$ com constante. Mas o estimador é **consistente** e assintoticamente normal.

Q14 · AIC e BIC

Ideia: k inclui σ^2. O BIC pune com $\ln T$, o AIC com 2. Resolução em 04_lista · AU02.

Variação A. $T = 100$: AR(1) com $\ln L = -140{,}2$; ARMA(1,1) com $-138{,}9$; AR(2) com $-138{,}7$. **Resposta.**

Modelo	k	AIC	BIC
AR(1)	2	284,4	**289,610**
ARMA(1,1)	3	283,8	291,616
AR(2)	3	**283,4**	291,216

O AIC escolhe o AR(2), e o BIC escolhe o AR(1).

Variação B. Esqueci de contar σ^2: muda a escolha? **Resposta.** Não, se todos os modelos estimam σ^2: somar 1 a todos os k desloca todos os critérios igualmente. **Mas o valor pedido fica errado e perde ponto.**

Parte VII

Bloco 5 — Previsão (Q15)

Capítulo 5 · Previsão: o elástico e o leque

← apostila · anterior: cap. 4 · próximo: cap. 6 · questão da lista: Q15

Pergunta de abertura

A previsão do tempo para amanhã usa a frente fria que está chegando. A previsão para daqui a 40 dias é praticamente a **média histórica** daquele dia do ano. **Por que a informação de hoje "se gasta" com o horizonte?** E outra pergunta, mais de fundo: entre todas as regras possíveis para prever, por que a escolhida é **a média condicional**, e não, por exemplo, o valor mais provável ou a mediana?

A AU02 trata a previsão em três lugares: MA (p. 54–57), AR (p. 72–76) e ARMA(1,1) (p. 85). As três seguem o mesmo roteiro:

1. escrever o modelo na data futura;
2. tirar a esperança condicional ao que se sabe hoje, Ω_T;
3. medir o erro.

Este capítulo mostra **por que** o roteiro é esse e o que ele implica.

A imagem

A previsão de um AR estacionário é um elástico preso na média. Hoje a série está longe da média μ. A previsão para amanhã puxa uma fração $1-\phi_1$ do caminho de volta; a de depois de amanhã puxa de novo; e assim por diante. O elástico nunca passa do ponto, se $\phi_1 > 0$, e a previsão converge para μ geometricamente: $\hat{y}_{T+h/T} - \mu = \phi_1^h(y_T - \mu)$.

A incerteza é um leque que abre e para de abrir.

- No horizonte 1, a única coisa que você não sabe é o choque de amanhã: a variância do erro é σ^2.
- A cada passo, entra um choque novo, multiplicado pelo peso ψ_j correspondente. O leque abre.
- Num processo estacionário, os ψ_j encolhem, e o leque **para de abrir** em γ_0, a variância incondicional: o horizonte infinito é a "climatologia".
- Num processo I(1), os pesos não encolhem, e o leque abre **para sempre**.

O MA(q) é uma memória de q dias. Depois de q passos, nenhum choque que você conhece afeta mais o futuro, e a melhor previsão é a média (AU02, p. 55).

O ARIMA(0,1,1) é um termômetro com inércia. A previsão é uma média das observações passadas com pesos que decaem geometricamente, $\alpha,\ \alpha(1-\alpha),\ \alpha(1-\alpha)^2, \ldots$: o "esquecimento exponencial". É a suavização exponencial simples, vista como um modelo.

> **Onde a analogia quebra**
>
> - **O elástico puxa a previsão, não a série.** A trajetória realizada não volta suavemente para μ: ela continua levando choques e oscilando. Quem desliza suavemente para a média é a **esperança condicional**.
> - **Com $\phi_1 < 0$, o elástico passa do ponto a cada período.** A previsão oscila em torno de μ enquanto converge.

- **O leque das fórmulas é estreito demais.** $\sigma^2 \sum \psi_j^2$ supõe que os parâmetros são conhecidos. Com parâmetros estimados, há uma incerteza extra, e os intervalos reais são mais largos. A normalidade dos erros também é uma hipótese, que a AU03 manda testar.

Teoria

Elementos da previsão (AU02, p. 54 e 72; AU03, p. 39–40): a origem T, a informação $\Omega_T = \{y_T, y_{T-1}, \dots\}$, o horizonte h, e

$$\hat{y}_{T+h/T} = E(y_{T+h} \mid \Omega_T), \qquad e_{T+h/T} = y_{T+h} - \hat{y}_{T+h/T}.$$

As três regras da esperança condicional (AU02, p. 54–55 e 72–73):

- o que já foi observado sai como está: $E(y_{T-j} \mid \Omega_T) = y_{T-j}$ e $E(\varepsilon_{T-j} \mid \Omega_T) = \varepsilon_{T-j}$ para $j \geq 0$;
- choque futuro vira zero: $E(\varepsilon_{T+j} \mid \Omega_T) = 0$ para $j \geq 1$;
- valor futuro vira a previsão dele: $E(y_{T+j} \mid \Omega_T) = \hat{y}_{T+j/T}$.

MA(q) (AU02, p. 54–57): $\hat{y}_{T+h/T} = \mu$ para $h > q$. No MA(1), o EQM é σ^2 em $h = 1$ e $(1 + \theta_1^2)\sigma^2$ em $h \geq 2$.

AR(1) (AU02, p. 72–76):

- $\hat{y}_{T+h/T} = \mu + \phi_1^h (y_T - \mu)$: a previsão volta à média geometricamente, à taxa ϕ_1 por passo;
- $e_{T+h/T} = \sum_{j=0}^{h-1} \phi_1^j \varepsilon_{T+h-j}$;
- $\mathrm{Var}(e_{T+h/T}) = \sigma^2 \frac{1-\phi_1^{2h}}{1-\phi_1^2} \to \frac{\sigma^2}{1-\phi_1^2} = \gamma_0$.

Caso geral pelos pesos ψ (lista, Q15c). Com $y_t = \mu + \sum_{j \geq 0} \psi_j \varepsilon_{t-j}$:

$$e_{T+h/T} = \sum_{j=0}^{h-1} \psi_j \, \varepsilon_{T+h-j} \quad \text{(um MA}(h-1)\text{)}, \qquad \mathrm{Var}(e_{T+h/T}) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2.$$

Intervalo de previsão (AU02, p. 56 e 74), com erros gaussianos: $\hat{y}_{T+h/T} \pm z_{\alpha/2} \sqrt{\mathrm{Var}(e_{T+h/T})}$. A 95%, $z = 1{,}96$.

ARIMA e longo prazo. Para $h > q$, as previsões obedecem à parte autorregressiva generalizada, $\phi(L)(1-L)^d \, \hat{y}_{T+h/T} = 0$ (BJRL, cap. 5). Com $d = 1$ e sem AR, a previsão fica **plana**. No ARIMA(0,1,1), ela é a suavização exponencial.

Iterada × direta (AU03, p. 41):

- a **iterada** usa o modelo de um passo recursivamente, como em todas as fórmulas acima;
- a **direta** estima um modelo diferente para cada horizonte.

Na prova teórica, a iterada é a que se deriva.

Demonstrações

D5.1 · O previsor de mínimo EQM é a esperança condicional (Q15a)

Seja g qualquer previsor construído com Ω_T, e $m = E(y_{T+h} \mid \Omega_T)$. Para encurtar, escreva $y \equiv y_{T+h}$, $E_T(\cdot) \equiv E(\cdot \mid \Omega_T)$ e $\mathrm{Var}_T(\cdot) \equiv \mathrm{Var}(\cdot \mid \Omega_T)$.

(1)	$E_T\big((y-g)^2\big) = E_T\big((y-m+m-g)^2\big)$	[soma e subtrai m]
(2)	$\quad = E_T\big((y-m)^2\big) + 2E_T\big((y-m)(m-g)\big) + E_T\big((m-g)^2\big)$	[quadrado, F4]
(3)	$E_T\big((y-m)(m-g)\big) = (m-g)\,E_T\big(y-m\big)$	[$m-g$ é conhecido em T]
(4)	$E_T\big(y-m\big) = m-m = 0$	[definição de m]
(5)	$E_T\big((m-g)^2\big) = (m-g)^2$	[conhecido em T]
(6)	$E_T\big((y-g)^2\big) = \mathrm{Var}_T(y) + (m-g)^2$	[(2)–(5)]
(7)	$\geq \mathrm{Var}_T(y)$, com igualdade $\iff g = m$	[$(m-g)^2 \geq 0$]

$\hat{y}_{T+h/T} = E(y_{T+h} \mid \Omega_T)$ minimiza o EQM; qualquer outro previsor paga $(m-g)^2$ a mais

O critério é que decide: com perda quadrática, é a média. Com perda absoluta, $|y-g|$, seria a mediana condicional. Sob normalidade, as duas coincidem.

D5.2 · ARMA(1,1): $\hat{y}_{T+1/T}$ e $\hat{y}_{T+2/T}$ (Q15b)

Modelo: $y_t = c + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$ (AU02, p. 85).

(1)	$y_{T+1} = c + \phi_1 y_T + \varepsilon_{T+1} + \theta_1 \varepsilon_T$	[modelo em $T+1$]
(2)	$\hat{y}_{T+1/T} = c + \phi_1 y_T + 0 + \theta_1 \varepsilon_T$	[regras: conhecido fica, futuro $\to 0$]
(3)	$y_{T+2} = c + \phi_1 y_{T+1} + \varepsilon_{T+2} + \theta_1 \varepsilon_{T+1}$	[modelo em $T+2$]
(4)	$\hat{y}_{T+2/T} = c + \phi_1 \hat{y}_{T+1/T} + 0 + 0$	[$y_{T+1} \to$ previsão; os dois choques são futuros]
(5)	$\hat{y}_{T+h/T} = c + \phi_1 \hat{y}_{T+h-1/T}, \quad h \geq 2$	[mesma conta]
(6)	$\hat{y}_{T+h/T} - \mu = \phi_1^{h-1}\big(\hat{y}_{T+1/T} - \mu\big) \to 0$	[$c = (1-\phi_1)\mu$; $\lvert\phi_1\rvert < 1$]

$$\hat{y}_{T+1/T} = c + \phi_1 y_T + \theta_1 \varepsilon_T, \qquad \hat{y}_{T+2/T} = c + \phi_1 \hat{y}_{T+1/T}$$

O MA só aparece no primeiro passo, através de ε_T, que é conhecido em T porque o processo é **invertível**. Na lista, $\theta_1 = -\theta$: $\hat{y}_{T+1|T} = \phi y_T - \theta a_T$, com média zero.

D5.3 · O erro de previsão é um MA($h-1$), e sua variância (Q15c)

(1) $y_{T+h} = \mu + \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j} + \sum_{j\geq h} \psi_j \varepsilon_{T+h-j}$ [Wold, separa futuro e passado]

(2) $\hat{y}_{T+h/T} = \mu + 0 + \sum_{j\geq h} \psi_j \varepsilon_{T+h-j}$ [futuro $\to$ 0; passado conhecido, invertível]

(3) $e_{T+h/T} = y_{T+h} - \hat{y}_{T+h/T} = \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j}$ [(1) − (2)]

(4) $E(e_{T+h/T} \mid \Omega_T) = \sum_{j=0}^{h-1} \psi_j E(\varepsilon_{T+h-j}) = 0$ [F4, soma finita; RB]

(5) $\mathrm{Var}(e_{T+h/T}) = E\Big(\Big(\sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j}\Big)^2\Big) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$ [RB: só termos quadrados]

(6) $\mathrm{Var}(e_{T+h/T}) \to \sigma^2 \sum_{j\geq 0} \psi_j^2 = \gamma_0$ [$h \to \infty$; cap. 1, D1.3]

$$e_{T+h/T} = \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j} \ \text{(MA}(h-1)\text{)}, \qquad \mathrm{Var} = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2 \ \uparrow \ \gamma_0$$

Intervalo de 95% (Q15d): $\hat{y}_{T+h/T} \pm 1{,}96\, \sigma \sqrt{\sum_{j=0}^{h-1} \psi_j^2}$. Um detalhe que cai em prova: os erros de **horizontes diferentes** são correlacionados. e_{T+1} e e_{T+2} dividem o choque ε_{T+1}.

D5.4 · ARIMA(0,1,1) é suavização exponencial (Q15e)

Nos slides, $\Delta y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$; na lista, $\theta_1 = -\theta$, com $0 < \theta < 1$.

(1) $y_{T+1} = y_T + \varepsilon_{T+1} + \theta_1 \varepsilon_T$ [modelo em $T+1$]

(2) $\hat{y}_{T+1/T} = y_T + \theta_1 \varepsilon_T$ [futuro $\to 0$]

(3) $\varepsilon_T = y_T - \hat{y}_{T/T-1}$ [o choque é o erro de um passo]

(4) $\hat{y}_{T+1/T} = y_T + \theta_1 (y_T - \hat{y}_{T/T-1}) = (1+\theta_1)\, y_T - \theta_1\, \hat{y}_{T/T-1}$ [(3) em (2)]

(5) $\alpha \equiv 1 + \theta_1 = 1 - \theta$: $\quad \hat{y}_{T+1/T} = \alpha\, y_T + (1-\alpha)\, \hat{y}_{T/T-1}$ [lista: $\theta_1 = -\theta$]

(6) $\hat{y}_{T+1/T} = \alpha \sum_{j\geq 0} (1-\alpha)^j\, y_{T-j}$ [(5) iterada; $0 < 1-\alpha < 1$]

(7) $\hat{y}_{T+h/T} = \hat{y}_{T+h-1/T} = \cdots = \hat{y}_{T+1/T}, \quad h \geq 2$ [$\varepsilon_{T+1}, \varepsilon_{T+2}, \ldots$ futuros]

$$\hat{y}_{T+h/T} = \alpha \sum_{j\geq 0} (1-\alpha)^j y_{T-j} \text{ para todo } h \geq 1, \qquad \alpha = 1 - \theta = 1 + \theta_1$$

A previsão de longo prazo é **constante**: o nível suavizado de hoje. A constante de suavização é $\alpha = 1 - \theta$. Quanto maior o θ da lista, menor o α, e mais a previsão "lembra" do passado distante. Os pesos de (6) somam 1, porque $\alpha \sum (1-\alpha)^j = \alpha \cdot \frac{1}{\alpha} = 1$ (F2).

Exemplo

1. AR(1) com $\mu = 10$, $\phi_1 = 0{,}8$, $\sigma^2 = 1$, e a última observação $y_T = 14$:

h	$\hat{y}_{T+h/T}$	Var(e)	intervalo de 95%
1	13,2	1	[11,24; 15,16]
2	12,56	1,64	
3	12,048	2,0496	
∞	10	2,7778	$10 \pm 3{,}267$

- O elástico puxa 20% do desvio por período: $4 \to 3{,}2 \to 2{,}56 \to 2{,}048$. A meia-vida do desvio é de 3,11 períodos.
- O leque abre de 1 para 1,64 e 2,05 e para em $\gamma_0 = 2{,}78$.

2. ARMA(1,1) da AU02, p. 86 ($\phi_1 = 0{,}8$, $\theta_1 = 0{,}6$, $\mu = 0$), com $y_T = 2$ e $\varepsilon_T = 0{,}5$:

- $\hat{y}_{T+1/T} = 0{,}8(2) + 0{,}6(0{,}5) = 1{,}9$;
- $\hat{y}_{T+2/T} = 0{,}8(1{,}9) = 1{,}52$.

Com $\psi = (1;\ 1{,}4;\ 1{,}12)$, a variância do erro é 1, depois $1 + 1{,}96 = 2{,}96$, depois 4,2144. O leque abre mais rápido que no AR(1), porque $\psi_1 = 1{,}4 > 1$.

3. Suavização exponencial, com $\theta^{\text{lista}} = 0{,}6$:

- $\alpha = 0{,}4$;
- os pesos de y_T, y_{T-1}, y_{T-2} são 0,4; 0,24; 0,144.

Numa série simulada de 300 observações, a recursão (5) e o `predict` do ARIMA(0,1,1) do R dão a mesma previsão, com diferença zero, e a previsão de 3 passos é igual à de 1: plana.

Avaliar previsões

A Q15 pergunta como prever. A AU03, p. 32–60, completa com a pergunta seguinte: **como saber se a previsão foi boa**, e se um modelo prevê melhor que outro. Nada disso é cobrado diretamente na lista, mas é o fecho natural do bloco e cai bem como item de discussão.

Treino, teste e janelas (AU03, p. 32–38). A amostra é dividida:

- um trecho de **treino**, para estimar;
- um trecho de **teste**, para medir os erros fora da amostra, que é o único lugar onde o erro de previsão é honesto.

Ao avançar a origem da previsão, há três esquemas:

- **janela fixa**: estima uma vez, no treino original, e só prevê;
- **janela recursiva**, ou expansiva: reestima a cada origem com todos os dados até ali;
- **janela móvel**, ou deslizante: reestima com as últimas R observações, que é o esquema que se adapta a quebras.

A AU03, p. 37–38, ressalta que essa escolha, o horizonte e a forma de prever (iterada ou direta) são três decisões independentes.

DA5.1 · Iterada × direta: quando a direta ganha (AU03, p. 41–44)

A **iterada** estima o modelo de um passo e o aplica h vezes. A **direta** regride y_{t+h} diretamente em y_t, um modelo por horizonte. No AR(1) de média zero, a iterada usa $\hat{\phi}^h y_T$, e a direta usa $\hat{b}_h y_T$, com $\hat{b}_h$ da regressão de y_{t+h} em y_t.

(1) $b_h^* = \dfrac{\mathrm{Cov}(y_{t+h}, y_t)}{\mathrm{Var}(y_t)} = \rho_h$ [a direta]

(2) $\operatorname{plim} \hat{\phi} = \rho_1 \;\Rightarrow$ iterada usa ρ_1^h [MQO do AR(1)]

(3) AR(1) verdadeiro: $\rho_h = \phi^h = \rho_1^h$: mesmo alvo [cap. 2, D2.4]

(4) $EQM(b) = E\big((y_{T+h} - b y_T)^2\big) = \gamma_0\big(1 - 2b\rho_h + b^2\big)$ [F4, estac.]

(5) $\dfrac{d\,EQM}{db} = \gamma_0(-2\rho_h + 2b) = 0 \;\Rightarrow\; b = \rho_h$ [a direta é a ótima linear]

(6) AR(2) verdadeiro, AR(1) ajustado: $\rho_1^h \neq \rho_h \;\Rightarrow\; EQM_{iter} > EQM_{dir}$ [(4), (5)]

modelo certo: iterada (mesmo alvo, menos parâmetros); modelo errado e h longo: direta

Com o AR(2) do caderno ($\phi_1 = 1{,}5$, $\phi_2 = -0{,}6$) ajustado como AR(1), em $h = 5$:

- a iterada usa $\rho_1^5 = 0{,}9375^5 = 0{,}7242$, mas o certo é $\rho_5 = 0{,}3417$;
- o EQM relativo da iterada é $1{,}0295\,\gamma_0$, pior até do que prever a média;
- o da direta é $0{,}8832\,\gamma_0$;
- a direta reduz o RMSE em 7,4%.

DA5.2 · As métricas de previsão pontual (AU03, p. 45–49)

Com os erros fora da amostra $\hat{e}_t = y_t - \hat{y}_t$, $t = 1, \ldots, n$:

(7) $MAD = \dfrac{1}{n}\sum |\hat{e}_t|$ [na unidade de y]

(8) $RMSE = \sqrt{\dfrac{1}{n}\sum \hat{e}_t^2}$ [pune erros grandes]

(9) $MAPE = \dfrac{100}{n}\sum \left|\hat{e}_t / y_t\right|$ [sem escala; exige $y_t \neq 0$]

(10) $MASE = \dfrac{\frac{1}{n}\sum |\hat{e}_t|}{Q}, \quad Q = \dfrac{1}{T_{tr} - m}\sum_{t=m+1}^{T_{tr}} |y_t - y_{t-m}|$ [escala do ingênuo no treino]

(11) $MASE < 1 \iff$ melhor que o ingênuo [(10)]

Exemplo. São cinco previsões, com reais $(102; 98; 105; 110; 107)$ e previstos $(100; 101; 103; 106; 109)$; o treino é $(95; 97; 96; 99; 101; 100)$, com $m = 1$.

- $MAD = 2{,}6$, $RMSE = 2{,}7203$ e $MAPE = 2{,}49\%$;
- $Q = 1{,}8$, logo $MASE = 1{,}44$: o modelo é **pior que o ingênuo**, embora o MAPE pareça baixo.

DA5.3 · Diebold-Mariano: a diferença é real? (AU03, p. 50–51)

(12) $d_t = L(e_{1t}) - L(e_{2t}),\ \ L(e) = e^2$ [diferencial de perda]

(13) $H_0 \ : \ E(d_t) = 0$ (mesma acurácia) [AU03 p. 50]

(14) $DM = \dfrac{\bar{d}}{\sqrt{\hat{V}(\bar{d})}} \xrightarrow{d} N(0,1), \quad \hat{V}(\bar{d}) = \dfrac{\hat{\sigma}_d^2}{n}$ se $h = 1$ [TLC]

(15) rejeita H_0 a 5% se $|DM| > 1{,}96$; o sinal de $\bar{d}$ diz quem é melhor [AU03 p. 51]

Com $h > 1$, os d_t são autocorrelacionados até a defasagem $h-1$, porque o erro de h passos é um MA($h-1$) (D5.3). Então $\hat{V}(\bar{d})$ precisa de um estimador robusto, do tipo Newey-West. E o esquema de reestimação importa: com **janela móvel**, a alternativa de Giacomini e White (2006), citada na AU03, p. 51, compara os **métodos** de previsão, incluindo a incerteza da estimação; com janela recursiva, o DM compara os modelos populacionais.

Exemplo com dez erros de dois modelos: $\bar{d} = 1{,}46$, $\hat{V}(\bar{d}) = 0{,}1581$ e $DM = 3{,}67 > 1{,}96$. O modelo 2 prevê significativamente melhor.

DA5.4 · Intervalos e distribuições: Winkler, CRPS e Christoffersen (AU03, p. 52–60)

Na linha (18), $z = (y_t - \mu)/\sigma$, e Φ e φ são a acumulada e a densidade da normal padrão.

(16) $W_t = (u - \ell) + \frac{2}{\alpha}(\ell - y_t)\,\mathbb{1}\{y_t < \ell\} + \frac{2}{\alpha}(y_t - u)\,\mathbb{1}\{y_t > u\}$ [Winkler, AU03 p. 53–55]

(17) $CRPS_t = \int_{-\infty}^{\infty} \big(F_t(x) - \mathbb{1}\{x \geq y_t\}\big)^2 dx$ [AU03 p. 56–58]

(18) $CRPS = \sigma\Big(z\big(2\Phi(z) - 1\big) + 2\varphi(z) - \frac{1}{\sqrt{\pi}}\Big)$ [$F_t = N(\mu, \sigma^2)$]

(19) $I_t = \mathbb{1}\{y_t \notin [\ell, u]\},\ \ \hat{\pi} = \frac{n_1}{n};\ \ H_0 \ : \ E(I_t) = \alpha$ [violações, AU03 p. 59]

(20) $LR_{uc} = -2\ln\big[(1-\alpha)^{n_0}\alpha^{n_1}\big] + 2\ln\big[(1-\hat{\pi})^{n_0}\hat{\pi}^{\,n_1}\big] \sim \chi^2_1$ [incondicional]

(21) $LR_{cc} = LR_{uc} + LR_{ind} \sim \chi^2_2$ [AU03 p. 59–60]

> Winkler: largura + $\frac{2}{\alpha}$ × distância do ponto fora; CRPS: área entre F_t e o degrau em y_t
>
> $$LR_{cc} = LR_{uc} + LR_{ind}$$

Exemplos:

- **Winkler**, com $\alpha = 0{,}05$ e o intervalo $[8; 12]$: $W = 4$ se $y = 10$ (dentro); $W = 24$ se $y = 7{,}5$ (meio ponto abaixo); $W = 44$ se $y = 13$ (um ponto acima). A cobertura que falha custa caro.
- **CRPS** com $y_t = 0$: a distribuição larga, $N(0; 9)$, dá 0,7011; a deslocada, $N(2; 1)$, dá 1,4528; a calibrada e afiada, $N(0; 0{,}25)$, dá 0,1168. A fórmula (18) coincide com a integral numérica (17).
- **Christoffersen**, com 100 intervalos de 90% e 15 violações: $LR_{uc} = 2{,}45$, $p = 0{,}12$. Não se rejeita a cobertura nominal, mas é preciso ainda o teste de independência: violações **agrupadas** reprovam o modelo mesmo com a frequência certa (AU03, p. 60).

Cadeia socrática

P1. Por que $E(\varepsilon_{T+1} \mid \Omega_T) = 0$, mas $E(\varepsilon_T \mid \Omega_T) = \varepsilon_T$?

Resposta

ε_{T+1} é a notícia de amanhã: é RB e não se correlaciona com nada de hoje, então a melhor aposta é a média, zero. ε_T já aconteceu e, se o modelo é invertível, pode ser calculado a partir de $y_T, y_{T-1}, \ldots$: é informação, não incerteza.

P2. Num MA(2), qual é $\hat{y}_{T+3/T}$?

Resposta

μ. $y_{T+3} = \mu + \varepsilon_{T+3} + \theta_1\varepsilon_{T+2} + \theta_2\varepsilon_{T+1}$: os três choques são futuros. A memória de 2 dias acabou (AU02, p. 55).

P3. E a variância do erro desse MA(2) no horizonte 3?

Resposta

$(1 + \theta_1^2 + \theta_2^2)\sigma^2 = \gamma_0$. Depois de q passos, o erro de previsão tem toda a variância do processo: você não sabe nada além da média.

P4. No AR(1), por que a variância do erro cresce, mas não passa de γ_0?

Resposta

Cada passo soma um termo $\phi_1^{2j}\sigma^2$, sempre positivo, e por isso ela cresce. Mas os termos encolhem geometricamente, e a soma converge para $\sigma^2/(1 - \phi_1^2) = \gamma_0$. No limite, prever é dar a média incondicional, com a incerteza incondicional.

P5. E se $\phi_1 = 1$?

Resposta

Então $\psi_j = 1$ para todo j, e $\text{Var}(e_{T+h}) = h\sigma^2$ cresce sem limite: o leque abre para sempre. A previsão pontual fica em y_T, sem drift, e não volta a média nenhuma. É o barco à deriva do cap. 3.

P6. Os erros de previsão de 1 e de 2 passos, feitos na mesma origem, são independentes?

Resposta

Não. $e_{T+1} = \varepsilon_{T+1}$ e $e_{T+2} = \varepsilon_{T+2} + \psi_1\varepsilon_{T+1}$ dividem ε_{T+1}: Cov $= \psi_1\sigma^2$. Uma surpresa amanhã contamina a previsão de depois de amanhã.

P7. Por que o ARIMA(0,1,1) dá previsão plana, se a série não é estacionária?

Resposta

Porque, sem drift, a melhor estimativa do **nível** futuro é o nível atual suavizado: os choques futuros têm média zero e não deslocam a esperança. O que cresce com h é a incerteza, não a previsão. Com drift, a previsão seria uma reta.

P8. Na D5.1, se o critério fosse o erro absoluto, a previsão seria outra?

Resposta

Seria a **mediana** condicional. Com erros gaussianos, média e mediana coincidem, e a fórmula não muda. Com distribuições assimétricas, mudam: a Q15(a) é sobre o EQM, e o enunciado define a perda.

Diálogo

Sobre o erro de calcular a variância do erro com os coeficientes errados.

Aluno: No ARMA(1,1), a variância do erro de dois passos é $\sigma^2(1+\phi_1^2)$, como no AR(1).

Professor: De onde vem esse ϕ_1^2?

Aluno: Do AR(1): $e_{T+2} = \varepsilon_{T+2} + \phi_1\varepsilon_{T+1}$.

Professor: E no ARMA(1,1)? Escreva y_{T+2} e tire a previsão.

Aluno: $y_{T+2} = \phi_1 y_{T+1} + \varepsilon_{T+2} + \theta_1\varepsilon_{T+1}$. E $y_{T+1} = \hat{y}_{T+1/T} + \varepsilon_{T+1}$. Substituindo, o erro é $\varepsilon_{T+2} + \phi_1\varepsilon_{T+1} + \theta_1\varepsilon_{T+1}$.

Professor: Então o coeficiente de ε_{T+1} é?

Aluno: $\phi_1 + \theta_1$, que é o ψ_1! A variância é $\sigma^2\big(1+(\phi_1+\theta_1)^2\big)$.

Professor: Com $\phi_1 = 0{,}8$ e $\theta_1 = 0{,}6$?

Aluno: $1 + 1{,}96 = 2{,}96$, bem maior que os 1,64 que eu teria dado.

Professor: Qual é a regra geral, então?

Aluno: Não copiar a fórmula do AR. Usar sempre $\sigma^2 \sum_{j=0}^{h-1} \psi_j^2$, com os ψ do modelo que está na questão, e conferir o sinal: na lista, $\psi_1 = \phi - \theta$.

Na prova

A folha de caderno do bloco está em a_mao_cap5.md: Q15 (a) a (e) em 40 linhas numeradas, cada uma com a justificativa, mais a versão para a prova e a conferência em R.

Questão	O que este capítulo dá	Resolução completa
Q15 (a)	média condicional minimiza o EQM	Q15
Q15 (b)–(d)	ARMA(1,1) em $h = 1, 2$; erro MA($h-1$); intervalo de 95%	Q15
Q15 (e)	ARIMA(0,1,1), previsão plana, $\alpha = 1 - \theta$	Q15
Q12 (c)	previsão do SARIMA trimestral, que usa as mesmas regras	Q12

Armadilhas:

- tratar ε_T como zero: ele é **conhecido** em T;
- usar ϕ_1^j como peso do erro num ARMA, quando o certo é ψ_j;
- esquecer que o MA "morre" depois de q passos;
- na Q15(e), escrever $\alpha = \theta$ em vez de $1 - \theta$ na convenção da lista;
- no caderno de 26/08, a previsão do MA(2) misturou $E(y_t \mid \Omega_{t-1})$ com $E(y_{t+2} \mid \Omega_t)$ (ver Q15).

Checklist de 30 segundos:

1. Escrevi o modelo **na data futura** antes de tirar a esperança?
2. Apliquei as três regras: conhecido fica, choque futuro é zero, y futuro vira previsão?
3. A variância do erro usa os ψ_j do modelo certo?
4. O intervalo tem $\pm 1{,}96\sqrt{\text{Var}}$, com a raiz?

5. Disse o que acontece no longo prazo (volta à média, ou fica plano)?

No material do professor

Roteiro de releitura:

- AU02, p. 44: modelo condicional × incondicional;
- AU02, p. 54–57: previsão do MA, o intervalo e o EQM;
- AU02, p. 72–76: previsão do AR(1), o erro e a variância;
- AU02, p. 85: previsão do ARMA(1,1);
- AU03, p. 32–41: treino e teste, esquemas de janela, horizonte e origem, iterada × direta.
- AU03, p. 42–49: o exemplo iterada × direta no AR(1) e as métricas MAPE, MAD, RMSE e MASE;
- AU03, p. 50–60: Diebold-Mariano, Winkler, CRPS e os testes de cobertura de Christoffersen.

Livros:

- **HAMILTON**, cap. 4: previsão ótima, a projeção linear e a esperança condicional;
- **BJRL**, cap. 5: previsão de ARIMA, pesos ψ, intervalos e a "função de previsão eventual";
- **ENDERS**, cap. 2: previsão de ARMA no nível do curso.

Na lista comentada: Q15 · Q12 · ferramenta F9 (esperança condicional).

Cap. 5 à mão — Q15 linha a linha

Cap. 5 à mão: Q15, linha a linha

← capítulo 5 · ← apostila · cap. 4 à mão

Versão de **caderno** do bloco 5 da lista: cada passagem numerada, uma operação por linha e o motivo entre colchetes. A notação é a dos slides: Ω_T, $\hat{y}_{T+h/T}$, $\theta_1 = -\theta^{\text{lista}}$. Para encurtar, $E_T(\cdot) \equiv E(\cdot \mid \Omega_T)$ e $\text{Var}_T(\cdot) \equiv \text{Var}(\cdot \mid \Omega_T)$.

Legenda:

- [RB]: ruído branco;
- [F2]: série geométrica;
- [F4]: linearidade da esperança;
- [F9]: as três regras da previsão: o que é conhecido em T fica, choque futuro vira zero, y futuro vira a previsão;
- [inv.]: invertibilidade, ou seja, ε_T é calculável a partir de $y_T, y_{T-1}, \ldots$;
- [(n)]: usando a linha (n).

Q15 · Previsão de um ARMA(p, q) estacionário e invertível

Enunciado (lista, Q15). Para um ARMA(p, q) estacionário e invertível:

- (a) o previsor de mínimo EQM é a esperança condicional;
- (b) as previsões de um e de dois passos do ARMA(1,1);
- (c) o erro de previsão é um MA($h-1$), com variância em função dos ψ_j;
- (d) o intervalo de 95% com erros gaussianos;
- (e) no ARIMA(0,1,1), a previsão de longo prazo é constante (suavização exponencial), e qual é a constante de suavização.

(a) A esperança condicional minimiza o EQM

Seja g qualquer previsor construído com Ω_T, $y \equiv y_{T+h}$ e $m \equiv E_T(y)$.

(1)	$E_T\big((y-g)^2\big) = E_T\big((y-m+m-g)^2\big)$	[soma e subtrai m]
(2)	$\quad = E_T\big((y-m)^2\big) + 2E_T\big((y-m)(m-g)\big) + E_T\big((m-g)^2\big)$	[quadrado, F4]
(3)	$E_T\big((y-m)(m-g)\big) = (m-g)\,E_T(y-m)$	[$m-g$ conhecido em T]
(4)	$E_T(y-m) = m-m = 0$	[definição de m]
(5)	$E_T\big((m-g)^2\big) = (m-g)^2$	[conhecido em T]
(6)	$E_T\big((y-g)^2\big) = \text{Var}_T(y) + (m-g)^2$	[(2)–(5)]
(7)	$E_T\big((y-g)^2\big) \geq \text{Var}_T(y)$, com igualdade $\iff g = m$	[$(m-g)^2 \geq 0$]

$$\boxed{\hat{y}_{T+h/T} = E(y_{T+h} \mid \Omega_T) \text{ minimiza o EQM}}$$

(b) ARMA(1,1): um e dois passos

Modelo: $y_t = c + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$ (AU02, p. 85).

Erro do caderno (26/08): a previsão do MA(2) misturou os horizontes e pôs θ_2 nos dois lugares

O caderno trocou $E(y_t \mid \Omega_{t-1})$ por $E(y_{t+2} \mid \Omega_t)$ na mesma linha. A defesa é sempre escrever o modelo **na data futura** antes de tirar a esperança, como em (8) e (11), e só então aplicar as regras [F9].

(8)	$y_{T+1} = c + \phi_1 y_T + \varepsilon_{T+1} + \theta_1 \varepsilon_T$	[modelo em $T+1$]
(9)	$\hat{y}_{T+1/T} = c + \phi_1 y_T + E_T(\varepsilon_{T+1}) + \theta_1 E_T(\varepsilon_T)$	[F4]
(10)	$= c + \phi_1 y_T + 0 + \theta_1 \varepsilon_T$	[F9; inv.]
(11)	$y_{T+2} = c + \phi_1 y_{T+1} + \varepsilon_{T+2} + \theta_1 \varepsilon_{T+1}$	[modelo em $T+2$]
(12)	$\hat{y}_{T+2/T} = c + \phi_1 \hat{y}_{T+1/T} + 0 + 0$	[F9: os dois choques são futuros]
(13)	$\hat{y}_{T+h/T} = c + \phi_1 \hat{y}_{T+h-1/T}, \quad h \geq 2$	[mesma conta]
(14)	$\hat{y}_{T+h/T} - \mu = \phi_1^{h-1}\big(\hat{y}_{T+1/T} - \mu\big) \to 0$	[$c = (1-\phi_1)\mu$; $\lvert\phi_1\rvert < 1$]
(15)	lista ($\mu = 0$) : $\hat{z}_{T+1\lvert T} = \phi z_T - \theta a_T$; $\hat{z}_{T+2\lvert T} = \phi\, \hat{z}_{T+1\lvert T}$	[$\theta_1 = -\theta$]

$$\boxed{\hat{y}_{T+1/T} = c + \phi_1 y_T + \theta_1 \varepsilon_T, \qquad \hat{y}_{T+2/T} = c + \phi_1 \hat{y}_{T+1/T}}$$

(c) O erro de previsão é um MA($h-1$)

Pela forma de Wold, $y_t = \mu + \sum_{j \geq 0} \psi_j \varepsilon_{t-j}$, com $\psi_0 = 1$:

(16)	$y_{T+h} = \mu + \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j} + \sum_{j \geq h} \psi_j \varepsilon_{T+h-j}$	[separa futuro e passado]
(17)	$\hat{y}_{T+h/T} = \mu + 0 + \sum_{j \geq h} \psi_j \varepsilon_{T+h-j}$	[F9; inv.]
(18)	$e_{T+h/T} = y_{T+h} - \hat{y}_{T+h/T} = \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j}$	[(16) − (17)]
(19)	(18) envolve h choques futuros, defasagens 0 a $h-1$: MA($h-1$)	[forma]
(20)	$E(e_{T+h/T}) = \sum_{j=0}^{h-1} \psi_j E(\varepsilon_{T+h-j}) = 0$	[F4, soma finita; RB]
(21)	$\mathrm{Var}(e_{T+h/T}) = \sum_{i=0}^{h-1} \sum_{j=0}^{h-1} \psi_i \psi_j E(\varepsilon_{T+h-i} \varepsilon_{T+h-j})$	[F4]
(22)	$= \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$	[RB: só $i = j$]
(23)	$h \to \infty$: $\mathrm{Var}(e_{T+h/T}) \to \sigma^2 \sum_{j \geq 0} \psi_j^2 = \gamma_0$	[processo linear]
(24)	ARMA(1,1): $\psi_1 = \phi_1 + \theta_1 \;\Rightarrow\; \mathrm{Var}(e_{T+2/T}) = \sigma^2\big(1 + (\phi_1 + \theta_1)^2\big)$	[(22), $h = 2$]
(25)	$\psi_2 = \phi_1(\phi_1 + \theta_1) \;\Rightarrow\; \mathrm{Var}(e_{T+3/T}) = \sigma^2\big(1 + \psi_1^2 + \psi_2^2\big)$	[(22), $h = 3$]
(26)	MA(q) : $\psi_j = 0$ para $j > q \;\Rightarrow\; \mathrm{Var}(e_{T+h/T}) = \gamma_0$ para $h > q$	[(22), AU02 p. 57]

$$\boxed{e_{T+h/T} = \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j} \;\; (\mathrm{MA}(h-1)), \qquad \mathrm{Var}(e_{T+h/T}) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2}$$

(d) Intervalo de 95%

(27) $\varepsilon_t \sim N(0,\sigma^2) \Rightarrow e_{T+h/T} \sim N\big(0,\ \sigma^2 \sum_{j=0}^{h-1} \psi_j^2\big)$ [soma de normais]

(28) $P\big(|e_{T+h/T}| \le 1{,}96\,\sigma_h\big) = 0{,}95, \quad \sigma_h \equiv \sigma\sqrt{\sum_{j=0}^{h-1} \psi_j^2}$ [normal padrão]

(29) $y_{T+h} \in \big[\hat{y}_{T+h/T} - 1{,}96\,\sigma_h;\ \hat{y}_{T+h/T} + 1{,}96\,\sigma_h\big]$ com prob. 0,95 [$y = \hat{y} + e$]

(30) $\mathrm{Cov}(e_{T+1/T}, e_{T+2/T}) = E\big(\varepsilon_{T+1}(\varepsilon_{T+2} + \psi_1\varepsilon_{T+1})\big) = \psi_1\sigma^2$ [RB]

$$\boxed{\hat{y}_{T+h/T} \pm 1{,}96\,\sigma\sqrt{\sum_{j=0}^{h-1} \psi_j^2}}$$

Em (30): os erros de horizontes diferentes, feitos na mesma origem, são **correlacionados**. Não se pode tratá-los como independentes.

(e) ARIMA(0,1,1) e suavização exponencial

Nos slides, $\Delta y_t = \varepsilon_t + \theta_1\varepsilon_{t-1}$; na lista, $\theta_1 = -\theta$, com $0 < \theta < 1$.

(31) $y_{T+1} = y_T + \varepsilon_{T+1} + \theta_1\varepsilon_T$ [modelo em $T+1$]

(32) $\hat{y}_{T+1/T} = y_T + \theta_1\varepsilon_T$ [F9]

(33) $\varepsilon_T = y_T - \hat{y}_{T/T-1}$ [o choque é o erro de 1 passo]

(34) $\hat{y}_{T+1/T} = (1+\theta_1)\,y_T - \theta_1\,\hat{y}_{T/T-1}$ [(33) em (32)]

(35) $\alpha \equiv 1+\theta_1 = 1-\theta: \quad \hat{y}_{T+1/T} = \alpha\,y_T + (1-\alpha)\,\hat{y}_{T/T-1}$ [$\theta_1 = -\theta$]

(36) $\hat{y}_{T+1/T} = \alpha\sum_{j\ge0}(1-\alpha)^j y_{T-j}$ [(35) iterada]

(37) $\alpha\sum_{j\ge0}(1-\alpha)^j = \alpha\cdot\frac{1}{1-(1-\alpha)} = 1$ [F2: pesos somam 1]

(38) $\hat{y}_{T+h/T} = \hat{y}_{T+h-1/T} + 0 = \cdots = \hat{y}_{T+1/T}, \quad h \ge 2$ [F9: choques futuros]

(39) $y_t = \dfrac{1+\theta_1 L}{1-L}\varepsilon_t: \quad \psi_0 = 1,\ \ \psi_j = 1+\theta_1 = \alpha,\ j \ge 1$ [F2, F7]

(40) $\mathrm{Var}(e_{T+h/T}) = \sigma^2\big(1+(h-1)\alpha^2\big) \to \infty$ [(22)]

$$\boxed{\hat{y}_{T+h/T} = \alpha\sum_{j\ge0}(1-\alpha)^j y_{T-j} \text{ para todo } h, \qquad \alpha = 1-\theta = 1+\theta_1}$$

A previsão é plana, e a constante de suavização é $\alpha = 1-\theta$. A **incerteza**, porém, cresce linearmente com h, por (40): o leque abre para sempre, porque o processo é I(1).

Versão para a prova

1. **(a)** Some e subtraia m; o termo cruzado zera, e sobra $\mathrm{Var}_T(y) + (m-g)^2$, mínimo em $g = m$.
2. **(b)** Modelo em $T+1$ e $T+2$, regras [F9]: $\hat{y}(1) = c + \phi_1 y_T + \theta_1\varepsilon_T$ e $\hat{y}(2) = c + \phi_1\hat{y}(1)$.
3. **(c)** Separe futuro e passado na forma de Wold: $e = \sum_{j<h}\psi_j\varepsilon_{T+h-j}$, com variância $\sigma^2\sum_{j<h}\psi_j^2$.
4. **(d)** $\hat{y} \pm 1{,}96\,\sigma\sqrt{\sum_{j<h}\psi_j^2}$.
5. **(e)** $\hat{y}(1) = \alpha y_T + (1-\alpha)\hat{y}_{T/T-1}$, com $\alpha = 1-\theta$; previsão plana; variância $\sigma^2(1+(h-1)\alpha^2)$.

Conferência

AR(1) com $\mu = 10$, $\phi_1 = 0{,}8$, $\sigma^2 = 1$ e $y_T = 14$:

- previsões 13,2; 12,56; 12,048;
- variâncias do erro 1; 1,64; 2,0496, com limite 2,7778;
- intervalo em $h = 1$: $[11{,}24;\ 15{,}16]$.

ARMA(1,1) com $\phi_1 = 0{,}8$, $\theta_1 = 0{,}6$, $y_T = 2$ e $\varepsilon_T = 0{,}5$:

- $\hat{y}(1) = 1{,}9$ e $\hat{y}(2) = 1{,}52$;
- variâncias do erro 2,96 em $h = 2$ e 4,2144 em $h = 3$;
- intervalo em $h = 2$: $[-1{,}852;\ 4{,}892]$;
- $\mathrm{Cov}(e_1, e_2) = \psi_1 = 1{,}4$.

Suavização exponencial com $\theta = 0{,}6$:

- $\alpha = 0{,}4$, com pesos 0,4; 0,24; 0,144;
- a recursão (35) coincide com o `predict` do ARIMA(0,1,1) do R, com diferença zero, e a previsão de 3 passos é igual à de 1.

CAPÍTULO 42

Q15 · Previsão em ARMA(p, q)

← índice · anterior: Q14 · próxima: Q16 · resolução curta em 05_lista, D05.1

O que a questão pede

Para um ARMA(p, q) estacionário e invertível:

- **(a) mostrar** que o previsor de mínimo EQM é $E(y_{T+h} \mid \mathcal{F}_T)$;
- **(b) derivar** as previsões de 1 e 2 passos do ARMA(1,1);
- **(c) mostrar** que o erro de previsão é um MA($h-1$) e calcular sua variância;
- **(d) construir** o intervalo de 95% com erros gaussianos;
- **(e) mostrar** que, no ARIMA(0,1,1), a previsão é uma suavização exponencial simples, e identificar a constante.

Da lista para os slides

Lista	Slides
$y_{T+h\|T} = E(y_{T+h} \mid \mathcal{F}_T)$	$\hat{y}_{t+k/t} = E(y_{t+k} \mid \Omega_t)$ (AU02, p. 54 e 72)
$e_T(h)$	$e_{t+k/t} = y_{t+k} - \hat{y}_{t+k/t}$ (AU02, p. 75)
ARMA(1,1) $z_t - \phi z_{t-1} = a_t - \theta a_{t-1}$	$y_t = c + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$ (AU02, p. 85), com $\theta_1 = -\theta$
ARIMA(0,1,1) $\Delta y_t = a_t - \theta a_{t-1}$	$\Delta y_t = \varepsilon_t + \theta^s \varepsilon_{t-1}$, com $\theta^s = -\theta$

Uso a origem T e o horizonte h, como a lista. O resto segue a notação dos slides.

Ferramentas

- **Slides:** AU02, p. 54–57 (previsão do MA, intervalo e EQM), p. 72–75 (previsão e erro do AR(1)), p. 85 (previsão do ARMA(1,1)); AU03 (avaliação fora da amostra).
- **Caixa:** [F4]; [F5]; [F9] esperança condicional e LEI.
- **Livro:** HAMILTON, cap. 4 (previsão ótima); BJRL, cap. 5 (pesos ψ, intervalos e atualização da previsão).

Demonstração minuciosa

(a) A esperança condicional minimiza o EQM

Seja g **qualquer** previsor que use só a informação Ω_T, e seja $m = E(y_{T+h} \mid \Omega_T)$.

1. **Some e subtraia** m: $y_{T+h} - g = (y_{T+h} - m) + (m - g)$.
2. **Eleve ao quadrado:** $(y_{T+h} - g)^2 = (y_{T+h} - m)^2 + (m - g)^2 + 2(y_{T+h} - m)(m - g)$.
3. **Tire a esperança condicional a Ω_T.** O termo $(m - g)$ é conhecido em T, porque m e g são funções de Ω_T, e sai da esperança:

$$E\big((y_{T+h} - m)(m - g) \mid \Omega_T\big) = (m - g)\, \underbrace{E(y_{T+h} - m \mid \Omega_T)}_{=m-m=0} = 0.$$

4. **Pela LEI** [F9], tirando a esperança incondicional: $E\big((y_{T+h} - g)^2\big) = E\big((y_{T+h} - m)^2\big) + E\big((m - g)^2\big)$.
5. **Conclusão:** o segundo termo é ≥ 0 e só vale zero com $g = m$. Portanto

$$\boxed{\hat{y}_{T+h/T} = E(y_{T+h} \mid \Omega_T) \text{ minimiza o EQM.}}$$

(b) Previsões do ARMA(1,1) (AU02, p. 85)

Escreva o modelo na data $T + h$: $y_{T+h} = c + \phi y_{T+h-1} + \varepsilon_{T+h} + \theta\varepsilon_{T+h-1}$, e aplique [F9].

$h = 1$**:** ε_{T+1} é futuro e vira 0; y_T e ε_T são conhecidos.

$$\boxed{\hat{y}_{T+1/T} = c + \phi y_T + \theta\varepsilon_T} \qquad \text{(lista, sem constante: } \phi z_T - \theta a_T\text{)}$$

$h = 2$**:** ε_{T+2} e ε_{T+1} viram 0, e y_{T+1} vira $\hat{y}_{T+1/T}$.

$$\boxed{\hat{y}_{T+2/T} = c + \phi\,\hat{y}_{T+1/T}}$$

O MA **some a partir de** $h = 2$, porque $q = 1$. Daí em diante, a previsão segue a recursão do AR e converge para $\mu = c/(1 - \phi)$.

(c) O erro é um MA($h - 1$)

Pelo Teorema de Wold (Q4), $y_{T+h} = \mu + \sum_{j\geq 0} \psi_j \varepsilon_{T+h-j}$. Separe os choques **futuros** dos **conhecidos**:

$$y_{T+h} = \mu + \underbrace{\sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j}}_{\text{choques de } T+1 \text{ a } T+h} + \underbrace{\sum_{j\geq h} \psi_j \varepsilon_{T+h-j}}_{\text{choques até } T}.$$

Aplicando [F9], os choques futuros viram 0 e os conhecidos ficam:

$$\hat{y}_{T+h/T} = \mu + \sum_{j\geq h} \psi_j \varepsilon_{T+h-j}.$$

Subtraindo:

$$\boxed{e_{T+h/T} = \sum_{j=0}^{h-1} \psi_j\, \varepsilon_{T+h-j} = \varepsilon_{T+h} + \psi_1\varepsilon_{T+h-1} + \cdots + \psi_{h-1}\varepsilon_{T+1}}$$

É um **MA($h - 1$)** nos choques futuros, com $\psi_0 = 1$. A variância sai por [F5], porque os choques são não correlacionados:

$$\boxed{V(e_{T+h/T}) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2 = \sigma^2\big(1 + \psi_1^2 + \cdots + \psi_{h-1}^2\big)}$$

No AR(1), $\psi_j = \phi^j$, e isso dá $\sigma^2(1 + \phi^2 + \cdots + \phi^{2(h-1)})$, a fórmula da AU02, p. 75.

Números, ARMA(1,1) com $\phi = 0{,}7$ e $\theta^{\text{lista}} = 0{,}4$ (nos slides, $\theta = -0{,}4$), e $\sigma^2 = 1$:

- $\psi_1 = \phi + \theta = 0{,}3$ e $\psi_2 = \phi\psi_1 = 0{,}21$;
- $V(1) = 1$, $V(2) = 1 + 0{,}09 = 1{,}09$ e $V(3) = 1{,}09 + 0{,}0441 = 1{,}1341$;

- $V(h) \to \gamma_0 = 1{,}1765$: em $h = 12$, já vale 1,1764.

No R, as previsões de 1 e 2 passos e as variâncias coincidem com o `predict()`, com diferença zero.

(d) Intervalo de 95%

Com erros gaussianos, $e_{T+h/T}$ é uma soma de normais e, portanto, é normal: $e_{T+h/T} \sim N\big(0,\ \sigma^2 \sum_{j<h} \psi_j^2\big)$. Logo $P\big(|e_{T+h/T}| \le 1{,}96\sqrt{V}\big) = 0{,}95$, e (AU02, p. 56 e 74)

$$\boxed{\hat{y}_{T+h/T} \ \pm\ 1{,}96\,\sigma\sqrt{1 + \psi_1^2 + \cdots + \psi_{h-1}^2}}$$

O intervalo **alarga com** h e, num processo estacionário, para de alargar em $\pm 1{,}96\sqrt{\gamma_0}$.

(e) ARIMA(0,1,1) é a suavização exponencial simples

O modelo é $y_t = y_{t-1} + \varepsilon_t + \theta^s \varepsilon_{t-1}$.

1. $h = 1$**:** $\hat{y}_{T+1/T} = y_T + \theta^s \varepsilon_T$.
2. $h \ge 2$**:** $\hat{y}_{T+h/T} = \hat{y}_{T+h-1/T} + 0 + 0$, e a previsão fica **constante em todos os horizontes**:

$$\hat{y}_{T+h/T} = y_T + \theta^s \varepsilon_T \quad \text{para todo } h \ge 1.$$

3. **Troque o choque pelo erro de previsão.** $\varepsilon_T = y_T - \hat{y}_{T/T-1}$ é o erro um passo à frente do Teorema de Wold. Substituindo:

$$\hat{y}_{T+1/T} = y_T + \theta^s(y_T - \hat{y}_{T/T-1}) = (1 + \theta^s)\, y_T - \theta^s\, \hat{y}_{T/T-1}.$$

4. **Chame** $\alpha = 1 + \theta^s$, logo $-\theta^s = 1 - \alpha$:

$$\boxed{\hat{y}_{T+1/T} = \alpha\, y_T + (1-\alpha)\, \hat{y}_{T/T-1}, \qquad \alpha = 1 + \theta^s \ \ \text{(lista: } \alpha = 1 - \theta)}$$

É a **suavização exponencial simples**: a nova previsão é uma média ponderada entre o dado novo e a previsão antiga.

5. **Abrindo a recursão:** $\hat{y}_{T+1/T} = \alpha \sum_{j \ge 0} (1-\alpha)^j y_{T-j}$, com pesos geométricos [F2]. Eles convergem se $|1 - \alpha| = |\theta| < 1$, que é **exatamente a invertibilidade**.

Com $\theta^{\text{lista}} = 0{,}6$: $\alpha = 0{,}4$. No R, a previsão do `arima` e a do `HoltWinters` com $\alpha = 0{,}4$ coincidem, com diferença da ordem de 10^{-16}.

Do meu caderno (26/08, 02/09 e 10/09)

- **26/08, MA(1):** $\hat{y}_{t+1/t} = c + \theta_1 \varepsilon_t$ e EQM de um passo $E\big((y_{t+1} - \hat{y}_{t+1/t})^2 \mid \Omega_t\big) = \sigma^2$, certos (AU02, p. 54 e 57). Também o intervalo $\hat{y}_{t+k/t} \pm z_{\alpha/2}\sqrt{MSE}$ e os três elementos da previsão: origem, informação e horizonte.
- **26/08, MA(2)**, com correção:

> **A previsão do MA(2) no caderno mistura os horizontes**
>
> - O certo é $E(y_t \mid \Omega_{t-1}) = c + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$. O caderno pôs θ_2 nos dois lugares.
> - A linha "$= c + \theta_1 E(\varepsilon_{t+1} \mid \Omega_t) + \theta_2 E(\varepsilon_t \mid \Omega_t) = c + \theta_2 \varepsilon_t$" é, na verdade, a previsão de **dois** passos, $E(y_{t+2} \mid \Omega_t)$.

> - Em $E(y_{t+3} \mid T)$ aparece θ_3; num MA(2), é θ_2. O resultado, *c*, está certo: depois de q passos, a previsão do MA(q) é a média.

- **02/09, AR(1):** $\hat{y}_{t+1/t} = \phi_0 + \phi_1 y_t$, $\hat{y}_{t+2/t} = \phi_0 + \phi_1 E(y_{t+1} \mid \Omega_t)$ e $e_{t+1/t} = \varepsilon_{t+1}$: certos (AU02, p. 72–75).
- **10/09, previsão iterada × direta:** a **iterada** estima um AR(1) e usa $\hat{y}_{t+h/t} = \hat{\phi}^h y_t$; a **direta** estima uma regressão por horizonte, $y_t = \phi^{(h)} y_{t-h} + u_t$, e usa $\hat{\phi}^{(h)} y_t$. Se o AR(1) estiver certo, $\phi^{(h)} = \phi^h$ e as duas coincidem. Também as métricas: MAPE (percentual), MAD (na unidade da série), RMSE e MASE (AU03).

O que o livro acrescenta

BJRL (cap. 5) mostra a **atualização da previsão**: quando chega y_{T+1}, cada previsão antiga se corrige por ψ_j vezes o erro novo, $\hat{y}_{T+h/T+1} = \hat{y}_{T+h/T} + \psi_{h-1} e_{T+1/T}$. É a forma mais rápida de refazer previsões na prova.

Armadilhas e variações

- **Esquecer $\psi_0 = 1$:** a variância de um passo é σ^2, e não zero.
- **Somar os ψ_j^2 até h** em vez de até $h - 1$.
- **SES com $\alpha = \theta$:** o certo é $\alpha = 1 - \theta$ na lista, ou $1 + \theta$ nos slides.
- **Variações:** AR(1) com média no Simulado 01, Q5; ARMA(1,1) com sinal positivo e SES no Simulado 02, Q5; MA(2) no Simulado 03, Q5.

CAPÍTULO 43

Bloco 5 — Previsão

Q15 · Previsão em ARMA

Ideia: $y_{T+h|T} = E(y_{T+h} \mid \mathcal{F}_T)$; o erro é um MA($h-1$); a variância é $\sigma^2 \sum_{j<h} \psi_j^2$. Resolução em 05_lista, D05.1 · HAMILTON cap. 4 · BJRL cap. 5.

Variação A. AR(2) com $\phi = (0{,}6;\ 0{,}2)$, $y_T = 2$, $y_{T-1} = 1$ e $\sigma^2 = 1$. **Resposta.** $y_{T+1|T} = 0{,}6 \cdot 2 + 0{,}2 \cdot 1 = 1{,}4$ e $y_{T+2|T} = 0{,}6 \cdot 1{,}4 + 0{,}2 \cdot 2 = 1{,}24$. Com $\psi_1 = 0{,}6$, $\text{Var}(e_T(2)) = 1 + 0{,}36 = 1{,}36$.

Variação B. Por que a variância do erro nunca diminui com h? **Resposta.** Cada passo acrescenta $\sigma^2 \psi_{h-1}^2 \geq 0$. No limite, ela converge para γ_0 num processo estacionário e diverge num processo I(1).

Variação C. ARIMA(0,1,1): qual a constante da suavização exponencial? **Resposta.** $\alpha = 1 - \theta$, na convenção BJ.

Parte VIII

Bloco 6 — Aplicação (Q16)

Capítulo 6 · Aplicação: Box-Jenkins de ponta a ponta num SARIMA mensal

← apostila · anterior: cap. 5 · questão da lista: Q16

Pergunta de abertura

Você tem 240 meses de uma variável macroeconômica, com tendência e sazonalidade. Alguém sugere um SARIMA$(1,1,1)(0,1,1)_{12}$. **Como você sabe se a sugestão é boa?** Não basta estimar: é preciso saber o que a FAC **deveria** mostrar se o modelo estivesse certo, o que os resíduos **deveriam** parecer, e como decidir contra um rival com um parâmetro a mais.

A Q16 é a questão-síntese da lista. Ela usa:

- a notação e a contagem do cap. 3;
- a FAC do cap. 2;
- os critérios do cap. 4;
- o diagnóstico da AU03.

Este capítulo junta as peças no **ciclo de Box-Jenkins** (AU03, p. 4–7).

A imagem

Box-Jenkins é um ciclo de diagnóstico médico. Os passos:

1. **Anamnese:** olhe o gráfico e a FAC.
2. **Hipótese diagnóstica:** identifique um modelo candidato.
3. **Tratamento:** estime.
4. **Exames de controle:** analise os resíduos.

Se os exames acusam algo, como uma autocorrelação que sobrou ou uma variância que muda, **volte ao passo 2**. O ciclo só termina quando os resíduos parecem ruído branco (AU03, p. 4–5).

Os resíduos são o que o modelo não conseguiu explicar. Se ainda há padrão neles, há informação na mesa. O Ljung-Box é o exame que pergunta se sobrou alguma correlação, em conjunto, até a defasagem K.

A FAC do SARIMA multiplicativo tem "satélites". Pense em duas engrenagens acopladas (cap. 3). O MA não sazonal deixa uma marca na defasagem 1, e o sazonal na 12. O produto dos dois cria marcas em 11 e 13, os satélites, em volta do pico sazonal: a assinatura do modelo multiplicativo.

Um quase fator comum é uma dupla de atores que se anulam em cena. Quando o AR e o MA têm raízes próximas, um desfaz o que o outro faz. O modelo ainda ajusta bem, mas fica impossível dizer quanto do efeito é de cada um: os erros-padrão explodem.

> **Onde a analogia quebra**
>
> - **"Resíduo branco" não prova que o modelo é o verdadeiro.** Vários modelos diferentes podem deixar resíduos limpos, e o ciclo seleciona um modelo **adequado**, não o único certo. É por isso que se usa um critério (BIC, LR) para escolher entre os adequados.

- **O médico examina a pessoa; nós examinamos uma única amostra.** Com 227 observações efetivas, um pico isolado na FAC dos resíduos, num de 24 lags, pode ser acaso: com 5% de nível, espera-se 1,2 rejeição "falsa" em 24. O teste conjunto existe para isso.
- **Os satélites só aparecem com os dois MA presentes.** Sem o MA não sazonal ($\theta_1 = 0$), não há satélite em 11 e 13.

Teoria

O modelo da Q16, nos slides:

$$(1-\phi L)(1-L)(1-L^{12})\,y_t = (1+\theta_1 L)(1+\Theta_1 L^{12})\,\varepsilon_t, \qquad \theta_1 = -\theta^{\text{lista}},\ \ \Theta_1 = -\Theta^{\text{lista}}.$$

Com $w_t = (1-L)(1-L^{12})y_t$, w_t é um ARMA(1,13) **restrito**, com MA só nas defasagens 1, 12 e 13, e o coeficiente da 13 igual a $\theta_1\Theta_1$.

Ciclo de Box-Jenkins (AU03, p. 4–7; AU02, p. 96–97):

1. **Identificação:** gráfico, diferenças para estacionarizar, FAC e FACP de w_t.
2. **Estimação:** MV, exata ou condicional (cap. 4).
3. **Diagnóstico** (*model checking*): resíduos, estabilidade e previsão.
4. **Uso:** previsão (cap. 5).

FAC do ARMA com MA de ordem q (AU02, p. 87): para $k > q$, vale a recursão do AR. No airline model ($\phi = 0$), a FAC de w_t é **zero fora de 1, 11, 12 e 13** (D6.1).

Diagnóstico dos resíduos (AU03, p. 9–22):

- **gráficos:** resíduos padronizados no tempo, histograma, QQ-plot e FAC dos resíduos (p. 10);
- **Jarque-Bera:** $JB = \frac{n}{6}\hat{S}^2 + \frac{n}{24}(\widehat{K}-3)^2 \sim \chi^2_2$, com H_0: normalidade (p. 11–14);
- **Ljung-Box:** $LB(K) = T(T+2)\sum_{i=1}^{K}\frac{\hat{\rho}_i^2}{T-i} \sim \chi^2_{K-p-q-P-Q}$, com $H_0 : \rho_1 = \cdots = \rho_K = 0$ nos erros (p. 15–17);
- **Breusch-Godfrey:** a versão LM, por regressão auxiliar dos resíduos (p. 18);
- **ARCH-LM:** $\hat{\varepsilon}_t^2$ regredido nas próprias defasagens, para detectar heterocedasticidade condicional (p. 19–22).

Escolha entre rivais (AU02, p. 98–99): mesmo T; BIC para identificar e AIC para prever; LR para modelos aninhados (cap. 4).

Demonstrações

D6.1 · A FAC do modelo das companhias aéreas: o pico e os satélites

Com $\phi = 0$: $w_t = (1+\theta_1 L)(1+\Theta_1 L^{12})\varepsilon_t = \varepsilon_t + \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \theta_1\Theta_1\varepsilon_{t-13}$. Os coeficientes são $\psi_0 = 1$, $\psi_1 = \theta_1$, $\psi_{12} = \Theta_1$, $\psi_{13} = \theta_1\Theta_1$ e zero nos demais.

(1)	$\gamma_k = \sigma^2 \sum_j \psi_j\psi_{j+k}$	[cap. 1, D1.3]
(2)	$\gamma_0 = \sigma^2\big(1+\theta_1^2+\Theta_1^2+\theta_1^2\Theta_1^2\big) = \sigma^2(1+\theta_1^2)(1+\Theta_1^2)$	[$k=0$; fatora]
(3)	$\gamma_1 = \sigma^2(\psi_0\psi_1 + \psi_{12}\psi_{13}) = \sigma^2\theta_1(1+\Theta_1^2)$	[$k=1$]
(4)	$\gamma_{11} = \sigma^2\psi_1\psi_{12} = \sigma^2\theta_1\Theta_1$	[$k=11$: só o par $(1,12)$]
(5)	$\gamma_{12} = \sigma^2(\psi_0\psi_{12} + \psi_1\psi_{13}) = \sigma^2\Theta_1(1+\theta_1^2)$	[$k=12$]
(6)	$\gamma_{13} = \sigma^2\psi_0\psi_{13} = \sigma^2\theta_1\Theta_1$	[$k=13$]
(7)	$\gamma_k = 0$ para $k \notin \{0,1,11,12,13\}$	[nenhum par à distância k]

Dividindo por γ_0:

$$\boxed{\rho_1 = \frac{\theta_1}{1+\theta_1^2}, \qquad \rho_{12} = \frac{\Theta_1}{1+\Theta_1^2}, \qquad \rho_{11} = \rho_{13} = \rho_1\,\rho_{12}}$$

Os satélites são o **produto** dos dois picos. É a forma mais rápida de reconhecer um MA multiplicativo na FAC. Com o AR ($\phi \neq 0$), as defasagens baixas passam a decair à taxa ϕ a partir de ρ_1, como no ARMA(1,1) do cap. 2.

D6.2 · Parâmetros, observações e a equação de w_t (Q16a e Q16b)

(1)	$(1+\theta_1 L)(1+\Theta_1 L^{12}) = 1 + \theta_1 L + \Theta_1 L^{12} + \theta_1\Theta_1 L^{13}$	[F8: quatro produtos]
(2)	$w_t = (1-L)(1-L^{12})y_t = y_t - y_{t-1} - y_{t-12} + y_{t-13}$	[F8]
(3)	$w_t = \phi w_{t-1} + \varepsilon_t + \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \theta_1\Theta_1\varepsilon_{t-13}$	[(1), (2)]
(4)	livres: ϕ, θ_1, Θ_1, σ^2; o coeficiente de ε_{t-13} é imposto	[forma multiplicativa]
(5)	sem constante: com $d = D = 1$, $c \neq 0$ geraria tendência quadrática em y_t	[cap. 3]
(6)	perdas: $d + sD = 1 + 12 = 13$; $T_{ef} = 240 - 13 = 227$	[(2) precisa de y_{t-13}]

$$\boxed{\text{4 parâmetros } (\phi, \theta_1, \Theta_1, \sigma^2), \qquad \text{227 observações efetivas}}$$

Na lista: $(1-\phi B)(1-B)(1-B^{12})y_t = (1-\theta B)(1-\Theta B^{12})a_t$, e o termo cruzado do MA é $+\theta\Theta B^{13}$, porque $(-\theta)(-\Theta) = +\theta\Theta$.

D6.3 · Ljung-Box e LR: as contas que decidem (Q16d e diagnóstico)

(1)	$LB(K) = T(T+2)\sum_{i=1}^{K} \frac{\hat\rho_i^2}{T-i}$	[AU03, p. 15]
(2)	$\nu = K - p - q - P - Q = 24 - 1 - 1 - 0 - 1 = 21$	[graus de liberdade com $K=24$]
(3)	rejeita H_0 a 5% se $LB(24) > \chi^2_{21;\,0{,}95} = 32{,}67$	[tabela]
(4)	$LR = 2\big(\ln L_{(2,1,1)} - \ln L_{(1,1,1)}\big) \xrightarrow{d} \chi^2(1)$	[$H_0 : \phi_2 = 0$; aninhados]
(5)	rejeita H_0 se $LR > 3{,}84$	[$\chi^2_{1;\,0{,}95}$]
(6)	BIC: multa $\ln 227 = 5{,}42$ por parâmetro	[cap. 4]

$$\nu_{LB} = K - p - q - P - Q, \qquad LR \sim \chi^2(1) \text{ com crítico } 3{,}84, \qquad \text{BIC exige } LR > \ln T_{ef} = 5{,}42$$

Ligando (5) e (6): o BIC prefere o modelo maior só se $LR > 5{,}42$, mais exigente que o teste a 5%, que pede $LR > 3{,}84$. É a D4.4 do cap. 4 aplicada.

Exemplo

1. A FAC teórica. Com $\theta^{\text{lista}} = 0{,}4$ e $\Theta^{\text{lista}} = 0{,}6$, ou seja, $\theta_1 = -0{,}4$ e $\Theta_1 = -0{,}6$ nos slides:

	ρ_1	ρ_2	ρ_{11}	ρ_{12}	ρ_{13}
airline ($\phi = 0$), pela D6.1	−0,3448	0	0,1521	−0,4412	0,1521
idem, pelo `ARMAacf`	−0,3448	0	0,1521	−0,4412	0,1521
Q16 ($\phi = 0{,}5$)	0,1052			−0,4411	

O pico sazonal quase não muda com o AR. Já ρ_1 muda até de sinal, porque o AR soma memória positiva às defasagens baixas.

2. Box-Jenkins de ponta a ponta. Simulei 240 meses do modelo verdadeiro ($\phi = 0{,}5$, $\theta_1 = -0{,}4$, $\Theta_1 = -0{,}6$, $\sigma^2 = 1$) e estimei o SARIMA$(1,1,1)(0,1,1)_{12}$ no R:

Parâmetro	verdadeiro	estimado	erro-padrão
ϕ	0,5	0,402	0,253
θ_1	−0,4	−0,218	0,266
Θ_1	−0,6	−0,705	0,058
σ^2	1	0,905	

Como ler:

- **observações:** o R usou 227, as 240 menos as 13 da D6.2;
- **diagnóstico:** $LB(24) = 15{,}39$ com 21 graus de liberdade, $p = 0{,}80$. Os resíduos parecem ruído branco, e o modelo é adequado;
- **rival:** contra o SARIMA$(2,1,1)(0,1,1)_{12}$, $LR = 0{,}47 < 3{,}84$, e o BIC do menor é 651,42 contra 656,38 do maior. Os dois apontam o modelo da Q16;
- **o alerta:** $\hat{\phi}$ e $\hat{\theta}_1$ têm erros-padrão de ~0,25, enormes perto dos valores. O motivo é um **quase fator comum**: $(1 - 0{,}5L)$ no AR e $(1 - 0{,}4L)$ no MA, com raízes 2 e 2,5, quase se cancelam. O par se anula em cena, e os dados não separam um do outro. Já o Θ_1, sem rival, é estimado com precisão.

Cadeia socrática

P1. Por que o coeficiente de ε_{t-13} não conta como parâmetro?

> **Resposta**
>
> Porque ele é o produto $\theta_1\Theta_1$, imposto pela forma multiplicativa. Não há um quinto número livre: conhecidos θ_1 e Θ_1, ele está determinado (D6.2).

P2. Por que não colocar uma constante, se a série cresce?

Resposta

Porque o crescimento já está nas duas raízes unitárias. Com $d = D = 1$, uma constante em w_t vira uma tendência **quadrática** em y_t, o que raramente faz sentido. É a regra 5 das notas de identificação de Duke e o argumento do cap. 3.

P3. Se o airline model tem FAC zero fora de 1, 11, 12 e 13, o que indica um pico em 24?

Resposta

Que falta algo sazonal: um AR sazonal, que geraria picos decaindo em 12, 24, 36…, ou um MA sazonal de ordem 2. O $\text{MA}(1)_{12}$ sozinho não gera nada em 24.

P4. Por que o Ljung-Box tem $K - p - q - P - Q$ graus de liberdade, e não K?

Resposta

Porque os resíduos vêm de um modelo **estimado**: cada parâmetro de AR e MA ajustado "consome" um grau de liberdade das autocorrelações, que ficam menores do que seriam com os choques verdadeiros. A variância σ^2 não entra na conta (AU03, p. 15).

P5. Os resíduos passaram no Ljung-Box. Acabou o diagnóstico?

Resposta

Não. Faltam:

- a **normalidade** (JB), que importa para os intervalos;
- a **heterocedasticidade condicional** (ARCH-LM, FAC de $\hat{\varepsilon}_t^2$);
- a **estabilidade** (Chow e CUSUM).

O Ljung-Box só olha a dependência **linear** nos resíduos (AU03, p. 7 e 19–30).

P6. No exemplo, por que $\hat{\phi}$ e $\hat{\theta}_1$ saíram tão imprecisos?

Resposta

Porque $(1 - 0{,}5L)$ e $(1 + \theta_1 L) = (1 - 0{,}4L)$ quase se cancelam: é um quase fator comum (cap. 2, P9). Os dados identificam bem o **efeito líquido**, mas não a divisão entre AR e MA. A regra de Duke manda testar o modelo com um AR e um MA a menos.

P7. Por que comparar com o $\text{SARIMA}(2,1,1)(0,1,1)_{12}$ pelo BIC, e não pelo R^2?

Resposta

Porque o R^2, ou a verossimilhança pura, sempre melhora com o parâmetro a mais: o maior contém o menor. O BIC desconta $\ln 227 = 5{,}42$ por parâmetro. E, como são aninhados, o LR dá uma confirmação com nível conhecido (D6.3).

P8. E se um modelo usasse $d = 0$ e o outro $d = 1$? Ainda posso comparar pelo BIC?

Resposta

Não diretamente. As variáveis modeladas são diferentes, y_t e Δy_t, e o número de observações efetivas também. A regra é mesmo T e mesma série (AU02, p. 99). A escolha de d e D vem antes, pela identificação e pelos testes de raiz unitária.

Diálogo

Sobre "os resíduos passaram, então o modelo está certo".

Aluno: Estimei o SARIMA da Q16, e o Ljung-Box deu $p = 0{,}80$. O modelo está certo.

Professor: Certo em que sentido?

Aluno: Os resíduos são ruído branco.

Professor: O teste mostrou que eles **são** ruído branco?

Aluno: ... Mostrou que eu não rejeito que sejam, até a defasagem 24.

Professor: E um SARIMA$(2,1,1)(0,1,1)_{12}$ também deixaria resíduos brancos?

Aluno: Provavelmente sim: ele contém o meu como caso particular.

Professor: Então o Ljung-Box escolhe entre os dois?

Aluno: Não. Ele separa os modelos adequados dos inadequados. Para escolher **entre** os adequados, preciso de outro critério: o BIC ou o LR. No exemplo, os dois ficaram com o menor.

Professor: E olhando as estimativas, nada incomoda?

Aluno: Os erros-padrão de ϕ e θ_1 são enormes... e as raízes do AR e do MA estão perto, 2 e 2,5. Pode ser um quase fator comum. Eu testaria também um modelo sem os dois, só com o MA sazonal.

Professor: Esse é o ciclo de Box-Jenkins: o diagnóstico manda de volta para a identificação.

Na prova

A folha de caderno do bloco está em a_mao_cap6.md: Q16 (a) a (d), mais o ciclo de Box-Jenkins em 41 linhas numeradas, cada uma com a justificativa, mais a versão para a prova e a conferência em R.

Questão	O que este capítulo dá	Resolução completa
Q16 (a)	o modelo em B, com o termo cruzado $+\theta\Theta B^{13}$	Q16
Q16 (b)	4 parâmetros e 227 observações efetivas	Q16
Q16 (c)	FAC de w_t: pico em 12, satélites em 11 e 13, decaimento à taxa ϕ	Q16
Q16 (d)	BIC (identificação) com o LR como confirmação, mesmo T	Q16
Q12 (d)	o roteiro de diagnóstico de resíduos	Q12

Armadilhas:

- contar 5 parâmetros, tratando $\theta\Theta$ como livre, ou 3, esquecendo σ^2;
- errar o sinal do termo cruzado na lista: $(-\theta)(-\Theta) = +\theta\Theta$;
- usar K graus de liberdade no Ljung-Box, em vez de $K - p - q - P - Q$;
- esperar um pico em 24 com um MA sazonal de ordem 1;
- dizer que "resíduo branco" prova que o modelo é o verdadeiro.

Checklist de 30 segundos:

1. Escrevi o modelo com os quatro polinômios e expandi o MA?
2. Contei os parâmetros, incluindo σ^2, e as observações perdidas, $d + sD$?
3. Descrevi a FAC com o pico, os satélites e o decaimento?
4. Listei o diagnóstico completo: gráficos, JB, LB com os graus de liberdade certos, ARCH e estabilidade?
5. Recomendei um critério **e** disse por quê (aninhados, mesmo T, objetivo)?

No material do professor

Roteiro de releitura:

- AU03, p. 4–7: o ciclo de Box-Jenkins e as duas dimensões da avaliação;
- AU03, p. 9–22: diagnóstico dos resíduos (gráficos, JB, Ljung-Box, Breusch-Godfrey, ARCH);
- AU03, p. 23–31: estabilidade, com Chow e análise recursiva/CUSUM;
- AU02, p. 87 e 90–97: FAC do ARMA(p, q), FACP e identificação;
- AU02, p. 98–99: AIC, BIC e a regra do mesmo T;
- AU05: SARIMA.

Livros:

- **BJRL**, cap. 9: o modelo das companhias aéreas, a FAC dos multiplicativos e a estratégia de partir dele;
- **ENDERS**, cap. 2: Box-Jenkins e diagnóstico no nível do curso;
- **HAMILTON**, cap. 5: a verossimilhança e os testes LR.

Na lista comentada: Q16 · Q12 · Q14.

Cap. 6 à mão — Q16 linha a linha

Cap. 6 à mão: Q16, linha a linha

← capítulo 6 · ← apostila · cap. 5 à mão

Versão de **caderno** do bloco 6 da lista: cada passagem numerada, uma operação por linha e o motivo entre colchetes. A notação é a dos slides, com o MA com sinal positivo: $\theta_1 = -\theta^{\text{lista}}$ e $\Theta_1 = -\Theta^{\text{lista}}$.

Legenda:

- [RB]: ruído branco;
- [F8]: multiplicar polinômios;
- caus.: o choque de hoje não se correlaciona com o passado;
- [(n)]: usando a linha (n).

Q16 · SARIMA$(1,1,1)(0,1,1)_{12}$ com 240 meses

Enunciado (lista, Q16). Para 240 observações mensais e o modelo SARIMA$(1,1,1)(0,1,1)_{12}$, pede-se:

- (a) o modelo completo com o operador de retardo;
- (b) quantos e quais parâmetros estimar;
- (c) a FAC e a FACP esperadas de $(1-B)(1-B^{12})y_t$;
- (d) o critério para compará-lo com o SARIMA$(2,1,1)(0,1,1)_{12}$.

(a) O modelo

(1)	$(1-\phi L)(1-L)(1-L^{12})\,y_t = (1+\theta_1 L)(1+\Theta_1 L^{12})\,\varepsilon_t$	[SARIMA, AU05]
(2)	$(1+\theta_1 L)(1+\Theta_1 L^{12}) = 1+\theta_1 L+\Theta_1 L^{12}+\theta_1\Theta_1 L^{13}$	[F8]
(3)	$(1-\phi L)(1-L) = 1-(1+\phi)L+\phi L^2$	[F8]
(4)	$(3)\times(1-L^{12}) = 1-(1+\phi)L+\phi L^2-L^{12}+(1+\phi)L^{13}-\phi L^{14}$	[F8]
(5)	$y_t = (1+\phi)y_{t-1}-\phi y_{t-2}+y_{t-12}-(1+\phi)y_{t-13}+\phi y_{t-14}+m_t$	[isola y_t]
(6)	$m_t = \varepsilon_t+\theta_1\varepsilon_{t-1}+\Theta_1\varepsilon_{t-12}+\theta_1\Theta_1\varepsilon_{t-13}$	[(2)]
(7)	$w_t \equiv (1-L)(1-L^{12})y_t = y_t-y_{t-1}-y_{t-12}+y_{t-13}$	[F8]
(8)	$w_t = \phi\, w_{t-1}+m_t$	[(1), (7)]
(9)	lista: $(1-\phi B)(1-B)(1-B^{12})y_t = (1-\theta B)(1-\Theta B^{12})a_t$, cruzado $+\theta\Theta B^{13}$	$[(-\theta)(-\Theta)=+\theta\Theta]$

$$\boxed{(1-\phi L)(1-L)(1-L^{12})\,y_t = (1+\theta_1 L)(1+\Theta_1 L^{12})\,\varepsilon_t}$$

(b) Os parâmetros e as observações

(10) livres: $\phi,\ \theta_1,\ \Theta_1,\ \sigma^2$ [3 polinômios + σ^2]

(11) o coeficiente de ε_{t-13} é $\theta_1\Theta_1$: imposto, não é livre [(2)]

(12) sem constante: com $d = D = 1,\ c \neq 0$ daria tendência quadrática [cap. 3]

(13) w_t precisa de y_{t-13} : perdem-se $d + sD = 1 + 12 = 13$ [(7)]

(14) $T_{ef} = 240 - 13 = 227$ [(13)]

4 parâmetros $(\phi, \theta_1, \Theta_1, \sigma^2)$; 227 observações efetivas

(c) A FAC e a FACP esperadas de w_t

Comece pelo caso $\phi = 0$, o modelo das companhias aéreas, em que $w_t = m_t$, com $\psi_0 = 1$, $\psi_1 = \theta_1$, $\psi_{12} = \Theta_1$, $\psi_{13} = \theta_1\Theta_1$ e os demais zero.

(15) $\gamma_k = \sigma^2 \sum_j \psi_j\psi_{j+k}$ [processo linear, AU02 p. 18]

(16) $\gamma_0 = \sigma^2(1 + \theta_1^2 + \Theta_1^2 + \theta_1^2\Theta_1^2) = \sigma^2(1 + \theta_1^2)(1 + \Theta_1^2)$ [$k = 0$; fatora]

(17) $\gamma_1 = \sigma^2(\psi_0\psi_1 + \psi_{12}\psi_{13}) = \sigma^2\theta_1(1 + \Theta_1^2)$ [$k = 1$]

(18) $\gamma_{11} = \sigma^2\psi_1\psi_{12} = \sigma^2\theta_1\Theta_1$ [$k = 11$]

(19) $\gamma_{12} = \sigma^2(\psi_0\psi_{12} + \psi_1\psi_{13}) = \sigma^2\Theta_1(1 + \theta_1^2)$ [$k = 12$]

(20) $\gamma_{13} = \sigma^2\psi_0\psi_{13} = \sigma^2\theta_1\Theta_1$ [$k = 13$]

(21) $\gamma_k = 0$ para $k \notin \{0, 1, 11, 12, 13\}$ [nenhum par à distância k]

(22) $\rho_1 = \dfrac{\theta_1}{1 + \theta_1^2}, \quad \rho_{12} = \dfrac{\Theta_1}{1 + \Theta_1^2}, \quad \rho_{11} = \rho_{13} = \rho_1\rho_{12}$ [$\div\gamma_0$]

Agora com o AR ($\phi \neq 0$), $w_t = \phi w_{t-1} + m_t$:

(23) $\gamma_k = \phi\gamma_{k-1} + E(m_t w_{t-k})$, e $E(m_t w_{t-k}) = 0$ para $k \geq 14$ [caus.: m_t vai até $t - 13$]

(24) $k \geq 14$: $\gamma_k = \phi\gamma_{k-1}$ [recursão do AR, AU02 p. 87]

(25) defasagens baixas: decaimento à taxa ϕ a partir de ρ_1 [como no ARMA(1,1)]

(26) em torno de 12: pico de Θ_1 com satélites em 11 e 13 [(18)–(20)]

(27) FACP: decai nas defasagens baixas e em torno de 12, 24, … [AU02 p. 95]

FAC: decai à taxa ϕ perto da origem; pico em 12, satélites em 11 e 13; FACP decai

(d) Como comparar com o SARIMA$(2,1,1)(0,1,1)_{12}$

(28)	o rival contém o modelo: $\phi_2 = 0 \;\Rightarrow$ aninhados	[1 restrição]
(29)	$LR = 2\big(\ln L_{(2,1,1)} - \ln L_{(1,1,1)}\big) \xrightarrow{d} \chi^2(1)$	[$H_0 : \phi_2 = 0$]
(30)	rejeita H_0 a 5% se $LR > 3{,}84$	[$\chi^2_{1;0,95}$]
(31)	$BIC = \dfrac{-2\ln L + k \ln T_{ef}}{T_{ef}}$, $\ln 227 = 5{,}42$	[AU02 p. 99]
(32)	o BIC prefere o rival $\iff LR > \ln 227 = 5{,}42$	[cap. 4, (38)]
(33)	mesmo $T_{ef} = 227$ nos dois: d e D iguais	[AU02 p. 99]
(34)	resíduos: $LB(24) \sim \chi^2_\nu$, $\nu = 24 - p - q - P - Q = 21$	[AU03 p. 15]
(35)	rejeita "resíduo branco" se $LB(24) > 32{,}67$	[$\chi^2_{21;0,95}$]
(36)	completam: JB, ARCH-LM, Chow/CUSUM	[AU03 p. 11–31]
(37)	recomendação: BIC (identificação), com o LR como confirmação	[aninhados, mesmo T]

BIC (multa $\ln 227 = 5{,}42$) e LR (crítico 3,84), mesmo $T_{ef} = 227$; LB com $\nu = 21$

O ciclo de Box-Jenkins em que tudo isso se encaixa (AU03, p. 4–7):

(38)	identificar: gráfico, diferenças, FAC e FACP de w_t	[item (c)]
(39)	estimar: MV exata ou condicional	[cap. 4]
(40)	diagnosticar: resíduos, estabilidade, previsão; se falhar, voltar a (38)	[item (d)]
(41)	usar: prever com as regras da esperança condicional	[cap. 5]

Versão para a prova

1. **(a)** Escreva (1) e expanda o MA, (2): o termo cruzado é $\theta_1\Theta_1 L^{13}$, que na lista vira $+\theta\Theta B^{13}$.
2. **(b)** São 4 parâmetros, $\phi, \theta, \Theta, \sigma^2$. Perdem-se 13 observações, e sobram 227.
3. **(c)**
   - pico em 12;
   - satélites em 11 e 13, iguais a $\rho_1\rho_{12}$ no airline;
   - decaimento à taxa ϕ nas defasagens baixas;
   - FACP decaindo.
4. **(d)** BIC e LR, porque os modelos são aninhados e têm o mesmo T, com críticos 3,84 e $\ln 227 = 5{,}42$. O Ljung-Box tem 21 graus de liberdade.

Conferência

O lado AR, com $\phi = 0{,}5$: os coeficientes de y_{t-1}, y_{t-2}, y_{t-12}, y_{t-13} e y_{t-14} em (5) são 1,5; −0,5; 1; −1,5; 0,5. O produto dos polinômios no R confere, com diferença zero.

A FAC. Com $\theta^{\text{lista}} = 0{,}4$ e $\Theta^{\text{lista}} = 0{,}6$, o termo cruzado vale 0,24.

- No airline, (22) dá $\rho_1 = -0{,}3448$, $\rho_{12} = -0{,}4412$ e $\rho_{11} = \rho_{13} = 0{,}1521$, iguais ao `ARMAacf`, com $\rho_2 = 0$.
- Com $\phi = 0{,}5$, $\rho_1 = 0{,}1052$ e $\rho_{12} = -0{,}4411$.

Os testes: $\chi^2_{1;0,95} = 3{,}84$, $\ln 227 = 5{,}42$ e $\chi^2_{21;0,95} = 32{,}67$.

A simulação de 240 meses do modelo verdadeiro:

- o R usou 227 observações;
- $LB(24) = 15{,}39$, com $p = 0{,}80$;
- $LR = 0{,}47$;
- BIC de 651,42 contra 656,38 do rival.

CAPÍTULO 46

Q16 · SARIMA$(1,1,1)(0,1,1)_{12}$ com 240 observações mensais

← índice · anterior: Q15 · resolução curta em 06_lista

O que a questão pede

- **(a) Escrever** o modelo completo com o operador de defasagem.
- **(b) Contar** e listar os parâmetros a estimar.
- **(c) Descrever** a FAC e a FACP esperadas de $(1-B)(1-B^{12})y_t$.
- **(d) Recomendar** um critério para comparar com o SARIMA$(2,1,1)(0,1,1)_{12}$.

Da lista para os slides

Lista	Slides
$(1-\phi B)(1-B)(1-B^{12})y_t = (1-\theta B)(1-\Theta B^{12})a_t$	$(1-\phi L)(1-L)(1-L^{12})y_t = (1+\theta^s L)(1+\Theta^s L^{12})\varepsilon_t$

Com $\theta^s = -\theta$ e $\Theta^s = -\Theta$.

Ferramentas

- **Slides:** AU02, p. 87 (FAC do ARMA(p,q): recursão do AR para $k > q$), p. 96–97 (identificação de modelos mistos), p. 98–99 (AIC, BIC, mesmo T); AU03, p. 15–17 (Ljung-Box com $\nu = k - p - q$); AU05 (SARIMA).
- **Caixa:** [F8] multiplicar polinômios.
- **Livro:** BJRL, cap. 9 (o modelo das companhias aéreas e a FAC dos multiplicativos); ENDERS, cap. 2.

Demonstração minuciosa

(a) O modelo completo

$$\boxed{(1-\phi L)(1-L)(1-L^{12})\,y_t = (1+\theta^s L)(1+\Theta^s L^{12})\,\varepsilon_t}$$

Expandindo o MA [F8]: $(1+\theta^s L)(1+\Theta^s L^{12}) = 1+\theta^s L+\Theta^s L^{12}+\theta^s\Theta^s L^{13}$. Na lista, isso é $1-\theta B-\Theta B^{12}+\theta\Theta B^{13}$.

Definindo $w_t = (1-L)(1-L^{12})y_t$, ou seja, $w_t = y_t - y_{t-1} - y_{t-12} + y_{t-13}$:

$$w_t = \phi w_{t-1} + \varepsilon_t + \theta^s\varepsilon_{t-1} + \Theta^s\varepsilon_{t-12} + \theta^s\Theta^s\varepsilon_{t-13}.$$

(b) Parâmetros

$$\boxed{\text{4 parâmetros: } \phi,\ \theta,\ \Theta,\ \sigma^2}$$

- O coeficiente de ε_{t-13} **não** é um parâmetro novo: é o produto $\theta\Theta$, imposto pela forma multiplicativa.
- Não há constante: com $d = D = 1$, uma constante em w_t implicaria uma tendência quadrática em y_t, o que raramente faz sentido.
- Observações efetivas: perdem-se $d + sD = 1 + 12 = 13$, e sobram $240 - 13 = 227$.

(c) FAC e FACP esperadas de w_t

w_t é um ARMA(1,13) restrito: AR(1) com MA só nas defasagens 1, 12 e 13. Pela AU02, p. 87, para $k > 13$ vale a recursão do AR, $\gamma_k = \phi\gamma_{k-1}$. O padrão esperado:

1. **Perto da origem**, defasagens 1, 2, 3…: decaimento geométrico a partir de ρ_1, à taxa ϕ, como no ARMA(1,1) da Q6.
2. **Perto de 12**: um pico forte em 12, gerado por Θ, com os "satélites" 11 e 13. É a assinatura do produto $(1 + \theta^s L)(1 + \Theta^s L^{12})$.
3. **Depois de 13**: decaimento geométrico, por causa de ϕ. Sem fator AR sazonal, não há pico relevante em 24.
4. **FACP**: decai, sem corte, nas defasagens baixas e em torno de 12, 24…, porque há MA de verdade nas duas escalas (AU02, p. 95).

Números, com $\phi = 0{,}5$, $\theta^{\text{lista}} = 0{,}4$ e $\Theta^{\text{lista}} = 0{,}6$:

- $\rho_1 = 0{,}1052$ e $\rho_2 = 0{,}0525$, decaindo à taxa $\phi = 0{,}5$;
- $\rho_{12} = -0{,}4411$, o pico sazonal;
- satélites $\rho_{11} = -0{,}0463$ e $\rho_{13} = -0{,}0464$.

Sem o AR, isto é, com $\phi = 0$ (o modelo das companhias aéreas), a FAC seria **zero fora de 1, 11, 12 e 13**.

Leitura para a prova: "FAC com pico em 12 e satélites em 11 e 13, mais decaimento nas defasagens baixas; FACP decaindo" $\Longrightarrow$ SARIMA$(1,1,1)(0,1,1)_{12}$.

(d) Como comparar com o SARIMA$(2,1,1)(0,1,1)_{12}$

1. **Os modelos são aninhados:** o segundo vira o primeiro com $\phi_2 = 0$.
2. **Teste LR:** $LR = 2(\ell_{(2)} - \ell_{(1)}) \sim \chi^2(1)$ sob $H_0 : \phi_2 = 0$. Rejeite se $LR > 3{,}84$, a 5%.
3. **BIC**, que é consistente e pune com $\ln 227 \approx 5{,}42$ por parâmetro. Use se o objetivo é **identificar** o modelo. Use o **AIC** se o objetivo é **prever** (Q14).
4. **Mesmo** T (AU02, p. 99): os dois têm $d = D = 1$, então os dois usam as mesmas 227 observações. Confira se o software usou a mesma amostra.
5. **Complementos:** Ljung-Box dos resíduos dos dois, com $\nu = K - p - q - P - Q$ (AU03, p. 15), e erro de previsão fora da amostra (AU03).

Recomendação: o BIC, com o LR como confirmação, porque os modelos são aninhados e o objetivo é a especificação.

Do meu caderno (09/09)

O caderno desenha a FAC e a FACP do AR(2), em que a FAC decai e a FACP corta em 2, e do MA(2), em que a FAC corta em 2 e a FACP decai. São as duas "assinaturas" que, combinadas nas escalas 1 e 12, dão o padrão do item (c).

O que o livro acrescenta

BJRL (cap. 9) apresenta o SARIMA$(0,1,1)(0,1,1)_{12}$ ("airline model") como o ponto de partida para séries mensais com tendência e sazonalidade. O $(1,1,1)$ desta questão o estende com um AR não sazonal. A estratégia do livro: começar do modelo das companhias aéreas e acrescentar termos só se a FAC dos resíduos pedir.

Armadilhas e variações

- **Contar 5 parâmetros**, tratando $\theta\Theta$ como livre, ou 3, esquecendo σ^2.
- **Esperar pico em 24** com um MA sazonal: o MA$(1)_{12}$ só gera pico em 12. Pico decaindo em 12, 24, 36… indicaria um AR sazonal.
- **Variações:** o modelo das companhias aéreas no Simulado 01, Q6; identificação por uma FAC amostral no Simulado 03, Q6; contagem do SARIMA$(2,1,1)(1,1,1)_{12}$ no banco.

CAPÍTULO 47

Bloco 6 — Aplicação

Q16 · SARIMA mensal

Ideia: escrever o modelo, contar os parâmetros, prever a FAC de w_t e escolher entre modelos aninhados. Resolução em 06_lista · BJRL cap. 9 · AU03.

Variação A. SARIMA$(2,1,1)(1,1,1)_{12}$ com $T = 240$. **Resposta.** São ϕ_1, ϕ_2, θ, Φ, Θ e σ^2: **6** parâmetros. Perdem-se 13 observações, e sobram 227.

Variação B. Que padrão na FAC de w_t indicaria SAR em vez de SMA? **Resposta.** Com SMA(1), a FAC corta em 12. Com SAR(1), ela **decai** em 12, 24, 36… e a FACP corta em 12.

Parte IX

Treino: simulados, gabaritos e log de erros

CAPÍTULO 48

Simulado 01

> **Regras**
>
> Sem consulta e sem calculadora gráfica, **1h50**, cronometrado. Total: 10,0 pontos, uma questão por bloco da lista. Comece pelos itens de conta curta (Q4 e Q1c) e só depois vá às demonstrações. Em todo item, escreva **primeiro a fórmula geral** e, se houver MA, **a convenção de sinal**. O gabarito com rubrica está em simulado_01_gabarito.md; não abra antes de terminar.

Notação. a_t, ε_t e u_t são ruído branco, $RB(0, \sigma^2)$. O operador de defasagem é B, e o MA segue a convenção da lista: $\theta(B) = 1 - \theta_1 B - \cdots - \theta_q B^q$.

Questão 1 (1,5) — Bloco 1: processos e momentos

Seja o passeio aleatório sem drift $y_t = y_{t-1} + u_t$, com $y_0 = 2$ fixo.

a) Escreva y_t em função de y_0 e dos choques e calcule $E(y_t)$, $\mathrm{Var}(y_t)$ e $\mathrm{Cov}(y_t, y_{t-k})$, $0 \le k < t$. **(0,5)**

b) Mostre que $\mathrm{Corr}(y_t, y_{t-k}) = \sqrt{(t-k)/t}$ e calcule-a para $t = 100$ com $k = 1$ e $k = 10$. O que isso diz sobre a FAC amostral de um passeio aleatório? **(0,5)**

c) Dois processos estacionários e não correlacionados entre si têm autocovariâncias x_t : $\gamma_0 = 1{,}0$, $\gamma_1 = 0{,}4$, $\gamma_j = 0$ $(j \ge 2)$ e w_t : $\gamma_0 = 1{,}5$, $\gamma_1 = -0{,}6$, $\gamma_2 = 0{,}1$, $\gamma_j = 0$ $(j \ge 3)$. Calcule a autocovariância de $y_t = 2x_t + w_t$ e diga a que classe ARMA ele pertence. **(0,5)**

Questão 2 (2,0) — Bloco 2: ARMA

Considere $z_t - 0{,}6 z_{t-1} = a_t - 0{,}3 a_{t-1}$, com $\sigma_a^2 = 1$.

a) Escreva o modelo com o operador B e verifique estacionariedade e invertibilidade pelas raízes. **(0,4)**

b) Calcule γ_0, γ_1 e γ_2. **(0,6)**

c) Obtenha ρ_1 e ρ_2 e mostre que $\rho_k = \phi \rho_{k-1}$ para $k \ge 2$. **(0,4)**

d) Obtenha os três primeiros pesos ψ_j e π_j. **(0,6)**

Questão 3 (1,5) — Bloco 3: integração e sobrediferenciação

Seja $y_t = 0{,}5 y_{t-1} + \varepsilon_t$, $\varepsilon_t \sim RB(0, 1)$, e $w_t = \Delta y_t$.

a) Mostre que $(1 - 0{,}5B) w_t = (1 - B)\varepsilon_t$ e diga por que w_t não é invertível. **(0,5)**

b) Calcule $\mathrm{Var}(w_t)$ e $\rho_1(w)$ e compare com $\mathrm{Var}(y_t)$. **(0,6)**

c) Quais são as consequências de diferenciar esta série para a estimação e para a previsão? **(0,4)**

Questão 4 (1,5) — Bloco 4: estimação e seleção

a) Com $T = 200$, quatro modelos de média zero deram as log-verossimilhanças: AR(1) $-301{,}2$; ARMA(1,1) $-299{,}8$; AR(2) $-298{,}9$; AR(3) $-297{,}0$. Contando σ^2 em k e usando $\ln 200 \approx 5{,}2983$, calcule AIC e BIC e diga qual modelo cada critério escolhe. Por que podem discordar? **(0,9)**

b) Num AR(1) sem constante com $T = 101$, as somas de $t = 2$ a T são $\sum y_t y_{t-1} = 84$, $\sum y_{t-1}^2 = 120$ e $\sum y_t^2 = 130$. Escreva a log-verossimilhança condicional em y_1 e obtenha $\hat{\phi}$ e $\hat{\sigma}^2$. **(0,6)**

Questão 5 (2,0) — Bloco 5: previsão

Seja $y_t - 10 = 0{,}8(y_{t-1} - 10) + a_t$, $\sigma_a^2 = 4$, e $y_T = 12$.

a) Mostre que o previsor de mínimo EQM de y_{T+h} é $E(y_{T+h} \mid \mathcal{F}_T)$. **(0,6)**

b) Calcule $y_{T+h|T}$ para $h = 1, 2, 3$ e a fórmula geral. **(0,4)**

c) Mostre que o erro de previsão é um MA($h-1$) e calcule sua variância para $h = 1, 2, 3$. **(0,5)**

d) Construa os intervalos de 95% para $h = 1$ e $h = 2$. Para onde vão a previsão e a variância quando $h \to \infty$? **(0,5)**

Questão 6 (1,5) — Bloco 6: SARIMA aplicado

Uma série mensal com $T = 180$ observações foi identificada como SARIMA$(0,1,1)(0,1,1)_{12}$, com $\theta = 0{,}4$ e $\Theta = 0{,}6$.

a) Escreva o modelo com o operador B e expanda o lado MA. **(0,3)**

b) Quantos parâmetros são estimados? Quantas observações sobram depois das diferenças? **(0,3)**

c) Calcule a FAC teórica de $w_t = (1-B)(1-B^{12})y_t$ nas defasagens 1, 11, 12 e 13 e descreva a FACP. **(0,6)**

d) Para comparar com um SARIMA$(1,1,1)(0,1,1)_{12}$, que critério você usaria? **(0,3)**

CAPÍTULO 49

Simulado 02

> **Regras**
>
> Sem consulta, **1h50**, cronometrado, 10,0 pontos. Este simulado troca de convenção de sinal **dentro da prova** (Q1c e Q5 usam o sinal positivo dos slides; o resto usa Box-Jenkins). Antes de cada conta, escreva qual convenção está usando. Gabarito em simulado_02_gabarito.md.

Questão 1 (1,5) — Bloco 1: estacionariedade e Wold

a) Sejam A e B variáveis aleatórias não correlacionadas, com média zero e variância σ^2, e $\omega \in (0, \pi)$ fixo. Mostre que $z_t = A\cos(\omega t) + B\sin(\omega t)$ é estacionário de segunda ordem. **(0,4)**

b) Com $\omega = \pi/2$ e $\sigma^2 = 1$, calcule $\text{Cov}(z_t, z_{t-1})$ e $\text{Cov}(z_t, z_{t-2})$. Por que esse processo é o exemplo típico do componente **determinístico** da decomposição de Wold? **(0,4)**

c) Na convenção de sinal positivo, seja $x_t = a_t + 0{,}5a_{t-1}$ com $\sigma_a^2 = 2$. Calcule γ_0, γ_1 e ρ_1. Mostre que $x_t^* = e_t + 2e_{t-1}$, com $\sigma_e^2 = 0{,}5$, tem exatamente as mesmas autocovariâncias. Qual dos dois se escolhe, e por quê? **(0,7)**

Questão 2 (2,0) — Bloco 2: AR(2)

Seja $y_t = 0{,}5y_{t-1} + 0{,}3y_{t-2} + \varepsilon_t$, $\varepsilon_t \sim RB(0, 1)$.

a) Verifique a estacionariedade pelas três desigualdades do triângulo e pelas raízes do polinômio AR. **(0,4)**

b) Escreva as equações de Yule-Walker e obtenha ρ_1, ρ_2 e ρ_3. **(0,5)**

c) Calcule γ_0. **(0,4)**

d) Calcule ϕ_{11}, ϕ_{22} e ϕ_{33}. **(0,3)**

e) Calcule ψ_1, ψ_2 e ψ_3. **(0,4)**

Questão 3 (2,0) — Bloco 3: sazonalidade e ARIMA

a) Para o SAR(1)$_4$ $y_t = 0{,}6y_{t-4} + \varepsilon_t$, $\sigma^2 = 1$: calcule γ_0, ρ_4 e ρ_8 e diga quanto valem ρ_1 e ρ_3. Descreva a FACP. **(0,7)**

b) Escreva $(1 - 0{,}5B)(1 - 0{,}6B^4)y_t = \varepsilon_t$ como AR(5) e dê a restrição que os coeficientes satisfazem. **(0,6)**

c) Expanda o ARIMA(1,1,1) $(1 - 0{,}4B)(1 - B)y_t = (1 - 0{,}7B)a_t$ em equação de diferenças para y_t. **(0,4)**

d) Mostre que $w_t = \Delta y_t$ do item c) é um ARMA(1,1) estacionário e invertível. **(0,3)**

Questão 4 (1,5) — Bloco 4: seleção e verossimilhança

Com $T = 120$ e média zero: ARMA(1,1) $\ln L = -170{,}4$; AR(2) $\ln L = -171{,}9$; ARMA(2,1) $\ln L = -169{,}8$. Use $\ln 120 \approx 4{,}7875$ e $\chi^2_{1;\,0{,}95} = 3{,}84$.

a) Calcule AIC e BIC na forma da AU02 (divididos por T) e diga quais modelos são escolhidos. **(0,8)**

b) Teste ARMA(1,1) contra ARMA(2,1) pela razão de verossimilhança. **(0,4)**

c) Num AR(1), qual a diferença entre a verossimilhança exata e a condicional? Por que, com $T = 120$, isso quase não importa? **(0,3)**

Questão 5 (1,5) — Bloco 5: previsão

a) Na convenção de sinal positivo, $z_t = 0{,}5z_{t-1} + a_t + 0{,}4a_{t-1}$, $\sigma_a^2 = 1$, com $z_T = 2$ e $\hat{a}_T = 1$. Calcule $z_{T+h|T}$ para $h = 1, 2, 3$, os pesos ψ_1 e ψ_2, as variâncias dos erros para $h = 1, 2, 3$ e o intervalo de 95% para $h = 2$. **(1,0)**

b) No ARIMA(0,1,1) $\Delta y_t = a_t - 0{,}7a_{t-1}$, com $y_T = 50$ e $\hat{a}_T = 2$, calcule $y_{T+h|T}$ para todo $h \geq 1$ e mostre que a previsão é uma suavização exponencial simples. Qual a constante de suavização? **(0,5)**

Questão 6 (1,5) — Bloco 6: SARIMA aplicado

Uma série mensal com $T = 144$ foi modelada como SARIMA$(1,0,0)(0,1,1)_{12}$.

a) Escreva o modelo em B e a equação de y_t em função do passado. **(0,4)**

b) Quantos parâmetros e quantas observações efetivas? **(0,2)**

c) Escreva $y_{T+1|T}$ e $y_{T+13|T}$. **(0,4)**

d) O Ljung-Box dos resíduos com $K = 24$ deu $Q = 28{,}5$. Quantos graus de liberdade? Com $\chi^2_{22;\,0{,}95} = 33{,}92$, qual a conclusão? **(0,5)**

CAPÍTULO 50

Simulado 03

> **Regras**
>
> Sem consulta, **1h50**, 10,0 pontos. É o simulado mais longo: se aos 90 minutos faltar uma questão inteira, escreva só as **fórmulas e a estrutura** dela, porque elas valem ponto. Gabarito em simulado_03_gabarito.md.

Questão 1 (1,5) — Bloco 1: tendência determinística × estocástica

Com $\varepsilon_t \sim RB(0,1)$, considere

- **(TS)** $y_t = 2 + 0{,}5t + u_t$, com $u_t = 0{,}6u_{t-1} + \varepsilon_t$;
- **(DS)** $z_t = 0{,}5 + z_{t-1} + \varepsilon_t$, com $z_0 = 0$.

a) Calcule $E(y_t)$ e $\mathrm{Var}(y_t)$, e $E(y_{10})$. **(0,4)**

b) Calcule $E(z_t)$ e $\mathrm{Var}(z_t)$, e $\mathrm{Var}(z_{10})$. **(0,3)**

c) Qual o efeito de um choque unitário em ε_t sobre y_{t+5} e sobre z_{t+5}? **(0,3)**

d) Mostre que Δy_t é um ARMA(1,1) não invertível e calcule $\rho_1(\Delta y)$. Como se deve tirar a não estacionariedade de cada série? **(0,5)**

Questão 2 (2,0) — Bloco 2: verdadeiro ou falso

Na convenção de sinal positivo, seja $Y_t = \alpha Y_{t-1} + u_t + \beta u_{t-1}$, com $|\alpha| < 1$, $u_t \sim RB(0,\sigma^2)$, e $\gamma_h = E(Y_t Y_{t-h})$. Julgue, **com demonstração**, cada afirmativa. Depois, confira os números com $\alpha = \beta = 0{,}5$ e $\sigma^2 = 1$.

1. $\gamma_0 = \dfrac{1 + 2\alpha\beta + \beta^2}{1 - \alpha^2}\sigma^2$.
2. $\gamma_1 = \dfrac{(1 + \alpha\beta)(\alpha + \beta)}{1 - \alpha^2}\sigma^2$.
3. $\rho_2 = \alpha\rho_1$.
4. $\gamma_0 = \sigma^2/(1 - \alpha^2)$, porque a parte MA não afeta a variância.
5. Na representação $Y_t = \sum_{j\geq 1} \pi_j Y_{t-j} + u_t$, os pesos são $\pi_j = (\alpha + \beta)\beta^{j-1}$.
6. Como $|\alpha| < 1$, o processo é invertível.

Cada afirmativa julgada com a conta que a sustenta vale 0,25; o sistema que dá γ_0 e γ_1 vale 0,4; a conferência numérica, 0,1.

Questão 3 (2,0) — Bloco 3: previsão de um SARIMA trimestral

Para $(1 - 0{,}5B)(1 - B)(1 - B^4)y_t = (1 - 0{,}6B^4)a_t$, as últimas observações e resíduos são:

	$T-5$	$T-4$	$T-3$	$T-2$	$T-1$	T
y	100	104	98	101	107	103
$\hat{a}$	—	—	1,0	−0,5	0,8	0,4

a) Expanda o lado AR e escreva y_t em função do passado. **(0,6)**

b) Quantas observações se perdem com as diferenças? **(0,2)**

c) Calcule $y_{T+h|T}$ para $h = 1, \dots, 5$. **(1,0)**

d) Por que o termo MA some a partir de $h = 5$? Qual a forma da função de previsão a longo prazo? **(0,2)**

Questão 4 (1,5) — Bloco 4: seleção de SARIMA mensais

Com $T = 240$ observações mensais, ajustaram-se M1 = SARIMA$(1,1,1)(0,1,1)_{12}$, com $\ln L = -412{,}6$, e M2 = SARIMA$(2,1,1)(0,1,1)_{12}$, com $\ln L = -411{,}9$. Use o número de observações efetivas e $\ln 227 \approx 5{,}4250$.

a) Quantos parâmetros tem cada modelo? Quantas observações efetivas há? **(0,3)**

b) Calcule AIC e BIC. **(0,6)**

c) Faça o teste LR de M1 contra M2. **(0,4)**

d) Qual critério você recomendaria, e por quê? **(0,2)**

Questão 5 (1,5) — Bloco 5: previsão de um MA(2)

Seja $y_t = 3 + a_t - 0{,}5a_{t-1} + 0{,}2a_{t-2}$, com $\sigma_a^2 = 1$, $\hat{a}_T = 1$ e $\hat{a}_{T-1} = -2$.

a) Classifique na convenção Box-Jenkins e calcule $y_{T+h|T}$ para $h = 1, 2, 3$. **(0,5)**

b) Calcule $\mathrm{Var}(e_T(h))$ para $h = 1, 2, 3$ e o intervalo de 95% para $h = 3$. **(0,5)**

c) Mostre que, para $h > q$, a previsão é a média e a variância do erro é γ_0. O que isso diz sobre a "memória" de um MA(q)? **(0,5)**

Questão 6 (1,5) — Bloco 6: identificação e diagnóstico

Numa série mensal com $T = 240$, a FAC e a FACP amostrais de $w_t = (1-B)(1-B^{12})y_t$ deram:

Defasagem	1	2	3	11	12	13	24
FAC	−0,41	0,03	−0,05	0,17	−0,39	0,15	0,04
FACP	−0,41	−0,16	−0,12	0,06	−0,33	−0,20	−0,15

As demais defasagens ficaram dentro da banda.

a) Qual a banda aproximada de 95%? Que defasagens são significativas? **(0,3)**

b) Proponha um modelo e mostre que a FAC teórica com $\theta = \Theta = 0{,}5$ reproduz o padrão. **(0,6)**

c) O Ljung-Box dos resíduos com $K = 24$ deu $Q = 30{,}1$. Conclua com $\chi^2_{22;\,0{,}95} = 33{,}92$. **(0,4)**

d) E se a FAC dos resíduos tivesse um pico só na defasagem 12? **(0,2)**

CAPÍTULO 51

Simulado 01 — gabarito

Enunciado em simulado_01.md. Todos os números saem de prova.R.

> **Como se corrigir**
>
> Some os pontos **por passo**, pelo que você escreveu, não pelo que sabia. Fórmula geral escrita e aplicada com erro de conta ainda vale o passo da fórmula. Número certo sem fórmula nem justificativa vale metade. Cada passo que faltou vira uma linha no log de erros.

Questão 1 (1,5)

Origem na lista: itens a) e b): (lista, Q1); item c): (lista, Q3).

a) Momentos do passeio sem drift (0,5)

Por substituição recursiva, $y_t = y_0 + \sum_{j=1}^{t} u_j$. Então:

- $E(y_t) = y_0 + \sum_j E(u_j) = 2$ *[RB: $E(u_j) = 0$]*;
- $\text{Var}(y_t) = \sum_{j=1}^{t} \text{Var}(u_j) = t\sigma^2$ *[RB: choques não correlacionados; y_0 fixo]*;
- $\text{Cov}(y_t, y_{t-k}) = \text{Cov}\left(\sum_{j=1}^{t} u_j, \sum_{i=1}^{t-k} u_i\right) = (t-k)\sigma^2$ *[só os $t-k$ choques comuns contam].*

Conclusão: a média é constante, mas variância e covariância dependem de t. **O processo não é estacionário.**

Rubrica	Pontos
Solução recursiva $y_0 + \sum u_j$	0,1
E, Var e Cov com a hipótese de RB citada	0,3
Frase-conclusão "não estacionário, porque Var depende de t"	0,1

b) A correlação e a FAC amostral (0,5)

$$\text{Corr}(y_t, y_{t-k}) = \frac{(t-k)\sigma^2}{\sqrt{t\sigma^2\,(t-k)\sigma^2}} = \sqrt{\frac{t-k}{t}}.$$

Com $t = 100$: $k = 1$ dá $\sqrt{0{,}99} = 0{,}9950$; $k = 10$ dá $\sqrt{0{,}90} = 0{,}9487$.

Interpretação: a correlação fica perto de 1 por muitas defasagens e cai quase em linha reta. A FAC amostral de um passeio aleatório **decai muito devagar**, e esse é o sinal visual de raiz unitária (AU01; Enders, cap. 4). Num AR(1) estacionário, ao contrário, a queda é geométrica.

Rubrica	Pontos
Fórmula da correlação a partir de a)	0,2
Os dois valores	0,1
Ligação com a FAC amostral que decai devagar	0,2

c) Soma de processos (0,5)

Como x e w não são correlacionados, os termos cruzados somem:

$$\gamma_y(k) = \text{Cov}(2x_t + w_t,\ 2x_{t-k} + w_{t-k}) = 4\gamma_x(k) + \gamma_w(k).$$

$\gamma_0 = 4(1{,}0) + 1{,}5 = 5{,}5$, $\gamma_1 = 4(0{,}4) - 0{,}6 = 1{,}0$, $\gamma_2 = 0 + 0{,}1 = 0{,}1$ e $\gamma_k = 0$ para $k \geq 3$. Logo $\rho_1 = 0{,}1818$ e $\rho_2 = 0{,}0182$.

Conclusão: os momentos não dependem de t, então y_t é estacionário, e a FAC **corta depois da defasagem 2**: y_t é um **MA(2)** (lista, Q3).

Rubrica	Pontos
$\gamma_y = 4\gamma_x + \gamma_w$ citando a não correlação	0,2
$\gamma_0, \gamma_1, \gamma_2$	0,2
MA(2) pela FAC que corta em 2	0,1

> **Erro que custa ponto aqui**
>
> Escrever $2\gamma_x$ em vez de $4\gamma_x$: a constante sai **ao quadrado** da covariância. É o mesmo tipo de erro do efeito marginal na P1 de Econometria I: o número sem a fórmula escrita antes.

Questão 2 (2,0)

Origem na lista: itens a) e d): (lista, Q5); itens b) e c): (lista, Q6).

Convenção: Box-Jenkins, $\phi = 0{,}6$, $\theta = 0{,}3$.

a) Operador e raízes (0,4)

$(1 - 0{,}6B)z_t = (1 - 0{,}3B)a_t$.

- AR: $1 - 0{,}6z = 0 \Rightarrow z = 1{,}6667$, fora do círculo unitário: **estacionário**.
- MA: $1 - 0{,}3z = 0 \Rightarrow z = 3{,}3333$, fora do círculo unitário: **invertível**.
- Não há fator comum, então é um ARMA(1,1) de verdade.

b) Autocovariâncias (0,6)

Dois momentos auxiliares, multiplicando o modelo por a_t e a_{t-1}:

- $E(z_t a_t) = \sigma^2$;
- $E(z_t a_{t-1}) = \phi\sigma^2 - \theta\sigma^2 = (\phi - \theta)\sigma^2$.

Multiplicando por z_t e por z_{t-1} e tirando a esperança:

$$\gamma_0 = \phi\gamma_1 + \sigma^2 - \theta(\phi - \theta)\sigma^2, \qquad \gamma_1 = \phi\gamma_0 - \theta\sigma^2.$$

Substituindo a segunda na primeira:

$$\gamma_0 = \frac{1 + \theta^2 - 2\phi\theta}{1 - \phi^2}\sigma^2 = \frac{1 + 0{,}09 - 0{,}36}{1 - 0{,}36} = \frac{0{,}73}{0{,}64} = 1{,}140625.$$

Então $\gamma_1 = 0{,}6(1{,}140625) - 0{,}3 = 0{,}384375$ e, para $k \geq 2$, $\gamma_k = \phi\gamma_{k-1}$: $\gamma_2 = 0{,}230625$.

Rubrica	Pontos
$E(z_t a_t)$ e $E(z_t a_{t-1})$	0,2
Sistema de γ_0 e γ_1	0,2
Os três valores	0,2

c) FAC (0,4)

$\rho_1 = \gamma_1/\gamma_0 = \frac{(1-\phi\theta)(\phi-\theta)}{1+\theta^2-2\phi\theta} = \frac{0{,}82\cdot 0{,}3}{0{,}73} = 0{,}3370$ e $\rho_2 = 0{,}2022$.

Para $k \geq 2$, multiplicar o modelo por z_{t-k} dá $\gamma_k = \phi\gamma_{k-1}$, porque $E(a_t z_{t-k}) = E(a_{t-1} z_{t-k}) = 0$ *[z só depende de choques passados: causalidade].* Dividindo por γ_0: $\rho_k = \phi\rho_{k-1} = \phi^{k-1}\rho_1$. **A FAC decai geometricamente a partir de ρ_1, não de 1.**

d) Pesos (0,6)

$\psi(B) = \frac{1-\theta B}{1-\phi B}$ dá $\psi_j = (\phi-\theta)\phi^{j-1}$: $\psi_1 = 0{,}3$, $\psi_2 = 0{,}18$, $\psi_3 = 0{,}108$.

$\pi(B) = \frac{1-\phi B}{1-\theta B} = 1 - \sum_{j\geq 1}\pi_j B^j$ dá $\pi_j = (\phi-\theta)\theta^{j-1}$: $\pi_1 = 0{,}3$, $\pi_2 = 0{,}09$, $\pi_3 = 0{,}027$.

Os ψ convergem porque $|\phi| < 1$; os π, porque $|\theta| < 1$ (lista, Q6c).

Rubrica	Pontos
$\psi(B) = \theta(B)/\phi(B)$ e os três ψ_j	0,3
$\pi(B) = \phi(B)/\theta(B)$ e os três π_j	0,3

Questão 3 (1,5)

Origem na lista: (lista, Q9).

a) A forma ARMA de w_t (0,5)

Aplique $(1-B)$ dos dois lados de $(1-0{,}5B)y_t = \varepsilon_t$. Os operadores comutam:

$$(1-0{,}5B)(1-B)y_t = (1-B)\varepsilon_t \implies \boxed{(1-0{,}5B)w_t = (1-B)\varepsilon_t}$$

É um ARMA(1,1) com $\phi = 0{,}5$ e $\theta = 1$. O polinômio MA $1 - z$ tem raiz $z = 1$, **sobre** o círculo unitário. Os pesos de $\pi(B) = \frac{1-0{,}5B}{1-B} = 1 - 0{,}5(B + B^2 + \cdots)$ são todos iguais a 0,5 e não decaem: **não existe AR(∞) convergente**, então w_t não é invertível (D03.2).

b) Variância e FAC (0,6)

$$\mathrm{Var}(w_t) = 2(\gamma_0 - \gamma_1) = 2\gamma_0(1-\phi) = \frac{2\sigma^2}{1+\phi} = \frac{2}{1{,}5} = 1{,}3333.$$

$$\rho_1(w) = \frac{2\gamma_1 - \gamma_0 - \gamma_2}{2(\gamma_0 - \gamma_1)} = -\frac{1-\phi}{2} = -0{,}25.$$

$\mathrm{Var}(y_t) = \sigma^2/(1-\phi^2) = 1{,}3333$: com $\phi = 0{,}5$, **diferenciar não reduziu a variância**. Para $\phi < 0{,}5$ ela até aumenta. Variância que não cai e ρ_1 negativo são os dois sintomas clássicos de sobrediferenciação.

c) Consequências (0,4)

- **Estimação:** a MV do MA fica na fronteira $\theta = 1$, e a inferência sobre θ deixa de ser padrão (D03.2 e o *pile-up* do módulo 03).
- **Previsão:** o modelo diferenciado trata y como I(1). A previsão não volta à média, e a variância do erro cresce sem limite, quando a verdadeira converge para γ_0.
- **Princípio:** só diferenciar com evidência de raiz unitária (ADF e KPSS juntos).

Rubrica	Pontos
a) equação em B com os operadores comutando	0,2
a) raiz $z = 1 \Longrightarrow$ não invertível $\Longrightarrow$ sem AR(∞) (**a conclusão vale ponto**)	0,3
b) Var(w) e $\rho_1(w)$	0,4
b) comparação com Var(y)	0,2
c) estimação e previsão	0,4

Questão 4 (1,5)

Origem na lista: item a): (lista, Q14); item b): (lista, Q13).

a) AIC e BIC (0,9)

$AIC = -2\ln L + 2k$ e $BIC = -2\ln L + k\ln T$, com k contando os coeficientes **e** σ^2.

Modelo	k	$-2\ln L$	AIC	BIC	AIC/T (AU02)
AR(1)	2	602,4	606,4	**612,997**	3,032
ARMA(1,1)	3	599,6	605,6	615,495	3,028
AR(2)	3	597,8	603,8	613,695	3,019
AR(3)	4	594,0	**602,0**	615,193	3,010

O AIC escolhe o AR(3) e o BIC escolhe o AR(1). A divisão por T da AU02 não muda a ordem.

Por que discordam: cada parâmetro custa 2 no AIC e $\ln 200 = 5{,}30$ no BIC. O BIC pune mais e é **consistente**: se o modelo verdadeiro está entre os candidatos, ele o escolhe com probabilidade que vai a 1. O AIC é **eficiente** para previsão, mas tende a sobreparametrizar (lista, Q14).

Rubrica	Pontos
Fórmulas com k incluindo σ^2	0,2
Oito números	0,4
Escolhas e a explicação (penalidade, consistência × eficiência)	0,3

b) MV condicional = MQO (0,6)

Condicionando em y_1, com ε_t normal:

$$\ell(\phi,\sigma^2) = -\frac{T-1}{2}\ln(2\pi) - \frac{T-1}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}\sum_{t=2}^{T}(y_t-\phi y_{t-1})^2.$$

Para ϕ, maximizar ℓ é minimizar a soma dos quadrados, isto é, **MQO**:

$$\hat\phi = \frac{\sum y_t y_{t-1}}{\sum y_{t-1}^2} = \frac{84}{120} = 0{,}7, \qquad \hat\sigma^2 = \frac{1}{T-1}\Big(\sum y_t^2 - \hat\phi\sum y_t y_{t-1}\Big) = \frac{130-58{,}8}{100} = 0{,}712.$$

Rubrica	Pontos
ℓ condicional com $T-1$ termos	0,2
Condição de primeira ordem e $\hat\phi = 0{,}7$	0,2
$\hat\sigma^2 = 0{,}712$	0,2

Erro que custa ponto aqui

Este é o item de conta curta que ficou em branco na P1 de Econometria I (Q4b: 340/85). São duas divisões. Faça este item **antes** das demonstrações.

Questão 5 (2,0)

Origem na lista: (lista, Q15).

a) O previsor ótimo (0,6)

Seja g qualquer função de $\mathcal{F}_T$ e $m = E(y_{T+h} \mid \mathcal{F}_T)$. Somando e subtraindo m:

$$E\big((y_{T+h}-g)^2\big) = E\big((y_{T+h}-m)^2\big) + E\big((m-g)^2\big) + 2E\big((y_{T+h}-m)(m-g)\big).$$

O termo cruzado é zero pela **lei das expectativas iteradas**: $(m-g)$ é conhecido em T, e $E(y_{T+h}-m \mid \mathcal{F}_T) = 0$. Como $E\big((m-g)^2\big) \geq 0$, o EQM é mínimo com $g = m$. **Conclusão:** $y_{T+h|T} = E(y_{T+h} \mid \mathcal{F}_T)$ (D05.1).

b) Previsões (0,4)

$y_{T+h|T} - 10 = 0{,}8^h(y_T - 10)$, logo 11,6, 11,28 e 11,024 para $h = 1, 2, 3$.

c) Erro de previsão (0,5)

Com $\psi_j = 0{,}8^j$: $e_T(h) = \sum_{j=0}^{h-1}\psi_j a_{T+h-j}$, um MA$(h-1)$ nos choques futuros, e

$$\operatorname{Var}\big(e_T(h)\big) = \sigma^2\sum_{j=0}^{h-1}\psi_j^2 \;:\quad 4;\;\; 4(1+0{,}64) = 6{,}56;\;\; 6{,}56 + 4(0{,}4096) = 8{,}1984.$$

d) Intervalos e longo prazo (0,5)

- $h = 1$: $11{,}6 \pm 1{,}96\sqrt{4}$, isto é, $[7{,}68;\ 15{,}52]$.
- $h = 2$: $11{,}28 \pm 1{,}96\sqrt{6{,}56} = 11{,}28 \pm 5{,}0200$, isto é, $[6{,}2600;\ 16{,}3000]$.
- $h \to \infty$: a previsão vai à média $\mu = 10$, e a variância vai a $\sigma^2/(1-\phi^2) = 11{,}111 = \gamma_0$. A incerteza da previsão de longo prazo é a variância incondicional.

Rubrica	Pontos
a) decomposição e termo cruzado zero pela LEI	0,4
a) **frase-conclusão** do mínimo	0,2
b) fórmula geral e três valores	0,4
c) MA($h-1$) com $\psi_0 = 1$ e as variâncias	0,5
d) dois intervalos e limites	0,5

Erro que custa ponto aqui

Esquecer $\psi_0 = 1$ e escrever $\mathrm{Var}(e_T(1)) = 0$, ou somar ψ_j^2 até h em vez de $h-1$. Escreva o MA($h-1$) do erro antes da variância.

Questão 6 (1,5)

Origem na lista: (lista, Q16).

a) Modelo (0,3)

$$(1-B)(1-B^{12})y_t = (1-0{,}4B)(1-0{,}6B^{12})a_t = (1-0{,}4B-0{,}6B^{12}+0{,}24B^{13})a_t.$$

O produto cria o termo em B^{13} com coeficiente $\theta\Theta$: é o "modelo das companhias aéreas".

b) Parâmetros e observações (0,3)

Três parâmetros: θ, Θ e σ^2. Sem constante, porque $D = 1$. Perdem-se $d + sD = 1 + 12 = 13$ observações, e sobram $180 - 13 = 167$.

c) FAC e FACP (0,6)

w_t é um MA(13) com coeficientes só em 1, 12 e 13, e $\gamma_0 = (1+\theta^2)(1+\Theta^2)\sigma^2$:

Defasagem	Fórmula	Valor
1	$-\theta/(1+\theta^2)$	$-0{,}3448$
11 e 13	$\theta\Theta/[(1+\theta^2)(1+\Theta^2)]$	0,1521
12	$-\Theta/(1+\Theta^2)$	$-0{,}4412$
as demais	—	0

A FACP **decai** nas defasagens baixas, a partir da 1, e em torno de 12 e 24, como em todo MA. O "grupo" 11-12-13 na FAC é a assinatura do produto (lista, Q16c).

d) Comparação (0,3)

Os modelos são **aninhados**: $\phi = 0$ volta ao primeiro. Use o **BIC**, que é consistente, junto com o **teste LR**, $2(\ell_1 - \ell_0) \sim \chi^2(1)$. Confira também se $\hat{\phi}$ e $\hat{\theta}$ não ficaram quase iguais, porque isso indica fator comum. Se o objetivo for prever, complemente com o RMSE fora da amostra (AU03).

Rubrica	Pontos
a)	0,3
b) 3 parâmetros com σ^2 e 13 perdidas	0,3
c) os quatro valores	0,4
c) FACP	0,2
d)	0,3

CAPÍTULO 52

Simulado 01: a correção da minha tentativa

Esta é a correção da tentativa de 01/11, feita à mão e corrigida pela rubrica do gabarito. Cada erro foi lançado no log. O objetivo não é a nota: é achar **a primeira linha** em que cada item desandou e a regra que impede o erro de voltar.

1. A nota pela rubrica: cerca de 1,6 de 10

Questão	O que foi feito	Pontos
Q1 (1,5)	a) e b) quase completos; c) com as contas certas e a classificação errada	**≈ 1,15**
Q2 (2,0)	a) raízes certas; b) travou na definição de γ_0; c) e d) em branco	≈ 0,3
Q3 (1,5)	a) chegou à forma pedida, mas sem derivar e sem a conclusão; b) e c) em branco	≈ 0,15
Q4 (1,5)	escolheu o modelo pelo $\ln L$, sem AIC nem BIC; b) em branco	0
Q5 (2,0) e Q6 (1,5)	em branco	0

A leitura que importa: mais da metade dos pontos perdidos era **conta curta que nem foi tentada**: AIC/BIC, $\hat{\phi} = 84/120$, previsões de um AR(1), contagem de parâmetros. É o mesmo padrão da P1 de Econometria I. O bloco 1, ao contrário, está seguro.

2. O que já está certo

- **Q1 a):**
  - a recursão até $y_t = y_0 + \sum_{i=1}^{t} u_i$;
  - $E(y_t) = y_0 = 2$, com a hipótese de RB citada;
  - $\text{Var}(y_t) = t\sigma^2$ pela soma dupla, separando $i = j$ de $i \neq j$;
  - $\text{Cov}(y_t, y_{t-k}) = (t-k)\sigma^2$ pelos choques comuns.
- **Q1 b):** a correlação $\sqrt{(t-k)/t}$ derivada passo a passo, e os valores 0,995 e 0,949.
- **Q1 c):** $\gamma_y(k) = 4\gamma_x(k) + \gamma_w(k)$ com os quatro termos da covariância, e os números 5,5; 1,0; 0,1; 0.
- **Q2 a):** as raízes 1,667 (AR) e 3,33 (MA), as duas fora do círculo: estacionário e invertível.

3. Os oito pontos de perda

1. **Q1 c): "ARMA(1,2)" no lugar de MA(2).** A FAC zera a partir da defasagem 3. Uma FAC que **corta** em q é de um MA(q); a parte AR faria a FAC decair, nunca zerar. *(conceito, T)*
2. **Q1 a) e b): faltou a frase de fecho.**
   - Em a): "a variância depende de t, logo **não é estacionário**" vale 0,1.
   - Em b): "a FAC amostral de um passeio **decai devagar, quase em linha reta**: sinal de raiz unitária" vale 0,2.

   A conta estava pronta. *(V)*
3. **Q1: o E desapareceu.** Escreveu-se $\text{Var}(y_t) = (y_t - \mu)^2$ e $\sum_{i \neq j} u_i u_j$. O certo é $\text{Var}(y_t) = E\big((y_t - \mu)^2\big)$ e $\sum_{i \neq j} E(u_i u_j) = 0$. Sem o E, a linha afirma algo falso. *(N)*

4. **Q2 b): "$\gamma_0 = \mathrm{Cov}(z_t, z_{t-1})$". Foi aqui que travou.**
   - $\gamma_0 = \mathrm{Var}(z_t) = E(z_t^2)$;
   - $\gamma_1 = \mathrm{Cov}(z_t, z_{t-1}) = E(z_t z_{t-1})$.

   Com a definição trocada, o roteiro do ARMA não tem por onde começar. *(N, E)*
5. **A variável do polinômio.** Escreveu-se $\phi(z_t) = 1 - 0{,}6z_t$ e $\theta(a_t) = 1 - 0{,}3\tilde{a}_t$. A raiz é de um **número**, não da série. Quando a série se chama z_t, use outra letra: $\phi(x) = 1 - 0{,}6x = 0 \Rightarrow x = 1{,}667$. *(N)*
6. **Q3 a): a passagem certa foi trocada pela do passeio.** "$y_t - y_{t-1} = \varepsilon_t$" vale para o passeio, não para $y_t = 0{,}5y_{t-1} + \varepsilon_t$. O certo:
   - $w_t = 0{,}5y_{t-1} + \varepsilon_t - y_{t-1} = -0{,}5y_{t-1} + \varepsilon_t$;
   - para chegar a $(1 - 0{,}5B)w_t = (1 - B)\varepsilon_t$, **multiplica-se** $(1 - 0{,}5B)y_t = \varepsilon_t$ **por** $(1 - B)$; a forma não deve ser copiada do enunciado;
   - "$\theta = 1$, em cima do círculo" estava no caminho, mas a conclusão que vale 0,3 é: "raiz $z = 1 \Longrightarrow$ **não invertível** $\Longrightarrow$ **sem AR(∞)**". *(A, V)*
7. **Q4: o modelo escolhido pelo** $\ln L$**.** O maior $\ln L$ é o **menos negativo**, −297,0 do AR(3), e mesmo assim não basta: é preciso penalizar. Com k contando σ^2:
   - o **AIC** escolhe o AR(3), com 602,0;
   - o **BIC** escolhe o **AR(1)**, com 613,0.

   O "AR(1)" escrito coincidiu com o BIC, mas pelo motivo errado. *(R, E)*
8. **Tempo e ordem.** Com uns 25 minutos de contas curtas no início, entravam:
   - Q4 b): $\hat{\phi} = 84/120 = 0{,}7$ e $\hat{\sigma}^2 = 0{,}712$;
   - Q5 b): as previsões do AR(1);
   - Q6 a)–b): o modelo e a contagem.

   São uns 3 pontos sem nenhuma demonstração nova. *(T)*

4. A destrava do ARMA: o roteiro de quatro movimentos

Serve para **qualquer** ARMA(1,1). No simulado, $z_t = 0{,}6z_{t-1} + a_t - 0{,}3a_{t-1}$, com $\sigma^2 = 1$, na convenção da lista.

(1)	$E(z_t a_t) = 0{,}6E(z_{t-1}a_t) + E(a_t^2) - 0{,}3E(a_{t-1}a_t) = 1$	[modelo × a_t; caus., RB]
(2)	$E(z_t a_{t-1}) = 0{,}6E(z_{t-1}a_{t-1}) + 0 - 0{,}3E(a_{t-1}^2) = 0{,}6 - 0{,}3 = 0{,}3$	[modelo × a_{t-1}; (1)]
(3)	$\gamma_0 = E(z_t z_t) = 0{,}6\gamma_1 + E(a_t z_t) - 0{,}3E(a_{t-1}z_t) = 0{,}6\gamma_1 + 1 - 0{,}09$	[modelo × z_t; (1), (2)]
(4)	$\gamma_1 = E(z_t z_{t-1}) = 0{,}6\gamma_0 + 0 - 0{,}3 \cdot 1 = 0{,}6\gamma_0 - 0{,}3$	[modelo × z_{t-1}; caus.]
(5)	$\gamma_0 = 0{,}6(0{,}6\gamma_0 - 0{,}3) + 0{,}91 = 0{,}36\gamma_0 + 0{,}73$	[(4) em (3)]
(6)	$\gamma_0 = \dfrac{0{,}73}{0{,}64} = 1{,}1406; \quad \gamma_1 = 0{,}3844; \quad \gamma_2 = 0{,}6\gamma_1 = 0{,}2306$	[isola; (4)]

Depois do sistema:

- $\rho_1 = \gamma_1/\gamma_0 = 0{,}337$ e $\rho_k = 0{,}6\,\rho_{k-1}$ para $k \geq 2$;
- $\psi_j = (\phi - \theta)\phi^{j-1}$: 0,3; 0,18; 0,108;
- $\pi_j = (\phi - \theta)\theta^{j-1}$: 0,3; 0,09; 0,027.

É a Q6 da lista com números. A folha à mão da Q6 é o mesmo roteiro, linha a linha, no sinal dos slides.

Para não travar de novo

Antes de qualquer conta de ARMA, escreva as três primeiras linhas no automático:

1. "$\gamma_0 = E(z_t^2)$, $\gamma_1 = E(z_t z_{t-1})$";
2. "momentos auxiliares: $\times a_t$ e $\times a_{t-1}$";
3. "$\times z_t$ e $\times z_{t-1}$".

O resto é álgebra de um sistema 2×2.

5. A regra de prova que muda a nota

1. **Leitura de 3 minutos**, marcando a convenção do MA, o T e o s.
2. **Contas curtas primeiro**, em uns 25 minutos:
   - AIC e BIC;
   - $\hat{\phi}$ e $\hat{\sigma}^2$;
   - raízes;
   - ψ e π por fórmula;
   - previsões de 1 a 3 passos;
   - observações perdidas e parâmetros.
3. **Derivações**, da mais curta para a mais longa.
4. **Fechar cada item** com a frase que o verbo pede: "logo, não é estacionário"; "logo, MA(2)"; "logo, não invertível, sem AR(∞)".

CAPÍTULO 53

Simulado 02 — gabarito

Enunciado em simulado_02.md. Números de prova.R. Erros vão para o log.

Questão 1 (1,5)

Origem na lista: (lista, Q4): o componente determinístico de Wold no item b) e a invertibilidade como escolha entre θ e $1/\theta$ no item c).

a) O processo harmônico é estacionário (0,4)

- $E(z_t) = \cos(\omega t)E(A) + \sin(\omega t)E(B) = 0$, para todo t.
- Como $\text{Cov}(A, B) = 0$ e $\text{Var}(A) = \text{Var}(B) = \sigma^2$:

$$\text{Cov}(z_t, z_{t-k}) = \sigma^2\big[\cos(\omega t)\cos(\omega(t-k)) + \sin(\omega t)\sin(\omega(t-k))\big] = \sigma^2\cos(\omega k),$$

pela identidade $\cos(x - y) = \cos x \cos y + \sin x \sin y$.

Conclusão: média constante e autocovariância que só depende de k: **estacionário de segunda ordem**. A variância é σ^2, finita.

b) Covariâncias e o componente determinístico (0,4)

Com $\omega = \pi/2$: $\text{Cov}(z_t, z_{t-1}) = \cos(\pi/2) = 0$ e $\text{Cov}(z_t, z_{t-2}) = \cos(\pi) = -1$. Uma simulação com 20 mil pares (A, B) dá $-0{,}9996$ para $z_7 z_5$, sem depender de t.

Por que é determinístico: duas observações bastam para resolver A e B e, daí em diante, **todo o futuro é previsto sem erro**. Não há choque novo: o erro de previsão um passo à frente é zero. No Teorema de Wold, $y_t = \sum_j \psi_j \varepsilon_{t-j} + V_t$, esse é o termo V_t, previsível linearmente a partir do passado remoto e não correlacionado com os ε. Um processo "puramente não determinístico" é aquele em que $V_t = 0$ (lista, Q4a; Hamilton, cap. 4).

c) Duas representações para a mesma FAC (0,7)

Convenção: sinal positivo, $\theta(L) = 1 + \theta L$.

- $x_t = a_t + 0{,}5a_{t-1}$, $\sigma^2 = 2$: $\gamma_0 = (1 + 0{,}25)\cdot 2 = 2{,}5$, $\gamma_1 = 0{,}5 \cdot 2 = 1$, $\rho_1 = 0{,}4$.
- $x_t^* = e_t + 2e_{t-1}$, $\sigma^2 = 0{,}5$: $\gamma_0 = (1 + 4)\cdot 0{,}5 = 2{,}5$, $\gamma_1 = 2 \cdot 0{,}5 = 1$.

Em geral, θ e $1/\theta$ dão o mesmo $\rho_1 = \theta/(1 + \theta^2)$. A raiz de $1 + 0{,}5z$ é $z = -2$, com módulo 2, fora do círculo. A de $1 + 2z$ tem módulo 0,5, dentro.

Escolha: o invertível, x_t. Só ele tem uma representação AR(∞) convergente, $a_t = \sum_j (-0{,}5)^j x_{t-j}$. Isso permite recuperar os choques a partir dos dados, o que é necessário para a verossimilhança e para a previsão. Fixar a invertibilidade é o que torna o MA **identificado** (lista, Q4c).

Rubrica	Pontos
a) média e Cov $= \sigma^2\cos(\omega k)$ com a identidade citada	0,3
a) conclusão	0,1

Rubrica	Pontos
b) os dois valores	0,1
b) previsível sem erro $\Rightarrow$ termo V_t de Wold	0,3
c) convenção declarada e as duas FAC	0,4
c) raízes, escolha do invertível e o porquê	0,3

Questão 2 (2,0)

Origem na lista: (lista, Q7), com a FACP e os pesos ψ do cap. 2.

a) Estacionariedade (0,4)

- Triângulo: $\phi_1 + \phi_2 = 0{,}8 < 1$; $\phi_2 - \phi_1 = -0{,}2 < 1$; $|\phi_2| = 0{,}3 < 1$. As três valem.
- Raízes de $1 - 0{,}5z - 0{,}3z^2 = 0$: $z = 1{,}1736$ e $z = -2{,}8403$, ambas fora do círculo unitário.

Conclusão: estacionário. Como as raízes são reais, não há ciclo: a FAC decai sem a forma de senoide amortecida.

b) Yule-Walker (0,5)

Multiplicando o modelo por y_{t-k}, $k \geq 1$, e dividindo por γ_0: $\rho_k = \phi_1\rho_{k-1} + \phi_2\rho_{k-2}$.

- $k = 1$: $\rho_1 = \phi_1 + \phi_2\rho_1 \Rightarrow \rho_1 = \frac{\phi_1}{1-\phi_2} = \frac{0{,}5}{0{,}7} = 0{,}7143$.
- $k = 2$: $\rho_2 = \phi_1\rho_1 + \phi_2 = 0{,}6571$.
- $k = 3$: $\rho_3 = \phi_1\rho_2 + \phi_2\rho_1 = 0{,}5429$.

c) Variância (0,4)

Multiplicando por y_t: $\gamma_0 = \phi_1\gamma_1 + \phi_2\gamma_2 + \sigma^2$, logo

$$\gamma_0 = \frac{\sigma^2}{1 - \phi_1\rho_1 - \phi_2\rho_2} = \frac{(1-\phi_2)\sigma^2}{(1+\phi_2)\big[(1-\phi_2)^2 - \phi_1^2\big]} = \frac{0{,}7}{1{,}3 \cdot 0{,}24} = 2{,}2436.$$

d) FACP (0,3)

$\phi_{11} = \rho_1 = 0{,}7143$; $\phi_{22} = \frac{\rho_2 - \rho_1^2}{1-\rho_1^2} = 0{,}3 = \phi_2$; $\phi_{33} = 0$. **A FACP de um AR(2) corta depois da defasagem 2**, e o último coeficiente não nulo é o próprio ϕ_2.

e) Pesos ψ (0,4)

$\psi_j = \phi_1\psi_{j-1} + \phi_2\psi_{j-2}$, com $\psi_0 = 1$ e $\psi_{-1} = 0$: $\psi_1 = 0{,}5$, $\psi_2 = 0{,}25 + 0{,}3 = 0{,}55$, $\psi_3 = 0{,}275 + 0{,}15 = 0{,}425$.

Rubrica	Pontos
a) desigualdades e raízes, com a conclusão	0,4
b) equação geral de YW	0,2
b) três valores	0,3
c) γ_0 com a fórmula escrita	0,4

Rubrica	Pontos
d)	0,3
e) recursão com $\psi_0 = 1$ e os três valores	0,4

Erro que custa ponto aqui

Escrever $\rho_2 = \phi_2$ ou $\phi_{22} = \rho_2$. Quem é igual a ϕ_2 é a **FACP** em 2, não a FAC.

Questão 3 (2,0)

Origem na lista: itens a) e b): (lista, Q11); itens c) e d): (lista, Q10).

a) SAR$(1)_4$ (0,7)

O modelo é um AR(1) em "anos": y_t só se liga a y_{t-4}, y_{t-8}, e assim por diante.

- $\gamma_0 = \sigma^2/(1-\Phi^2) = 1/0{,}64 = 1{,}5625$.
- $\rho_{4m} = \Phi^m$: $\rho_4 = 0{,}6$ e $\rho_8 = 0{,}36$.
- $\rho_k = 0$ fora dos múltiplos de 4, em particular $\rho_1 = \rho_3 = 0$. Multiplicando por y_{t-1}: $\gamma_1 = \Phi\gamma_3$ e $\gamma_3 = \Phi\gamma_1$, logo $\gamma_1(1-\Phi^2) = 0$.

A **FACP** tem um único pico, $\phi_{44} = 0{,}6$, e é zero no resto. É o AR(1) "esticado" de 1 para 4 (lista, Q11).

b) O AR(5) restrito (0,6)

$$(1-0{,}5B)(1-0{,}6B^4) = 1 - 0{,}5B - 0{,}6B^4 + 0{,}3B^5 \implies y_t = 0{,}5y_{t-1} + 0{,}6y_{t-4} - 0{,}3y_{t-5} + \varepsilon_t.$$

É um AR(5) com **três restrições**: $\phi_2 = \phi_3 = 0$ e $\phi_5 = -\phi_1\phi_4$, isto é, $-0{,}3 = -(0{,}5)(0{,}6)$. O AR(5) livre teria 5 coeficientes; o multiplicativo tem 2.

c) ARIMA(1,1,1) (0,4)

$(1-0{,}4B)(1-B) = 1 - 1{,}4B + 0{,}4B^2$, então

$$\boxed{y_t = 1{,}4y_{t-1} - 0{,}4y_{t-2} + a_t - 0{,}7a_{t-1}}$$

Os coeficientes AR somam 1: é a raiz unitária aparecendo na equação em nível.

d) A diferença é ARMA(1,1) (0,3)

$(1-0{,}4B)(1-B)y_t = (1-0{,}4B)w_t = (1-0{,}7B)a_t$. A raiz AR é 2,5 e a raiz MA é 1,4286, ambas fora do círculo: **estacionário e invertível**. O ARIMA(p,1,q) é, por definição, um ARMA(p,q) na diferença (lista, Q10a).

Rubrica	Pontos
a) γ_0, ρ_4, ρ_8	0,3
a) zeros fora dos múltiplos, com a justificativa	0,2
a) FACP	0,2
b) produto e equação	0,3
b) as três restrições	0,3

Rubrica	Pontos
c)	0,4
d)	0,3

Questão 4 (1,5)

Origem na lista: itens a) e b): (lista, Q14); item c): (lista, Q13).

a) Critérios (0,8)

$AIC = \frac{-2\ln L + 2k}{T}$ e $BIC = \frac{-2\ln L + k\ln T}{T}$ (AU02), com k incluindo σ^2.

Modelo	k	AIC (R)	BIC (R)	AIC/T	BIC/T
ARMA(1,1)	3	346,8	355,162	**2,890**	**2,960**
AR(2)	3	349,8	358,162	2,915	2,985
ARMA(2,1)	4	347,6	358,750	2,897	2,990

Os dois critérios escolhem o ARMA(1,1). Dividir por T não muda a ordenação; só muda a escala.

b) Razão de verossimilhança (0,4)

- H_0: ARMA(1,1), isto é, $\phi_2 = 0$; H_1: ARMA(2,1).
- $LR = 2(\ell_1 - \ell_0) = 2(-169{,}8 + 170{,}4) = 1{,}2 \sim \chi^2(1)$ sob H_0.
- $1{,}2 < 3{,}84$, com $p = 0{,}273$: **não se rejeita** H_0.
- **Conclusão:** o segundo coeficiente AR não melhora o ajuste o bastante, e fica o ARMA(1,1), em linha com o BIC.

c) Exata × condicional (0,3)

A exata acrescenta a densidade de $y_1 \sim N\big(0, \sigma^2/(1-\phi^2)\big)$:

$$\ell_{ex} = \ell_{cond} - \tfrac{1}{2}\ln(2\pi) - \tfrac{1}{2}\ln\frac{\sigma^2}{1-\phi^2} - \frac{(1-\phi^2)y_1^2}{2\sigma^2}.$$

Esse termo não é quadrático em ϕ, então a exata não tem forma fechada. Mas é **uma** parcela contra $T-1$: os dois estimadores são assintoticamente equivalentes (Hamilton, cap. 5).

Rubrica	Pontos
a) fórmulas da AU02 com k correto	0,2
a) números e escolha	0,6
b) quatro linhas do teste	0,4
c)	0,3

Questão 5 (1,5)

Origem na lista: (lista, Q15): item a) é o item (b)–(d) e item b) é o item (e).

a) ARMA(1,1) com sinal positivo (1,0)

Convenção: sinal positivo, $\theta = 0{,}4$ entra **somando**.

- $z_{T+1|T} = 0{,}5 z_T + 0{,}4\hat{a}_T = 1 + 0{,}4 = 1{,}4$.
- $z_{T+2|T} = 0{,}5 \cdot 1{,}4 = 0{,}7$ e $z_{T+3|T} = 0{,}35$: depois do primeiro passo, o MA some e a previsão decai como ϕ^{h-1}.
- $\psi_1 = \phi + \theta = 0{,}9$ e $\psi_2 = \phi\psi_1 = 0{,}45$. Na convenção BJ, seria $\phi - \theta$.
- $\mathrm{Var}(e_T(h)) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$: 1; 1,81; 2,0125.
- IC de 95% para $h = 2$: $0{,}7 \pm 1{,}96\sqrt{1{,}81} = 0{,}7 \pm 2{,}6369$, isto é, $[-1{,}9369;\ 3{,}3369]$.

b) ARIMA(0,1,1) e suavização exponencial (0,5)

Convenção: BJ, $\theta = 0{,}7$.

- $y_{T+1|T} = y_T - \theta\hat{a}_T = 50 - 1{,}4 = 48{,}6$.
- Para $h \geq 2$: $y_{T+h|T} = y_{T+h-1|T}$. **A previsão é 48,6 para todo** h.

Como $\hat{a}_T = y_T - y_{T|T-1}$:

$$y_{T+1|T} = (1-\theta)y_T + \theta\, y_{T|T-1} = \alpha y_T + (1-\alpha) y_{T|T-1}, \qquad \alpha = 1 - \theta = 0{,}3.$$

Iterando, os pesos das observações passadas são $\alpha(1-\alpha)^j$: 0,3; 0,21; e assim por diante. É a suavização exponencial simples (lista, Q15e).

Rubrica	Pontos
a) convenção declarada e três previsões	0,3
a) ψ_1, ψ_2 e variâncias	0,4
a) intervalo	0,3
b) previsão constante	0,2
b) forma de SES e $\alpha = 1 - \theta$	0,3

A troca de convenção é a armadilha da prova

Em 5a, $\psi_1 = \phi + \theta$; em 5b, a previsão leva $-\theta\hat{a}_T$. Quem resolve tudo na mesma convenção perde os dois itens. A lista faz isso de propósito na Q8.

Questão 6 (1,5)

Origem na lista: itens a) e b): (lista, Q16); itens c) e d): (lista, Q12), a previsão e o diagnóstico.

a) Modelo (0,4)

$$(1-\phi B)(1-B^{12})y_t = (1-\Theta B^{12})a_t \implies y_t = \phi y_{t-1} + y_{t-12} - \phi y_{t-13} + a_t - \Theta a_{t-12}.$$

b) Parâmetros e observações (0,2)

São ϕ, Θ e σ^2: 3 parâmetros. Perdem-se $sD = 12$ observações; sobram 132.

c) Previsões (0,4)

$$y_{T+1|T} = \phi y_T + y_{T-11} - \phi y_{T-12} - \Theta \hat{a}_{T-11},$$
$$y_{T+13|T} = \phi\, y_{T+12|T} + y_{T+1|T} - \phi y_T.$$

O termo MA usa resíduos até $\hat{a}_T$, o que vale para $h \leq 12$. Em $h = 13$, ele já envolve a_{T+1}, cuja esperança é zero. O padrão sazonal de cada mês é carregado pelo y_{T+h-12}, ou pela sua previsão.

d) Ljung-Box (0,5)

- H_0: $\rho_1 = \cdots = \rho_{24} = 0$ nos erros; H_1: alguma autocorrelação.
- $Q = T(T+2)\sum_{k=1}^{24} \hat{r}_k^2/(T-k) = 28{,}5 \sim \chi^2(\nu)$, com $\nu = K - p - q - P - Q = 24 - 1 - 0 - 0 - 1 = 22$.
- $28{,}5 < 33{,}92$, com $p = 0{,}160$: não se rejeita H_0.
- **Conclusão:** os resíduos não mostram autocorrelação até a defasagem 24, e o modelo capturou a dinâmica.

Rubrica	Pontos
a)	0,4
b)	0,2
c)	0,4
d) $\nu = 22$ descontando os parâmetros	0,2
d) decisão e conclusão	0,3

CAPÍTULO 54

Simulado 03 — gabarito

Enunciado em simulado_03.md. Números de prova.R. Erros vão para o log.

Questão 1 (1,5)

Origem na lista: (lista, Q2) e (lista, Q10): tendência determinística × estocástica e sobrediferenciação.

a) TS (0,4)

- $E(y_t) = 2 + 0{,}5t + E(u_t) = 2 + 0{,}5t$, porque u é um AR(1) estacionário de média zero. Logo $E(y_{10}) = 7$.
- $\text{Var}(y_t) = \text{Var}(u_t) = \sigma^2/(1 - 0{,}6^2) = 1{,}5625$, **constante**. A média tem tendência; a variância, não.

b) DS (0,3)

$z_t = 0{,}5t + \sum_{j=1}^{t} \varepsilon_j$, logo $E(z_t) = 0{,}5t$ e $\text{Var}(z_t) = t\sigma^2$: $\text{Var}(z_{10}) = 10$. A variância cresce com t.

c) Persistência do choque (0,3)

- Em y: $\partial y_{t+5}/\partial \varepsilon_t = \psi_5 = 0{,}6^5 = 0{,}0778$. O choque é **transitório** e morre geometricamente.
- Em z: $\partial z_{t+5}/\partial \varepsilon_t = 1$, e o mesmo vale para todo horizonte. O choque é **permanente**: é a raiz unitária (D03.1).

d) Diferenciar a TS (0,5)

$\Delta y_t = 0{,}5 + \Delta u_t$. Aplicando $(1 - 0{,}6B)$:

$$(1 - 0{,}6B)(\Delta y_t - 0{,}5) = (1 - B)\varepsilon_t,$$

um ARMA(1,1) com $\theta = 1$, cujo MA tem raiz sobre o círculo: **não invertível**. Pela fórmula da Q9, $\rho_1 = -(1 - \phi)/2 = -0{,}2$.

Como tirar a não estacionariedade:

- y (TS): regredir em 1 e t e modelar o resíduo u_t como AR(1). Diferenciar sobrediferencia.
- z (DS): diferenciar. Tirar a tendência por regressão deixa uma raiz unitária no resíduo, com risco de regressão espúria.

Na prática, quem decide qual é o caso é o ADF com tendência (Mattos; Enders, cap. 4; lista, Q10).

Rubrica	Pontos
a)	0,4
b)	0,3
c) os dois efeitos com a palavra transitório/permanente	0,3
d) forma ARMA e raiz unitária no MA	0,2
d) $\rho_1 = -0{,}2$	0,1
d) regra para cada série	0,2

Questão 2 (2,0)

Origem na lista: (lista, Q8), modelo (I), com o ARMA(1,1) da (lista, Q6).

Convenção: sinal positivo. Os momentos auxiliares, multiplicando o modelo por u_t e por u_{t-1}, são:

- $E(Y_t u_t) = \sigma^2$;
- $E(Y_t u_{t-1}) = \alpha\sigma^2 + \beta\sigma^2 = (\alpha+\beta)\sigma^2$.

Multiplicando por Y_t e por Y_{t-1}:

$$\gamma_0 = \alpha\gamma_1 + \sigma^2 + \beta(\alpha+\beta)\sigma^2, \qquad \gamma_1 = \alpha\gamma_0 + \beta\sigma^2.$$

1. Verdadeira. Substituindo γ_1 na primeira: $\gamma_0(1-\alpha^2) = \sigma^2(1 + \alpha\beta + \alpha\beta + \beta^2)$. Com os números, $\gamma_0 = 1{,}75/0{,}75 = 2{,}3333$.

2. Verdadeira.

$$\gamma_1 = \alpha\gamma_0 + \beta\sigma^2 = \frac{\alpha + 2\alpha^2\beta + \alpha\beta^2 + \beta - \alpha^2\beta}{1-\alpha^2}\sigma^2 = \frac{(1+\alpha\beta)(\alpha+\beta)}{1-\alpha^2}\sigma^2.$$

Com os números, $\gamma_1 = 1{,}25/0{,}75 = 1{,}6667$ e $\rho_1 = 0{,}7143$.

3. Verdadeira. Para $h \geq 2$, $E(u_t Y_{t-h}) = E(u_{t-1}Y_{t-h}) = 0$ *[causalidade]*, então $\gamma_h = \alpha\gamma_{h-1}$ e $\rho_2 = \alpha\rho_1 = 0{,}3571$.

4. Falsa. $\sigma^2/(1-\alpha^2) = 1{,}3333$ é a variância do AR(1) puro. O MA soma $(2\alpha\beta + \beta^2)\sigma^2/(1-\alpha^2)$, e o certo é 2,3333.

5. Falsa. $\pi(B) = \frac{1-\alpha B}{1+\beta B} = (1-\alpha B)\sum_j (-\beta)^j B^j$. Então $\pi_j = (\alpha+\beta)(-\beta)^{j-1}$, com **sinal alternado**: $\pi_1 = 1$, $\pi_2 = -0{,}5$, $\pi_3 = 0{,}25$. A expressão da afirmativa é a da convenção BJ com $\beta \to \theta$.

6. Falsa. A invertibilidade depende só do MA: exige $|\beta| < 1$, isto é, a raiz de $1 + \beta z$ fora do círculo. $|\alpha| < 1$ garante a **estacionariedade**.

Rubrica	Pontos
Momentos auxiliares e o sistema de γ_0, γ_1	0,4
Cada afirmativa julgada **com** a conta que a sustenta (6 × 0,25)	1,5
Conferência numérica	0,1

> **Erro que custa ponto aqui**
>
> "V" ou "F" sem demonstração vale zero. O enunciado manda demonstrar: a conclusão é a última linha, não a única. É a lição da Q5 da P1 de Econometria I, que parou antes de concluir.

Questão 3 (2,0)

Origem na lista: (lista, Q12).

a) Expansão (0,6)

$$(1-0{,}5B)(1-B) = 1-1{,}5B+0{,}5B^2,$$

$$(1-1{,}5B+0{,}5B^2)(1-B^4) = 1-1{,}5B+0{,}5B^2-B^4+1{,}5B^5-0{,}5B^6,$$

$$\boxed{y_t = 1{,}5y_{t-1}-0{,}5y_{t-2}+y_{t-4}-1{,}5y_{t-5}+0{,}5y_{t-6}+a_t-0{,}6a_{t-4}}$$

b) Observações perdidas (0,2)

$d + sD = 1 + 4 = 5$.

c) Previsões (1,0)

Regra: valor conhecido fica; y futuro vira a própria previsão; $E(a_{T+j} \mid \mathcal{F}_T) = 0$ para $j \geq 1$.

h	Conta	$y_{T+h\|T}$
1	$1{,}5(103)-0{,}5(107)+98-1{,}5(104)+0{,}5(100)-0{,}6(1{,}0)$	92,4
2	$1{,}5(92{,}4)-0{,}5(103)+101-1{,}5(98)+0{,}5(104)-0{,}6(-0{,}5)$	93,4
3	$1{,}5(93{,}4)-0{,}5(92{,}4)+107-1{,}5(101)+0{,}5(98)-0{,}6(0{,}8)$	97,92
4	$1{,}5(97{,}92)-0{,}5(93{,}4)+103-1{,}5(107)+0{,}5(101)-0{,}6(0{,}4)$	92,94
5	$1{,}5(92{,}94)-0{,}5(97{,}92)+92{,}4-1{,}5(103)+0{,}5(107)$	81,85

Leitura mais curta de $h = 1$: a previsão é $y_{T-3} + (y_T - y_{T-4}) + 0{,}5[(y_T - y_{T-4}) - (y_{T-1} - y_{T-5})] - 0{,}6\hat{a}_{T-3}$. Ou seja, o mesmo trimestre do ano anterior, mais a variação anual recente, mais a correção AR, menos o choque sazonal.

d) MA e longo prazo (0,2)

O termo $-0{,}6a_{T+h-4}$ usa resíduos observados só até $h = 4$. Em $h = 5$, ele é a_{T+1}, de esperança zero. Daí em diante, as previsões seguem a equação homogênea, cujas raízes são 1 (dupla), -1, $\pm i$ e 2: **tendência linear + padrão sazonal fixo de período 4 + termo $0{,}5^h$ que some** (lista, Q12c).

Rubrica	Pontos
a)	0,6
b)	0,2
c) regra da esperança condicional escrita	0,2
c) cinco previsões (0,16 cada)	0,8
d)	0,2

Ganhe tempo

Escreva a equação do item a) uma vez e, para cada h, só substitua. Errar $h = 1$ contamina os outros, mas a rubrica dá o ponto do método em cada linha.

Questão 4 (1,5)

Origem na lista: (lista, Q16), item (d), e (lista, Q14).

a) Parâmetros e observações (0,3)

- M1: ϕ, θ, Θ e σ^2, isto é, $k = 4$.
- M2: ϕ_1, ϕ_2, θ, Θ e σ^2, isto é, $k = 5$.
- Observações efetivas: $240 - (1 + 12) = 227$.

b) Critérios (0,6)

Modelo	AIC $= -2 \ln L + 2k$	BIC $= -2 \ln L + k \ln 227$
M1	**833,2**	**846,900**
M2	833,8	850,925

Os dois escolhem M1.

c) LR (0,4)

- H_0: $\phi_2 = 0$ (M1).
- $LR = 2(-411{,}9 + 412{,}6) = 1{,}4 \sim \chi^2(1)$.
- $1{,}4 < 3{,}84$, com $p = 0{,}237$: não se rejeita H_0.
- **Conclusão:** fica M1.

d) Recomendação (0,2)

O **BIC**, porque é consistente. Como os modelos são aninhados, o LR é a confirmação formal. Se o objetivo for prever, o AIC e o erro fora da amostra são os árbitros (lista, Q16d).

Rubrica	Pontos
a)	0,3
b)	0,6
c)	0,4
d)	0,2

Questão 5 (1,5)

Origem na lista: (lista, Q15), item (c), no caso MA(q).

a) Previsões (0,5)

Convenção: BJ, com $\theta(B) = 1 - \theta_1 B - \theta_2 B^2$, $\theta_1 = 0{,}5$ e $\theta_2 = -0{,}2$. É um MA(2), sempre estacionário. É invertível? As raízes de $1 - 0{,}5z + 0{,}2z^2$ são complexas, com módulo $\sqrt{1/0{,}2} = 2{,}2361 > 1$: sim.

- $y_{T+1|T} = 3 - 0{,}5(1) + 0{,}2(-2) = 2{,}1$.
- $y_{T+2|T} = 3 + 0{,}2(1) = 3{,}2$.
- $y_{T+3|T} = 3$.

b) Variâncias e intervalo (0,5)

$\psi_0 = 1$, $\psi_1 = -0{,}5$, $\psi_2 = 0{,}2$, e então:

- $\text{Var}(e_T(1)) = 1$;
- $\text{Var}(e_T(2)) = 1 + 0{,}25 = 1{,}25$;
- $\text{Var}(e_T(3)) = 1{,}25 + 0{,}04 = 1{,}29 = \gamma_0/\sigma^2$.

IC de 95% para $h = 3$: $3 \pm 1{,}96\sqrt{1{,}29} = 3 \pm 2{,}2261$.

c) A memória finita (0,5)

$y_{T+h} = \mu + a_{T+h} - \theta_1 a_{T+h-1} - \theta_2 a_{T+h-2}$. Para $h > 2$, todos os choques são **futuros**, com esperança condicional zero. Logo:

- $y_{T+h|T} = \mu$;
- $e_T(h) = y_{T+h} - \mu$, cuja variância é $\text{Var}(y_t) = \gamma_0$.

Conclusão: um MA(q) só "lembra" q períodos. Além disso, a melhor previsão é a média incondicional, e o intervalo tem a largura da distribuição marginal.

Rubrica	Pontos
a) convenção e três previsões	0,5
b) variâncias com $\psi_0 = 1$ e intervalo	0,5
c) argumento e conclusão	0,5

Questão 6 (1,5)

Origem na lista: (lista, Q16), item (c), lido ao contrário: da FAC amostral para o modelo.

a) Banda (0,3)

Com 227 observações efetivas, a banda é $\pm 2/\sqrt{227} = \pm 0{,}1327$ (com 1,96, $\pm 0{,}1301$).

- **FAC** significativa nas defasagens 1, 11, 12 e 13.
- **FACP** significativa nas defasagens 1, 2, 12, 13 e 24, decaindo.

b) O modelo (0,6)

FAC cortando em 1 e em 12, com os "satélites" 11 e 13, e FACP decaindo: **SARIMA**$(0,1,1)(0,1,1)_{12}$, o modelo das companhias aéreas. Com $\theta = \Theta = 0{,}5$:

- $\rho_1 = -\theta/(1+\theta^2) = -0{,}4$;
- $\rho_{12} = -0{,}4$;
- $\rho_{11} = \rho_{13} = \theta\Theta/[(1+\theta^2)(1+\Theta^2)] = 0{,}16$;
- zero nas demais.

Os valores amostrais $-0{,}41$, $-0{,}39$, 0,17 e 0,15 batem.

c) Ljung-Box (0,4)

- $\nu = 24 - 0 - 1 - 0 - 1 = 22$.
- $Q = 30{,}1 < 33{,}92$, com $p = 0{,}116$: não se rejeita H_0 de ausência de autocorrelação.
- **Conclusão:** os resíduos se comportam como ruído branco até a defasagem 24.

d) Pico em 12 nos resíduos (0,2)

A parte **sazonal** está mal especificada: falta um termo em B^{12}, ou o Θ estimado está errado. Se $\widehat{\Theta} \approx 1$, há **sobrediferenciação sazonal**: a sazonalidade é determinística, e o melhor é usar dummies mensais com $D = 0$ (módulo 03, Q12d).

Rubrica	Pontos
a)	0,3
b) modelo	0,2
b) quatro valores teóricos e comparação	0,4
c)	0,4
d)	0,2

CAPÍTULO 55

Log de erros

Toda questão errada, incompleta ou resolvida acima do tempo-alvo entra aqui **no mesmo dia**, venha ela de um simulado, do banco ou da lista. A revisão segue o espaçamento +1, +3 e +7 dias: refaça a questão do zero, sem olhar a resolução, e anote a data em que acertou.

Como preencher

Uma linha por erro, não por questão: se uma derivação teve dois erros (esqueceu a hipótese e trocou o sinal), são duas linhas. A coluna "ação" diz o que muda no próximo treino. "Estudar mais" não vale.

Códigos

Os mesmos do log de Econometria I, para comparar as duas disciplinas.

Coluna	Valores
tipo (T)	**D** derivação · **C** cálculo · **T** conceitual · **V/F** julgamento
causa (C)	**H** hipótese não citada · **A** álgebra ou sinal · **N** notação ou convenção do MA · **L** leitura do enunciado (s, T, convenção) · **R** regra de decisão invertida · **V** conclusão sem interpretação · **E** esquecimento do resultado · **T** tempo
revisão	data da revisão; `ok` quando acertou sem consulta; `x` quando errou de novo (volta para +1)

Herança da P1 de Econometria I (09/10/2026)

Os seis erros da P1 de Econometria I, com a ação traduzida para séries temporais. Eles **não** se refazem como questões de Econometria I: a coluna "treino aqui" diz qual item desta prova exercita o mesmo músculo.

questão (Econ. I)	erro	C	treino aqui	ação
P1, Q1	$\mathbf{X}'\mathbf{X}$, inversa e $\hat{\beta}$ em branco	T	S1 Q4b; banco Q14	fazer os itens de conta antes das demonstrações; cronometrar 5 min
P1, Q2d	efeito marginal sem o termo $2\beta_3 EXP$	A	S1 Q1c ($4\gamma_x$); S2 Q5a ($\psi_1 = \phi + \theta$)	escrever a fórmula geral e a convenção antes dos números
P1, Q3c	rejeitou H_0 sem calcular F	E	S2 Q4b (LR); S2 Q6d (Ljung-Box)	teste em quatro linhas, com a estatística calculada
P1, Q4a	plim em branco	E	S1 Q2b (momentos auxiliares do ARMA)	refazer D02.2 de cabeça até sair em 8 min
P1, Q5	Gauss-Markov sem a conclusão "semidefinida positiva"	E	S1 Q3a (raiz $\Rightarrow$ não invertível $\Rightarrow$ sem AR(∞)); S1 Q5a	reler o verbo e fechar com a frase pedida
P1, Q6	FWL incompleto	E	S3 Q3 (previsão em cadeia)	escrever a equação expandida uma vez e só substituir

Registro

data	questão	T/C	erro	ação	revisões (+1 · +3 · +7)
01/11	S1 Q1c	T/E	classificou como ARMA(1,2) uma FAC que corta em 2	FAC que corta em $q \Rightarrow$ MA(q); AR nunca zera a FAC	03/11 · 04/11
01/11	S1 Q1a, b	T/V	sem a frase de fecho (não estacionário; FAC que decai devagar)	fechar todo item com a frase do verbo	03/11 · 04/11
01/11	S1 Q1a	D/N	Var $= (y_t - \mu)^2$ sem o E	escrever $E(\cdot)$ em toda linha de momento	03/11 · 04/11
01/11	S1 Q2b	D/N	$\gamma_0 = \text{Cov}(z_t, z_{t-1})$: definição trocada, e travou	$\gamma_0 = E(z_t^2)$, $\gamma_1 = E(z_t z_{t-1})$; roteiro de quatro movimentos	03/11 · 04/11
01/11	S1 Q2a, Q3a	C/N	raiz do polinômio escrita com a série ($\phi(z_t)$)	variável do polinômio é um número: $\phi(x) = 0$	03/11 · 04/11
01/11	S1 Q3a	D/A	$y_t - y_{t-1} = \varepsilon_t$ (do passeio) e forma copiada do enunciado	derivar: multiplicar $(1 - 0{,}5B)y_t = \varepsilon_t$ por $(1 - B)$	03/11 · 04/11
01/11	S1 Q4a	C/R	modelo escolhido pelo ln L, sem AIC nem BIC	AIC e BIC com k incluindo σ^2; menor vence	03/11 · 04/11
01/11	S1 Q4b, Q5, Q6	C/T	contas curtas em branco (cerca de 3 pontos)	25 minutos de contas curtas antes das derivações	03/11 · 04/11

Placar por causa

Atualize depois de cada simulado. A causa com mais linhas vira o foco do treino seguinte.

causa	S1 (01/11)	S2 (02/11)	S3 (03/11)
H hipótese	0		
A álgebra ou sinal	1		
N notação ou convenção	3		
L leitura	0		
R regra de decisão	1		
V conclusão	1		
E esquecimento	1		
T tempo	1		

Parte X

Consulta rápida

CAPÍTULO 56

Formulário

O MA está na convenção **Box-Jenkins**, $\theta(B) = 1 - \theta_1 B - \cdots$, salvo indicação. Para a convenção de sinal positivo dos slides, troque $\theta \to -\theta$. Ver CONVENCOES §2.

Processos de referência

Processo	$E(y_t)$	$\mathrm{Var}(y_t)$	$\mathrm{Cov}(y_t, y_{t-k})$
RB$(0, \sigma^2)$	0	σ^2	0
Passeio aleatório, y_0 fixo	y_0	$t\sigma^2$	$(t-k)\sigma^2$
Passeio com drift c	$y_0 + ct$	$t\sigma^2$	$(t-k)\sigma^2$
Drift e tendência δt	$y_0 + ct + \delta t(t+1)/2$	$t\sigma^2$	$(t-k)\sigma^2$
Processo linear $\sum \psi_j \varepsilon_{t-j}$	μ	$\sigma^2 \sum \psi_j^2$	$\sigma^2 \sum_j \psi_j \psi_{j+k}$

AR, MA e ARMA

Modelo	γ_0	FAC	FACP
AR(1)	$\sigma^2/(1-\phi^2)$	$\rho_k = \phi^k$	$\phi_{11} = \phi$; zero depois
AR(2)	$\dfrac{(1-\phi_2)\sigma^2}{(1+\phi_2)[(1-\phi_2)^2 - \phi_1^2]}$	$\rho_1 = \frac{\phi_1}{1-\phi_2}$, $\rho_2 = \phi_1\rho_1 + \phi_2$	corta após 2
MA(1)	$(1+\theta^2)\sigma^2$	$\rho_1 = -\theta/(1+\theta^2)$; zero depois	decai
MA(q), sinal positivo	$\sigma^2 \sum_{j=0}^{q} \theta_j^2$	$\gamma_k = \sigma^2 \sum_{j=0}^{q-k} \theta_j \theta_{j+k}$; corta em q	decai
ARMA(1,1)	$\frac{1+\theta^2-2\phi\theta}{1-\phi^2}\sigma^2$	$\rho_1 = \frac{(1-\phi\theta)(\phi-\theta)}{1+\theta^2-2\phi\theta}$, $\rho_k = \phi^{k-1}\rho_1$	decai

- **Pesos do ARMA(1,1):** $\psi_j = (\phi - \theta)\phi^{j-1}$ e $\pi_j = (\phi - \theta)\theta^{j-1}$.
- **Yule-Walker:** $\rho_k = \sum_i \phi_i \rho_{k-i}$ para $k \geq 1$, e $\gamma_0 = \sigma^2/(1 - \sum_i \phi_i \rho_i)$.
- **FACP:** $\phi_{11} = \rho_1$ e $\phi_{22} = (\rho_2 - \rho_1^2)/(1 - \rho_1^2)$.
- **Estacionariedade e invertibilidade:** as raízes de $\phi(z)$ e de $\theta(z)$ devem ficar fora do círculo unitário.
- **AR(2):** $\phi_1 + \phi_2 < 1$, $\phi_2 - \phi_1 < 1$ e $|\phi_2| < 1$.
- **MA(1):** $|\rho_1| \leq \frac{1}{2}$.
- **Média e constante:** $c = (1 - \sum \phi_i)\mu$.
- **Equação de diferenças (D02.4):** $y_{t+1} + a y_t = c$ dá $y_t = (y_0 - \frac{c}{1+a})(-a)^t + \frac{c}{1+a}$, estável se $|a| < 1$. No AR(2), raízes características complexas dão um ciclo de período $2\pi/\omega$, com $\cos\omega = \phi_1/(2\sqrt{-\phi_2})$.
- **Banda da FAC (D02.5):** $\pm 1{,}96/\sqrt{T}$ vale para ruído branco. Num MA(q) e $k > q$, use $\mathrm{Var}(\hat{\rho}_k) \approx (1 + 2\sum_{j \leq q} \rho_j^2)/T$.

Integração e sazonalidade

- **Sobrediferenciação:** se $\phi(B)y_t = \theta(B)\varepsilon_t$, então $\phi(B)\Delta y_t = (1-B)\theta(B)\varepsilon_t$, e o MA fica não invertível. Se y é RB, $\rho_1(\Delta y) = -1/2$.
- **TS diferenciada:** $y_t = \alpha + \beta t + u_t$ dá $\Delta y_t = \beta + u_t - u_{t-1}$.
- **SAR(1)$_s$:** $\gamma_{ms} = \Phi^m\sigma^2/(1-\Phi^2)$ e zero fora dos múltiplos de s. A FACP tem um pico, em s.
- **Multiplicativo:** $(1-\phi B)(1-\Phi B^s) = 1 - \phi B - \Phi B^s + \phi\Phi B^{s+1}$.
- **Observações perdidas** com $(1-B)^d(1-B^s)^D$: $d + sD$.

Raiz unitária

- **ADF:** $\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum \delta_i \Delta y_{t-i} + e_t$, com $H_0 : \gamma = 0$.
- **Críticos assintóticos de 5%:** −1,95 sem determinísticos, −2,86 com constante e −3,41 com constante e tendência.
- **KPSS:** H_0 é estacionariedade.
- **Poder (D03.3):** com $\phi = 0{,}95$ e $T = 100$, o DF rejeita só uma vez em oito. Não rejeitar não é aceitar a raiz unitária: cruze com o KPSS.
- **Quebra de nível (D03.4):** ignorada, ela empurra o ADF para "raiz unitária". Com a data conhecida, ponha a dummy na regressão e use o crítico próprio.

Estimação e seleção

- **AR(1), MV condicional:** $\hat\phi = \sum y_t y_{t-1} / \sum y_{t-1}^2$, que é o MQO. Assintoticamente, $\mathrm{Var}(\hat\phi) \approx (1-\phi^2)/T$.
- **Critérios no R:** $AIC = -2\ln L + 2k$ e $BIC = -2\ln L + k\ln T$.
- **Critérios na AU02:** os mesmos divididos por T.
- **Contagem de k:** ARMA(p,q) com média tem $k = p + q + 1$, mais σ^2 se a questão contar a variância.

Diagnóstico (AU03)

Teste	H_0	Estatística	Distribuição
Ljung-Box	$\rho_1 = \cdots = \rho_K = 0$	$T(T+2)\sum_{i=1}^{K} \hat\rho_i^2/(T-i)$	χ^2_{K-p-q} (resíduos)
Jarque-Bera	$S = 0$ e $K = 3$	$\frac{T}{6}\hat S^2 + \frac{T}{24}(\widehat K - 3)^2$	χ^2_2
ARCH-LM	$\alpha_1 = \cdots = \alpha_p = 0$	nR^2 de $\hat\varepsilon_t^2$ em p defasagens	χ^2_p
Breusch-Godfrey	sem autocorrelação até m	nR^2 da auxiliar	χ^2_m
Chow (data a priori)	coeficientes iguais	F	$F(k, T-2k)$
Diebold-Mariano	$E(d_t) = 0$	$\bar d/\sqrt{\hat V(\bar d)}$	$N(0,1)$

Previsão

- **Previsor ótimo:** $y_{T+h|T} = E(y_{T+h} \mid \mathcal{F}_T)$.
- **Erro e sua variância:** $e_T(h) = \sum_{j=0}^{h-1} \psi_j a_{T+h-j}$ e $\mathrm{Var} = \sigma^2 \sum_{j<h} \psi_j^2 \to \gamma_0$.
- **ARMA(1,1):** $y_{T+1|T} = \phi y_T - \theta a_T$ e $y_{T+h|T} = \phi^{h-1} y_{T+1|T}$.
- **ARIMA(0,1,1) = SES:** $y_{T+1|T} = (1-\theta)y_T + \theta y_{T|T-1}$, com $\alpha = 1-\theta$.

- **MASE:** $\frac{1}{n}\sum|e_t|/Q$, com $Q = \frac{1}{T_{tr}-m}\sum|y_t - y_{t-m}|$.
- **Winkler:** $W = (u-\ell) + \frac{2}{\alpha}(\ell - y)\mathbf{1}\{y < \ell\} + \frac{2}{\alpha}(y-u)\mathbf{1}\{y > u\}$.
- **CRPS da normal (D05.2):** $\sigma\left[z(2\Phi(z)-1) + 2\varphi(z) - 1/\sqrt{\pi}\right]$, com $z = (y-\mu)/\sigma$; com $\sigma \to 0$, vira $|y-\mu|$.
- **Christoffersen:** $\mathrm{LR}_{cc} = \mathrm{LR}_{uc} + \mathrm{LR}_{ind} \sim \chi^2_2$. A taxa de violações certa não basta: elas também têm de ser independentes.

Regressão dinâmica (AU06)

- **Exogeneidade:** contemporânea, $E(\varepsilon_t \mid x_t) = 0$; predeterminação, $E(x_s\varepsilon_t) = 0$ para $s \le t$; estrita, $E(\varepsilon_t \mid x_1, \dots, x_T) = 0$. Sem a estrita, o MQO é viesado mas consistente; sem a contemporânea, inconsistente.
- **DL(q):** o choque temporário dá $\partial y_{t+k}/\partial x_t = \beta_k$; o permanente acumula até $\beta(1) = \sum_j \beta_j$.
- **ARDL(p,q):** os multiplicadores seguem $m_k = \beta_k + \sum_i \phi_i m_{k-i}$. No ARDL(1,1), $m_0 = \beta_0$ e $m_k = \phi_1^{k-1}(\phi_1\beta_0 + \beta_1)$.
- **Longo prazo:** $\theta = \beta(1)/\lambda(1) = \sum_j \beta_j/(1 - \sum_i \phi_i)$, com erro padrão pelo método delta.
- **Omitir** y_{t-1}, com x AR(1) de parâmetro ρ: plim $\hat{\beta}_0 = \beta_0/(1-\phi_1\rho)$.
- **ECM do ARDL(1,1):** $\Delta y_t = \phi_0 + \beta_0\Delta x_t + \alpha(y_{t-1} - \theta x_{t-1}) + \varepsilon_t$, com $\alpha = \phi_1 - 1$. A meia-vida é $\ln 0{,}5/\ln\phi_1$.
- **Granger:** F de exclusão de $x_{t-1}, \dots, x_{t-p}$ na equação de y, sem x_t. Teste nas duas direções. *Feedback* $x_t = g x_{t-1} + \gamma y_{t-1} + v_t$ implica $E(\varepsilon_t x_{t+1}) = \gamma\sigma^2_\varepsilon$.
- **Diagnóstico:** Breusch-Godfrey, não Durbin-Watson, quando y_{t-1} é regressor. Resíduo autocorrelacionado pede mais defasagens, não HAC.