Séries temporais

Volume 4

Lista 01: guia de estudo e laboratório, o INPC passo a passo

Caderno de estudo · parte 1: ARMA, ARIMA e SARIMA

Prof. Guilherme Pereira · Econometria II (PPGEco/UFES)

Gerado em 26/10/2026 a partir de `github.com/fcarva/series-temporais` (commit `62d9421`). Material autoral: enunciados parafraseados, demonstrações próprias, números conferidos em R contra os scripts do repositório.

Sumário

I Guia de estudo: o que estou fazendo e por quê **1**

1 Guia de estudo da Lista 01: o que estou fazendo e por quê **2**

II Lista 01: o que foi feito **26**

2 Lista 01: o código completo, questão por questão **27**

III Laboratório Box-Jenkins **31**

3 Lista 01 — Box-Jenkins do INPC, passo a passo em R **32**

Parte I

Guia de estudo: o que estou fazendo e por quê

CAPÍTULO 1

Guia de estudo da Lista 01: o que estou fazendo e por quê

Este guia acompanha o script lista01_inpc.R passo a passo. A série é o **INPC mensal de jan/2013 a set/2026, 165 observações**. Para cada etapa da Lista 01, o guia diz:

- **o que** estou tentando descobrir;
- **por que** este teste, e não outro;
- **como** o teste funciona por dentro;
- **o que** o INPC respondeu;
- **o que** costuma cair na prova.

O guia foi feito para ler antes de rodar o código e para revisar antes da prova. Cada número citado sai do R (`lista01/guia_numeros.R`) e é conferido pelo build. As demonstrações completas estão nos módulos da lista teórica, indicados em cada seção.

Como usar

1. Leia a seção 0 inteira: ela dá o mapa.
2. Para cada questão, leia a seção aqui, rode o bloco correspondente no RStudio e confira se o número na tela bate com o do texto.
3. Termine com as perguntas de prova e tente responder sem olhar.

0. O mapa: o que a Lista 01 inteira está fazendo

O objetivo é construir um modelo para o INPC mensal que sirva para **prever**, e provar que ele é bom. A ferramenta é o ciclo de **Box-Jenkins**, que tem quatro fases:

1. **Transformar e tornar a série estacionária** (Q1 e Q2). Os modelos ARMA só valem para séries estacionárias. Primeiro se descobre o que é preciso fazer com a série (log? diferença? diferença sazonal?) para chegar lá.
2. **Identificar** (Q3). Olhando a FAC e a FACP da série estacionária, propõem-se alguns modelos candidatos.
3. **Estimar e escolher** (Q4). Os candidatos são estimados por máxima verossimilhança e comparados por AIC e BIC.
4. **Diagnosticar** (Q5 e Q6). Se o modelo está certo, o que sobra (os resíduos) é ruído branco. Se não for, volta-se à fase 2.

Depois do ciclo vem a **prova final** (Q7): o modelo prevê melhor, fora da amostra, do que regras ingênuas que não exigem econometria nenhuma?

Questão	Pergunta que estou respondendo	Ferramenta	O INPC respondeu
Q1	Como é a série? Preciso transformá-la?	gráficos, médias anuais e mensais	tendência, sazonalidade, outliers; usar log
Q2	Quantas diferenças (d) e diferenças sazonais (D)?	ADF (três versões e com dummies sazonais), PP, KPSS, DF-GLS	$d = 1$, $D = 0$: processo DS (passeio com drift)
Q3	Que estrutura ARMA tem a série diferenciada?	FAC e FACP	AR(1), talvez AR(2), e algo sazonal em 12; três candidatos

Questão	Pergunta que estou respondendo	Ferramenta	O INPC respondeu
Q4	Qual candidato é o melhor?	MV exata, AIC, BIC, raízes	AIC e BIC discordam por pouco; fica C1, o mais simples
Q5	O que sobrou é ruído branco? Os parâmetros são estáveis?	Ljung-Box, Jarque-Bera, ARCH-LM, Chow, CUSUM, sobreajuste	sim, exceto a normalidade
Q6	O que acontece se eu diferenciar demais?	o modelo com $d = 2$	o MA vai para a raiz unitária
Q7	O modelo prevê bem?	24 meses fora da amostra, RMSE/MAE/MAPE	bate o passeio aleatório e o sazonal ingênuo
Q8	Teoria, à mão	lista teórica	ver 02_lista e 03_lista

Os quatro conceitos que sustentam tudo

Quase toda pergunta de prova volta a um destes quatro conceitos.

1. Estacionariedade (fraca). Uma série é estacionária quando a média, a variância e as autocovariâncias não dependem do tempo:

$$E(y_t) = \mu, \qquad \mathrm{Var}(y_t) = \gamma_0, \qquad \mathrm{Cov}(y_t, y_{t-k}) = \gamma_k \quad \text{para todo } t.$$

Por que importa. Para estimar μ ou γ_k com uma única trajetória, é preciso que a série "se repita" ao longo do tempo. Se a média muda com t, cada observação vem de uma distribuição diferente, e a média amostral não estima nada.

2. Ruído branco. Uma sequência $a_t \sim RB(0, \sigma^2)$ tem média zero, variância constante e **nenhuma** autocorrelação. É o "imprevisível puro": o que um bom modelo deixa como resíduo.

3. O operador defasagem B**.** Por definição, $By_t = y_{t-1}$ e $B^k y_t = y_{t-k}$. Com ele, um AR(1) $y_t = \phi y_{t-1} + a_t$ vira $(1 - \phi B)y_t = a_t$. A diferença é $\Delta = 1 - B$, e a diferença sazonal é $\Delta_{12} = 1 - B^{12}$.

4. Raiz unitária. No AR(1), a raiz do polinômio $1 - \phi z = 0$ é $z = 1/\phi$:

- se $|\phi| < 1$, a raiz fica fora do círculo unitário e a série é estacionária: um choque morre como ϕ^k;
- se $\phi = 1$, a raiz é $z = 1$, a **raiz unitária**: $y_t = y_{t-1} + a_t$ é o passeio aleatório, e um choque **nunca morre**.

O passeio aleatório tem $\mathrm{Var}(y_t) = t\sigma^2$, que cresce com o tempo: não é estacionário. Mas sua diferença $\Delta y_t = a_t$ é. Uma série que fica estacionária depois de d diferenças é **integrada de ordem** d, $I(d)$.

> **A frase-resumo da Lista 01**
>
> O log do INPC é um processo **diferença estacionária**: tem tendência determinística (o drift, a inflação média) e tendência estocástica (a soma dos choques). Na definição ampla, é $I(1)$. A inflação mensal Δy_t é $I(0)$: estacionária em torno de uma média positiva, sem tendência nenhuma. Por isso o modelo é um ARIMA com $d = 1$ e constante para o log, o que é o mesmo que um ARMA com média para a inflação.

1. Q1: olhar a série antes de testar qualquer coisa

O que estou fazendo

Antes de qualquer teste, faço gráficos da série em três formas: o índice P_t, o log $y_t = 100 \ln P_t$ e a diferença Δy_t.

Por quê

Os testes respondem perguntas estreitas ("há raiz unitária?"), mas é o gráfico que diz **quais perguntas fazer**. Ele mostra:

- se há tendência, e se ela é linear ou exponencial;
- se há sazonalidade;
- se há quebras ou outliers, que podem enganar os testes depois;
- se a variabilidade cresce com o nível, o que pede uma transformação.

Por que $100 \ln P_t$

São três motivos, e vale saber os três.

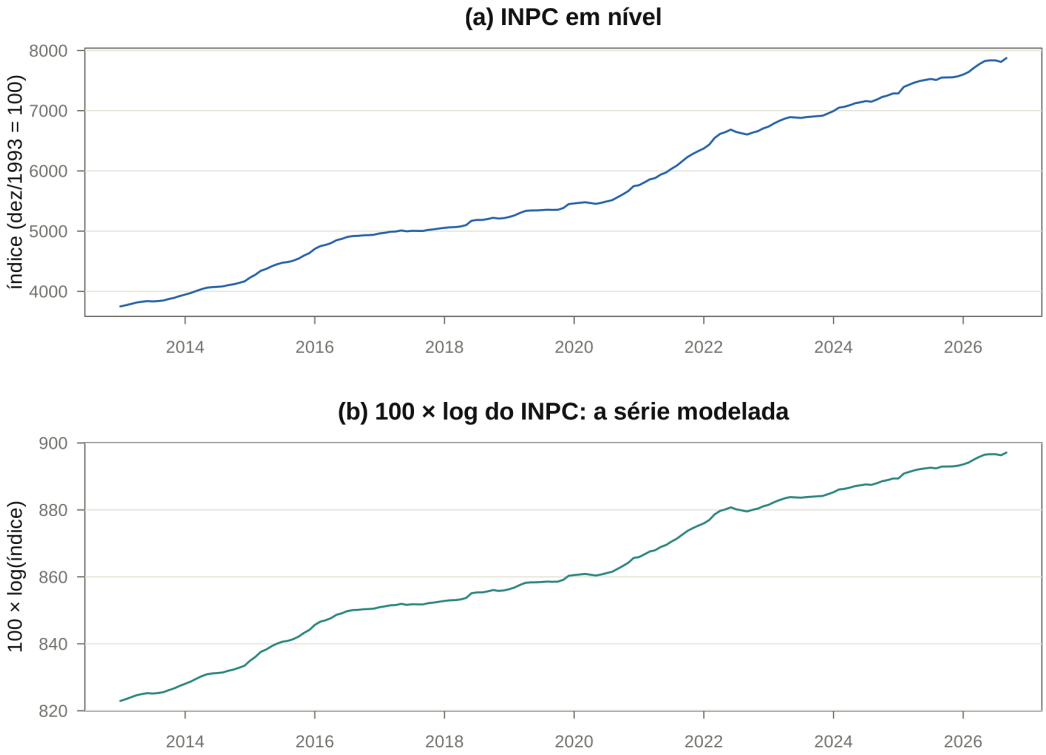
1. **O log estabiliza a variância.** Um índice de preços cresce de forma exponencial: um choque de 1% move o índice em 37 pontos quando ele vale 3.700 e em 79 pontos quando vale 7.900. Em log, os dois choques têm o mesmo tamanho.
2. **O log lineariza a tendência.** Se $P_t = P_0(1+\pi)^t$, então $\ln P_t = \ln P_0 + t\ln(1+\pi)$, que é uma reta.
3. **A diferença do log é a taxa de inflação.** Como $\ln(1+x) \approx x$ para x pequeno:

$$\Delta y_t = 100(\ln P_t - \ln P_{t-1}) = 100 \ln \frac{P_t}{P_{t-1}} \approx 100\,\frac{P_t - P_{t-1}}{P_{t-1}}.$$

Logo Δy_t é a inflação mensal em pontos percentuais. O fator 100 só muda a escala, para os números ficarem legíveis.

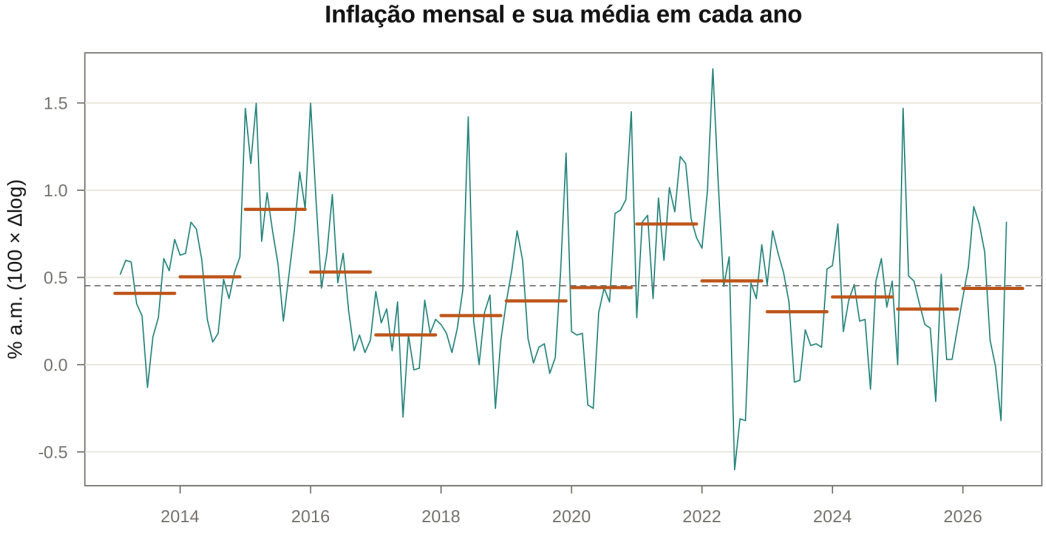
O gráfico não decide sozinho; a interpretação decide

O motivo 1 se confere no gráfico: se a amplitude de cada ano cresce com o nível, o log é necessário. Nesta janela, a relação é fraca, porque em 13 anos o índice só dobra (de 3.749 para 7.874) e a amplitude anual depende mais dos choques de cada ano do que do nível. Quem decide é o **motivo 3**. Com o log, o drift do modelo é a inflação média, uma *taxa* que pode ser constante. Sem o log, o drift seria um aumento médio em pontos de índice, que não pode ser constante: o mesmo 0,5% ao mês vale 19 pontos em 2013 e 39 pontos em 2026.



O que o INPC mostrou

- **Tendência** forte no índice; em log, quase uma reta. A inclinação do log é a inflação, e ela muda de patamar. A média anual da inflação vai de 0,17% a.m. (2017) a 0,89% a.m. (2015): alta em 2015–2016 e no pós-pandemia (2021–2022), baixa em 2017–2019. A Q5 testa se essas mudanças quebram os parâmetros do modelo (Chow e CUSUM, aula 03): não quebram.
- **Sazonalidade** invisível no índice, mas presente na inflação mensal: fevereiro, março e dezembro altos, agosto baixo.
- **Outliers** na inflação: os maiores valores são mar/2022, jan/2016, mar/2015 e fev/2025, e o menor é jul/2022 (corte de impostos sobre combustíveis). Os choques que o modelo não explica, jun/2018 (greve dos caminhoneiros), jul/2022 e fev/2025 (fim do bônus de Itaipu na conta de luz), aparecem depois nos resíduos padronizados (Q5).



A figura, da versão completa do código, mostra a inflação mensal com a média de cada ano.

> **Na prova**
>
> Se perguntarem "por que usar log", não basta "para estabilizar a variância". Diga também que a diferença do log é a taxa de crescimento, o que dá ao modelo uma interpretação econômica direta. Quando o gráfico é ambíguo, como aqui, é esse argumento que decide.

2. Q2: quantas diferenças? (raiz unitária)

O que estou fazendo

Estou decidindo d (o número de diferenças regulares) e D (o número de diferenças sazonais) para tornar a série estacionária.

Por quê: a pergunta de fundo é DS ou TS

Uma série que sobe ao longo do tempo pode ter dois tipos de tendência, e eles pedem tratamentos opostos:

	Tendência estacionária (TS)	Diferença estacionária (DS)
Modelo	$y_t = \alpha + \beta t + u_t$, u_t estacionário	$y_t = \beta + y_{t-1} + u_t$ (passeio com drift)
Tendências que contém	só determinística	determinística (βt) **e** estocástica ($\sum u_j$)
Um choque hoje	passa: a série volta para a reta	é permanente: muda o nível para sempre
Variância de y_t	constante	cresce com t
Como estacionarizar	tirar a tendência (regredir em t)	diferenciar
Errar para o outro lado	diferenciar uma TS cria um MA não invertível	tirar a tendência de uma DS deixa uma raiz unitária no resíduo

Os quatro processos (MATTOS, 2019, seção 1.11)

A tabela acima é um resumo. O texto de Mattos (MAT), da bibliografia do curso, organiza tudo em quatro processos, que diferem em **quais tendências** contêm. Somando a equação de um passeio com drift desde o início:

$$y_t = y_0 + \beta t + \sum_{j=1}^{t} u_j,$$

aparecem as duas tendências: βt é a parte **determinística** (um acréscimo fixo e previsível a cada período), e $\sum u_j$ é a parte **estocástica** (a soma de todos os choques, que nunca se apaga).

Processo	Equação	Tendência determinística	Tendência estocástica	No INPC
Estacionário	$y_t = a + \rho y_{t-1} + u_t$, $\lvert\rho\rvert < 1$	não	não	a inflação mensal
Raiz unitária, I(1)	$y_t = y_{t-1} + u_t$	não	sim	—
Tendência estacionária (TS)	$y_t = a + bt + u_t$	sim	não	rejeitado

Processo	Equação	Tendência determinística	Tendência estocástica	No INPC
Diferença estacionária (DS)	$y_t = a + y_{t-1} + u_t$	sim	sim	o log do índice

Duas definições de I(1). Na definição **ampla**, usada pela maioria dos livros, uma série é I(1) se precisa de uma diferença para ficar estacionária: o passeio com e sem drift são ambos I(1). Na definição **restrita** de Engle e Granger, adotada por Mattos, I(1) é só o processo sem termos determinísticos; o passeio com drift é "diferença estacionária", que **contém** um processo I(1) somado a uma reta. Na prova, diga qual definição está usando: "o log do INPC é DS (I(1) na definição ampla)".

Toda série é estocástica. Não faz sentido perguntar se a *série* é determinística ou estocástica: todas têm choques aleatórios. O que é determinístico ou estocástico é a **tendência**.

Os dois erros têm custo. A Q6 mostra o custo de diferenciar demais. O custo de não diferenciar uma série I(1) é pior: a inferência usual deixa de valer, e aparecem regressões espúrias. Os testes de raiz unitária servem para escolher entre as duas colunas da tabela.

O teste ADF, por dentro

A ideia. Escreva um AR(1) para y: $y_t = \rho y_{t-1} + a_t$. Há raiz unitária se $\rho = 1$. Subtraindo y_{t-1} dos dois lados:

$$\Delta y_t = (\rho - 1) y_{t-1} + a_t = \gamma\, y_{t-1} + a_t, \qquad \gamma = \rho - 1.$$

Testar $\rho = 1$ é testar $\gamma = 0$, um teste t comum numa regressão de Δy_t em y_{t-1}.

Por que "aumentado". Se a série tiver mais dinâmica do que um AR(1), o erro dessa regressão fica autocorrelacionado, e o teste erra o tamanho. A solução de Said e Dickey é acrescentar defasagens de Δy_t até o erro ficar branco:

$$\Delta y_t = \alpha + \beta t + \gamma\, y_{t-1} + \sum_{i=1}^{k} \delta_i\, \Delta y_{t-i} + e_t.$$

- H_0: $\gamma = 0$ (raiz unitária, DS).
- H_1: $\gamma < 0$ (estacionária em torno de $\alpha + \beta t$, TS).

O teste é **unilateral à esquerda**: rejeita-se H_0 quando $\tau = \hat{\gamma} / \operatorname{ep}(\hat{\gamma})$ é muito negativo.

O que cada versão testa (MAT, seção 2.2). As hipóteses mudam com os termos determinísticos:

Versão	H_0 (raiz unitária)	H_1 (sem raiz unitária)
sem constante	I(1) puro: só tendência estocástica	estacionário com média zero
com constante	I(1) puro: só tendência estocástica	estacionário com média $\neq 0$
com constante e tendência	DS: tendência determinística + estocástica	TS: tendência determinística + erro estacionário

Na versão com tendência, **as duas hipóteses são não estacionárias**. Ali o ADF não testa "estacionária ou não"; testa se há um processo I(1) embutido na série. É um erro comum, e Mattos chama a atenção para ele.

Por que a estatística não segue a t de Student. Sob H_0, o regressor y_{t-1} é um passeio aleatório, não estacionário. A variância amostral de y_{t-1} não converge para uma constante, e o teorema central do limite usual não se aplica. A distribuição limite de τ é um funcional do movimento browniano (a distribuição de Dickey-Fuller). Ela é assimétrica e deslocada para a esquerda, e os valores críticos são mais negativos do que $-1{,}645$.

Os três casos e seus valores críticos. Os termos determinísticos mudam a distribuição, e por isso há três tabelas:

Regressão	Estatística	Crítico de 5%
sem constante e sem tendência	τ_1	$-1{,}95$
com constante	τ_2	$-2{,}86$
com constante e tendência	τ_3	$-3{,}41$

(Com $T = 165$, o `urca` imprime $-3{,}43$ e $-2{,}88$, os valores ajustados ao tamanho da amostra. O `urca` não dá p-valores; eles vêm das superfícies de MacKinnon, com `punitroot`.)

Por onde começar. A hipótese alternativa precisa descrever a série de forma plausível. O log do INPC sobe por 13 anos. Se ele for estacionário, só pode ser estacionário **em torno de uma tendência**. Por isso o teste usa constante e tendência.

Como escolher a versão na prática (MAT, seção 2.2.5). Pelo gráfico. Se a série cresce, usa-se a versão com constante e tendência; na dúvida, também, porque ela engloba as outras. Se a série oscila em torno de uma média, usa-se a versão com constante. Para o INPC: o log do índice cresce (com tendência); a inflação oscila em torno de 0,45% (com constante).

Como escolher k. Defasagens de menos deixam autocorrelação no erro, e o teste erra o tamanho. Defasagens demais custam poder. A prática é partir de um máximo, $k_{\max} = 12\,(T/100)^{1/4} = 13$ para $T = 165$ (regra de Schwert), e escolher por AIC ou BIC.

Phillips-Perron: a mesma pergunta, outra correção

O PP estima a regressão **sem** as defasagens Δy_{t-i} e corrige a estatística depois, com uma variância de longo prazo de Newey-West. A vantagem é não depender da escolha de k. As hipóteses e os valores críticos são os mesmos do ADF.

KPSS: inverter as hipóteses

O ADF e o PP têm **pouco poder** quando ρ está perto de 1: um AR(1) com $\rho = 0{,}97$ e um passeio aleatório produzem amostras quase iguais. Por isso o teste "não rejeita" com frequência, e "não rejeitar" não prova a raiz unitária.

O KPSS inverte o papel das hipóteses. Ele escreve $y_t = \beta t + r_t + \varepsilon_t$, com $r_t = r_{t-1} + u_t$ um passeio aleatório:

- H_0: $\mathrm{Var}(u_t) = 0$, isto é, o passeio é constante e y é **estacionária** (em torno da tendência);
- H_1: há raiz unitária.

A estatística é $\mathrm{KPSS} = \sum_t S_t^2 / (T^2 \hat{\sigma}^2_{LP})$, em que S_t é a soma acumulada dos resíduos da regressão de y em $(1, t)$. Se a série tem raiz unitária, as somas acumuladas vagueiam e a estatística fica grande. Rejeita-se H_0 quando ela passa do crítico.

Por que usar os dois. O uso conjunto é chamado de análise confirmatória:

ADF/PP	KPSS	Conclusão
rejeita H_0 (estacionária)	não rejeita H_0 (estacionária)	estacionária: os dois concordam
não rejeita (raiz unitária)	rejeita (raiz unitária)	$I(1)$: os dois concordam
não rejeita	não rejeita	dados pouco informativos
rejeita	rejeita	conflito: olhar quebras, especificação, teoria

O que o INPC respondeu (no nível y_t)

Teste	Estatística	Crítico de 5%	Decisão
ADF, tendência, $k = 2$ (AIC)	$\tau_3 = -2{,}36$	$-3{,}43$	não rejeita a raiz unitária
ADF, tendência, $k = 1$ (BIC)	$\tau_3 = -2{,}09$	$-3{,}43$	não rejeita
PP, tendência	$Z_\tau = -1{,}96$	$-3{,}44$	não rejeita
KPSS, tendência	0,082	0,146	não rejeita a estacionariedade

O ADF e o PP apontam raiz unitária, e o KPSS não confirma: estamos na terceira linha da tabela confirmatória, **dados pouco informativos**. O $\hat{\rho}$ da regressão ADF é $1 + \hat{\gamma} = 0{,}972$, exatamente a zona em que é difícil distinguir uma série muito persistente de uma raiz unitária, sobretudo com só 165 meses.

As três versões, lidas como Mattos (Q2b):

1. **Com tendência** (a versão certa, pelo gráfico): $\tau_3 = -2{,}36$, p-valor de MacKinnon 0,40. Não rejeita H_0, e H_0 aqui é **DS**: $y_t = y_0 + \alpha t + \sum_{j \le t} u_j$, tendência determinística (o drift, α = inflação média) mais tendência estocástica. É um **passeio aleatório com drift**, $\Delta y_t = \alpha + u_t$.
2. **Só com constante:** $\tau_2 = -1{,}01$ também não rejeita, mas a alternativa desta versão (estacionária em torno de uma média fixa) não descreve uma série que cresce. O resultado não acrescenta nada.
3. **Sem nada:** a alternativa (média zero) é ainda menos plausível.

Repare no que acontece sem termo nenhum: $\tau_1 = +3{,}94$, **positivo**. O teste interpreta o drift omitido como explosividade. A lição: um teste de raiz unitária com termos determinísticos errados dá a resposta errada.

A decisão: $d = 1$, e como defendê-la

Adota-se tendência estocástica, $d = 1$, por cinco argumentos. Na prova, cite pelo menos três.

1. **Os testes de raiz unitária concordam.** ADF com AIC e com BIC, ADF com dummies sazonais, PP e DF-GLS (MAT, seção 2.4: $-1{,}70$ contra o crítico de $-2{,}93$): nenhum rejeita.
2. **O KPSS tem pouco poder aqui.** Com 165 observações e 13 defasagens na variância de longo prazo, a estatística tende a ficar pequena mesmo sob raiz unitária. Não rejeitar a estacionariedade não é evidência forte a favor dela.
3. **O argumento econômico.** Sob metas de inflação, o Banco Central mira a inflação, não o nível de preços. Um choque que eleva o índice não é revertido: o nível nunca volta para uma trajetória fixa. Isso é a definição de tendência estocástica.
4. **O teste na diferença.** Na inflação Δy_t, o ADF com constante dá $\tau_2 = -5{,}16$, muito abaixo de $-2{,}88$, e o KPSS de nível dá 0,114, abaixo do crítico de 0,463. Os dois concordam: Δy é estacionária, então $d = 1$ basta.
5. **O diagnóstico de sobrediferenciação.** Se y fosse TS, diferenciar criaria um MA com raiz unitária em Δy. Na Q5, o MA(1) acrescentado ao modelo de Δy sai $-0{,}17$, longe de -1.

Robustez à sazonalidade (MAT, seção 2.6). Numa série mensal, a sazonalidade não modelada pode distorcer o ADF. A correção de Dickey e Miller é acrescentar 11 dummies sazonais centradas à regressão do teste; os valores críticos continuam os mesmos. No INPC, com dummies e defasagens pelo BIC:

- log do índice, versão com tendência: $\tau = -2{,}21$, contra o crítico de $-3{,}43$. Não rejeita: continua DS;
- inflação, versão com constante: $\tau = -6{,}74$, contra $-2{,}88$. Rejeita: continua estacionária.

A conclusão $d = 1$ (ou $d = 0$ para a inflação) não depende de como se trata a sazonalidade.

> **Por que o argumento 5 é forte**
>
> Se $y_t = \alpha + \beta t + u_t$ com u_t estacionário, então $\Delta y_t = \beta + (1 - B)u_t$. O fator $(1 - B)$ no lado do erro é um MA com raiz exatamente unitária. Se o modelo estimado para Δy não mostra esse MA, a série não era TS. É a mesma álgebra da Q10 da lista teórica (03_lista).

A diferença sazonal: $D = 0$

A pergunta. A sazonalidade é **determinística** (cada mês tem uma média própria e fixa) ou **estocástica** (o padrão sazonal vagueia como um passeio aleatório, $y_t = y_{t-12} + a_t$)? Só a segunda pede a diferença sazonal $1 - B^{12}$.

Como decidir com o que o curso dá. São duas evidências.

- **As dummies sazonais no ADF** (MAT, seção 2.6, acima): na inflação, 3 das 11 dummies são significativas a 5%. Há sazonalidade determinística, e a raiz unitária regular continua rejeitada.
- **A FAC sazonal.** Uma raiz unitária sazonal faria a FAC de Δy decair devagar nos múltiplos de 12, como a FAC do nível decai devagar nas defasagens regulares. Não é o que acontece: 0,22 em 12, −0,03 em 24 e 0,02 em 36.

Logo $D = 0$.

> **Armadilha**
>
> Diferenciar sazonalmente sem precisar é o análogo sazonal da Q6: cria um MA sazonal com raiz unitária. Se o padrão é fixo, ele se modela com termos SAR/SMA ou com dummies, não com $1 - B^{12}$.

3. Q3: identificar a estrutura pela FAC e pela FACP

O que estou fazendo

Estou olhando as "impressões digitais" da inflação Δy_t para propor modelos.

As duas ferramentas

A FAC mede a correlação total entre Δy_t e Δy_{t-k}:

$$\rho_k = \frac{\text{Cov}(\Delta y_t, \Delta y_{t-k})}{\text{Var}(\Delta y_t)}.$$

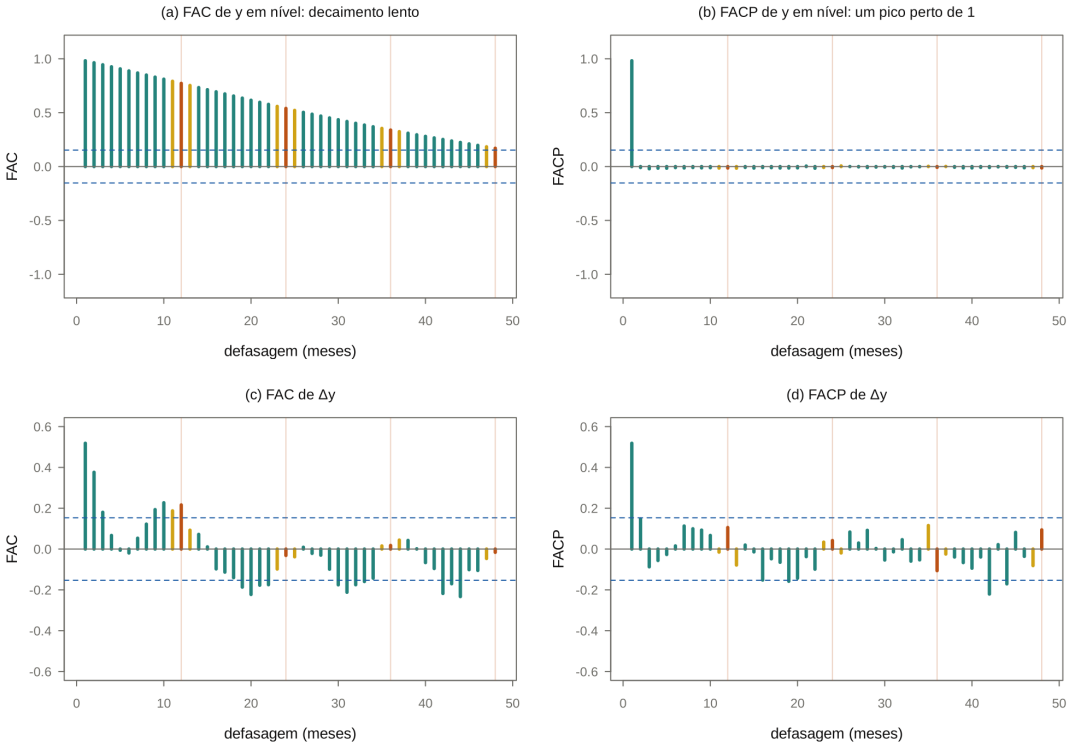
A FACP mede a correlação **líquida** em k: a que sobra depois de descontar o efeito das defasagens $1, \ldots, k-1$. Na prática, ϕ_{kk} é o último coeficiente de um AR(k) ajustado à série.

A banda. Se a série fosse ruído branco, $\hat{\rho}_k$ teria desvio-padrão aproximado de $1/\sqrt{T}$. A banda de 95% é $\pm 1{,}96/\sqrt{T} = \pm 0{,}153$ para o INPC. Uma barra fora da banda é uma autocorrelação estatisticamente diferente de zero. Com 165 observações a banda é larga, e efeitos moderados ficam no limite.

Por que FAC e FACP juntas identificam o modelo

Processo	FAC	FACP	Por quê
AR(p)	decai (geométrica ou senoidal)	**corta** depois de p	y_t depende só de p defasagens diretamente; o resto é efeito indireto
MA(q)	**corta** depois de q	decai	y_t e y_{t-k} não compartilham choque nenhum para $k > q$
ARMA(p, q)	decai depois de q	decai depois de p	mistura dos dois
SAR$(1)_{12}$	picos em 12, 24, 36 decaindo	pico só em 12	o mesmo, em múltiplos de 12
SMA$(1)_{12}$	pico só em 12	picos em 12, 24, 36 decaindo	o mesmo, em múltiplos de 12

Os picos vizinhos de 12. Num modelo multiplicativo como $(1-\phi B)(1-\Phi B^{12})$, o produto gera um termo em B^{13} com coeficiente $\phi\Phi$. Isso cria correlação nas defasagens 11 e 13, ao lado do pico em 12 (Q11 e Q16 da lista teórica). Quando Φ é pequeno, esse termo cruzado também é, e não aparece no correlograma.



Os dois painéis de cima são a FAC e a FACP do **nível** y_t, e valem como revisão da Q2. A FAC decai muito devagar, quase em linha reta, e a FACP tem um único pico perto de 1. É a assinatura visual de uma raiz unitária: num processo estacionário, a FAC cairia geometricamente. Os painéis de baixo são os da inflação Δy_t, que são os que se leem para identificar o modelo.

O que o INPC mostrou

- **FACP**: $\phi_{11} = 0{,}518$, claramente fora da banda. $\phi_{22} = 0{,}147$ fica **no limite** da banda (0,153); depois tudo cai dentro. A leitura principal é AR(1); o AR(2) é uma alternativa.
- **FAC**: 0,518, 0,376, 0,180... Decai, mas o segundo valor é maior que $0{,}518^2 \approx 0{,}27$: mais devagar que um AR(1) puro, o que reforça o AR(2) como alternativa.
- **Defasagem 12**: a FAC vale 0,216, acima da banda, e a FACP vale 0,105, dentro. Em 24 a FAC já é $-0{,}031$. Há algo sazonal, fraco, e não fica claro se é SAR (decaimento) ou SMA (corte). Com só 13 repetições de cada mês, é o esperado.
- **Defasagem 13**: a FACP vale $-0{,}078$, dentro da banda: não há sinal claro de termo cruzado multiplicativo.

Como há duas ambiguidades (a parte sazonal e o AR(2)), entram três candidatos, todos com $d = 1$, $D = 0$ e drift:

Candidato	Modelo para y_t	O que testa
C1	SARIMA(1,1,0)(1,0,0)$_{12}$	AR(1) com SAR(1): a leitura principal
C2	SARIMA(1,1,0)(0,0,1)$_{12}$	troca o SAR por um SMA
C3	SARIMA(2,1,0)(1,0,0)$_{12}$	acrescenta o AR(2)

Por que o drift. Num modelo com $d = 1$, a constante do modelo de Δy vira uma tendência linear em y. Aqui, ela é a inflação média mensal. Sem drift, o modelo diria que a inflação média é zero. O ADF da Q2 já

tinha dito que ela é necessária: a versão certa para y é a com tendência, e H_0 ali é o passeio **com drift**.

Na prova

A identificação é uma **proposta**, não uma conclusão. Quem decide entre os candidatos é a estimação (Q4) e o diagnóstico (Q5). Por isso a Lista pede três candidatos, e não um.

4. Q4: estimar e escolher

O que estou fazendo

Estou estimando os três candidatos por máxima verossimilhança e escolhendo um.

O modelo escolhido, escrito por extenso

O C1 é:

$$(1-\phi B)(1-\Phi B^{12})(\Delta y_t-\mu)=a_t, \qquad a_t \sim RB(0,\sigma^2).$$

Parâmetro	Significado	Estimativa
ϕ	persistência da inflação de um mês para o outro	0,506
Φ	persistência do padrão sazonal de um ano para o outro	0,178 (p-valor 0,022)
μ	inflação média mensal (o drift), em %	0,453
σ^2	variância do choque	0,1259

O sinal do MA

O C2 tem um MA sazonal. O R escreve o MA com sinal **positivo**, $1+\Theta B^{12}$; a lista (convenção de Box-Jenkins) escreve $1-\Theta B^{12}$. Um Θ positivo no R é negativo na notação da lista. Diga sempre qual convenção está usando. Ver CONVENCOES.md §2.

Por que máxima verossimilhança exata

Há dois jeitos de estimar um ARMA:

- **Mínimos quadrados condicionais (CSS):** fixam-se os valores iniciais, por exemplo os choques anteriores à amostra iguais a zero, e minimiza-se a soma dos quadrados dos erros. É rápido, mas descarta informação das primeiras observações. Com um termo sazonal, isso significa perder ao menos 12 meses, o que pesa numa amostra de 165.
- **MV exata:** escreve-se a verossimilhança de toda a amostra, incluindo as primeiras observações. O filtro de Kalman decompõe a verossimilhança nos erros de previsão um passo à frente v_t e nas suas variâncias F_t:

$$\ln L=-\frac{1}{2}\sum_{t=1}^{T}\left[\ln(2\pi F_t)+\frac{v_t^2}{F_t}\right].$$

A MV exata usa toda a informação e impõe estacionariedade e invertibilidade. Para o AR(1) puro, a MV condicional coincide com o MQO (Q13 da lista teórica).

AIC e BIC: o que eles medem

Quanto mais parâmetros, maior a verossimilhança: um modelo grande sempre "ajusta" melhor. Os critérios cobram um preço por parâmetro:

$$AIC = -2\ln L + 2k, \qquad BIC = -2\ln L + k\ln n.$$

Menor é melhor. No **R**, k conta **todos** os parâmetros estimados, **incluindo** σ^2 (o script confere à mão). Com $n = 164$, $\ln n \approx 5{,}1$: o BIC cobra mais que o dobro do AIC por parâmetro.

> **A versão das aulas (AU02, slides 98–99)**
>
> A aula difere do R em dois pontos:
> - divide os critérios por T: $AIC = (-2\ln L + 2k)/T$;
> - conta $k = p + q + 1$ num ARMA com média, **sem** σ^2. O R usa $k = p + q + P + Q + 1 + 1$.
>
> Com o mesmo T e os mesmos ajustes em todos os modelos, a ordenação é idêntica: só muda o valor do critério. É exatamente o que a Q4(d) pede: dizer qual convenção o software usa. A resposta é "o R inclui σ^2; a convenção da aula não inclui". A mesma aula alerta que não se comparam critérios entre séries de tamanhos diferentes: T deve ser o mesmo.

Quando a comparação é válida. Só se compara AIC entre modelos com a **mesma variável dependente** e a **mesma amostra efetiva**. Um modelo com $d = 1$ e outro com $d = 2$ têm verossimilhanças de séries diferentes (Δy e $\Delta^2 y$), e seus AIC não se comparam. Aqui os três têm $d = 1$, $D = 0$ e $n = T - d - sD = 165 - 1 - 0 = 164$. A comparação vale.

O que o INPC respondeu

Modelo	AIC	BIC
C1: AR(1) + SAR	125,618	**138,017**
C2: AR(1) + SMA	125,966	138,366
C3: AR(2) + SAR	**125,104**	140,603

O AIC escolhe C3, e o BIC escolhe C1. Os dois critérios discordam, e isso tem explicação teórica:

- o **BIC é consistente**: se o modelo verdadeiro está entre os candidatos, o BIC o escolhe com probabilidade que tende a 1;
- o **AIC é eficiente**: ele minimiza o erro de previsão esperado, mesmo que nenhum candidato seja o modelo verdadeiro.

A escolha: C1. O objetivo da Lista é prever, o que favorece o AIC. Mas a vantagem do C3 no AIC é de só 0,51 ponto, e duas evidências apontam para o mais simples:

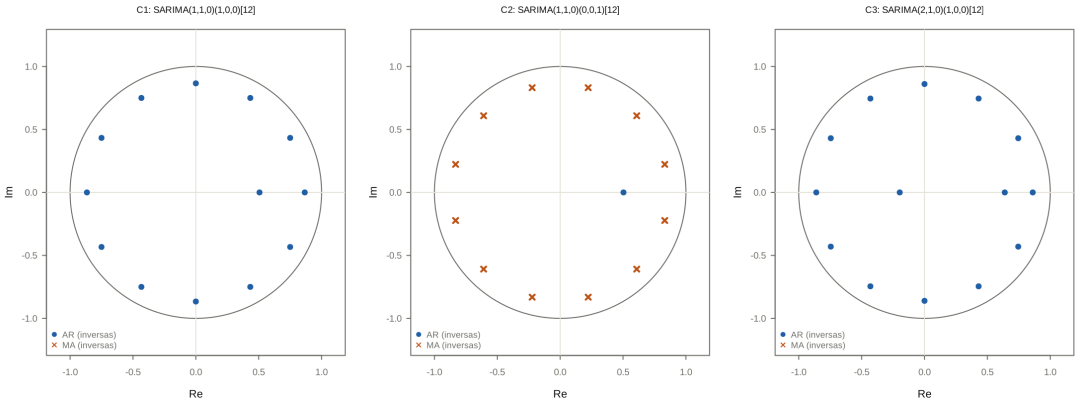
- o $\hat{\phi}_2 = 0{,}126$ do C3 não é significativo (p-valor 0,111): o ganho de ajuste vem de um parâmetro que não se distingue de zero;
- o BIC, que pune mais o excesso de parâmetros, prefere o C1.

É o **princípio da parcimônia** da aula 02. A regra foi fixada **antes** de olhar a validação da Q7: se AIC e BIC divergem, fica o modelo menor quando o parâmetro extra do maior não é significativo a 5%.

As raízes: o modelo é estacionário?

- **Estacionariedade:** as raízes de $(1 - \phi z)(1 - \Phi z^{12}) = 0$ precisam estar fora do círculo unitário, $|z| > 1$.
- **Invertibilidade:** o C1 não tem MA, então é invertível por construção.

O gráfico do R mostra as **raízes inversas** $1/z$, que precisam ficar **dentro** do círculo. No C1, a raiz inversa regular é $\hat{\phi} = 0{,}506$, e as 12 sazonais têm módulo $\widehat{\Phi}^{1/12} = 0{,}866$. Repare: um $\widehat{\Phi}$ pequeno, de 0,18, vira 12 raízes inversas de módulo alto, porque $\Phi^{1/12}$ fica perto de 1 mesmo para Φ pequeno. Isso não é problema: elas continuam dentro do círculo.



5. Q5: diagnosticar os resíduos

O que estou fazendo

Estou verificando se os resíduos $\hat{a}_t$ do C1 se comportam como o modelo supõe: ruído branco, com variância constante e, de preferência, normal.

Por quê

O modelo diz que a_t é imprevisível. Se os resíduos tiverem autocorrelação, sobrou estrutura que o modelo não captou, e as previsões podem melhorar. Cada teste checa uma suposição diferente:

Suposição	Teste	Se falhar, o que se perde
sem autocorrelação	Ljung-Box	o modelo está mal especificado; volta à Q3
variância condicional constante	ARCH-LM	os intervalos de previsão ficam errados em períodos turbulentos
normalidade	Jarque-Bera	os intervalos ficam errados nas caudas; os estimadores continuam consistentes

Ljung-Box

A estatística junta as autocorrelações dos resíduos até a defasagem K:

$$Q(K) = T(T+2)\sum_{j=1}^{K}\frac{\hat{\rho}_j^2}{T-j}.$$

- H_0: $\rho_1 = \cdots = \rho_K = 0$ nos resíduos.
- Sob H_0, $Q \sim \chi^2(K - p - q - P - Q)$.

Por que descontar os graus de liberdade. Os parâmetros ARMA foram escolhidos justamente para zerar as primeiras autocorrelações dos resíduos. Cada parâmetro estimado "gasta" um grau de liberdade. No C1, $p + q + P + Q = 1 + 0 + 1 + 0 = 2$; o drift não conta, porque não mexe na autocorrelação. Com $K = 24$, são $24 - 2 = 22$ graus.

Resultado: $Q = 20{,}32$, p-valor 0,563. Não rejeita: os resíduos não têm autocorrelação.

O contraste com um modelo ruim (Q5d). O modelo sem o AR(1), SARIMA$(0,1,0)(1,0,0)_{12}$, tem p-valor de Ljung-Box 0,000: os resíduos herdam a autocorrelação de 0,52 da inflação. É por isso que todos os candidatos têm o AR(1).

Jarque-Bera

O teste compara a assimetria S e a curtose K dos resíduos com as da normal ($S = 0$, $K = 3$):

$$JB = \frac{T}{6}\left[S^2 + \frac{(K-3)^2}{4}\right] \sim \chi^2(2) \text{ sob } H_0.$$

Resultado: $JB = 18{,}1$, e a normalidade é rejeitada. A curtose dos resíduos é 4,4, acima de 3: as caudas são mais pesadas que as da normal. A causa são três choques: os resíduos padronizados passam de 3 em módulo em jun/2018, jul/2022 e fev/2025.

Isso invalida o modelo? Não. A MV gaussiana continua consistente sem normalidade (é quase-MV), e as previsões pontuais continuam válidas. O que fica comprometido são os intervalos de previsão, que supõem caudas normais.

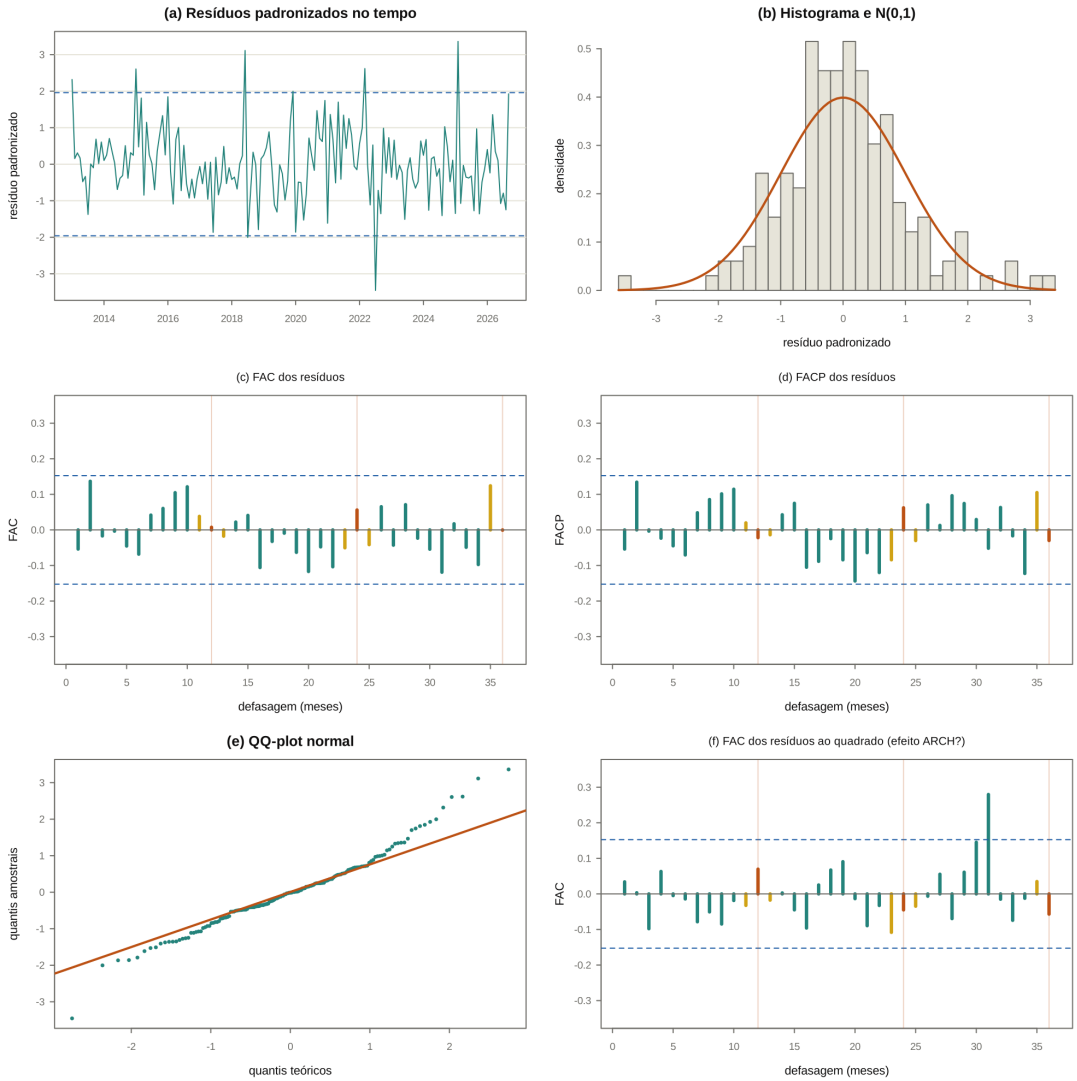
ARCH-LM

O teste verifica se a **variância** dos choques depende do passado. A regressão auxiliar é:

$$\hat{a}_t^2 = \alpha_0 + \alpha_1 \hat{a}_{t-1}^2 + \cdots + \alpha_{12}\hat{a}_{t-12}^2 + u_t.$$

H_0: $\alpha_1 = \cdots = \alpha_{12} = 0$. A estatística é $TR^2 \sim \chi^2(12)$.

Resultado: $LM = 5{,}95$, p-valor 0,918. Não há efeito ARCH.



Sobreajuste

A lógica. Se o C1 está correto, acrescentar um parâmetro não deve ajudar: ele deve sair não significativo. Acrescenta-se um termo em cada direção:

- um AR(2) a mais (que é o C3): p-valor 0,111;
- um MA(1) a mais: p-valor 0,169, com $\hat{\theta} = -0{,}17$.

Nenhum é significativo. Não falta dinâmica no C1. E o MA(1) extra, longe de -1, é o argumento 5 da Q2: Δy não está sobrediferenciada.

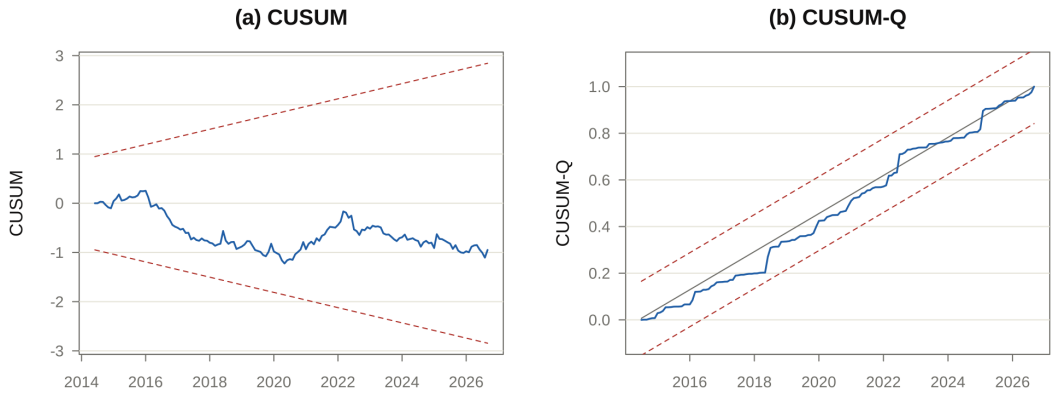
Estabilidade dos parâmetros: Chow e CUSUM (aula 03)

A pergunta. Os mesmos coeficientes valem para os 13 anos inteiros? Se não valerem, o modelo é uma média de regimes e prevê mal. Os dois testes da aula 03 pedem uma regressão por MQO; usa-se a versão autorregressiva do C1, Δy_t em Δy_{t-1}, Δy_{t-12} e Δy_{t-13} (o produto $(1-\phi B)(1-\Phi B^{12})$ gera essas três defasagens).

- **Chow.** Divide a amostra numa data T_B e testa, com um F, se os coeficientes são iguais antes e depois. A data precisa ser escolhida **antes** de olhar os dados; escolhida pelos dados, o F deixa de ter a distribuição usual. Aqui, T_B = mar/2020, o início da pandemia: $F = 0{,}457$, p-valor 0,767. Não rejeita.
- **CUSUM.** Estima o modelo recursivamente, com $1, 2, \ldots$ observações a mais, e acumula os erros de previsão de um passo padronizados (os resíduos recursivos). Sob estabilidade, a soma oscila em torno de zero; se os coeficientes mudam, ela deriva e sai das bandas. Aqui, p-valor 0,372: fica dentro.

- **CUSUM-Q.** Acumula os **quadrados** dos resíduos recursivos; sai das bandas se a variância muda. O maior desvio é 0,117, abaixo do crítico de 0,159.

Os parâmetros são estáveis. É a evidência formal para usar os 13 anos (seção 8).



6. Q6: o que acontece quando se diferencia demais

O que estou fazendo

Estou estimando, de propósito, o modelo errado, com $d = 2$, para ver como ele denuncia o erro.

A teoria (Q9 da lista teórica)

Suponha que y é $I(1)$ e que a inflação segue $\phi(B)\Delta y_t = \theta(B)a_t$. Diferenciar mais uma vez multiplica os dois lados por $(1 - B)$:

$$\phi(B)\,\Delta^2 y_t = (1 - B)\,\theta(B)\,a_t.$$

O fator $(1 - B)$ entra no **MA**. Sua raiz é $z = 1$, exatamente sobre o círculo unitário. O modelo deixa de ser invertível: não é possível recuperar os choques a_t a partir do passado da série.

Os sintomas

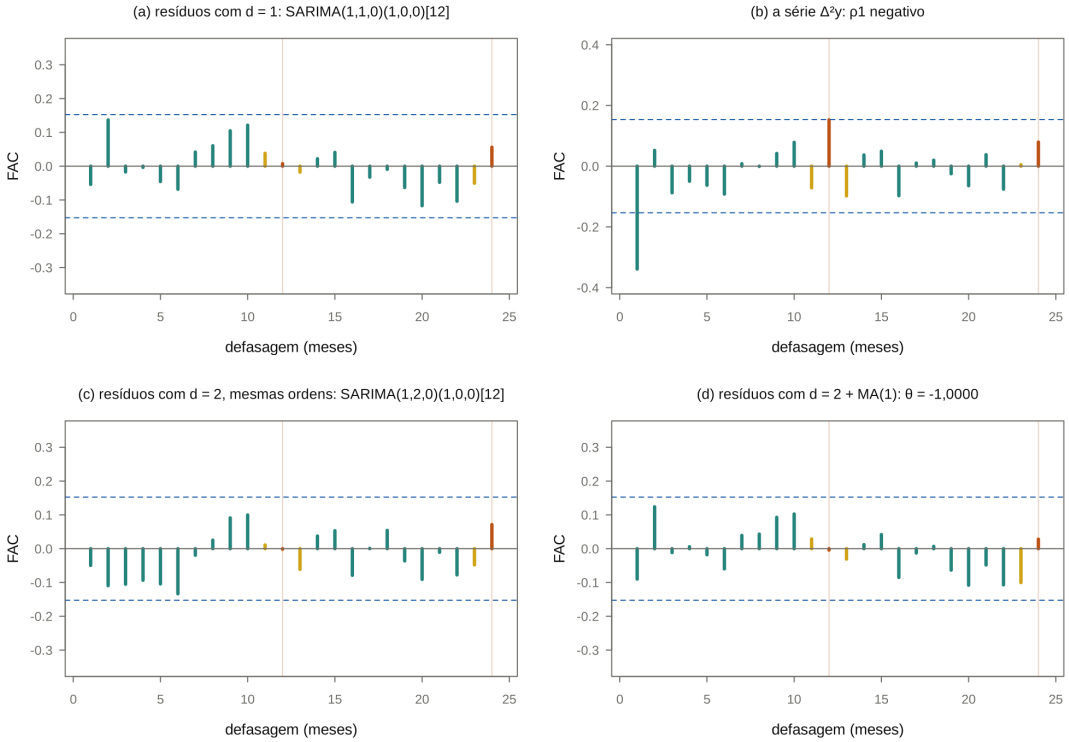
Sintoma	Por quê	O INPC com $d = 2$
$\hat{\theta} \approx -1$ (convenção do R)	é o fator $(1 - B)$ estimado	$\hat{\theta} = -1{,}0000$
variância residual maior	diferenciar ruído soma variância: $\mathrm{Var}(a_t - a_{t-1}) = 2\sigma^2$	$\hat{\sigma}^2$ sobe 19,9% sem o MA extra (0,1509 contra 0,1259)
ρ_1 negativo na série diferenciada	a diferença de uma série estacionária induz correlação negativa	$\hat{\rho}_1(\Delta^2 y) = -0{,}339$
AR que troca de sinal	o AR tenta absorver a correlação negativa	$\hat{\phi} = -0{,}345$, contra +0,506 com $d = 1$

De onde vem o ρ_1 teórico. Se $x_t = \Delta y_t$ é um AR(1) com parâmetro ϕ, então $w_t = x_t - x_{t-1}$ tem:

$$\gamma_0^w = 2(\gamma_0 - \gamma_1) = 2\gamma_0(1 - \phi), \qquad \gamma_1^w = 2\gamma_1 - \gamma_0 - \gamma_2 = -\gamma_0(1 - \phi)^2,$$

$$\rho_1^w = \frac{\gamma_1^w}{\gamma_0^w} = -\frac{1-\phi}{2}.$$

Com $\hat{\phi} = 0{,}506$, o valor teórico é $-0{,}247$; o observado é $-0{,}339$, na mesma direção e ordem de grandeza. Se x_t fosse ruído branco ($\phi = 0$), daria $-0{,}5$: é o valor de referência do "teste de olho" para sobrediferenciação.



Na prova

A pergunta clássica é "como saber se diferenciei demais?". A resposta tem três partes: um MA estimado perto de -1 (ou $+1$ na convenção de Box-Jenkins), uma variância residual que aumenta em vez de diminuir e um ρ_1 perto de $-0{,}5$ na série diferenciada.

7. Q7: o modelo prevê bem?

O que estou fazendo

Estou separando os últimos 24 meses (out/2024 a set/2026), estimando o modelo só com os dados anteriores e vendo como ele prevê os meses que não viu.

Por que fora da amostra

Dentro da amostra, um modelo maior sempre se ajusta melhor, porque ele se adapta ao ruído. A previsão fora da amostra é o único teste em que o modelo não pode "trapacear". É também a forma honesta de responder à pergunta prática: este modelo vale o trabalho?

Os dois esquemas

	Esquema 1: origem fixa	Esquema 2: origem móvel, um passo
O que se prevê	$h = 1, \ldots, 24$, todos a partir de T_0	só o mês seguinte, a cada mês

	Esquema 1: origem fixa	Esquema 2: origem móvel, um passo
Informação usada	só até T_0	os dados observados até o mês anterior
Coeficientes	estimados até T_0	os mesmos, sem reestimar
Simula	um plano de dois anos feito hoje	um analista que atualiza a previsão todo mês

O esquema 2 é bem mais fácil, porque a cada passo o modelo conhece o último dado. Por isso seus erros são muito menores.

A previsão e o intervalo

A previsão ótima, no sentido de menor erro quadrático médio, é a esperança condicional: $y_{T+h|T} = E(y_{T+h} \mid \mathcal{F}_T)$. Escrevendo o modelo como MA(∞), $y_t = \sum_j \psi_j a_{t-j}$, o erro de previsão em h passos é:

$$e_T(h) = a_{T+h} + \psi_1 a_{T+h-1} + \cdots + \psi_{h-1} a_{T+1}, \qquad \mathrm{Var}(e_T(h)) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2.$$

Num modelo integrado, os ψ_j não vão a zero, e a variância cresce sem limite com h. O intervalo de 95% é a previsão $\pm 1{,}96\sqrt{\mathrm{Var}(e_T(h))}$ e se abre como um funil.

De volta ao índice. O modelo prevê $y = 100 \ln P$. Para chegar ao índice, aplica-se $\exp(y/100)$. A rigor, isso dá a **mediana** da previsão do índice, não a média; a correção para a média seria multiplicar por $\exp(\sigma_h^2/2)$, desprezível aqui.

Por que comparar com regras ingênuas

Um RMSE sozinho não diz nada: 80 pontos é muito ou pouco? O que dá sentido ao número é a comparação com regras que qualquer um aplicaria sem econometria:

- **passeio aleatório**: o próximo valor é igual ao último, $\hat{P}_{t+h} = P_t$;
- **sazonal ingênuo**: o próximo valor é igual ao do mesmo mês do ano anterior, $\hat{P}_{t+h} = P_{t+h-12}$.

Se o modelo não bate essas regras, ele não vale o trabalho.

As métricas

Com $e_t = P_t - \hat{P}_t$:

$$RMSE = \sqrt{\frac{1}{H}\sum e_t^2}, \qquad MAE = \frac{1}{H}\sum |e_t|, \qquad MAPE = \frac{100}{H}\sum |e_t/P_t|.$$

O RMSE pune mais os erros grandes. O MAE trata todos os erros igualmente. O MAPE é em %, o que permite comparar séries de escalas diferentes.

A AU03 (slides 46 e 49) faz dois alertas que valem para este trabalho:

- **o MAPE exige** $y_t \neq 0$ e fica instável perto de zero. No índice, que vale milhares de pontos, não há problema; na **variação** mensal, que tem meses com inflação zero, ele não serve. Para uma série que cruza o zero, a aula sugere o **MASE**: o erro absoluto dividido pelo erro médio de um ingênuo (sazonal, com $m = 12$) no treino. MASE menor que 1 bate o ingênuo;
- **um modelo em log precisa ser retro-transformado** antes de calcular as métricas. É por isso que as métricas aqui usam $\exp(y/100)$, no índice.

O que o INPC respondeu

Previsor	RMSE, esquema 1	MAPE, esquema 1	RMSE, esquema 2	MAPE, esquema 2
SARIMA C1	81,5	0,86%	30,7	0,30%
passeio aleatório	425,1	4,96%	40,9	0,43%
sazonal ingênuo	525,3	6,59%	328,7	4,33%

O SARIMA vence nos dois esquemas. As razões:

- **passeio aleatório, esquema 1**: ele prevê o índice parado por dois anos, ignorando a inflação. Erra cada vez mais com h;
- **sazonal ingênuo**: no **índice**, ele repete o nível de 12 meses antes. Erra sempre por um ano inteiro de inflação, cerca de 5%;
- **SARIMA**: o drift carrega a inflação média, e o AR e a parte sazonal ajustam o perfil.

Cuidado com a comparação

Na **inflação** Δy, o sazonal ingênuo é um competidor muito mais duro, porque não carrega o erro de nível. O resultado de uma comparação depende da variável em que o erro é medido. Quase toda a vantagem do modelo no índice vem de prever a inflação média (o drift). E o enunciado proíbe mudar o modelo depois de ver o resultado (Q7f).

A diferença é significativa? Diebold-Mariano (aula 03). Uma diferença de RMSE só conta se sobreviver ao teste. O DM compara as perdas quadráticas dos dois previsores, mês a mês, no esquema 2; DM negativo favorece o modelo:

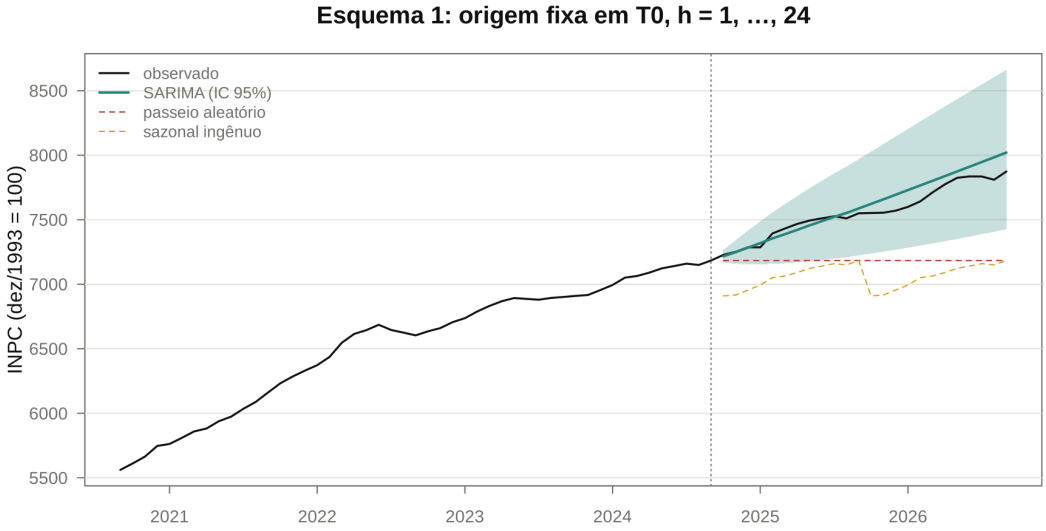
- contra o passeio aleatório: $DM = -2{,}41$, p-valor 0,025;
- contra o sazonal ingênuo: $DM = -24{,}0$, p-valor $< 0{,}001$.

O ganho é significativo a 5% contra os dois, mas bem menor contra o passeio aleatório a um passo: ele erra só a inflação de um mês.

A cobertura. Dos 24 valores observados, 100% caíram dentro do intervalo de 95% do esquema 1. Isso está acima do nominal, mas não prova que o intervalo está errado:

- o intervalo de um modelo integrado se abre muito com h;
- os 24 erros de uma única origem estão fortemente correlacionados entre si; na prática, são quase uma única observação.

O teste de **cobertura incondicional** de Christoffersen (aula 03), LR_{uc}, compara a proporção de violações com os 5% nominais: no esquema 1, $LR_{uc} = 2{,}46$, p-valor 0,117, não rejeita. No esquema 2, de um passo, a cobertura é 91,7% (2 violações em 24), p-valor 0,492.



8. Por que 13 anos (2013–2026) e não 26 (2000–2026)

A dupla tinha duas séries possíveis: esta, de jan/2013 a set/2026, e uma mais longa, de jan/2000 a set/2026, com 321 meses. Escolheu-se a curta. Essa escolha é uma pergunta de prova em potencial, porque ilustra um trade-off central de séries temporais.

O que a série longa oferece. Mais dados significam estimativas mais precisas: o erro-padrão do $\hat{\phi}$ do mesmo modelo C1 é 0,044 com 26 anos e 0,067 com 13. A banda da FAC é mais estreita, os testes de raiz unitária têm mais poder, e há mais repetições de cada mês para estimar a sazonalidade.

O que ela custa. Ela mistura regimes. Os 13 anos a mais trazem a crise de 2002–2003 e a queda de patamar da inflação em 2004:

- nos testes de raiz unitária, o ADF passa a rejeitar ($\tau_3 = -3{,}985$), e o KPSS também rejeita a estacionariedade (0,170): os testes entram em **conflito**, porque confundem a mudança de regime com tendência;
- os resíduos ficam muito menos normais: o JB do mesmo C1 vai de 18,1 para 384,7, por causa do choque de nov/2002;
- a previsão piora: no esquema 1, o RMSE do C1 estimado com 26 anos é 110,9, contra 81,5 com 13. O drift da série longa ainda carrega a inflação média do começo dos anos 2000.

O que a AU03 diz sobre isso (slides 24 e 37). Um modelo estimado na amostra inteira pode passar em todos os testes de resíduos e ainda descrever mal cada subperíodo: a estabilidade dos parâmetros é uma hipótese a mais, que se verifica com Chow ou CUSUM. Na janela de 13 anos ela passa nos dois (Q5). Quando há instabilidade, a aula indica a **janela deslizante**, que descarta o passado distante e é mais robusta a quebras, ao custo de estimativas mais ruidosas. Escolher 2013–2026 é aplicar essa ideia: descartar o regime de 2000–2004.

A regra prática. Use a série mais longa **dentro de um regime estável**. É um trade-off entre variância (que cai com mais dados) e viés (que cresce quando a amostra mistura processos diferentes). O INPC recente ainda tem mudanças de patamar (Q1), mas sem um episódio da dimensão de 2002.

> **Na prova**
>
> Se perguntarem "por que não usar a série mais longa disponível?", a resposta é: porque mais dados só ajudam se o mesmo modelo, com os mesmos parâmetros, vale para toda a amostra. Mostre a evidência: os parâmetros são estáveis na janela curta (Chow e CUSUM), os testes de raiz unitária mudam de

> conclusão na longa, e a previsão piora com ela.

9. A Q8 (teoria, manuscrita)

A Q8 pede dois exercícios da lista teórica resolvidos à mão. Os mais ligados ao que a parte empírica fez são:

Exercício	Ligação com a parte empírica	Resolução
Q6 (ARMA(1,1): FAC e pesos)	a forma da FAC que se lê na Q3	02_lista
Q9 (sobrediferenciação)	é a Q6 empírica no papel	03_lista
Q10 (DS × TS)	o argumento 5 da Q2	03_lista
Q12 (SARIMA e previsão)	a estrutura multiplicativa e a Q7	03_lista
Q14 (AIC e BIC)	a escolha da Q4	04_lista

10. As armadilhas que mais caem

1. **"Não rejeitar a raiz unitária prova que ela existe."** Falso. O ADF tem pouco poder perto de $\rho = 1$. Por isso se usa o KPSS junto.
2. **Usar o crítico da t de Student no ADF.** Sob H_0, a distribuição é a de Dickey-Fuller, com críticos mais negativos.
3. **Ler a versão com tendência como "estacionária ou não".** Nela, H_0 é DS e H_1 é TS: as duas são não estacionárias. Não rejeitar quer dizer que há um processo I(1) somado à tendência determinística (MAT, seção 2.2).
4. **Esquecer os termos determinísticos.** Sem constante, o τ_1 do INPC sai até positivo.
5. **Comparar AIC entre modelos com d diferentes.** São verossimilhanças de séries diferentes.
6. **Tratar uma diferença de AIC menor que 2 como decisiva.** Nessa faixa os modelos são praticamente equivalentes, e a parcimônia desempata.
7. **Contar o drift nos graus de liberdade do Ljung-Box.** Só $p + q + P + Q$ entram.
8. **Achar que rejeitar a normalidade invalida o modelo.** Afeta os intervalos, não a consistência.
9. **Trocar o sinal do MA.** O R usa $1 + \theta B$; a lista usa $1 - \theta B$.
10. **Ler as raízes inversas como se fossem as raízes.** No gráfico do R, ficar **dentro** do círculo é o bom.
11. **Mudar o modelo depois de ver o resultado da previsão.** A validação fora da amostra deixa de ser fora da amostra.

11. A ordem de raciocínio, numa página

Se na prova vier uma série nova, siga esta ordem:

1. **Gráfico.** Tendência? Sazonalidade? Variância crescente? Outliers? Quebras?
2. **Transformação.** Se a amplitude cresce com o nível, log. Se o gráfico for ambíguo, decide a interpretação.
3. ***d.*** ADF na versão que o gráfico indica (com tendência se a série cresce), PP, KPSS e DF-GLS. Se discordarem, decidir com argumentos e testar de novo na diferença.
4. ***D.*** ADF com dummies sazonais centradas e a FAC nos múltiplos de 12. Dummies significativas e FAC sazonal que cai logo pedem $D = 0$.
5. **FAC e FACP** da série estacionária. Parte regular nas primeiras defasagens; parte sazonal em 12, 24, 36; picos em 11 e 13 indicam estrutura multiplicativa.
6. **Candidatos.** Dois ou três, cobrindo as leituras possíveis.
7. **MV exata.** Comparar AIC e BIC com a mesma amostra. Se divergem e o parâmetro extra não é significativo: parcimônia. Conferir as raízes.

8. **Resíduos e estabilidade.** Ljung-Box com os graus de liberdade certos, ARCH-LM, Jarque-Bera. Chow com data escolhida antes, CUSUM e CUSUM-Q. Sobreajuste.
9. **Previsão fora da amostra** contra o passeio aleatório e o sazonal ingênuo, com Diebold-Mariano e o teste de cobertura.

12. Perguntas de prova, com resposta

Tente responder antes de ler a resposta.

1. Por que modelar $100 \ln P_t$ e não P_t? Porque o log estabiliza a variância de uma série que cresce exponencialmente e lineariza a tendência. Além disso, a diferença do log é a taxa de inflação mensal em %, e o drift vira uma taxa média que pode ser constante.

2. O gráfico de amplitude contra média quase não mostra relação. Por que mesmo assim usar o log? Porque, com o índice só dobrando em 13 anos, há pouca informação no gráfico. Quando ele é ambíguo, decide a interpretação: com log, Δy é a inflação, e o drift é uma taxa que pode ser constante.

3. Qual a diferença entre uma série TS e uma DS? Por que importa? Na TS, só há tendência determinística: choques são temporários, e a série volta para a reta; estacionariza-se tirando a tendência. Na DS, há tendência determinística **e** estocástica: choques são permanentes; estacionariza-se diferenciando. Tratar uma como a outra gera, respectivamente, um MA não invertível ou um resíduo com raiz unitária.

3b. A inflação mensal é I(0)? E o índice, é determinístico ou estocástico? A inflação é I(0): estacionária em torno de uma média, sem tendência nenhuma. O log do índice é diferença estacionária: tem uma tendência determinística (o drift) e uma estocástica (a soma dos choques). "Determinística" e "estocástica" se aplicam à tendência, não à série: toda série econômica é estocástica.

4. Por que o teste ADF não usa os valores críticos da normal? Porque, sob H_0, o regressor y_{t-1} é não estacionário, e a estatística τ converge para um funcional do movimento browniano, não para uma normal. A distribuição é deslocada para a esquerda.

5. Para que servem as defasagens Δy_{t-i} no ADF? Para tornar o erro da regressão um ruído branco. Sem elas, a autocorrelação do erro distorce o tamanho do teste.

6. O ADF com constante e tendência não rejeitou no INPC. O que isso quer dizer? Que não se rejeita H_0: a série é DS, tendência determinística mais estocástica (um passeio com drift). A alternativa seria TS. As duas hipóteses são não estacionárias, então o teste não pergunta "estacionária ou não", e sim "há um I(1) embutido?" (MAT, seção 2.2). A versão com tendência é a certa porque o gráfico mostra a série crescendo.

7. ADF e PP não rejeitam, e o KPSS também não. O que fazer? É o caso "dados pouco informativos". Pesam os testes de raiz unitária todos na mesma direção, o pouco poder do KPSS em amostra curta, o argumento econômico (metas de inflação) e a ausência de um MA unitário no modelo da diferença. Conclui-se $d = 1$.

8. O que indica um pico na FACP em 1 e um valor no limite da banda em 2? Um AR(1) como leitura principal, com o AR(2) como alternativa a testar na estimação. Foi o que gerou o candidato C3.

9. O que indicam picos na FAC em 11, 12 e 13? Uma estrutura multiplicativa regular × sazonal, que gera termos cruzados em 12 ± 1.

10. O k do AIC inclui σ^2? Depende da convenção, e a Q4(d) pede para dizer qual. No R, sim: σ^2 também é estimado por MV e entra em k. Na AU02, não: $k = p + q + 1$ num ARMA com média. Como o +1 é igual para todos os modelos, a ordenação pelo AIC não muda.

11. AIC escolhe C3 e BIC escolhe C1. Qual usar? Em geral, para prever, o AIC. Mas aqui a vantagem do C3 é de 0,51 ponto e vem de um ϕ_2 não significativo ($p = 0{,}111$). Pelo princípio da parcimônia (AU02), fica o C1.

12. Quantos graus de liberdade tem o Ljung-Box com $K = 24$ para um SARIMA(1,1,0)(1,0,0)$_{12}$ com drift? $24 - (1 + 0 + 1 + 0) = 22$. O drift não entra.

13. O Jarque-Bera rejeitou. O modelo é inválido? Não. Os estimadores de MV gaussiana continuam consistentes, e a previsão pontual vale. O que fica errado são os intervalos de previsão nas caudas. Aqui, a não normalidade vem de três choques identificáveis.

14. Como reconhecer sobrediferenciação no output? Um MA estimado perto de -1 (convenção do R), variância residual maior do que com uma diferença a menos e ρ_1 perto de $-0{,}5$ na série diferenciada.

15. Por que o modelo com $d = 2$ não é invertível? Porque diferenciar uma série estacionária introduz o fator $(1 - B)$ no MA, com raiz em $z = 1$, sobre o círculo unitário.

16. Qual a diferença entre o esquema 1 e o esquema 2 da Q7? O esquema 1 prevê 24 meses de uma vez, só com a informação até T_0. O esquema 2 prevê um mês por vez, usando os dados observados até ali, com os mesmos coeficientes. O esquema 2 é mais fácil e erra menos.

17. Por que o intervalo de previsão de um ARIMA se abre com o horizonte? Porque a variância do erro é $\sigma^2 \sum_{j=0}^{h-1} \psi_j^2$. Num modelo integrado, os ψ_j não vão a zero, e a soma cresce sem limite.

18. Por que o sazonal ingênuo vai tão mal no índice? Porque ele repete o nível de 12 meses antes. No índice, isso significa errar sistematicamente por um ano inteiro de inflação.

19. Uma cobertura de 100% num intervalo de 95% indica um problema? Não necessariamente. São só 24 pontos, de uma única origem, com erros fortemente correlacionados. O LR_{uc} de Christoffersen não rejeita a cobertura nominal ($p = 0{,}117$).

20. Por que usar 13 anos e não a série inteira desde 2000? Porque a série longa mistura regimes: a crise de 2002–2003 e a queda de patamar de 2004 fazem os testes de raiz unitária entrarem em conflito, pioram muito a normalidade dos resíduos e pioram a previsão. Na janela curta, Chow e CUSUM não rejeitam a estabilidade. Mais dados reduzem a variância das estimativas, mas só valem a pena se o mesmo modelo serve para toda a amostra.

13. Onde cada ponto está nos slides do professor

Conferência deste guia contra as aulas de 2026 (AU01 a AU03) e o texto de Mattos (MAT), que é a leitura do curso para raiz unitária. As aulas AU04 (raiz unitária) e AU05 (ARIMA e SARIMA) não estavam disponíveis na conferência; os pontos delas ficam apoiados no MAT.

Ponto do guia	Onde está	O que confirma
Estacionariedade fraca × estrita	AU01, slides 24–26	a fraca exige média, variância e autocovariâncias constantes; a estrita, a distribuição conjunta inteira. Os testes da Q2 falam da fraca
Passeio aleatório e passeio com drift	AU01, slides 28–29, 45–47	$\mathrm{Var}(y_t) = t\sigma^2$; com drift, a média é $y_0 + \alpha t$, "tendência linear", e a variância continua $t\sigma^2$: as duas tendências da DS
Drift **e** tendência num passeio	AU01, slide 30; MAT, nota 9	gera tendência quadrática. Por isso, sob H_0 do ADF com tendência, o termo bt desaparece
FAC que decai devagar	AU01, slides 48–50	é o primeiro sinal de não estacionariedade, antes de qualquer teste (painéis de cima da figura da Q3)
Raízes fora do círculo; inversas dentro	AU02, slides 27–36	estacionariedade olha o lado AR; invertibilidade, o lado MA. Um MA puro é sempre estacionário; um AR puro é sempre invertível

Ponto do guia	Onde está	O que confirma
$\lvert\rho_1\rvert \leq 1/2$ num MA(1), máximo em $\theta = \pm 1$	AU02, slide 35	é o limite que a série sobrediferenciada atinge (Q6)
MV exata pelo filtro de Kalman	AU02, slide 60	não condiciona nos valores iniciais e é preferível quando o MA está perto de não invertível
AIC e BIC	AU02, slides 98–99	divididos por T, com $k = p + q + 1$ sem σ^2; o mesmo T em todos os modelos
Ljung-Box com graus de liberdade corrigidos	AU03, slide 15	$\nu = K - p - q$ para resíduos de um ARMA; aqui, com a parte sazonal, $K - p - q - P - Q$
Jarque-Bera	AU03, slides 11–14	a normalidade não é necessária para a estrutura ARMA; importa para inferência, intervalos e a MV gaussiana
ARCH-LM	AU03, slide 20	$nR^2 \sim \chi^2(p)$, com $n = T - p$
Estabilidade e janela	AU03, slides 24–37	um ajuste único pode esconder subperíodos; Chow (data escolhida antes), análise recursiva, CUSUM e CUSUM-Q; a janela deslizante é robusta a quebras
Esquemas 1 e 2 da Q7	AU03, slides 36 e 39–42	o esquema 1 é a previsão **iterada**, com a informação congelada em T_0; o esquema 2 é a janela fixa, com a origem avançando sem reestimar
RMSE, MAD (o nosso MAE), MAPE e MASE	AU03, slides 45–49	o MAPE falha perto de zero; o MASE serve para séries que cruzam o zero
Diebold-Mariano e cobertura	AU03, slides 50–51 e 59	diferença de RMSE só conta se sobreviver ao DM; a cobertura se testa com Christoffersen (o Kupiec é a parte incondicional)
ADF, PP, DF-GLS, as versões e os quatro processos	MAT, seções 1.11 e 2.2–2.4	ver a seção 2 deste guia
ADF com dummies sazonais centradas	MAT, seção 2.6	a sazonalidade determinística entra na regressão sem mudar os críticos; é como se decide D aqui

Parte II

Lista 01: o que foi feito

CAPÍTULO 2

Lista 01: o código completo, questão por questão

Esta pasta é uma versão autossuficiente da parte empírica da Lista 01 (Questões 1 a 7), pronta para entregar. Ela segue as normas de entrega:

- o código comentado, na ordem de execução;
- o banco efetivamente usado;
- o `sessionInfo()`;
- o relatório em PDF, gerado direto do código, sem nenhum número digitado à mão.

A série é o **INPC em nível** (número-índice), de **jan/2013 a set/2026 (165 meses)**, modelado como $y_t = 100 \ln P_t$. A série longa, de jan/2000 a set/2026, fica em `dados/inpc_2000_2026.csv` e entra só como checagem de robustez (Q2d e seção 8 do guia). A diferença em relação a trabalho_inpc/ é a série de partida: lá a série modelada é a variação mensal, com $d = 0$; aqui é o índice, com $d = 1$. Os modelos são equivalentes (um SARMA para Δy é um SARIMA com $d = 1$ para y). Partir do índice, porém, exercita todas as etapas que o enunciado pede: transformação, testes no nível e na diferença e sobrediferenciação para $d = 2$.

Para estudar para a prova

Comece pelo guia de estudo. Ele explica, questão por questão, o que cada passo está tentando descobrir, por que cada teste e não outro, como o teste funciona por dentro e o que o INPC respondeu. Explica também por que a janela é 2013–2026 e não 2000–2026. Termina com as armadilhas mais comuns e 20 perguntas de prova com resposta.

A versão da dupla em Quarto (variação mensal, $d = 0$)

A pasta dupla/ tem a versão em Quarto feita pela dupla, que modela a variação mensal do INPC com $d = 0$. Ela foi revisada e completada: inpc_lista_1_revisado.qmd, com a base `dupla/inpc_13_a_26.csv`. A revisão lista o que estava errado e por quê.

O jeito mais simples: um script só, em qualquer lugar

lista01_inpc.R é autossuficiente. Copie-o para qualquer pasta e rode no RStudio, bloco a bloco, ou com `Rscript lista01_inpc.R`; é preciso ter R e internet. O script:

1. instala os pacotes que faltarem (`forecast`, `tseries`, `urca`, `lmtest`, `FinTS`, `jsonlite`);
2. baixa o INPC da API do IBGE (SIDRA, tabela 1736), com o período fixo jan/2013–set/2026, definido em duas linhas no topo (`INICIO` e `FIM`);
3. roda os testes das Questões 1 a 7 na ordem da lista.

Cada passo é comentado como num roteiro de investigação: a pergunta, a fórmula por extenso, as hipóteses, o que esperar sob H_0 e como ler o resultado. Os testes imprimem a decisão em português, e os gráficos aparecem na janela de plots, já anotados (no gráfico da previsão, por exemplo, a cobertura do intervalo aparece no título). O script grava na pasta a base usada (`inpc_lista01.csv`) e as versões dos pacotes (`sessionInfo_lista01.txt`).

Como rodar a versão completa

```
Rscript lista01/rodar_tudo.R            # scripts 01–07 + relatorio_lista01.pdf
Rscript lista01/rodar_tudo.R --sem-pdf  # só os scripts
```

No Windows, use `scripts\r.ps1 lista01\rodar_tudo.R`. Para o PDF é preciso LaTeX com LuaLaTeX e as fontes Libertinus (TeX Live ou MiKTeX).

Laboratório: a lista inteira num script simples

laboratorio_lista01.R é um **script R único e linear**, com cerca de 300 linhas e nenhuma função própria. Ele lê a base, roda a bateria de testes e responde cada item da lista nos comentários `#'`. Usa as bibliotecas principais:

- `forecast`: `Arima`, `forecast`, `accuracy`, `checkresiduals`, `ndiffs`/`nsdiffs`;
- `urca`: `ur.df`, `ur.pp`, `ur.kpss`;
- `tseries`: Jarque-Bera e KPSS;
- `lmtest`: `coeftest`;
- `FinTS`: ARCH-LM.

É o arquivo para estudar rodando no RStudio. Os scripts `01_…07_` e o `relatorio_lista01.Rmd` são a versão completa. Todas as versões usam só as ferramentas das aulas 01 a 03, do texto de Mattos (2019), leitura do curso para raiz unitária, e as que o enunciado pede. O comando `Rscript lista01/renderizar_laboratorio.R` transforma o laboratório em PDF e na nota laboratorio_lista01.md, que aparece no Obsidian e no volume 4 do caderno.

Arquivos, na ordem de execução

Arquivo	Questão	O que faz e com quais ferramentas
`00_configuracao.R`	—	pacotes, semente, caminhos e funções auxiliares (correlograma com banda $\pm 1{,}96/\sqrt{T}$, polinômios regular × sazonal, raízes inversas)
`01_dados_inspecao.R`	Q1	gráficos em nível e em log; amplitude × média anual; inflação média de cada ano e de cada mês; maiores e menores valores
`02_raiz_unitaria.R`	Q2	ADF (`urca::ur.df`, defasagens por AIC/BIC com $p_{\max}$ de Schwert, p-valor de MacKinnon), PP, KPSS; as três versões do ADF lidas como em Mattos (2019, seção 2.2); ADF com 11 dummies sazonais centradas (MAT, seção 2.6) para D; DF-GLS (MAT, seção 2.4) e a série longa (2000–2026) para DS × TS
`03_identificacao.R`	Q3	FAC/FACP com 48 defasagens, banda $\pm 1{,}96/\sqrt{T}$, leitura em $s-1, s, s+1$; três candidatos
`04_estimacao_selecao.R`	Q4	MV exata dos candidatos; tabela única; conferência numérica de que σ^2 entra em k; regra de parcimônia quando AIC e BIC divergem; raízes no círculo unitário; grade de 64 SARIMA

Arquivo	Questão	O que faz e com quais ferramentas
`05_diagnostico.R`	Q5	painel de resíduos; Ljung-Box com $\nu = K - (p+q+P+Q)$; Jarque-Bera; ARCH-LM (`FinTS`); McLeod-Li; Chow em mar/2020, CUSUM e CUSUM-Q (`strucchange`, aula 03); caminho dos 64 modelos com o motivo de cada descarte; sobreajuste com teste t
`06_sobrediferenciacao.R`	Q6	o modelo com $d = 2$, com e sem o MA extra: $\hat{\theta}$, raiz MA, $\hat{\sigma}^2$, FAC; o ρ_1 teórico de $\Delta^2 y$
`07_previsao.R`	Q7	24 meses de validação; esquema 1 (origem fixa) e 2 (um passo, coeficientes fixos via `Arima(y, model = ...)`); RMSE/MAE/MAPE contra passeio aleatório e sazonal ingênuo; Diebold-Mariano (HLN) e cobertura incondicional de Christoffersen (LR_{uc}), da aula 03
`rodar_tudo.R`	—	roda tudo em processos separados, grava `saidas/sessionInfo.txt` e gera o PDF
`relatorio_lista01.Rmd`	Q1–Q7	o relatório: lê `saidas/` e escreve cada número inline
`dados/inpc_lista01.csv`	—	o banco: INPC (SIDRA, tabela 1736), jan/2013 a set/2026
`dados/inpc_2000_2026.csv`	Q2(d)	a série longa, só para a checagem de robustez

O que o código encontrou (para estudar)

Questão	Resultado
Q1	índice com tendência; a inflação média anual vai de 0,17% a.m. (2017) a 0,89% a.m. (2015); sazonalidade em Δy (fev, mar e dez altos; ago baixo); o gráfico de amplitude × média não decide, e o log é escolhido pela interpretação
Q2	nenhum teste rejeita a raiz unitária no nível (ADF com AIC e BIC, com e sem dummies sazonais, PP, DF-GLS); na versão com tendência, isso quer dizer DS (MAT); o KPSS também não rejeita (dados pouco informativos). Adota-se $d = 1$; $D = 0$ (dummies sazonais significativas e FAC sazonal que cai logo). Com a série longa, o ADF passa a rejeitar e o KPSS também: conflito causado pela crise de 2002–2003
Q3	FACP com pico em 1 e valor no limite da banda em 2; sazonalidade fraca em 12; candidatos AR(1)+SAR, AR(1)+SMA e AR(2)+SAR
Q4	o AIC escolhe SARIMA(2,1,0)(1,0,0)$_{12}$ e o BIC escolhe SARIMA(1,1,0)(1,0,0)$_{12}$; o ϕ_2 do primeiro não é significativo ($p = 0{,}11$): pela parcimônia, fica o SARIMA(1,1,0)(1,0,0)$_{12}$
Q5	ruído branco e sem ARCH; o JB rejeita por caudas (choques de jun/2018, jul/2022 e fev/2025); Chow ($p = 0{,}77$), CUSUM ($p = 0{,}37$) e CUSUM-Q não rejeitam a estabilidade; o sobreajuste não é significativo
Q6	com $d = 2$, $\hat{\theta} = -1{,}0000$ (raiz MA unitária); $\hat{\sigma}^2$ sobe 19,9% sem o MA extra; o AR troca de sinal
Q7	bate o passeio aleatório e o sazonal ingênuo nos dois esquemas (DM significativo a 5%); cobertura de 100% no esquema 1 e de 92% no esquema 2

Antes de entregar

- Trocar `[nomes da dupla]` no cabeçalho do `.Rmd`.
- Comunicar ao professor a escolha da série.
- Entregar a pasta inteira: o código, `dados/`, `saidas/sessionInfo.txt` e o PDF.
- Questão 8: resolver à mão dois exercícios da lista teórica (sugestão: Q6 e Q12, resolvidos em 02_lista e 03_lista).

Parte III

Laboratório Box-Jenkins

CAPÍTULO 3

Lista 01 — Box-Jenkins do INPC, passo a passo em R

Script único e linear: lê a base, roda a bateria de testes e responde a lista, questão por questão. Rode bloco a bloco no RStudio. Para virar PDF e nota do Obsidian, use `Rscript lista01/renderizar_laboratorio.R`.

Série. INPC/IBGE (SIDRA, tabela 1736), índice mensal de jan/2013 a set/2026 (165 meses). Modela-se $y_t = 100 \ln P_t$, de modo que Δy_t é a inflação mensal em %.

Sinal do MA. O R escreve o MA como $1 + \theta B$; a lista escreve $1 - \theta B$.

Pacotes e dados

```
library(forecast)   # Arima, forecast, accuracy, checkresiduals
library(tseries)    # jarque.bera.test, kpss.test
library(urca)       # ur.df, ur.pp, ur.kpss, ur.ers (com as regressões auxiliares completas)
library(lmtest)     # coeftest
library(FinTS)      # ArchTest (ARCH-LM)
library(strucchange) # Chow e CUSUM (aula 03)

arq <- if (file.exists("dados/inpc_lista01.csv")) "dados/inpc_lista01.csv" else
 ↪  "lista01/dados/inpc_lista01.csv"
dados <- read.csv(arq)
P  <- ts(dados$indice, start = c(2013, 1), frequency = 12)   # índice em nível
y  <- 100 * log(P)                                            # série modelada
dy <- diff(y)                                                 # inflação mensal (%)
length(y)                                                     # T >= 120
```

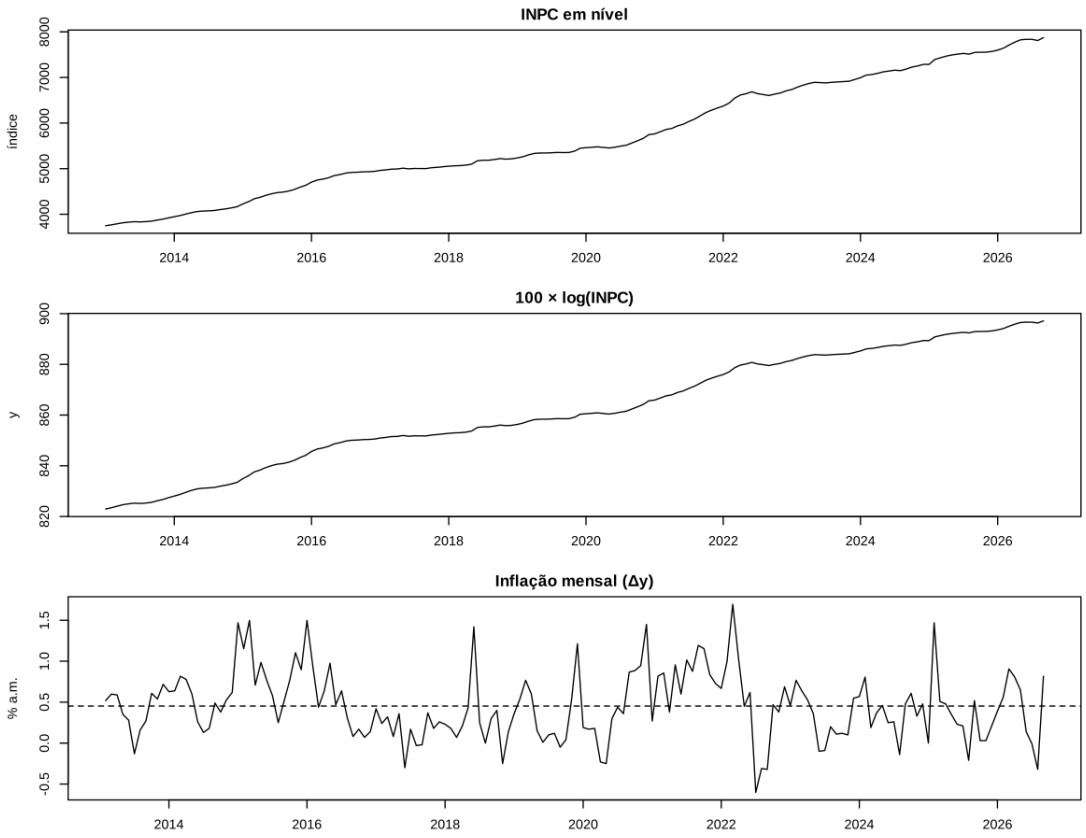
```
#> [1] 165
```

```
summary(as.numeric(dy))
```

```
#>    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
#> -0.6019  0.1774  0.4240  0.4525  0.6727  1.6956
```

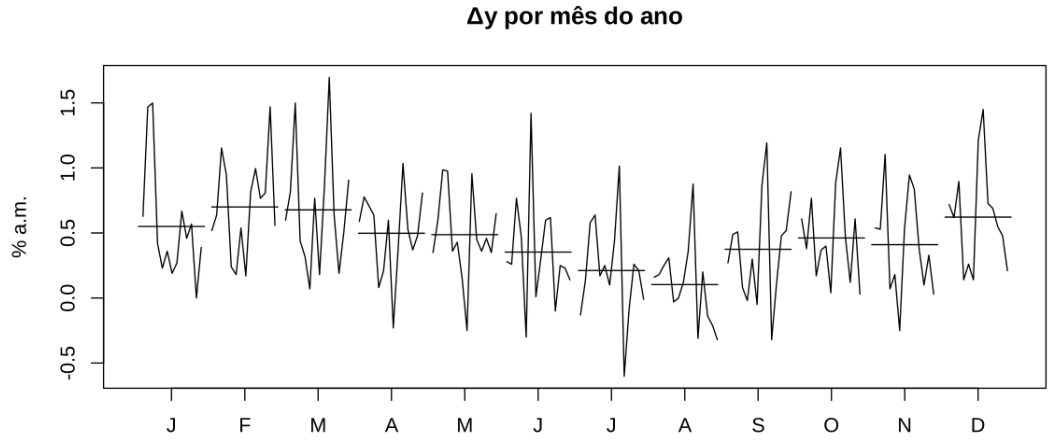
Questão 1 — Inspeção gráfica e transformação

```
par(mfrow = c(3, 1), mar = c(3, 4, 2, 1))
plot(P,  main = "INPC em nível", ylab = "índice", xlab = "")
plot(y,  main = "100 × log(INPC)", ylab = "y", xlab = "")
plot(dy, main = "Inflação mensal (Δy)", ylab = "% a.m.", xlab = ""); abline(h = mean(dy), lty
 ↪  = 2)
```




```
par(mfrow = c(1, 1))
```

```
monthplot(dy, main = "Δy por mês do ano", ylab = "% a.m.")
```




```
round(tapply(as.numeric(dy), floor(time(dy) + 1e-9), mean), 2)   # inflação média de cada ano
```

```
#> 2013 2014 2015 2016 2017 2018 2019 2020 2021 2022 2023 2024 2025 2026
#> 0.41 0.50 0.89 0.53 0.17 0.28 0.37 0.44 0.81 0.48 0.30 0.39 0.32 0.44
```

Resposta (a).

- **Tendência:** forte no nível (o índice dobra em 13 anos). Em log, vira quase uma reta.
- **Inclinação:** a inclinação do log (a inflação) muda. A média anual vai de 0,17% a.m.

1. a 0,89% a.m. (2015): alta em 2015–2016 e no pós-pandemia, baixa em 2017–2019.

- **Nível:** não há mudança de nível; choques no índice não são revertidos.
- **Sazonalidade:** aparece só em Δy. Fevereiro, março e dezembro são altos, agosto é baixo.
- **Outliers:** os maiores Δy estão em mar/2022, jan/2016, mar/2015 e fev/2025; o menor, em jul/2022. Os choques que o modelo não explica aparecem nos resíduos (Q5).
- **Dispersão:** muda pouco com o nível nesta janela (o índice só dobra em 13 anos), e o gráfico não decide sozinho a transformação.

Transformação: log. Quem decide é a interpretação: com log, Δy é a taxa de inflação e o drift é uma taxa média, que pode ser constante. Sem log, o drift seria um aumento em pontos de índice, que cresce com o nível. # Questão 2 — Ordem de integração

(a) ADF, PP e KPSS no nível

Regressão do ADF: $\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_i \delta_i \Delta y_{t-i} + e_t$.

- **ADF e PP:** H_0 é raiz unitária ($\gamma = 0$).
- **KPSS:** H_0 é estacionariedade.

As defasagens do ADF são escolhidas por AIC, até 13 (regra de Schwert, $12(T/100)^{1/4}$).

```
adf_ct <- ur.df(y, type = "trend", lags = 13, selectlags = "AIC")
summary(adf_ct)
```

```
#>
#> ###############################################
#> # Augmented Dickey-Fuller Test Unit Root Test #
#> ###############################################
#>
#> Test regression trend
#>
#>
#> Call:
#> lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
#>
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#> -0.98423 -0.20477 -0.00534  0.16454  1.21624
#>
#> Coefficients:
#>              Estimate Std. Error t value Pr(>|t|)
#> (Intercept) 23.733501   9.971220   2.380   0.0186 *
#> z.lag.1     -0.028469   0.012080  -2.357   0.0198 *
#> tt           0.012115   0.005394   2.246   0.0262 *
#> z.diff.lag1  0.429117   0.081802   5.246 5.37e-07 ***
#> z.diff.lag2  0.171394   0.083175   2.061   0.0411 *
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 0.3572 on 146 degrees of freedom
#> Multiple R-squared:  0.3111, Adjusted R-squared:  0.2923
#> F-statistic: 16.49 on 4 and 146 DF,  p-value: 3.618e-11
#>
#>
#> Value of test-statistic is: -2.3567 7.4491 3.0468
#>
#> Critical values for test statistics:
#>       1pct  5pct 10pct
#> tau3 -3.99 -3.43 -3.13
```

```
#> phi2  6.22  4.75  4.07
#> phi3  8.43  6.49  5.47
```

```
summary(ur.pp(y, type = "Z-tau", model = "trend", lags = "long"))
```

```
#>
#> ###################################
#> # Phillips-Perron Unit Root Test #
#> ###################################
#>
#> Test regression with intercept and trend
#>
#>
#> Call:
#> lm(formula = y ~ y.l1 + trend)
#>
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#> -0.95987 -0.28227 -0.02666  0.25634  1.30575
#>
#> Coefficients:
#>              Estimate Std. Error t value Pr(>|t|)
#> (Intercept) 12.503940  11.114130   1.125    0.262
#> y.l1         0.986017   0.012896  76.458   <2e-16 ***
#> trend        0.005318   0.005863   0.907    0.366
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 0.4109 on 161 degrees of freedom
#> Multiple R-squared:  0.9996, Adjusted R-squared:  0.9996
#> F-statistic: 2.239e+05 on 2 and 161 DF,  p-value: < 2.2e-16
#>
#>
#> Value of test-statistic, type: Z-tau  is: -1.963
#>
#>            aux. Z statistics
#> Z-tau-mu             -0.7713
#> Z-tau-beta            2.4426
#>
#> Critical values for Z statistics:
#>                      1pct      5pct     10pct
#> critical values -4.016497 -3.437891 -3.142926
```

```
summary(ur.kpss(y, type = "tau", lags = "long"))
```

```
#>
#> ########################
#> # KPSS Unit Root Test #
#> ########################
#>
#> Test is of type: tau with 13 lags.
#>
#> Value of test-statistic is: 0.0822
#>
#> Critical value for a significance level of:
#>                 10pct  5pct 2.5pct  1pct
#> critical values 0.119 0.146  0.176 0.216
```

(b) Constante e tendência

Cada versão do ADF compara hipóteses diferentes (Mattos, 2019, seção 2.2):

- **constante e tendência:** H_0 DS (tendência determinística mais estocástica) contra H_1 TS (só determinística); as duas são não estacionárias;
- **só constante:** H_0 I(1) contra H_1 estacionária em torno de uma média;
- **nada:** H_0 I(1) contra H_1 estacionária com média zero.

A versão se escolhe pelo gráfico: y cresce, então constante e tendência. Os p-valores vêm de MacKinnon (`punitroot`).

```
tau <- c(tau3 = adf_ct@teststat[1, "tau3"],
         tau2 = ur.df(y, type = "drift", lags = 13, selectlags = "AIC")@teststat[1, "tau2"],
         tau1 = ur.df(y, type = "none",  lags = 13, selectlags = "AIC")@teststat[1, "tau1"])
rbind(tau, p = c(punitroot(tau[1], trend = "ct"), punitroot(tau[2], trend = "c"),
 ↪  punitroot(tau[3], trend = "nc")))
```

```
#>           tau3      tau2      tau1
#> tau -2.3567094 -1.010274 3.9350441
#> p    0.4025205  0.751864 0.9999843
```

Resposta. Nenhuma versão rejeita. Na versão com tendência, isso quer dizer que a série é **DS**: $y_t = y_0 + \alpha t + \sum_{j \le t} u_j$, uma tendência determinística (o drift, a inflação média) mais uma estocástica. Sem determinísticos, τ_1 é positivo: o teste confunde a tendência omitida com explosividade.

(c) Série diferenciada e diferença sazonal

```
summary(ur.df(dy, type = "drift", lags = 13, selectlags = "AIC"))@teststat
```

```
#>                tau2     phi1
#> statistic -5.159213 13.31178
```

```
kpss.test(dy)                          # H0: estacionária
```

```
#>
#>  KPSS Test for Level Stationarity
#>
#> data:  dy
#> KPSS Level = 0.16442, Truncation lag parameter = 4, p-value = 0.1
```

Para D, segue-se Mattos (2019, seção 2.6): o ADF com 11 dummies sazonais **centradas** na regressão auxiliar (Dickey-Miller). As dummies captam a sazonalidade determinística, e τ mantém os críticos do ADF.

```
adf_saz <- function(x, tendencia, pmax = 13) {
  dx <- diff(x); m <- cycle(dx); idx <- (pmax + 1):length(dx)
  DC <- sapply(1:11, function(j) ifelse(m == j, 1 - 1 / 12, -1 / 12)); colnames(DC) <-
 ↪  paste0("DC", 1:11)
  ajuste <- function(p) {
    X <- cbind(nivel = as.numeric(x)[idx], DC[idx, ])
    if (p > 0) X <- cbind(X, sapply(1:p, function(j) as.numeric(dx)[idx - j]))
    if (tendencia) X <- cbind(X, tt = idx)
    lm(as.numeric(dx)[idx] ~ X)
  }
  p <- which.min(sapply(0:pmax, function(k) BIC(ajuste(k)))) - 1
  cf <- summary(ajuste(p))$coefficients
  c(tau = cf["Xnivel", "t value"], defasagens = p, dummies_signif = sum(cf[grepl("^XDC",
   ↪  rownames(cf)), 4] < 0.05))
}
```

```
rbind(y = adf_saz(y, TRUE), dy = adf_saz(dy, FALSE))
```

```
#>          tau defasagens dummies_signif
#> y  -2.207251          2              4
#> dy -6.743067          0              3
```

```
acf(dy, lag.max = 36, plot = FALSE)$acf[c(13, 25, 37)]   # FAC de Δy em 12, 24, 36
```

```
#> [1]  0.21609575 -0.03133938  0.01758861
```

Resposta. Em Δy, o ADF rejeita com folga e o KPSS não rejeita: $d = 1$. Com as dummies, o nível continua sem rejeitar ($-2{,}21$ contra $-3{,}43$) e Δy continua rejeitando; várias dummies são significativas, logo a sazonalidade é determinística. A FAC sazonal de Δy cai logo (0,22 em 12, quase zero em 24 e 36), sem o decaimento lento de uma raiz sazonal: $D = 0$.

(d) DS ou TS?

No nível, ADF e PP não rejeitam a raiz unitária, e o KPSS também não rejeita a estacionariedade: os dados são pouco informativos. O DF-GLS (Mattos, 2019, seção 2.4), mais potente contra alternativas persistentes, também não rejeita:

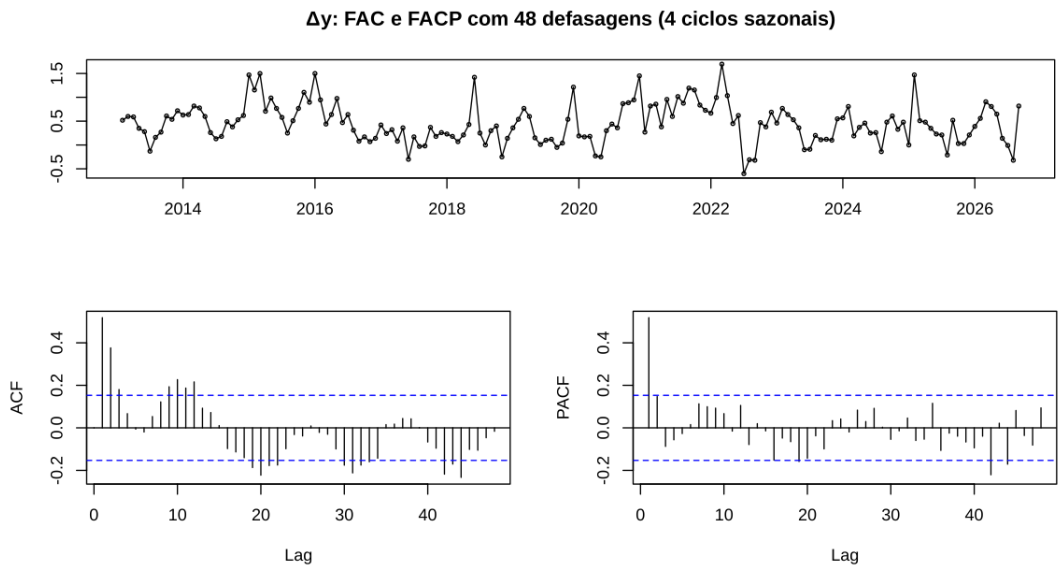
```
summary(ur.ers(y, type = "DF-GLS", model = "trend", lag.max = 1))   # 1 defasagem, a do ADF
 ↪  por BIC
```

```
#>
#> ###############################################
#> # Elliot, Rothenberg and Stock Unit Root Test #
#> ###############################################
#>
#> Test of type DF-GLS
#> detrending of series with intercept and trend
#>
#>
#> Call:
#> lm(formula = dfgls.form, data = data.dfgls)
#>
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#> -1.06159 -0.18542 -0.00639  0.17683  1.23612
#>
#> Coefficients:
#>              Estimate Std. Error t value Pr(>|t|)
#> yd.lag       -0.01776    0.01042  -1.704   0.0902 .
#> yd.diff.lag1  0.53237    0.06719   7.923  3.6e-13 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 0.3516 on 161 degrees of freedom
#> Multiple R-squared:  0.2833, Adjusted R-squared:  0.2744
#> F-statistic: 31.82 on 2 and 161 DF,  p-value: 2.261e-12
#>
#>
#> Value of test-statistic is: -1.7044
#>
#> Critical values of DF-GLS are:
#>                  1pct  5pct 10pct
#> critical values -3.46 -2.93 -2.64
```

Adota-se DS ($d = 1$). As razões:

1. Todos os testes de raiz unitária (ADF com e sem dummies, PP, DF-GLS) apontam DS.
2. O KPSS tem pouco poder em amostra curta.
3. Sob metas de inflação, o nível de preços não volta a uma trajetória fixa.
4. A Q5 mostra que Δy não tem MA unitário, que seria o sinal de diferenciação em excesso. # Questão 3 — FAC, FACP e candidatos

```
tsdisplay(dy, lag.max = 48, main = "Δy: FAC e FACP com 48 defasagens (4 ciclos sazonais)")
```




```
round(cbind(FAC = acf(dy, 13, plot = FALSE)$acf[-1], FACP = pacf(dy, 13, plot = FALSE)$acf),
 ↪  3)
```

```
#>          FAC   FACP
#>  [1,]  0.518  0.518
#>  [2,]  0.376  0.147
#>  [3,]  0.180 -0.087
#>  [4,]  0.067 -0.056
#>  [5,] -0.006 -0.027
#>  [6,] -0.019  0.015
#>  [7,]  0.053  0.113
#>  [8,]  0.122  0.099
#>  [9,]  0.193  0.093
#> [10,]  0.227  0.067
#> [11,]  0.187 -0.015
#> [12,]  0.216  0.105
#> [13,]  0.092 -0.078
```

Resposta (b).

- **Parte regular:** a FACP tem um pico claro em 1, e o valor em 2 fica no limite da banda (±0,15). A FAC decai: AR(1), com o AR(2) como alternativa.
- **Defasagem sazonal:** há um pico em 12 na FAC (dentro da banda na FACP). Ele cabe tanto num SAR(1) (decaimento em 12, 24, ...) quanto num SMA(1) (corte em 12).

(c) Candidatos, todos com $d = 1$, $D = 0$ e drift (a inflação média):

- **C1:** SARIMA(1,1,0)(1,0,0)$_{12}$;
- **C2:** SARIMA(1,1,0)(0,0,1)$_{12}$;
- **C3:** SARIMA(2,1,0)(1,0,0)$_{12}$. # Questão 4 — Estimação e seleção

```
C1 <- Arima(y, order = c(1, 1, 0), seasonal = c(1, 0, 0), include.drift = TRUE, method = "ML")
C2 <- Arima(y, order = c(1, 1, 0), seasonal = c(0, 0, 1), include.drift = TRUE, method = "ML")
C3 <- Arima(y, order = c(2, 1, 0), seasonal = c(1, 0, 0), include.drift = TRUE, method = "ML")
coeftest(C1); coeftest(C2); coeftest(C3)
```

```
#>
#> z test of coefficients:
#>
#>       Estimate Std. Error z value  Pr(>|z|)
#> ar1   0.506437   0.067211  7.5350 4.883e-14 ***
#> sar1  0.178301   0.077769  2.2927   0.02186 *
#> drift 0.453309   0.065131  6.9600 3.403e-12 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

#>
#> z test of coefficients:
#>
#>       Estimate Std. Error z value  Pr(>|z|)
#> ar1   0.503540   0.067696  7.4383 1.020e-13 ***
#> sma1  0.166043   0.074046  2.2424   0.02493 *
#> drift 0.453728   0.062445  7.2661 3.701e-13 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

#>
#> z test of coefficients:
#>
#>       Estimate Std. Error z value  Pr(>|z|)
#> ar1   0.441476   0.078072  5.6547 1.561e-08 ***
#> ar2   0.125824   0.079049  1.5917   0.11145
#> sar1  0.165444   0.078553  2.1061   0.03519 *
#> drift 0.452989   0.072444  6.2530 4.027e-10 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
tab <- rbind(C1 = c(C1$nobs, C1$sigma2, C1$loglik, C1$aic, C1$bic),
             C2 = c(C2$nobs, C2$sigma2, C2$loglik, C2$aic, C2$bic),
             C3 = c(C3$nobs, C3$sigma2, C3$loglik, C3$aic, C3$bic))
colnames(tab) <- c("n efetivo", "sigma2", "logLik", "AIC", "BIC")
round(tab, 3)
```

```
#>    n efetivo sigma2  logLik     AIC     BIC
#> C1       164  0.126 -58.809 125.618 138.017
#> C2       164  0.126 -58.983 125.966 138.366
#> C3       164  0.125 -57.552 125.104 140.603
```

(b) $n = T - d - sD = 165 - 1 = 164$ nos três modelos.

(c) A comparação é **válida**: os três modelos têm a mesma variável, o mesmo d e o mesmo D, logo a mesma amostra efetiva. Com d diferente, a verossimilhança seria de outra série, e o AIC deixaria de ser comparável.

(d) O R conta $\hat{\sigma}^2$ em k, como mostra a conta à mão:

```
k <- length(coef(C1)) + 1                    # coeficientes + sigma2
c(AIC_manual = -2 * C1$loglik + 2 * k, AIC_R = C1$aic)
```

```
#> AIC_manual      AIC_R
#>   125.6178   125.6178
```

(e) O AIC escolhe **C3** e o BIC escolhe **C1**: o BIC pune mais cada parâmetro ($\ln n \approx 5{,}1$ contra 2).

- O BIC é **consistente**: escolhe o modelo verdadeiro, se ele estiver entre os candidatos, com probabilidade que tende a 1.
- O AIC é **eficiente** para prever.

O objetivo aqui é prever (Q7), o que favorece o AIC. Mas a vantagem do C3 é de só 0,5 ponto de AIC e vem de um ϕ_2 não significativo:

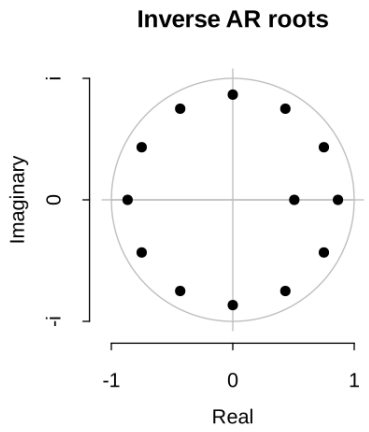
```
coeftest(C3)["ar2", ]
```

```
#>   Estimate Std. Error    z value   Pr(>|z|)
#> 0.12582411 0.07904902 1.59172253 0.11144706
```

Fica o **C1**, o mais parcimonioso (aula 02). A regra, fixada antes de olhar a validação: se AIC e BIC divergem, fica o modelo menor quando o parâmetro extra do maior não é significativo a 5%.

(f) Raízes inversas dentro do círculo unitário: o modelo é estacionário.

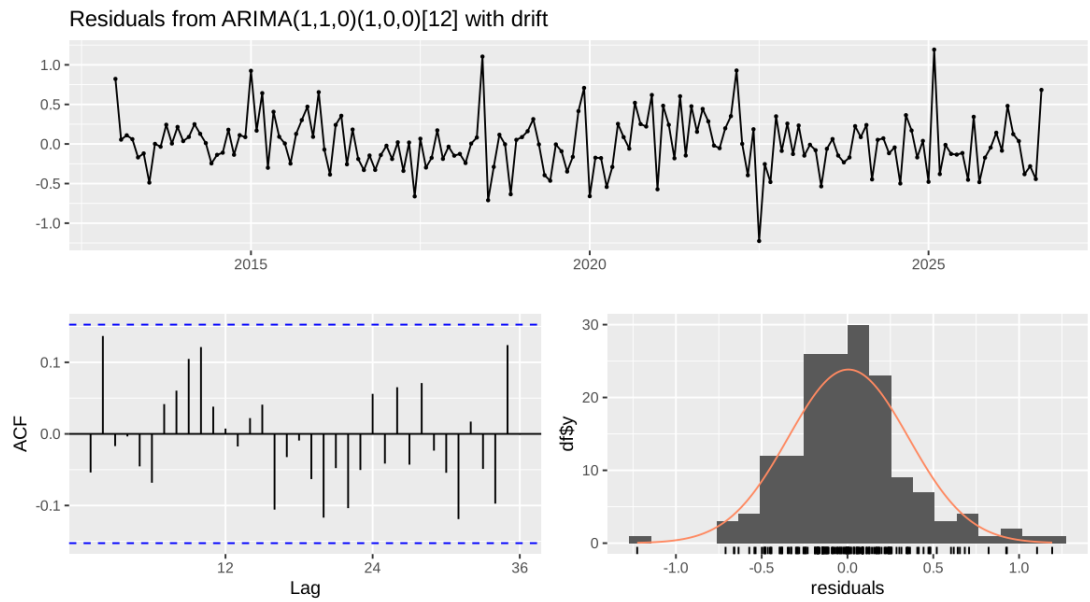
```
plot(C1)
```



A raiz inversa regular é $\hat{\phi} \approx 0{,}51$. As 12 sazonais têm módulo $\widehat{\Phi}^{1/12} \approx 0{,}87$: um $\widehat{\Phi}$ pequeno vira raízes inversas de módulo alto, mas ainda dentro do círculo. # Questão 5 — Diagnóstico

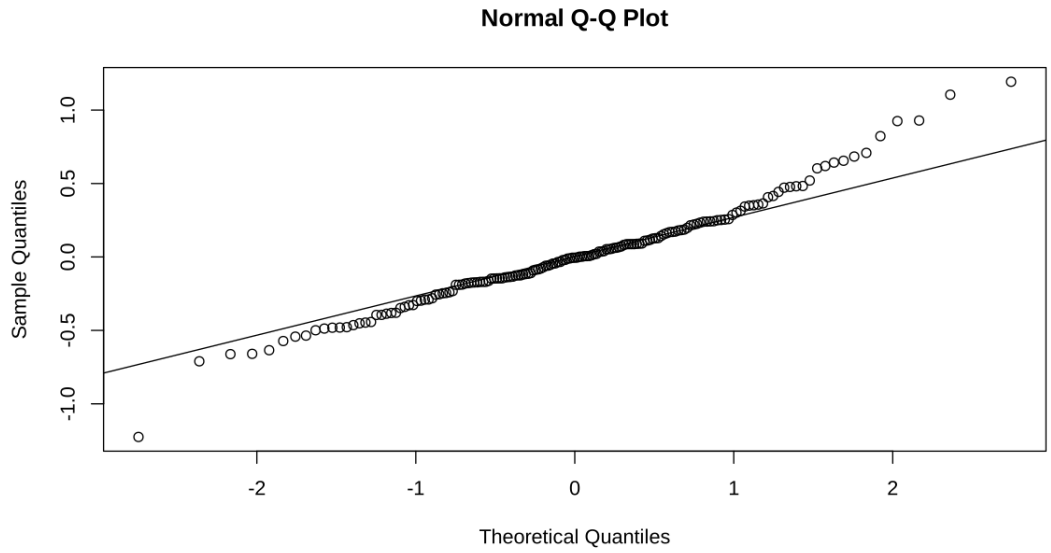
(a) O painel abaixo mostra os resíduos no tempo, a FAC e o histograma. O `checkresiduals` já roda o Ljung-Box com os graus de liberdade corrigidos. O QQ-plot vem em seguida.

```
checkresiduals(C1, lag = 24)
```




```
#>
#>  Ljung-Box test
#>
#> data:  Residuals from ARIMA(1,1,0)(1,0,0)[12] with drift
#> Q* = 20.318, df = 22, p-value = 0.5632
#>
#> Model df: 2.   Total lags used: 24
```

```
qqnorm(residuals(C1)); qqline(residuals(C1))
```



(b) e (c) Os testes. No Ljung-Box, $v = K - (p + q + P + Q) = 24 - 2 = 22$.

```
Box.test(residuals(C1), lag = 24, type = "Ljung-Box", fitdf = 2)
```

```
#>
#>  Box-Ljung test
#>
#> data:  residuals(C1)
#> X-squared = 20.318, df = 22, p-value = 0.5632
```

```
jarque.bera.test(residuals(C1))
```

```
#>
#>  Jarque Bera Test
#>
#> data:  residuals(C1)
#> X-squared = 18.121, df = 2, p-value = 0.0001162
```

```
ArchTest(residuals(C1), lags = 12)
```

```
#>
#>  ARCH LM-test; Null hypothesis: no ARCH effects
#>
#> data:  residuals(C1)
#> Chi-squared = 5.9531, df = 12, p-value = 0.9184
```

Resposta.

- **Ljung-Box:** não rejeita; os resíduos são ruído branco.
- **ARCH-LM:** não rejeita; não há heterocedasticidade condicional.
- **Jarque-Bera: rejeita** a normalidade, por caudas pesadas.

(d) O diagnóstico de autocorrelação não falhou. A não normalidade vem de choques pontuais (greve dos caminhoneiros em 2018, corte de tributos em 2022, bônus de Itaipu em 2025). Ela afeta os intervalos de previsão, mas não a consistência do estimador. Modelos sem o AR(1) foram descartados, porque deixam autocorrelação nos resíduos (Ljung-Box rejeita).

Estabilidade (aula 03). Chow com a quebra fixada antes (mar/2020) e CUSUM dos resíduos recursivos, na versão de MQO do C1 (Δy_t em Δy_{t-1}, Δy_{t-12} e Δy_{t-13}):

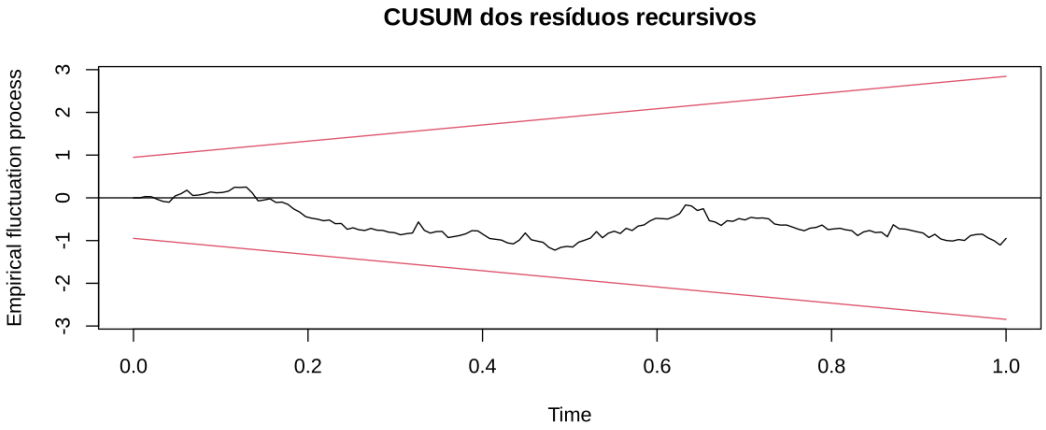
```
dyv <- as.numeric(dy); nn <- length(dyv)
df_ols <- data.frame(dy = dyv[14:nn], l1 = dyv[13:(nn - 1)], l12 = dyv[2:(nn - 12)], l13 =
 ↪  dyv[1:(nn - 13)])
TB <- which(abs(time(dy)[14:nn] - (2020 + 2 / 12)) < 1e-6)
sctest(dy ~ ., data = df_ols, type = "Chow", point = TB - 1)
```

```
#>
#>  Chow test
#>
#> data:  dy ~ .
#> F = 0.4573, p-value = 0.7669
```

```
cusum <- efp(dy ~ ., data = df_ols, type = "Rec-CUSUM")
sctest(cusum)
```

```
#>
#>  Recursive CUSUM test
#>
#> data:  cusum
#> S = 0.62251, p-value = 0.3716
```

```
plot(cusum, main = "CUSUM dos resíduos recursivos")
```



Nenhum dos dois rejeita: os coeficientes são estáveis na janela de 13 anos.

(e) Sobreajuste: um AR e um MA a mais.

```
coeftest(Arima(y, order = c(2, 1, 0), seasonal = c(1, 0, 0), include.drift = TRUE, method =
 ↪  "ML"))["ar2", ]
```

```
#>   Estimate Std. Error    z value   Pr(>|z|)
#> 0.12582411 0.07904902 1.59172253 0.11144706
```

```
coeftest(Arima(y, order = c(1, 1, 1), seasonal = c(1, 0, 0), include.drift = TRUE, method =
 ↪  "ML"))["ma1", ]
```

```
#>   Estimate Std. Error    z value   Pr(>|z|)
#> -0.1732418  0.1258123 -1.3769865  0.1685164
```

Resposta. Nenhum dos coeficientes extras é significativo, então a especificação está adequada. O MA extra fica longe de -1, o que confirma que Δy não foi sobrediferenciada. # Questão 6 — Sobrediferenciação ($d^* + 1 = 2$)

```
D2  <- Arima(y, order = c(1, 2, 0), seasonal = c(1, 0, 0), method = "ML")   # mesmas ordens
D2m <- Arima(y, order = c(1, 2, 1), seasonal = c(1, 0, 0), method = "ML")   # com um MA a mais
coeftest(D2m)
```

```
#>
#> z test of coefficients:
#>
#>       Estimate Std. Error  z value  Pr(>|z|)
#> ar1   0.515253   0.068065   7.5700 3.733e-14 ***
#> ma1  -1.000000   0.022023 -45.4079 < 2.2e-16 ***
#> sar1  0.184267   0.078266   2.3544   0.01855 *
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
abs(polyroot(c(1, coef(D2m)["ma1"])))                 # raiz do MA
```

```
#> [1] 1
```

```
c(sigma2_d1 = C1$sigma2, sigma2_d2 = D2$sigma2, sigma2_d2_MA = D2m$sigma2)
```

```
#>    sigma2_d1    sigma2_d2 sigma2_d2_MA
#>    0.1258763    0.1508776    0.1308745
```

```
c(rho1_d1 = acf(residuals(C1), plot = FALSE)$acf[2], rho1_d2 = acf(residuals(D2), plot =
 ↪  FALSE)$acf[2],
  rho1_serie_d2 = acf(diff(dy), plot = FALSE)$acf[2])
```

```
#>       rho1_d1       rho1_d2 rho1_serie_d2
#>   -0.05386913   -0.04942052   -0.33881841
```

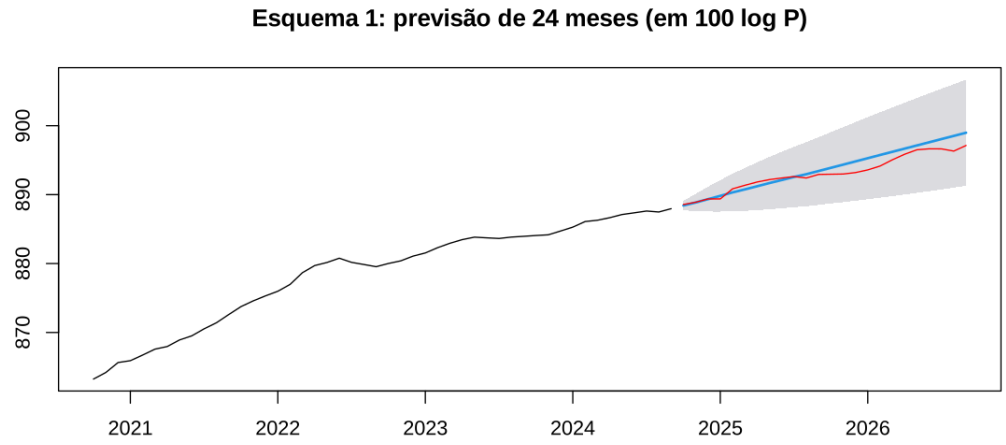
Resposta.

- **(a)** $\hat{\theta} \approx -1$ (na convenção da lista, $\theta = 1$). A raiz do MA é 1, **sobre o círculo unitário**: o modelo fica não invertível.
- **(b)** $\hat{\sigma}^2$ aumenta com a diferença extra, cerca de 20% sem o MA.
- **(c)** A série $\Delta^2 y$ tem ρ_1 negativo, perto de $-(1-\phi)/2$. No modelo, o AR troca de sinal para absorver esse ρ_1.
- **(d)** Os sinais práticos de sobrediferenciação: MA perto de -1, AR que troca de sinal, $\rho_1 \approx -0{,}5$ e σ^2 que sobe. # Questão 7 — Previsão fora da amostra

O treino vai até $T_0 = T - 24$, e os 24 meses finais são a validação. As métricas são calculadas no índice $P = e^{y/100}$.

```
T0 <- length(y) - 24
y_treino <- window(y, end = time(y)[T0])
P_treino <- window(P, end = time(P)[T0])
P_teste  <- window(P, start = time(P)[T0 + 1])
fit <- Arima(y_treino, order = c(1, 1, 0), seasonal = c(1, 0, 0), include.drift = TRUE, method
 ↪  = "ML")   # C1

# Esquema 1: origem fixa, h = 1..24, com IC de 95%
prev1 <- forecast(fit, h = 24, level = 95)
plot(prev1, include = 48, main = "Esquema 1: previsão de 24 meses (em 100 log P)")
lines(window(y, start = time(y)[T0 + 1]), col = "red")
```




```
# Esquema 2: um passo à frente, SEM reestimar (mesmos coeficientes do treino)
prev2 <- window(fitted(Arima(y, model = fit)), start = time(y)[T0 + 1])

# Benchmarks no índice: passeio aleatório e sazonal ingênuo
rw1 <- naive(P_treino, h = 24)$mean                                  # origem fixa
sn1 <- snaive(P_treino, h = 24)$mean
rw2 <- window(stats::lag(P, -1), start = start(P_teste), end = end(P_teste))    # um passo:
 ↪  P_{t-1}
```

```
sn2 <- window(stats::lag(P, -12), start = start(P_teste), end = end(P_teste))   # um passo:
 ↪  P_{t-12}

metricas <- c("RMSE", "MAE", "MAPE")
rbind("SARIMA, esquema 1"            = accuracy(exp(prev1$mean / 100), P_teste)[, metricas],
      "SARIMA, esquema 2"            = accuracy(exp(prev2 / 100), P_teste)[, metricas],
      "Passeio aleatório, esquema 1" = accuracy(rw1, P_teste)[, metricas],
      "Passeio aleatório, esquema 2" = accuracy(rw2, P_teste)[, metricas],
      "Sazonal ingênuo, esquema 1"   = accuracy(sn1, P_teste)[, metricas],
      "Sazonal ingênuo, esquema 2"   = accuracy(sn2, P_teste)[, metricas])
```

```
#>                                  RMSE       MAE      MAPE
#> SARIMA, esquema 1              81.54227  65.94999 0.8611550
#> SARIMA, esquema 2              30.69034  22.38202 0.2957467
#> Passeio aleatório, esquema 1 425.13541 379.63083 4.9583361
#> Passeio aleatório, esquema 2  40.88458  32.23250 0.4259191
#> Sazonal ingênuo, esquema 1   525.33598 501.93250 6.5949984
#> Sazonal ingênuo, esquema 2   328.65202 326.97292 4.3288906
```

```
# (g) cobertura do IC de 95% do esquema 1
mean(P_teste >= exp(prev1$lower / 100) & P_teste <= exp(prev1$upper / 100))
```

```
#> [1] 1
```

Resposta.

- **(f)** O SARIMA supera o passeio aleatório e o sazonal ingênuo nos dois esquemas e nas três métricas. O sazonal ingênuo vai muito mal porque, no índice, ele repete o nível de 12 meses antes, sem a inflação do ano. O modelo não foi alterado em função desses resultados.
- **(g)** Todas as 24 observações caíram dentro do IC de 95% do esquema 1: a cobertura empírica (100%) é maior que a nominal. O intervalo de um modelo integrado se abre com h, e os 24 erros de uma única origem são correlacionados entre si.

Versões do software (exigidas na entrega):

```
sessionInfo()
```

```
#> R version 4.3.3 (2024-02-29)
#> Platform: x86_64-pc-linux-gnu (64-bit)
#> Running under: Ubuntu 24.04.5 LTS
#>
#> Matrix products: default
#> BLAS:   /usr/lib/x86_64-linux-gnu/blas/libblas.so.3.12.0
#> LAPACK: /usr/lib/x86_64-linux-gnu/lapack/liblapack.so.3.12.0
#>
#> locale:
#>  [1] LC_CTYPE=C.UTF-8       LC_NUMERIC=C           LC_TIME=C.UTF-8
#>  [4] LC_COLLATE=C.UTF-8     LC_MONETARY=C.UTF-8    LC_MESSAGES=C.UTF-8
#>  [7] LC_PAPER=C.UTF-8       LC_NAME=C              LC_ADDRESS=C
#> [10] LC_TELEPHONE=C         LC_MEASUREMENT=C.UTF-8 LC_IDENTIFICATION=C
#>
#> time zone: Etc/UTC
#> tzcode source: system (glibc)
#>
#> attached base packages:
#> [1] stats     graphics  grDevices utils     datasets  methods   base
#>
#> other attached packages:
#> [1] strucchange_1.5-3 sandwich_3.1-0    FinTS_0.4-9       lmtest_0.9-40
#> [5] zoo_1.8-12        urca_1.3-3        tseries_0.10-55   forecast_8.21.1
```

```
#>
#> loaded via a namespace (and not attached):
#>  [1] utf8_1.2.4        generics_0.1.3    lattice_0.22-5    digest_0.6.34
#>  [5] magrittr_2.0.3    evaluate_0.23     grid_4.3.3        fastmap_1.1.1
#>  [9] nnet_7.3-19       tinytex_0.49      fansi_1.0.5       scales_1.3.0
#> [13] cli_3.6.2         rlang_1.1.3       munsell_0.5.0     withr_2.5.0
#> [17] yaml_2.3.8        tools_4.3.3       parallel_4.3.3    dplyr_1.1.4
#> [21] colorspace_2.1-0  ggplot2_3.4.4     curl_5.2.0        vctrs_0.6.5
#> [25] R6_2.5.1          lifecycle_1.0.4   pkgconfig_2.0.3   pillar_1.9.0
#> [29] gtable_0.3.4      glue_1.7.0        quantmod_0.4.26   Rcpp_1.0.12
#> [33] highr_0.10        xfun_0.41         tibble_3.2.1      tidyselect_1.2.0
#> [37] knitr_1.45        farver_2.1.1      htmltools_0.5.7   nlme_3.1-164
#> [41] rmarkdown_2.25    xts_0.13.2        labeling_0.4.3    timeDate_4032.109
#> [45] fracdiff_1.5-3    compiler_4.3.3    quadprog_1.5-8    TTR_0.24.4
```