Séries temporais

Volume 6

Lista comentada: Q1–Q16 passo a passo na notação dos slides

Caderno de estudo · parte 1: ARMA, ARIMA e SARIMA

Prof. Guilherme Pereira · Econometria II (PPGEco/UFES)

Gerado em 27/10/2026 a partir de `github.com/fcarva/series-temporais` (commit `caf5a2e`). Material autoral: enunciados parafraseados, demonstrações próprias, números conferidos em R contra os scripts do repositório.

Sumário

I Como usar, notação e caixa de ferramentas **1**

1 Lista comentada: as 16 questões, passo a passo, na notação dos slides **2**

II Bloco 1 — Processos e momentos **7**

2 Q1 · Momentos do passeio aleatório com drift **8**

3 Q2 · Passeio com drift e tendência determinística **12**

4 Q3 · FAC de $z_{3t} = z_{1t} + 2z_{2t}$ **15**

5 Q4 · Teorema de Wold **18**

III Bloco 2 — AR, MA e ARMA **21**

6 Q5 · Três modelos: operador, classificação, raízes, ψ_j e π_j **22**

7 Q6 · ARMA(1,1) **25**

8 Q7 · AR(2): Yule-Walker e variância **29**

9 Q8 · Verdadeiro ou falso, com demonstração **33**

IV Bloco 3 — Integrados, ARIMA e SARIMA **37**

10 Q9 · Sobrediferenciação: diferenciar um AR(1) que já é estacionário **38**

11 Q10 · ARIMA, raiz unitária e tendência determinística **41**

12 Q11 · SAR(1)$_4$ e o multiplicativo como AR(5) restrito **44**

13 Q12 · SARIMA$(1,1,0)(0,1,1)_4$ trimestral **47**

V Blocos 4 a 6 — Estimação, previsão e aplicação **51**

14 Q13 · Log-verossimilhança condicional do AR(1) e o estimador de MQO **52**

15 Q14 · AIC e BIC **55**

16 Q15 · Previsão em ARMA(p,q) **58**

17 Q16 · SARIMA$(1,1,1)(0,1,1)_{12}$ com 240 observações mensais **62**

Parte I

Como usar, notação e caixa de ferramentas

CAPÍTULO 1

Lista comentada: as 16 questões, passo a passo, na notação dos slides

Cada questão da lista "Processos ARMA, ARIMA e SARIMA" tem aqui uma nota própria, com **todas as passagens**, inclusive as de álgebra elementar: Bhaskara, soma de série geométrica, quadrado de uma soma, multiplicação de polinômios termo a termo. A notação é **a dos slides do professor** (AU01–AU03). Cada nota junta quatro fontes:

- a lista;
- o slide que sustenta cada passo, com a página;
- o livro que aprofunda;
- o que está no **meu caderno**, com as correções onde ele errou.

Todos os números estão em lista_comentada.R (id `lc`) e são conferidos pelo build.

Bloco	Questões
1. Processos e momentos	Q1 · Q2 · Q3 · Q4
2. AR, MA e ARMA	Q5 · Q6 · Q7 · Q8
3. Integrados, ARIMA e SARIMA	Q9 · Q10 · Q11 · Q12
4. Estimação e seleção	Q13 · Q14
5. Previsão	Q15
6. Aplicação	Q16

Para treinar com outros números, use o banco de variações e os simulados.

1. Da lista para os slides

A lista e os slides usam convenções diferentes para o MA. **A prova sai da lista**, então cada nota começa traduzindo o enunciado e termina escrevendo o resultado também no sinal da lista.

Objeto	Slides (AU01–AU03)	Lista
Operador de defasagem	L, com $L^i y_t = y_{t-i}$ (AU02, p. 11)	B
Ruído branco	$\varepsilon_t \sim RB(0, \sigma^2)$	a_t, ε_t ou u_t
Polinômio AR	$\phi_p(L) = 1 - \phi_1 L - \cdots - \phi_p L^p$ (AU02, p. 12)	igual, com B
Polinômio MA	$\theta_q(L) = 1 + \theta_1 L + \cdots + \theta_q L^q$, **sinal positivo** (AU02, p. 13)	$\theta(B) = 1 - \theta_1 B - \cdots$, **sinal negativo** (exceto Q8)
Pesos MA(∞)	$y_t = \mu + \Psi(L)\varepsilon_t$, com $\psi_0 = 1$ (AU02, p. 16)	ψ_j
Pesos AR(∞)	$\pi(L)\tilde{y}_t = \varepsilon_t$, com $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots$ (AU02, p. 19)	igual
Passeio com drift e tendência	$Y_t = \alpha_1 + Y_{t-1} + \alpha_2 t + \varepsilon_t$ (AU01, p. 30)	$y_t = c + \delta t + y_{t-1} + u_t$
Informação até t	Ω_t	$\mathcal{F}_T$
Previsão e erro	$\hat{y}_{t+k/t} = E(y_{t+k} \mid \Omega_t)$; $e_{t+k/t} = y_{t+k} - \hat{y}_{t+k/t}$ (AU02, p. 72–75)	$y_{T+h\|T}$; $e_T(h)$
Variância	$V(\cdot)$	Var$(\cdot)$

Objeto	Slides (AU01–AU03)	Lista

A regra de tradução do MA

Se a lista escreve $a_t - \theta a_{t-1}$, nos slides isso é $\varepsilon_t + \theta^s \varepsilon_{t-1}$ com

$$\theta^s = -\theta^{\text{lista}}.$$

Toda fórmula dos slides vira a da lista trocando $\theta \to -\theta$. Exemplo: $\rho_1 = \frac{\theta}{1+\theta^2}$ (slides, AU02, p. 47) vira $\rho_1 = \frac{-\theta}{1+\theta^2}$ (lista).

2. Caixa de ferramentas

Ferramentas que aparecem em quase toda questão, demonstradas **uma vez** aqui. Nas notas, cada passo cita a ferramenta pelo id: [F1], [F2]…

F1 · Bhaskara, as raízes e o módulo

Enunciado. As raízes de $az^2 + bz + c = 0$, com $a \neq 0$, são

$$z = \frac{-b \pm \sqrt{\Delta}}{2a}, \qquad \Delta = b^2 - 4ac.$$

Demonstração (completar o quadrado).

1. Divida tudo por a: $z^2 + \frac{b}{a}z + \frac{c}{a} = 0$.
2. Some e subtraia $\left(\frac{b}{2a}\right)^2$: $\left(z + \frac{b}{2a}\right)^2 - \frac{b^2}{4a^2} + \frac{c}{a} = 0$.
3. Isole o quadrado: $\left(z + \frac{b}{2a}\right)^2 = \frac{b^2-4ac}{4a^2} = \frac{\Delta}{4a^2}$.
4. Tire a raiz dos dois lados: $z + \frac{b}{2a} = \pm\frac{\sqrt{\Delta}}{2a}$, logo $z = \frac{-b\pm\sqrt{\Delta}}{2a}$.

Três casos.

- $\Delta > 0$: duas raízes reais distintas.
- $\Delta = 0$: uma raiz real dupla, $z = -b/(2a)$.
- $\Delta < 0$: duas raízes complexas conjugadas, $z = \frac{-b}{2a} \pm i\frac{\sqrt{-\Delta}}{2a}$, com $i = \sqrt{-1}$.

Módulo de um complexo. Para $z = h + vi$, $|z| = \sqrt{h^2 + v^2}$. As duas conjugadas $h \pm vi$ têm **o mesmo módulo**.

Atalho (Vieta). O produto das raízes é $z_1 z_2 = c/a$. Para conjugadas, $z_1 z_2 = |z|^2$, logo $|z| = \sqrt{c/a}$.

Para que serve. Estacionariedade (raízes de $\phi(z)$) e invertibilidade (raízes de $\theta(z)$) exigem $|z| > 1$ (AU02, p. 27 e 33). Na revisão de equações a diferenças (EQD, p. 24–26), a mesma fórmula aparece para a equação característica $b^2 + a_1 b + a_2 = 0$.

Raízes z ou autovalores λ? Fora ou dentro?

AU02, p. 28: as raízes de $\phi(z) = 1 - \phi_1 z - \phi_2 z^2$ devem ficar **fora** do círculo, $|z| > 1$. As raízes de $\lambda^2 - \phi_1\lambda - \phi_2 = 0$, que são os autovalores da matriz F (p. 40), devem ficar **dentro**, $|\lambda| < 1$. São a mesma condição, porque $\lambda = 1/z$. Escreva sempre qual das duas você está usando.

F2 · Série geométrica

Para $r \neq 1$, $S_n = \sum_{j=0}^{n-1} r^j = \frac{1-r^n}{1-r}$.

Demonstração.

1. $S_n = 1 + r + \cdots + r^{n-1}$.
2. $rS_n = r + r^2 + \cdots + r^n$.
3. Subtraindo, os termos do meio cancelam: $S_n - rS_n = 1 - r^n$, logo $S_n = \frac{1-r^n}{1-r}$.
4. Se $|r| < 1$, então $r^n \to 0$ e $\sum_{j\geq 0} r^j = \frac{1}{1-r}$. Se $|r| \geq 1$, a série não converge.

É o que permite escrever $(1-\phi L)^{-1} = 1 + \phi L + \phi^2 L^2 + \cdots$ quando $|\phi| < 1$ (AU02, p. 11 e 21) e $\sum \phi^{2j} = \frac{1}{1-\phi^2}$.

F3 · Soma dos primeiros inteiros

$\sum_{s=1}^{t} s = \frac{t(t+1)}{2}$.

Demonstração (Gauss). Escreva a soma duas vezes, uma em ordem crescente e outra em decrescente, e some coluna a coluna. Cada coluna dá $t+1$, e são t colunas: $2S = t(t+1)$. Aparece na tendência do passeio com drift e tendência (Q2 e Q8). Exemplo: $\sum_{s=1}^{10} s = 55$.

F4 · Linearidade da esperança

$E(a + bX + cY) = a + bE(X) + cE(Y)$ para constantes a, b e c. Constantes saem da esperança: $E(c) = c$. **Não** vale $E(XY) = E(X)E(Y)$ em geral. Isso só vale quando X e Y são não correlacionados.

F5 · Variância e covariância de combinações lineares

- $V(aX + bY) = a^2V(X) + b^2V(Y) + 2ab\,\mathrm{Cov}(X, Y)$.
- $\mathrm{Cov}\left(\sum_i a_i X_i, \sum_j b_j Y_j\right) = \sum_i \sum_j a_i b_j \,\mathrm{Cov}(X_i, Y_j)$.

Com ruído branco, $E(\varepsilon_i \varepsilon_j) = \sigma^2$ se $i = j$ e 0 se $i \neq j$. Num produto de duas somas de choques, **só sobrevivem os termos com o mesmo índice**. A constante sai **ao quadrado** da variância.

F6 · Causalidade: o choque de hoje não conversa com o passado

Num processo estacionário escrito como $y_t = \mu + \sum_{j\geq 0} \psi_j \varepsilon_{t-j}$, o valor y_{t-k} só depende de $\varepsilon_{t-k}, \varepsilon_{t-k-1}, \ldots$ Logo:

$$E\big(\varepsilon_t(y_{t-k} - \mu)\big) = 0 \;\; (k \geq 1), \qquad E\big(\varepsilon_t(y_t - \mu)\big) = \psi_0\sigma^2 = \sigma^2, \qquad E\big(\varepsilon_{t-1}(y_t - \mu)\big) = \psi_1\sigma^2.$$

No ARMA(1,1) dos slides, $\psi_1 = \phi_1 + \theta_1$. É o "momento auxiliar" da AU02, p. 83, e do meu caderno de 02/09.

F7 · Igualar coeficientes (inverter um polinômio em L)

Se $\Psi(L)\phi(L) = \theta(L)$, os coeficientes de cada potência L^j são iguais dos dois lados. Isso dá os ψ_j por recursão:

$$\psi_j = \phi_1\psi_{j-1} + \cdots + \phi_p\psi_{j-p} + \theta_j \qquad (\psi_0 = 1;\ \psi_{\text{negativo}} = 0;\ \theta_j = 0 \text{ se } j > q).$$

Os π_j saem do mesmo jeito, de $\pi(L)\theta(L) = \phi(L)$.

F8 · Multiplicar polinômios em L

Distributiva termo a termo, somando expoentes: $L^a \cdot L^b = L^{a+b}$. Exemplo:

$$(1-\phi L)(1-L) = 1 - L - \phi L + \phi L^2 = 1 - (1+\phi)L + \phi L^2.$$

F9 · Esperança condicional na previsão

Com a informação Ω_t (AU02, p. 54 e 72):

- o que é conhecido em t sai como está: $E(y_{t-j} \mid \Omega_t) = y_{t-j}$ e $E(\varepsilon_{t-j} \mid \Omega_t) = \varepsilon_{t-j}$ para $j \geq 0$;
- choque futuro tem esperança zero: $E(\varepsilon_{t+j} \mid \Omega_t) = 0$ para $j \geq 1$;
- y futuro vira a própria previsão: $E(y_{t+j} \mid \Omega_t) = \hat{y}_{t+j/t}$.

A **lei das expectativas iteradas** (LEI), $E\big(E(X \mid \Omega_t)\big) = E(X)$, fecha a prova do previsor ótimo (Q15).

3. O meu caderno e onde ele entra

As fotos do caderno (aulas de 13/08 a 10/09) ficam em `materiais/caderno/`, fora do git: o repositório é público. Cada nota transcreve o trecho que importa na seção "Do meu caderno". Quando o caderno tem erro, a nota mostra a correção.

Aula	Conteúdo no caderno	Questão
13/08	introdução, o que é série temporal, FAC e FACP, Spanos (1999)	Q3, Q4
19/08	momentos do passeio aleatório (média, variância, covariância)	Q1
19/08	passeio com drift e tendência; solução recursiva do AR(1); estável × instável	Q2, Q4
19/08	multiplicador dinâmico (demanda por moeda de Goldfeld)	Q4, Q6
20/08	notação em L; processo linear geral; pesos π; momentos condicionais × incondicionais	Q4, Q5
20/08	MA(1): média, variância e covariâncias condicionais e incondicionais	Q3, Q5
26/08	MA(2) e MA(q); previsão do MA; intervalo e EQM; verossimilhança do MA(1)	Q3, Q13, Q15
26/08	AR(1): média, variância com a decomposição A + B + C	Q4, Q9
02/09	ARMA(1,1): momentos auxiliares, γ_0, γ_k	Q6
02/09	AR(1) e AR(2): Yule-Walker; previsão do AR(1) e erro	Q7, Q15
03/09	condição de estacionariedade do AR(2); exemplo com Bhaskara e raízes complexas	Q7
03/09	MA(1) $\longrightarrow$ AR(∞); ARMA(1,2); par $\theta = 0{,}5$ e $\theta = 2$; forma F do AR(p)	Q4, Q5, Q7
09/09	desenho da FAC e da FACP do AR(2) e do MA(2); estabilidade e quebra estrutural	Q12, Q16
10/09	previsão iterada × direta; métricas (MAPE, MAD, RMSE, MASE)	Q15

Os erros do caderno que precisam ser desaprendidos

1. **19/08, AR(1) recursivo:** $y_2 = \phi^2 + \phi\varepsilon_1 + \varepsilon_2$. Falta o y_0; o certo é $\phi^2 y_0$. Na linha seguinte aparece y_0^2 no lugar de y_0. A fórmula final $y_t = \phi^t y_0 + \sum \phi^{t-i}\varepsilon_i$ está certa. Ver Q4.
2. **19/08:** "$E(XY) = E(X)E(Y)$" e "$\sigma^2 = E(X^2)$" valem só com X e Y não correlacionados e com média zero, respectivamente [F4]. Ver Q1.

3. **26/08, MA(2):** a esperança condicional mistura $E(y_t \mid \Omega_{t-1})$ com $E(y_{t+2} \mid \Omega_t)$, e há θ_3 no lugar de θ_2. Ver Q15.
4. **02/09, ARMA(1,1):** $\gamma_0 = \frac{\sigma^2(\theta_1+1+2\theta_1\phi_1)}{1-\phi_1^2}$ perdeu o quadrado, porque o certo é θ_1^2. Também $\gamma_k = \phi_1^k\gamma_1$ está errado; o certo é $\phi_1^{k-1}\gamma_1$. Ver Q6.
5. **03/09, AR(2)** $y_t = 1{,}5y_{t-1} - 0{,}6y_{t-2} + a_t$**:** o polinômio virou $1 - 1{,}5B - 0{,}6B^2$, quando o certo é $1 - 1{,}5B + 0{,}6B^2$. Daí Δ saiu com o sinal trocado, e os "módulos" 0,6 e 0,52 estão errados. As duas raízes conjugadas têm o mesmo módulo, $\sqrt{0{,}6} = 0{,}7746$. Ver Q7.
6. **03/09, MA(1) → AR(∞):** apareceu $+\theta_1^2\varepsilon_{t-2}$; o certo é $-\theta_1^2\varepsilon_{t-2}$, e os sinais alternam (AU02, p. 31). Ver Q4.

As referências "(32/83)" e "(35/83)" do caderno são da versão antiga dos slides. Na versão atual da AU02 (99 páginas), o EQM do MA(1) está na p. 57 e a verossimilhança condicional do MA(1) nas p. 58–59.

4. Livros

Os PDFs estão na pasta "Econometria II" do Drive; as citações são por capítulo.

Livro	Onde ajuda nesta lista
ENDERS (2014)	cap. 1: equações a diferenças, solução homogênea e particular, estabilidade (Q4, Q7); cap. 2: ARMA, FAC e FACP, Box-Jenkins, previsão, sazonalidade (Q5–Q16); cap. 4: tendências e raiz unitária (Q1, Q2, Q9, Q10)
HAMILTON (1994)	cap. 2: operador de defasagem e inversão de polinômios (Q4, Q5); cap. 3: momentos do ARMA, invertibilidade e o par $\theta \leftrightarrow 1/\theta$ (Q3–Q8); cap. 4: previsão ótima e Wold (Q4, Q15); cap. 5: MV exata e condicional do AR(1) (Q13)
BJRL (2016)	convenção de sinal da lista; cap. 3–4: modelos estacionários e não estacionários (Q5–Q10); cap. 5: previsão, com os pesos ψ (Q12, Q15); cap. 6–8: identificação, estimação e diagnóstico (Q13, Q14, Q16); cap. 9: modelos sazonais e o modelo das companhias aéreas (Q11, Q12, Q16)
TSAY (2010)	cap. 2: AR, MA, ARMA, previsão e critérios de informação em linguagem aplicada (Q6, Q7, Q14, Q15)
MAT (Mattos, 2019)	tendência determinística × estocástica, processo DS × TS, decomposição de Beveridge-Nelson (Q1, Q2, Q10)

Parte II

Bloco 1 — Processos e momentos

Q1 · Momentos do passeio aleatório com drift

← índice · resolução curta em 01_lista · próxima: Q2

O que a questão pede

Para um passeio aleatório com drift c, valor inicial $y_0 = 10$ e choques ruído branco:

- **calcular** a média, a variância e a autocovariância de ordem k;
- **dizer** se o processo é estacionário.

Da lista para os slides

Lista	Slides (AU01, p. 29)
$y_t = c + y_{t-1} + u_t$, $u_t \sim RB(0, \sigma^2)$, $y_0 = 10$	$Y_t = \alpha_1 + Y_{t-1} + \varepsilon_t$, $\varepsilon_t \sim RB(0, \sigma^2)$, $\alpha_1 = c$

Não há MA: nada muda de sinal. Abaixo, c é o drift e ε_t é o choque.

Ferramentas

- **Slides:** AU01, p. 28–29 (propriedades do passeio, com e sem drift) e p. 45–48 (as contas do passeio sem drift, que a Q1 generaliza); AU01, p. 25 (definição de estacionariedade de 2ª ordem).
- **Caixa:** [F4] linearidade da esperança; [F5] variância de soma de choques.
- **Livro:** MAT, §1.8 (média e variância do passeio com deslocamento); ENDERS, cap. 4 (passeio aleatório com drift).

Demonstração minuciosa

Passo 1 — Solução recursiva

Substitua para trás, um período de cada vez:

- $t = 1$: $y_1 = c + y_0 + \varepsilon_1$.
- $t = 2$: $y_2 = c + y_1 + \varepsilon_2 = c + (c + y_0 + \varepsilon_1) + \varepsilon_2 = y_0 + 2c + \varepsilon_1 + \varepsilon_2$.
- $t = 3$: $y_3 = c + y_2 + \varepsilon_3 = y_0 + 3c + \varepsilon_1 + \varepsilon_2 + \varepsilon_3$.

O padrão: cada período soma um c e um choque novo. Por indução, se $y_{t-1} = y_0 + c(t-1) + \sum_{i=1}^{t-1} \varepsilon_i$, então

$$y_t = c + y_{t-1} + \varepsilon_t = y_0 + c(t-1) + c + \sum_{i=1}^{t-1} \varepsilon_i + \varepsilon_t \quad \Longrightarrow \quad \boxed{y_t = y_0 + ct + \sum_{i=1}^{t} \varepsilon_i}$$

Com $y_0 = 10$: $y_t = 10 + ct + \sum_{i=1}^{t} \varepsilon_i$.

Passo 2 — Média

$$\begin{aligned} E(y_t) &= E\Big(10 + ct + \sum_{i=1}^{t} \varepsilon_i\Big) && \text{[Passo 1]} \\ &= 10 + ct + \sum_{i=1}^{t} E(\varepsilon_i) && \text{[F4]} \\ &= 10 + ct && \text{[RB]} \end{aligned}$$

Por quê: [F4] constantes saem da esperança, e a esperança da soma é a soma das esperanças; [RB] $E(\varepsilon_i) = 0$ para todo i.

$$\boxed{E(y_t) = 10 + ct = \mu_t}$$

A média depende de t sempre que $c \neq 0$: é uma **reta** (tendência determinística linear, AU01, p. 29).

Passo 3 — Variância

Primeiro o desvio em relação à média: $y_t - \mu_t = (10 + ct + \sum \varepsilon_i) - (10 + ct) = \sum_{i=1}^{t} \varepsilon_i$. Então:

$$\begin{aligned} V(y_t) = E\big((y_t - \mu_t)^2\big) &= E\Big(\Big(\sum_{i=1}^{t} \varepsilon_i\Big)^2\Big) \\ &= E\Big(\sum_{i=1}^{t}\sum_{j=1}^{t} \varepsilon_i \varepsilon_j\Big) && \text{[(i)]} \\ &= \sum_{i=1}^{t}\sum_{j=1}^{t} E(\varepsilon_i \varepsilon_j) && \text{[F4]} \\ &= \sum_{i=1}^{t} E(\varepsilon_i^2) + \sum_{i \neq j} E(\varepsilon_i \varepsilon_j) && \text{[(ii)]} \\ &= t\sigma^2 + 0 && \text{[RB]} \end{aligned}$$

Por quê:

- (i) o quadrado de uma soma é a soma dupla dos produtos, $\big(\sum_i a_i\big)^2 = \sum_i \sum_j a_i a_j$;
- (ii) separam-se os pares com $i = j$ dos pares com $i \neq j$;
- [RB] $E(\varepsilon_i^2) = \sigma^2$, e $E(\varepsilon_i \varepsilon_j) = 0$ se $i \neq j$.

$$\boxed{V(y_t) = t\sigma^2}$$

O $y_0 = 10$ é **fixo**, com variância zero, e por isso não aparece. O drift também não aparece: constante não tem variância.

Passo 4 — Autocovariância de ordem k ($0 \le k < t$)

$$\begin{aligned}
\gamma_{t,k} &= E\big((y_t - \mu_t)(y_{t-k} - \mu_{t-k})\big) \\
&= E\Big(\Big(\sum_{i=1}^{t} \varepsilon_i\Big)\Big(\sum_{j=1}^{t-k} \varepsilon_j\Big)\Big) && \text{[Passo 1]} \\
&= \sum_{i=1}^{t}\sum_{j=1}^{t-k} E(\varepsilon_i \varepsilon_j) && \text{[F5]} \\
&= \sum_{j=1}^{t-k} E(\varepsilon_j^2) && \text{[só } i = j\text{]} \\
&= (t-k)\sigma^2 && \text{[RB]}
\end{aligned}$$

Por quê "só $i = j$": pelo ruído branco, $E(\varepsilon_i \varepsilon_j) = 0$ quando $i \neq j$. Os pares com o mesmo índice só existem para $j = 1, \dots, t-k$, porque a segunda soma para em $t-k$.

$$\boxed{\operatorname{Cov}(y_t, y_{t-k}) = (t-k)\sigma^2}$$

A intuição: y_t e y_{t-k} compartilham os $t-k$ choques mais antigos. Os k choques mais novos só estão em y_t.

Passo 5 — É estacionário?

A definição (AU01, p. 25) exige três coisas constantes no tempo: média, variância e autocovariância. Aqui:

1. $E(y_t) = 10 + ct$ depende de t (se $c \neq 0$);
2. $V(y_t) = t\sigma^2$ depende de t **mesmo com** $c = 0$;
3. $\operatorname{Cov}(y_t, y_{t-k}) = (t-k)\sigma^2$ depende de t, e não só de k.

Conclusão: o processo não é estacionário, porque as três condições falham.

A correlação reforça (AU01, p. 48): $\rho(t,k) = \frac{(t-k)\sigma^2}{\sqrt{t\sigma^2 (t-k)\sigma^2}} = \sqrt{\frac{t-k}{t}} \to 1$ quando t cresce. A FAC amostral decai devagar, e é esse o primeiro sinal de raiz unitária (AU01, p. 50).

Como tornar estacionário: $\Delta y_t = y_t - y_{t-1} = c + \varepsilon_t$, com média c, variância σ^2 e covariâncias nulas. Uma diferença basta: $y_t \sim I(1)$.

Conferência por simulação

Com $c = 1$, $\sigma^2 = 1$ e 20 mil trajetórias, em $t = 30$:

- média teórica $10 + 30 = 40$; simulada 40,01;
- variância teórica 30; simulada 29,95;
- $\operatorname{Cov}(y_{30}, y_{20})$ teórica $(30 - 10) = 20$; simulada 19,99.

Do meu caderno (19/08)

O caderno faz o passeio **sem drift**, $y_t = y_{t-1} + \varepsilon_t$ com $y_0 = 0$:

- solução recursiva escrita linha a linha, $y_1 = y_0 + \varepsilon_1$, $y_2 = y_0 + \varepsilon_1 + \varepsilon_2$, até $y_t = y_0 + \sum_{i=1}^{t} \varepsilon_i$;
- $E(y_t) = y_0 = 0$;
- $V(y_t) = E\big((y_0 + \sum \varepsilon_i - y_0)^2\big)$, deixada no meio da conta;
- a covariância, $E\big((\varepsilon_1 + \cdots + \varepsilon_t)(\varepsilon_1 + \cdots + \varepsilon_{t-k})\big) = E(\varepsilon_1^2 + \cdots + \varepsilon_{t-k}^2) = (t-k)\sigma^2$: certa, e é exatamente o Passo 4.

Duas anotações do caderno que só valem com hipótese

- "$E(XY) = E(X)E(Y)$" vale **só** se X e Y forem não correlacionados [F4]. Aqui serve para $E(\varepsilon_i\varepsilon_j) = 0$ com $i \neq j$, mas não para $E(\varepsilon_i^2)$, que é σ^2 e não $E(\varepsilon_i)^2 = 0$.
- "$\sigma^2 = E(X^2)$" vale **só** com média zero: em geral $V(X) = E(X^2) - E(X)^2$, e é isso que a expansão $E(X^2) - 2E(X)\mu + \mu^2$ do caderno mostra.

Na prova, escreva a hipótese ao lado do sinal de igual.

O que o livro acrescenta

MAT (§1.8) escreve o mesmo processo como **tendência determinística mais tendência estocástica**: $Y_t = \underbrace{Y_0 + at}_{\text{determinística}} + \underbrace{\sum_{i=1}^{t} \varepsilon_i}_{\text{estocástica}}$. A média vem toda da primeira parte, e a variância, toda da segunda. É o caso particular mais simples de processo **diferença estacionária** (DS), e a ponte para a Q2 e a Q10.

Armadilhas e variações

- **Covariância com t no lugar de $t - k$.** Os choques comuns são os de y_{t-k}, o mais curto.
- **Esquecer de dizer por que não é estacionário.** "Não é estacionário" sem citar a condição que falha é a conclusão sem justificativa, o erro da Q5 da P1 de Econometria I (log).
- **Variações:** y_0 aleatório, Δy_t e a correlação $\sqrt{(t-k)/t}$ estão no banco e no Simulado 01, Q1.

Q2 · Passeio com drift e tendência determinística

← índice · anterior: Q1 · próxima: Q3 · resolução curta em 01_lista

O que a questão pede

Para $y_t = c + \delta t + y_{t-1} + u_t$, com $y_0 = 0$:

- **(a) derivar** a solução explícita;
- **(b) calcular** média, variância e autocovariância;
- **(c) comparar** com o passeio com drift da Q1;
- **(d) discutir** a natureza da tendência e como remover a não estacionariedade.

Da lista para os slides

Lista	Slides (AU01, p. 30)
$y_t = c + \delta t + y_{t-1} + u_t$, $y_0 = 0$	$Y_t = \alpha_1 + Y_{t-1} + \alpha_2 t + \varepsilon_t$ (“RW + drift + trend”)

Tradução: $\alpha_1 = c$ e $\alpha_2 = \delta$. Uso a notação do slide.

Ferramentas

- **Slides:** AU01, p. 30 (o resultado pronto, sem a conta); MAT, §1.1–1.3 (tendência determinística e estocástica, tendência geral) e o Quadro 1 (p. 20).
- **Caixa:** [F3] soma dos inteiros; [F4]; [F5].
- **Livro:** ENDERS, cap. 4 (modelos com tendência).

Demonstração minuciosa

(a) Solução explícita

Escreva $Y_t - Y_{t-1} = \alpha_1 + \alpha_2 t + \varepsilon_t$ e some de $s = 1$ até $s = t$:

$$\sum_{s=1}^{t}(Y_s - Y_{s-1}) = \sum_{s=1}^{t}\alpha_1 + \sum_{s=1}^{t}\alpha_2 s + \sum_{s=1}^{t}\varepsilon_s.$$

1. O lado esquerdo é **telescópico**: $(Y_1 - Y_0) + (Y_2 - Y_1) + \cdots + (Y_t - Y_{t-1}) = Y_t - Y_0$, porque cada termo intermediário aparece uma vez com $+$ e outra com $-$.
2. $\sum_{s=1}^{t}\alpha_1 = \alpha_1 t$, porque são t parcelas iguais.
3. $\sum_{s=1}^{t}\alpha_2 s = \alpha_2 \sum_{s=1}^{t} s = \alpha_2 \frac{t(t+1)}{2}$ [F3].
4. Com $Y_0 = 0$:

$$\boxed{Y_t = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum_{s=1}^{t}\varepsilon_s}$$

Conferência para $t = 2$: pela recursão, $Y_1 = \alpha_1 + \alpha_2 + \varepsilon_1$ e $Y_2 = \alpha_1 + 2\alpha_2 + Y_1 + \varepsilon_2 = 2\alpha_1 + 3\alpha_2 + \varepsilon_1 + \varepsilon_2$. Pela fórmula, $2\alpha_1 + \alpha_2 \cdot \frac{2 \cdot 3}{2} + \varepsilon_1 + \varepsilon_2 = 2\alpha_1 + 3\alpha_2 + \varepsilon_1 + \varepsilon_2$. Bate.

(b) Momentos

- **Média.** $E(Y_t) = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2} + \sum E(\varepsilon_s) = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$ [F4, RB]. É uma **parábola** em t.
- **Desvio.** $Y_t - E(Y_t) = \sum_{s=1}^{t} \varepsilon_s$, exatamente o mesmo da Q1.
- **Variância.** Repetindo o Passo 3 da Q1: $V(Y_t) = t\sigma^2$.
- **Covariância.** Repetindo o Passo 4: $\text{Cov}(Y_t, Y_{t-k}) = (t-k)\sigma^2$.

$$\boxed{E(Y_t) = \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}, \qquad V(Y_t) = t\sigma^2, \qquad \text{Cov}(Y_t, Y_{t-k}) = (t-k)\sigma^2}$$

Na lista: $E(y_t) = ct + \delta \frac{t(t+1)}{2}$.

(c) Comparação com o passeio com drift

	Drift (Q1)	Drift e tendência (Q2)
Média	linear: $y_0 + \alpha_1 t$	quadrática: $\alpha_1 t + \alpha_2 t(t+1)/2$
Variância	$t\sigma^2$	$t\sigma^2$
Autocovariância	$(t-k)\sigma^2$	$(t-k)\sigma^2$

Só a média muda. A parte aleatória, $\sum \varepsilon_s$, é a mesma nos dois, e é ela que gera a variância.

(d) A natureza da tendência e como removê-la

Os dois processos têm **duas tendências ao mesmo tempo** (MAT, §1.3, "tendência geral"):

- uma **estocástica**, $\sum \varepsilon_s$: cada choque fica para sempre no nível;
- uma **determinística**: linear na Q1, quadrática na Q2.

Como remover:

1. **Q1:** uma diferença basta, $\Delta Y_t = \alpha_1 + \varepsilon_t$, que é estacionário.
2. **Q2:** uma diferença **não basta**, porque $\Delta Y_t = \alpha_1 + \alpha_2 t + \varepsilon_t$ ainda tem tendência linear na média. Há dois caminhos:
   - **diferenciar e tirar a tendência por regressão:** regredir ΔY_t em 1 e t e trabalhar com o resíduo, que é ε_t;
   - **diferenciar duas vezes:** $\Delta^2 Y_t = \Delta(\alpha_1 + \alpha_2 t + \varepsilon_t) = \alpha_2 + \varepsilon_t - \varepsilon_{t-1}$. A média fica constante, mas sobra um MA(1) com raiz unitária, $\theta = -1$ nos slides: não invertível (ver Q9).

Implicação prática: use o primeiro caminho. A diferença extra cria um MA não invertível, e o modelo fica difícil de estimar e de prever (Q9 e Q10).

Conferência numérica

Com $\alpha_1 = 1$, $\alpha_2 = 0{,}2$ e $t = 30$: $E(Y_{30}) = 30 + 0{,}2 \cdot \frac{30 \cdot 31}{2} = 30 + 0{,}2 \cdot 465 = 123$. A simulação, com 20 mil trajetórias, dá 123,01. E $\sum_{s=1}^{10} s = 55$.

Do meu caderno (19/08)

"Random Walk: $Y_t = \alpha + Y_{t-1} + \varepsilon_t$; $Y_t = \alpha + Y_{t-1} + \alpha_2 t + \varepsilon_t$, termo de **tendência determinística**", com a palavra "sustentada" e a ligação "teste de **raiz unitária**". É o slide da AU01, p. 30, sem a conta. A demonstração do item (a) acima é a que faltou no caderno: somar a equação de 1 a t e usar a soma telescópica.

O que o livro acrescenta

MAT, Quadro 1 (p. 20), classifica os quatro casos:

- estacionário;
- raiz unitária pura;
- tendência estacionária (TS);
- diferença estacionária (DS).

A Q2 é um DS **com** tendência determinística extra. A regra geral do texto: **tendência estocástica se tira com diferença, e tendência determinística se tira com regressão em** *t*. Diferenciar uma tendência determinística, ou regredir um passeio em *t*, é o erro dos dois lados (Q10).

Armadilhas e variações

- **Escrever** $\alpha_2 t^2/2$ em vez de $\alpha_2 t(t+1)/2$: é a afirmativa 4 da Q8, que é falsa por isso. Escreva a soma de Gauss [F3] antes.
- **Dizer que a variância muda com a tendência.** Termos determinísticos não têm variância.
- **Variações:** números no banco.

CAPÍTULO 4

Q3 · FAC de $z_{3t} = z_{1t} + 2z_{2t}$

← índice · anterior: Q2 · próxima: Q4 · resolução curta em 01_lista

O que a questão pede

Dois processos estacionários e **não correlacionados entre si**:

- z_1: $\gamma_0 = 0{,}5$, $\gamma_1 = 0{,}2$ e zero depois;
- z_2: $\gamma_0 = 2{,}30$, $\gamma_1 = -1{,}43$, $\gamma_2 = 0{,}30$ e zero depois.

Pede-se:

- **(a) calcular** a autocovariância de $z_3 = z_1 + 2z_2$;
- **(b) verificar** se z_3 é estacionário;
- **(c) classificar** z_3 como ARMA(p, q) pela FAC.

Da lista para os slides

Não há operador nem MA escrito: a notação é a mesma. Uso $\gamma_k^{(1)}$, $\gamma_k^{(2)}$ e $\gamma_k^{(3)}$ para as autocovariâncias de z_1, z_2 e z_3.

Ferramentas

- **Slides:** AU01, p. 25 (estacionariedade) e p. 35 (autocovariância); AU02, p. 51–52 (FAC do MA(q): zero depois de q).
- **Caixa:** [F5] covariância de combinações lineares.
- **Livro:** HAMILTON, cap. 4 (soma de processos ARMA); ENDERS, cap. 2 (FAC de MA(q)).

Demonstração minuciosa

(a) A autocovariância de z_3

Com médias μ_1 e μ_2, a média de z_3 é $\mu_3 = \mu_1 + 2\mu_2$ [F4], e o desvio é $z_{3t} - \mu_3 = (z_{1t} - \mu_1) + 2(z_{2t} - \mu_2)$. Então:

$$
\begin{aligned}
\gamma_k^{(3)} &= \operatorname{Cov}(z_{3t}, z_{3,t-k}) \\
&= \operatorname{Cov}\left(z_{1t} + 2z_{2t},\ z_{1,t-k} + 2z_{2,t-k}\right) \\
&= \operatorname{Cov}(z_{1t}, z_{1,t-k}) + 2\operatorname{Cov}(z_{1t}, z_{2,t-k}) && \text{[F5]} \\
&\quad + 2\operatorname{Cov}(z_{2t}, z_{1,t-k}) + 4\operatorname{Cov}(z_{2t}, z_{2,t-k}) \\
&= \gamma_k^{(1)} + 0 + 0 + 4\gamma_k^{(2)} && \text{[(i)]}
\end{aligned}
$$

Por quê:

- [F5] a covariância é bilinear: distribuindo, saem quatro termos;
- (i) z_1 e z_2 são não correlacionados, então as duas covariâncias cruzadas valem zero.

$$\boxed{\gamma_k^{(3)} = \gamma_k^{(1)} + 4\gamma_k^{(2)}}$$

O fator 2 entra **ao quadrado**, porque multiplica os dois lados da covariância. Agora, defasagem por defasagem:

- $k = 0$: $\gamma_0^{(3)} = 0{,}5 + 4(2{,}30) = 0{,}5 + 9{,}2 = 9{,}70$.
- $k = 1$: $\gamma_1^{(3)} = 0{,}2 + 4(-1{,}43) = 0{,}2 - 5{,}72 = -5{,}52$.
- $k = 2$: $\gamma_2^{(3)} = 0 + 4(0{,}30) = 1{,}20$.
- $k \geq 3$: $\gamma_k^{(3)} = 0 + 0 = 0$.

As autocorrelações são $\rho_1 = -5{,}52/9{,}70 = -0{,}5691$ e $\rho_2 = 1{,}20/9{,}70 = 0{,}1237$.

(b) Estacionariedade

Pelas três condições da AU01, p. 25:

1. $E(z_{3t}) = \mu_1 + 2\mu_2$ não depende de t, porque μ_1 e μ_2 não dependem [F4, estacionariedade de z_1 e z_2];
2. $V(z_{3t}) = \gamma_0^{(3)} = 9{,}70$ é finita e constante;
3. $\gamma_k^{(3)}$ depende só de k, porque $\gamma_k^{(1)}$ e $\gamma_k^{(2)}$ dependem só de k.

$$\boxed{z_3 \text{ é estacionário de segunda ordem.}}$$

(c) Classe ARMA

A FAC de z_3 é **diferente de zero até a defasagem 2 e zero daí em diante**. Pela AU02, p. 51: num MA(q), $\gamma_k = 0$ para todo $k > q$, e só o MA tem esse **corte**. A FAC de um AR ou de um ARMA decai sem nunca zerar.

$$\boxed{z_3 \sim \text{MA}(2) = \text{ARMA}(0, 2)}$$

Faz sentido: z_1 tem FAC que corta em 1 (é um MA(1)), z_2 tem FAC que corta em 2 (é um MA(2)), e a soma não pode ter memória mais longa que a parcela mais longa.

Do meu caderno (20/08 e 26/08)

O caderno calcula a FAC do MA(1) e do MA(2) na notação dos slides, que é a ferramenta do item (c):

- MA(1), $y_t = \varepsilon_t + \theta\varepsilon_{t-1}$: $\gamma_1 = E\big((\varepsilon_t + \theta\varepsilon_{t-1})(\varepsilon_{t-1} + \theta\varepsilon_{t-2})\big)$. Dos quatro produtos, só $\theta\varepsilon_{t-1}^2$ tem os índices iguais, logo $\gamma_1 = \theta\sigma^2$ e $\gamma_k = 0$ para $k \geq 2$. **Certo.**
- MA(2): $\gamma_1 = \theta_1\sigma^2 + \theta_1\theta_2\sigma^2 = (\theta_1 + \theta_1\theta_2)\sigma^2$. **Certo** (AU02, p. 51, com $\theta_0 = 1$).
- O γ_2 ficou pela metade. Completando: $\gamma_2 = E\big((\varepsilon_t + \theta_1\varepsilon_{t-1} + \theta_2\varepsilon_{t-2})(\varepsilon_{t-2} + \theta_1\varepsilon_{t-3} + \theta_2\varepsilon_{t-4})\big)$. O único par com o mesmo índice é $\theta_2\varepsilon_{t-2} \cdot \varepsilon_{t-2}$, logo $\gamma_2 = \theta_2\sigma^2$ e $\gamma_k = 0$ para $k \geq 3$.

O que o livro acrescenta

HAMILTON (cap. 4) prova o caso geral: a soma de um MA(q_1) com um MA(q_2) não correlacionados é um MA($\max(q_1, q_2)$). Os parâmetros do MA resultante não são a soma dos parâmetros: eles se acham igualando as autocovariâncias, como no item (a).

Armadilhas e variações

- $2\gamma^{(2)}$ **em vez de** $4\gamma^{(2)}$**.** É o erro mais comum desta questão.
- **Esquecer de citar "não correlacionados"** ao zerar os termos cruzados. Sem a hipótese, faltam $2[\gamma_{12}(k) + \gamma_{21}(k)]$.
- **Variações:** $z_1 - z_2$ e $3z_1 + z_2$ no banco; $2x + w$ no Simulado 01, Q1c.

Q4 · Teorema de Wold

← índice · anterior: Q3 · próxima: Q5 · resolução curta em 01_lista

O que a questão pede

- **(a) Enunciar** o Teorema de Wold e discutir o componente determinístico.
- **(b) Mostrar** que o AR(1) estacionário satisfaz a decomposição e identificar os ψ_j.
- **(c) Explicar** por que a invertibilidade do MA é necessária para um AR(∞) convergente.

Da lista para os slides

Lista	Slides
$y_t = \sum_{j\geq 0} \psi_j \varepsilon_{t-j}$, $\psi_0 = 1$, $\sum \psi_j^2 < \infty$	processo linear geral $y_t = \mu + \Psi(L)\varepsilon_t$ (AU02, p. 15–18)
AR(1) $y_t = \phi y_{t-1} + \varepsilon_t$	$(1 - \phi L)y_t = \varepsilon_t$ (AU02, p. 21)
MA(1) para o item (c)	$y_t = (1 + \theta L)\varepsilon_t$, sinal positivo (AU02, p. 22)

Ferramentas

- **Slides:** AU02, p. 4–6 (solução recursiva e multiplicador dinâmico), p. 15–20 (processo linear, $\Psi(L)$ e $\pi(L)$), p. 21 (AR(1) $\longrightarrow \Psi$), p. 22–23 e 31–32 (MA(1) $\longrightarrow \pi$), p. 34 (identificação).
- **Caixa:** [F2] série geométrica; [F5]; [F7].
- **Livro:** HAMILTON, cap. 4 (decomposição de Wold) e cap. 2 (inverter $1 - \phi L$); ENDERS, cap. 1 (solução de equações a diferenças).

Demonstração minuciosa

(a) O enunciado

Teorema de Wold

Todo processo $\{y_t\}$ **estacionário de segunda ordem**, com média zero, pode ser escrito como

$$y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} + \kappa_t,$$

em que:

1. $\psi_0 = 1$ e $\sum_{j\geq 0} \psi_j^2 < \infty$;
2. $\varepsilon_t \sim RB(0, \sigma^2)$ é o **erro de previsão linear um passo à frente**: $\varepsilon_t = y_t - \hat{E}(y_t \mid y_{t-1}, y_{t-2}, \dots)$;
3. κ_t é **determinístico**: pode ser previsto sem erro, por uma função linear do passado remoto de y;
4. κ_t e ε_s são não correlacionados para todo t e todo s.

O componente determinístico. É a parte de y_t que não vem de choque nenhum. Exemplos:

- uma constante, $\kappa_t = \mu$, que é por isso que o slide escreve $y_t = \mu + \Psi(L)\varepsilon_t$;
- um ciclo de amplitude aleatória sorteada uma vez, $\kappa_t = A\cos(\omega t) + B\sin(\omega t)$, que é estacionário, mas, conhecidos dois valores, é previsto sem erro para sempre (ver o Simulado 02, Q1).

Um processo com $\kappa_t = 0$ é **puramente não determinístico**: é o caso dos ARMA estacionários.

Por que $\sum \psi_j^2 < \infty$. Pela AU02, p. 18, $\gamma_0 = \sigma^2 \sum \psi_j^2$. A variância só existe, finita, se a soma converge. É a estacionariedade escrita nos pesos (AU02, p. 17: "square summable").

(b) O AR(1) satisfaz Wold

Caminho 1: substituição recursiva (AU02, p. 4, e meu caderno de 19/08). Partindo de $y_t = \phi y_{t-1} + \varepsilon_t$:

- $y_t = \phi(\phi y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \phi^2 y_{t-2} + \phi\varepsilon_{t-1} + \varepsilon_t$;
- $y_t = \phi^2(\phi y_{t-3} + \varepsilon_{t-2}) + \phi\varepsilon_{t-1} + \varepsilon_t = \phi^3 y_{t-3} + \phi^2\varepsilon_{t-2} + \phi\varepsilon_{t-1} + \varepsilon_t$;
- depois de n substituições: $y_t = \phi^n y_{t-n} + \sum_{j=0}^{n-1} \phi^j \varepsilon_{t-j}$.

O resto vai a zero. O erro de truncar a soma em n termos é $\phi^n y_{t-n}$, e

$$E\Big(\Big(y_t - \sum_{j=0}^{n-1} \phi^j \varepsilon_{t-j}\Big)^2\Big) = E\big(\phi^{2n} y_{t-n}^2\big) = \phi^{2n}\gamma_0 \xrightarrow[n\to\infty]{} 0 \quad \text{se } |\phi| < 1.$$

Usei que $E(y_{t-n}^2) = \gamma_0$ é constante, por estacionariedade, e que $\phi^{2n} \to 0$. Logo, em média quadrática:

$$\boxed{y_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}, \qquad \psi_j = \phi^j}$$

Caminho 2: operador (AU02, p. 21). $(1 - \phi L)y_t = \varepsilon_t \Rightarrow y_t = (1 - \phi L)^{-1}\varepsilon_t$. Pela série geométrica com $r = \phi L$ [F2], $(1 - \phi L)^{-1} = 1 + \phi L + \phi^2 L^2 + \cdots$, que só converge se $|\phi| < 1$. Comparando com $\Psi(L) = 1 + \psi_1 L + \psi_2 L^2 + \cdots$, coeficiente a coeficiente [F7]: $\psi_j = \phi^j$.

Conferindo as condições de Wold.

1. $\psi_0 = \phi^0 = 1$. ✓
2. $\sum_{j\geq 0} \psi_j^2 = \sum_{j\geq 0} (\phi^2)^j = \frac{1}{1-\phi^2} < \infty$, porque $\phi^2 < 1$ [F2]. ✓ Com $\phi = 0{,}5$: $\sum \psi_j^2 = 1{,}3333$, e $\psi_3 = 0{,}125$.
3. ε_t é RB e é o erro de previsão um passo à frente: $y_t - E(y_t \mid y_{t-1}, \dots) = y_t - \phi y_{t-1} = \varepsilon_t$. ✓
4. $\kappa_t = 0$: o AR(1) de média zero é puramente não determinístico. ✓

Leitura econômica. $\psi_j = \phi^j = \partial y_{t+j}/\partial \varepsilon_t$ é o **multiplicador dinâmico** (AU02, p. 6): o efeito de um choque de hoje daqui a j períodos. Com $|\phi| < 1$, ele some (AU02, p. 26: com $\phi = 0{,}5$, os pesos são 1; 0,5; 0,25; 0,125...).

(c) Por que a invertibilidade é necessária

Tome o MA(1) dos slides, $y_t = (1 + \theta L)\varepsilon_t$. Para escrever um AR(∞), é preciso **recuperar ε_t a partir de $y_t, y_{t-1}, \dots$** (AU02, p. 30).

Por substituição (AU02, p. 31). De $\varepsilon_t = y_t - \theta\varepsilon_{t-1}$:

- $\varepsilon_t = y_t - \theta(y_{t-1} - \theta\varepsilon_{t-2}) = y_t - \theta y_{t-1} + \theta^2\varepsilon_{t-2}$;
- e assim por diante: $\varepsilon_t = y_t - \theta y_{t-1} + \theta^2 y_{t-2} - \theta^3 y_{t-3} + \cdots + (-\theta)^n \varepsilon_{t-n}$.

Pelo operador. $(1 + \theta L)^{-1}$ é a série geométrica com $r = -\theta L$ [F2], logo $(1 + \theta L)^{-1} = \sum_j (-\theta)^j L^j$. Comparando com $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots$, sai $\pi_j = -(-\theta)^j$ (AU02, p. 23).

A condição. O resto $(-\theta)^n \varepsilon_{t-n}$ só some se $|\theta| < 1$. Com $\theta = 0{,}5$, os pesos são 1; −0,5; 0,25; −0,125..., que convergem. Com $\theta = 2$, são 1; −2; 4; −8..., que explodem (AU02, p. 32). Em geral, as raízes de $\theta_q(z) = 1 + \theta_1 z + \cdots + \theta_q z^q$ devem ficar fora do círculo unitário (AU02, p. 33).

$$\boxed{|\theta| < 1 \iff \sum_{j\geq 1} |\pi_j| = \sum_{j\geq 1} |\theta|^j < \infty}$$

Conclusão: sem invertibilidade, a série $\sum_j \pi_j y_{t-j}$ não converge. Então ε_t não pode ser recuperado do passado observado, e **não existe representação AR(∞)**.

Segunda razão: identificação (AU02, p. 34, e meu caderno de 03/09). $\theta = 0{,}5$ com $\sigma^2 = 4$ e $\theta = 2$ com $\sigma^2 = 1$ dão a mesma FAC: $\gamma_0 = (1+\theta^2)\sigma^2 = 5$ e $\gamma_1 = \theta\sigma^2 = 2$ nos dois casos, logo $\rho_1 = 0{,}4$. Nenhuma amostra separa os dois. Exigir $|\theta| < 1$ escolhe um deles, aquele em que ε_t é o erro de previsão do Teorema de Wold.

Do meu caderno

19/08, AR(1) recursivo. O caderno escreve:

- $y_1 = \phi y_0 + \varepsilon_1$;
- $y_2 = \phi(\phi y_0 + \varepsilon_1) + \varepsilon_2 = \phi^2 + \phi\varepsilon_1 + \varepsilon_2$;
- $y_3 = \phi(\phi y_0^2 + \phi\varepsilon_1 + \varepsilon_2) + \varepsilon_3$;
- e conclui $y_t = \phi^t y_0 + \phi^{t-1}\varepsilon_1 + \cdots + \varepsilon_t$, com as notas "$|\phi| < 1$ estável, regulador da memória, esquecer os choques passados" e "$|\phi| \geq 1$ instável".

Duas correções

- $y_2 = \phi^2 \mathbf{y_0} + \phi\varepsilon_1 + \varepsilon_2$: faltou o y_0. Na linha de y_3, o certo é $\phi(\phi^2 y_0 + \phi\varepsilon_1 + \varepsilon_2)$, e não ϕy_0^2. A fórmula final está certa.
- "$|\phi| \geq 1$ instável" junta dois casos que a AU02, p. 10 e 26, separa. Com $|\phi| = 1$, o processo é um passeio aleatório: cada choque fica para sempre, mas não explode. Com $|\phi| > 1$, o processo é explosivo: choques antigos pesam mais.

19/08, multiplicador dinâmico. Em $y_t = \phi y_{t-1} + \beta X_t + u_t$, o caderno chega a $\partial y_{t+j}/\partial X_t = \phi^j \beta$, que está certo; na demanda por moeda de Goldfeld, dois períodos à frente dá $0{,}72^2 \times 0{,}19 = 0{,}098$ (AU02, p. 7). Na linha de y_{t+1}, o último termo deveria ser u_{t+1}, e não u_{t-1}.

03/09, MA(1) → AR(∞). O caderno faz $y_t = \theta_1(y_{t-1} - \theta_1\varepsilon_{t-2}) + \varepsilon_t$ e escreve $+\theta_1^2\varepsilon_{t-2}$. O certo é $y_t = \theta_1 y_{t-1} - \theta_1^2\varepsilon_{t-2} + \varepsilon_t$: o sinal alterna a cada substituição, como no item (c). E $\varepsilon_{t-1} = y_{t-1} - \theta_1\varepsilon_{t-2}$, não ε_{t+2}.

O que o livro acrescenta

HAMILTON (cap. 4) usa o Teorema de Wold para justificar toda a modelagem Box-Jenkins. Qualquer processo estacionário é um MA(∞), e o ARMA(p,q) é só uma forma **parcimoniosa** de aproximar o polinômio infinito $\Psi(L)$ pela razão $\theta(L)/\phi(L)$ (AU02, p. 43).

Armadilhas e variações

- **Enunciar Wold sem "estacionário de segunda ordem"** ou sem $\sum \psi_j^2 < \infty$: são as duas hipóteses que valem ponto.
- **Confundir as duas condições:** estacionariedade é sobre o AR e garante MA(∞); invertibilidade é sobre o MA e garante AR(∞) (AU02, p. 36).
- **Variações:** π_j do MA(1) da lista, que tem sinal de Box-Jenkins, no banco.

Parte III

Bloco 2 — AR, MA e ARMA

Q5 · Três modelos: operador, classificação, raízes, ψ_j e π_j

← índice · anterior: Q4 · próxima: Q6 · resolução curta em 02_lista

O que a questão pede

Para três modelos:

- **escrever** com o operador de defasagem;
- **classificar** como ARMA(p, q);
- **verificar** a estacionariedade e a invertibilidade;
- **obter** os quatro primeiros pesos ψ_j e π_j.

Da lista para os slides

A lista usa $\tilde{z}_t$ (desvio da média), a_t e o MA com **sinal negativo**. Nos slides, o MA tem sinal positivo, então cada θ da lista troca de sinal [regra do README].

Modelo	Lista	Slides
(1)	$\tilde{z}_t - 0{,}5\tilde{z}_{t-1} = a_t$	$(1 - 0{,}5L)\tilde{z}_t = \varepsilon_t$
(2)	$\tilde{z}_t = a_t - 1{,}3a_{t-1} + 0{,}4a_{t-2}$	$\tilde{z}_t = (1 + \theta_1 L + \theta_2 L^2)\varepsilon_t$ com $\theta_1 = -1{,}3$, $\theta_2 = 0{,}4$
(3)	$\tilde{z}_t - 0{,}5\tilde{z}_{t-1} = a_t - 1{,}3a_{t-1} + 0{,}4a_{t-2}$	$(1 - 0{,}5L)\tilde{z}_t = (1 - 1{,}3L + 0{,}4L^2)\varepsilon_t$

Os **pesos** ψ_j e π_j não dependem da convenção do MA: $\tilde{z}_t = \sum \psi_j \varepsilon_{t-j}$ e $\tilde{z}_t = \sum \pi_j \tilde{z}_{t-j} + \varepsilon_t$ são iguais na lista e nos slides (AU02, p. 16 e 19).

Ferramentas

- **Slides:** AU02, p. 12–14 (escrever em L); p. 21 (AR(1) $\longrightarrow \psi$); p. 22–23 (MA(1) $\longrightarrow \pi_j = -(-\theta)^j$); p. 27 (raízes do AR fora do círculo); p. 29 (todo MA é estacionário); p. 33 (raízes do MA fora do círculo).
- **Caixa:** [F1] Bhaskara; [F2] série geométrica; [F7] igualar coeficientes; [F8] multiplicar polinômios.
- **Livro:** HAMILTON, cap. 2 e 3; BJRL, cap. 3 (os mesmos três tipos de modelo, na convenção da lista).

Demonstração minuciosa

Modelo (1): $(1 - 0{,}5L)\tilde{z}_t = \varepsilon_t$

Classificação. O AR tem grau 1 e o MA tem grau 0: **AR(1) = ARMA(1,0)**.

Estacionariedade (AU02, p. 27). $\phi(z) = 1 - 0{,}5z = 0 \Rightarrow z = 1/0{,}5 = 2$. Como $|2| > 1$, a raiz está fora do círculo: **estacionário**.

Invertibilidade. Não há polinômio MA: todo AR puro é invertível (AU02, p. 36).

Pesos ψ (AU02, p. 21). $\Psi(L) = (1 - 0{,}5L)^{-1} = \sum_j 0{,}5^j L^j$ [F2, válido porque $|0{,}5| < 1$]:

$$\psi_1 = 0{,}5; \quad \psi_2 = 0{,}25; \quad \psi_3 = 0{,}125; \quad \psi_4 = 0{,}0625.$$

Pesos π. O modelo já está na forma AR: $\pi(L) = 1 - 0{,}5L$, logo $\pi_1 = 0{,}5$ e $\pi_2 = \pi_3 = \pi_4 = 0$.

Modelo (2): $\tilde{z}_t = (1 - 1{,}3L + 0{,}4L^2)\varepsilon_t$

Classificação. Não há AR, e o MA tem grau 2: **MA(2) = ARMA(0,2)**.

Estacionariedade. Todo MA(q) é estacionário, porque é uma soma finita de choques, com $\sum|\psi_j| = 1 + 1{,}3 + 0{,}4 < \infty$ (AU02, p. 29).

Invertibilidade: Bhaskara em detalhe [F1]. A condição é que as raízes de $\theta(z) = 1 - 1{,}3z + 0{,}4z^2$ fiquem fora do círculo (AU02, p. 33).

1. **Ponha na forma padrão:** $0{,}4z^2 - 1{,}3z + 1 = 0$, ou seja, $a = 0{,}4$, $b = -1{,}3$ e $c = 1$.
2. **Discriminante:** $\Delta = b^2 - 4ac = (-1{,}3)^2 - 4(0{,}4)(1) = 1{,}69 - 1{,}60 = 0{,}09$.
3. **Raiz do discriminante:** $\sqrt{0{,}09} = 0{,}3$, positivo, então são duas raízes reais.
4. **Raízes:** $z = \frac{-b \pm \sqrt{\Delta}}{2a} = \frac{1{,}3 \pm 0{,}3}{2(0{,}4)} = \frac{1{,}3 \pm 0{,}3}{0{,}8}$, logo
   - $z_1 = \frac{1{,}6}{0{,}8} = 2$;
   - $z_2 = \frac{1{,}0}{0{,}8} = 1{,}25$.
5. **Conferência de Vieta:** soma $z_1 + z_2 = 3{,}25 = -b/a = 1{,}3/0{,}4$ ✓; produto $z_1 z_2 = 2{,}5 = c/a = 1/0{,}4$ ✓.
6. **Conclusão:** $|2| > 1$ e $|1{,}25| > 1$, então o processo é **invertível**.

Fatoração (útil no modelo 3). Raízes 2 e 1,25 correspondem aos fatores $(1 - z/2)$ e $(1 - z/1{,}25)$:

$$1 - 1{,}3L + 0{,}4L^2 = (1 - 0{,}5L)(1 - 0{,}8L).$$

Conferindo por [F8]: $(1 - 0{,}5L)(1 - 0{,}8L) = 1 - 0{,}8L - 0{,}5L + 0{,}4L^2 = 1 - 1{,}3L + 0{,}4L^2$ ✓.

Pesos ψ. O MA já é a forma MA(∞), truncada: $\psi_1 = -1{,}3$, $\psi_2 = 0{,}4$ e $\psi_3 = \psi_4 = 0$.

Pesos π: igualar coeficientes [F7]. Escreva $\theta(L)^{-1} = 1 + c_1 L + c_2 L^2 + \cdots$. Como $\pi(L) = \theta(L)^{-1}$ e $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots$, vale $\pi_j = -c_j$. Exigindo $(1 + c_1 L + c_2 L^2 + \cdots)(1 - 1{,}3L + 0{,}4L^2) = 1$, potência por potência:

Potência	Equação	c_j
L^1	$c_1 - 1{,}3 = 0$	$c_1 = 1{,}3$
L^2	$c_2 - 1{,}3c_1 + 0{,}4 = 0$	$c_2 = 1{,}3(1{,}3) - 0{,}4 = 1{,}69 - 0{,}4 = 1{,}29$
L^3	$c_3 - 1{,}3c_2 + 0{,}4c_1 = 0$	$c_3 = 1{,}3(1{,}29) - 0{,}4(1{,}3) = 1{,}677 - 0{,}52 = 1{,}157$
L^4	$c_4 - 1{,}3c_3 + 0{,}4c_2 = 0$	$c_4 = 1{,}3(1{,}157) - 0{,}4(1{,}29) = 1{,}5041 - 0{,}516 = 0{,}9881$

$$\boxed{\pi_1 = -1{,}3; \quad \pi_2 = -1{,}29; \quad \pi_3 = -1{,}157; \quad \pi_4 = -0{,}9881}$$

Os pesos decaem **devagar**, à taxa $1/1{,}25 = 0{,}8$ por período, porque a raiz 1,25 está perto do círculo unitário. O `ARMAtoMA` do R dá os mesmos valores, com diferença zero.

Modelo (3): $(1 - 0{,}5L)\tilde{z}_t = (1 - 1{,}3L + 0{,}4L^2)\varepsilon_t$

Aparência: ARMA(1,2). Mas a fatoração do modelo (2) mostra um **fator comum**:

$$(1 - 0{,}5L)\tilde{z}_t = (1 - 0{,}5L)(1 - 0{,}8L)\varepsilon_t.$$

Como $|0{,}5| < 1$, $(1 - 0{,}5L)$ é inversível [F2]. Multiplicando os dois lados por $(1 - 0{,}5L)^{-1}$:

$$\boxed{\tilde{z}_t = (1 - 0{,}8L)\varepsilon_t \;:\; \text{MA}(1) = \text{ARMA}(0,1)}$$

Na lista: $\tilde{z}_t = a_t - 0{,}8a_{t-1}$, isto é, $\theta = 0{,}8$ na convenção de Box-Jenkins.

Como enxergar sem fatorar. A raiz do AR, $z = 2$, aparece também entre as raízes do MA, $\{2;\ 1{,}25\}$. Raiz repetida dos dois lados é sinal de fator comum.

- **Estacionário:** é um MA finito.
- **Invertível:** $1 - 0{,}8z = 0 \Rightarrow z = 1{,}25 > 1$.
- **Pesos ψ:** $\psi_1 = -0{,}8$ e $\psi_j = 0$ para $j \geq 2$.
- **Pesos π:** pela AU02, p. 23, $\pi_j = -(-\theta)^j$ com $\theta = -0{,}8$ nos slides, logo $\pi_j = -(0{,}8)^j$:

$$\pi_1 = -0{,}8; \quad \pi_2 = -0{,}64; \quad \pi_3 = -0{,}512; \quad \pi_4 = -0{,}4096.$$

Os ψ_j do modelo (3) escrito "inteiro" e os do MA(1) cancelado coincidem até $j = 20$, com diferença zero no R.

Do meu caderno (03/09)

O caderno escreve um ARMA(1,2) já na notação dos slides: $y_t - \phi_1 B y_t = \theta_1 B\varepsilon_t + \theta_2 B^2\varepsilon_t + \varepsilon_t$, logo $(1 - \phi_1 B)y_t = (1 + \theta_1 B + \theta_2 B^2)\varepsilon_t$. Depois as duas condições: $1 - \phi_1 z = 0$ com $|z| > 1$ (estacionariedade) e $1 + \theta_1 z + \theta_2 z^2 = 0$ com $|z| > 1$ (invertibilidade). O método está certo. No caderno, o polinômio do MA saiu como "$1 + \theta_2 zb + \theta_2 zb^2$"; o certo é $1 + \theta_1 z + \theta_2 z^2$. O caderno usa B com o sinal positivo dos slides: na prova, diga qual convenção está usando.

O que o livro acrescenta

BJRL (cap. 3) e HAMILTON (cap. 3) insistem no **fator comum**: um ARMA(p, q) com fator comum não é identificado. Infinitos pares (ϕ, θ) geram a mesma série, e a estimação fica instável, com erros-padrão enormes e $\hat{\phi} \approx -\hat{\theta}$ nos slides. A regra prática é sempre fatorar antes de classificar.

Armadilhas e variações

- **Bhaskara com o sinal de b trocado.** Em $0{,}4z^2 - 1{,}3z + 1$, $b = -1{,}3$ e $-b = +1{,}3$.
- **Classificar o modelo (3) como ARMA(1,2)** sem fatorar: perde o item inteiro.
- **π_j com o sinal errado.** $\pi(L) = 1 - \pi_1 L - \cdots$ tem o sinal de menos na definição (AU02, p. 19).
- **Variações:** $(1 - 0{,}8L + 0{,}15L^2)$, que também tem fator comum, $1 - 2{,}5L + L^2$, que não é invertível, e $1 - 1{,}2L + 0{,}2L^2$, que tem raiz unitária, no banco.

CAPÍTULO 7

Q6 · ARMA(1,1)

← índice · anterior: Q5 · próxima: Q7 · resolução curta em 02_lista

O que a questão pede

Para o ARMA(1,1) estacionário e invertível:

- **(a) calcular** γ_0, γ_1 e γ_k ($k \geq 2$);
- **(b) obter** ρ_1 e **mostrar** que $\rho_k = \phi^{k-1}\rho_1$;
- **(c) mostrar** as formas AR(∞) e MA(∞) e dizer quando a convergência é mais lenta.

Da lista para os slides

Lista (Box-Jenkins)	Slides (AU02, p. 81)
$z_t - \phi z_{t-1} = a_t - \theta a_{t-1}$	$(z_t - \mu) = \phi_1(z_{t-1} - \mu) + \varepsilon_t + \theta_1\varepsilon_{t-1}$

Nos slides, $\theta_1 = -\theta$ (lista) e $\phi_1 = \phi$. Abaixo, escrevo ϕ e θ **na convenção dos slides** e uso $\tilde{z}_t = z_t - \mu$. Cada resultado final aparece também na forma da lista.

Ferramentas

- **Slides:** AU02, p. 82–83 (γ_0 com a expansão do quadrado), p. 84 (γ_k), p. 87 (o ARMA(p,q) geral); AU02, p. 43 ($\Psi = \Theta/\Phi$).
- **Caixa:** [F4]; [F5]; [F6] momentos auxiliares; [F7] igualar coeficientes.
- **Livro:** HAMILTON, cap. 3 (ARMA(1,1)); BJRL, cap. 3 (as mesmas fórmulas na convenção da lista); ENDERS, cap. 2.

Demonstração minuciosa

Passo 0 — Os dois momentos auxiliares [F6]

Todo o resto depende destes dois:

- $E(\varepsilon_t\tilde{z}_t) = E\big(\varepsilon_t(\phi\tilde{z}_{t-1} + \varepsilon_t + \theta\varepsilon_{t-1})\big) = \phi \cdot 0 + \sigma^2 + \theta \cdot 0 = \sigma^2$. Os zeros vêm de: $\tilde{z}_{t-1}$ não depende de ε_t (causalidade), e $E(\varepsilon_t\varepsilon_{t-1}) = 0$ (RB).
- $E(\varepsilon_{t-1}\tilde{z}_t) = E\big(\varepsilon_{t-1}(\phi\tilde{z}_{t-1} + \varepsilon_t + \theta\varepsilon_{t-1})\big) = \phi E(\varepsilon_{t-1}\tilde{z}_{t-1}) + 0 + \theta\sigma^2 = \phi\sigma^2 + \theta\sigma^2 = (\phi + \theta)\sigma^2$. Usei o primeiro momento, deslocado um período.

(a) γ_0 — expandindo o quadrado (AU02, p. 82–83)

$\gamma_0 = E(\tilde{z}_t^2) = E\big((\phi\tilde{z}_{t-1} + \varepsilon_t + \theta\varepsilon_{t-1})^2\big)$. Pelo quadrado de três parcelas, $(A + B + C)^2 = A^2 + B^2 + C^2 + 2AB + 2AC + 2BC$:

Termo	Esperança	Por quê
$A^2 = \phi^2 \tilde{z}_{t-1}^2$	$\phi^2 \gamma_0$	estacionariedade: $E(\tilde{z}_{t-1}^2) = \gamma_0$
$B^2 = \varepsilon_t^2$	σ^2	RB
$C^2 = \theta^2 \varepsilon_{t-1}^2$	$\theta^2 \sigma^2$	RB
$2AB = 2\phi \tilde{z}_{t-1} \varepsilon_t$	0	causalidade [F6]
$2AC = 2\phi\theta \tilde{z}_{t-1} \varepsilon_{t-1}$	$2\phi\theta\sigma^2$	primeiro momento auxiliar, deslocado
$2BC = 2\theta \varepsilon_t \varepsilon_{t-1}$	0	RB

Somando: $\gamma_0 = \phi^2 \gamma_0 + \sigma^2 + \theta^2 \sigma^2 + 2\phi\theta\sigma^2$. Passe $\phi^2 \gamma_0$ para a esquerda e divida por $1 - \phi^2$ (que é diferente de zero, porque $|\phi| < 1$):

$$\boxed{\gamma_0 = \frac{1 + 2\phi\theta + \theta^2}{1 - \phi^2} \sigma^2} \qquad \text{(lista: } \gamma_0 = \tfrac{1+\theta^2-2\phi\theta}{1-\phi^2}\sigma^2\text{)}$$

(a) γ_1 (AU02, p. 84)

Multiplique o modelo por $\tilde{z}_{t-1}$ e tire a esperança:

$$\gamma_1 = \phi E(\tilde{z}_{t-1}^2) + E(\varepsilon_t \tilde{z}_{t-1}) + \theta E(\varepsilon_{t-1} \tilde{z}_{t-1}) = \phi\gamma_0 + 0 + \theta\sigma^2.$$

Substituindo γ_0 e pondo tudo sobre $1 - \phi^2$:

$$\gamma_1 = \frac{\phi(1 + 2\phi\theta + \theta^2) + \theta(1 - \phi^2)}{1 - \phi^2}\sigma^2 = \frac{\phi + 2\phi^2\theta + \phi\theta^2 + \theta - \phi^2\theta}{1 - \phi^2}\sigma^2 = \frac{\phi + \theta + \phi^2\theta + \phi\theta^2}{1 - \phi^2}\sigma^2.$$

O numerador fatora: $(1 + \phi\theta)(\phi + \theta) = \phi + \theta + \phi^2\theta + \phi\theta^2$ ✓ [F8]. Logo

$$\boxed{\gamma_1 = \frac{(1 + \phi\theta)(\phi + \theta)}{1 - \phi^2}\sigma^2} \qquad \text{(lista: } \gamma_1 = \tfrac{(1-\phi\theta)(\phi-\theta)}{1-\phi^2}\sigma^2\text{)}$$

(a) γ_k para $k \geq 2$

Multiplique por $\tilde{z}_{t-k}$:

$$\gamma_k = \phi\gamma_{k-1} + E(\varepsilon_t \tilde{z}_{t-k}) + \theta E(\varepsilon_{t-1} \tilde{z}_{t-k}).$$

Com $k \geq 2$, $\tilde{z}_{t-k}$ só depende de choques até $t - k \leq t - 2$, anteriores a $t - 1$ e a t: as duas esperanças são zero [F6]. Logo:

$$\boxed{\gamma_k = \phi\gamma_{k-1} \quad (k \geq 2) \qquad \Longrightarrow \qquad \gamma_k = \phi^{k-1}\gamma_1}$$

A última passagem é por indução: $\gamma_2 = \phi\gamma_1$, $\gamma_3 = \phi\gamma_2 = \phi^2\gamma_1$, e assim por diante.

(b) FAC

Dividindo por γ_0, o σ^2 e o $1-\phi^2$ cancelam:

$$\boxed{\rho_1 = \frac{(1+\phi\theta)(\phi+\theta)}{1+2\phi\theta+\theta^2}, \qquad \rho_k = \phi\rho_{k-1} = \phi^{k-1}\rho_1 \;\; (k \geq 1)}$$

Na lista: $\rho_1 = \frac{(1-\phi\theta)(\phi-\theta)}{1+\theta^2-2\phi\theta}$.

Leitura: a FAC do ARMA(1,1) **decai geometricamente como a de um AR(1), mas a partir de ρ_1, e não de 1**. O MA só mexe no primeiro valor (AU02, p. 87: para $k \geq q+1$, vale a recursão do AR).

Números, com $\phi = 0{,}7$ e $\theta^{\text{lista}} = 0{,}4$, isto é, $\theta = -0{,}4$ nos slides, e $\sigma^2 = 1$:

- $\gamma_0 = \frac{1+2(0{,}7)(-0{,}4)+0{,}16}{1-0{,}49} = \frac{1-0{,}56+0{,}16}{0{,}51} = \frac{0{,}60}{0{,}51} = 1{,}1765$;
- $\gamma_1 = 0{,}7(1{,}1765) - 0{,}4 = 0{,}4235$;
- $\rho_1 = 0{,}36$, $\rho_2 = 0{,}252$, $\rho_3 = 0{,}1764$: cada um é 0,7 vezes o anterior.

(c) MA(∞) e AR(∞)

MA(∞) [F7]. $\Psi(L) = \frac{1+\theta L}{1-\phi L}$, então $\Psi(L)(1-\phi L) = 1+\theta L$. Igualando as potências:

- L^1: $\psi_1 - \phi = \theta$, logo $\psi_1 = \phi + \theta$;
- L^j, $j \geq 2$: $\psi_j - \phi\psi_{j-1} = 0$, logo $\psi_j = \phi\psi_{j-1}$.

$$\boxed{\psi_j = (\phi+\theta)\phi^{j-1}} \qquad \text{(lista: } (\phi-\theta)\phi^{j-1}\text{)}$$

AR(∞). $\pi(L) = \frac{1-\phi L}{1+\theta L}$, então $\pi(L)(1+\theta L) = 1-\phi L$, com $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots$:

- L^1: $\theta - \pi_1 = -\phi$, logo $\pi_1 = \phi + \theta$;
- L^j, $j \geq 2$: $-\pi_j - \theta\pi_{j-1} = 0$, logo $\pi_j = -\theta\pi_{j-1}$.

$$\boxed{\pi_j = (\phi+\theta)(-\theta)^{j-1}} \qquad \text{(lista: } (\phi-\theta)\theta^{j-1}\text{)}$$

Com os mesmos números: $\psi_1, \psi_2, \psi_3 = 0{,}3;\ 0{,}21;\ 0{,}147$ e $\pi_1, \pi_2, \pi_3 = 0{,}3;\ 0{,}12;\ 0{,}048$.

Quando a convergência é mais lenta.

- Os ψ_j decaem como $|\phi|^j$: **mais devagar quanto mais perto de 1 estiver** $|\phi|$. Com $\phi = 0{,}95$, são precisos 80 pesos até $|\psi_j| < 0{,}01$; com $\phi = 0{,}3$, bastam 3.
- Os π_j decaem como $|\theta|^j$: mais devagar quanto mais perto de 1 estiver $|\theta|$, isto é, perto da não invertibilidade.

Do meu caderno (02/09)

O caderno segue exatamente o roteiro da AU02, p. 81–84:

- $E(y_t \mid \Omega_{t-1}) = c + \phi_1 y_{t-1} + \theta_1 \varepsilon_{t-1}$ e $V(y_t \mid \Omega_{t-1}) = \sigma^2$, certos;
- $\mu = c/(1-\phi_1)$, certo;
- os momentos auxiliares $E(\varepsilon_t\varepsilon_t) = \sigma^2$, $E((y_t - \mu)\varepsilon_t)$, $E((y_{t+1} - \mu)\varepsilon_t)$, certos.

Dois erros do caderno nesta questão

1. Na linha certa, $\gamma_0 = \phi_1^2\gamma_0 + \theta_1^2\sigma^2 + \sigma^2 + 2\phi_1\theta_1\sigma^2$, o θ_1 está ao quadrado. Duas linhas depois, o resultado final aparece como $\gamma_0 = \frac{\sigma^2(\theta_1+1+2\theta_1\phi_1)}{1-\phi_1^2}$: **o quadrado sumiu**. Com $\phi = 0{,}7$ e $\theta = -0{,}4$, a fórmula do caderno dá 0,0784, quando o certo é 1,1765.
2. "$\gamma_k = \phi_1^k\gamma_1$ para $k \geq 2$" está errado: o certo é $\gamma_k = \phi_1^{k-1}\gamma_1$. Confira com $k = 2$: $\gamma_2 = \phi_1\gamma_1$, um único ϕ_1.

É o erro "A, álgebra" do log: a linha intermediária estava certa, e o erro entrou ao copiar.

O que o livro acrescenta

BJRL (cap. 3) mostra o ARMA(1,1) como o caso em que **nem a FAC nem a FACP cortam**: as duas decaem. É por isso que ele é tão usado como "modelo de bolso" quando a identificação pela FAC e pela FACP fica ambígua (AU02, p. 96–97).

Armadilhas e variações

- **Misturar as convenções:** usar $\phi - \theta$ (lista) numa conta feita com o sinal dos slides.
- **Esquecer o termo cruzado** $2\phi\theta\sigma^2$ em γ_0: é ele que exige o segundo momento auxiliar.
- **Variações:** $\phi = 0{,}9$ e $\theta = 0{,}5$; $\phi = \theta$, que é ruído branco; e a versão com sinal positivo, no banco. Simulados: S01, Q2 e S03, Q2.

CAPÍTULO 8

Q7 · AR(2): Yule-Walker e variância

← índice · anterior: Q6 · próxima: Q8 · resolução curta em 02_lista

O que a questão pede

Para $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$:

- **(a) escrever** as equações de Yule-Walker e **resolvê-las** para ρ_1 e ρ_2;
- **(b) calcular** a variância γ_0.

Acrescento o que a prova costuma pedir junto: a **condição de estacionariedade** pelas raízes, com Bhaskara, e o exemplo numérico do meu caderno, refeito.

Da lista para os slides

Mesma notação: $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$, ou $(1 - \phi_1 L - \phi_2 L^2) y_t = \varepsilon_t$ (AU02, p. 12). Não há MA.

Ferramentas

- **Slides:** AU02, p. 68–69 (Yule-Walker), p. 27–28 (raízes z × autovalores λ), p. 37–41 (forma F e as três desigualdades do AR(2)), p. 92 (FACP); EQD, p. 24–26 (equação característica de segunda ordem e os três casos de raízes).
- **Caixa:** [F1] Bhaskara e módulo de complexos; [F6] causalidade.
- **Livro:** ENDERS, cap. 1 (equação de segunda ordem, raízes complexas e ciclos) e cap. 2; HAMILTON, cap. 1–3.

Demonstração minuciosa

(a) Yule-Walker (AU02, p. 68)

Multiplique o modelo por y_{t-k}, com $k \geq 1$, e tire a esperança. Com média zero, $E(y_t y_{t-k}) = \gamma_k$:

$$\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} + \underbrace{E(\varepsilon_t y_{t-k})}_{=0 \text{ [F6]}} \quad (k \geq 1).$$

Divida por γ_0:

$$\boxed{\rho_k = \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} \quad (k \geq 1)}$$

Use $\rho_0 = 1$ e a simetria $\rho_{-k} = \rho_k$:

- $k = 1$**:** $\rho_1 = \phi_1 \rho_0 + \phi_2 \rho_{-1} = \phi_1 + \phi_2 \rho_1$. Passando $\phi_2 \rho_1$ para a esquerda, $\rho_1(1 - \phi_2) = \phi_1$, e

$$\boxed{\rho_1 = \frac{\phi_1}{1 - \phi_2}}$$

- $k = 2$**:** $\rho_2 = \phi_1 \rho_1 + \phi_2 \rho_0 = \phi_1 \rho_1 + \phi_2$. Substituindo ρ_1:

$$\boxed{\rho_2 = \frac{\phi_1^2}{1-\phi_2} + \phi_2 = \frac{\phi_1^2 + \phi_2(1-\phi_2)}{1-\phi_2}}$$

(b) Variância γ_0

Multiplique o modelo por y_t, o caso $k = 0$:

$$\gamma_0 = \phi_1\gamma_1 + \phi_2\gamma_2 + E(\varepsilon_t y_t) = \phi_1\gamma_1 + \phi_2\gamma_2 + \sigma^2.$$

Usei $E(\varepsilon_t y_t) = \psi_0\sigma^2 = \sigma^2$ [F6]. Troque $\gamma_k = \rho_k\gamma_0$ e isole γ_0:

$$\gamma_0(1 - \phi_1\rho_1 - \phi_2\rho_2) = \sigma^2 \quad \Longrightarrow \quad \boxed{\gamma_0 = \frac{\sigma^2}{1 - \phi_1\rho_1 - \phi_2\rho_2}}$$

Forma fechada. Substitua ρ_1 e ρ_2 no denominador. Tudo sobre $1-\phi_2$:

$$1 - \phi_1\rho_1 - \phi_2\rho_2 = \frac{(1-\phi_2) - \phi_1^2 - \phi_2\phi_1^2 - \phi_2^2(1-\phi_2)}{1-\phi_2}.$$

Agrupando o numerador:

- $(1-\phi_2) - \phi_2^2(1-\phi_2) = (1-\phi_2)(1-\phi_2^2) = (1-\phi_2)(1-\phi_2)(1+\phi_2) = (1+\phi_2)(1-\phi_2)^2$;
- $-\phi_1^2 - \phi_2\phi_1^2 = -\phi_1^2(1+\phi_2)$.

Logo o numerador é $(1+\phi_2)\big[(1-\phi_2)^2 - \phi_1^2\big]$ e

$$\boxed{\gamma_0 = \frac{(1-\phi_2)\,\sigma^2}{(1+\phi_2)\big[(1-\phi_2)^2 - \phi_1^2\big]}}$$

Números, com $\phi_1 = 0{,}6$, $\phi_2 = 0{,}2$ e $\sigma^2 = 1$:

- $\rho_1 = 0{,}6/0{,}8 = 0{,}75$;
- $\rho_2 = 0{,}6(0{,}75) + 0{,}2 = 0{,}65$;
- $\gamma_0 = \frac{0{,}8}{1{,}2\,(0{,}64-0{,}36)} = \frac{0{,}8}{0{,}336} = 2{,}381$. Pela outra forma, $1/(1-0{,}45-0{,}13) = 1/0{,}42 = 2{,}381$ ✓.

Complemento — estacionariedade pelas raízes, com Bhaskara

A condição é que as raízes de $\phi(z) = 1 - \phi_1 z - \phi_2 z^2$ fiquem fora do círculo (AU02, p. 27). Com os números acima:

1. $1 - 0{,}6z - 0{,}2z^2 = 0$. Multiplicando por -1: $0{,}2z^2 + 0{,}6z - 1 = 0$, ou seja, $a = 0{,}2$, $b = 0{,}6$ e $c = -1$.
2. $\Delta = 0{,}6^2 - 4(0{,}2)(-1) = 0{,}36 + 0{,}80 = 1{,}16$.
3. $z = \frac{-0{,}6 \pm \sqrt{1{,}16}}{0{,}4} = \frac{-0{,}6 \pm 1{,}0770}{0{,}4}$, logo $z_1 = 1{,}1926$ e $z_2 = -4{,}1926$.
4. As duas têm módulo maior que 1: **estacionário**.

Na prova, há um atalho: as três desigualdades da AU02, p. 41. Aqui, $\phi_1 + \phi_2 = 0{,}8 < 1$, $\phi_2 - \phi_1 = -0{,}4 < 1$ e $|\phi_2| = 0{,}2 < 1$.

Do meu caderno (02/09 e 03/09) — o exemplo refeito

02/09. O caderno escreve o AR(2) em desvios, multiplica por $(y_{t-k} - \mu)$ e chega a $\gamma_k = \phi_1\gamma_{k-1} + \phi_2\gamma_{k-2}$, com $\gamma_1 = \phi_1\gamma_0 + \phi_2\gamma_1$, $\gamma_2 = \phi_1\gamma_1 + \phi_2\gamma_0$ e $\gamma_0 = \phi_1\gamma_1 + \phi_2\gamma_2 + \sigma^2$. Tudo certo: são as equações acima, antes de dividir por γ_0. O caderno também tem a FACP, $\rho_1 = \phi_1 + \phi_2\rho_1$ e $\rho_2 = \phi_1\rho_1 + \phi_2$ (AU02, p. 92 e 94), e a forma F do AR(2) com $\det(F - \lambda I) = \lambda^2 - \phi_1\lambda - \phi_2$, também certas.

03/09. O exemplo $y_t = 1{,}5y_{t-1} - 0{,}6y_{t-2} + a_t$, com Bhaskara. **O caderno erra o sinal logo no primeiro passo.** Refazendo do zero:

1. **Passe todos os termos em y para a esquerda:** $y_t - 1{,}5y_{t-1} + 0{,}6y_{t-2} = a_t$, logo $(1 - 1{,}5L + 0{,}6L^2)y_t = a_t$.

   Os coeficientes são $\phi_1 = 1{,}5$ e $\phi_2 = -0{,}6$, e no polinômio entra $-\phi_2 L^2 = +0{,}6L^2$. O caderno escreveu $-0{,}6B^2$.
2. **Equação característica**, a dos autovalores λ (AU02, p. 28): $\lambda^2 - \phi_1\lambda - \phi_2 = 0$, ou seja, $\lambda^2 - 1{,}5\lambda + 0{,}6 = 0$. O caderno escreveu $-0{,}6$.
3. **Discriminante:** $\Delta = (-1{,}5)^2 - 4(1)(0{,}6) = 2{,}25 - 2{,}40 = -0{,}15$. É negativo, então as raízes são complexas (EQD, p. 25, caso 3).
4. **Raiz de um número negativo:** $\sqrt{-0{,}15} = i\sqrt{0{,}15} = 0{,}3873\,i$.
5. **Raízes:** $\lambda = \frac{1{,}5 \pm 0{,}3873\,i}{2} = 0{,}75 \pm 0{,}1936\,i$.
6. **Módulo** [F1]: $|\lambda| = \sqrt{0{,}75^2 + 0{,}1936^2} = \sqrt{0{,}5625 + 0{,}0375} = \sqrt{0{,}6} = 0{,}7746$.
   - As **duas** conjugadas têm o mesmo módulo, 0,7746.
   - Atalho de Vieta: $|\lambda|^2 = c/a = 0{,}6$.
7. **Conclusão:** $|\lambda| = 0{,}7746 < 1$, dentro do círculo, o que equivale a $|z| = 1/0{,}7746 = 1{,}2910 > 1$, fora (AU02, p. 28). **Estacionário.** O maior autovalor da matriz F, calculado no R, é 0,7746 ✓.
8. **Conferência pelas desigualdades:** $\phi_1 + \phi_2 = 0{,}9 < 1$, $\phi_2 - \phi_1 = -2{,}1 < 1$ e $|\phi_2| = 0{,}6 < 1$ ✓.
9. **O que as raízes complexas significam:** a FAC e as respostas a choques são uma **senoide amortecida**. O processo tem um pseudociclo que encolhe à taxa 0,7746 por período.

> **O que o caderno errou neste exemplo**
>
> - **Sinal do polinômio:** escreveu $1 - 1{,}5B - 0{,}6B^2$ e $\lambda^2 - 1{,}5\lambda - 0{,}6$. Com esse sinal, Δ seria $2{,}25 + 2{,}4 = 4{,}65$, positivo, e as raízes seriam reais.
> - **Δ:** escreveu $\Delta = 0{,}15$, positivo, e logo depois $\sqrt{-0{,}15}$. O certo é $\Delta = -0{,}15$.
> - **Parte imaginária:** escreveu $\frac{1{,}5 \pm 0{,}15i}{2}$, quando o certo é $\frac{1{,}5 \pm \sqrt{0{,}15}\,i}{2}$. Ainda assim, chegou a $0{,}75 \pm 0{,}19i$, que está certo.
> - **Módulos:** escreveu $\lambda_1 = \sqrt{0{,}75^2 + 0{,}19^2} \approx 0{,}6$, mas 0,6 é o **quadrado** do módulo; o módulo é 0,7746. E escreveu $\lambda_2 = \sqrt{0{,}75 - 0{,}19^2} \approx 0{,}52$, uma fórmula que não existe (daria 0,8449). As conjugadas têm o mesmo módulo.
>
> A conclusão "estacionário" estava certa por acaso. Numa prova que pede o módulo, perdem-se os pontos da conta.

O que o livro acrescenta

ENDERS (cap. 1) e a revisão EQD (p. 25) dão a leitura das raízes complexas: escrevendo $\lambda = r(\cos\omega \pm i\sin\omega)$, o módulo r diz se o ciclo amortece ($r < 1$) ou explode, e ω dá o período, $2\pi/\omega$. No exemplo, $\cos\omega = 0{,}75/0{,}7746$, logo $\omega \approx 0{,}2527$ rad, e o período é de $2\pi/\omega \approx 24{,}87$ observações.

Armadilhas e variações

- **Confundir z e λ:** "raízes fora" vale para z, "dentro" vale para λ. Diga qual está usando.
- $\rho_2 = \phi_2$**:** errado. Quem é igual a ϕ_2 é a **FACP** em 2, ϕ_{22} (AU02, p. 92).
- **Variações:** $\phi = (1;\ -0{,}5)$, com raízes complexas e ciclo de 8 períodos, no banco; $\phi = (0{,}5;\ 0{,}3)$ completo no Simulado 02, Q2.

CAPÍTULO 9

Q8 · Verdadeiro ou falso, com demonstração

← índice · anterior: Q7 · próxima: Q9 · resolução curta em 02_lista

O que a questão pede

Julgar cinco afirmativas, **com demonstração**, sobre dois modelos:

- **(I)** ARMA(1,1), com $\gamma_h = E(Y_t Y_{t+h})$;
- **(II)** passeio com drift c e tendência θt.

Da lista para os slides

A Q8 é a única questão da lista que **já usa o sinal positivo dos slides**:

Lista	Slides
(I) $Y_t = \alpha Y_{t-1} + u_t + \beta u_{t-1}$, $0 < \alpha < 1$, Y_0 fixo	$y_t = \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$ (AU02, p. 81), com $\phi_1 = \alpha$ e $\theta_1 = \beta$
(II) $Z_t = c + Z_{t-1} + \theta t + \varepsilon_t$	$Y_t = \alpha_1 + Y_{t-1} + \alpha_2 t + \varepsilon_t$ (AU01, p. 30), com $\alpha_1 = c$ e $\alpha_2 = \theta$

Mantenho as letras da lista, α e β, porque é nelas que as afirmativas estão escritas. Como Y_0 é fixo, o processo (I) só é estacionário depois que o efeito do valor inicial, $\alpha^t Y_0$, some. As afirmativas tratam dos momentos estacionários.

Ferramentas

- **Slides:** AU02, p. 83–84 (γ_0 e γ_1 do ARMA(1,1) com sinal positivo); AU01, p. 30.
- **Caixa:** [F3]; [F6] momentos auxiliares $E(Y_t u_t) = \sigma^2$ e $E(Y_t u_{t-1}) = (\alpha + \beta)\sigma^2$.
- **Livro:** HAMILTON, cap. 3.

Os momentos auxiliares (valem para 1 a 3)

- $E(Y_t u_t) = E\big((\alpha Y_{t-1} + u_t + \beta u_{t-1}) u_t\big) = 0 + \sigma^2 + 0 = \sigma^2$.
- $E(Y_t u_{t-1}) = E\big((\alpha Y_{t-1} + u_t + \beta u_{t-1}) u_{t-1}\big) = \alpha\sigma^2 + 0 + \beta\sigma^2 = (\alpha + \beta)\sigma^2$.

As cinco afirmativas

1. $\gamma_0 = \alpha\gamma_1 + \sigma^2 + \beta(\alpha+\beta)\sigma^2$ — **VERDADEIRA**

Multiplique o modelo por Y_t e tire a esperança:

$$\gamma_0 = E(Y_tY_t) = \alpha E(Y_{t-1}Y_t) + E(u_tY_t) + \beta E(u_{t-1}Y_t) = \alpha\gamma_1 + \sigma^2 + \beta(\alpha+\beta)\sigma^2.$$

$E(Y_{t-1}Y_t) = \gamma_1$ pela definição $\gamma_h = E(Y_tY_{t+h})$, e os outros dois termos são os momentos auxiliares. **É exatamente a afirmativa.**

Com $\alpha = 0{,}6$, $\beta = 0{,}3$ e $\sigma^2 = 1$: $\gamma_0 = 2{,}265625$, e o lado direito dá $0{,}6(1{,}659375) + 1 + 0{,}3(0{,}9) = 2{,}265625$ ✓.

2. $\gamma_1 = \alpha(\gamma_0 + \sigma^2) + \beta\sigma^2$ — **FALSA**

Multiplique o modelo de Y_{t+1} por Y_t:

$$\gamma_1 = E(Y_{t+1}Y_t) = \alpha E(Y_tY_t) + E(u_{t+1}Y_t) + \beta E(u_tY_t) = \alpha\gamma_0 + 0 + \beta\sigma^2.$$

O zero vem de u_{t+1}, que é futuro em relação a Y_t [F6]. Logo $\gamma_1 = \alpha\gamma_0 + \beta\sigma^2$ (AU02, p. 84). A afirmativa tem um $\alpha\sigma^2$ **a mais**. Com os números: o certo é 1,659375, e a afirmativa dá 2,259375.

3. $\rho_h = \frac{(\beta+\alpha)(1+\alpha\beta)}{1+2\alpha\beta+\beta^2}$ — **FALSA (só vale para $h = 1$)**

Resolvendo o sistema das afirmativas 1 e 2 (a versão corrigida da 2), como na Q6:

$$\gamma_0 = \frac{1+2\alpha\beta+\beta^2}{1-\alpha^2}\sigma^2, \qquad \gamma_1 = \frac{(1+\alpha\beta)(\alpha+\beta)}{1-\alpha^2}\sigma^2 \quad\Longrightarrow\quad \rho_1 = \frac{(\alpha+\beta)(1+\alpha\beta)}{1+2\alpha\beta+\beta^2}.$$

Para $h \geq 2$, porém, $\gamma_h = \alpha\gamma_{h-1}$, porque os choques de Y_{t+h} não se cruzam com Y_t. Logo $\rho_h = \alpha^{h-1}\rho_1$, que **muda com** h. A afirmativa escreve uma expressão que não depende de h. Com os números: $\rho_1 = 0{,}7324$, que coincide com a expressão, mas $\rho_2 = 0{,}4394 \neq 0{,}7324$.

4. $Z_t = ct + \frac{\theta}{2}t^2 + Z_0 + \sum_{j=1}^{t}\varepsilon_j$ — **FALSA**

Somando a equação de 1 a t, como na Q2:

$$Z_t = Z_0 + ct + \theta\sum_{s=1}^{t} s + \sum_{j=1}^{t}\varepsilon_j = Z_0 + ct + \theta\frac{t(t+1)}{2} + \sum_{j=1}^{t}\varepsilon_j \quad \text{[F3]}.$$

A afirmativa troca $\frac{t(t+1)}{2} = \frac{t^2}{2} + \frac{t}{2}$ por $\frac{t^2}{2}$: falta $\frac{\theta t}{2}$. Com $c = 1$, $\theta = 0{,}5$ e $Z_0 = 0$: $E(Z_4) = 4 + 0{,}5 \cdot 10 = 9$, enquanto a afirmativa dá $4 + 0{,}25 \cdot 16 = 8$.

5. $V(Z_t) = (c + \theta t)\sigma^2$ — **FALSA**

Pela afirmativa 4 corrigida, a única parte aleatória é $\sum_{j=1}^{t}\varepsilon_j$, e Z_0, ct e $\theta t(t+1)/2$ são constantes. Logo $V(Z_t) = V\left(\sum\varepsilon_j\right) = t\sigma^2$ [F5]. **Drift e tendência não têm variância.**

Gabarito: V, F, F, F, F.

Do meu caderno (02/09)

Os momentos auxiliares desta questão são os do caderno: "$E((y_t - \mu)\varepsilon_t) = \sigma^2$" e "$E((y_{t+1} - \mu)\varepsilon_t) = \phi_1\sigma^2$". O caderno os escreve para o **AR(1)**. No ARMA(1,1), o segundo vira $(\phi_1 + \theta_1)\sigma^2$, por causa do termo MA. Ver a correção do γ_0 do caderno na Q6.

Armadilhas e variações

- **Responder V ou F sem a conta.** Vale zero quando o enunciado diz "com demonstração". É a lição da Q5 da P1 de Econometria I: a conclusão é a última linha, não a única.
- **Achar que a Q8 está na convenção da lista.** Ela está na dos slides: $+\beta$.
- **Variações:** o mesmo V ou F com outros itens (os π_j com sinal alternado e a invertibilidade dependendo de β) no Simulado 03, Q2; $E(Z_4)$ no banco.

Parte IV

Bloco 3 — Integrados, ARIMA e SARIMA

Q9 · Sobrediferenciação: diferenciar um AR(1) que já é estacionário

← índice · anterior: Q8 · próxima: Q10 · resolução curta em 03_lista · demonstração D03.2 em 03_teoria

O que a questão pede

Para $y_t = \phi y_{t-1} + \varepsilon_t$ com $|\phi| < 1$ e $w_t = \Delta y_t$:

- **(a) mostrar** que $w_t = -(1-\phi)y_{t-1} + \varepsilon_t$ e que $(1-\phi L)w_t = (1-L)\varepsilon_t$, identificando os polinômios;
- **(b) mostrar** que o MA de w_t tem raiz unitária e dizer o que isso implica para o AR(∞);
- **(c) discutir** por que diferenciar uma série estacionária prejudica a previsão e a estimação.

Da lista para os slides

Mesmo modelo, com L no lugar de B. O MA de w_t é $1 - L$: nos slides, $1 + \theta L$ com $\theta = -1$; na lista, $1 - \theta B$ com $\theta = 1$.

Ferramentas

- **Slides:** AU02, p. 21 (AR(1) como MA(∞)), p. 22–23 (π_j do MA(1) e a condição $|\theta| < 1$), p. 33 (raízes do MA), p. 63 (variância do AR(1)).
- **Caixa:** [F2]; [F5]; [F8].
- **Livro:** MAT, §1.4–1.5 (processo integrado; raiz unitária no MA é não invertibilidade); BJRL, cap. 4; ENDERS, cap. 4.

Demonstração minuciosa

(a) As duas formas de w_t

Primeira forma. Substitua o modelo em $w_t = y_t - y_{t-1}$:

$$w_t = (\phi y_{t-1} + \varepsilon_t) - y_{t-1} = (\phi - 1)y_{t-1} + \varepsilon_t = \boxed{-(1-\phi)y_{t-1} + \varepsilon_t}$$

Segunda forma. O AR(1) em operador é $(1-\phi L)y_t = \varepsilon_t$. Aplique $(1-L)$ aos dois lados:

$$(1-L)(1-\phi L)y_t = (1-L)\varepsilon_t.$$

Os polinômios em L comutam, porque o produto [F8] dá $1 - (1+\phi)L + \phi L^2$ nas duas ordens. Então $(1-\phi L)\underbrace{(1-L)y_t}_{w_t} = (1-L)\varepsilon_t$, ou seja,

$$\boxed{(1-\phi L)\, w_t = (1-L)\, \varepsilon_t}$$

Pela forma MA(∞), como pede a lista: $y_t = \Psi(L)\varepsilon_t$ com $\Psi(L) = (1-\phi L)^{-1}$, logo $w_t = (1-L)y_t = (1-L)\Psi(L)\varepsilon_t = \frac{1-L}{1-\phi L}\varepsilon_t$. Multiplicando por $(1-\phi L)$, obtém-se a mesma equação.

Polinômios:

- AR: $\phi(L) = 1 - \phi L$, o mesmo de y;
- MA: $\theta(L) = 1 - L$, um ARMA(1,1) com $\theta = -1$ nos slides.

(b) A raiz unitária do MA

$\theta(z) = 1 - z = 0 \Rightarrow z = 1$, e $|z| = 1$ não é maior que 1: a raiz está **sobre** o círculo unitário. Pela AU02, p. 33, o processo **não é invertível**.

O que acontece com o AR(∞). $\pi(L) = \frac{1-\phi L}{1-L}$. A expansão de $(1 - L)^{-1} = 1 + L + L^2 + \cdots$ é a série geométrica com razão de módulo 1, que **não converge** [F2]. Mesmo assim, formalmente:

$$\pi(L) = (1 - \phi L)(1 + L + L^2 + \cdots) = 1 + (1 - \phi)L + (1 - \phi)L^2 + \cdots$$

Como $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots$, vale $\pi_j = -(1 - \phi)$ **para todo** j: os pesos não decaem. Com $\phi = 0{,}6$, $\pi_5 = -0{,}4$, igual a π_1. Então:

$$\boxed{\pi_j = -(1 - \phi) \text{ para todo } j \implies \sum_{j \geq 1} |\pi_j| = \infty}$$

Conclusão: não existe representação AR(∞) convergente, e ε_t não pode ser recuperado de $w_t, w_{t-1}, \ldots$

(c) Por que sobrediferenciar prejudica

Os momentos mostram o estrago. Use $\gamma_k = \phi^k \gamma_0$ e $\gamma_0 = \sigma^2/(1 - \phi^2)$ (AU02, p. 63):

- **Variância:** $V(w_t) = V(y_t) + V(y_{t-1}) - 2\,\mathrm{Cov}(y_t, y_{t-1}) = 2\gamma_0 - 2\gamma_1 = 2\gamma_0(1 - \phi)$ [F5]. Como $1 - \phi^2 = (1 - \phi)(1 + \phi)$, fica $V(w_t) = \frac{2\sigma^2}{1+\phi}$.
- **Autocovariância:** $\mathrm{Cov}(w_t, w_{t-1}) = \mathrm{Cov}(y_t - y_{t-1},\ y_{t-1} - y_{t-2}) = \gamma_1 - \gamma_2 - \gamma_0 + \gamma_1 = \gamma_0(2\phi - 1 - \phi^2) = -\gamma_0(1 - \phi)^2$.
- **Autocorrelação:** $\rho_1(w) = \frac{-\gamma_0(1-\phi)^2}{2\gamma_0(1-\phi)} = -\frac{1-\phi}{2}$.

Com $\phi = 0{,}6$ e $\sigma^2 = 1$: $V(y) = 1{,}5625$, $V(w) = 1{,}25$ e $\rho_1(w) = -0{,}2$. A FAC de w ganha um **pico negativo em 1**: é a assinatura da sobrediferenciação. Se y fosse ruído branco, seria $\rho_1 = -0{,}5$.

Consequências para a estimação:

1. O MA verdadeiro está na fronteira, $\theta = -1$. A MV tende a empilhar estimativas em $|\hat{\theta}| = 1$ (o "pile-up" de D03.2), e os erros-padrão e testes deixam de ter a distribuição usual.
2. A verossimilhança condicional, que reconstrói ε_t por recursão (AU02, p. 59), **não esquece o valor inicial** quando $|\theta| = 1$, e os resíduos ficam contaminados.
3. Estima-se um parâmetro a mais, o MA, que não existia no processo verdadeiro: perde-se parcimônia.

Consequências para a previsão:

1. O modelo em diferença trata y como I(1): a previsão de y_{T+h} **não volta à média**, quando o verdadeiro $\hat{y}_{T+h} \to \mu$.
2. A variância do erro cresce **sem limite** com h, quando a verdadeira converge para γ_0: os intervalos ficam largos demais.
3. Perde-se a informação sobre o **nível** da série.

Regra: só diferencie com evidência de raiz unitária, com ADF e KPSS juntos (AU04; MAT §2).

Do meu caderno (26/08)

O caderno calcula γ_0 do AR(1) com a decomposição **A + B + C**: $E\big((\phi_1(y_{t-1}-\mu)+\varepsilon_t)^2\big)$. É a conta que dá o γ_0 usado no item (c). Completando o que ficou aberto:

- **(A)** $\phi_1^2 E\big((y_{t-1}-\mu)^2\big) = \phi_1^2\gamma_0$: certo, por estacionariedade;
- **(B)** $2\phi_1 E\big((y_{t-1}-\mu)\varepsilon_t\big)$: o caderno abre $y_{t-1}-\mu = \phi_1(y_{t-2}-\mu)+\varepsilon_{t-1}$ e para. A conclusão é $B=0$, porque y_{t-1} só tem choques até $t-1$, e nenhum se correlaciona com ε_t [F6];
- **(C)** $E(\varepsilon_t^2)=\sigma^2$: certo.

Logo $\gamma_0 = \phi_1^2\gamma_0 + \sigma^2$, e $\gamma_0 = \sigma^2/(1-\phi_1^2)$, como na AU02, p. 63. A anotação "$E(\varepsilon_t^2) \neq E(\varepsilon_t)^2$" também está certa: a primeira vale σ^2, e a segunda, 0.

O que o livro acrescenta

MAT (§1.5) observa que um ARIMA pode ter raiz unitária no **MA**, e não só no AR, e que nesse caso o modelo é não invertível. A Q9 é exatamente isso. É também a base do teste KPSS: sob a hipótese de estacionariedade, a diferença tem uma raiz unitária no MA.

Armadilhas e variações

- **Dizer "não invertível" sem a cadeia completa:** raiz $z=1 \Longrightarrow \pi_j$ não decaem $\Longrightarrow$ não há AR(∞). As três partes valem ponto.
- **Variância:** escrever $V(w)=2\sigma^2$, que só vale se y for ruído branco.
- **Variações:** ruído branco diferenciado e $\phi=0{,}9$ no banco; $\phi=0{,}5$ completo no Simulado 01, Q3.

CAPÍTULO 11

Q10 · ARIMA, raiz unitária e tendência determinística

← índice · anterior: Q9 · próxima: Q11 · resolução curta em 03_lista

O que a questão pede

- **(a) Mostrar** que, se $y_t \sim$ ARIMA(p,1,q), então $\Delta y_t \sim$ ARMA(p, q).
- **(b) Expandir** o ARIMA(1,1,1) numa equação de diferenças para y_t.
- **(c) Discutir** a diferença entre raiz unitária e tendência determinística.
- **(d) Dizer** o que resulta de diferenciar uma série que só tem tendência determinística, e se isso é adequado.
- **(e) Explicar** por que tirar a tendência por regressão é preferível, ligando com a sobrediferenciação.

Da lista para os slides

Lista	Slides
$(1-\phi B)(1-B)y_t = (1-\theta B)a_t$	$(1-\phi L)(1-L)y_t = (1+\theta^s L)\varepsilon_t$, com $\theta^s = -\theta$
tendência determinística $\alpha + \beta t$	$TD_t = a + bt$ (MAT, §1.1)

Ferramentas

- **Slides:** AU01, p. 28–30 (passeio, drift e tendência); MAT, §1.1–1.4 e Quadro 1 (p. 20).
- **Caixa:** [F8] multiplicar polinômios; [F5].
- **Livro:** ENDERS, cap. 4 (DS × TS); MAT, decomposição de Beveridge-Nelson (§1.6).

Demonstração minuciosa

(a) A diferença de um ARIMA(p,1,q) é um ARMA(p, q)

Por definição, $y_t \sim$ ARIMA(p,1,q) significa $\phi(L)(1-L)y_t = \theta(L)\varepsilon_t$, com $\phi(z)$ e $\theta(z)$ com todas as raízes fora do círculo (MAT, §1.4). Defina $w_t = (1-L)y_t = \Delta y_t$. Substituindo:

$$\phi(L)\, w_t = \theta(L)\, \varepsilon_t.$$

É um ARMA(p, q) para w_t: estacionário, porque as raízes de ϕ estão fora, e invertível, porque as de θ estão fora. **A raiz unitária está toda no fator** $(1-L)$, que a diferença remove. ■

(b) Expansão do ARIMA(1,1,1)

Multiplique o lado AR termo a termo [F8]:

$$(1-\phi L)(1-L) = 1\cdot 1 - 1\cdot L - \phi L\cdot 1 + \phi L\cdot L = 1-(1+\phi)L+\phi L^2.$$

Então $\left(1-(1+\phi)L+\phi L^2\right)y_t = (1+\theta^s L)\varepsilon_t$. Aplicando os operadores:

$$y_t - (1+\phi)y_{t-1} + \phi y_{t-2} = \varepsilon_t + \theta^s \varepsilon_{t-1}$$

$$\boxed{y_t = (1+\phi)y_{t-1} - \phi y_{t-2} + \varepsilon_t + \theta^s \varepsilon_{t-1}} \qquad \text{(lista: } \cdots + a_t - \theta a_{t-1}\text{)}$$

A marca da raiz unitária: os coeficientes AR somam $(1+\phi)+(-\phi) = 1$. Com $\phi = 0{,}4$, os coeficientes são 1,4 e $-0{,}4$. O polinômio $1 - 1{,}4z + 0{,}4z^2$ tem raiz $z = 1$: vale $1 - 1{,}4 + 0{,}4 = 0$.

(c) Raiz unitária × tendência determinística

	Raiz unitária (DS)	Tendência determinística (TS)
Modelo	$y_t = \beta + y_{t-1} + u_t$	$y_t = \alpha + \beta t + u_t$, com u_t estacionário
Solução	$y_t = y_0 + \beta t + \sum_{i\le t} u_i$	$y_t = \alpha + \beta t + u_t$
Efeito de um choque	**permanente**: entra na soma para sempre	**transitório**: some à velocidade de u_t
Variância	cresce com t	constante em torno da reta
Intervalo de previsão	alarga sem limite com h	fica limitado
Como estacionarizar	**diferenciar**	**regredir em** t e ficar com o resíduo

As duas séries **parecem iguais no gráfico**: crescem ao longo de uma reta. O que muda é o que acontece depois de um choque. MAT (Quadro 1) chama a primeira de "diferença estacionária" e a segunda de "tendência estacionária".

(d) Diferenciar uma série TS

Com $y_t = \alpha + \beta t + u_t$:

$$\Delta y_t = (\alpha + \beta t + u_t) - (\alpha + \beta(t-1) + u_{t-1}) = \beta + u_t - u_{t-1} = \beta + (1-L)u_t.$$

- Se u_t é ruído branco: $\Delta y_t = \beta + \varepsilon_t - \varepsilon_{t-1}$, um MA(1) com $\theta^s = -1$, **não invertível**, com $\rho_1 = \frac{-1}{1+1} = -0{,}5$.
- Se u_t é AR(1): $(1-\phi L)(\Delta y_t - \beta) = (1-L)\varepsilon_t$, exatamente a Q9.

$$\boxed{\Delta y_t = \beta + (1-L)\,u_t}$$

Conclusão: não é adequado. Diferenciar uma TS cria o fator $(1-L)$, uma raiz unitária, no MA. É a sobrediferenciação.

(e) Por que tirar a tendência por regressão é preferível (para uma TS)

1. **Mantém o modelo invertível:** o resíduo u_t é um ARMA estacionário comum, sem raiz no MA.
2. **Estimação regular:** sem parâmetro na fronteira, a inferência usual vale (Q9c).
3. **Previsão correta:** a previsão volta para a reta $\alpha + \beta(T + h)$, e os intervalos ficam limitados. O modelo diferenciado erraria nas duas coisas.
4. **Ligação com a sobrediferenciação:** a diferença é o remédio **para a raiz unitária**. Usada numa série sem raiz unitária, ela "sobra" e vira o fator $(1 - L)$ no MA.

O erro simétrico também existe: tirar a tendência por regressão de uma série DS deixa uma **raiz unitária no resíduo**, e a regressão em *t* fica espúria. **Quem decide é o teste:** ADF com constante e tendência (MAT, §2; AU04).

Do meu caderno (19/08)

"Passeio com drift: $Y_t = \alpha + Y_{t-1} + \varepsilon_t$"; "$+\alpha_2 t$: termo de tendência determinística"; "teste de **raiz unitária**"; "$|\phi| < 1$ estável; $|\phi| \geq 1$ instável"; "tendência estocástica: ϕ". Essa última anotação resume a questão: **tendência estocástica é** $\phi = 1$, a raiz unitária, e não uma função de *t*.

O que o livro acrescenta

MAT (§1.6) apresenta a **decomposição de Beveridge-Nelson**: todo processo I(1) é a soma de uma tendência estocástica (um passeio aleatório) com um componente estacionário. A raiz unitária não é "uma tendência mais forte". É outro tipo de não estacionariedade.

Armadilhas e variações

- **Na (b), esquecer de trocar o sinal do MA** ao passar dos slides para a lista.
- **Na (d), parar em "$\Delta y_t = \beta + u_t - u_{t-1}$"** sem dizer que o resultado é não invertível e, portanto, inadequado. O verbo é "esse procedimento é adequado?".
- **Variações:** a expansão do ARIMA(2,1,0) e a TS com ruído branco no banco; TS × DS com números no Simulado 03, Q1.

CAPÍTULO 12

Q11 · SAR(1)$_4$ e o multiplicativo como AR(5) restrito

← índice · anterior: Q10 · próxima: Q12 · resolução curta em 03_lista

O que a questão pede

Para $y_t = \Phi y_{t-4} + \varepsilon_t$ com $|\Phi| < 1$:

- **(a) calcular** γ_0, γ_4, γ_8 e γ_{4m}, e dizer quanto vale γ_k fora dos múltiplos de 4;
- **(b) descrever** a FAC e a FACP e comparar com o AR(1);
- **(c) escrever** $(1-\phi L)(1-\Phi L^4)y_t = \varepsilon_t$ como AR(5) e dar as restrições.

Da lista para os slides

Mesma notação, com L no lugar de B. O SAR(1)$_4$ é um AR(4) com $\phi_1 = \phi_2 = \phi_3 = 0$ e $\phi_4 = \Phi$. Assim, as ferramentas do AR(p) dos slides valem diretamente.

Ferramentas

- **Slides:** AU02, p. 63–64 (γ_0 e γ_k do AR(1), cujo método se repete aqui), p. 68 (Yule-Walker do AR(p)), p. 90–93 (FACP e o corte do AR); AU05 (sazonalidade).
- **Caixa:** [F6]; [F8].
- **Livro:** BJRL, cap. 9 (modelos sazonais multiplicativos); ENDERS, cap. 2 (sazonalidade).

Demonstração minuciosa

(a) Autocovariâncias

γ_0. Eleve ao quadrado e tire a esperança:

$$\gamma_0 = E\big((\Phi y_{t-4} + \varepsilon_t)^2\big) = \Phi^2 E(y_{t-4}^2) + 2\Phi \underbrace{E(y_{t-4}\varepsilon_t)}_{0\ [F6]} + E(\varepsilon_t^2) = \Phi^2\gamma_0 + \sigma^2,$$

$$\boxed{\gamma_0 = \frac{\sigma^2}{1-\Phi^2}}$$

γ_k, $k \geq 1$. Multiplique por y_{t-k}: $\gamma_k = \Phi\gamma_{k-4} + E(\varepsilon_t y_{t-k}) = \Phi\gamma_{k-4}$, com $\gamma_{-j} = \gamma_j$.

Múltiplos de 4:

- $\gamma_4 = \Phi\gamma_0$;
- $\gamma_8 = \Phi\gamma_4 = \Phi^2\gamma_0$;
- por indução, $\gamma_{4m} = \Phi^m\gamma_0$.

$$\boxed{\gamma_{4m} = \Phi^m \frac{\sigma^2}{1-\Phi^2}, \qquad \rho_{4m} = \Phi^m}$$

Fora dos múltiplos:

- $k = 1$: $\gamma_1 = \Phi\gamma_{-3} = \Phi\gamma_3$.
- $k = 3$: $\gamma_3 = \Phi\gamma_{-1} = \Phi\gamma_1$.
- Substituindo uma na outra: $\gamma_1 = \Phi^2\gamma_1$, ou $\gamma_1(1 - \Phi^2) = 0$. Como $\Phi^2 \neq 1$, $\gamma_1 = 0$, e daí $\gamma_3 = 0$.
- $k = 2$: $\gamma_2 = \Phi\gamma_{-2} = \Phi\gamma_2$, ou $\gamma_2(1 - \Phi) = 0$, logo $\gamma_2 = 0$.
- Para $k \geq 5$ fora dos múltiplos, $\gamma_k = \Phi\gamma_{k-4}$ cai num desses zeros.

$$\boxed{\gamma_k = 0 \text{ se } k \text{ não é múltiplo de 4}}$$

Números, com $\Phi = 0{,}7$ e $\sigma^2 = 1$: $\gamma_0 = 1/0{,}51 = 1{,}9608$, $\rho_4 = 0{,}7$, $\rho_8 = 0{,}49$, e $\rho_1 = \rho_2 = \rho_3 = 0$.

(b) FAC e FACP

	AR(1), ϕ	SAR(1)$_4$, Φ
FAC	ϕ^k em **todas** as defasagens, decaindo	Φ^m **só em** 4, 8, 12, ...; zero no resto
FACP	um pico, em 1 ($\phi_{11} = \phi$)	um pico, em 4 ($\phi_{44} = \Phi$); zero no resto

O SAR(1)$_4$ é o **AR(1) "esticado"**: a dependência pula de ano em ano, de trimestre para o mesmo trimestre. Pela AU02, p. 93, a FACP de um AR(p) corta depois de p. Aqui, o AR(4) tem $\phi_4 = \Phi$ e os outros zeros, então $\phi_{44} = 0{,}7$ e $\phi_{88} = 0$.

(c) O multiplicativo como AR(5) restrito

Multiplique termo a termo [F8]:

$$(1 - \phi L)(1 - \Phi L^4) = 1 - \Phi L^4 - \phi L + \phi\Phi L^5 = 1 - \phi L - \Phi L^4 + \phi\Phi L^5.$$

Então $y_t - \phi y_{t-1} - \Phi y_{t-4} + \phi\Phi y_{t-5} = \varepsilon_t$, ou

$$\boxed{y_t = \phi y_{t-1} + 0 \cdot y_{t-2} + 0 \cdot y_{t-3} + \Phi y_{t-4} - \phi\Phi\, y_{t-5} + \varepsilon_t}$$

Comparando com o AR(5) livre, $y_t = \sum_{i=1}^{5} \phi_i y_{t-i} + \varepsilon_t$, são **três restrições**:

$$\phi_2 = 0, \qquad \phi_3 = 0, \qquad \phi_5 = -\phi_1\phi_4.$$

O AR(5) livre tem 5 coeficientes; o multiplicativo tem 2. Com $\phi = 0{,}4$ e $\Phi = 0{,}7$: $\phi_1 = 0{,}4$, $\phi_4 = 0{,}7$ e $\phi_5 = -0{,}28 = -(0{,}4)(0{,}7)$.

Do meu caderno

O caderno não tem aula de sazonalidade antes de 10/09. A ferramenta usada aqui é a do AR(1) de 26/08: multiplicar por $(y_{t-k} - \mu)$, tirar a esperança e obter $\gamma_k = \phi_1\gamma_{k-1}$ ("$\gamma_1 = \phi_1\gamma_0$, $\gamma_2 = \phi_1\gamma_1$, $\gamma_3 = \phi_1\gamma_2$"). Para o SAR, troque o passo 1 pelo passo 4: $\gamma_k = \Phi\gamma_{k-4}$.

O que o livro acrescenta

BJRL (cap. 9) justifica a forma **multiplicativa**. O fator $(1 - \Phi L^4)$ liga cada trimestre ao mesmo trimestre do ano anterior, e o fator $(1 - \phi L)$ liga trimestres vizinhos. O termo $\phi\Phi L^5$ é a **interação** dos dois. Por isso a FAC do multiplicativo deixa de ser zero fora dos múltiplos de 4: o fator $(1 - \phi L)$ espalha a dependência para as defasagens vizinhas, e a FACP passa a ter valores relevantes em 1, 4 e 5.

Armadilhas e variações

- **Na (a), dizer "$\gamma_1 = \Phi^{1/4}\gamma_0$"** ou outra interpolação: fora dos múltiplos, é zero, e a prova vem do sistema $\gamma_1 = \Phi\gamma_3$, $\gamma_3 = \Phi\gamma_1$.
- **Contar 2 restrições** em vez de 3: os dois zeros e o produto.
- **Variações:** $\text{SAR}(1)_{12}$ e o MA(13) restrito do SMA no banco; $\Phi = 0{,}6$ e o AR(5) com $(0{,}5;\ 0{,}6)$ no Simulado 02, Q3.

CAPÍTULO 13

Q12 · SARIMA$(1,1,0)(0,1,1)_4$ trimestral

← índice · anterior: Q11 · próxima: Q13 · resolução curta em 03_lista

O que a questão pede

- **(a) Escrever** o modelo em B.
- **(b) Dizer** quantas observações se perdem com $(1-B)(1-B^4)$, e por quê.
- **(c) Derivar** $y_{T+h|T}$ para $h = 1, 2, 4, 5$ e mostrar como a sazonalidade se propaga.
- **(d) Discutir** o diagnóstico de resíduos.

Da lista para os slides

Lista	Slides
$(1-\phi B)(1-B)(1-B^4)y_t = (1-\Theta B^4)a_t$	$(1-\phi L)(1-L)(1-L^4)y_t = (1+\Theta^s L^4)\varepsilon_t$, com $\Theta^s = -\Theta$
$y_{T+h\|T}$, $\mathscr{F}_T$	$\hat{y}_{T+h/T} = E(y_{T+h} \mid \Omega_T)$ (AU02, p. 72)

Ferramentas

- **Slides:** AU02, p. 72–75 (previsão recursiva e erro do AR), p. 85 (previsão do ARMA(1,1): o MA some depois de q passos); AU03, p. 9–19 (diagnóstico: gráficos, Jarque-Bera, Ljung-Box, Breusch-Godfrey, ARCH); AU05 (SARIMA).
- **Caixa:** [F8] multiplicar polinômios; [F9] esperança condicional na previsão.
- **Livro:** BJRL, cap. 5 (previsão) e cap. 9 (sazonais); ENDERS, cap. 2.

Demonstração minuciosa

(a) O modelo

$$\boxed{(1-\phi L)(1-L)(1-L^4)\,y_t = (1+\Theta^s L^4)\,\varepsilon_t} \qquad \text{(lista: } (1-\phi B)(1-B)(1-B^4)y_t = (1-\Theta B^4)a_t\text{)}$$

Expandindo o lado AR [F8], em duas etapas:

1. $(1-\phi L)(1-L) = 1 - L - \phi L + \phi L^2 = 1 - (1+\phi)L + \phi L^2$.
2. Multiplicando por $(1-L^4)$, cada termo do primeiro fator vezes 1 e vezes $-L^4$:

$$\big(1-(1+\phi)L+\phi L^2\big)(1-L^4) = 1-(1+\phi)L+\phi L^2 - L^4 + (1+\phi)L^5 - \phi L^6.$$

Passando para a forma de equação, todos os y defasados à direita:

$$\boxed{y_t = (1+\phi)y_{t-1} - \phi y_{t-2} + y_{t-4} - (1+\phi)y_{t-5} + \phi y_{t-6} + \varepsilon_t + \Theta^s \varepsilon_{t-4}}$$

Com $\phi = 0{,}4$, os coeficientes de y_{t-1} a y_{t-6} são 1,4; −0,4; 0; 1; −1,4; 0,4.

(b) Observações perdidas: 5

$w_t = (1-L)(1-L^4)y_t = (1-L-L^4+L^5)y_t = y_t - y_{t-1} - y_{t-4} + y_{t-5}$.

- Para calcular w_t, é preciso ter y_{t-5}.
- Com dados $y_1, \dots, y_T$, o primeiro w calculável é w_6, que usa y_1.
- Sobram $T-5$ valores de w.

$$\boxed{d + sD = 1 + 4 \cdot 1 = 5 \text{ observações perdidas}}$$

(c) Equações de previsão

Escreva o modelo na data $T+h$ e aplique as três regras de [F9]: o que é conhecido fica, y futuro vira a previsão, e choque futuro vira zero. Notação: $\hat{y}(h) = \hat{y}_{T+h/T}$.

$h = 1$. Os índices: $y_{T+1-1} = y_T$, y_{T-1}, y_{T-3}, y_{T-4}, y_{T-5} e $\varepsilon_{T+1-4} = \varepsilon_{T-3}$, todos conhecidos. E ε_{T+1} vira 0.

$$\hat{y}(1) = (1+\phi)y_T - \phi y_{T-1} + y_{T-3} - (1+\phi)y_{T-4} + \phi y_{T-5} + \Theta^s \varepsilon_{T-3}$$

$h = 2$. Agora y_{T+1} é futuro e vira $\hat{y}(1)$; ε_{T-2} é conhecido.

$$\hat{y}(2) = (1+\phi)\hat{y}(1) - \phi y_T + y_{T-2} - (1+\phi)y_{T-3} + \phi y_{T-4} + \Theta^s \varepsilon_{T-2}$$

$h = 3$, que não é pedido, mas $h = 4$ e $h = 5$ usam:

$$\hat{y}(3) = (1+\phi)\hat{y}(2) - \phi\hat{y}(1) + y_{T-1} - (1+\phi)y_{T-2} + \phi y_{T-3} + \Theta^s \varepsilon_{T-1}$$

$h = 4$. O último choque conhecido, ε_T, entra aqui.

$$\hat{y}(4) = (1+\phi)\hat{y}(3) - \phi\hat{y}(2) + y_T - (1+\phi)y_{T-1} + \phi y_{T-2} + \Theta^s \varepsilon_T$$

$h = 5$. O termo MA seria ε_{T+1}, futuro, e **some**. O y_{T+1}, que aparece como y_{t-4}, vira $\hat{y}(1)$.

$$\hat{y}(5) = (1+\phi)\hat{y}(4) - \phi\hat{y}(3) + \hat{y}(1) - (1+\phi)y_T + \phi y_{T-1}$$

Essas fórmulas foram conferidas contra o `predict()` do R numa série simulada com $\phi = 0{,}4$ e $\Theta^s = -0{,}6$: diferença máxima da ordem de 10^{-15}.

Como a sazonalidade se propaga.

1. O termo y_{T+h-4}, ou $\hat{y}(h-4)$, traz o **mesmo trimestre do ano anterior**: o desenho sazonal é copiado para frente.
2. O MA sazonal corrige esse desenho com os quatro últimos choques, ε_{T-3} a ε_T, e **para em** $h = 4$.
3. Para $h \geq 5$, as previsões obedecem à equação homogênea $(1-\phi L)(1-L)(1-L^4)\hat{y}(h) = 0$. As raízes são 1 (dupla: uma do $1-L$ e outra do $1-L^4$), -1, $\pm i$ (as outras três raízes de $z^4 = 1$) e $1/\phi$. A função de previsão é, portanto, **tendência linear + padrão sazonal fixo de período 4 + termo ϕ^h que some**.

(d) Diagnóstico de resíduos (AU03)

1. **Gráficos** (AU03, p. 10): resíduos padronizados no tempo (quebras, *outliers*, variância mudando), histograma, QQ-plot e FAC dos resíduos. **Olhe as defasagens 4 e 8**: um pico ali indica a parte sazonal mal especificada.
2. **Ljung-Box** (AU03, p. 15): $H_0 : \rho_1 = \cdots = \rho_K = 0$ nos erros, com $LB(K) = T(T+2)\sum_{i=1}^{K} \frac{\hat{\rho}_i^2}{T-i} \sim \chi^2_\nu$ e $\nu = K - p - q - P - Q = K - 2$ aqui.
3. **Breusch-Godfrey** (AU03, p. 18): alternativa do tipo LM, com $nR^2 \sim \chi^2_m$.
4. **Normalidade, Jarque-Bera** (AU03, p. 11–14): $JB = \frac{n}{6}\hat{S}^2 + \frac{n}{24}(\widehat{K} - 3)^2 \sim \chi^2_2$, com H_0: $S = 0$ e $K = 3$.
5. **Heterocedasticidade condicional** (AU03, p. 19): FAC de $\hat{\varepsilon}_t^2$ e teste ARCH-LM.
6. **Estabilidade:** Chow numa data escolhida *a priori* e CUSUM (análise recursiva).
7. **Invertibilidade:** $\widehat{\Theta}$ perto de 1 sugere **sobrediferenciação sazonal**, ou seja, sazonalidade determinística. A alternativa é usar dummies trimestrais com $D = 0$.

Do meu caderno (09/09)

O caderno desenha a FAC e a FACP do AR(2) e do MA(2), as "assinaturas" que se procuram nos resíduos, e anota "análise de **estabilidade** dos parâmetros" e "**quebra estrutural**", os itens 6 e 7 acima. Em 10/09 vêm a previsão iterada e as métricas, ligadas à Q15.

O que o livro acrescenta

BJRL (cap. 5) dá a regra geral que esta questão aplica: **as previsões de um ARIMA(p,d,q) obedecem, a partir de $h > q$, à parte autorregressiva generalizada** $\phi(L)(1-L)^d$. A forma da função de previsão de longo prazo é lida nas raízes desse polinômio. O MA só ajusta o "ponto de partida".

Armadilhas e variações

- **Índices.** O erro mais comum é trocar y_{T-3} por y_{T-4} em $\hat{y}(1)$. Escreva primeiro a equação na data t, depois troque t por $T + h$.
- **Dizer que o MA some em $h = 2$.** Ele é **sazonal**, de defasagem 4, e some só em $h = 5$.
- **Variações:** o mesmo modelo com números, com previsões de $h = 1$ a 5, no Simulado 03, Q3; o SARIMA$(0,1,1)(0,1,1)_4$ no banco.

Parte V

Blocos 4 a 6 — Estimação, previsão e aplicação

Q13 · Log-verossimilhança condicional do AR(1) e o estimador de MQO

← índice · anterior: Q12 · próxima: Q14 · resolução curta em 04_lista, D04.1

O que a questão pede

Para $y_t = \phi y_{t-1} + \varepsilon_t$ com $\varepsilon_t \sim N(0, \sigma^2)$: **escrever** a log-verossimilhança condicional em y_1 e **obter** o estimador $\hat{\phi}$, mostrando que é o de MQO.

Da lista para os slides

Mesmo modelo. A AU02 escreve o AR(1) com intercepto, $y_t = \phi_0 + \phi_1 y_{t-1} + \varepsilon_t$ (p. 78). A lista não tem intercepto, então tome $\phi_0 = 0$ e $\phi_1 = \phi$.

Ferramentas

- **Slides:** AU02, p. 76–77 (verossimilhança fatorada em densidades condicionais), p. 78–79 (MV exata, com a densidade de y_1), p. 80 (MV condicional ≡ MQO; os dois métodos são assintoticamente equivalentes).
- **Livro:** HAMILTON, cap. 5 (MV exata e condicional do AR(1)); TSAY, cap. 2.

Demonstração minuciosa

Passo 1 — A densidade de cada observação, dado o passado

Dado y_{t-1}, o único termo aleatório de $y_t = \phi y_{t-1} + \varepsilon_t$ é $\varepsilon_t \sim N(0, \sigma^2)$. Logo $y_t \mid y_{t-1} \sim N(\phi y_{t-1}, \sigma^2)$:

$$f(y_t \mid y_{t-1}; \phi, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_t - \phi y_{t-1})^2}{2\sigma^2}\right), \qquad t = 2, \dots, T.$$

Passo 2 — A verossimilhança condicional em y_1

A densidade conjunta se fatora numa cadeia de condicionais (AU02, p. 77):

$$f(y_T, \dots, y_1) = f(y_1) \prod_{t=2}^{T} f(y_t \mid y_{t-1}, \dots, y_1) = f(y_1) \prod_{t=2}^{T} f(y_t \mid y_{t-1}).$$

A última igualdade vale porque, num AR(1), só o último valor importa. **Condicionar em** y_1 é tratar y_1 como fixo e descartar $f(y_1)$ (AU02, p. 80):

$$L_c(\phi, \sigma^2) = \prod_{t=2}^{T} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_t - \phi y_{t-1})^2}{2\sigma^2}\right).$$

Passo 3 — O logaritmo

O log transforma produto em soma; $\ln \frac{1}{\sqrt{2\pi\sigma^2}} = -\frac{1}{2}\ln(2\pi) - \frac{1}{2}\ln\sigma^2$, e $\ln e^x = x$. São $T-1$ parcelas:

$$\boxed{\ell_c(\phi, \sigma^2) = -\frac{T-1}{2}\ln(2\pi) - \frac{T-1}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}\sum_{t=2}^{T}(y_t - \phi y_{t-1})^2}$$

Passo 4 — Maximizar em ϕ é minimizar a soma dos quadrados

Só o último termo depende de ϕ, e ele entra com sinal negativo. Logo:

$$\arg\max_{\phi}\ \ell_c = \arg\min_{\phi}\ S(\phi), \qquad S(\phi) = \sum_{t=2}^{T}(y_t - \phi y_{t-1})^2.$$

$S(\phi)$ é exatamente a soma dos quadrados dos resíduos da regressão de y_t em y_{t-1}, sem intercepto: **é o problema do MQO.**

Passo 5 — Condição de primeira ordem

Pela regra da cadeia, $\frac{d}{d\phi}(y_t - \phi y_{t-1})^2 = 2(y_t - \phi y_{t-1})(-y_{t-1})$. Então:

$$\frac{dS}{d\phi} = -2\sum_{t=2}^{T} y_{t-1}(y_t - \phi y_{t-1}) = 0 \implies \sum_{t=2}^{T} y_t y_{t-1} - \phi\sum_{t=2}^{T} y_{t-1}^2 = 0$$

$$\boxed{\hat{\phi} = \frac{\sum_{t=2}^{T} y_t y_{t-1}}{\sum_{t=2}^{T} y_{t-1}^2}}$$

Segunda ordem: $\frac{d^2S}{d\phi^2} = 2\sum y_{t-1}^2 > 0$, então é um mínimo de S e um máximo de ℓ_c.

Passo 6 — A variância

Derive em σ^2, tratando σ^2 como variável:

$$\frac{\partial \ell_c}{\partial \sigma^2} = -\frac{T-1}{2\sigma^2} + \frac{S(\phi)}{2\sigma^4} = 0 \implies \boxed{\hat{\sigma}^2 = \frac{S(\hat{\phi})}{T-1} = \frac{1}{T-1}\sum_{t=2}^{T}(y_t - \hat{\phi} y_{t-1})^2}$$

Conferência no R: numa série simulada com $T = 301$, o máximo numérico da log-verossimilhança e a fórmula de MQO diferem em menos de 10^{-10}, e o `lm()` sem intercepto dá o mesmo valor, com diferença da ordem de 10^{-16}.

Exata × condicional (AU02, p. 78–80)

A MV **exata** acrescenta $\ln f(y_1)$, com $y_1 \sim N\big(0, \sigma^2/(1-\phi^2)\big)$, que é a distribuição incondicional:

$$\ell = \ell_c - \frac{1}{2}\ln(2\pi) - \frac{1}{2}\ln\frac{\sigma^2}{1-\phi^2} - \frac{(1-\phi^2)y_1^2}{2\sigma^2}.$$

Esse termo não é quadrático em ϕ: a exata **não tem forma fechada** e exige otimização numérica. Mas é **uma** parcela contra $T-1$, e os dois estimadores são consistentes e assintoticamente equivalentes. A exata só vale a pena em amostra pequena ou com ϕ perto de 1.

Do meu caderno (26/08 e 10/09)

- **26/08, "Verossimilhança (testar no R)":** $y_t = \theta_0 + \varepsilon_t + \theta_1\varepsilon_{t-1}$, $\Theta = (\theta_0, \theta_1, \sigma^2)$, $y_t \mid \varepsilon_{t-1} \sim N(\theta_0 + \theta_1\varepsilon_{t-1}, \sigma^2)$ e a densidade normal. É a verossimilhança **condicional do MA(1)** (AU02, p. 58–59). A diferença para o AR: no MA, os ε_t precisam ser reconstruídos por recursão a partir de $\varepsilon_0 = 0$, e não há forma fechada. No AR, o condicional é MQO.
- **26/08, AR(1) condicional:** $E(y_t \mid \Omega_{t-1}) = c + \phi_1 y_{t-1}$ e $V(y_t \mid \Omega_{t-1}) = \sigma^2$: são a média e a variância da densidade do Passo 1.
- **10/09:** "Estimação: $y_t = \phi y_{t-1} + u_t \rightarrow \min_\phi \sum u_t^2$": é o Passo 4 em uma linha.

O que o livro acrescenta

HAMILTON (cap. 5) mostra que, com intercepto, a MV condicional do AR(p) é o MQO de y_t em $(1, y_{t-1}, \ldots, y_{t-p})$, e que $\hat{\sigma}^2$ divide por $T - p$ (o número de parcelas). O estimador é **viesado** em amostra finita, porque y_{t-1} não é estritamente exógeno, mas é **consistente**.

Armadilhas e variações

- **Somar de $t = 1$:** a soma condicional começa em $t = 2$, porque y_0 não existe na amostra.
- **Dividir por T** em $\hat{\sigma}^2$: o número de parcelas é $T - 1$.
- **Não dizer por que é MQO:** a frase "maximizar ℓ_c em ϕ equivale a minimizar $S(\phi)$, porque o único termo com ϕ entra com sinal negativo" é a que vale o ponto.
- **Variações:** a conta com somas dadas, $\hat{\phi} = 84/120$, no Simulado 01, Q4b; exata × condicional no Simulado 02, Q4c.

CAPÍTULO 15

Q14 · AIC e BIC

← índice · anterior: Q13 · próxima: Q15 · resolução curta em 04_lista

O que a questão pede

Com $T = 150$ e três modelos de média zero, ARMA(1,1), ARMA(2,0) e ARMA(0,2), com $\ln L = -210{,}3;\ -212{,}8;\ -214{,}1$, e k **incluindo a variância do erro**:

- **(a) calcular** AIC e BIC e indicar o modelo escolhido por cada um;
- **(b) explicar** a diferença de penalidade e as propriedades assintóticas (consistência × eficiência).

Da lista para os slides

A AU02 (p. 98–99) define os critérios **divididos por** T:

$$AIC = \frac{-2\ln L(\Theta)}{T} + \frac{2k}{T}, \qquad BIC = \frac{-2\ln L(\Theta)}{T} + \frac{k\ln T}{T}.$$

O R e a maior parte dos livros não dividem por T. **Com o mesmo T para todos os modelos, a ordenação é idêntica.** Faço as duas versões, porque a prova pode pedir a do slide.

Contagem de k. A AU02, p. 99, diz que um ARMA(p,q) **com média** tem $p+q+1$ parâmetros, o "+1" sendo a média. A lista manda contar σ^2, e os modelos têm média zero. Aqui as duas contagens coincidem: são dois coeficientes mais um, ou seja, $k = 3$ nos três modelos. O que importa é **usar a mesma regra para todos**.

Ferramentas

- **Slides:** AU02, p. 97 (parcimônia), p. 98–99 (AIC, BIC, mesmo T, menor é melhor).
- **Livro:** TSAY, cap. 2 (critérios de informação); BJRL, cap. 6.

Demonstração minuciosa

(a) As contas

Passo 1 — o termo de ajuste, $-2\ln L$:

- ARMA(1,1): $-2(-210{,}3) = 420{,}6$;
- ARMA(2,0): $-2(-212{,}8) = 425{,}6$;
- ARMA(0,2): $-2(-214{,}1) = 428{,}2$.

Passo 2 — as penalidades, com $k = 3$:

- AIC: $2k = 6$;
- BIC: $k\ln T = 3\ln 150 = 3(5{,}0106) = 15{,}0319$.

Passo 3 — somar:

Modelo	$-2\ln L$	AIC	BIC	AIC/T (AU02)	BIC/T (AU02)
ARMA(1,1)	420,6	**426,6**	**435,632**	**2,8440**	**2,9042**
ARMA(2,0)	425,6	431,6	440,632	2,8773	2,9375
ARMA(0,2)	428,2	434,2	443,232	2,8947	2,9549

Conclusão: AIC e BIC escolhem o ARMA(1,1).

Como os três têm o mesmo k, a penalidade é igual para todos, e a escolha é decidida só pelo ajuste: o maior $\ln L$ ganha.

(b) Penalidades e propriedades assintóticas

A diferença de penalidade. Cada parâmetro a mais custa:

- **2** no AIC, sempre;
- $\ln T$ no BIC. Com $T = 150$, $\ln T = 5{,}01$.

Como $\ln T > 2$ sempre que $T \geq 8$, **o BIC pune mais e escolhe modelos menores**.

Consistência (BIC). Se o modelo verdadeiro está entre os candidatos, a probabilidade de o BIC escolhê-lo vai a 1 quando $T \to \infty$. A penalidade $k \ln T$ cresce sem limite e acaba eliminando qualquer parâmetro supérfluo, cujo ganho de ajuste é limitado.

Eficiência (AIC). O AIC **não é consistente**: mesmo com $T \to \infty$, ele escolhe um modelo grande demais com probabilidade positiva, porque a penalidade fixa, 2, não cresce. Em compensação, é **assintoticamente eficiente**: quando o modelo verdadeiro **não** está entre os candidatos (o caso realista), ele escolhe o que minimiza o erro de previsão esperado.

Na prática:

- para **identificar a ordem verdadeira**, use o BIC;
- para **prever**, use o AIC;
- quando discordam, olhe os resíduos dos dois (AU03) e o desempenho fora da amostra.

Do meu caderno (10/09)

O caderno anota as **métricas de previsão** (MAPE, MAD, RMSE, MASE) e a separação **treino/validação**: a avaliação fora da amostra que desempata quando AIC e BIC discordam (AU03).

O que o livro acrescenta

TSAY (cap. 2) observa que, em séries financeiras curtas, o BIC tende a escolher modelos muito parcimoniosos. Ele recomenda olhar os dois critérios **e** o Ljung-Box dos resíduos de cada candidato, antes de decidir.

Armadilhas e variações

- **Esquecer σ^2 em k:** se a lista manda contar, conte. Aqui não muda a escolha, porque é a mesma para todos, mas muda o **valor** pedido.
- **Comparar modelos estimados com T diferentes:** proibido (AU02, p. 99). Em SARIMA, o número de observações efetivas muda com d e D.
- **Dizer "o BIC é melhor":** depende do objetivo. A resposta precisa ter consistência × eficiência.

- **Variações:** AIC e BIC discordando com $T = 200$ no Simulado 01, Q4; a versão da AU02 com LR no Simulado 02, Q4; $T = 100$ no banco.

Q15 · Previsão em ARMA(p, q)

← índice · anterior: Q14 · próxima: Q16 · resolução curta em 05_lista, D05.1

O que a questão pede

Para um ARMA(p, q) estacionário e invertível:

- **(a) mostrar** que o previsor de mínimo EQM é $E(y_{T+h} \mid \mathcal{F}_T)$;
- **(b) derivar** as previsões de 1 e 2 passos do ARMA(1,1);
- **(c) mostrar** que o erro de previsão é um MA($h-1$) e calcular sua variância;
- **(d) construir** o intervalo de 95% com erros gaussianos;
- **(e) mostrar** que, no ARIMA(0,1,1), a previsão é uma suavização exponencial simples, e identificar a constante.

Da lista para os slides

Lista	Slides
$y_{T+h\|T} = E(y_{T+h} \mid \mathcal{F}_T)$	$\hat{y}_{t+k/t} = E(y_{t+k} \mid \Omega_t)$ (AU02, p. 54 e 72)
$e_T(h)$	$e_{t+k/t} = y_{t+k} - \hat{y}_{t+k/t}$ (AU02, p. 75)
ARMA(1,1) $z_t - \phi z_{t-1} = a_t - \theta a_{t-1}$	$y_t = c + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$ (AU02, p. 85), com $\theta_1 = -\theta$
ARIMA(0,1,1) $\Delta y_t = a_t - \theta a_{t-1}$	$\Delta y_t = \varepsilon_t + \theta^s \varepsilon_{t-1}$, com $\theta^s = -\theta$

Uso a origem T e o horizonte h, como a lista. O resto segue a notação dos slides.

Ferramentas

- **Slides:** AU02, p. 54–57 (previsão do MA, intervalo e EQM), p. 72–75 (previsão e erro do AR(1)), p. 85 (previsão do ARMA(1,1)); AU03 (avaliação fora da amostra).
- **Caixa:** [F4]; [F5]; [F9] esperança condicional e LEI.
- **Livro:** HAMILTON, cap. 4 (previsão ótima); BJRL, cap. 5 (pesos ψ, intervalos e atualização da previsão).

Demonstração minuciosa

(a) A esperança condicional minimiza o EQM

Seja g **qualquer** previsor que use só a informação Ω_T, e seja $m = E(y_{T+h} \mid \Omega_T)$.

1. **Some e subtraia** m: $y_{T+h} - g = (y_{T+h} - m) + (m - g)$.
2. **Eleve ao quadrado:** $(y_{T+h} - g)^2 = (y_{T+h} - m)^2 + (m - g)^2 + 2(y_{T+h} - m)(m - g)$.
3. **Tire a esperança condicional a Ω_T.** O termo $(m - g)$ é conhecido em T, porque m e g são funções de Ω_T, e sai da esperança:

$$E\big((y_{T+h} - m)(m - g) \mid \Omega_T\big) = (m - g)\, \underbrace{E(y_{T+h} - m \mid \Omega_T)}_{=m-m=0} = 0.$$

4. **Pela LEI** [F9], tirando a esperança incondicional: $E\big((y_{T+h} - g)^2\big) = E\big((y_{T+h} - m)^2\big) + E\big((m - g)^2\big)$.
5. **Conclusão:** o segundo termo é ≥ 0 e só vale zero com $g = m$. Portanto

$$\boxed{\hat{y}_{T+h/T} = E(y_{T+h} \mid \Omega_T) \text{ minimiza o EQM.}}$$

(b) Previsões do ARMA(1,1) (AU02, p. 85)

Escreva o modelo na data $T + h$: $y_{T+h} = c + \phi y_{T+h-1} + \varepsilon_{T+h} + \theta\varepsilon_{T+h-1}$, e aplique [F9].

$h = 1$**:** ε_{T+1} é futuro e vira 0; y_T e ε_T são conhecidos.

$$\boxed{\hat{y}_{T+1/T} = c + \phi y_T + \theta\varepsilon_T} \qquad \text{(lista, sem constante: } \phi z_T - \theta a_T\text{)}$$

$h = 2$**:** ε_{T+2} e ε_{T+1} viram 0, e y_{T+1} vira $\hat{y}_{T+1/T}$.

$$\boxed{\hat{y}_{T+2/T} = c + \phi\,\hat{y}_{T+1/T}}$$

O MA **some a partir de** $h = 2$, porque $q = 1$. Daí em diante, a previsão segue a recursão do AR e converge para $\mu = c/(1 - \phi)$.

(c) O erro é um MA($h - 1$)

Pelo Teorema de Wold (Q4), $y_{T+h} = \mu + \sum_{j\geq 0} \psi_j \varepsilon_{T+h-j}$. Separe os choques **futuros** dos **conhecidos**:

$$y_{T+h} = \mu + \underbrace{\sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j}}_{\text{choques de } T+1 \text{ a } T+h} + \underbrace{\sum_{j\geq h} \psi_j \varepsilon_{T+h-j}}_{\text{choques até } T}.$$

Aplicando [F9], os choques futuros viram 0 e os conhecidos ficam:

$$\hat{y}_{T+h/T} = \mu + \sum_{j\geq h} \psi_j \varepsilon_{T+h-j}.$$

Subtraindo:

$$\boxed{e_{T+h/T} = \sum_{j=0}^{h-1} \psi_j\, \varepsilon_{T+h-j} = \varepsilon_{T+h} + \psi_1\varepsilon_{T+h-1} + \cdots + \psi_{h-1}\varepsilon_{T+1}}$$

É um **MA($h - 1$)** nos choques futuros, com $\psi_0 = 1$. A variância sai por [F5], porque os choques são não correlacionados:

$$\boxed{V(e_{T+h/T}) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2 = \sigma^2\big(1 + \psi_1^2 + \cdots + \psi_{h-1}^2\big)}$$

No AR(1), $\psi_j = \phi^j$, e isso dá $\sigma^2(1 + \phi^2 + \cdots + \phi^{2(h-1)})$, a fórmula da AU02, p. 75.

Números, ARMA(1,1) com $\phi = 0{,}7$ e $\theta^{\text{lista}} = 0{,}4$ (nos slides, $\theta = -0{,}4$), e $\sigma^2 = 1$:

- $\psi_1 = \phi + \theta = 0{,}3$ e $\psi_2 = \phi\psi_1 = 0{,}21$;
- $V(1) = 1$, $V(2) = 1 + 0{,}09 = 1{,}09$ e $V(3) = 1{,}09 + 0{,}0441 = 1{,}1341$;

- $V(h) \to \gamma_0 = 1{,}1765$: em $h = 12$, já vale 1,1764.

No R, as previsões de 1 e 2 passos e as variâncias coincidem com o `predict()`, com diferença zero.

(d) Intervalo de 95%

Com erros gaussianos, $e_{T+h/T}$ é uma soma de normais e, portanto, é normal: $e_{T+h/T} \sim N\big(0,\ \sigma^2 \sum_{j<h} \psi_j^2\big)$. Logo $P\big(|e_{T+h/T}| \le 1{,}96\sqrt{V}\big) = 0{,}95$, e (AU02, p. 56 e 74)

$$\boxed{\hat{y}_{T+h/T} \ \pm\ 1{,}96\,\sigma\sqrt{1 + \psi_1^2 + \cdots + \psi_{h-1}^2}}$$

O intervalo **alarga com** h e, num processo estacionário, para de alargar em $\pm 1{,}96\sqrt{\gamma_0}$.

(e) ARIMA(0,1,1) é a suavização exponencial simples

O modelo é $y_t = y_{t-1} + \varepsilon_t + \theta^s \varepsilon_{t-1}$.

1. $h = 1$**:** $\hat{y}_{T+1/T} = y_T + \theta^s \varepsilon_T$.
2. $h \ge 2$**:** $\hat{y}_{T+h/T} = \hat{y}_{T+h-1/T} + 0 + 0$, e a previsão fica **constante em todos os horizontes**:

$$\hat{y}_{T+h/T} = y_T + \theta^s \varepsilon_T \quad \text{para todo } h \ge 1.$$

3. **Troque o choque pelo erro de previsão.** $\varepsilon_T = y_T - \hat{y}_{T/T-1}$ é o erro um passo à frente do Teorema de Wold. Substituindo:

$$\hat{y}_{T+1/T} = y_T + \theta^s(y_T - \hat{y}_{T/T-1}) = (1 + \theta^s)\, y_T - \theta^s\, \hat{y}_{T/T-1}.$$

4. **Chame** $\alpha = 1 + \theta^s$, logo $-\theta^s = 1 - \alpha$:

$$\boxed{\hat{y}_{T+1/T} = \alpha\, y_T + (1-\alpha)\, \hat{y}_{T/T-1}, \qquad \alpha = 1 + \theta^s \ \ \text{(lista: } \alpha = 1 - \theta)}$$

É a **suavização exponencial simples**: a nova previsão é uma média ponderada entre o dado novo e a previsão antiga.

5. **Abrindo a recursão:** $\hat{y}_{T+1/T} = \alpha \sum_{j \ge 0} (1-\alpha)^j y_{T-j}$, com pesos geométricos [F2]. Eles convergem se $|1 - \alpha| = |\theta| < 1$, que é **exatamente a invertibilidade**.

Com $\theta^{\text{lista}} = 0{,}6$: $\alpha = 0{,}4$. No R, a previsão do `arima` e a do `HoltWinters` com $\alpha = 0{,}4$ coincidem, com diferença da ordem de 10^{-16}.

Do meu caderno (26/08, 02/09 e 10/09)

- **26/08, MA(1):** $\hat{y}_{t+1/t} = c + \theta_1 \varepsilon_t$ e EQM de um passo $E\big((y_{t+1} - \hat{y}_{t+1/t})^2 \mid \Omega_t\big) = \sigma^2$, certos (AU02, p. 54 e 57). Também o intervalo $\hat{y}_{t+k/t} \pm z_{\alpha/2}\sqrt{MSE}$ e os três elementos da previsão: origem, informação e horizonte.
- **26/08, MA(2)**, com correção:

> **A previsão do MA(2) no caderno mistura os horizontes**
>
> - O certo é $E(y_t \mid \Omega_{t-1}) = c + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$. O caderno pôs θ_2 nos dois lugares.
> - A linha "$= c + \theta_1 E(\varepsilon_{t+1} \mid \Omega_t) + \theta_2 E(\varepsilon_t \mid \Omega_t) = c + \theta_2 \varepsilon_t$" é, na verdade, a previsão de **dois** passos, $E(y_{t+2} \mid \Omega_t)$.

> - Em $E(y_{t+3} \mid T)$ aparece θ_3; num MA(2), é θ_2. O resultado, *c*, está certo: depois de q passos, a previsão do MA(q) é a média.

- **02/09, AR(1):** $\hat{y}_{t+1/t} = \phi_0 + \phi_1 y_t$, $\hat{y}_{t+2/t} = \phi_0 + \phi_1 E(y_{t+1} \mid \Omega_t)$ e $e_{t+1/t} = \varepsilon_{t+1}$: certos (AU02, p. 72–75).
- **10/09, previsão iterada × direta:** a **iterada** estima um AR(1) e usa $\hat{y}_{t+h/t} = \hat{\phi}^h y_t$; a **direta** estima uma regressão por horizonte, $y_t = \phi^{(h)} y_{t-h} + u_t$, e usa $\hat{\phi}^{(h)} y_t$. Se o AR(1) estiver certo, $\phi^{(h)} = \phi^h$ e as duas coincidem. Também as métricas: MAPE (percentual), MAD (na unidade da série), RMSE e MASE (AU03).

O que o livro acrescenta

BJRL (cap. 5) mostra a **atualização da previsão**: quando chega y_{T+1}, cada previsão antiga se corrige por ψ_j vezes o erro novo, $\hat{y}_{T+h/T+1} = \hat{y}_{T+h/T} + \psi_{h-1} e_{T+1/T}$. É a forma mais rápida de refazer previsões na prova.

Armadilhas e variações

- **Esquecer $\psi_0 = 1$:** a variância de um passo é σ^2, e não zero.
- **Somar os ψ_j^2 até h** em vez de até $h - 1$.
- **SES com $\alpha = \theta$:** o certo é $\alpha = 1 - \theta$ na lista, ou $1 + \theta$ nos slides.
- **Variações:** AR(1) com média no Simulado 01, Q5; ARMA(1,1) com sinal positivo e SES no Simulado 02, Q5; MA(2) no Simulado 03, Q5.

Q16 · SARIMA$(1,1,1)(0,1,1)_{12}$ com 240 observações mensais

← índice · anterior: Q15 · resolução curta em 06_lista

O que a questão pede

- **(a) Escrever** o modelo completo com o operador de defasagem.
- **(b) Contar** e listar os parâmetros a estimar.
- **(c) Descrever** a FAC e a FACP esperadas de $(1-B)(1-B^{12})y_t$.
- **(d) Recomendar** um critério para comparar com o SARIMA$(2,1,1)(0,1,1)_{12}$.

Da lista para os slides

Lista	Slides
$(1-\phi B)(1-B)(1-B^{12})y_t = (1-\theta B)(1-\Theta B^{12})a_t$	$(1-\phi L)(1-L)(1-L^{12})y_t = (1+\theta^s L)(1+\Theta^s L^{12})\varepsilon_t$

Com $\theta^s = -\theta$ e $\Theta^s = -\Theta$.

Ferramentas

- **Slides:** AU02, p. 87 (FAC do ARMA(p,q): recursão do AR para $k > q$), p. 96–97 (identificação de modelos mistos), p. 98–99 (AIC, BIC, mesmo T); AU03, p. 15–17 (Ljung-Box com $\nu = k - p - q$); AU05 (SARIMA).
- **Caixa:** [F8] multiplicar polinômios.
- **Livro:** BJRL, cap. 9 (o modelo das companhias aéreas e a FAC dos multiplicativos); ENDERS, cap. 2.

Demonstração minuciosa

(a) O modelo completo

$$\boxed{(1-\phi L)(1-L)(1-L^{12})\,y_t = (1+\theta^s L)(1+\Theta^s L^{12})\,\varepsilon_t}$$

Expandindo o MA [F8]: $(1+\theta^s L)(1+\Theta^s L^{12}) = 1+\theta^s L+\Theta^s L^{12}+\theta^s\Theta^s L^{13}$. Na lista, isso é $1-\theta B-\Theta B^{12}+\theta\Theta B^{13}$.

Definindo $w_t = (1-L)(1-L^{12})y_t$, ou seja, $w_t = y_t - y_{t-1} - y_{t-12} + y_{t-13}$:

$$w_t = \phi w_{t-1} + \varepsilon_t + \theta^s\varepsilon_{t-1} + \Theta^s\varepsilon_{t-12} + \theta^s\Theta^s\varepsilon_{t-13}.$$

(b) Parâmetros

$$\boxed{\text{4 parâmetros: } \phi,\ \theta,\ \Theta,\ \sigma^2}$$

- O coeficiente de ε_{t-13} **não** é um parâmetro novo: é o produto $\theta\Theta$, imposto pela forma multiplicativa.
- Não há constante: com $d = D = 1$, uma constante em w_t implicaria uma tendência quadrática em y_t, o que raramente faz sentido.
- Observações efetivas: perdem-se $d + sD = 1 + 12 = 13$, e sobram $240 - 13 = 227$.

(c) FAC e FACP esperadas de w_t

w_t é um ARMA(1,13) restrito: AR(1) com MA só nas defasagens 1, 12 e 13. Pela AU02, p. 87, para $k > 13$ vale a recursão do AR, $\gamma_k = \phi\gamma_{k-1}$. O padrão esperado:

1. **Perto da origem**, defasagens 1, 2, 3...: decaimento geométrico a partir de ρ_1, à taxa ϕ, como no ARMA(1,1) da Q6.
2. **Perto de 12**: um pico forte em 12, gerado por Θ, com os "satélites" 11 e 13. É a assinatura do produto $(1 + \theta^s L)(1 + \Theta^s L^{12})$.
3. **Depois de 13**: decaimento geométrico, por causa de ϕ. Sem fator AR sazonal, não há pico relevante em 24.
4. **FACP**: decai, sem corte, nas defasagens baixas e em torno de 12, 24..., porque há MA de verdade nas duas escalas (AU02, p. 95).

Números, com $\phi = 0{,}5$, $\theta^{\text{lista}} = 0{,}4$ e $\Theta^{\text{lista}} = 0{,}6$:

- $\rho_1 = 0{,}1052$ e $\rho_2 = 0{,}0525$, decaindo à taxa $\phi = 0{,}5$;
- $\rho_{12} = -0{,}4411$, o pico sazonal;
- satélites $\rho_{11} = -0{,}0463$ e $\rho_{13} = -0{,}0464$.

Sem o AR, isto é, com $\phi = 0$ (o modelo das companhias aéreas), a FAC seria **zero fora de 1, 11, 12 e 13**.

Leitura para a prova: "FAC com pico em 12 e satélites em 11 e 13, mais decaimento nas defasagens baixas; FACP decaindo" $\Longrightarrow$ SARIMA$(1,1,1)(0,1,1)_{12}$.

(d) Como comparar com o SARIMA$(2,1,1)(0,1,1)_{12}$

1. **Os modelos são aninhados:** o segundo vira o primeiro com $\phi_2 = 0$.
2. **Teste LR:** $LR = 2(\ell_{(2)} - \ell_{(1)}) \sim \chi^2(1)$ sob $H_0 : \phi_2 = 0$. Rejeite se $LR > 3{,}84$, a 5%.
3. **BIC**, que é consistente e pune com $\ln 227 \approx 5{,}42$ por parâmetro. Use se o objetivo é **identificar** o modelo. Use o **AIC** se o objetivo é **prever** (Q14).
4. **Mesmo** T (AU02, p. 99): os dois têm $d = D = 1$, então os dois usam as mesmas 227 observações. Confira se o software usou a mesma amostra.
5. **Complementos:** Ljung-Box dos resíduos dos dois, com $\nu = K - p - q - P - Q$ (AU03, p. 15), e erro de previsão fora da amostra (AU03).

Recomendação: o BIC, com o LR como confirmação, porque os modelos são aninhados e o objetivo é a especificação.

Do meu caderno (09/09)

O caderno desenha a FAC e a FACP do AR(2), em que a FAC decai e a FACP corta em 2, e do MA(2), em que a FAC corta em 2 e a FACP decai. São as duas "assinaturas" que, combinadas nas escalas 1 e 12, dão o padrão do item (c).

O que o livro acrescenta

BJRL (cap. 9) apresenta o SARIMA$(0,1,1)(0,1,1)_{12}$ ("airline model") como o ponto de partida para séries mensais com tendência e sazonalidade. O $(1,1,1)$ desta questão o estende com um AR não sazonal. A estratégia do livro: começar do modelo das companhias aéreas e acrescentar termos só se a FAC dos resíduos pedir.

Armadilhas e variações

- **Contar 5 parâmetros**, tratando $\theta\Theta$ como livre, ou 3, esquecendo σ^2.
- **Esperar pico em 24** com um MA sazonal: o MA$(1)_{12}$ só gera pico em 12. Pico decaindo em 12, 24, 36… indicaria um AR sazonal.
- **Variações:** o modelo das companhias aéreas no Simulado 01, Q6; identificação por uma FAC amostral no Simulado 03, Q6; contagem do SARIMA$(2,1,1)(1,1,1)_{12}$ no banco.