Séries temporais

Volume 7

Apostila da P1: teoria, demonstrações, exemplos, perguntas e imagens, bloco a bloco da lista

---

Caderno de estudo · parte 1: ARMA, ARIMA e SARIMA

Prof. Guilherme Pereira · Econometria II (PPGEco/UFES)

Gerado em 28/10/2026 a partir de `github.com/fcarva/series-temporais` (commit `9a22eb5`). Material autoral: enunciados parafraseados, demonstrações próprias, números conferidos em R contra os scripts do repositório.

Sumário

I Como usar a apostila **1**

1 Apostila da P1: entender a fundo, na notação do professor **2**

II Bloco 1 — Processos e momentos **5**

2 Capítulo 1 · Processos e momentos: o que é estável numa série **6**

III Bloco 2 — AR, MA e ARMA **17**

3 Capítulo 2 · AR, MA e ARMA: memória, eco e reconstrução **18**

IV Bloco 3 — Integrados, ARIMA e SARIMA **27**

4 Capítulo 3 · Integrados, ARIMA e SARIMA: a diferença na dose certa **28**

V Bloco 4 — Estimação e seleção **37**

5 Capítulo 4 · Estimação e seleção: o detetive e os dois juízes **38**

VI Bloco 5 — Previsão **47**

6 Capítulo 5 · Previsão: o elástico e o leque **48**

VII Bloco 6 — Aplicação **59**

7 Capítulo 6 · Aplicação: Box-Jenkins de ponta a ponta num SARIMA mensal **60**

Parte I

Como usar a apostila

CAPÍTULO 1

Apostila da P1: entender a fundo, na notação do professor

A prova de 05/11 tem de 5 a 6 questões teóricas tiradas da lista "Processos ARMA, ARIMA e SARIMA". Esta apostila reúne, **um capítulo por bloco da lista**:

- a aula, com a página do slide;
- o livro, pelo capítulo;
- as demonstrações completas, linha a linha;
- um exemplo com números conferidos em R.

Ela acrescenta duas coisas que o material não tem: **perguntas em cadeia e um diálogo** (o lado socrático) e **imagens** (metáforas e analogias), cada uma com o ponto onde deixa de valer.

Capítulo	Questões	Aulas	Ideia central
1 · Processos e momentos	Q1–Q4	AU01, MAT, EQD, AU02 p. 15–23	o que é "estável" numa série: momentos, passeio, Wold
2 · AR, MA e ARMA	Q5–Q8	AU02	memória (AR), eco (MA) e a reconstrução dos choques (invertibilidade)
3 · Integrados, ARIMA e SARIMA	Q9–Q12	AU01 p. 28–30, MAT, AU05	raiz unitária, diferença na dose certa, sazonalidade
4 · Estimação e seleção	Q13–Q14	AU02 p. 58–99	verossimilhança, Yule-Walker, AIC e BIC
5 · Previsão	Q15	AU02 p. 44–57 e 72–85, AU03	a previsão como esperança condicional e o erro que cresce
6 · Aplicação: SARIMA mensal	Q16	AU02 p. 96–99, AU03	Box-Jenkins de ponta a ponta

Como estudar um capítulo

As nove seções têm sempre a mesma ordem, e a ordem é o método:

1. **Pergunta de abertura.** Responda de cabeça, mesmo errado. É o "não sei" que faz o resto grudar.
2. **A imagem.** A metáfora do tema e, numa caixa, **onde a analogia quebra**. Os limites da imagem ensinam tanto quanto ela.
3. **Teoria.** Os resultados, com a página da aula. É o que se cita na prova.
4. **Demonstrações.** Copie no papel, linha a linha. Cada capítulo tem a sua **folha à mão**, com as questões do bloco em linhas numeradas e justificadas: cap. 1 · cap. 2 · cap. 3 · cap. 4 · cap. 5 · cap. 6. Depois refaça sem olhar.
5. **Exemplo.** Os números que dão corpo à fórmula, todos conferidos em R.
6. **Cadeia socrática.** Cubra a caixa de resposta e responda primeiro. Cada pergunta prepara a seguinte.
7. **Diálogo.** O erro mais comum do tema, encenado: o aluno erra, e o professor conduz por perguntas.
8. **Na prova.** As questões da lista, as armadilhas e um checklist de 30 segundos.
9. **No material do professor.** O roteiro de releitura dos slides, na ordem, e o livro.

Ordem sugerida até 05/11, pelo peso na prova: cap. 2, depois 1, 3, 5, 4 e 6. A cada capítulo, faça as questões correspondentes da lista comentada e, no fim, os simulados.

Notação

Tudo segue os **slides**: L, $\varepsilon_t \sim RB(0, \sigma^2)$, $\phi(L) = 1 - \phi_1 L - \cdots$, $\theta(L) = 1 + \theta_1 L + \cdots$ (sinal positivo), Ω_t e $\hat{y}_{t+k/t}$. Cada capítulo termina a teoria com a **tradução para a lista**, que usa B e o sinal de Box-Jenkins: $\theta_1 = -\theta^{\text{lista}}$. A esperança vem com parênteses, $E(\cdot)$, como no resto do repositório; os slides usam colchetes.

As justificativas entre colchetes nas demonstrações:

- [RB]: ruído branco;
- [F4]: linearidade da esperança;
-
-

As ferramentas F1–F9 (Bhaskara, série geométrica, soma de Gauss…) estão demonstradas na caixa de ferramentas.

De onde vêm as imagens e as perguntas

A didática foi calibrada pelo melhor material aberto de séries temporais: Hyndman e Athanasopoulos, Penn State, Duke, Northwestern, MIT e as discussões clássicas do Cross Validated. O registro do que inspirou cada seção está em fontes.md. **O conteúdo, a notação e as páginas citadas são sempre os do professor**: as fontes externas só ajudaram a escolher as imagens e a ordem das perguntas.

Os números estão em apostila.R (id `ap`) e são conferidos pelo build. O loop do autoestudo mede cada capítulo pela régua da apostila.

Parte II

Bloco 1 — Processos e momentos

Capítulo 1 · Processos e momentos: o que é estável numa série

← apostila · próximo: cap. 2 · questões da lista: Q1 a Q4

Pergunta de abertura

Só existe **um** PIB brasileiro de 1996 a 2026: uma única história, que não se repete. Mesmo assim, falamos da "média" e da "variância" do crescimento, como se tivéssemos visto muitas histórias. **Com que direito se calcula a média de algo que aconteceu uma vez só?** E, se a resposta envolve "supor que o futuro se parece com o passado", **em que sentido exatamente ele se parece?**

A AU01 responde com dois conceitos, um para cada metade da pergunta (p. 23–27):

- **estacionariedade:** o futuro se parece com o passado nos momentos;
- **ergodicidade:** uma única história basta para aprender esses momentos.

O resto do capítulo é o que acontece quando eles falham, no passeio aleatório, e o que se ganha quando valem, com o Teorema de Wold.

A imagem

O processo é uma máquina de histórias; a série é uma história que saiu dela (AU01, p. 22–23). Imagine universos paralelos. Em cada um, a mesma máquina gera uma trajetória diferente do PIB. Nós moramos em um só deles e vemos uma só trajetória. $E(y_t)$ é a média **entre universos** numa data fixa, não a média ao longo do tempo.

Estacionariedade é um rio de nível estável. A água que passa muda o tempo todo: cada gota é nova, como cada choque. Mas, em qualquer trecho que você olhe:

- o nível médio é o mesmo;
- a agitação é a mesma;
- a semelhança entre dois pontos depende só da **distância** entre eles, não de onde estão.

São exatamente as três condições da AU01, p. 25: μ constante, γ_0 constante e γ_k dependendo só de k.

Ergodicidade é poder trocar o "entre universos" pelo "ao longo do tempo". Caminhar rio abaixo e anotar o nível equivale a fotografar mil rios paralelos no mesmo instante. Com ergodicidade, a média temporal da nossa única série converge para a média entre universos (AU01, p. 27).

O passeio aleatório é um barquinho sem correnteza que o traga de volta. Cada onda, que é o choque, empurra o barquinho e o deixa onde parou. Não há força que o puxe para um ponto fixo, e a "sorte" passada fica **grudada** na posição. Com drift, o rio está inclinado: o barquinho desce, em média, α_1 por período, mas continua sendo empurrado sem volta.

Wold diz que toda série estacionária é uma soma de notícias passadas. Tire de y_t tudo o que o passado de y permitia prever. O que sobra é a **notícia** de hoje, ε_t, o erro de previsão um passo à frente. Wold garante que a série inteira é uma soma ponderada das notícias de hoje e de antes, $\sum \psi_j \varepsilon_{t-j}$, mais uma parte que o passado prevê **sem erro nenhum**.

Onde a analogia quebra

- **O rio estável pode não ser ergódico.** Suponha que, ao nascer, cada rio recebeu um nível sorteado uma única vez, e depois só oscila em torno dele: $y_t = Z + \varepsilon_t$. Cada rio é perfeitamente estacionário, mas caminhar ao longo do **seu** rio ensina o seu Z, nunca a média entre rios. O exemplo deste capítulo mostra os números.
- **As "notícias" de Wold não são independentes, só não correlacionadas.** Wold é uma afirmação sobre previsão **linear**. O processo pode ter estrutura não linear, por exemplo na variância, que o ε_t de Wold não captura.
- **O barquinho sugere um objeto físico com inércia**, mas o passeio não "acelera": a variância cresce linearmente, $t\sigma^2$, e o desvio padrão só com $\sqrt{t}$.

Teoria

O que se procura numa série (AU01, p. 8): dinâmica, tendência, sazonalidade e ciclos, não linearidade e variância que muda. Esta lista trata de modelos **univariados**, em que só o passado da própria série explica o presente, e não dos multivariados, que trazem outras variáveis (AU01, p. 17–18).

Processo estocástico (AU01, p. 21–23): uma coleção $\{y_t\}$ de variáveis aleatórias indexadas pelo tempo. A série observada é **uma** realização dele.

Estacionariedade de 2ª ordem, ou fraca (AU01, p. 25). Para todo t:

$$E(y_t) = \mu, \qquad \mathrm{Var}(y_t) = \gamma_0 < \infty, \qquad E\big((y_t - \mu)(y_{t-k} - \mu)\big) = \gamma_k \text{ (só depende de } k).$$

Estacionariedade estrita (AU01, p. 26): a distribuição conjunta de $(y_{t_1}, \ldots, y_{t_k})$ não muda com um deslocamento h das datas.

- Estrita com variância finita implica fraca.
- A volta só vale sob normalidade.

Ergodicidade (AU01, p. 27): $\bar{y} = \frac{1}{T}\sum y_t \to \mu$ (na média) e a autocovariância amostral converge para γ_k (no 2º momento).

Ruído branco (AU01, p. 31): $E(\varepsilon_t) = 0$, $\mathrm{Var}(\varepsilon_t) = \sigma^2$, $E(\varepsilon_t \varepsilon_{t-k}) = 0$ para $k \neq 0$.

Passeio aleatório e variações (AU01, p. 28–30). Com valor inicial fixo y_0:

Modelo	$E(Y_t)$	$\mathrm{Var}(Y_t)$	$\mathrm{Cov}(Y_t, Y_{t-k})$
$Y_t = Y_{t-1} + \varepsilon_t$	y_0	$t\sigma^2$	$(t-k)\sigma^2$
$Y_t = \alpha_1 + Y_{t-1} + \varepsilon_t$ (drift)	$y_0 + \alpha_1 t$	$t\sigma^2$	$(t-k)\sigma^2$
$Y_t = \alpha_1 + Y_{t-1} + \alpha_2 t + \varepsilon_t$	$y_0 + \alpha_1 t + \alpha_2 \frac{t(t+1)}{2}$	$t\sigma^2$	$(t-k)\sigma^2$

Os três **não são estacionários**: a variância cresce com t. Os dois últimos têm também a média dependendo de t, uma **tendência determinística**, linear ou quadrática, somada à **tendência estocástica** $\sum \varepsilon_s$.

FAC (AU01, p. 35): sob estacionariedade, $\rho_k = \gamma_k / \gamma_0$, com $\gamma_k = \gamma_{-k}$.

Combinação de processos (lista, Q3). Se x_t e w_t são estacionários e não correlacionados em todas as defasagens, então $z_t = a x_t + b w_t$ é estacionário e $\gamma_z(k) = a^2 \gamma_x(k) + b^2 \gamma_w(k)$.

Processo linear geral (AU02, p. 15–18):

$$y_t = \mu + \sum_{j \geq 0} \psi_j \varepsilon_{t-j}, \quad \psi_0 = 1, \quad \sum_{j \geq 0} \psi_j^2 < \infty \implies \gamma_k = \sigma^2 \sum_{j \geq 0} \psi_j \psi_{j+k}.$$

Teorema de Wold (HAMILTON, cap. 4; lista, Q4). Todo processo estacionário de 2ª ordem, com média zero, escreve-se como

$$y_t = \sum_{j\geq 0} \psi_j \varepsilon_{t-j} + \kappa_t, \qquad \psi_0 = 1, \ \sum_{j\geq 0} \psi_j^2 < \infty,$$

em que:

- $\varepsilon_t = y_t - \hat{E}(y_t \mid y_{t-1}, y_{t-2}, \dots)$ é o erro da **melhor previsão linear** um passo à frente, e por isso é ruído branco;
- κ_t é o componente **determinístico**, previsto sem erro pelo passado de y, como uma senoide de amplitude sorteada uma vez;
- κ_t não se correlaciona com nenhum ε_s.

O processo é **puramente não determinístico** quando $\kappa_t = 0$. É o caso dos ARMA estacionários, e a lista supõe isso.

Demonstrações

O formato é o da folha à mão. A Q2 (drift e tendência) está demonstrada lá por inteiro, inclusive a esperança do somatório.

D1.1 · Passeio com drift: os momentos dependem de t (Q1)

Modelo: $y_t = c + y_{t-1} + u_t$, com y_0 fixo e $u_t \sim RB(0, \sigma^2)$ (AU01, p. 29). O caso sem drift, $c = 0$ e $y_0 = 0$, é feito passo a passo na AU01, p. 45–47.

(1) $y_t - y_{t-1} = c + u_t$ [modelo]

(2) $\sum_{s=1}^{t} (y_s - y_{s-1}) = y_t - y_0$ [telescópica]

(3) $y_t = y_0 + ct + \sum_{s=1}^{t} u_s$ [(1), (2)]

(4) $E(y_t) = y_0 + ct + \sum_{s=1}^{t} E(u_s) = y_0 + ct$ [F4, soma finita; RB]

(5) $\mathrm{Var}(y_t) = E\Big(\Big(\sum_{s=1}^{t} u_s\Big)^2\Big) = \sum_{s=1}^{t} E(u_s^2) = t\sigma^2$ [RB: só $i = j$]

(6) $\mathrm{Cov}(y_t, y_{t-k}) = E\Big(\sum_{i=1}^{t} u_i \sum_{j=1}^{t-k} u_j\Big) = \sum_{j=1}^{t-k} E(u_j^2) = (t-k)\sigma^2$ [RB]

(7) $\mathrm{Corr}(y_t, y_{t-k}) = \dfrac{(t-k)\sigma^2}{\sqrt{t\sigma^2 (t-k)\sigma^2}} = \sqrt{\dfrac{t-k}{t}}$ [(5), (6)]

$$\boxed{E(y_t) = y_0 + ct, \qquad \mathrm{Var}(y_t) = t\sigma^2, \qquad \mathrm{Cov}(y_t, y_{t-k}) = (t-k)\sigma^2 \implies \text{não estacionário}}$$

Em (7), para k fixo e t grande, a correlação vai a 1: **a FAC de um passeio decai devagar, quase linearmente**. É a assinatura visual da raiz unitária, retomada no cap. 3.

D1.2 · Soma de processos não correlacionados (Q3)

$z_t = x_t + b\,w_t$, com x e w estacionários, médias μ_x e μ_w, e $\mathrm{Cov}(x_t, w_s) = 0$ para todos t, s.

(1)	$E(z_t) = \mu_x + b\,\mu_w$	[F4: constante]
(2)	$z_t - E(z_t) = (x_t - \mu_x) + b\,(w_t - \mu_w)$	[(1)]
(3)	$\gamma_z(k) = E\Big(\big((x_t - \mu_x) + b(w_t - \mu_w)\big)\big((x_{t-k} - \mu_x) + b(w_{t-k} - \mu_w)\big)\Big)$	[(2)]
(4)	$\quad = \gamma_x(k) + b\,\mathrm{Cov}(x_t, w_{t-k}) + b\,\mathrm{Cov}(w_t, x_{t-k}) + b^2\gamma_w(k)$	[F4: quatro produtos]
(5)	$\quad = \gamma_x(k) + 0 + 0 + b^2\gamma_w(k)$	[não correlacionados]
(6)	com $b = 2$: $\gamma_{z_3}(k) = \gamma_{z_1}(k) + 4\,\gamma_{z_2}(k)$	[Q3]

$$\boxed{\gamma_z(k) = \gamma_x(k) + b^2\gamma_w(k) \;:\; \text{a constante sai ao quadrado; a FAC de } z \text{ corta onde corta a mais longa}}$$

Como γ_{z_1} corta depois de 1 e γ_{z_2} depois de 2, γ_{z_3} corta depois de 2. Um processo cuja FAC zera a partir de 3 é um **MA(2)**.

D1.3 · Processo linear: $\gamma_k = \sigma^2 \sum \psi_j\psi_{j+k}$

Com $y_t - \mu = \sum_{i\geq 0} \psi_i\varepsilon_{t-i}$ (AU02, p. 18):

(1)	$\gamma_k = E\Big(\sum_{i\geq 0}\psi_i\varepsilon_{t-i}\sum_{l\geq 0}\psi_l\varepsilon_{t-k-l}\Big)$	[definição]
(2)	$\quad = \sum_{i\geq 0}\sum_{l\geq 0}\psi_i\psi_l\,E(\varepsilon_{t-i}\varepsilon_{t-k-l})$	[F4; troca vale com $\sum\psi^2 < \infty$]
(3)	$E(\varepsilon_{t-i}\varepsilon_{t-k-l}) = \sigma^2$ se $i = k + l$, e 0 se não	[RB]
(4)	$\gamma_k = \sigma^2\sum_{l\geq 0}\psi_{k+l}\psi_l$	[só $i = k + l$]
(5)	$\gamma_0 = \sigma^2\sum_{l\geq 0}\psi_l^2$	[$k = 0$]
(6)	MA(2) com $\psi = (1;\ 0{,}7;\ 0{,}6)$: $\gamma_1 = \sigma^2(1\cdot 0{,}7 + 0{,}7\cdot 0{,}6) = 1{,}12\,\sigma^2$	[(4)]

$$\boxed{\gamma_k = \sigma^2\sum_{j\geq 0}\psi_j\psi_{j+k}}$$

A condição $\sum\psi_j^2 < \infty$ é exatamente o que faz (5) ser finito: é a "somabilidade" da AU02, p. 17.

D1.4 · Wold do AR(1): os ψ_j explícitos (Q4b)

$y_t = \phi y_{t-1} + \varepsilon_t$, com $|\phi| < 1$ (AU02, p. 21 e 25).

(1) $y_t = \phi(\phi y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \phi^2 y_{t-2} + \phi\varepsilon_{t-1} + \varepsilon_t$ [modelo em $t-1$]

(2) $y_t = \phi^n y_{t-n} + \sum_{j=0}^{n-1} \phi^j \varepsilon_{t-j}$ [n substituições]

(3) $E\Big(\Big(y_t - \sum_{j=0}^{n-1} \phi^j \varepsilon_{t-j}\Big)^2\Big) = \phi^{2n} E(y_{t-n}^2) = \phi^{2n}\gamma_0$ [(2), estac.]

(4) $\phi^{2n}\gamma_0 \to 0$ quando $n \to \infty$ [$|\phi| < 1$]

(5) $y_t = \sum_{j\geq 0} \phi^j \varepsilon_{t-j}$ [limite em média quadrática]

(6) $\sum_{j\geq 0} \psi_j^2 = \sum_{j\geq 0} \phi^{2j} = \dfrac{1}{1-\phi^2} < \infty$ [F2: geométrica, razão ϕ^2]

$$\boxed{\psi_j = \phi^j, \quad \psi_0 = 1, \quad \sum \psi_j^2 = \frac{1}{1-\phi^2} < \infty \ : \ \text{o AR(1) é um Wold com } \kappa_t = 0}$$

Os ε_t são mesmo as inovações de Wold: como $y_{t-1}, y_{t-2}, \ldots$ só contêm choques até $t-1$, a melhor previsão linear de y_t é ϕy_{t-1}, e o erro é ε_t. A parte determinística é nula, porque nada em y_t é previsível sem erro.

D1.5 · Estacionário, mas não ergódico

$y_t = Z + \varepsilon_t$, com $Z \sim (0, \sigma_Z^2)$ sorteado **uma vez**, independente de $\{\varepsilon_t\}$.

(1) $E(y_t) = E(Z) + E(\varepsilon_t) = 0$ [F4]

(2) $\gamma_0 = E\big((Z+\varepsilon_t)^2\big) = \sigma_Z^2 + 2E(Z\varepsilon_t) + \sigma^2 = \sigma_Z^2 + \sigma^2$ [independência]

(3) $\gamma_k = E\big((Z+\varepsilon_t)(Z+\varepsilon_{t-k})\big) = \sigma_Z^2, \quad k \geq 1$ [RB, independência]

(4) (1)–(3) não dependem de $t \implies$ estacionário [AU01, p. 25]

(5) $\bar{y} = \dfrac{1}{T}\sum_{t=1}^{T}(Z+\varepsilon_t) = Z + \dfrac{1}{T}\sum_{t=1}^{T}\varepsilon_t$ [numa trajetória]

(6) $\bar{y} \to Z \neq 0 = \mu$ [lei dos grandes números em ε]

$$\boxed{\text{estacionário, mas } \bar{y} \to Z, \text{ não } \mu \ : \ \text{não é ergódico na média}}$$

A pista está em (3): $\gamma_k = \sigma_Z^2$ **não vai a zero**. Uma condição suficiente para a ergodicidade na média é $\gamma_k \to 0$, ou, mais precisamente, $\sum|\gamma_k| < \infty$. Os ARMA estacionários a cumprem.

D1.6 · Como ler o correlograma: FAC, FACP e a banda (AU01, p. 35–49)

A FAC e a FACP são a "assinatura", ou o DNA, de um processo (AU01, p. 36 e 43): medem a memória e a dependência de y_t em relação às próprias defasagens. A ideia de identificação é comparar o correlograma dos dados, o gráfico das AU01, p. 38 e 42, com as assinaturas teóricas.

(1)	$\rho_k = \dfrac{\mathrm{Cov}(y_t, y_{t-k})}{\sqrt{\mathrm{Var}(y_t)\,\mathrm{Var}(y_{t-k})}} = \dfrac{\gamma_k}{\gamma_0}$	[AU01 p. 37; estac.]
(2)	$\lvert\rho_k\rvert \leq 1$	[Cauchy-Schwarz; AU01 p. 39]
(3)	sob RB: $\hat{\rho}_k \approx N(0, 1/T) \;\Rightarrow$ banda $\pm\, 1{,}96/\sqrt{T}$	[AU01 p. 39]
(4)	$\phi_{kk} = \mathrm{Corr}(y_t, y_{t-k} \mid y_{t-1}, \ldots, y_{t-k+1})$	[AU01 p. 40–41]
(5)	$k = 1 \;:\; \phi_{11} = \rho_1$	[regressão de y_t em y_{t-1}]
(6)	$k = 2 \;:\; \rho_1 = \phi_{21} + \phi_{22}\rho_1, \qquad \rho_2 = \phi_{21}\rho_1 + \phi_{22}$	[AU02 p. 92]
(7)	$\phi_{21} = \rho_1(1 - \phi_{22})$	[1ª equação]
(8)	$\rho_2 = \rho_1^2(1 - \phi_{22}) + \phi_{22} \;\Rightarrow\; \phi_{22}(1 - \rho_1^2) = \rho_2 - \rho_1^2$	[(7) na 2ª]
(9)	$\phi_{22} = \dfrac{\rho_2 - \rho_1^2}{1 - \rho_1^2}$	[isola]
(10)	AR(1) : $\rho_2 = \rho_1^2 \;\Rightarrow\; \phi_{22} = 0$: a FACP corta	[AU02 p. 94]
(11)	MA(1) : $\rho_2 = 0 \;\Rightarrow\; \phi_{22} = -\dfrac{\rho_1^2}{1 - \rho_1^2} \neq 0$: a FACP decai	[AU02 p. 95]
(12)	passeio: $\rho(t, k) = \sqrt{(t-k)/t} \to 1$ para k fixo	[D1.1; AU01 p. 48]

$\phi_{22} = \dfrac{\rho_2 - \rho_1^2}{1 - \rho_1^2}$; banda $\pm\, 1{,}96/\sqrt{T}$; passeio: FAC perto de 1 que cai devagar

Em (3), a derivação da banda está no aprofundamento do bloco 2. Em (4), ϕ_{kk} é o último coeficiente de um AR(k) ajustado (AU02, p. 90), e por isso (6) usa o Yule-Walker do AR(2). A FAC "carrega" os efeitos intermediários; a FACP os remove (AU01, p. 39–41). Por isso:

- o AR(p) tem FAC que decai e FACP que corta em p;
- o MA(q), o contrário.

Números:

- no MA(1) com $\theta_1 = 0{,}5$, $\rho_1 = 0{,}4$, e (11) dá $\phi_{22} = -0{,}16/0{,}84 = -0{,}1905$, igual ao `ARMAacf`;
- no AR(1) com $\phi = 0{,}7$, $\phi_{22} = 0$;
- numa simulação com $T = 200$, banda $\pm 0{,}139$, como na AU01, p. 49:
  - a FAC amostral do passeio vale 0,970, 0,876 e 0,763 nas defasagens 1, 5 e 10: decai quase em linha reta;
  - a do AR(1) com $\phi = 0{,}7$ vale 0,639, 0,290 e −0,082, contra os teóricos 0,7, 0,168 e 0,028: cai rápido e entra na banda.

Exemplo

Três experimentos numéricos, todos do R.

1. O passeio da Q1, com $y_0 = 10$, $c = 0{,}5$ e $\sigma^2 = 1$, em $t = 20$ e $k = 5$:

Momento	Fórmula (D1.1)	40 mil trajetórias simuladas
$E(y_{20})$	$10 + 0{,}5 \cdot 20 = 20$	20,01
$\mathrm{Var}(y_{20})$	$20\sigma^2 = 20$	19,98
$\mathrm{Cov}(y_{20}, y_{15})$	$15\sigma^2 = 15$	14,99
$\mathrm{Corr}(y_{20}, y_{15})$	$\sqrt{15/20} = 0{,}866$	

2. A soma da Q3. Com $\gamma_{z_1} = (0{,}5;\ 0{,}2;\ 0)$ e $\gamma_{z_2} = (2{,}30;\ -1{,}43;\ 0{,}30;\ 0)$, a D1.2 dá:

- $\gamma_0 = 0{,}5 + 4(2{,}30) = 9{,}7$;
- $\gamma_1 = 0{,}2 + 4(-1{,}43) = -5{,}52$;
- $\gamma_2 = 0 + 4(0{,}30) = 1{,}2$;
- $\gamma_3 = 0$.

Daí $\rho_1 = -0{,}5691$ e $\rho_2 = 0{,}1237$: a FAC corta depois de 2, então z_3 é **MA(2)**.

3. Wold e o processo linear.

- AR(1) com $\phi = 0{,}5$: os pesos são $\psi_1 = 0{,}5$, ..., $\psi_4 = 0{,}0625$, e $\sum \psi_j^2 = 1/(1 - 0{,}25) = 1{,}3333$. A soma de 200 termos no R dá o mesmo valor.
- MA(2) com $\psi = (1;\ 0{,}7;\ 0{,}6)$: a D1.3 dá $\gamma_1 = 1{,}12\,\sigma^2$, $\gamma_2 = 0{,}6\,\sigma^2$ e $\rho_1 = 0{,}6054$, igual ao `ARMAacf`.

4. O rio sorteado da D1.5. Três trajetórias de $y_t = Z + \varepsilon_t$, cada uma com 5 000 períodos:

Trajetória	Z sorteado	média temporal $\bar{y}$
1	2,287	2,290
2	−1,197	−1,197
3	−0,694	−0,668

Cada média temporal acerta o **seu** Z, não o $\mu = 0$ do processo. Já a média **entre** 20 mil trajetórias numa data fixa dá −0,007, perto de zero. É a diferença entre "ao longo do tempo" e "entre universos".

Cadeia socrática

P1. O ruído branco é estacionário? E é ergódico?

> **Resposta**
>
> Sim aos dois. Média 0, variância σ^2 e $\gamma_k = 0$ para $k \neq 0$: nada depende de t. E, como γ_k é zero fora da origem, a média temporal converge para 0 (AU01, p. 31).

P2. Se uma série tem média constante, ela é estacionária?

> **Resposta**
>
> Não necessariamente. O passeio sem drift tem $E(Y_t) = y_0$, constante, mas $\mathrm{Var}(Y_t) = t\sigma^2$ cresce. Estacionariedade de 2ª ordem exige as **três** condições (AU01, p. 25 e 28).

P3. Por que, no passeio, $\mathrm{Cov}(Y_t, Y_{t-k})$ depende de t, e não só de k?

Resposta

Porque a covariância conta os choques que as duas datas têm em comum, que são $t - k$. Duas datas com a mesma distância k, mas mais tarde na amostra, compartilham mais choques. No rio estável, isso não acontece: só a distância importa.

P4. Um ciclo forte e irregular, como a população de linces que sobe e desce a cada ~10 anos, é estacionário?

Resposta

Pode ser. Um ciclo **aperiódico**, sem data fixa para os picos, é compatível com momentos constantes: um AR(2) com raízes complexas faz isso (cap. 2, D2.5). Não estacionário é o que tem tendência na média ou variância que cresce, não o que oscila.

P5. O que é exatamente o ε_t do Teorema de Wold?

Resposta

O erro da melhor previsão **linear** de y_t feita com $y_{t-1}, y_{t-2}, \ldots$, a "notícia" de hoje. Por construção, ele não se correlaciona com nada do passado, inclusive com os ε anteriores, e por isso é RB.

P6. Wold diz que todo processo estacionário **é** um MA(∞). Então para que servem o AR e o ARMA?

Resposta

Para resumir com poucos parâmetros. Um MA(∞) tem infinitos ψ_j. O AR(1) os gera todos com um único número, $\psi_j = \phi^j$, e o ARMA(p, q) com $p + q$. Wold justifica a classe; o ARMA a torna estimável (AU02, p. 43).

P7. Por que a Q4(c) diz que, sem invertibilidade, não há AR(∞) convergente?

Resposta

Porque os pesos da forma AR(∞) de um MA(1) são $\pi_j = -(-\theta_1)^j$. Com $|\theta_1| \geq 1$, eles não diminuem, e a soma $\sum \pi_j y_{t-j}$ não converge (cap. 2, D2.2).

P8. Um processo pode ser estritamente estacionário e **não** fracamente estacionário?

Resposta

Sim, se a variância for infinita. Uma sequência i.i.d. de Cauchy tem a mesma distribuição em todas as datas, o que a torna estritamente estacionária, mas não tem média nem variância. A estacionariedade estrita só implica a fraca quando os momentos existem (AU01, p. 26).

Diálogo

Sobre o erro de achar que "estacionário" quer dizer "sem tendência visível".

Aluno: O passeio sem drift não tem tendência, $E(Y_t) = y_0$. Então ele é estacionário.

Professor: O que a definição da AU01, p. 25, pede?

Aluno: Média constante, variância constante e covariância dependendo só da distância.

Professor: E a variância do passeio?

Aluno: $t\sigma^2$... Cresce com o tempo. Então não é estacionário. Mas no gráfico ele não "sobe".

Professor: Simule mil trajetórias e sobreponha. O que acontece com o leque?

Aluno: Ele abre: em $t = 100$, as trajetórias estão muito mais espalhadas que em $t = 10$. Cada trajetória sozinha não sobe, mas o conjunto se espalha.

Professor: Então "tendência" não é a única forma de não estacionariedade. E a recíproca: uma série que oscila muito, em ciclos largos, é necessariamente não estacionária?

Aluno: Pelo exemplo dos linces, não. Se os ciclos não têm data marcada e a amplitude não cresce, os momentos podem ser constantes.

Professor: Qual é a regra, então?

Aluno: Não julgar pelo "formato" do gráfico. Calcular os três momentos e ver se algum depende de *t*. No passeio, quem denuncia é a variância.

Na prova

A folha de caderno do bloco está em a_mao_cap1.md: Q1 a Q4 (a Q2 em esqueleto, com a folha completa ao lado) em 52 linhas numeradas, cada uma com a justificativa, mais a versão para a prova e a conferência em R.

Questão	O que este capítulo dá	Resolução completa
Q1	momentos do passeio com drift e $y_0 = 10$; não estacionário	Q1
Q2	drift e tendência: solução, momentos, natureza da tendência	Q2 e a folha à mão
Q3	autocovariância de $z_1 + 2z_2$, estacionariedade e classe MA(2)	Q3
Q4	enunciado de Wold, componente determinístico, AR(1) e invertibilidade	Q4

Armadilhas:

- na Q1, esquecer o $y_0 = 10$ na média;
- na Q3, usar $2\gamma_{z_2}$ em vez de $4\gamma_{z_2}$: a constante sai **ao quadrado**;
- confundir "não depende de *t*" com "não depende de *k*";
- dizer que o componente determinístico de Wold é uma "tendência linear". Ele é o que o passado prevê sem erro, e uma tendência faria a média depender de *t*;
- no caderno, y_2 do AR(1) recursivo saiu sem o y_0 (ver Q4).

Checklist de 30 segundos:

1. Testei as **três** condições de estacionariedade, não só a média?
2. Usei y_0 do enunciado?
3. Cada esperança com a justificativa: [F4], [RB]?
4. Na soma de processos, constantes ao quadrado e produtos cruzados zerados **com** o motivo?
5. Fechei com a frase pedida ("logo, não é estacionário")?

No material do professor

Roteiro de releitura:

- AU01, p. 21–23: processo estocástico × série observada;
- AU01, p. 24–27: estacionariedade fraca e estrita, ergodicidade;
- AU01, p. 28–31: passeio, drift, drift e tendência, ruído branco;
- AU01, p. 32–35: AR, MA e as definições de FAC;
- AU02, p. 15–23: processo linear geral e os pesos ψ e π;

- MAT, §1: tendência determinística × estocástica, que liga com o cap. 3.

Livros:

- **HAMILTON**, cap. 3 (estacionariedade, ergodicidade, processo linear) e cap. 4.8 (Teorema de Wold);
- **ENDERS**, cap. 2: estacionariedade e FAC no nível do curso;
- **BJRL**, cap. 2: autocovariância e FAC.

Na lista comentada: Q1 · Q2 · Q3 · Q4 · ferramentas F2, F3, F4 e F5.

Parte III

Bloco 2 — AR, MA e ARMA

Capítulo 2 · AR, MA e ARMA: memória, eco e reconstrução

← apostila · anterior: cap. 1 · próximo: cap. 3 · questões da lista: Q5 a Q8

Pergunta de abertura

O Banco Central sobe os juros hoje, e a inflação reage. **Daqui a dois anos, esse choque ainda está na inflação, ou já se dissolveu?** E a pergunta inversa: nós só vemos a série da inflação, nunca os choques. **Olhando só para a série, dá para descobrir quais choques a produziram?**

O próprio professor abre o tema com essas duas perguntas (AU02, p. 24):

- a primeira é a **estacionariedade**, uma propriedade do lado AR;
- a segunda é a **invertibilidade**, uma propriedade do lado MA.

O capítulo inteiro é a resposta a elas. Guarde as duas: toda condição técnica que aparecer abaixo, "raízes fora do círculo unitário" por exemplo, é só uma forma precisa de responder "sim" a uma delas.

A imagem

O MA é um eco numa sala. Você grita uma vez, que é o choque ε_t. A sala devolve o grito q vezes, cada vez com um volume θ_j, e depois fica em silêncio absoluto. Por isso a FAC de um MA(q) **corta** depois da defasagem q: quem está a mais de q períodos de distância não divide nenhum grito com você.

O AR é uma mola com atrito. Puxe a mola, que é o choque, e solte. A cada período, sobra uma fração ϕ_1 do desvio da posição de equilíbrio:

- com $\phi_1 = 0{,}5$, metade do desvio sobrevive a cada passo e a mola volta rápido;
- com $\phi_1 = 0{,}99$, ela quase não perde força;
- com $\phi_1 = 1$, **a mola quebrou**: o desvio nunca diminui, e você tem um passeio aleatório.

A FAC **decai** geometricamente, mas nunca chega a zero, porque o choque de hoje carrega um pouco de todos os anteriores.

O AR(2) com raízes complexas é um balanço empurrado. O balanço vai e volta, com amplitude cada vez menor. O período de ida e volta sai das raízes do polinômio, e o "atrito" é o módulo delas.

A invertibilidade é reconstruir as notas ouvindo a gravação. A gravação, y_t, mistura cada nota, ε_t, com o eco da nota anterior. Para recuperar a nota de hoje, desconte o eco, mas o eco depende da nota de ontem, que você também precisa recuperar, e assim por diante. Com $|\theta_1| < 1$, cada correção pesa menos que a anterior e o processo converge. Com $|\theta_1| > 1$, as gravações antigas pesam **mais** que as recentes, e a reconstrução explode.

O fator comum é uma fração que se simplifica. Em $\frac{6}{9}$, o 3 de cima cancela com o 3 de baixo e sobra $\frac{2}{3}$. Em $(1 - 0{,}5L)\, y_t = (1 - 0{,}5L)\, \varepsilon_t$, o mesmo fator cancela e sobra $y_t = \varepsilon_t$: o "ARMA(1,1)" era ruído branco disfarçado.

> **Onde a analogia quebra**
>
> - O eco real decai suavemente. O "eco" do MA pode ser **mais alto na segunda volta que na primeira** ($\theta_2 > \theta_1$) e para **exatamente** em q, sem cauda nenhuma.
> - A mola real com atrito nunca troca de lado a cada período. Um AR(1) com $\phi_1 < 0$ troca: o desvio muda de sinal a cada passo, e a FAC alterna $+, -, +, -$.

> - Na música, um MA não invertível ainda é um processo **legítimo e estacionário**. Ele tem exatamente a mesma FAC que o seu par invertível (AU02, p. 34). A invertibilidade não é uma lei física: é uma **escolha de representação**, a única em que os choques podem ser lidos a partir do passado observado.

Teoria

Toda a notação é a dos slides. A **tradução para a lista** está na última tabela desta seção.

Operador de defasagem (AU02, p. 11–14). $L^j y_t = y_{t-j}$. Os modelos viram polinômios em L:

$$\phi(L) = 1 - \phi_1 L - \cdots - \phi_p L^p, \qquad \theta(L) = 1 + \theta_1 L + \cdots + \theta_q L^q, \qquad \phi(L)\, y_t = c + \theta(L)\, \varepsilon_t.$$

Processo linear geral (AU02, p. 15–20). $y_t = \mu + \Psi(L)\varepsilon_t = \mu + \sum_{j\geq 0} \psi_j \varepsilon_{t-j}$, com $\psi_0 = 1$.

- Se $\sum \psi_j^2 < \infty$, as autocovariâncias existem e valem $\gamma_k = \sigma^2 \sum_{j\geq 0} \psi_j \psi_{j+k}$ (AU02, p. 18).
- A forma AR(∞) é $\pi(L)\tilde{y}_t = \varepsilon_t$, com $\pi(L) = 1 - \pi_1 L - \pi_2 L^2 - \cdots = \Psi(L)^{-1}$ (AU02, p. 19–20).

MA(q) (AU02, p. 29 e 49–52). A soma é finita, então **todo MA(q) é estacionário**, para quaisquer θ. Com $\theta_0 = 1$:

$$\gamma_k = \begin{cases} \sigma^2 \sum_{j=0}^{q-k} \theta_j \theta_{j+k}, & k = 0, 1, \ldots, q, \\ 0, & k > q, \end{cases}$$

e a FAC **trunca** depois de q. No MA(1), $|\rho_1| \leq \frac{1}{2}$ (AU02, p. 35).

Invertibilidade (AU02, p. 22–23 e 30–36). O MA é invertível quando as raízes de $\theta(z) = 1+\theta_1 z+\cdots+\theta_q z^q = 0$ estão **fora** do círculo unitário. No MA(1), isso é $|\theta_1| < 1$, e os pesos são $\pi_j = -(-\theta_1)^j$. Os parâmetros θ e $1/\theta$ geram a mesma FAC (AU02, p. 34). A invertibilidade escolhe, entre os dois, aquele em que ε_t é recuperável. No MA(q), a condição também pode ser checada pelos autovalores de uma matriz companheira com $-\theta_1, \ldots, -\theta_q$ na primeira linha, como a matriz F do AR (AU02, p. 42).

AR(p) (AU02, p. 25–28 e 37–41). O AR é estacionário quando as raízes de $\phi(z) = 1 - \phi_1 z - \cdots - \phi_p z^p = 0$ estão fora do círculo unitário, ou seja, quando $|z_i| > 1$. Há duas formas equivalentes de escrever a mesma condição (AU02, p. 28):

- as raízes $\lambda_i = 1/z_i$ de $\lambda^p - \phi_1 \lambda^{p-1} - \cdots - \phi_p = 0$ estão **dentro** do círculo, $|\lambda_i| < 1$;
- os autovalores da matriz F são menores que 1 em módulo.

No AR(2), a condição vira o **triângulo** (AU02, p. 41): $\phi_1 + \phi_2 < 1$, $\phi_2 - \phi_1 < 1$ e $|\phi_2| < 1$.

Yule-Walker e FACP (AU02, p. 68–70 e 90–95).

- A FAC do AR(p) obedece $\rho_k = \phi_1 \rho_{k-1} + \cdots + \phi_p \rho_{k-p}$ para $k \geq 1$.
- A FACP, ϕ_{kk}, é o último coeficiente de um AR(k) ajustado. Ela **corta** depois de p no AR(p) e **decai** no MA, porque um MA invertível é um AR(∞).

ARMA(p, q) (AU02, p. 43 e 81–87).

- $\Psi(L) = \theta(L)/\phi(L)$.
- Para $k \geq q + 1$, a FAC segue a recursão do AR. As q primeiras são "contaminadas" pelo MA.
- Se $\phi(L)$ e $\theta(L)$ têm uma raiz em comum, ela cancela: é o **fator comum**, e o modelo está superparametrizado.

	FAC	FACP
AR(p)	decai (geométrica ou senoidal amortecida)	**corta** depois de p
MA(q)	**corta** depois de q	decai
ARMA(p,q)	decai a partir de q	decai a partir de p

Da lista para os slides. A lista usa B e o sinal de Box-Jenkins, exceto na Q8. Se o modelo for ARMA, troque θ^{lista} por $-\theta_1$ antes de usar qualquer fórmula desta seção.

	Slides	Lista (Q5–Q7)
defasagem	L	B
MA(1)	$y_t = \varepsilon_t + \theta_1\varepsilon_{t-1}$	$\tilde{z}_t = a_t - \theta a_{t-1}$, logo $\theta_1 = -\theta$
ARMA(1,1), ψ_j	$(\phi_1 + \theta_1)\phi_1^{j-1}$	$(\phi - \theta)\phi^{j-1}$
MA(1), ρ_1	$\frac{\theta_1}{1+\theta_1^2}$	$\frac{-\theta}{1+\theta^2}$

Demonstrações

O formato é o da folha à mão: uma operação por linha e o motivo entre colchetes.

- [RB]: ruído branco;
- [F4]: linearidade da esperança;
-
- caus.: o choque de hoje não se correlaciona com o passado de y.

O ARMA(1,1) completo, com γ_0 de nove termos, já está demonstrado na folha à mão e não se repete aqui.

D2.1 · MA(1): momentos e a FAC que corta em 1

Modelo: $y_t = c + \varepsilon_t + \theta_1\varepsilon_{t-1}$ (AU02, p. 45–47).

(1)	$E(y_t) = E(c) + E(\varepsilon_t) + \theta_1 E(\varepsilon_{t-1})$	[F4]
(2)	$= c + 0 + 0 \equiv \mu$	[RB]
(3)	$y_t - \mu = \varepsilon_t + \theta_1\varepsilon_{t-1}$	[(2)]
(4)	$\gamma_0 = E\big((\varepsilon_t + \theta_1\varepsilon_{t-1})^2\big) = E(\varepsilon_t^2) + 2\theta_1 E(\varepsilon_t\varepsilon_{t-1}) + \theta_1^2 E(\varepsilon_{t-1}^2)$	[(3), F4]
(5)	$= \sigma^2 + 0 + \theta_1^2\sigma^2 = (1+\theta_1^2)\,\sigma^2$	[RB]
(6)	$\gamma_1 = E\big((\varepsilon_t + \theta_1\varepsilon_{t-1})(\varepsilon_{t-1} + \theta_1\varepsilon_{t-2})\big)$	[(3) em t e $t-1$]
(7)	$= E(\varepsilon_t\varepsilon_{t-1}) + \theta_1 E(\varepsilon_t\varepsilon_{t-2}) + \theta_1 E(\varepsilon_{t-1}^2) + \theta_1^2 E(\varepsilon_{t-1}\varepsilon_{t-2})$	[F4]
(8)	$= 0 + 0 + \theta_1\sigma^2 + 0 = \theta_1\sigma^2$	[RB]
(9)	$\gamma_k = E\big((\varepsilon_t + \theta_1\varepsilon_{t-1})(\varepsilon_{t-k} + \theta_1\varepsilon_{t-k-1})\big), \quad k \geq 2$	[(3)]
(10)	$= 0$	[RB: datas t, $t-1$ contra $t-k$, $t-k-1$]

Em (10), como $k \geq 2$, a data mais recente do segundo parêntese, $t-k$, é anterior à mais antiga do primeiro, $t-1$. Nenhum choque aparece nos dois: todos os produtos têm datas diferentes.

$$\boxed{\gamma_0 = (1+\theta_1^2)\sigma^2, \qquad \rho_1 = \frac{\theta_1}{1+\theta_1^2}, \qquad \rho_k = 0 \ (k \geq 2)}$$

Conclusão: nada depende de t, então o MA(1) é estacionário **para qualquer** θ_1. A FAC corta em 1.

D2.2 · MA(1) → AR(∞): quando os choques são recuperáveis

Em desvios, $y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$ (AU02, p. 31). Isole o choque de hoje e substitua o de ontem, repetidamente:

$$
\begin{aligned}
&(1)\quad \varepsilon_t = y_t - \theta_1 \varepsilon_{t-1} && \text{[isola } \varepsilon_t\text{]}\\
&(2)\quad \varepsilon_{t-1} = y_{t-1} - \theta_1 \varepsilon_{t-2} && \text{[(1) em } t-1\text{]}\\
&(3)\quad \varepsilon_t = y_t - \theta_1 y_{t-1} + \theta_1^2 \varepsilon_{t-2} && \text{[(2) em (1)]}\\
&(4)\quad \varepsilon_t = y_t - \theta_1 y_{t-1} + \theta_1^2 y_{t-2} - \theta_1^3 \varepsilon_{t-3} && \text{[(1) em } t-2\text{]}\\
&(5)\quad \varepsilon_t = \sum_{j=0}^{n-1} (-\theta_1)^j y_{t-j} + (-\theta_1)^n \varepsilon_{t-n} && \text{[após } n \text{ passos]}\\
&(6)\quad E\big(((-\theta_1)^n \varepsilon_{t-n})^2\big) = \theta_1^{2n}\sigma^2 \xrightarrow[n\to\infty]{} 0 \iff |\theta_1| < 1 && \text{[RB]}\\
&(7)\quad y_t = \sum_{j\geq 1} \pi_j y_{t-j} + \varepsilon_t, \qquad \pi_j = -(-\theta_1)^j && \text{[(5), (6)]}
\end{aligned}
$$

Em (7), passe a soma de (5), sem o termo $j = 0$, para o outro lado: $y_t = \varepsilon_t - \sum_{j\geq 1}(-\theta_1)^j y_{t-j}$. Os sinais alternam: $\pi_1 = \theta_1$, $\pi_2 = -\theta_1^2$, $\pi_3 = \theta_1^3$ (AU02, p. 23).

MA(1) invertível $\iff |\theta_1| < 1 \iff$ a raiz de $1 + \theta_1 z = 0$, $z = -1/\theta_1$, está fora do círculo

D2.3 · θ_1 e $1/\theta_1$ têm a mesma FAC, e $|\rho_1| \leq \frac{1}{2}$

Compare o MA(1) com (θ_1, σ^2) e o MA(1) com $(1/\theta_1,\ \theta_1^2\sigma^2)$ (AU02, p. 34–35).

$$
\begin{aligned}
&(1)\quad \rho_1(1/\theta_1) = \frac{1/\theta_1}{1 + 1/\theta_1^2} && \text{[D2.1]}\\
&(2)\quad = \frac{(1/\theta_1)\cdot\theta_1^2}{(1 + 1/\theta_1^2)\cdot\theta_1^2} = \frac{\theta_1}{\theta_1^2 + 1} = \rho_1(\theta_1) && \text{[multiplica por } \theta_1^2\text{]}\\
&(3)\quad \gamma_0 :\ \big(1 + 1/\theta_1^2\big)\theta_1^2\sigma^2 = (\theta_1^2 + 1)\,\sigma^2 && \text{[igual ao do par]}\\
&(4)\quad \gamma_1 :\ (1/\theta_1)\,\theta_1^2\sigma^2 = \theta_1\sigma^2 && \text{[igual ao do par]}\\
&(5)\quad \gamma_k = 0 \text{ nos dois, para } k \geq 2 && \text{[D2.1]}\\
&(6)\quad (1 - |\theta_1|)^2 \geq 0 && \text{[quadrado]}\\
&(7)\quad 1 - 2|\theta_1| + \theta_1^2 \geq 0 \implies 1 + \theta_1^2 \geq 2|\theta_1| && \text{[expande]}\\
&(8)\quad |\rho_1| = \frac{|\theta_1|}{1 + \theta_1^2} \leq \frac{|\theta_1|}{2|\theta_1|} = \frac{1}{2} && \text{[(7)]}
\end{aligned}
$$

(θ_1, σ^2) e $(1/\theta_1, \theta_1^2\sigma^2)$ são indistinguíveis nos dados; $\quad |\rho_1| \leq \frac{1}{2}$, com igualdade em $|\theta_1| = 1$

Conclusão: nenhuma amostra, por maior que seja, separa os dois. A invertibilidade é a regra que escolhe um deles. E se a FAC amostral mostra $\hat{\rho}_1 = 0{,}8$ e depois zero, **não** é um MA(1).

D2.4 · AR(1): média, variância e FAC

Modelo: $y_t = c + \phi_1 y_{t-1} + \varepsilon_t$, com $|\phi_1| < 1$ (AU02, p. 62–64).

(1)	$E(y_t) = c + \phi_1 E(y_{t-1}) + E(\varepsilon_t)$	[F4]
(2)	$\mu = c + \phi_1 \mu \implies \mu = \dfrac{c}{1-\phi_1}$	[estac., RB]
(3)	$y_t - \mu = \phi_1 (y_{t-1} - \mu) + \varepsilon_t$	$[c = (1-\phi_1)\mu]$
(4)	$\gamma_0 = \phi_1^2 E\big((y_{t-1}-\mu)^2\big) + 2\phi_1 E\big((y_{t-1}-\mu)\varepsilon_t\big) + E(\varepsilon_t^2)$	$[(3)^2,$ F4]
(5)	$\gamma_0 = \phi_1^2 \gamma_0 + 0 + \sigma^2$	[estac., caus., RB]
(6)	$\gamma_0 = \dfrac{\sigma^2}{1-\phi_1^2}$	[isola]
(7)	$\gamma_k = \phi_1 E\big((y_{t-1}-\mu)(y_{t-k}-\mu)\big) + E\big(\varepsilon_t (y_{t-k}-\mu)\big)$	$[(3) \times (y_{t-k}-\mu)]$
(8)	$\gamma_k = \phi_1 \gamma_{k-1} + 0, \quad k \geq 1$	[caus.]

Por indução em (8): $\gamma_1 = \phi_1 \gamma_0$, $\gamma_2 = \phi_1 \gamma_1 = \phi_1^2 \gamma_0$, …

$$\boxed{\mu = \frac{c}{1-\phi_1}, \qquad \gamma_0 = \frac{\sigma^2}{1-\phi_1^2}, \qquad \rho_k = \phi_1^k}$$

Compare com o ARMA(1,1), em que $\rho_k = \phi_1^{k-1}\rho_1$: lá o expoente é $k-1$, porque a recursão só começa em $k = 2$.

D2.5 · AR(2): raízes por Bhaskara, ciclo e Yule-Walker

Modelo: $y_t = \phi_1 y_{t-1} + \phi_2 y_{t-2} + \varepsilon_t$ (AU02, p. 27 e 68; EQD). O exemplo é o do caderno de 03/09, $\phi_1 = 1{,}5$ e $\phi_2 = -0{,}6$.

Raízes. $\phi(z) = 1 - \phi_1 z - \phi_2 z^2 = 0$. Na ordem de Bhaskara, $az^2 + bz + c = 0$ com $a = -\phi_2$, $b = -\phi_1$ e $c = 1$.

(1)	$\Delta = b^2 - 4ac = \phi_1^2 + 4\phi_2$	$[a = -\phi_2,\ b = -\phi_1,\ c = 1]$
(2)	$\Delta = (1{,}5)^2 + 4(-0{,}6) = 2{,}25 - 2{,}4 = -0{,}15 < 0$	[raízes complexas]
(3)	$z = \dfrac{-b \pm \sqrt{\Delta}}{2a} = \dfrac{1{,}5 \pm i\sqrt{0{,}15}}{1{,}2} = 1{,}25 \pm 0{,}3227\, i$	[Bhaskara]
(4)	$\lvert z\rvert^2 = 1{,}25^2 + 0{,}3227^2 = 1{,}6667 = \dfrac{c}{a} = \dfrac{1}{0{,}6}$	[produto das conjugadas]
(5)	$\lvert z\rvert = 1{,}2910 > 1 \implies$ estacionário; $\quad \lvert\lambda\rvert = \dfrac{1}{\lvert z\rvert} = \sqrt{0{,}6} = 0{,}7746$	[AU02, p. 27–28]

Confira pelo triângulo: $\phi_1 + \phi_2 = 0{,}9 < 1$; $\phi_2 - \phi_1 = -2{,}1 < 1$; $|\phi_2| = 0{,}6 < 1$. ✓

O período do ciclo. As raízes inversas resolvem $\lambda^2 - \phi_1 \lambda - \phi_2 = 0$. Escreva-as como $\lambda = r e^{\pm i\omega}$.

(6)	$\lambda_1 \lambda_2 = -\phi_2 \implies r^2 = -\phi_2, \quad r = \sqrt{-\phi_2}$	[produto das raízes]
(7)	$\lambda_1 + \lambda_2 = \phi_1 \implies 2r\cos\omega = \phi_1$	[soma das raízes]
(8)	$\cos\omega = \dfrac{\phi_1}{2\sqrt{-\phi_2}} = \dfrac{1{,}5}{2(0{,}7746)} = 0{,}9682$	[(6), (7)]
(9)	período $= \dfrac{2\pi}{\omega} = \dfrac{2\pi}{\arccos(0{,}9682)} = 24{,}87$ períodos	[uma volta $= 2\pi$]

Yule-Walker. Multiplique o modelo por y_{t-k} e tire a esperança:

$$\text{(10)}\quad \gamma_1 = \phi_1\gamma_0 + \phi_2\gamma_1 \implies \rho_1 = \phi_1 + \phi_2\rho_1 \qquad [k=1,\ \div\gamma_0]$$

$$\text{(11)}\quad \rho_1 = \frac{\phi_1}{1-\phi_2} = \frac{1{,}5}{1{,}6} = 0{,}9375 \qquad [\text{isola}]$$

$$\text{(12)}\quad \rho_2 = \phi_1\rho_1 + \phi_2 = 1{,}5(0{,}9375) - 0{,}6 = 0{,}80625 \qquad [k=2]$$

$$|z| = \sqrt{1/0{,}6} = 1{,}291 > 1, \qquad \rho_1 = \frac{\phi_1}{1-\phi_2}, \qquad \rho_2 = \phi_1\rho_1 + \phi_2, \qquad \text{ciclo de } \approx 25 \text{ períodos}$$

O erro do caderno nesta conta

No caderno, o polinômio virou $1 - 1{,}5B - 0{,}6B^2$. O sinal de ϕ_2 entra **trocado**: $-\phi_2 B^2 = -(-0{,}6)B^2 = +0{,}6B^2$. Daí o Δ saiu com sinal errado e os módulos 0,6 e 0,52 também. O módulo certo das raízes inversas é $\sqrt{0{,}6} = 0{,}7746$, igual para as duas conjugadas.

Exemplo

Quatro processos, uma tabela. Todos os números vêm do R. Os dois primeiros são os mesmos da AU02, p. 34. O AR(2) é o do caderno, e o ARMA(1,1) é o da AU02, p. 86.

Processo (slides)	O que olhar	Resultado
MA(1), $\theta_1 = 0{,}5$, $\sigma^2 = 4$	$\gamma_0, \gamma_1, \rho_1$	5; 2; 0,4
MA(1), $\theta_1 = 2$, $\sigma^2 = 1$	$\gamma_0, \gamma_1, \rho_1$	5; 2; 0,4: **idênticos**
reconstrução de ε_t	peso de y_{t-4}, $(-\theta_1)^4$	0,0625 com $\theta_1 = 0{,}5$; **16** com $\theta_1 = 2$
AR(1), $\phi_1 = 0{,}8$, $\sigma^2 = 1$	γ_0; ρ_5; meia-vida	2,7778; 0,3277; 3,11 períodos
AR(2), $\phi_1 = 1{,}5$, $\phi_2 = -0{,}6$	Δ; $\lvert z\rvert$; ρ_1; ρ_2; ciclo	−0,15; 1,2910; 0,9375; 0,8063; 24,87
ARMA(1,1), $\phi_1 = 0{,}8$, $\theta_1 = 0{,}6$	ψ_1, ψ_2, ψ_3; ρ_1	1,4; 1,12; 0,896; 0,8931

Como ler a tabela:

1. **O par MA(1).** As duas linhas têm a mesma FAC, e a diferença máxima calculada pelo `ARMAacf` é zero. Mas a terceira linha mostra a diferença que importa: com $\theta_1 = 2$, a observação de quatro períodos atrás pesa 16 vezes na reconstrução do choque de hoje. **Só o par invertível é útil.**
2. **O AR(1).** Com $\phi_1 = 0{,}8$, um choque perde metade da força em pouco mais de 3 períodos, porque $\ln 0{,}5 / \ln 0{,}8 = 3{,}11$. Depois de 5 períodos, sobra $0{,}8^5 = 0{,}33$ dele.
3. **O AR(2).** A memória é longa, com $\rho_1 = 0{,}94$, e oscila: o balanço completa uma volta a cada ~25 períodos e perde amplitude à taxa $|\lambda| = 0{,}77$ por período.
4. **O ARMA(1,1).** Os pesos começam em $\psi_1 = \phi_1 + \theta_1 = 1{,}4$, maior que 1, porque o MA soma um eco ao primeiro passo. Depois decaem à taxa 0,8 do AR.

Cadeia socrática

Tente responder antes de ler a caixa. Cada pergunta prepara a seguinte.

P1. Num MA(3), pode haver correlação entre y_t e y_{t-4}?

Resposta

Não. y_t contém os choques de t a $t-3$, e y_{t-4} contém os de $t-4$ a $t-7$. Eles não dividem nenhum choque, e o RB zera todos os produtos cruzados: $\gamma_4 = 0$. É o eco que parou.

P2. Então, se a FAC amostral mostra $\hat{\rho}_1 = 0{,}8$ e zero depois, o processo é um MA(1)?

Resposta

Não pode ser. No MA(1), $|\rho_1| \leq \frac{1}{2}$ (D2.3). Um corte em 1 com $\hat{\rho}_1 = 0{,}8$ indica outro modelo, ou um problema na amostra (AU02, p. 35).

P3. Por que o MA(q) é estacionário para quaisquer θ, mas o AR(p) precisa de condição?

Resposta

O MA(q) é uma soma **finita** de choques: a variância é $\sigma^2 \sum \theta_j^2$, sempre finita. O AR é uma soma **infinita** de choques passados, com pesos ψ_j. Ela só converge se os pesos encolhem, e é aí que entram as raízes fora do círculo (AU02, p. 29).

P4. E se, no AR(1), $\phi_1 = 1$?

Resposta

Então $\psi_j = 1^j = 1$ para todo j: todo choque antigo pesa o mesmo que o de hoje e nunca some. $\gamma_0 = \sigma^2/(1-1)$ não existe. É o passeio aleatório da Q2: **a mola quebrou** (AU02, p. 26).

P5. E com $\phi_1 = -0{,}8$, como fica a FAC?

Resposta

$\rho_k = (-0{,}8)^k$: $-0{,}8$; $0{,}64$; $-0{,}512\ldots$ O sinal alterna e o módulo decai. Um desvio para cima hoje tende a virar um desvio para baixo amanhã.

P6. Por que a FACP de um AR(2) é zero a partir da defasagem 3?

Resposta

ϕ_{33} é o último coeficiente de um AR(3) ajustado a um processo que é AR(2). Depois de controlar por y_{t-1} e y_{t-2}, a defasagem y_{t-3} não traz informação nova, e o coeficiente dela é zero (AU02, p. 93–94).

P7. Se $\theta_1 = 2$ gera um processo estacionário com a mesma FAC de $\theta_1 = 0{,}5$, por que proibir o 2?

Resposta

Por dois motivos (AU02, p. 30–34):

- **reconstrução:** com $\theta_1 = 2$, o peso de y_{t-j} na recuperação de ε_t é $(-2)^j$ e explode, então não dá para prever, porque a previsão precisa de ε_t;
- **identificação:** os dois modelos são indistinguíveis nos dados, e sem uma regra a verossimilhança teria dois máximos iguais.

P8. No ARMA(1,1), por que $\rho_k = \phi_1^{k-1}\rho_1$ e não ϕ_1^k?

Resposta

Porque a recursão $\gamma_k = \phi_1 \gamma_{k-1}$ só vale a partir de $k = 2$. Em $k = 1$, o termo $\theta_1 E(\varepsilon_{t-1} y_{t-1}) = \theta_1 \sigma^2$ ainda aparece. O MA "contamina" só o primeiro valor, e o decaimento parte de ρ_1, não de $\rho_0 = 1$.

P9. Que modelo é $(1 - 0{,}5L)\, y_t = (1 - 0{,}5L)\, \varepsilon_t$?

Resposta

Ruído branco. O fator $(1 - 0{,}5L)$ aparece dos dois lados e cancela, como o 3 em $6/9$. Pela fórmula, $\psi_1 = \phi_1 + \theta_1 = 0{,}5 + (-0{,}5) = 0$, e todos os outros pesos também são zero. Estimar um ARMA(1,1) aqui dá parâmetros instáveis: é o **fator comum**.

P10. No AR(2), o que muda quando $\Delta < 0$?

Resposta

As raízes ficam complexas, e a FAC vira uma **senoide amortecida**: o balanço. A estacionariedade ainda exige módulo fora do círculo, $|z| = \sqrt{-1/\phi_2} > 1$, o que equivale a $|\phi_2| < 1$ no caso complexo. O período do ciclo é $2\pi / \arccos\left(\phi_1 / (2\sqrt{-\phi_2})\right)$.

Diálogo

Sobre o erro que mais cai nesta parte: misturar o sinal da lista com o dos slides.

Aluno: Na Q5, o modelo é $\tilde{z}_t = a_t - 1{,}3a_{t-1} + 0{,}4a_{t-2}$. Pela fórmula dos slides, $\theta_1 = 1{,}3$, e o MA não é invertível, porque $1{,}3 > 1$.

Professor: Que fórmula você usou para concluir que não é invertível?

Aluno: $|\theta_1| < 1$. A que vale no MA(1).

Professor: E esse modelo é um MA(1)?

Aluno: Não, é MA(2)... Então eu preciso das raízes de $\theta(z)$.

Professor: Isso. E qual é o $\theta(z)$, escrito com cuidado?

Aluno: Nos slides o sinal é positivo, $\theta(z) = 1 + \theta_1 z + \theta_2 z^2$. Como a lista tem $-1{,}3$ e $+0{,}4$, fica $\theta_1 = -1{,}3$ e $\theta_2 = 0{,}4$. Então $\theta(z) = 1 - 1{,}3z + 0{,}4z^2$.

Professor: Agora as raízes.

Aluno: $\Delta = 1{,}69 - 1{,}6 = 0{,}09$, e $z = \frac{1{,}3 \pm 0{,}3}{0{,}8}$, que dá 2 e 1,25. As duas estão fora do círculo. É invertível!

Professor: Então o "1,3 maior que 1" não provava nada. Num MA(2), um coeficiente maior que 1 é compatível com a invertibilidade. O que decide são as **raízes**. Qual é a regra que você leva para a prova?

Aluno: Primeiro, traduzir o sinal: $\theta^{\text{lista}} = -\theta_1$. Segundo, montar o polinômio inteiro. Terceiro, aplicar Bhaskara e olhar o módulo das raízes. O atalho $|\theta_1| < 1$ só vale no MA(1).

Professor: E o mesmo vale para o AR(2) do seu caderno: o erro lá foi o sinal de ϕ_2, não a conta de Bhaskara.

Na prova

A folha de caderno do bloco está em a_mao_cap2.md: Q5, Q7 e Q8 em 80 linhas numeradas, cada uma com a justificativa, mais o esqueleto da Q6, a versão para a prova e a conferência em R. É o que se copia no papel para treinar.

Questão	O que este capítulo dá	Resolução completa
Q5	escrever em B, classificar, estacionariedade e invertibilidade pelas raízes, pesos ψ_j e π_j	Q5
Q6	ARMA(1,1): γ_k, $\rho_k = \phi_1^{k-1}\rho_1$, MA($\infty$) e AR($\infty$)	Q6 e a folha à mão
Q7	AR(2): Yule-Walker, ρ_1, ρ_2, γ_0	Q7
Q8 (I)	ARMA(1,1) no sinal positivo, julgamento V/F	Q8

Armadilhas (do log de erros e do caderno):

- usar $|\theta_1| < 1$ num MA(2), em vez das raízes;
- trocar o sinal de ϕ_2 ao montar $\phi(z)$;
- escrever $\gamma_k = \phi_1^k \gamma_1$ no ARMA(1,1), quando o certo é $\phi_1^{k-1}\gamma_1$;
- perder o quadrado de θ_1^2 em γ_0;
- concluir "MA(1)" por um corte em 1 com $\hat{\rho}_1 > 0{,}5$.

Checklist de 30 segundos, antes de entregar:

1. Escrevi qual convenção de sinal estou usando?
2. Montei o polinômio **inteiro** antes de falar de raízes?
3. Estacionariedade pelo $\phi(z)$ e invertibilidade pelo $\theta(z)$, separadamente?
4. Cada esperança tem a justificativa ([RB], caus., estac.)?
5. O resultado final está traduzido para o sinal da lista?

No material do professor

Roteiro de releitura, na ordem deste capítulo:

- AU02, p. 11–14: operador L;
- AU02, p. 15–23: processo linear geral, Ψ, π, e os exemplos AR(1) e MA(1);
- AU02, p. 24: as duas perguntas da abertura;
- AU02, p. 25–29: memória do AR e estacionariedade do MA;
- AU02, p. 30–36: invertibilidade, o par θ e $1/\theta$, e a dualidade AR $\leftrightarrow$ MA;
- AU02, p. 37–41: matriz F e triângulo do AR(2);
- AU02, p. 45–53: momentos do MA(1) e do MA(q);
- AU02, p. 61–71: AR(1), AR(p) e Yule-Walker;
- AU02, p. 81–87: ARMA(1,1) e ARMA(p, q);
- AU02, p. 90–97: FACP e identificação.

A EQD dá a base de equações de diferenças de 2ª ordem para o caso complexo.

Livros:

- **ENDERS**, cap. 2: ARMA e FAC no nível do curso, com as raízes características bem explicadas;
- **HAMILTON**, cap. 3: o rigor do processo linear e da invertibilidade;
- **BJRL**, cap. 3: a convenção de sinal da lista e a FAC dos modelos mistos.

Na lista comentada: Q5 · Q6 · Q7 · Q8 · caixa de ferramentas F1 (Bhaskara), F2 (série geométrica), F7 (igualar coeficientes).

Parte IV

Bloco 3 — Integrados, ARIMA e SARIMA

Capítulo 3 · Integrados, ARIMA e SARIMA: a diferença na dose certa

← apostila · anterior: cap. 2 · próximo: cap. 4 · questões da lista: Q9 a Q12

Pergunta de abertura

O PIB cresce há décadas. Para modelá-lo com um ARMA, você precisa de uma série estacionária. Há dois caminhos:

- **tirar a diferença**, Δy_t;
- **regredir em** t e usar o resíduo.

Os dois dão o mesmo resultado? E se, na dúvida, você diferenciar uma vez a mais, "por segurança", **o que se perde?**

A resposta depende de uma pergunta que veio do cap. 2: **o choque de hoje some ou fica para sempre?**

- Se fica, a tendência é **estocástica** e o remédio é a diferença.
- Se some, e a série só oscila em torno de uma reta, a tendência é **determinística** e o remédio é a regressão.

Errar o remédio, em qualquer das duas direções, tem custo (MAT, p. 1–16; lista, Q9 e Q10).

A imagem

A tendência determinística é um trem num trilho. O trem balança, sai um pouco do eixo, mas o trilho o traz de volta: os desvios são transitórios. Saber em que ponto do trilho o trem está daqui a dez anos é fácil, e a incerteza não cresce com o horizonte.

A tendência estocástica é um barco à deriva com vento a favor. O vento, que é o drift, empurra para frente em média. Cada onda, que é o choque, desloca o barco, e **ninguém o traz de volta**: o desvio fica incorporado à rota. A incerteza sobre a posição daqui a dez anos cresce com o horizonte, exatamente como $\text{Var}(y_t) = t\sigma^2$ do cap. 1.

A diferença é um remédio, e a dose importa.

- **Subdose** (não diferenciar uma série com raiz unitária): a doença continua, e a FAC decai devagar, quase em linha reta.
- **Sobredose** (diferenciar o que já era estacionário): aparece um efeito colateral, um MA com raiz **exatamente** em $z = 1$. A assinatura é $\hat{\rho}_1$ negativo, perto de $-0{,}5$.

Uma regra prática das notas de identificação de Duke: nunca mais de duas diferenças no total, contando a sazonal.

A diferença sazonal compara com o mesmo mês do ano anterior. Em vez de "quanto mudou desde o mês passado", $(1 - L^{12})y_t$ pergunta "quanto mudou desde o mesmo mês do ano passado". O padrão de dezembro é comparado com dezembro, e a sazonalidade some se for estável.

O SAR é a memória de calendário. Num $\text{SAR}(1)_4$ trimestral, o primeiro trimestre lembra o primeiro trimestre do ano anterior, e só ele. **O multiplicativo são duas engrenagens acopladas:** uma gira a cada período (o ϕ) e outra a cada ano (o Φ). Quando se encaixam, aparece um dente a mais, o termo $\phi\Phi L^5$, e com ele os picos "satélites" em volta da defasagem sazonal.

Onde a analogia quebra

- **A sobredose não "adoece" a série.** Δy_t de um AR(1) estacionário **continua estacionária**. O custo é outro: um MA não invertível, sem AR(∞), com estimação e previsão piores. O efeito colateral é de eficiência, não de estacionariedade.
- **O trilho pode ser elástico demais para se ver.** Um processo TS com desvios AR(1) de $\phi = 0{,}98$ volta ao trilho tão devagar que, numa amostra curta, é praticamente indistinguível de um passeio. É por isso que os testes de raiz unitária têm pouco poder (MAT, §2).
- **"Comparar com o ano anterior" só limpa sazonalidade estável.** Se o padrão sazonal muda ao longo dos anos, a diferença sazonal não basta, e o que sobra precisa de termos SAR/SMA.

Teoria

Processo integrado (MAT, p. 8–9). $y_t \sim I(d)$ se é preciso diferenciar d vezes para obter um processo estacionário e invertível. **ARIMA(p, d, q)** quer dizer que $w_t = (1 - L)^d y_t$ é ARMA(p, q):

$$\phi(L)(1 - L)^d \, y_t = c + \theta(L) \, \varepsilon_t, \qquad \phi(z) \neq 0 \text{ e } \theta(z) \neq 0 \text{ para } |z| \leq 1.$$

Como $\phi(L)(1 - L)^d$ tem d raízes **exatamente** em $z = 1$, as "raízes unitárias", o nível não é estacionário, mas a diferença é.

Tendência estacionária (TS) × diferença estacionária (DS) (MAT, p. 1–16; AU01, p. 28–30):

	TS: $y_t = \alpha + \beta t + u_t$, u_t estacionário	DS: $\Delta y_t = \beta + u_t$, u_t estacionário
tendência	determinística	estocástica: $\sum u_s$
efeito de um choque	transitório	**permanente**
variância do erro de previsão	limitada	cresce com o horizonte
como estacionarizar	regredir em t	diferenciar
erro se trocar	diferenciar dá MA não invertível	regredir em t deixa um passeio no resíduo

A **decomposição de Beveridge-Nelson** (MAT, p. 11) separa um processo DS em uma tendência estocástica, que é um passeio, e um ciclo estacionário.

Sobrediferenciação (lista, Q9 e Q10). Diferenciar um processo já estacionário cria um MA com o fator $(1 - L)$, de raiz $z = 1$ (AU02, p. 33):

- o processo continua estacionário, mas **não é invertível**;
- some a forma AR(∞) convergente (AU02, p. 30–31);
- a variância pode aumentar;
- a previsão piora.

SAR, SMA e SARIMA (AU05; BJRL, cap. 9). Com período s:

$$\phi(L) \, \Phi(L^s) \, (1 - L)^d (1 - L^s)^D \, y_t = c + \theta(L) \, \Theta(L^s) \, \varepsilon_t, \qquad \text{SARIMA}(p, d, q)(P, D, Q)_s.$$

- A diferença sazonal, $(1 - L^s) \, y_t = y_t - y_{t-s}$, compara cada período com o mesmo período do ano anterior. O polinômio $1 - z^s$ tem as s raízes da unidade, todas com módulo 1, e por isso ela remove uma sazonalidade estável, do tipo "passeio sazonal".

- O **SAR(1)**$_s$, $y_t = \Phi_1 y_{t-s} + \varepsilon_t$, tem FAC não nula **só** nas defasagens múltiplas de s: $\rho_{js} = \Phi_1^j$.
- No **multiplicativo**, o produto dos polinômios cria termos cruzados, como $\phi\Phi L^{s+1}$, com coeficientes **restritos**.
- As diferenças $(1-L)^d(1-L^s)^D$ consomem $d + sD$ observações.

Na lista, troque L por B. O MA usa o sinal de Box-Jenkins, $\Theta^{\text{lista}} = -\Theta_1$, e o lado AR não muda.

Demonstrações

D3.1 · Diferenciar um AR(1) estacionário cria uma raiz unitária no MA (Q9)

$y_t = \phi y_{t-1} + \varepsilon_t$, com $|\phi| < 1$, e $w_t = \Delta y_t = y_t - y_{t-1}$.

(1)	$w_t = y_t - y_{t-1} = \phi y_{t-1} + \varepsilon_t - y_{t-1}$	[modelo]
(2)	$w_t = -(1-\phi)\, y_{t-1} + \varepsilon_t$	[agrupa y_{t-1}]
(3)	$(1-\phi L)\, y_t = \varepsilon_t$	[modelo em L]
(4)	$(1-L)(1-\phi L)\, y_t = (1-L)\, \varepsilon_t$	[aplica $(1-L)$ aos dois lados]
(5)	$(1-\phi L)\,(1-L) y_t = (1-L)\, \varepsilon_t$	[polinômios comutam]
(6)	$(1-\phi L)\, w_t = (1-L)\, \varepsilon_t$	[$w_t = (1-L)y_t$]
(7)	$\theta(z) = 1 - z = 0 \implies z = 1,\ \lvert z\rvert = 1$	[raiz no círculo]
(8)	$(1-L)^{-1} = 1 + L + L^2 + \cdots$	[F2 com razão 1]

Em (8), a série geométrica de razão 1 tem todos os pesos iguais a 1, e eles não encolhem. Os π_j de w_t não são somáveis, e **não existe AR(∞) convergente**. Os choques não podem ser recuperados do passado de w.

A assinatura na FAC. Com γ_k de y e $\gamma_k = \phi^k \gamma_0$:

(9)	$\gamma_w(0) = E\big((y_t - y_{t-1})^2\big) = 2\gamma_0 - 2\gamma_1 = 2\gamma_0(1-\phi)$	[F5]
(10)	$\gamma_w(1) = E\big((y_t - y_{t-1})(y_{t-1} - y_{t-2})\big) = 2\gamma_1 - \gamma_0 - \gamma_2 = -\gamma_0(1-\phi)^2$	[F5, $\gamma_k = \phi^k\gamma_0$]
(11)	$\rho_w(1) = \dfrac{-\gamma_0(1-\phi)^2}{2\gamma_0(1-\phi)} = -\dfrac{1-\phi}{2}$	[(10) ÷ (9)]

$$(1-\phi L)\, w_t = (1-L)\, \varepsilon_t \ :\ \text{ARMA(1,1) com MA não invertível;} \qquad \rho_w(1) = -\tfrac{1-\phi}{2} \in (-1, 0)$$

Com $\phi = 0$, ou seja, diferenciando um ruído branco, $\rho_w(1) = -0{,}5$ **exatamente**: é a assinatura clássica da sobrediferenciação.

D3.2 · Diferenciar uma tendência determinística (Q10d)

$y_t = \alpha + \beta t + u_t$, com $u_t \sim RB(0, \sigma^2)$.

(1)	$y_{t-1} = \alpha + \beta(t-1) + u_{t-1}$	[modelo em $t-1$]
(2)	$\Delta y_t = \beta t - \beta(t-1) + u_t - u_{t-1}$	[subtrai]
(3)	$\Delta y_t = \beta + u_t - u_{t-1} = \beta + (1-L)\, u_t$	[simplifica]
(4)	$\gamma_0 = E\big((u_t - u_{t-1})^2\big) = 2\sigma^2$	[RB]
(5)	$\gamma_1 = E\big((u_t - u_{t-1})(u_{t-1} - u_{t-2})\big) = -\sigma^2$	[RB: só u_{t-1}^2]
(6)	$\rho_1 = -\frac{1}{2}, \qquad \theta(z) = 1 - z \Rightarrow z = 1$	[não invertível]

$$\boxed{\Delta(\text{TS}) = \beta + (1-L)u_t \ : \ \text{estacionário, mas com MA não invertível; o certo é regredir } y_t \text{ em } (1,t)}$$

Pela regressão, o resíduo estima u_t diretamente, sem criar estrutura falsa. É o mesmo argumento da Q2(d), demonstrado na folha à mão.

D3.3 · ARIMA(1,1,1): a equação de diferenças (Q10b)

Nos slides: $(1-\phi_1 L)(1-L)\,y_t = (1+\theta_1 L)\,\varepsilon_t$.

(1)	$(1-\phi_1 L)(1-L) = 1 - L - \phi_1 L + \phi_1 L^2$	[F8: termo a termo]
(2)	$= 1 - (1+\phi_1)L + \phi_1 L^2$	[agrupa]
(3)	$y_t - (1+\phi_1)y_{t-1} + \phi_1 y_{t-2} = \varepsilon_t + \theta_1 \varepsilon_{t-1}$	[aplica a y_t]
(4)	$y_t = (1+\phi_1)y_{t-1} - \phi_1 y_{t-2} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$	[isola y_t]
(5)	raízes do lado AR: $1-\phi_1 z = 0 \Rightarrow z = 1/\phi_1$; $\quad 1 - z = 0 \Rightarrow z = 1$	[uma raiz unitária]
(6)	na lista: $\theta_1 = -\theta \ \Rightarrow \ y_t = (1+\phi)y_{t-1} - \phi y_{t-2} + a_t - \theta a_{t-1}$	[tradução]

$$\boxed{y_t = (1+\phi_1)\,y_{t-1} - \phi_1\,y_{t-2} + \varepsilon_t + \theta_1 \varepsilon_{t-1}}$$

Olhando para (4), parece um "AR(2)". Mas a soma dos coeficientes, $(1+\phi_1) - \phi_1 = 1$, é a marca de uma raiz unitária: $\phi(1) = 0$.

D3.4 · SAR(1)$_4$: a FAC só vive nos múltiplos de 4 (Q11a)

$y_t = \Phi_1 y_{t-4} + \varepsilon_t$, com $|\Phi_1| < 1$. Multiplique por y_{t-k} e tire a esperança.

(1)	$\gamma_0 = \Phi_1^2 \gamma_0 + \sigma^2 \implies \gamma_0 = \dfrac{\sigma^2}{1-\Phi_1^2}$	[como no AR(1), cap. 2]
(2)	$\gamma_k = \Phi_1 \gamma_{k-4}, \quad k \geq 1$	[caus.]
(3)	$\gamma_4 = \Phi_1 \gamma_0, \qquad \gamma_8 = \Phi_1 \gamma_4 = \Phi_1^2 \gamma_0$	[(2)]
(4)	$k=2: \ \gamma_2 = \Phi_1 \gamma_{-2} = \Phi_1 \gamma_2 \implies (1-\Phi_1)\gamma_2 = 0 \implies \gamma_2 = 0$	[$\gamma_{-k} = \gamma_k$]
(5)	$k=1: \ \gamma_1 = \Phi_1 \gamma_3; \qquad k=3: \ \gamma_3 = \Phi_1 \gamma_1$	[(2)]
(6)	$\gamma_1 = \Phi_1^2 \gamma_1 \implies (1-\Phi_1^2)\gamma_1 = 0 \implies \gamma_1 = \gamma_3 = 0$	[(5)]

Por (2), os zeros de $k = 1, 2, 3$ se propagam para $5, 6, 7, 9, \ldots$

$$\boxed{\gamma_{4j} = \Phi_1^j \gamma_0, \qquad \gamma_k = 0 \text{ se } k \text{ não é múltiplo de } 4}$$

FAC: decai geometricamente só nos múltiplos de 4, igual a um AR(1) "esticado". **FACP:** um único pico, em 4, e zero no resto.

D3.5 · O multiplicativo é um AR(5) restrito (Q11c)

$(1-\phi L)(1-\Phi L^4)\,y_t = \varepsilon_t$.

(1)	$(1-\phi L)(1-\Phi L^4) = 1\cdot 1 + 1\cdot(-\Phi L^4) + (-\phi L)\cdot 1 + (-\phi L)(-\Phi L^4)$	[F8: quatro produtos]
(2)	$= 1 - \phi L - \Phi L^4 + \phi\Phi L^5$	[simplifica]
(3)	$y_t = \phi\, y_{t-1} + \Phi\, y_{t-4} - \phi\Phi\, y_{t-5} + \varepsilon_t$	[isola y_t]
(4)	AR(5) : $\phi_1 = \phi,\ \phi_2 = 0,\ \phi_3 = 0,\ \phi_4 = \Phi,\ \phi_5 = -\phi\Phi$	[compara]
(5)	restrições: $\phi_2 = \phi_3 = 0$ e $\phi_5 = -\phi_1\phi_4$	[3 restrições]
(6)	parâmetros livres: $5 - 3 = 2,\ (\phi, \Phi)$	[parcimônia]

$$\boxed{(1-\phi L)(1-\Phi L^4) = 1 - \phi L - \Phi L^4 + \phi\Phi L^5 \ : \quad \phi_2 = \phi_3 = 0,\ \ \phi_5 = -\phi_1\phi_4}$$

O termo $\phi\Phi L^5$ é o "dente a mais" das engrenagens. É ele que cria os satélites na FAC em volta da defasagem 4.

D3.6 · Beveridge-Nelson e o mapa dos testes de raiz unitária (MAT §1.6 e §2)

Beveridge-Nelson (MAT, p. 11 e apêndice A). Todo processo I(1) é a soma de uma tendência estocástica, um passeio, com um ciclo estacionário. A conta no ARIMA(0,1,1) dos slides, $\Delta y_t = \mu + \varepsilon_t + \theta_1\varepsilon_{t-1}$, com y_0 e $\varepsilon_0 = 0$:

(1)	$\Delta y_t = \mu + \psi(L)\,\varepsilon_t, \qquad \psi(L) = 1 + \theta_1 L$	[modelo]
(2)	$\psi(L) = \psi(1) + (1-L)\,\psi^*(L)$	[divide $\psi(L) - \psi(1)$ por $(1-L)$]
(3)	$1 + \theta_1 L = (1+\theta_1) + (1-L)(-\theta_1)$	[confere: $1 + \theta_1 - \theta_1 + \theta_1 L$]
(4)	$y_t = y_0 + \mu t + \psi(1)\sum_{s=1}^{t}\varepsilon_s + \psi^*(L)\varepsilon_t - \psi^*(L)\varepsilon_0$	[soma de 1 a t; $(1-L)$ telescopa]
(5)	$\underbrace{y_0 + \mu t + (1+\theta_1)\sum_{s=1}^{t}\varepsilon_s}_{\text{tendência (passeio)}} + \underbrace{(-\theta_1)\,\varepsilon_t}_{\text{ciclo}}$	[(3), (4), $\varepsilon_0 = 0$]
(6)	$\psi(1) = 1 + \theta_1$: a fração de um choque que fica para sempre	[persistência]
(7)	$\theta_1 \to -1 \ \Rightarrow\ \psi(1) \to 0$: nada é permanente, e y_t é TS	[sobrediferenciação, D3.1]

$$\boxed{y_t = \underbrace{y_0 + \mu t + \psi(1)\sum \varepsilon_s}_{\text{tendência estocástica}} + \underbrace{\psi^*(L)\varepsilon_t}_{\text{ciclo}}, \qquad \psi(1) = \text{persistência}}$$

Com $\theta_1 = -0{,}6$, $\psi(1) = 0{,}4$: 40% de cada choque é permanente, e o resto se desfaz no período seguinte. Numa série simulada de 5 000 períodos, a tendência mais o ciclo de (5) reconstroem y_t com diferença da ordem de 10^{-13}. A identidade (3) confere com diferença zero.

O mapa dos testes (MAT §2; AU04). Todos partem da mesma regressão; o que muda é como tratam o erro e os termos determinísticos.

(8)	$y_t = \rho\, y_{t-1} + u_t \;\Rightarrow\; \Delta y_t = \gamma\, y_{t-1} + u_t,\;\; \gamma = \rho - 1;\;\; H_0 : \gamma = 0$	[MAT §2.1, p. 17]
(9)	DF: $\tau = \hat{\gamma} / ep(\hat{\gamma})$, críticos não padrão, três especificações	[MAT §2.2, p. 19–23]
(10)	ADF: acrescenta $\sum_{i=1}^{k} \delta_i \Delta y_{t-i}$ para branquear u_t	[MAT p. 24–28]
(11)	PP: corrige τ pela variância de longo prazo, sem defasagens	[MAT §2.3, p. 29]
(12)	DF-GLS: tira os determinísticos por MQG antes; mais poder	[MAT §2.4, p. 32]
(13)	ERS ponto ótimo: o teste mais poderoso contra uma alternativa fixada	[MAT §2.5, p. 35]
(14)	KPSS: nula invertida (estacionariedade), para cruzar com o ADF	[AU04]
(15)	raiz unitária sazonal: HEGY, OCSB, Canova-Hansen	[MAT §2.6; AU05]

Em (15), o MAT, p. 38, estende o ADF para a frequência sazonal. A ligação com a lista: na Q10, decidir entre TS e DS é exatamente o que esses testes fazem. Com ϕ perto de 1, nenhum deles tem muito poder (D03.3 no aprofundamento deste bloco). Por isso a regra prática é cruzar um teste de nula "raiz unitária" com um de nula "estacionário".

Exemplo

1. Quanto custa diferenciar um AR(1) estacionário. Valores do R para $w_t = \Delta y_t$, com $\sigma^2 = 1$, a partir de (9)–(11) da D3.1:

ϕ	Var(y_t)	Var(w_t)	$\rho_w(1)$	leitura
0,2	1,0417	1,6667	−0,40	a variância **aumenta** 60%: sobredose clara
0,5	1,3333	1,3333	−0,25	empata
0,9	5,2632	1,0526	−0,05	parece "melhorar", mas o MA tem raiz unitária

- O caso $\phi = 0$ (ruído branco diferenciado) dá $\rho_w(1) = -0{,}5$, conferido com o `ARMAacf`.
- Com $\phi = 0{,}5$, o `ARMAacf(ar = 0.5, ma = -1)` confirma −0,25.

A regra de Duke ("a ordem certa de diferenciação costuma ser a de menor desvio padrão") acerta com $\phi = 0{,}2$ e engana com $\phi = 0{,}9$. Por isso o critério final é a raiz do MA, não a variância.

2. SAR(1)$_4$ com $\Phi_1 = 0{,}6$.

- $\gamma_0 = 1/(1 - 0{,}36) = 1{,}5625$;
- $\gamma_4 = 0{,}9375$;
- $\gamma_8 = 0{,}5625$.

No R, $\rho_1 = 0$, $\rho_4 = 0{,}6$ e $\rho_8 = 0{,}36$: a FAC só vive nos múltiplos de 4.

3. Multiplicativo com $\phi = 0{,}5$ e $\Phi = 0{,}6$. Vira o AR(5) $y_t = 0{,}5y_{t-1} + 0{,}6y_{t-4} - 0{,}3y_{t-5} + \varepsilon_t$.

4. Observações perdidas com $d = D = 1$:

- trimestral (Q12): $1 + 4 = 5$;
- mensal (Q16): $1 + 12 = 13$.

Cadeia socrática

P1. Se Δy_t é estacionário, y_t é necessariamente um passeio aleatório?

Resposta

Não. y_t é I(1), mas Δy_t pode ser qualquer ARMA estacionário e invertível. O passeio é o caso particular em que Δy_t é ruído branco. Um ARIMA(1,1,1) também tem Δy_t estacionário (D3.3).

P2. A série tem tendência linear clara. Diferenciar resolve?

Resposta

Torna estacionário nos dois casos, TS ou DS. Mas, se a tendência é determinística, diferenciar cria um MA com raiz unitária (D3.2). O remédio certo para TS é a regressão em *t*. "Torna estacionário" não basta: precisa ser estacionário **e invertível**.

P3. Como reconhecer a sobrediferenciação pela FAC?

Resposta

$\hat{\rho}_1$ negativo e forte, perto de $-0{,}5$, e a FAC cortando depois disso, que é a cara de um MA(1) com $\theta_1 \approx -1$. Na estimação, $\hat{\theta}_1$ encosta em -1. Pela regra de Duke, uma raiz unitária no MA pede **uma diferença a menos**.

P4. E a subdiferenciação?

Resposta

FAC com correlações positivas que decaem muito devagar, quase em linha reta (cap. 1, D1.1: Corr $= \sqrt{(t-k)/t}$). No AR estimado, a soma dos coeficientes fica perto de 1, como em D3.3, em que $(1+\phi_1) - \phi_1 = 1$.

P5. Por que, num SAR(1)$_4$, $\gamma_1 = 0$, se o processo tem memória?

Resposta

Porque a memória é de **calendário**: y_t depende de y_{t-4}, que depende de y_{t-8}... A cadeia nunca passa por y_{t-1}. Formalmente, $\gamma_1 = \Phi_1^2 \gamma_1$ força $\gamma_1 = 0$ (D3.4).

P6. No SARIMA(1,0,0)(1,0,0)$_4$, de onde vem o coeficiente de y_{t-5}?

Resposta

Do produto dos dois polinômios: $(-\phi L)(-\Phi L^4) = \phi\Phi L^5$. Ninguém o escolheu: ele é **imposto**, $\phi_5 = -\phi_1\phi_4$. É isso que faz o multiplicativo ser parcimonioso, com 2 parâmetros no lugar de 5.

P7. Quantas observações a Q12 perde, e por quê?

Resposta

Cinco. $(1-L)(1-L^4)y_t = y_t - y_{t-1} - y_{t-4} + y_{t-5}$ precisa de y_{t-5}. O primeiro w calculável é w_6. Em geral, perdem-se $d + sD$.

P8. "Raiz unitária" e "não estacionário" são sinônimos?

Resposta

Não. Toda raiz unitária no AR gera não estacionariedade, mas uma série TS também é não estacionária, porque a média depende de *t*, e não tem raiz unitária. E uma raiz unitária no **MA** não torna o processo não estacionário: torna-o não invertível (D3.1).

Diálogo

Sobre "diferenciar por segurança".

Aluno: Na dúvida, eu diferencio. Se a série já era estacionária, diferenciar não estraga nada: continua estacionária.

Professor: Continua estacionária, sim. E invertível?

Aluno: ... Pela D3.1, aparece $(1 - L)$ no MA, com raiz em $z = 1$. Então não é invertível.

Professor: E o que você perde sem a invertibilidade?

Aluno: A forma AR(∞). Sem ela, não dá para recuperar os ε_t a partir dos dados... e a previsão precisa deles.

Professor: Algo mais? Olhe a variância na tabela do exemplo.

Aluno: Com $\phi = 0{,}2$, a variância de Δy é 1,67, contra 1,04 do nível. Eu acrescentei ruído.

Professor: Então "por segurança" tem um preço. Qual seria a regra?

Aluno: Diferenciar só com evidência de raiz unitária: FAC lenta e um teste. Depois de diferenciar, olhar $\hat{\rho}_1$: se estiver perto de $-0{,}5$, ou se o $\hat{\theta}_1$ encostar em -1, voltar uma diferença.

Professor: E se a tendência for determinística?

Aluno: Aí não diferencio: regrido em *t*. Diferenciar uma TS também cria o $(1 - L)$ no MA (D3.2).

Na prova

A folha de caderno do bloco está em a_mao_cap3.md: Q9 a Q12 em 67 linhas numeradas, cada uma com a justificativa, mais a versão para a prova e a conferência em R.

Questão	O que este capítulo dá	Resolução completa
Q9	sobrediferenciação do AR(1): $(1 - \phi B)w_t = (1 - B)\varepsilon_t$, raiz $z = 1$, sem AR(∞)	Q9
Q10	ARIMA ⟶ ARMA na diferença; ARIMA(1,1,1) expandido; TS × DS; regressão × diferença	Q10
Q11	SAR(1)$_4$: γ_{4j}, zeros fora dos múltiplos; multiplicativo como AR(5) restrito	Q11
Q12	SARIMA(1,1,0)(0,1,1)$_4$: modelo, 5 perdas, previsão, diagnóstico	Q12

Armadilhas:

- dizer que a sobrediferenciação "torna a série não estacionária": ela torna **não invertível**;
- na Q11(a), esquecer de **provar** que $\gamma_1 = \gamma_2 = \gamma_3 = 0$ (D3.4, linhas 4–6);
- contar 5 parâmetros livres no AR(5) restrito: são 2;
- na Q10(b), errar o sinal de $\phi_1 L^2$ na expansão;
- confundir "tem tendência" com "tem raiz unitária".

Checklist de 30 segundos:

1. Disse **qual** tendência (determinística ou estocástica) e o remédio correspondente?
2. Mostrei a raiz do MA ($z = 1$) quando falei de sobrediferenciação?
3. Expandi os polinômios termo a termo (F8)?
4. Contei as observações perdidas com $d + sD$?
5. Traduzi o sinal do MA sazonal para a lista ($\Theta^{\text{lista}} = -\Theta_1$)?

No material do professor

Roteiro de releitura:

- AU01, p. 28–30: passeio, drift e tendência;
- MAT, p. 1–9: tendência determinística, estocástica, processo integrado e raiz unitária;
- MAT, p. 11–16: Beveridge-Nelson, diferença estacionária, memória e os quatro processos;
- AU02, p. 30–36: invertibilidade, a razão pela qual $(1 - L)$ no MA é um problema;
- MAT, p. 38: ADF com sazonalidade;
- AU05: ARIMA e SARIMA, com a notação $(p, d, q)(P, D, Q)_s$.

Livros:

- **BJRL**, cap. 4 (ARIMA) e cap. 9 (sazonais multiplicativos);
- **ENDERS**, cap. 4: tendências e raiz unitária;
- **HAMILTON**, cap. 15: processos com tendência, TS × DS.

Na lista comentada: Q9 · Q10 · Q11 · Q12 · ferramentas F2 e F8.

Parte V

Bloco 4 — Estimação e seleção

CAPÍTULO 5

Capítulo 4 · Estimação e seleção: o detetive e os dois juízes

← apostila · anterior: cap. 3 · próximo: cap. 5 · questões da lista: Q13 e Q14

Pergunta de abertura

Você ajustou três modelos à mesma série de 150 observações, e um deles tem a maior log-verossimilhança. **Ele é o melhor?** Agora acrescente parâmetros: um AR(20) sempre terá verossimilhança maior ou igual à de um AR(1), porque contém o AR(1) como caso particular. **Então "maior verossimilhança" não pode ser o critério sozinho. O que falta?**

E, antes disso, uma pergunta sobre como se chega aos números: **por que o MQO de y_t contra y_{t-1} dá exatamente o estimador de máxima verossimilhança do AR(1)?** E por que, para um MA(1), não existe fórmula fechada (AU02, p. 60 e 80)?

A imagem

A máxima verossimilhança é um detetive. A cena do crime são os dados, e os suspeitos são os valores possíveis dos parâmetros. O detetive pergunta, para cada suspeito: "se tivesse sido você, quão provável seria esta cena?". E escolhe aquele sob o qual a cena é **menos surpreendente**. É isso que maximizar $L(\Theta) = f(y_1, \dots, y_T; \Theta)$ quer dizer.

Condicional × exata é por onde começar a contar a história.

- A versão **condicional** começa no segundo capítulo: trata y_1 como dado e explica só como cada observação nasceu da anterior.
- A versão **exata** também explica o primeiro capítulo, perguntando quão provável era y_1 sob o processo estacionário (AU02, p. 78–80).

Com muitos capítulos, o primeiro pesa pouco, e as duas concordam.

Yule-Walker é copiar as correlações. Em vez de perguntar qual parâmetro torna os dados mais prováveis, ele pergunta: qual parâmetro faz o modelo **reproduzir as correlações que eu medi**? No AR(1), isso é $\hat{\phi} = \hat{\rho}_1$, um método de momentos.

AIC e BIC são dois juízes de um concurso que cobram multa por parâmetro. Os dois dão nota pelo ajuste, $-2 \ln L$, e descontam uma multa por parâmetro:

- **o AIC cobra multa fixa, 2 por parâmetro**. Ele quer o modelo que vai **prever melhor** a próxima observação;
- **o BIC cobra** $\ln T$ **por parâmetro**, uma multa que cresce com o tamanho da amostra. Ele quer **acertar qual é o modelo verdadeiro**.

Com $T = 150$, a multa do BIC já é $\ln 150 = 5{,}01$, duas vezes e meia a do AIC.

> **Onde a analogia quebra**
>
> - **O detetive não dá a probabilidade de o suspeito ser culpado.** $L(\Theta)$ é a probabilidade dos **dados** dado o parâmetro, não a do parâmetro dado os dados. Dizer "o modelo A tem 70% de chance de ser o certo" não sai da verossimilhança.

- **O juiz BIC só é infalível se o culpado está na fila.** A consistência do BIC supõe que o modelo verdadeiro está entre os candidatos. Se nenhum está, o que importa é prever bem, e aí o AIC é o que tem a propriedade ótima, a eficiência.
- **A multa não é uma regra de rejeição com nível fixo.** Entre dois modelos aninhados que diferem por um parâmetro, o AIC equivale a um teste da razão de verossimilhança com valor crítico 2. Isso dá um "nível" de 15,7%, que **não cai** com T. É por isso que o AIC superajusta para sempre (D4.4).

Teoria

Verossimilhança e fatoração (AU02, p. 77). A densidade conjunta se fatora em condicionais sucessivas:

$$f(y_T, \dots, y_1; \Phi) = f(y_1; \Phi) \prod_{t=2}^{T} f(y_t \mid y_{t-1}, \dots, y_1; \Phi), \qquad \widehat{\Phi} = \arg\max_{\Phi} \ln L(\Phi).$$

AR(1), exata e condicional (AU02, p. 78–80).

- Na **exata**, $y_1 \sim N\big(\frac{\phi_0}{1-\phi_1}, \frac{\sigma^2}{1-\phi_1^2}\big)$, a distribuição incondicional, entra na conta.
- Na **condicional**, y_1 é tratado como fixo.
- As duas são consistentes e assintoticamente equivalentes. A exata é melhor em amostras pequenas e perto da fronteira $|\phi_1| \to 1$.
- No AR, a condicional normal **coincide com o MQO** (D4.1).

MA(1) e ARMA (AU02, p. 58–60 e 88–89). A condicional fixa $\varepsilon_0 = 0$ e reconstrói os choques pela recursão $\varepsilon_t = y_t - \theta_0 - \theta_1 \varepsilon_{t-1}$. A log-verossimilhança é

$$\ln L(\Theta) = -\frac{T}{2}\ln(2\pi) - \frac{T}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}\sum_{t=1}^{T}\varepsilon_t^2.$$

Como cada ε_t depende de θ_1 de forma **não linear**, através de toda a recursão, **não há solução analítica**, e a maximização é numérica. A exata usa o filtro de Kalman (AU02, p. 60).

Yule-Walker (AU02, p. 68–71). O estimador troca as ρ_k teóricas pelas amostrais e resolve $\widehat{R}\widehat{\Phi} = \hat{r}$. No AR(1), $\hat{\phi}_{YW} = \hat{\rho}_1$.

Critérios de informação (AU02, p. 98–99). Com k parâmetros, **incluindo a variância** (como pede a Q14), e T fixo:

$$AIC = \frac{-2\ln L(\widehat{\Theta}) + 2k}{T}, \qquad BIC = \frac{-2\ln L(\widehat{\Theta}) + k\ln T}{T}, \qquad \text{escolhe-se o menor.}$$

- O R reporta as versões **sem** a divisão por T. Com o mesmo T, a ordenação é a mesma.
- **Nunca** compare modelos estimados com T diferentes (AU02, p. 99).

Consistência × eficiência.

- **BIC: consistente.** Se o modelo verdadeiro está entre os candidatos, P(BIC escolhe o verdadeiro) $\to 1$, porque a multa $\ln T \to \infty$ elimina os modelos grandes demais.
- **AIC: eficiente.** Não é consistente, porque superajusta com probabilidade que não vai a zero. Mas minimiza o erro de previsão quando o verdadeiro é complexo demais para estar na lista.

Demonstrações

D4.1 · AR(1): log-verossimilhança condicional e o MQO (Q13)

$y_t = \phi y_{t-1} + \varepsilon_t$, com $\varepsilon_t \sim N(0, \sigma^2)$, condicionando em y_1.

(1) $y_t \mid y_{t-1} \sim N(\phi y_{t-1}, \sigma^2)$ [ε_t normal]

(2) $f(y_t \mid y_{t-1}) = \dfrac{1}{\sqrt{2\pi\sigma^2}} \exp\Big(- \dfrac{(y_t - \phi y_{t-1})^2}{2\sigma^2} \Big)$ [densidade normal]

(3) $\ln L(\phi, \sigma^2 \mid y_1) = \displaystyle\sum_{t=2}^{T} \ln f(y_t \mid y_{t-1})$ [fatoração, AU02 p. 80]

(4) $= -\dfrac{T-1}{2}\ln(2\pi) - \dfrac{T-1}{2}\ln\sigma^2 - \dfrac{1}{2\sigma^2}\displaystyle\sum_{t=2}^{T}(y_t - \phi y_{t-1})^2$ [(2) em (3)]

(5) $\dfrac{\partial \ln L}{\partial \phi} = \dfrac{1}{\sigma^2}\displaystyle\sum_{t=2}^{T}(y_t - \phi y_{t-1})\, y_{t-1} = 0$ [CPO em ϕ]

(6) $\displaystyle\sum_{t=2}^{T} y_t y_{t-1} = \hat{\phi}\sum_{t=2}^{T} y_{t-1}^2$ [distributiva]

(7) $\hat{\phi} = \dfrac{\sum_{t=2}^{T} y_t y_{t-1}}{\sum_{t=2}^{T} y_{t-1}^2}$ [isola]

(8) $\dfrac{\partial \ln L}{\partial \sigma^2} = -\dfrac{T-1}{2\sigma^2} + \dfrac{1}{2\sigma^4}\displaystyle\sum_{t=2}^{T}\hat{\varepsilon}_t^2 = 0$ [CPO em σ^2]

(9) $\hat{\sigma}^2 = \dfrac{1}{T-1}\displaystyle\sum_{t=2}^{T}\hat{\varepsilon}_t^2$ [multiplica por $2\sigma^4$]

$$\boxed{\hat{\phi}_{MV\,cond} = \frac{\sum_{t=2}^{T} y_t y_{t-1}}{\sum_{t=2}^{T} y_{t-1}^2} = \hat{\phi}_{MQO}}$$

Em (5), só o último termo de (4) depende de ϕ. Por que coincidem: em (4), para qualquer σ^2 fixo, maximizar $\ln L$ em ϕ é **minimizar** $\sum(y_t - \phi y_{t-1})^2$, que é exatamente o problema do MQO.

D4.2 · A verossimilhança exata acrescenta o primeiro capítulo

Com média zero, $y_1 \sim N\big(0, \sigma^2/(1-\phi^2)\big)$ (AU02, p. 78–79).

(1) $\ln f(y_1) = -\dfrac{1}{2}\ln(2\pi) - \dfrac{1}{2}\ln\dfrac{\sigma^2}{1-\phi^2} - \dfrac{(1-\phi^2)\,y_1^2}{2\sigma^2}$ [densidade de y_1]

(2) $\ln L_{exata} = \ln f(y_1) + \ln L_{cond}$ [fatoração completa]

(3) $\dfrac{\partial \ln f(y_1)}{\partial \phi} = -\dfrac{\phi}{1-\phi^2} + \dfrac{\phi\, y_1^2}{\sigma^2}$ [derivada; $\partial\ln(1-\phi^2)/\partial\phi = -2\phi/(1-\phi^2)$]

(4) CPO: $\dfrac{1}{\sigma^2}\displaystyle\sum_{t=2}^{T}(y_t - \phi y_{t-1})y_{t-1} - \dfrac{\phi}{1-\phi^2} + \dfrac{\phi\, y_1^2}{\sigma^2} = 0$ [(2), (3), D4.1(5)]

(5) o termo $\dfrac{\phi}{1-\phi^2}$ torna (4) não linear em ϕ [sem fórmula fechada]

(6) (1) é um termo só, contra $T-1$ termos em $\ln L_{cond}$ [peso $O(1/T)$]

$$\boxed{\ln L_{exata} = \ln f(y_1) + \ln L_{cond} \ : \ \text{solução numérica, assintoticamente igual à condicional}}$$

Em (1), $-\frac{1}{2}\ln\frac{\sigma^2}{1-\phi^2} = -\frac{1}{2}\ln\sigma^2 + \frac{1}{2}\ln(1-\phi^2)$, e o último termo vai a $-\infty$ quando $|\phi| \to 1$. A verossimilhança exata **pune** estimativas na fronteira, e o termo $-\frac{\phi}{1-\phi^2}$ em (4) empurra $\hat{\phi}$ para dentro da região estacionária. É por isso que a exata se comporta melhor perto da fronteira (AU02, p. 80).

D4.3 · Yule-Walker no AR(1) e a diferença para o MQO

(1)	$\rho_1 = \phi$	[cap. 2, D2.4]
(2)	$\hat{\rho}_1 = \dfrac{\hat{\gamma}_1}{\hat{\gamma}_0} = \dfrac{\frac{1}{T}\sum_{t=2}^{T} y_t y_{t-1}}{\frac{1}{T}\sum_{t=1}^{T} y_t^2}$	[AU02, p. 71, média zero]
(3)	$\hat{\phi}_{YW} = \hat{\rho}_1 = \dfrac{\sum_{t=2}^{T} y_t y_{t-1}}{\sum_{t=1}^{T} y_t^2}$	[troca teórico por amostral]
(4)	MQO: denominador $\displaystyle\sum_{t=2}^{T} y_{t-1}^2 = \sum_{t=1}^{T-1} y_t^2$	[D4.1(7)]
(5)	YW: denominador $\displaystyle\sum_{t=1}^{T} y_t^2 = \sum_{t=1}^{T-1} y_t^2 + y_T^2$	[um termo a mais]
(6)	$\lvert\hat{\phi}_{YW}\rvert \le \lvert\hat{\phi}_{MQO}\rvert$	[denominador maior]

$$\boxed{\hat{\phi}_{YW} = \hat{\rho}_1 \ : \ \text{mesmo numerador do MQO, denominador com } y_T^2 \text{ a mais; diferença } O(1/T)}$$

D4.4 · Por que o BIC é consistente e o AIC não

Compare o modelo pequeno, verdadeiro e com k parâmetros, com um grande, que tem $k+1$ e contém o pequeno. Seja $LR = 2(\ln L_{grande} - \ln L_{pequeno}) \ge 0$.

(1)	$AIC_{grande} < AIC_{pequeno} \iff -2\ln L_g + 2(k+1) < -2\ln L_p + 2k$	[definição, sem $\div T$]
(2)	$\iff LR > 2$	[rearranja]
(3)	$BIC_{grande} < BIC_{pequeno} \iff LR > \ln T$	[mesma conta, multa $\ln T$]
(4)	sob o modelo pequeno verdadeiro: $LR \xrightarrow{d} \chi^2(1)$	[teste LR, 1 restrição]
(5)	$P(\text{AIC superajusta}) \to P\big(\chi^2(1) > 2\big) = 0{,}157 > 0$	[(2), (4)]
(6)	$P(\text{BIC superajusta}) = P(LR > \ln T) \to 0$	[$\ln T \to \infty$, $LR = O_p(1)$]

$$\boxed{\text{AIC} \equiv \text{teste LR com crítico fixo 2 (nível} \approx 15{,}7\%); \qquad \text{BIC} \equiv \text{crítico } \ln T \to \infty \ : \ \text{consistente}}$$

Escolher um modelo pequeno demais, ao contrário, é punido pelos **dois**: o LR cresce como T quando o parâmetro omitido é diferente de zero, e vence qualquer multa.

Exemplo

1. Os três estimadores do AR(1), numa série simulada com $\phi = 0{,}6$ e $T = 200$:

Estimador	Fórmula	$\hat{\phi}$
MQO (= MV condicional)	D4.1(7)	0,6537 (o `lm` dá o mesmo)
Yule-Walker	D4.3(3)	0,6487 (o `ar.yw` dá o mesmo)
MV exata	numérica	0,6620

Os três diferem só na terceira casa: são assintoticamente equivalentes. O YW fica abaixo do MQO, como previsto em D4.3(6). A variância estimada pelo MQO é $\hat{\sigma}^2 = 1{,}0491$.

2. A Q14, com $T = 150$, $k = 3$ nos três modelos e $\ln 150 = 5{,}0106$:

Modelo	$\ln L$	AIC (slides)	BIC (slides)	AIC (R)	BIC (R)
ARMA(1,1)	−210,3	**2,8440**	**2,9042**	426,6	435,63
ARMA(2,0)	−212,8	2,8773	2,9375	431,6	440,63
ARMA(0,2)	−214,1	2,8947	2,9549	434,2	443,23

Os dois escolhem o ARMA(1,1). Com o **mesmo** k, a multa é igual para os três, e decide só a verossimilhança. A diferença entre AIC e BIC só pesaria se os modelos tivessem números diferentes de parâmetros.

3. Os dois juízes em ação, em mil simulações de um AR(1) verdadeiro com $\phi = 0{,}5$, comparado com um AR(2):

T	AIC escolhe o AR(2)	BIC escolhe o AR(2)
150	15,7%	3,2%
2000	12,4%	0,6%

A teoria da D4.4 prevê, para o AIC, $P(\chi^2(1) > 2) = 0{,}1573$ **em qualquer** T, e a simulação confirma: o AIC não melhora com mais dados. O BIC vai a zero.

Cadeia socrática

P1. Na D4.1, por que a CPO em ϕ não depende de σ^2?

> **Resposta**
>
> Porque σ^2 só multiplica a soma de quadrados, e a CPO iguala essa derivada a zero: o fator $1/\sigma^2$ sai. É por isso que $\hat{\phi}$ sai antes, pelo MQO, e $\hat{\sigma}^2$ vem depois, dos resíduos.

P2. No MA(1), por que a mesma conta não tem fórmula fechada?

> **Resposta**
>
> Porque $\varepsilon_t = y_t - \theta_0 - \theta_1 \varepsilon_{t-1}$ depende de θ_1 através de **toda** a recursão: ε_t é um polinômio de grau $t-1$ em θ_1. A soma de quadrados não é quadrática em θ_1, e a CPO não se resolve à mão (AU02, p. 60).

P3. Por que o MA precisa ser invertível para a verossimilhança condicional funcionar bem?

Resposta

Porque a recursão parte de um chute, $\varepsilon_0 = 0$. O erro desse chute se propaga com peso $(-\theta_1)^t$: some se $|\theta_1| < 1$ e explode se não. Além disso, sem a restrição, θ e $1/\theta$ dão verossimilhanças iguais, e o máximo não é único (cap. 2, D2.3).

P4. Se a exata e a condicional são assintoticamente equivalentes, quando a diferença importa?

Resposta

Em amostras pequenas e com $|\phi|$ perto de 1. Aí y_1 carrega muita informação, porque a variância incondicional $\sigma^2/(1-\phi^2)$ é enorme, e a exata a aproveita (D4.2).

P5. Na Q14, AIC e BIC concordaram. Isso sempre acontece?

Resposta

Não. Concordaram porque os três modelos têm o mesmo $k = 3$, e as multas se cancelam. Com k diferentes, o BIC, de multa $\ln 150 \approx 5$, tende a escolher o menor modelo, e o AIC, de multa 2, o maior.

P6. Se o AIC superajusta para sempre, por que alguém o usaria?

Resposta

Porque superajustar com **um parâmetro a mais, de valor perto de zero** custa pouco na previsão, e subajustar custa muito. Quando o processo verdadeiro é um ARMA de ordem infinita, ou não está na lista, não há "modelo verdadeiro" a acertar, e o AIC é o que minimiza o erro de previsão: a eficiência.

P7. Posso comparar o AIC de um ARMA(1,1) em y_t com o de um ARMA(1,1) em Δy_t?

Resposta

Não. As séries são diferentes, e o T efetivo também, porque se perde uma observação. A verossimilhança de uma série não é comparável com a de outra. A regra da AU02, p. 99, é: mesmo T, mesma variável dependente.

P8. O k da Q14 inclui σ^2. E se eu esquecer de incluí-lo?

Resposta

Todos os modelos perdem 1 em k, e a **ordenação não muda**: a multa cai igual para todos. Mas o valor numérico do AIC e do BIC muda, e numa prova de conta isso é erro. Siga o enunciado: $k = p + q + 1$ com média zero e $p + q + 2$ com média (AU02, p. 99).

Diálogo

Sobre "o BIC é melhor porque é consistente".

Aluno: O BIC é consistente, e o AIC não. Então o BIC é sempre melhor.

Professor: Consistente para quê, exatamente?

Aluno: Para escolher o modelo verdadeiro quando T cresce.

Professor: E qual é a hipótese escondida nessa frase?

Aluno: ... Que o modelo verdadeiro está entre os candidatos.

Professor: A inflação brasileira é exatamente um ARMA(1,1)?

Aluno: Provavelmente não. É algo mais complicado, e o ARMA é uma aproximação.

Professor: Então o que significa "acertar o modelo verdadeiro" nesse caso?

Aluno: Nada: não tem verdadeiro na lista. Aí a pergunta útil é qual aproxima melhor para prever.

Professor: E qual critério tem a propriedade ótima para isso?

Aluno: O AIC, a eficiência. Então a regra não é "um é melhor". É: se o objetivo é **identificar** a estrutura, uso o BIC; se é **prever**, o AIC. E, se os dois concordam, como na Q14, a escolha é robusta.

Professor: E na prova, se o enunciado só pede "qual cada um seleciona"?

Aluno: Calculo os dois com o mesmo T, digo o vencedor de cada um e, na discussão, explico as multas, 2 contra $\ln T$, e as propriedades assintóticas.

Na prova

A folha de caderno do bloco está em a_mao_cap4.md: Q13 e Q14 em 43 linhas numeradas, cada uma com a justificativa, mais a versão para a prova e a conferência em R.

Questão	O que este capítulo dá	Resolução completa
Q13	log-verossimilhança condicional do AR(1) e o MQO de ϕ	Q13
Q14	AIC e BIC de três modelos com $T = 150$; consistência × eficiência	Q14

Armadilhas:

- na Q13, somar de $t = 1$, quando a condicional começa em $t = 2$ e tem $T - 1$ termos;
- esquecer de derivar $\hat{\sigma}^2$ ou dividir por T em vez de $T - 1$, quando se condiciona em y_1;
- na Q14, usar $k = 2$ em vez de 3, ignorando a variância, ou trocar o sinal de $\ln L$: o menor critério vence;
- dizer que "o BIC sempre escolhe o modelo menor": ele **tende** a escolher, e só quando os k diferem.

Checklist de 30 segundos:

1. A condicional começa em $t = 2$?
2. Escrevi as duas CPOs, para ϕ e para σ^2?
3. Calculei AIC e BIC com o mesmo T e o mesmo k do enunciado?
4. Disse "menor vence" e qual foi o escolhido por **cada** critério?
5. Expliquei $2 \times \ln T$ e consistência × eficiência, com a hipótese de o verdadeiro estar na lista?

No material do professor

Roteiro de releitura:

- AU02, p. 58–60: verossimilhança condicional do MA(1) e o método exato;
- AU02, p. 68–71: Yule-Walker e a FAC amostral;
- AU02, p. 77–80: MV exata e condicional do AR(1);
- AU02, p. 88–89: verossimilhança condicional do ARMA(1,1);
- AU02, p. 96–99: identificação e critérios de informação.

Livros:

- **HAMILTON**, cap. 5: a verossimilhança exata e condicional do AR e do MA, com todas as contas;

- **ENDERS**, cap. 2: critérios de informação no nível do curso;
- **BJRL**, cap. 7: estimação e a convenção de sinal da lista.

Na lista comentada: Q13 · Q14.

Parte VI

Bloco 5 — Previsão

Capítulo 5 · Previsão: o elástico e o leque

← apostila · anterior: cap. 4 · próximo: cap. 6 · questão da lista: Q15

Pergunta de abertura

A previsão do tempo para amanhã usa a frente fria que está chegando. A previsão para daqui a 40 dias é praticamente a **média histórica** daquele dia do ano. **Por que a informação de hoje "se gasta" com o horizonte?** E outra pergunta, mais de fundo: entre todas as regras possíveis para prever, por que a escolhida é **a média condicional**, e não, por exemplo, o valor mais provável ou a mediana?

A AU02 trata a previsão em três lugares: MA (p. 54–57), AR (p. 72–76) e ARMA(1,1) (p. 85). As três seguem o mesmo roteiro:

1. escrever o modelo na data futura;
2. tirar a esperança condicional ao que se sabe hoje, Ω_T;
3. medir o erro.

Este capítulo mostra **por que** o roteiro é esse e o que ele implica.

A imagem

A previsão de um AR estacionário é um elástico preso na média. Hoje a série está longe da média μ. A previsão para amanhã puxa uma fração $1 - \phi_1$ do caminho de volta; a de depois de amanhã puxa de novo; e assim por diante. O elástico nunca passa do ponto, se $\phi_1 > 0$, e a previsão converge para μ geometricamente: $\hat{y}_{T+h/T} - \mu = \phi_1^h(y_T - \mu)$.

A incerteza é um leque que abre e para de abrir.

- No horizonte 1, a única coisa que você não sabe é o choque de amanhã: a variância do erro é σ^2.
- A cada passo, entra um choque novo, multiplicado pelo peso ψ_j correspondente. O leque abre.
- Num processo estacionário, os ψ_j encolhem, e o leque **para de abrir** em γ_0, a variância incondicional: o horizonte infinito é a "climatologia".
- Num processo I(1), os pesos não encolhem, e o leque abre **para sempre**.

O MA(q) é uma memória de q dias. Depois de q passos, nenhum choque que você conhece afeta mais o futuro, e a melhor previsão é a média (AU02, p. 55).

O ARIMA(0,1,1) é um termômetro com inércia. A previsão é uma média das observações passadas com pesos que decaem geometricamente, $\alpha,\ \alpha(1-\alpha),\ \alpha(1-\alpha)^2, \ldots$: o "esquecimento exponencial". É a suavização exponencial simples, vista como um modelo.

> **Onde a analogia quebra**
>
> - **O elástico puxa a previsão, não a série.** A trajetória realizada não volta suavemente para μ: ela continua levando choques e oscilando. Quem desliza suavemente para a média é a **esperança condicional**.
> - **Com $\phi_1 < 0$, o elástico passa do ponto a cada período.** A previsão oscila em torno de μ enquanto converge.

- **O leque das fórmulas é estreito demais.** $\sigma^2 \sum \psi_j^2$ supõe que os parâmetros são conhecidos. Com parâmetros estimados, há uma incerteza extra, e os intervalos reais são mais largos. A normalidade dos erros também é uma hipótese, que a AU03 manda testar.

Teoria

Elementos da previsão (AU02, p. 54 e 72; AU03, p. 39–40): a origem T, a informação $\Omega_T = \{y_T, y_{T-1}, \dots\}$, o horizonte h, e

$$\hat{y}_{T+h/T} = E(y_{T+h} \mid \Omega_T), \qquad e_{T+h/T} = y_{T+h} - \hat{y}_{T+h/T}.$$

As três regras da esperança condicional (AU02, p. 54–55 e 72–73):

- o que já foi observado sai como está: $E(y_{T-j} \mid \Omega_T) = y_{T-j}$ e $E(\varepsilon_{T-j} \mid \Omega_T) = \varepsilon_{T-j}$ para $j \geq 0$;
- choque futuro vira zero: $E(\varepsilon_{T+j} \mid \Omega_T) = 0$ para $j \geq 1$;
- valor futuro vira a previsão dele: $E(y_{T+j} \mid \Omega_T) = \hat{y}_{T+j/T}$.

MA(q) (AU02, p. 54–57): $\hat{y}_{T+h/T} = \mu$ para $h > q$. No MA(1), o EQM é σ^2 em $h = 1$ e $(1 + \theta_1^2)\sigma^2$ em $h \geq 2$.

AR(1) (AU02, p. 72–76):

- $\hat{y}_{T+h/T} = \mu + \phi_1^h (y_T - \mu)$: a previsão volta à média geometricamente, à taxa ϕ_1 por passo;
- $e_{T+h/T} = \sum_{j=0}^{h-1} \phi_1^j \varepsilon_{T+h-j}$;
- $\mathrm{Var}(e_{T+h/T}) = \sigma^2 \frac{1-\phi_1^{2h}}{1-\phi_1^2} \to \frac{\sigma^2}{1-\phi_1^2} = \gamma_0$.

Caso geral pelos pesos ψ (lista, Q15c). Com $y_t = \mu + \sum_{j \geq 0} \psi_j \varepsilon_{t-j}$:

$$e_{T+h/T} = \sum_{j=0}^{h-1} \psi_j \, \varepsilon_{T+h-j} \quad \text{(um MA}(h-1)\text{)}, \qquad \mathrm{Var}(e_{T+h/T}) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2.$$

Intervalo de previsão (AU02, p. 56 e 74), com erros gaussianos: $\hat{y}_{T+h/T} \pm z_{\alpha/2} \sqrt{\mathrm{Var}(e_{T+h/T})}$. A 95%, $z = 1{,}96$.

ARIMA e longo prazo. Para $h > q$, as previsões obedecem à parte autorregressiva generalizada, $\phi(L)(1-L)^d \, \hat{y}_{T+h/T} = 0$ (BJRL, cap. 5). Com $d = 1$ e sem AR, a previsão fica **plana**. No ARIMA(0,1,1), ela é a suavização exponencial.

Iterada × direta (AU03, p. 41):

- a **iterada** usa o modelo de um passo recursivamente, como em todas as fórmulas acima;
- a **direta** estima um modelo diferente para cada horizonte.

Na prova teórica, a iterada é a que se deriva.

Demonstrações

D5.1 · O previsor de mínimo EQM é a esperança condicional (Q15a)

Seja g qualquer previsor construído com Ω_T, e $m = E(y_{T+h} \mid \Omega_T)$. Para encurtar, escreva $y \equiv y_{T+h}$, $E_T(\cdot) \equiv E(\cdot \mid \Omega_T)$ e $\mathrm{Var}_T(\cdot) \equiv \mathrm{Var}(\cdot \mid \Omega_T)$.

(1)	$E_T\big((y-g)^2\big) = E_T\big((y-m+m-g)^2\big)$	[soma e subtrai m]
(2)	$\quad = E_T\big((y-m)^2\big) + 2E_T\big((y-m)(m-g)\big) + E_T\big((m-g)^2\big)$	[quadrado, F4]
(3)	$E_T\big((y-m)(m-g)\big) = (m-g)\,E_T\big(y-m\big)$	[$m-g$ é conhecido em T]
(4)	$E_T\big(y-m\big) = m-m = 0$	[definição de m]
(5)	$E_T\big((m-g)^2\big) = (m-g)^2$	[conhecido em T]
(6)	$E_T\big((y-g)^2\big) = \mathrm{Var}_T(y) + (m-g)^2$	[(2)–(5)]
(7)	$\geq \mathrm{Var}_T(y)$, com igualdade $\iff g = m$	[$(m-g)^2 \geq 0$]

$$\boxed{\hat{y}_{T+h/T} = E(y_{T+h} \mid \Omega_T) \text{ minimiza o EQM; qualquer outro previsor paga } (m-g)^2 \text{ a mais}}$$

O critério é que decide: com perda quadrática, é a média. Com perda absoluta, $|y-g|$, seria a mediana condicional. Sob normalidade, as duas coincidem.

D5.2 · ARMA(1,1): $\hat{y}_{T+1/T}$ e $\hat{y}_{T+2/T}$ (Q15b)

Modelo: $y_t = c + \phi_1 y_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$ (AU02, p. 85).

(1)	$y_{T+1} = c + \phi_1 y_T + \varepsilon_{T+1} + \theta_1 \varepsilon_T$	[modelo em $T+1$]
(2)	$\hat{y}_{T+1/T} = c + \phi_1 y_T + 0 + \theta_1 \varepsilon_T$	[regras: conhecido fica, futuro $\to 0$]
(3)	$y_{T+2} = c + \phi_1 y_{T+1} + \varepsilon_{T+2} + \theta_1 \varepsilon_{T+1}$	[modelo em $T+2$]
(4)	$\hat{y}_{T+2/T} = c + \phi_1 \hat{y}_{T+1/T} + 0 + 0$	[$y_{T+1} \to$ previsão; os dois choques são futuros]
(5)	$\hat{y}_{T+h/T} = c + \phi_1 \hat{y}_{T+h-1/T}, \quad h \geq 2$	[mesma conta]
(6)	$\hat{y}_{T+h/T} - \mu = \phi_1^{h-1}\big(\hat{y}_{T+1/T} - \mu\big) \to 0$	[$c = (1-\phi_1)\mu$; $\lvert\phi_1\rvert < 1$]

$$\boxed{\hat{y}_{T+1/T} = c + \phi_1 y_T + \theta_1 \varepsilon_T, \qquad \hat{y}_{T+2/T} = c + \phi_1 \hat{y}_{T+1/T}}$$

O MA só aparece no primeiro passo, através de ε_T, que é conhecido em T porque o processo é **invertível**. Na lista, $\theta_1 = -\theta$: $\hat{y}_{T+1|T} = \phi y_T - \theta a_T$, com média zero.

D5.3 · O erro de previsão é um MA($h-1$), e sua variância (Q15c)

(1) $y_{T+h} = \mu + \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j} + \sum_{j\geq h} \psi_j \varepsilon_{T+h-j}$ [Wold, separa futuro e passado]

(2) $\hat{y}_{T+h/T} = \mu + 0 + \sum_{j\geq h} \psi_j \varepsilon_{T+h-j}$ [futuro $\to$ 0; passado conhecido, invertível]

(3) $e_{T+h/T} = y_{T+h} - \hat{y}_{T+h/T} = \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j}$ [(1) − (2)]

(4) $E(e_{T+h/T} \mid \Omega_T) = \sum_{j=0}^{h-1} \psi_j E(\varepsilon_{T+h-j}) = 0$ [F4, soma finita; RB]

(5) $\mathrm{Var}(e_{T+h/T}) = E\Big(\Big(\sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j}\Big)^2\Big) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$ [RB: só termos quadrados]

(6) $\mathrm{Var}(e_{T+h/T}) \to \sigma^2 \sum_{j\geq 0} \psi_j^2 = \gamma_0$ [$h \to \infty$; cap. 1, D1.3]

$$e_{T+h/T} = \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j} \ \text{(MA}(h-1)\text{)}, \qquad \mathrm{Var} = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2 \ \uparrow \ \gamma_0$$

Intervalo de 95% (Q15d): $\hat{y}_{T+h/T} \pm 1{,}96\, \sigma \sqrt{\sum_{j=0}^{h-1} \psi_j^2}$. Um detalhe que cai em prova: os erros de **horizontes diferentes** são correlacionados. e_{T+1} e e_{T+2} dividem o choque ε_{T+1}.

D5.4 · ARIMA(0,1,1) é suavização exponencial (Q15e)

Nos slides, $\Delta y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1}$; na lista, $\theta_1 = -\theta$, com $0 < \theta < 1$.

(1) $y_{T+1} = y_T + \varepsilon_{T+1} + \theta_1 \varepsilon_T$ [modelo em $T+1$]

(2) $\hat{y}_{T+1/T} = y_T + \theta_1 \varepsilon_T$ [futuro $\to 0$]

(3) $\varepsilon_T = y_T - \hat{y}_{T/T-1}$ [o choque é o erro de um passo]

(4) $\hat{y}_{T+1/T} = y_T + \theta_1 (y_T - \hat{y}_{T/T-1}) = (1+\theta_1)\, y_T - \theta_1\, \hat{y}_{T/T-1}$ [(3) em (2)]

(5) $\alpha \equiv 1 + \theta_1 = 1 - \theta$: $\quad \hat{y}_{T+1/T} = \alpha\, y_T + (1-\alpha)\, \hat{y}_{T/T-1}$ [lista: $\theta_1 = -\theta$]

(6) $\hat{y}_{T+1/T} = \alpha \sum_{j\geq 0} (1-\alpha)^j\, y_{T-j}$ [(5) iterada; $0 < 1-\alpha < 1$]

(7) $\hat{y}_{T+h/T} = \hat{y}_{T+h-1/T} = \cdots = \hat{y}_{T+1/T}, \quad h \geq 2$ [$\varepsilon_{T+1}, \varepsilon_{T+2}, \ldots$ futuros]

$$\hat{y}_{T+h/T} = \alpha \sum_{j\geq 0} (1-\alpha)^j y_{T-j} \text{ para todo } h \geq 1, \qquad \alpha = 1 - \theta = 1 + \theta_1$$

A previsão de longo prazo é **constante**: o nível suavizado de hoje. A constante de suavização é $\alpha = 1 - \theta$. Quanto maior o θ da lista, menor o α, e mais a previsão "lembra" do passado distante. Os pesos de (6) somam 1, porque $\alpha \sum (1-\alpha)^j = \alpha \cdot \frac{1}{\alpha} = 1$ (F2).

Exemplo

1. AR(1) com $\mu = 10$, $\phi_1 = 0{,}8$, $\sigma^2 = 1$, e a última observação $y_T = 14$:

h	$\hat{y}_{T+h/T}$	Var(e)	intervalo de 95%
1	13,2	1	[11,24; 15,16]
2	12,56	1,64	
3	12,048	2,0496	
∞	10	2,7778	$10 \pm 3{,}267$

- O elástico puxa 20% do desvio por período: $4 \to 3{,}2 \to 2{,}56 \to 2{,}048$. A meia-vida do desvio é de 3,11 períodos.
- O leque abre de 1 para 1,64 e 2,05 e para em $\gamma_0 = 2{,}78$.

2. ARMA(1,1) da AU02, p. 86 ($\phi_1 = 0{,}8$, $\theta_1 = 0{,}6$, $\mu = 0$), com $y_T = 2$ e $\varepsilon_T = 0{,}5$:

- $\hat{y}_{T+1/T} = 0{,}8(2) + 0{,}6(0{,}5) = 1{,}9$;
- $\hat{y}_{T+2/T} = 0{,}8(1{,}9) = 1{,}52$.

Com $\psi = (1;\ 1{,}4;\ 1{,}12)$, a variância do erro é 1, depois $1 + 1{,}96 = 2{,}96$, depois 4,2144. O leque abre mais rápido que no AR(1), porque $\psi_1 = 1{,}4 > 1$.

3. Suavização exponencial, com $\theta^{\text{lista}} = 0{,}6$:

- $\alpha = 0{,}4$;
- os pesos de y_T, y_{T-1}, y_{T-2} são 0,4; 0,24; 0,144.

Numa série simulada de 300 observações, a recursão (5) e o `predict` do ARIMA(0,1,1) do R dão a mesma previsão, com diferença zero, e a previsão de 3 passos é igual à de 1: plana.

Avaliar previsões

A Q15 pergunta como prever. A AU03, p. 32–60, completa com a pergunta seguinte: **como saber se a previsão foi boa**, e se um modelo prevê melhor que outro. Nada disso é cobrado diretamente na lista, mas é o fecho natural do bloco e cai bem como item de discussão.

Treino, teste e janelas (AU03, p. 32–38). A amostra é dividida:

- um trecho de **treino**, para estimar;
- um trecho de **teste**, para medir os erros fora da amostra, que é o único lugar onde o erro de previsão é honesto.

Ao avançar a origem da previsão, há três esquemas:

- **janela fixa**: estima uma vez, no treino original, e só prevê;
- **janela recursiva**, ou expansiva: reestima a cada origem com todos os dados até ali;
- **janela móvel**, ou deslizante: reestima com as últimas R observações, que é o esquema que se adapta a quebras.

A AU03, p. 37–38, ressalta que essa escolha, o horizonte e a forma de prever (iterada ou direta) são três decisões independentes.

DA5.1 · Iterada × direta: quando a direta ganha (AU03, p. 41–44)

A **iterada** estima o modelo de um passo e o aplica h vezes. A **direta** regride y_{t+h} diretamente em y_t, um modelo por horizonte. No AR(1) de média zero, a iterada usa $\hat{\phi}^h y_T$, e a direta usa $\hat{b}_h y_T$, com $\hat{b}_h$ da regressão de y_{t+h} em y_t.

(1) $b_h^* = \dfrac{\mathrm{Cov}(y_{t+h}, y_t)}{\mathrm{Var}(y_t)} = \rho_h$ [a direta]

(2) $\operatorname{plim} \hat{\phi} = \rho_1 \;\Rightarrow$ iterada usa ρ_1^h [MQO do AR(1)]

(3) AR(1) verdadeiro: $\rho_h = \phi^h = \rho_1^h$: mesmo alvo [cap. 2, D2.4]

(4) $EQM(b) = E\big((y_{T+h} - b y_T)^2\big) = \gamma_0\big(1 - 2b\rho_h + b^2\big)$ [F4, estac.]

(5) $\dfrac{d\,EQM}{db} = \gamma_0(-2\rho_h + 2b) = 0 \;\Rightarrow\; b = \rho_h$ [a direta é a ótima linear]

(6) AR(2) verdadeiro, AR(1) ajustado: $\rho_1^h \neq \rho_h \;\Rightarrow\; EQM_{iter} > EQM_{dir}$ [(4), (5)]

modelo certo: iterada (mesmo alvo, menos parâmetros); modelo errado e h longo: direta

Com o AR(2) do caderno ($\phi_1 = 1{,}5$, $\phi_2 = -0{,}6$) ajustado como AR(1), em $h = 5$:

- a iterada usa $\rho_1^5 = 0{,}9375^5 = 0{,}7242$, mas o certo é $\rho_5 = 0{,}3417$;
- o EQM relativo da iterada é $1{,}0295\,\gamma_0$, pior até do que prever a média;
- o da direta é $0{,}8832\,\gamma_0$;
- a direta reduz o RMSE em 7,4%.

DA5.2 · As métricas de previsão pontual (AU03, p. 45–49)

Com os erros fora da amostra $\hat{e}_t = y_t - \hat{y}_t$, $t = 1, \ldots, n$:

(7) $MAD = \dfrac{1}{n}\sum |\hat{e}_t|$ [na unidade de y]

(8) $RMSE = \sqrt{\dfrac{1}{n}\sum \hat{e}_t^2}$ [pune erros grandes]

(9) $MAPE = \dfrac{100}{n}\sum \left|\hat{e}_t / y_t\right|$ [sem escala; exige $y_t \neq 0$]

(10) $MASE = \dfrac{\frac{1}{n}\sum |\hat{e}_t|}{Q}, \quad Q = \dfrac{1}{T_{tr} - m}\sum_{t=m+1}^{T_{tr}} |y_t - y_{t-m}|$ [escala do ingênuo no treino]

(11) $MASE < 1 \iff$ melhor que o ingênuo [(10)]

Exemplo. São cinco previsões, com reais $(102; 98; 105; 110; 107)$ e previstos $(100; 101; 103; 106; 109)$; o treino é $(95; 97; 96; 99; 101; 100)$, com $m = 1$.

- $MAD = 2{,}6$, $RMSE = 2{,}7203$ e $MAPE = 2{,}49\%$;
- $Q = 1{,}8$, logo $MASE = 1{,}44$: o modelo é **pior que o ingênuo**, embora o MAPE pareça baixo.

DA5.3 · Diebold-Mariano: a diferença é real? (AU03, p. 50–51)

(12) $d_t = L(e_{1t}) - L(e_{2t}),\ \ L(e) = e^2$ [diferencial de perda]

(13) $H_0 \ : \ E(d_t) = 0$ (mesma acurácia) [AU03 p. 50]

(14) $DM = \dfrac{\bar{d}}{\sqrt{\hat{V}(\bar{d})}} \xrightarrow{d} N(0,1), \quad \hat{V}(\bar{d}) = \dfrac{\hat{\sigma}_d^2}{n}$ se $h = 1$ [TLC]

(15) rejeita H_0 a 5% se $|DM| > 1{,}96$; o sinal de $\bar{d}$ diz quem é melhor [AU03 p. 51]

Com $h > 1$, os d_t são autocorrelacionados até a defasagem $h-1$, porque o erro de h passos é um MA($h-1$) (D5.3). Então $\hat{V}(\bar{d})$ precisa de um estimador robusto, do tipo Newey-West. E o esquema de reestimação importa: com **janela móvel**, a alternativa de Giacomini e White (2006), citada na AU03, p. 51, compara os **métodos** de previsão, incluindo a incerteza da estimação; com janela recursiva, o DM compara os modelos populacionais.

Exemplo com dez erros de dois modelos: $\bar{d} = 1{,}46$, $\hat{V}(\bar{d}) = 0{,}1581$ e $DM = 3{,}67 > 1{,}96$. O modelo 2 prevê significativamente melhor.

DA5.4 · Intervalos e distribuições: Winkler, CRPS e Christoffersen (AU03, p. 52–60)

Na linha (18), $z = (y_t - \mu)/\sigma$, e Φ e φ são a acumulada e a densidade da normal padrão.

(16) $W_t = (u - \ell) + \frac{2}{\alpha}(\ell - y_t)\,\mathbb{1}\{y_t < \ell\} + \frac{2}{\alpha}(y_t - u)\,\mathbb{1}\{y_t > u\}$ [Winkler, AU03 p. 53–55]

(17) $CRPS_t = \int_{-\infty}^{\infty} \big(F_t(x) - \mathbb{1}\{x \geq y_t\}\big)^2 dx$ [AU03 p. 56–58]

(18) $CRPS = \sigma\Big(z\big(2\Phi(z) - 1\big) + 2\varphi(z) - \frac{1}{\sqrt{\pi}}\Big)$ [$F_t = N(\mu, \sigma^2)$]

(19) $I_t = \mathbb{1}\{y_t \notin [\ell, u]\},\ \ \hat{\pi} = \frac{n_1}{n};\ \ H_0 \ : \ E(I_t) = \alpha$ [violações, AU03 p. 59]

(20) $LR_{uc} = -2\ln\big[(1-\alpha)^{n_0}\alpha^{n_1}\big] + 2\ln\big[(1-\hat{\pi})^{n_0}\hat{\pi}^{\,n_1}\big] \sim \chi^2_1$ [incondicional]

(21) $LR_{cc} = LR_{uc} + LR_{ind} \sim \chi^2_2$ [AU03 p. 59–60]

> Winkler: largura + $\frac{2}{\alpha}$ × distância do ponto fora; CRPS: área entre F_t e o degrau em y_t
>
> $$LR_{cc} = LR_{uc} + LR_{ind}$$

Exemplos:

- **Winkler**, com $\alpha = 0{,}05$ e o intervalo $[8; 12]$: $W = 4$ se $y = 10$ (dentro); $W = 24$ se $y = 7{,}5$ (meio ponto abaixo); $W = 44$ se $y = 13$ (um ponto acima). A cobertura que falha custa caro.
- **CRPS** com $y_t = 0$: a distribuição larga, $N(0; 9)$, dá 0,7011; a deslocada, $N(2; 1)$, dá 1,4528; a calibrada e afiada, $N(0; 0{,}25)$, dá 0,1168. A fórmula (18) coincide com a integral numérica (17).
- **Christoffersen**, com 100 intervalos de 90% e 15 violações: $LR_{uc} = 2{,}45$, $p = 0{,}12$. Não se rejeita a cobertura nominal, mas é preciso ainda o teste de independência: violações **agrupadas** reprovam o modelo mesmo com a frequência certa (AU03, p. 60).

Cadeia socrática

P1. Por que $E(\varepsilon_{T+1} \mid \Omega_T) = 0$, mas $E(\varepsilon_T \mid \Omega_T) = \varepsilon_T$?

Resposta

ε_{T+1} é a notícia de amanhã: é RB e não se correlaciona com nada de hoje, então a melhor aposta é a média, zero. ε_T já aconteceu e, se o modelo é invertível, pode ser calculado a partir de $y_T, y_{T-1}, \ldots$: é informação, não incerteza.

P2. Num MA(2), qual é $\hat{y}_{T+3/T}$?

Resposta

μ. $y_{T+3} = \mu + \varepsilon_{T+3} + \theta_1\varepsilon_{T+2} + \theta_2\varepsilon_{T+1}$: os três choques são futuros. A memória de 2 dias acabou (AU02, p. 55).

P3. E a variância do erro desse MA(2) no horizonte 3?

Resposta

$(1 + \theta_1^2 + \theta_2^2)\sigma^2 = \gamma_0$. Depois de q passos, o erro de previsão tem toda a variância do processo: você não sabe nada além da média.

P4. No AR(1), por que a variância do erro cresce, mas não passa de γ_0?

Resposta

Cada passo soma um termo $\phi_1^{2j}\sigma^2$, sempre positivo, e por isso ela cresce. Mas os termos encolhem geometricamente, e a soma converge para $\sigma^2/(1 - \phi_1^2) = \gamma_0$. No limite, prever é dar a média incondicional, com a incerteza incondicional.

P5. E se $\phi_1 = 1$?

Resposta

Então $\psi_j = 1$ para todo j, e $\text{Var}(e_{T+h}) = h\sigma^2$ cresce sem limite: o leque abre para sempre. A previsão pontual fica em y_T, sem drift, e não volta a média nenhuma. É o barco à deriva do cap. 3.

P6. Os erros de previsão de 1 e de 2 passos, feitos na mesma origem, são independentes?

Resposta

Não. $e_{T+1} = \varepsilon_{T+1}$ e $e_{T+2} = \varepsilon_{T+2} + \psi_1\varepsilon_{T+1}$ dividem ε_{T+1}: Cov $= \psi_1\sigma^2$. Uma surpresa amanhã contamina a previsão de depois de amanhã.

P7. Por que o ARIMA(0,1,1) dá previsão plana, se a série não é estacionária?

Resposta

Porque, sem drift, a melhor estimativa do **nível** futuro é o nível atual suavizado: os choques futuros têm média zero e não deslocam a esperança. O que cresce com h é a incerteza, não a previsão. Com drift, a previsão seria uma reta.

P8. Na D5.1, se o critério fosse o erro absoluto, a previsão seria outra?

Resposta

Seria a **mediana** condicional. Com erros gaussianos, média e mediana coincidem, e a fórmula não muda. Com distribuições assimétricas, mudam: a Q15(a) é sobre o EQM, e o enunciado define a perda.

Diálogo

Sobre o erro de calcular a variância do erro com os coeficientes errados.

Aluno: No ARMA(1,1), a variância do erro de dois passos é $\sigma^2(1+\phi_1^2)$, como no AR(1).

Professor: De onde vem esse ϕ_1^2?

Aluno: Do AR(1): $e_{T+2} = \varepsilon_{T+2} + \phi_1\varepsilon_{T+1}$.

Professor: E no ARMA(1,1)? Escreva y_{T+2} e tire a previsão.

Aluno: $y_{T+2} = \phi_1 y_{T+1} + \varepsilon_{T+2} + \theta_1\varepsilon_{T+1}$. E $y_{T+1} = \hat{y}_{T+1/T} + \varepsilon_{T+1}$. Substituindo, o erro é $\varepsilon_{T+2} + \phi_1\varepsilon_{T+1} + \theta_1\varepsilon_{T+1}$.

Professor: Então o coeficiente de ε_{T+1} é?

Aluno: $\phi_1 + \theta_1$, que é o ψ_1! A variância é $\sigma^2\big(1 + (\phi_1+\theta_1)^2\big)$.

Professor: Com $\phi_1 = 0{,}8$ e $\theta_1 = 0{,}6$?

Aluno: $1 + 1{,}96 = 2{,}96$, bem maior que os 1,64 que eu teria dado.

Professor: Qual é a regra geral, então?

Aluno: Não copiar a fórmula do AR. Usar sempre $\sigma^2 \sum_{j=0}^{h-1} \psi_j^2$, com os ψ do modelo que está na questão, e conferir o sinal: na lista, $\psi_1 = \phi - \theta$.

Na prova

A folha de caderno do bloco está em a_mao_cap5.md: Q15 (a) a (e) em 40 linhas numeradas, cada uma com a justificativa, mais a versão para a prova e a conferência em R.

Questão	O que este capítulo dá	Resolução completa
Q15 (a)	média condicional minimiza o EQM	Q15
Q15 (b)–(d)	ARMA(1,1) em $h = 1, 2$; erro MA($h-1$); intervalo de 95%	Q15
Q15 (e)	ARIMA(0,1,1), previsão plana, $\alpha = 1 - \theta$	Q15
Q12 (c)	previsão do SARIMA trimestral, que usa as mesmas regras	Q12

Armadilhas:

- tratar ε_T como zero: ele é **conhecido** em T;
- usar ϕ_1^j como peso do erro num ARMA, quando o certo é ψ_j;
- esquecer que o MA "morre" depois de q passos;
- na Q15(e), escrever $\alpha = \theta$ em vez de $1 - \theta$ na convenção da lista;
- no caderno de 26/08, a previsão do MA(2) misturou $E(y_t \mid \Omega_{t-1})$ com $E(y_{t+2} \mid \Omega_t)$ (ver Q15).

Checklist de 30 segundos:

1. Escrevi o modelo **na data futura** antes de tirar a esperança?
2. Apliquei as três regras: conhecido fica, choque futuro é zero, y futuro vira previsão?
3. A variância do erro usa os ψ_j do modelo certo?
4. O intervalo tem $\pm 1{,}96\sqrt{\text{Var}}$, com a raiz?

5. Disse o que acontece no longo prazo (volta à média, ou fica plano)?

No material do professor

Roteiro de releitura:

- AU02, p. 44: modelo condicional × incondicional;
- AU02, p. 54–57: previsão do MA, o intervalo e o EQM;
- AU02, p. 72–76: previsão do AR(1), o erro e a variância;
- AU02, p. 85: previsão do ARMA(1,1);
- AU03, p. 32–41: treino e teste, esquemas de janela, horizonte e origem, iterada × direta.
- AU03, p. 42–49: o exemplo iterada × direta no AR(1) e as métricas MAPE, MAD, RMSE e MASE;
- AU03, p. 50–60: Diebold-Mariano, Winkler, CRPS e os testes de cobertura de Christoffersen.

Livros:

- **HAMILTON**, cap. 4: previsão ótima, a projeção linear e a esperança condicional;
- **BJRL**, cap. 5: previsão de ARIMA, pesos ψ, intervalos e a "função de previsão eventual";
- **ENDERS**, cap. 2: previsão de ARMA no nível do curso.

Na lista comentada: Q15 · Q12 · ferramenta F9 (esperança condicional).

Parte VII

Bloco 6 — Aplicação

Capítulo 6 · Aplicação: Box-Jenkins de ponta a ponta num SARIMA mensal

← apostila · anterior: cap. 5 · questão da lista: Q16

Pergunta de abertura

Você tem 240 meses de uma variável macroeconômica, com tendência e sazonalidade. Alguém sugere um SARIMA$(1,1,1)(0,1,1)_{12}$. **Como você sabe se a sugestão é boa?** Não basta estimar: é preciso saber o que a FAC **deveria** mostrar se o modelo estivesse certo, o que os resíduos **deveriam** parecer, e como decidir contra um rival com um parâmetro a mais.

A Q16 é a questão-síntese da lista. Ela usa:

- a notação e a contagem do cap. 3;
- a FAC do cap. 2;
- os critérios do cap. 4;
- o diagnóstico da AU03.

Este capítulo junta as peças no **ciclo de Box-Jenkins** (AU03, p. 4–7).

A imagem

Box-Jenkins é um ciclo de diagnóstico médico. Os passos:

1. **Anamnese:** olhe o gráfico e a FAC.
2. **Hipótese diagnóstica:** identifique um modelo candidato.
3. **Tratamento:** estime.
4. **Exames de controle:** analise os resíduos.

Se os exames acusam algo, como uma autocorrelação que sobrou ou uma variância que muda, **volte ao passo 2**. O ciclo só termina quando os resíduos parecem ruído branco (AU03, p. 4–5).

Os resíduos são o que o modelo não conseguiu explicar. Se ainda há padrão neles, há informação na mesa. O Ljung-Box é o exame que pergunta se sobrou alguma correlação, em conjunto, até a defasagem K.

A FAC do SARIMA multiplicativo tem "satélites". Pense em duas engrenagens acopladas (cap. 3). O MA não sazonal deixa uma marca na defasagem 1, e o sazonal na 12. O produto dos dois cria marcas em 11 e 13, os satélites, em volta do pico sazonal: a assinatura do modelo multiplicativo.

Um quase fator comum é uma dupla de atores que se anulam em cena. Quando o AR e o MA têm raízes próximas, um desfaz o que o outro faz. O modelo ainda ajusta bem, mas fica impossível dizer quanto do efeito é de cada um: os erros-padrão explodem.

> **Onde a analogia quebra**
>
> - **"Resíduo branco" não prova que o modelo é o verdadeiro.** Vários modelos diferentes podem deixar resíduos limpos, e o ciclo seleciona um modelo **adequado**, não o único certo. É por isso que se usa um critério (BIC, LR) para escolher entre os adequados.

- **O médico examina a pessoa; nós examinamos uma única amostra.** Com 227 observações efetivas, um pico isolado na FAC dos resíduos, num de 24 lags, pode ser acaso: com 5% de nível, espera-se 1,2 rejeição "falsa" em 24. O teste conjunto existe para isso.
- **Os satélites só aparecem com os dois MA presentes.** Sem o MA não sazonal ($\theta_1 = 0$), não há satélite em 11 e 13.

Teoria

O modelo da Q16, nos slides:

$$(1-\phi L)(1-L)(1-L^{12})\,y_t = (1+\theta_1 L)(1+\Theta_1 L^{12})\,\varepsilon_t, \qquad \theta_1 = -\theta^{\text{lista}},\ \ \Theta_1 = -\Theta^{\text{lista}}.$$

Com $w_t = (1-L)(1-L^{12})y_t$, w_t é um ARMA(1,13) **restrito**, com MA só nas defasagens 1, 12 e 13, e o coeficiente da 13 igual a $\theta_1\Theta_1$.

Ciclo de Box-Jenkins (AU03, p. 4–7; AU02, p. 96–97):

1. **Identificação:** gráfico, diferenças para estacionarizar, FAC e FACP de w_t.
2. **Estimação:** MV, exata ou condicional (cap. 4).
3. **Diagnóstico** (*model checking*): resíduos, estabilidade e previsão.
4. **Uso:** previsão (cap. 5).

FAC do ARMA com MA de ordem q (AU02, p. 87): para $k > q$, vale a recursão do AR. No airline model ($\phi = 0$), a FAC de w_t é **zero fora de 1, 11, 12 e 13** (D6.1).

Diagnóstico dos resíduos (AU03, p. 9–22):

- **gráficos:** resíduos padronizados no tempo, histograma, QQ-plot e FAC dos resíduos (p. 10);
- **Jarque-Bera:** $JB = \frac{n}{6}\hat{S}^2 + \frac{n}{24}(\widehat{K}-3)^2 \sim \chi^2_2$, com H_0: normalidade (p. 11–14);
- **Ljung-Box:** $LB(K) = T(T+2)\sum_{i=1}^{K}\frac{\hat{\rho}_i^2}{T-i} \sim \chi^2_{K-p-q-P-Q}$, com $H_0 : \rho_1 = \cdots = \rho_K = 0$ nos erros (p. 15–17);
- **Breusch-Godfrey:** a versão LM, por regressão auxiliar dos resíduos (p. 18);
- **ARCH-LM:** $\hat{\varepsilon}_t^2$ regredido nas próprias defasagens, para detectar heterocedasticidade condicional (p. 19–22).

Escolha entre rivais (AU02, p. 98–99): mesmo T; BIC para identificar e AIC para prever; LR para modelos aninhados (cap. 4).

Demonstrações

D6.1 · A FAC do modelo das companhias aéreas: o pico e os satélites

Com $\phi = 0$: $w_t = (1+\theta_1 L)(1+\Theta_1 L^{12})\varepsilon_t = \varepsilon_t + \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \theta_1\Theta_1\varepsilon_{t-13}$. Os coeficientes são $\psi_0 = 1$, $\psi_1 = \theta_1$, $\psi_{12} = \Theta_1$, $\psi_{13} = \theta_1\Theta_1$ e zero nos demais.

(1)	$\gamma_k = \sigma^2 \sum_j \psi_j\psi_{j+k}$	[cap. 1, D1.3]
(2)	$\gamma_0 = \sigma^2\big(1+\theta_1^2+\Theta_1^2+\theta_1^2\Theta_1^2\big) = \sigma^2(1+\theta_1^2)(1+\Theta_1^2)$	[$k=0$; fatora]
(3)	$\gamma_1 = \sigma^2(\psi_0\psi_1 + \psi_{12}\psi_{13}) = \sigma^2\theta_1(1+\Theta_1^2)$	[$k=1$]
(4)	$\gamma_{11} = \sigma^2\psi_1\psi_{12} = \sigma^2\theta_1\Theta_1$	[$k=11$: só o par $(1,12)$]
(5)	$\gamma_{12} = \sigma^2(\psi_0\psi_{12} + \psi_1\psi_{13}) = \sigma^2\Theta_1(1+\theta_1^2)$	[$k=12$]
(6)	$\gamma_{13} = \sigma^2\psi_0\psi_{13} = \sigma^2\theta_1\Theta_1$	[$k=13$]
(7)	$\gamma_k = 0$ para $k \notin \{0,1,11,12,13\}$	[nenhum par à distância k]

Dividindo por γ_0:

$$\boxed{\rho_1 = \frac{\theta_1}{1+\theta_1^2}, \qquad \rho_{12} = \frac{\Theta_1}{1+\Theta_1^2}, \qquad \rho_{11} = \rho_{13} = \rho_1\,\rho_{12}}$$

Os satélites são o **produto** dos dois picos. É a forma mais rápida de reconhecer um MA multiplicativo na FAC. Com o AR ($\phi \neq 0$), as defasagens baixas passam a decair à taxa ϕ a partir de ρ_1, como no ARMA(1,1) do cap. 2.

D6.2 · Parâmetros, observações e a equação de w_t (Q16a e Q16b)

(1)	$(1+\theta_1 L)(1+\Theta_1 L^{12}) = 1 + \theta_1 L + \Theta_1 L^{12} + \theta_1\Theta_1 L^{13}$	[F8: quatro produtos]
(2)	$w_t = (1-L)(1-L^{12})y_t = y_t - y_{t-1} - y_{t-12} + y_{t-13}$	[F8]
(3)	$w_t = \phi w_{t-1} + \varepsilon_t + \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \theta_1\Theta_1\varepsilon_{t-13}$	[(1), (2)]
(4)	livres: ϕ, θ_1, Θ_1, σ^2; o coeficiente de ε_{t-13} é imposto	[forma multiplicativa]
(5)	sem constante: com $d = D = 1$, $c \neq 0$ geraria tendência quadrática em y_t	[cap. 3]
(6)	perdas: $d + sD = 1 + 12 = 13$; $T_{ef} = 240 - 13 = 227$	[(2) precisa de y_{t-13}]

$$\boxed{\text{4 parâmetros } (\phi, \theta_1, \Theta_1, \sigma^2), \qquad \text{227 observações efetivas}}$$

Na lista: $(1-\phi B)(1-B)(1-B^{12})y_t = (1-\theta B)(1-\Theta B^{12})a_t$, e o termo cruzado do MA é $+\theta\Theta B^{13}$, porque $(-\theta)(-\Theta) = +\theta\Theta$.

D6.3 · Ljung-Box e LR: as contas que decidem (Q16d e diagnóstico)

(1)	$LB(K) = T(T+2)\sum_{i=1}^{K} \frac{\hat\rho_i^2}{T-i}$	[AU03, p. 15]
(2)	$\nu = K - p - q - P - Q = 24 - 1 - 1 - 0 - 1 = 21$	[graus de liberdade com $K=24$]
(3)	rejeita H_0 a 5% se $LB(24) > \chi^2_{21;\,0{,}95} = 32{,}67$	[tabela]
(4)	$LR = 2\big(\ln L_{(2,1,1)} - \ln L_{(1,1,1)}\big) \xrightarrow{d} \chi^2(1)$	[$H_0 : \phi_2 = 0$; aninhados]
(5)	rejeita H_0 se $LR > 3{,}84$	[$\chi^2_{1;\,0{,}95}$]
(6)	BIC: multa $\ln 227 = 5{,}42$ por parâmetro	[cap. 4]

$$\nu_{LB} = K - p - q - P - Q, \qquad LR \sim \chi^2(1) \text{ com crítico } 3{,}84, \qquad \text{BIC exige } LR > \ln T_{ef} = 5{,}42$$

Ligando (5) e (6): o BIC prefere o modelo maior só se $LR > 5{,}42$, mais exigente que o teste a 5%, que pede $LR > 3{,}84$. É a D4.4 do cap. 4 aplicada.

Exemplo

1. A FAC teórica. Com $\theta^{\text{lista}} = 0{,}4$ e $\Theta^{\text{lista}} = 0{,}6$, ou seja, $\theta_1 = -0{,}4$ e $\Theta_1 = -0{,}6$ nos slides:

	ρ_1	ρ_2	ρ_{11}	ρ_{12}	ρ_{13}
airline ($\phi = 0$), pela D6.1	−0,3448	0	0,1521	−0,4412	0,1521
idem, pelo `ARMAacf`	−0,3448	0	0,1521	−0,4412	0,1521
Q16 ($\phi = 0{,}5$)	0,1052			−0,4411	

O pico sazonal quase não muda com o AR. Já ρ_1 muda até de sinal, porque o AR soma memória positiva às defasagens baixas.

2. Box-Jenkins de ponta a ponta. Simulei 240 meses do modelo verdadeiro ($\phi = 0{,}5$, $\theta_1 = -0{,}4$, $\Theta_1 = -0{,}6$, $\sigma^2 = 1$) e estimei o SARIMA$(1,1,1)(0,1,1)_{12}$ no R:

Parâmetro	verdadeiro	estimado	erro-padrão
ϕ	0,5	0,402	0,253
θ_1	−0,4	−0,218	0,266
Θ_1	−0,6	−0,705	0,058
σ^2	1	0,905	

Como ler:

- **observações:** o R usou 227, as 240 menos as 13 da D6.2;
- **diagnóstico:** $LB(24) = 15{,}39$ com 21 graus de liberdade, $p = 0{,}80$. Os resíduos parecem ruído branco, e o modelo é adequado;
- **rival:** contra o SARIMA$(2,1,1)(0,1,1)_{12}$, $LR = 0{,}47 < 3{,}84$, e o BIC do menor é 651,42 contra 656,38 do maior. Os dois apontam o modelo da Q16;
- **o alerta:** $\hat{\phi}$ e $\hat{\theta}_1$ têm erros-padrão de ~0,25, enormes perto dos valores. O motivo é um **quase fator comum**: $(1 - 0{,}5L)$ no AR e $(1 - 0{,}4L)$ no MA, com raízes 2 e 2,5, quase se cancelam. O par se anula em cena, e os dados não separam um do outro. Já o Θ_1, sem rival, é estimado com precisão.

Cadeia socrática

P1. Por que o coeficiente de ε_{t-13} não conta como parâmetro?

> **Resposta**
>
> Porque ele é o produto $\theta_1\Theta_1$, imposto pela forma multiplicativa. Não há um quinto número livre: conhecidos θ_1 e Θ_1, ele está determinado (D6.2).

P2. Por que não colocar uma constante, se a série cresce?

Resposta

Porque o crescimento já está nas duas raízes unitárias. Com $d = D = 1$, uma constante em w_t vira uma tendência **quadrática** em y_t, o que raramente faz sentido. É a regra 5 das notas de identificação de Duke e o argumento do cap. 3.

P3. Se o airline model tem FAC zero fora de 1, 11, 12 e 13, o que indica um pico em 24?

Resposta

Que falta algo sazonal: um AR sazonal, que geraria picos decaindo em 12, 24, 36…, ou um MA sazonal de ordem 2. O $\text{MA}(1)_{12}$ sozinho não gera nada em 24.

P4. Por que o Ljung-Box tem $K - p - q - P - Q$ graus de liberdade, e não K?

Resposta

Porque os resíduos vêm de um modelo **estimado**: cada parâmetro de AR e MA ajustado "consome" um grau de liberdade das autocorrelações, que ficam menores do que seriam com os choques verdadeiros. A variância σ^2 não entra na conta (AU03, p. 15).

P5. Os resíduos passaram no Ljung-Box. Acabou o diagnóstico?

Resposta

Não. Faltam:

- a **normalidade** (JB), que importa para os intervalos;
- a **heterocedasticidade condicional** (ARCH-LM, FAC de $\hat{\varepsilon}_t^2$);
- a **estabilidade** (Chow e CUSUM).

O Ljung-Box só olha a dependência **linear** nos resíduos (AU03, p. 7 e 19–30).

P6. No exemplo, por que $\hat{\phi}$ e $\hat{\theta}_1$ saíram tão imprecisos?

Resposta

Porque $(1 - 0{,}5L)$ e $(1 + \theta_1 L) = (1 - 0{,}4L)$ quase se cancelam: é um quase fator comum (cap. 2, P9). Os dados identificam bem o **efeito líquido**, mas não a divisão entre AR e MA. A regra de Duke manda testar o modelo com um AR e um MA a menos.

P7. Por que comparar com o $\text{SARIMA}(2,1,1)(0,1,1)_{12}$ pelo BIC, e não pelo R^2?

Resposta

Porque o R^2, ou a verossimilhança pura, sempre melhora com o parâmetro a mais: o maior contém o menor. O BIC desconta $\ln 227 = 5{,}42$ por parâmetro. E, como são aninhados, o LR dá uma confirmação com nível conhecido (D6.3).

P8. E se um modelo usasse $d = 0$ e o outro $d = 1$? Ainda posso comparar pelo BIC?

Resposta

Não diretamente. As variáveis modeladas são diferentes, y_t e Δy_t, e o número de observações efetivas também. A regra é mesmo T e mesma série (AU02, p. 99). A escolha de d e D vem antes, pela identificação e pelos testes de raiz unitária.

Diálogo

Sobre "os resíduos passaram, então o modelo está certo".

Aluno: Estimei o SARIMA da Q16, e o Ljung-Box deu $p = 0{,}80$. O modelo está certo.

Professor: Certo em que sentido?

Aluno: Os resíduos são ruído branco.

Professor: O teste mostrou que eles **são** ruído branco?

Aluno: ... Mostrou que eu não rejeito que sejam, até a defasagem 24.

Professor: E um SARIMA$(2,1,1)(0,1,1)_{12}$ também deixaria resíduos brancos?

Aluno: Provavelmente sim: ele contém o meu como caso particular.

Professor: Então o Ljung-Box escolhe entre os dois?

Aluno: Não. Ele separa os modelos adequados dos inadequados. Para escolher **entre** os adequados, preciso de outro critério: o BIC ou o LR. No exemplo, os dois ficaram com o menor.

Professor: E olhando as estimativas, nada incomoda?

Aluno: Os erros-padrão de ϕ e θ_1 são enormes... e as raízes do AR e do MA estão perto, 2 e 2,5. Pode ser um quase fator comum. Eu testaria também um modelo sem os dois, só com o MA sazonal.

Professor: Esse é o ciclo de Box-Jenkins: o diagnóstico manda de volta para a identificação.

Na prova

A folha de caderno do bloco está em a_mao_cap6.md: Q16 (a) a (d), mais o ciclo de Box-Jenkins em 41 linhas numeradas, cada uma com a justificativa, mais a versão para a prova e a conferência em R.

Questão	O que este capítulo dá	Resolução completa
Q16 (a)	o modelo em B, com o termo cruzado $+\theta\Theta B^{13}$	Q16
Q16 (b)	4 parâmetros e 227 observações efetivas	Q16
Q16 (c)	FAC de w_t: pico em 12, satélites em 11 e 13, decaimento à taxa ϕ	Q16
Q16 (d)	BIC (identificação) com o LR como confirmação, mesmo T	Q16
Q12 (d)	o roteiro de diagnóstico de resíduos	Q12

Armadilhas:

- contar 5 parâmetros, tratando $\theta\Theta$ como livre, ou 3, esquecendo σ^2;
- errar o sinal do termo cruzado na lista: $(-\theta)(-\Theta) = +\theta\Theta$;
- usar K graus de liberdade no Ljung-Box, em vez de $K - p - q - P - Q$;
- esperar um pico em 24 com um MA sazonal de ordem 1;
- dizer que "resíduo branco" prova que o modelo é o verdadeiro.

Checklist de 30 segundos:

1. Escrevi o modelo com os quatro polinômios e expandi o MA?
2. Contei os parâmetros, incluindo σ^2, e as observações perdidas, $d + sD$?
3. Descrevi a FAC com o pico, os satélites e o decaimento?
4. Listei o diagnóstico completo: gráficos, JB, LB com os graus de liberdade certos, ARCH e estabilidade?
5. Recomendei um critério **e** disse por quê (aninhados, mesmo T, objetivo)?

No material do professor

Roteiro de releitura:

- AU03, p. 4–7: o ciclo de Box-Jenkins e as duas dimensões da avaliação;
- AU03, p. 9–22: diagnóstico dos resíduos (gráficos, JB, Ljung-Box, Breusch-Godfrey, ARCH);
- AU03, p. 23–31: estabilidade, com Chow e análise recursiva/CUSUM;
- AU02, p. 87 e 90–97: FAC do ARMA(p, q), FACP e identificação;
- AU02, p. 98–99: AIC, BIC e a regra do mesmo T;
- AU05: SARIMA.

Livros:

- **BJRL**, cap. 9: o modelo das companhias aéreas, a FAC dos multiplicativos e a estratégia de partir dele;
- **ENDERS**, cap. 2: Box-Jenkins e diagnóstico no nível do curso;
- **HAMILTON**, cap. 5: a verossimilhança e os testes LR.

Na lista comentada: Q16 · Q12 · Q14.