Lista 01 — Box-Jenkins do INPC, passo a passo em R

Econometria II · PPGEco/UFES · bateria de testes das Questões 1 a 7

root

2026-10-26

Sumário

Pacotes e dados 1

Questão 1 — Inspeção gráfica e transformação 2
(a) ADF, PP e KPSS no nível . . . 3
(b) Constante e tendência . . . 5
(c) Série diferenciada e diferença sazonal . . . 6
(d) DS ou TS? . . . 6

Script único e linear: lê a base, roda a bateria de testes e responde a lista, questão por questão. Rode bloco a bloco no RStudio. Para virar PDF e nota do Obsidian, use `Rscript lista01/renderizar_laboratorio.R`.

Série. INPC/IBGE (SIDRA, tabela 1736), índice mensal de jan/2013 a set/2026 (165 meses). Modela-se $y_t = 100 \ln P_t$, de modo que Δy_t é a inflação mensal em %.

Sinal do MA. O R escreve o MA como $1 + \theta B$; a lista escreve $1 - \theta B$.

Pacotes e dados

```
library(forecast)   # Arima, forecast, accuracy, checkresiduals
library(tseries)    # jarque.bera.test, kpss.test
library(urca)       # ur.df, ur.pp, ur.kpss, ur.ers (com as regressões auxiliares completas)
library(lmtest)     # coeftest
library(FinTS)      # ArchTest (ARCH-LM)
library(strucchange) # Chow e CUSUM (aula 03)

arq <- if (file.exists("dados/inpc_lista01.csv")) "dados/inpc_lista01.csv" else "lista01/dados/inpc_lista01.csv"
dados <- read.csv(arq)
P  <- ts(dados$indice, start = c(2013, 1), frequency = 12)   # índice em nível
y  <- 100 * log(P)                                           # série modelada
dy <- diff(y)                                                # inflação mensal (%)
length(y)                                                    # T >= 120
```

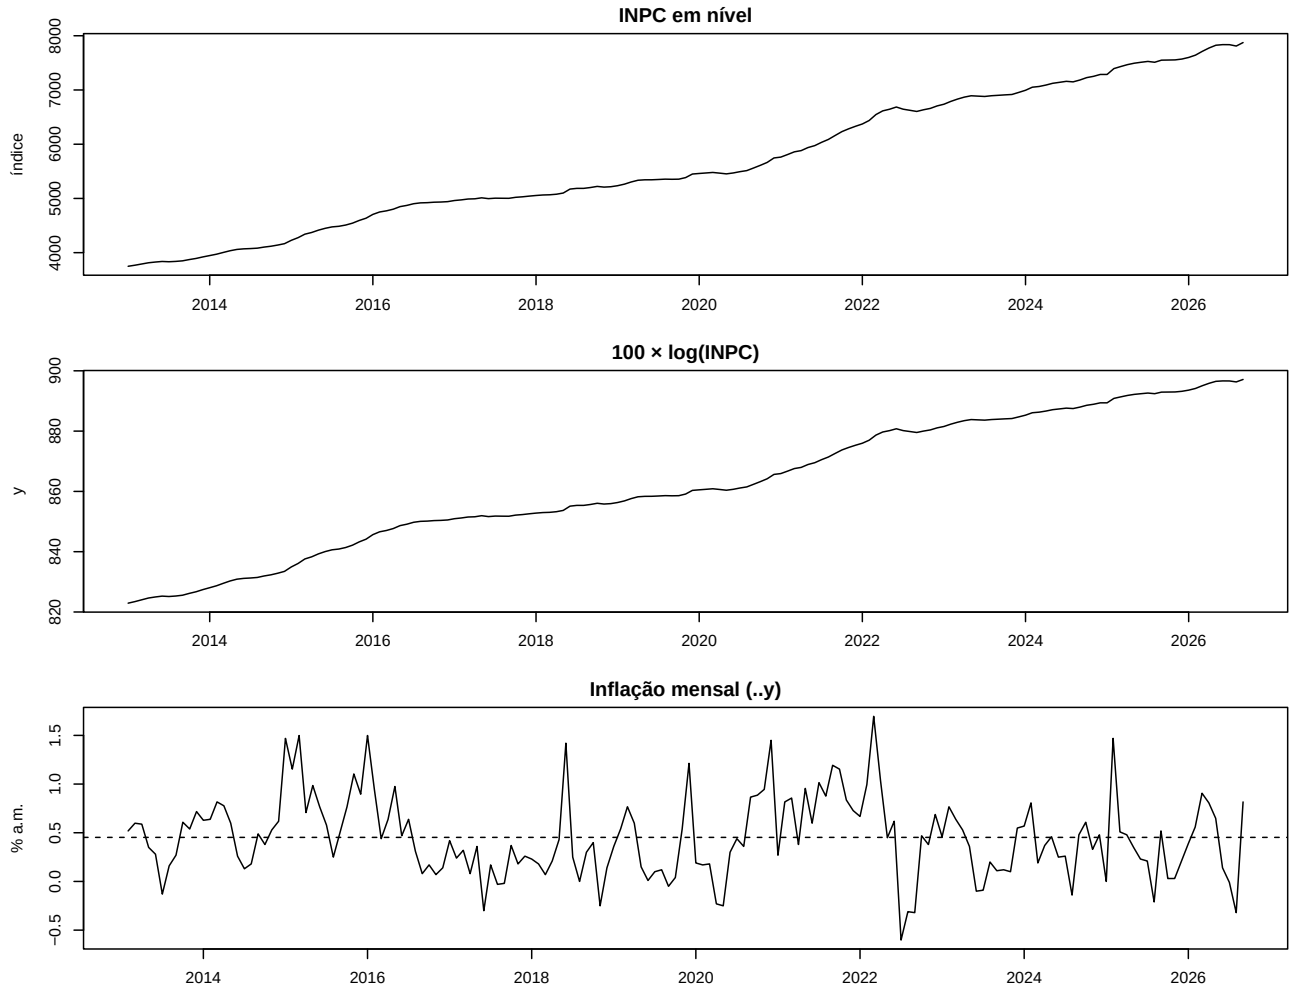
```
#> [1] 165
```

```
summary(as.numeric(dy))
```

```
#>    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
#> -0.6019  0.1774  0.4240  0.4525  0.6727  1.6956
```

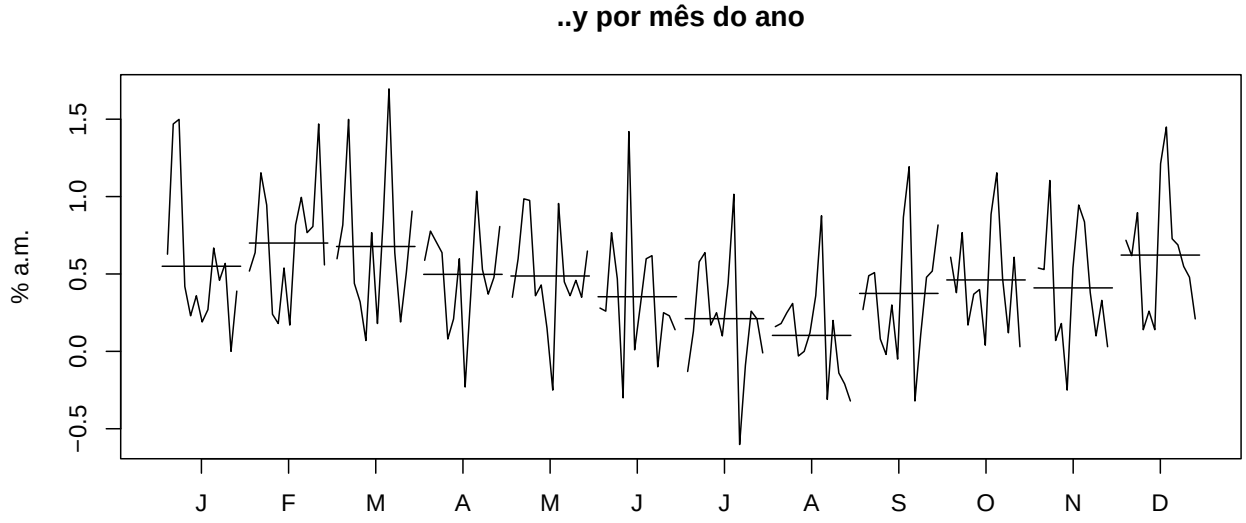
Questão 1 — Inspeção gráfica e transformação

```r
par(mfrow = c(3, 1), mar = c(3, 4, 2, 1))
plot(P,  main = "INPC em nível", ylab = "índice", xlab = "")
plot(y,  main = "100 × log(INPC)", ylab = "y", xlab = "")
plot(dy, main = "Inflação mensal (Δy)", ylab = "% a.m.", xlab = ""); abline(h = mean(dy), lty = 2)
```




```r
par(mfrow = c(1, 1))
```

```r
monthplot(dy, main = "Δy por mês do ano", ylab = "% a.m.")
```




```
round(tapply(as.numeric(dy), floor(time(dy) + 1e-9), mean), 2)   # inflação média de cada ano
```

```
#> 2013 2014 2015 2016 2017 2018 2019 2020 2021 2022 2023 2024 2025 2026
#> 0.41 0.50 0.89 0.53 0.17 0.28 0.37 0.44 0.81 0.48 0.30 0.39 0.32 0.44
```

Resposta (a).

- **Tendência:** forte no nível (o índice dobra em 13 anos). Em log, vira quase uma reta.
- **Inclinação:** a inclinação do log (a inflação) muda. A média anual vai de 0,17% a.m.
(2017) a 0,89% a.m. (2015): alta em 2015–2016 e no pós-pandemia, baixa em 2017–2019.
- **Nível:** não há mudança de nível; choques no índice não são revertidos.
- **Sazonalidade:** aparece só em Δy. Fevereiro, março e dezembro são altos, agosto é baixo.
- **Outliers:** os maiores Δy estão em mar/2022, jan/2016, mar/2015 e fev/2025; o menor, em jul/2022. Os choques que o modelo não explica aparecem nos resíduos (Q5).
- **Dispersão:** muda pouco com o nível nesta janela (o índice só dobra em 13 anos), e o gráfico não decide sozinho a transformação.

Transformação: log. Quem decide é a interpretação: com log, Δy é a taxa de inflação e o drift é uma taxa média, que pode ser constante. Sem log, o drift seria um aumento em pontos de índice, que cresce com o nível. # Questão 2 — Ordem de integração

(a) ADF, PP e KPSS no nível

Regressão do ADF: $\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_i \delta_i \Delta y_{t-i} + e_t$.

- **ADF e PP:** H_0 é raiz unitária ($\gamma = 0$).
- **KPSS:** H_0 é estacionariedade.

As defasagens do ADF são escolhidas por AIC, até 13 (regra de Schwert, $12(T/100)^{1/4}$).

```
adf_ct <- ur.df(y, type = "trend", lags = 13, selectlags = "AIC")
summary(adf_ct)
```

```
#>
#> ###############################################
#> # Augmented Dickey-Fuller Test Unit Root Test #
#> ###############################################
#>
```

```
#> Test regression trend
#>
#>
#> Call:
#> lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)
#>
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#> -0.98423 -0.20477 -0.00534  0.16454  1.21624
#>
#> Coefficients:
#>              Estimate Std. Error t value Pr(>|t|)
#> (Intercept) 23.733501   9.971220   2.380   0.0186 *
#> z.lag.1     -0.028469   0.012080  -2.357   0.0198 *
#> tt           0.012115   0.005394   2.246   0.0262 *
#> z.diff.lag1  0.429117   0.081802   5.246 5.37e-07 ***
#> z.diff.lag2  0.171394   0.083175   2.061   0.0411 *
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 0.3572 on 146 degrees of freedom
#> Multiple R-squared:  0.3111, Adjusted R-squared:  0.2923
#> F-statistic: 16.49 on 4 and 146 DF,  p-value: 3.618e-11
#>
#>
#> Value of test-statistic is: -2.3567 7.4491 3.0468
#>
#> Critical values for test statistics:
#>       1pct  5pct 10pct
#> tau3 -3.99 -3.43 -3.13
#> phi2  6.22  4.75  4.07
#> phi3  8.43  6.49  5.47
```

```
summary(ur.pp(y, type = "Z-tau", model = "trend", lags = "long"))
```

```
#>
#> ###################################
#> # Phillips-Perron Unit Root Test #
#> ###################################
#>
#> Test regression with intercept and trend
#>
#>
#> Call:
#> lm(formula = y ~ y.l1 + trend)
#>
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#> -0.95987 -0.28227 -0.02666  0.25634  1.30575
#>
#> Coefficients:
#>              Estimate Std. Error t value Pr(>|t|)
#> (Intercept) 12.503940  11.114130   1.125    0.262
#> y.l1         0.986017   0.012896  76.458   <2e-16 ***
#> trend        0.005318   0.005863   0.907    0.366
#> ---
```

```
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 0.4109 on 161 degrees of freedom
#> Multiple R-squared:  0.9996, Adjusted R-squared:  0.9996
#> F-statistic: 2.239e+05 on 2 and 161 DF,  p-value: < 2.2e-16
#>
#>
#> Value of test-statistic, type: Z-tau  is: -1.963
#>
#>            aux. Z statistics
#> Z-tau-mu             -0.7713
#> Z-tau-beta            2.4426
#>
#> Critical values for Z statistics:
#>                      1pct      5pct     10pct
#> critical values -4.016497 -3.437891 -3.142926
```

```
summary(ur.kpss(y, type = "tau", lags = "long"))
```

```
#>
#> ######################
#> # KPSS Unit Root Test #
#> ######################
#>
#> Test is of type: tau with 13 lags.
#>
#> Value of test-statistic is: 0.0822
#>
#> Critical value for a significance level of:
#>                 10pct  5pct 2.5pct  1pct
#> critical values 0.119 0.146  0.176 0.216
```

(b) Constante e tendência

Cada versão do ADF compara hipóteses diferentes (Mattos, 2019, seção 2.2):

- **constante e tendência:** H_0 DS (tendência determinística mais estocástica) contra H_1 TS (só determinística); as duas são não estacionárias;
- **só constante:** H_0 I(1) contra H_1 estacionária em torno de uma média;
- **nada:** H_0 I(1) contra H_1 estacionária com média zero.

A versão se escolhe pelo gráfico: y cresce, então constante e tendência. Os p-valores vêm de MacKinnon (`punitroot`).

```
tau <- c(tau3 = adf_ct@teststat[1, "tau3"],
         tau2 = ur.df(y, type = "drift", lags = 13, selectlags = "AIC")@teststat[1, "tau2"],
         tau1 = ur.df(y, type = "none",  lags = 13, selectlags = "AIC")@teststat[1, "tau1"])
rbind(tau, p = c(punitroot(tau[1], trend = "ct"), punitroot(tau[2], trend = "c"), punitroot(tau[3], trend = "nc")))
```

```
#>           tau3      tau2      tau1
#> tau -2.3567094 -1.010274 3.9350441
#> p    0.4025205  0.751864 0.9999843
```

Resposta. Nenhuma versão rejeita. Na versão com tendência, isso quer dizer que a série é **DS**: $y_t = y_0 + \alpha t + \sum_{j \le t} u_j$, uma tendência determinística (o drift, a inflação média) mais uma estocástica. Sem determinísticos, τ_1 é positivo: o teste confunde a tendência omitida com explosividade.

(c) Série diferenciada e diferença sazonal

```
summary(ur.df(dy, type = "drift", lags = 13, selectlags = "AIC"))@teststat
```

```
#>                tau2     phi1
#> statistic -5.159213 13.31178
```

```
kpss.test(dy)                          # H0: estacionária
```

```
#>
#>  KPSS Test for Level Stationarity
#>
#> data:  dy
#> KPSS Level = 0.16442, Truncation lag parameter = 4, p-value = 0.1
```

Para D, segue-se Mattos (2019, seção 2.6): o ADF com 11 dummies sazonais **centradas** na regressão auxiliar (Dickey-Miller). As dummies captam a sazonalidade determinística, e τ mantém os críticos do ADF.

```
adf_saz <- function(x, tendencia, pmax = 13) {
  dx <- diff(x); m <- cycle(dx); idx <- (pmax + 1):length(dx)
  DC <- sapply(1:11, function(j) ifelse(m == j, 1 - 1 / 12, -1 / 12)); colnames(DC) <- paste0("DC", 1:11)
  ajuste <- function(p) {
    X <- cbind(nivel = as.numeric(x)[idx], DC[idx, ])
    if (p > 0) X <- cbind(X, sapply(1:p, function(j) as.numeric(dx)[idx - j]))
    if (tendencia) X <- cbind(X, tt = idx)
    lm(as.numeric(dx)[idx] ~ X)
  }
  p <- which.min(sapply(0:pmax, function(k) BIC(ajuste(k)))) - 1
  cf <- summary(ajuste(p))$coefficients
  c(tau = cf["Xnivel", "t value"], defasagens = p, dummies_signif = sum(cf[grepl("^XDC", rownames(cf)), 4] < 0.05))
}
rbind(y = adf_saz(y, TRUE), dy = adf_saz(dy, FALSE))
```

```
#>          tau defasagens dummies_signif
#> y  -2.207251          2              4
#> dy -6.743067          0              3
```

```
acf(dy, lag.max = 36, plot = FALSE)$acf[c(13, 25, 37)]   # FAC de Δy em 12, 24, 36
```

```
#> [1]  0.21609575 -0.03133938  0.01758861
```

Resposta. Em Δy, o ADF rejeita com folga e o KPSS não rejeita: $d = 1$. Com as dummies, o nível continua sem rejeitar ($-2{,}21$ contra $-3{,}43$) e Δy continua rejeitando; várias dummies são significativas, logo a sazonalidade é determinística. A FAC sazonal de Δy cai logo (0,22 em 12, quase zero em 24 e 36), sem o decaimento lento de uma raiz sazonal: $D = 0$.

(d) DS ou TS?

No nível, ADF e PP não rejeitam a raiz unitária, e o KPSS também não rejeita a estacionariedade: os dados são pouco informativos. O DF-GLS (Mattos, 2019, seção 2.4), mais potente contra alternativas persistentes, também não rejeita:

```
summary(ur.ers(y, type = "DF-GLS", model = "trend", lag.max = 1))   # 1 defasagem, a do ADF por BIC
```

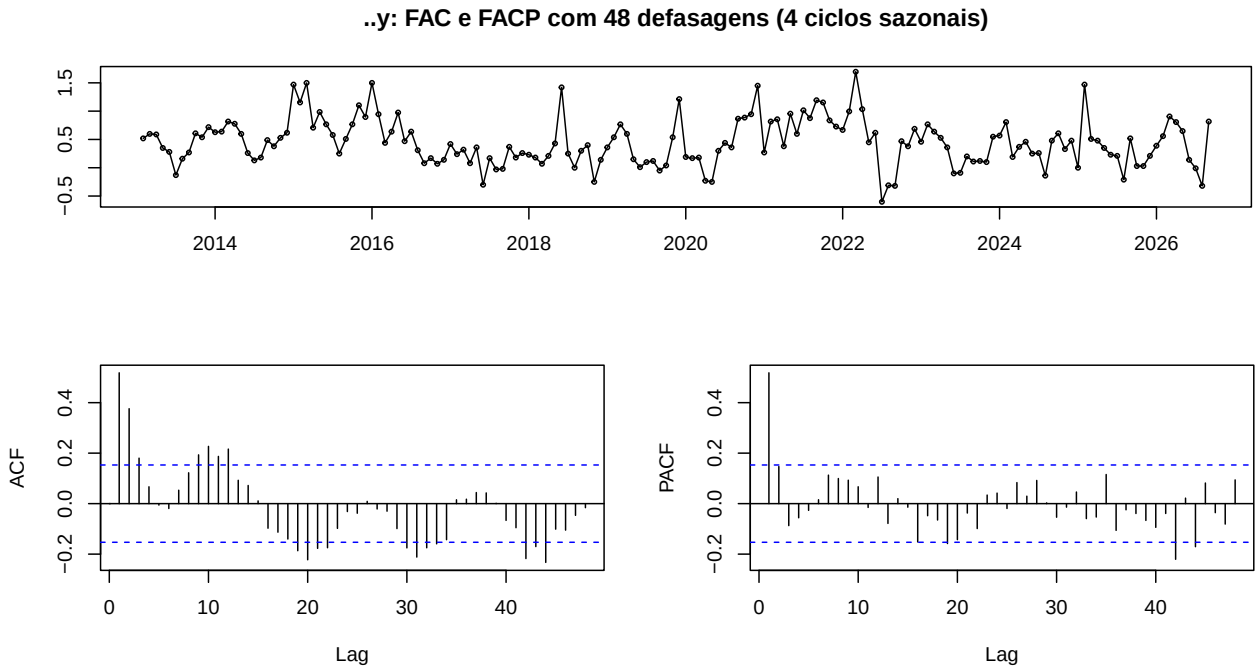
```
#>
#> ###############################################
#> # Elliot, Rothenberg and Stock Unit Root Test #
#> ###############################################
#>
#> Test of type DF-GLS
#> detrending of series with intercept and trend
#>
```

```
#>
#> Call:
#> lm(formula = dfgls.form, data = data.dfgls)
#>
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#> -1.06159 -0.18542 -0.00639  0.17683  1.23612
#>
#> Coefficients:
#>              Estimate Std. Error t value Pr(>|t|)
#> yd.lag       -0.01776    0.01042  -1.704   0.0902 .
#> yd.diff.lag1  0.53237    0.06719   7.923  3.6e-13 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 0.3516 on 161 degrees of freedom
#> Multiple R-squared:  0.2833, Adjusted R-squared:  0.2744
#> F-statistic: 31.82 on 2 and 161 DF,  p-value: 2.261e-12
#>
#>
#> Value of test-statistic is: -1.7044
#>
#> Critical values of DF-GLS are:
#>                  1pct  5pct 10pct
#> critical values -3.46 -2.93 -2.64
```

Adota-se DS ($d = 1$). As razões:

1. Todos os testes de raiz unitária (ADF com e sem dummies, PP, DF-GLS) apontam DS.
2. O KPSS tem pouco poder em amostra curta.
3. Sob metas de inflação, o nível de preços não volta a uma trajetória fixa.
4. A Q5 mostra que Δy não tem MA unitário, que seria o sinal de diferenciação em excesso. # Questão 3 — FAC, FACP e candidatos

```
tsdisplay(dy, lag.max = 48, main = "Δy: FAC e FACP com 48 defasagens (4 ciclos sazonais)")
```




```r
round(cbind(FAC = acf(dy, 13, plot = FALSE)$acf[-1], FACP = pacf(dy, 13, plot = FALSE)$acf), 3)
```

```
#>          FAC   FACP
#>  [1,]  0.518  0.518
#>  [2,]  0.376  0.147
#>  [3,]  0.180 -0.087
#>  [4,]  0.067 -0.056
#>  [5,] -0.006 -0.027
#>  [6,] -0.019  0.015
#>  [7,]  0.053  0.113
#>  [8,]  0.122  0.099
#>  [9,]  0.193  0.093
#> [10,]  0.227  0.067
#> [11,]  0.187 -0.015
#> [12,]  0.216  0.105
#> [13,]  0.092 -0.078
```

Resposta (b).

- **Parte regular:** a FACP tem um pico claro em 1, e o valor em 2 fica no limite da banda (±0,15). A FAC decai: AR(1), com o AR(2) como alternativa.
- **Defasagem sazonal:** há um pico em 12 na FAC (dentro da banda na FACP). Ele cabe tanto num SAR(1) (decaimento em 12, 24, ...) quanto num SMA(1) (corte em 12).

(c) Candidatos, todos com $d = 1$, $D = 0$ e drift (a inflação média):

- **C1:** SARIMA(1,1,0)$(1,0,0)_{12}$;
- **C2:** SARIMA(1,1,0)$(0,0,1)_{12}$;
- **C3:** SARIMA(2,1,0)$(1,0,0)_{12}$. # Questão 4 — Estimação e seleção

```r
C1 <- Arima(y, order = c(1, 1, 0), seasonal = c(1, 0, 0), include.drift = TRUE, method = "ML")
C2 <- Arima(y, order = c(1, 1, 0), seasonal = c(0, 0, 1), include.drift = TRUE, method = "ML")
C3 <- Arima(y, order = c(2, 1, 0), seasonal = c(1, 0, 0), include.drift = TRUE, method = "ML")
coeftest(C1); coeftest(C2); coeftest(C3)
```

```
#>
#> z test of coefficients:
#>
#>       Estimate Std. Error z value  Pr(>|z|)
#> ar1   0.506437   0.067211  7.5350 4.883e-14 ***
#> sar1  0.178301   0.077769  2.2927   0.02186 *
#> drift 0.453309   0.065131  6.9600 3.403e-12 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
#>
#> z test of coefficients:
#>
#>       Estimate Std. Error z value  Pr(>|z|)
#> ar1   0.503540   0.067696  7.4383 1.020e-13 ***
#> sma1  0.166043   0.074046  2.2424   0.02493 *
#> drift 0.453728   0.062445  7.2661 3.701e-13 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
#>
#> z test of coefficients:
#>
#>       Estimate Std. Error z value  Pr(>|z|)
#> ar1   0.441476   0.078072  5.6547 1.561e-08 ***
#> ar2   0.125824   0.079049  1.5917   0.11145
#> sar1  0.165444   0.078553  2.1061   0.03519 *
#> drift 0.452989   0.072444  6.2530 4.027e-10 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
tab <- rbind(C1 = c(C1$nobs, C1$sigma2, C1$loglik, C1$aic, C1$bic),
             C2 = c(C2$nobs, C2$sigma2, C2$loglik, C2$aic, C2$bic),
             C3 = c(C3$nobs, C3$sigma2, C3$loglik, C3$aic, C3$bic))
colnames(tab) <- c("n efetivo", "sigma2", "logLik", "AIC", "BIC")
round(tab, 3)
```

```
#>    n efetivo sigma2  logLik     AIC     BIC
#> C1       164  0.126 -58.809 125.618 138.017
#> C2       164  0.126 -58.983 125.966 138.366
#> C3       164  0.125 -57.552 125.104 140.603
```

(b) $n = T - d - sD = 165 - 1 = 164$ nos três modelos.

(c) A comparação é **válida**: os três modelos têm a mesma variável, o mesmo d e o mesmo D, logo a mesma amostra efetiva. Com d diferente, a verossimilhança seria de outra série, e o AIC deixaria de ser comparável.

(d) O R conta $\hat{\sigma}^2$ em k, como mostra a conta à mão:

```
k <- length(coef(C1)) + 1                    # coeficientes + sigma2
c(AIC_manual = -2 * C1$loglik + 2 * k, AIC_R = C1$aic)
```

```
#> AIC_manual      AIC_R
#>   125.6178   125.6178
```

(e) O AIC escolhe **C3** e o BIC escolhe **C1**: o BIC pune mais cada parâmetro ($\ln n \approx 5{,}1$ contra 2).

- O BIC é **consistente**: escolhe o modelo verdadeiro, se ele estiver entre os candidatos, com probabilidade que tende a 1.
- O AIC é **eficiente** para prever.

O objetivo aqui é prever (Q7), o que favorece o AIC. Mas a vantagem do C3 é de só 0,5 ponto de AIC e vem de um ϕ_2 não significativo:

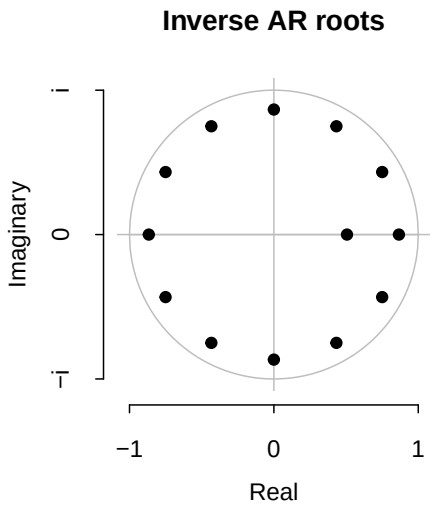
```
coeftest(C3)["ar2", ]
```

```
#>   Estimate Std. Error    z value   Pr(>|z|)
#> 0.12582411 0.07904902 1.59172253 0.11144706
```

Fica o **C1**, o mais parcimonioso (aula 02). A regra, fixada antes de olhar a validação: se AIC e BIC divergem, fica o modelo menor quando o parâmetro extra do maior não é significativo a 5%.

(f) Raízes inversas dentro do círculo unitário: o modelo é estacionário.

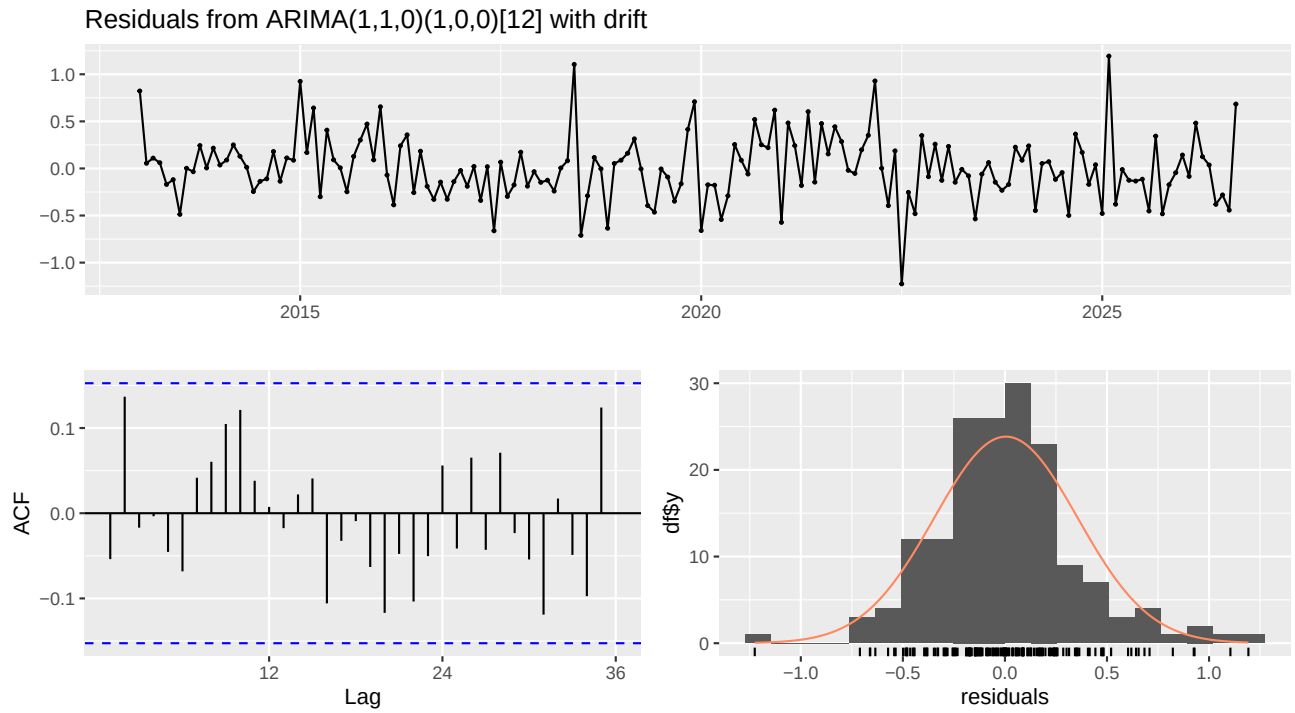
```
plot(C1)
```



A raiz inversa regular é $\hat{\phi} \approx 0{,}51$. As 12 sazonais têm módulo $\widehat{\Phi}^{1/12} \approx 0{,}87$: um $\widehat{\Phi}$ pequeno vira raízes inversas de módulo alto, mas ainda dentro do círculo. # Questão 5 — Diagnóstico

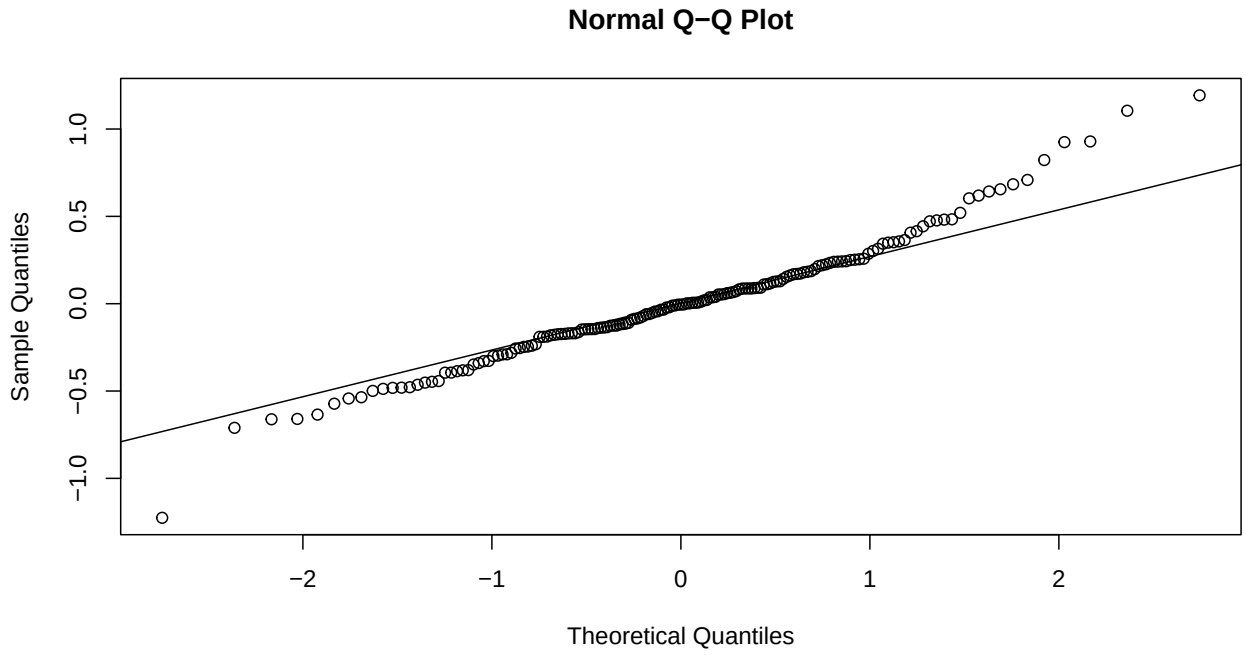
(a) O painel abaixo mostra os resíduos no tempo, a FAC e o histograma. O `checkresiduals` já roda o Ljung-Box com os graus de liberdade corrigidos. O QQ-plot vem em seguida.

```
checkresiduals(C1, lag = 24)
```




```
#>
#>  Ljung-Box test
#>
#> data:  Residuals from ARIMA(1,1,0)(1,0,0)[12] with drift
#> Q* = 20.318, df = 22, p-value = 0.5632
#>
#> Model df: 2.   Total lags used: 24
```

```
qqnorm(residuals(C1)); qqline(residuals(C1))
```



(b) e (c) Os testes. No Ljung-Box, $\nu = K - (p + q + P + Q) = 24 - 2 = 22$.

```
Box.test(residuals(C1), lag = 24, type = "Ljung-Box", fitdf = 2)
```

```
#>
#>  Box-Ljung test
#>
#> data:  residuals(C1)
#> X-squared = 20.318, df = 22, p-value = 0.5632
```

```
jarque.bera.test(residuals(C1))
```

```
#>
#>  Jarque Bera Test
#>
#> data:  residuals(C1)
#> X-squared = 18.121, df = 2, p-value = 0.0001162
```

```
ArchTest(residuals(C1), lags = 12)
```

```
#>
#>  ARCH LM-test; Null hypothesis: no ARCH effects
#>
#> data:  residuals(C1)
#> Chi-squared = 5.9531, df = 12, p-value = 0.9184
```

Resposta.

- **Ljung-Box:** não rejeita; os resíduos são ruído branco.
- **ARCH-LM:** não rejeita; não há heterocedasticidade condicional.
- **Jarque-Bera: rejeita** a normalidade, por caudas pesadas.

(d) O diagnóstico de autocorrelação não falhou. A não normalidade vem de choques pontuais (greve dos caminhoneiros em 2018, corte de tributos em 2022, bônus de Itaipu em 2025). Ela afeta os intervalos de previsão, mas não a consistência do estimador. Modelos sem o AR(1) foram descartados, porque deixam autocorrelação nos resíduos (Ljung-Box rejeita).

Estabilidade (aula 03). Chow com a quebra fixada antes (mar/2020) e CUSUM dos resíduos recursivos, na versão de MQO do C1 (Δy_t em Δy_{t-1}, Δy_{t-12} e Δy_{t-13}):

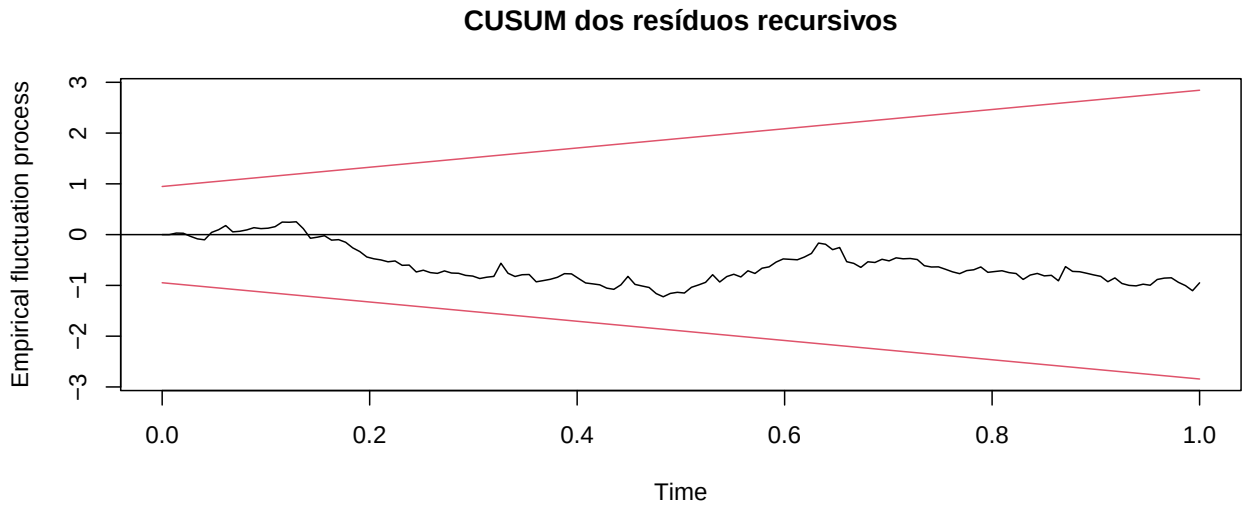
```
dyv <- as.numeric(dy); nn <- length(dyv)
df_ols <- data.frame(dy = dyv[14:nn], l1 = dyv[13:(nn - 1)], l12 = dyv[2:(nn - 12)], l13 = dyv[1:(nn - 13)])
TB <- which(abs(time(dy)[14:nn] - (2020 + 2 / 12)) < 1e-6)
sctest(dy ~ ., data = df_ols, type = "Chow", point = TB - 1)
```

```
#>
#>  Chow test
#>
#> data:  dy ~ .
#> F = 0.4573, p-value = 0.7669
```

```
cusum <- efp(dy ~ ., data = df_ols, type = "Rec-CUSUM")
sctest(cusum)
```

```
#>
#>  Recursive CUSUM test
#>
#> data:  cusum
#> S = 0.62251, p-value = 0.3716
```

```
plot(cusum, main = "CUSUM dos resíduos recursivos")
```



Nenhum dos dois rejeita: os coeficientes são estáveis na janela de 13 anos.

(e) Sobreajuste: um AR e um MA a mais.

```
coeftest(Arima(y, order = c(2, 1, 0), seasonal = c(1, 0, 0), include.drift = TRUE, method = "ML"))["ar2", ]
```

```
#>   Estimate Std. Error    z value   Pr(>|z|)
#> 0.12582411 0.07904902 1.59172253 0.11144706
```

```
coeftest(Arima(y, order = c(1, 1, 1), seasonal = c(1, 0, 0), include.drift = TRUE, method = "ML"))["ma1", ]
```

```
#>   Estimate Std. Error    z value   Pr(>|z|)
#> -0.1732418  0.1258123 -1.3769865  0.1685164
```

Resposta. Nenhum dos coeficientes extras é significativo, então a especificação está adequada. O MA extra fica longe de -1, o que confirma que Δy não foi sobrediferenciada. # Questão 6 — Sobrediferenciação ($d^* + 1 = 2$)

```
D2  <- Arima(y, order = c(1, 2, 0), seasonal = c(1, 0, 0), method = "ML")   # mesmas ordens
D2m <- Arima(y, order = c(1, 2, 1), seasonal = c(1, 0, 0), method = "ML")   # com um MA a mais
coeftest(D2m)
```

```
#>
#> z test of coefficients:
#>
#>       Estimate Std. Error  z value  Pr(>|z|)
#> ar1   0.515253   0.068065   7.5700 3.733e-14 ***
#> ma1  -1.000000   0.022023 -45.4079 < 2.2e-16 ***
#> sar1  0.184267   0.078266   2.3544   0.01855 *
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
abs(polyroot(c(1, coef(D2m)["ma1"])))                 # raiz do MA
```

```
#> [1] 1
```

```
c(sigma2_d1 = C1$sigma2, sigma2_d2 = D2$sigma2, sigma2_d2_MA = D2m$sigma2)
```

```
#>    sigma2_d1    sigma2_d2 sigma2_d2_MA
#>    0.1258763    0.1508776    0.1308745
```

```
c(rho1_d1 = acf(residuals(C1), plot = FALSE)$acf[2], rho1_d2 = acf(residuals(D2), plot = FALSE)$acf[2],
  rho1_serie_d2 = acf(diff(dy), plot = FALSE)$acf[2])
```

```
#>       rho1_d1       rho1_d2 rho1_serie_d2
#>   -0.05386913   -0.04942052   -0.33881841
```

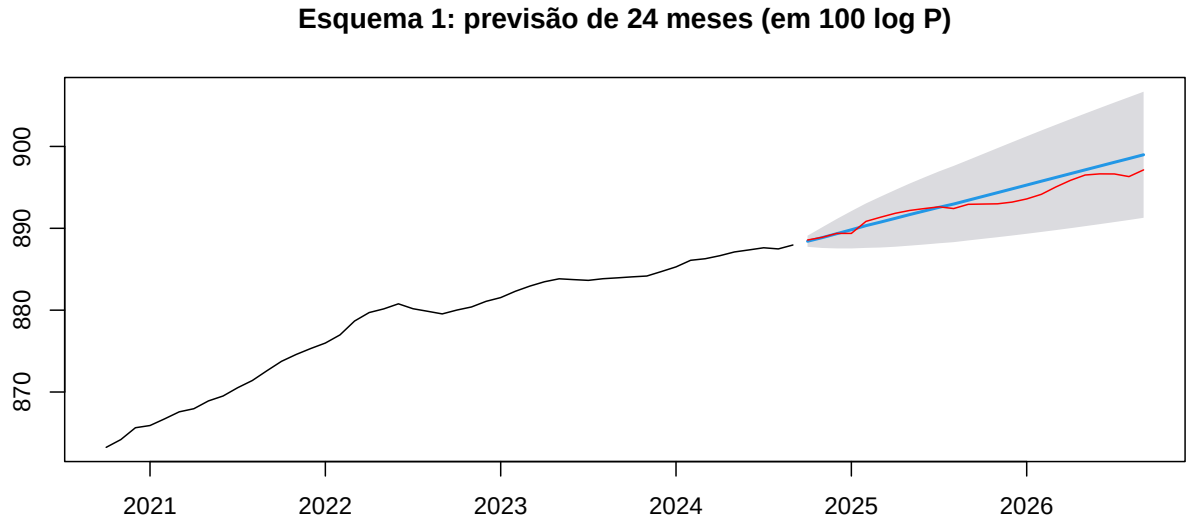
Resposta.

- **(a)** $\hat{\theta} \approx -1$ (na convenção da lista, $\theta = 1$). A raiz do MA é 1, **sobre o círculo unitário**: o modelo fica não invertível.
- **(b)** $\hat{\sigma}^2$ aumenta com a diferença extra, cerca de 20% sem o MA.
- **(c)** A série $\Delta^2 y$ tem ρ_1 negativo, perto de $-(1-\phi)/2$. No modelo, o AR troca de sinal para absorver esse ρ_1.
- **(d)** Os sinais práticos de sobrediferenciação: MA perto de -1, AR que troca de sinal, $\rho_1 \approx -0{,}5$ e σ^2 que sobe. # Questão 7 — Previsão fora da amostra

O treino vai até $T_0 = T - 24$, e os 24 meses finais são a validação. As métricas são calculadas no índice $P = e^{y/100}$.

```r
T0 <- length(y) - 24
y_treino <- window(y, end = time(y)[T0])
P_treino <- window(P, end = time(P)[T0])
P_teste  <- window(P, start = time(P)[T0 + 1])
fit <- Arima(y_treino, order = c(1, 1, 0), seasonal = c(1, 0, 0), include.drift = TRUE, method = "ML")   # C1

# Esquema 1: origem fixa, h = 1..24, com IC de 95%
prev1 <- forecast(fit, h = 24, level = 95)
plot(prev1, include = 48, main = "Esquema 1: previsão de 24 meses (em 100 log P)")
lines(window(y, start = time(y)[T0 + 1]), col = "red")
```




```r
# Esquema 2: um passo à frente, SEM reestimar (mesmos coeficientes do treino)
prev2 <- window(fitted(Arima(y, model = fit)), start = time(y)[T0 + 1])

# Benchmarks no índice: passeio aleatório e sazonal ingênuo
rw1 <- naive(P_treino, h = 24)$mean                                  # origem fixa
sn1 <- snaive(P_treino, h = 24)$mean
rw2 <- window(stats::lag(P, -1), start = start(P_teste), end = end(P_teste))    # um passo: P_{t-1}
sn2 <- window(stats::lag(P, -12), start = start(P_teste), end = end(P_teste))   # um passo: P_{t-12}

metricas <- c("RMSE", "MAE", "MAPE")
rbind("SARIMA, esquema 1"            = accuracy(exp(prev1$mean / 100), P_teste)[, metricas],
      "SARIMA, esquema 2"            = accuracy(exp(prev2 / 100), P_teste)[, metricas],
      "Passeio aleatório, esquema 1" = accuracy(rw1, P_teste)[, metricas],
```

```
      "Passeio aleatório, esquema 2" = accuracy(rw2, P_teste)[, metricas],
      "Sazonal ingênuo, esquema 1"   = accuracy(sn1, P_teste)[, metricas],
      "Sazonal ingênuo, esquema 2"   = accuracy(sn2, P_teste)[, metricas])
```

```
#>                                  RMSE       MAE      MAPE
#> SARIMA, esquema 1              81.54227  65.94999 0.8611550
#> SARIMA, esquema 2              30.69034  22.38202 0.2957467
#> Passeio aleatório, esquema 1 425.13541 379.63083 4.9583361
#> Passeio aleatório, esquema 2  40.88458  32.23250 0.4259191
#> Sazonal ingênuo, esquema 1   525.33598 501.93250 6.5949984
#> Sazonal ingênuo, esquema 2   328.65202 326.97292 4.3288906
```

```
# (g) cobertura do IC de 95% do esquema 1
mean(P_teste >= exp(prev1$lower / 100) & P_teste <= exp(prev1$upper / 100))
```

```
#> [1] 1
```

Resposta.

- **(f)** O SARIMA supera o passeio aleatório e o sazonal ingênuo nos dois esquemas e nas três métricas. O sazonal ingênuo vai muito mal porque, no índice, ele repete o nível de 12 meses antes, sem a inflação do ano. O modelo não foi alterado em função desses resultados.
- **(g)** Todas as 24 observações caíram dentro do IC de 95% do esquema 1: a cobertura empírica (100%) é maior que a nominal. O intervalo de um modelo integrado se abre com h, e os 24 erros de uma única origem são correlacionados entre si.

Versões do software (exigidas na entrega):

```
sessionInfo()
```

```
#> R version 4.3.3 (2024-02-29)
#> Platform: x86_64-pc-linux-gnu (64-bit)
#> Running under: Ubuntu 24.04.5 LTS
#>
#> Matrix products: default
#> BLAS:   /usr/lib/x86_64-linux-gnu/blas/libblas.so.3.12.0
#> LAPACK: /usr/lib/x86_64-linux-gnu/lapack/liblapack.so.3.12.0
#>
#> locale:
#>  [1] LC_CTYPE=C.UTF-8       LC_NUMERIC=C           LC_TIME=C.UTF-8
#>  [4] LC_COLLATE=C.UTF-8     LC_MONETARY=C.UTF-8    LC_MESSAGES=C.UTF-8
#>  [7] LC_PAPER=C.UTF-8       LC_NAME=C              LC_ADDRESS=C
#> [10] LC_TELEPHONE=C         LC_MEASUREMENT=C.UTF-8 LC_IDENTIFICATION=C
#>
#> time zone: Etc/UTC
#> tzcode source: system (glibc)
#>
#> attached base packages:
#> [1] stats     graphics  grDevices utils     datasets  methods   base
#>
#> other attached packages:
#> [1] strucchange_1.5-3 sandwich_3.1-0    FinTS_0.4-9       lmtest_0.9-40
#> [5] zoo_1.8-12        urca_1.3-3        tseries_0.10-55   forecast_8.21.1
#>
#> loaded via a namespace (and not attached):
#>  [1] gtable_0.3.4      dplyr_1.1.4       compiler_4.3.3    tidyselect_1.2.0
#>  [5] Rcpp_1.0.12       parallel_4.3.3    scales_1.3.0      yaml_2.3.8
#>  [9] fastmap_1.1.1     lattice_0.22-5    ggplot2_3.4.4     R6_2.5.1
#> [13] labeling_0.4.3    generics_0.1.3    curl_5.2.0        knitr_1.45
```

```
#> [17] tibble_3.2.1      munsell_0.5.0     nnet_7.3-19       timeDate_4032.109
#> [21] pillar_1.9.0      rlang_1.1.3       quantmod_0.4.26   utf8_1.2.4
#> [25] xfun_0.41         quadprog_1.5-8    cli_3.6.2         withr_2.5.0
#> [29] magrittr_2.0.3    xts_0.13.2        digest_0.6.34     grid_4.3.3
#> [33] nlme_3.1-164      lifecycle_1.0.4   fracdiff_1.5-3    vctrs_0.6.5
#> [37] evaluate_0.23     glue_1.7.0        farver_2.1.1      fansi_1.0.5
#> [41] colorspace_2.1-0  TTR_0.24.4        rmarkdown_2.25    tools_4.3.3
#> [45] pkgconfig_2.0.3   htmltools_0.5.7
```