Lista 01 — Modelagem Box-Jenkins do INPC

Econometria II · PPGEco/UFES · Avaliação parcial, parte empírica (Questões 1 a 7)

[nomes da dupla]

27/10/2026

Sumário

Série, dados e reprodutibilidade 1

Questão 1. Inspeção gráfica e transformação 2

Questão 2. Ordem de integração 4
(a) ADF, PP e KPSS na série em nível . . . 4
(b) Constante e tendência na regressão auxiliar . . . 4
(c) Série diferenciada: d e D . . . 5
(d) Tendência estocástica ou determinística? . . . 6

Questão 3. Identificação 7

Questão 4. Estimação e seleção 9

Questão 5. Diagnóstico 11

Questão 6. Sobrediferenciação 13

Questão 7. Previsão fora da amostra 16

Síntese 18

Série, dados e reprodutibilidade

Série. INPC/IBGE, número-índice (dez/1993 = 100), mensal, de jan/2013 a set/2026, com $T = 165$ observações (o mínimo exigido é 120). Fonte: SIDRA, tabela 1736. A série não está em nenhum pacote do R.

Reprodutibilidade. A pasta entregue contém:

- os scripts `00_configuracao.R` a `07_previsao.R`, na ordem das questões;
- `rodar_tudo.R`, que executa tudo e gera este PDF;
- o banco `dados/inpc_lista01.csv`, que é exatamente o usado;
- `saidas/sessionInfo.txt`, com as versões do R e dos pacotes.

Nenhum número deste texto foi digitado à mão: todos vêm de `saidas/`, gerado pelos scripts. A estimação usa máxima verossimilhança exata (`forecast::Arima`, `method = "ML"`). Os testes de raiz unitária vêm do `urca`,

com p-valores de MacKinnon (1996). Só se usam ferramentas vistas nas aulas 01 a 03 e no texto de Mattos (2019), leitura do curso para raiz unitária, além das que o enunciado pede.

Variável modelada. $y_t = 100 \ln P_t$. Assim, Δy_t é a inflação mensal em pontos percentuais de log. A correlação entre Δy_t e a variação mensal publicada pelo IBGE é 1,00000.

Questão 1. Inspeção gráfica e transformação

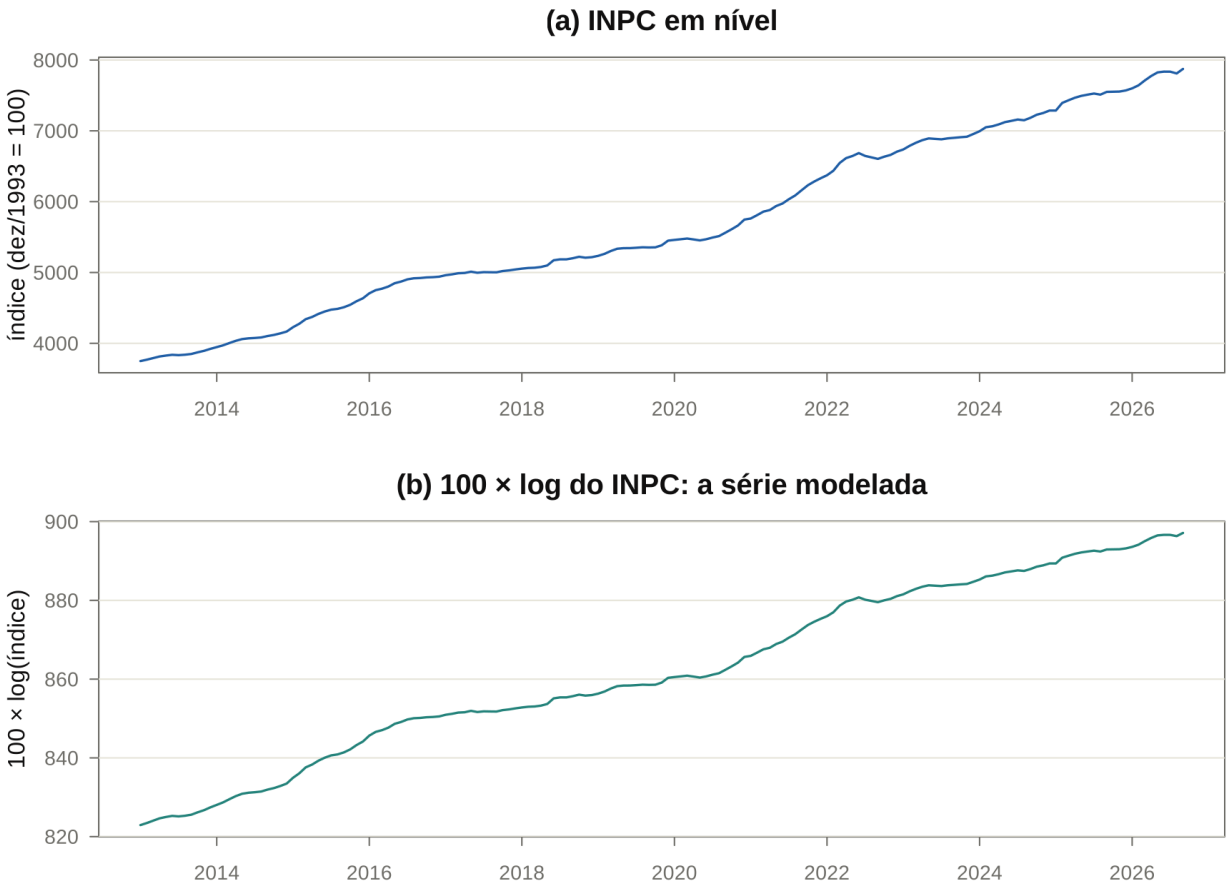


Figura 1: INPC em nível (a) e 100 × log do INPC (b).

(a) O que o gráfico mostra.

- **Tendência.** O índice sobe de 3.749 para 7.874 (2,10 vezes), sem nunca voltar. É uma tendência forte; em log, vira quase uma reta.
- **Mudanças de inclinação.** A inclinação do log do índice é a inflação, e ela muda de patamar (figura 3). A média anual da inflação vai de 0,17 % a.m. (em 2017) a 0,89 % a.m. (em 2015): mais alta em 2015–2016 (realinhamento de preços administrados) e no pós-pandemia (2021–2022), mais baixa em 2017–2019. Não há mudança de *nível* no índice: choques de preço não "voltam". A estabilidade formal dos parâmetros é testada na Questão 5, com Chow e CUSUM (aula 03).
- **Sazonalidade.** Ela é invisível no índice, mas aparece em Δy (painel (b) da figura seguinte). A inflação é maior em fevereiro (0,70), março (0,68) e dezembro (0,62), e menor em agosto (0,10). A Questão 2 testa se ela é determinística ou estocástica, e a Questão 3 a mede na FAC.

- **Outliers.** Os maiores valores de Δy estão na Tabela 1. Os de 2015–2016 e 2022 fazem parte dos regimes de inflação alta; os choques que o modelo não explica aparecem nos resíduos padronizados da Questão 5.
- **Dispersão.** No nível, a relação entre a amplitude e a média de cada ano é fraca nesta janela (painel (a) da figura seguinte). O índice só dobra em 13 anos, e a amplitude anual depende mais dos choques de cada ano do que do nível.

Tabela 1: Os quatro maiores valores e o menor valor da inflação mensal.

Mês	Δy (% a.m.)
mar/2022	1,70
jan/2016	1,50
mar/2015	1,50
fev/2025	1,47
jul/2022	-0,60

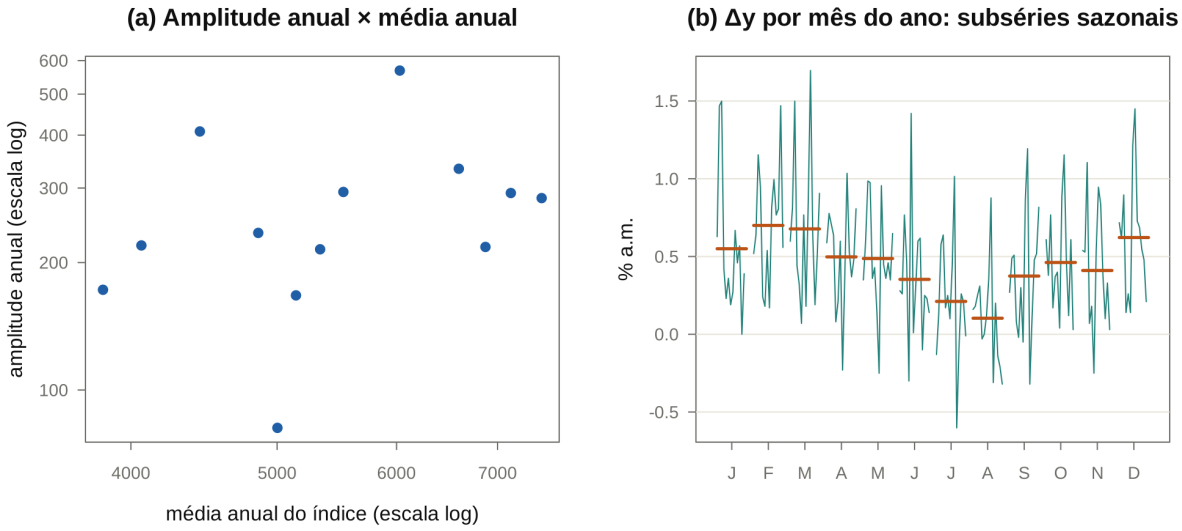


Figura 2: Amplitude anual contra a média anual do índice, em escala log-log (a), e subséries sazonais de Δy com a média de cada mês (b).

Transformação: logaritmo. O gráfico de amplitude contra média não mostra, nesta janela, uma relação forte entre dispersão e nível, e por isso não decide sozinho. Quem decide é a interpretação. Com o log, Δy é a inflação, a variável que a política monetária mira, e o drift do modelo é a inflação média, uma taxa que pode ser constante. Sem o log, o drift seria um aumento médio em *pontos de índice*, que não pode ser constante: o mesmo 0,5% de inflação vale 19 pontos em 2013 e 39 pontos em 2026. Por isso modela-se $y_t = 100 \ln P_t$, e as métricas de previsão da Questão 7 são calculadas depois de desfazer o log, como pede a aula 03.

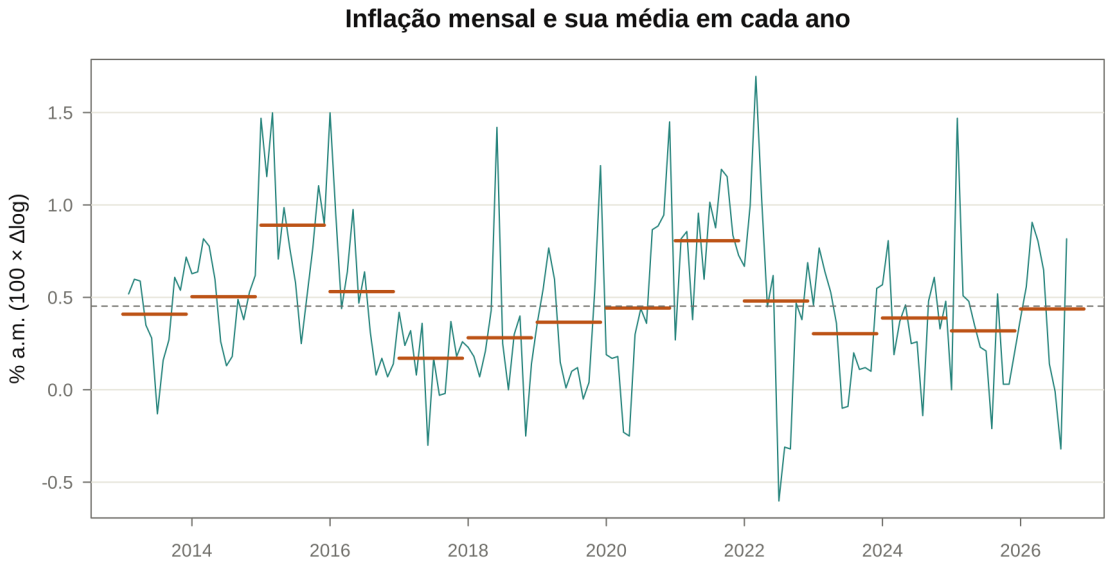


Figura 3: Inflação mensal (Δy) com a média de cada ano (laranja) e a média da amostra (tracejado).

Questão 2. Ordem de integração

A Questão 2 segue o texto de Mattos (2019), que organiza os processos em quatro tipos: estacionário (sem tendência), raiz unitária ou I(1) (só tendência estocástica), tendência estacionária, TS (só tendência determinística), e diferença estacionária, DS (as duas tendências, como num passeio com drift).

(a) ADF, PP e KPSS na série em nível

A defasagem máxima do ADF segue a regra de Schwert: $p_{\max} = \lfloor 12(T/100)^{1/4} \rfloor = 13$. Dentro dela, as defasagens são escolhidas por AIC (e por BIC, como checagem). PP e KPSS usam janela de Newey-West longa. Como o log do índice cresce, os três testes usam constante e tendência. Para o ADF e o PP, H_0 é raiz unitária; para o KPSS, H_0 é estacionariedade em torno da tendência.

Tabela 2: Testes na série em nível y_t (100 × log do INPC).

Série	Teste	Determinísticos	Estatística	Crítico 5%	p-valor	Defas.	Critério	Decisão
y (nível)	ADF	constante + tendência	-2,357	-3,430	0,401	2	AIC, pmax = 13 (Schwert)	não rejeita H0
y (nível)	ADF	constante + tendência	-2,088	-3,430	0,548	1	BIC, pmax = 13 (Schwert)	não rejeita H0
y (nível)	PP (Z-tau)	constante + tendência	-1,963	-3,438	0,617	13	janela de Newey-West (long)	não rejeita H0
y (nível)	KPSS	constante + tendência	0,082	0,146	> 0,10	13	janela de Newey-West (long)	não rejeita H0

Nenhum dos três rejeita a sua hipótese nula. O ADF ($\tau_3 = -2{,}357$, $p = 0{,}401$) e o PP ($p = 0{,}617$) não rejeitam a raiz unitária, e o KPSS (0,082 contra o crítico de 0,146) não rejeita a estacionariedade em tendência. É o caso "dados pouco informativos" da análise confirmatória, tratado no item (d).

(b) Constante e tendência na regressão auxiliar

A regressão do ADF é $\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_i \delta_i \Delta y_{t-i} + e_t$. Os termos determinísticos mudam o que o teste compara (Mattos, 2019, seção 2.2):

Tabela 3: As três versões do ADF no nível y_t e o que cada uma testa.

Versão	Estat.	H_0	H_1	Valor	Crítico 5%	Defas.	p (MacKinnon)	Decisão
sem constante	tau1	I(1) puro (só tendência estocástica)	estacionária, média zero	3,935	-1,95	2	1,000	não rejeita H0
só constante	tau2	I(1) puro (só tendência estocástica)	estacionária, média não nula	-1,010	-2,88	2	0,749	não rejeita H0
constante + tendência	tau3	DS (tendência determinística + estocástica)	TS (tendência determinística + erro estacionário)	-2,357	-3,43	2	0,401	não rejeita H0

Justificativa e leitura.

- **Por que constante e tendência.** A versão se escolhe pelo gráfico (Mattos, 2019, seção 2.2.5): o log do índice cresce ao longo dos 13 anos, então a versão adequada é a com constante e tendência; na dúvida, também, porque ela engloba as outras. Nela, H_0 é um processo **diferença estacionária** (tendência determinística mais tendência estocástica) e H_1 é um processo **tendência estacionária** (só tendência determinística). As duas hipóteses são não estacionárias: aqui o teste não pergunta "estacionária ou não", e sim "há um processo I(1) embutido?".
- **O resultado.** $\tau_3 = -2{,}357$ não rejeita: a série é DS. Somando a equação do passeio com drift desde o início, $y_t = y_0 + \alpha t + \sum_{j \le t} u_j$: uma tendência determinística (αt, com α igual à inflação média) mais uma tendência estocástica ($\sum u_j$). Na definição ampla, é I(1).
- **As outras versões.** Só com constante, $\tau_2 = -1{,}010$ também não rejeita, mas a alternativa dela (estacionária em torno de uma média fixa) não descreve uma série que cresce. Sem termos determinísticos, $\tau_1 = 3{,}935$ é **positivo**: o teste "vê" a tendência omitida como explosividade. Nesta série as três versões não rejeitam, mas só a versão com tendência compara hipóteses que fazem sentido para ela.

(c) Série diferenciada: d e D

Tabela 4: Testes em Δy_t.

Série	Teste	Determinísticos	Estatística	Crítico 5%	p-valor	Defas.	Critério	Decisão
Δy	ADF	constante	-5,159	-2,880	< 0,001	1	AIC, pmax = 13	rejeita H0
Δy	ADF	nenhum	-1,272	-1,950	0,187	8	AIC, pmax = 13	não rejeita H0
Δy	PP (Z-tau)	constante	-7,489	-2,879	< 0,001	13	janela de Newey-West (long)	rejeita H0
Δy	KPSS	constante	0,114	0,463	> 0,10	13	janela de Newey-West (long)	não rejeita H0

Δy oscila em torno de uma média, então a versão é a só com constante (Mattos, 2019, exemplo 2). ADF e PP com constante rejeitam a raiz unitária com folga, e o KPSS não rejeita a estacionariedade. Logo $d = 1$. Sem constante, o ADF nem rejeita, porque a inflação média é 0,45 % a.m., e não zero.

Diferença sazonal (D). A série é mensal e tem sazonalidade (Questão 1). Segue-se o procedimento de Mattos (2019, seção 2.6), de Dickey e Miller: acrescentar 11 dummies sazonais centradas à regressão do ADF. Elas captam uma sazonalidade **determinística** (médias mensais fixas) sem mudar a distribuição de τ.

Tabela 5: ADF com 11 dummies sazonais centradas (defasagens por BIC).

Série	Versão	τ	Crítico 5%	Defas.	Dummies signif. a 5%	Decisão
y (nível)	constante + tendência + 11 dummies	-2,207	-3,43	2	4	não rejeita H0
Δy	constante + 11 dummies	-6,743	-2,88	0	3	rejeita H0

- As conclusões não mudam com as dummies: no nível, $\tau = -2{,}207$ continua sem rejeitar; em Δy, $\tau = -6{,}743$ continua rejeitando.
- Em Δy, 3 das 11 dummies são significativas a 5%, os meses do meio do ano, de inflação mais baixa: há sazonalidade determinística.

- A FAC de Δy (Questão 3) não decai devagar nos múltiplos de 12: vale 0,216 em 12 e já é desprezível em 24 e 36. Uma raiz unitária sazonal faria a FAC sazonal decair lentamente, como a FAC regular do nível.

Logo $D = 0$. A sazonalidade é determinística e será modelada com termos sazonais ARMA, sem a diferença $1 - B^{12}$.

(d) Tendência estocástica ou determinística?

Tabela 6: DF-GLS (Mattos, 2019, seção 2.4), com o número de defasagens do ADF por BIC.

Teste	Estatística	Crítico 5%	Defas.	Decisão
DF-GLS (constante + tendência)	-1,704	-2,93	1	não rejeita H0

Tabela 7: Amostra longa (jan/2000 a set/2026), a mesma série com 13 anos a mais, como checagem.

Série	Teste	Determinísticos	Estatística	Crítico 5%	p-valor	Defas.	Critério	Decisão
y, 2000:01–2026:09	ADF	constante + tendência	-3,985	-3,420	0,010	13	AIC	rejeita H0
y, 2000:01–2026:09	ADF	constante + tendência	-3,607	-3,420	0,031	1	BIC	rejeita H0
y, 2000:01–2026:09	PP (Z-tau)	constante + tendência	-2,384	-3,425	0,387	16	Newey-West (long)	não rejeita H0
y, 2000:01–2026:09	KPSS	constante + tendência	0,170	0,146	0,030	16	Newey-West (long)	rejeita H0

Nenhum teste de raiz unitária rejeita nesta janela. O DF-GLS, que tem mais poder que o ADF quando a série é muito persistente (Mattos, 2019, seção 2.4), também não rejeita. A única voz contrária é o KPSS, que não rejeita a estacionariedade em tendência.

Escolha adotada: tendência estocástica com drift (DS), $d = 1$. Há quatro justificativas:

1. **Os testes de raiz unitária concordam.** ADF (com AIC e com BIC, com e sem dummies sazonais), PP e DF-GLS não rejeitam. A não rejeição do KPSS é compatível com pouco poder em amostra curta com janela de Newey-West longa: com 165 observações e 13 defasagens na variância de longo prazo, a estatística tende a ficar pequena.
2. **A economia aponta DS.** Sob metas de inflação, o Banco Central mira a *inflação*, não um *nível* de preços. Choques no nível de preços nunca são revertidos (*base drift*). Uma trajetória determinística para $\ln P_t$ seria uma meta de nível de preços, que o Brasil não tem. A literatura sobre índices de preços chega ao mesmo ponto: com testes mais potentes, a inflação é estacionária e os preços são I(1), e não I(2) (Culver e Papell, 1997); para o Brasil depois do Real, a dinâmica da inflação é globalmente estacionária (Maia e Cribari-Neto, 2006).
3. **O custo de errar é assimétrico e verificável.** Se a série fosse TS e diferenciássemos, Δy teria uma raiz unitária no MA. A Questão 5(e) testa isso: o MA(1) acrescentado ao modelo de Δy sai com coeficiente pequeno e não significativo, longe de -1. A Questão 6 mostra o que acontece quando a diferenciação está de fato em excesso.
4. **A amostra longa não muda a decisão.** Com os 26 anos (segunda tabela), o ADF passa a rejeitar a 5%, mas o PP continua sem rejeitar, e o KPSS agora rejeita a estacionariedade. Os 13 anos a mais trazem a crise de 2002–2003 e a queda de patamar da inflação em 2004, que os testes confundem com tendência. A janela recente deixa esse episódio de fora, e a Questão 5 mostra que, nela, os parâmetros são estáveis (Chow e CUSUM).

Questão 3. Identificação

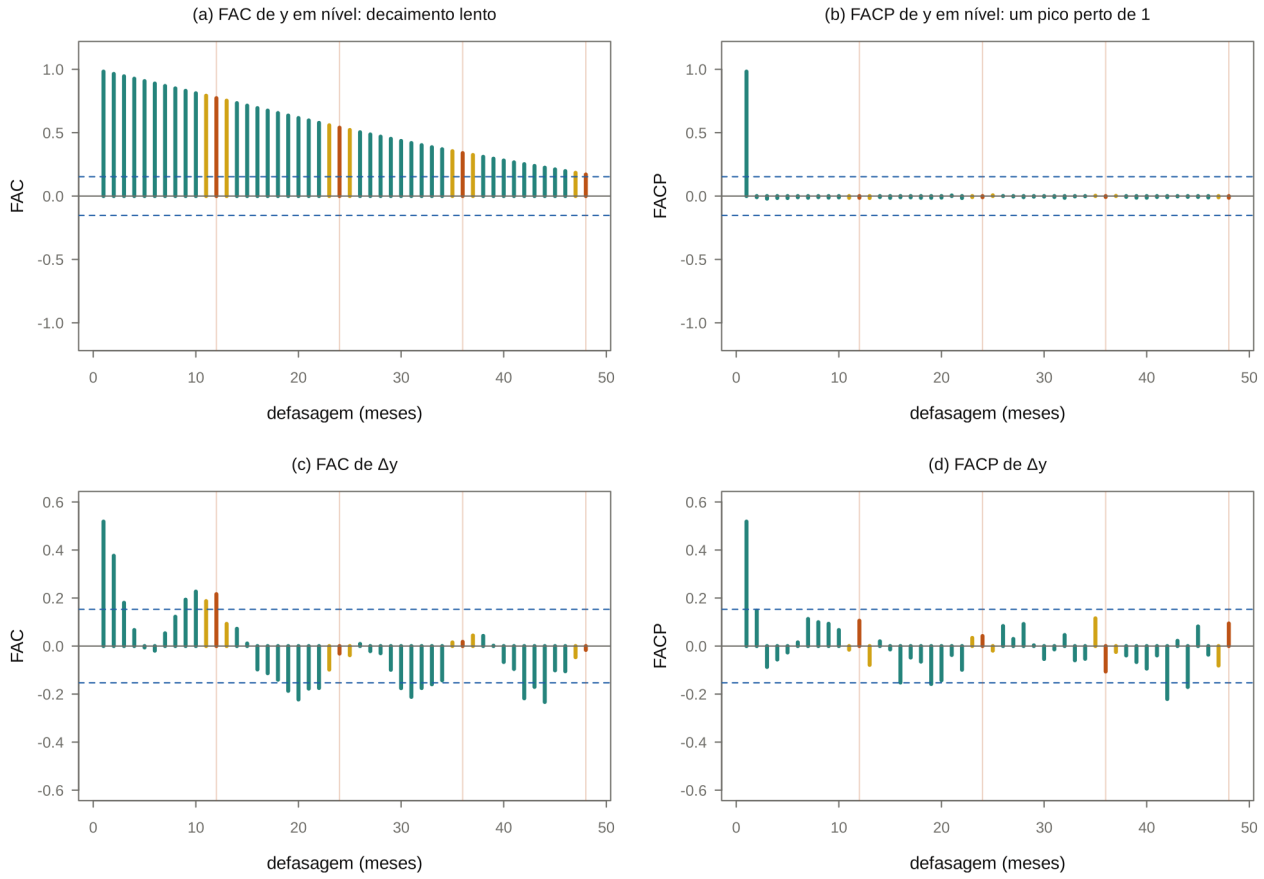


Figura 4: FAC e FACP com 48 defasagens (quatro ciclos sazonais) de y em nível (a, b) e de Δy (c, d). Azul: $\pm 1{,}96/\sqrt{T}$. Barras laranja: s, $2s$, $3s$, $4s$; amarelas: $s \pm 1$.

(a) A FAC de y em nível decai devagar e quase linearmente (painel a), e a FACP tem um único pico perto de 1 (painel b): é a assinatura de raiz unitária. A identificação, portanto, é feita em Δy ($d = 1$, $D = 0$, Q2). A Tabela a seguir traz os valores nas defasagens-chave; a coluna "sig." usa a banda $\pm 1{,}96/\sqrt{T} = \pm 0{,}153$ das aulas para as duas funções.

Tabela 8: FAC e FACP de Δy nas defasagens regulares e sazonais.

Defasagem	FAC	FACP	FAC sig.	FACP sig.
1	0,518	0,518	sim	sim
2	0,376	0,147	sim	
3	0,180	-0,087	sim	
11	0,187	-0,015	sim	
12	0,216	0,105	sim	
13	0,092	-0,078		
23	-0,098	0,034		
24	-0,031	0,042		
25	-0,038	-0,019		
35	0,015	0,115		
36	0,018	-0,106		
37	0,044	-0,024		
47	-0,046	-0,081		
48	-0,016	0,094		

(b) Leitura.

- **Parte regular.** A FACP tem um pico claro em 1: $\hat{\phi}_{11} = 0{,}518$. O $\hat{\phi}_{22} = 0{,}147$ fica **no limite** da banda ($\pm 0{,}153$), e depois tudo cai dentro. A FAC decai, mas mais devagar que num AR(1): $\hat{\rho}_2/\hat{\rho}_1 = 0{,}73$, maior que $\hat{\rho}_1 = 0{,}518$. Leitura: AR(1) regular, com um AR(2) como alternativa.
- **Parte sazonal.** Há pico em $s = 12$ na FAC (0,216), pouco acima da banda; na FACP, 0,105, dentro da banda. Em $2s$ e $3s$ os valores somem: -0,031 e 0,018 na FAC. A sazonalidade é fraca, como esperado com só 13 repetições de cada mês.
  - Lido como um **decaimento rápido** nas defasagens sazonais, isso é um SAR(1).
  - Lido como um **truncamento** em s, é um SMA(1).
  - A amostra não separa as duas leituras.
- **Vizinhanças.** Na FAC, $s - 1 = 11$ vale 0,187, e $s + 1 = 13$ vale 0,092; na FACP, $s + 1$ vale -0,078. Só a FAC em 11 passa da banda. Isso não pede um termo a mais: num AR(1) × SAR(1), a FAC nas vizinhanças de s não é zero, porque o produto dos dois polinômios gera autocorrelação em $s \pm 1$. Na FACP, nenhuma vizinhança é significativa.
- **Ljung-Box.** Δy está longe de ser ruído branco: $Q(24) = 148{,}3$, $p < 0{,}001$.

(c) Três candidatos para y, todos com $d = 1$, $D = 0$ e *drift*. O drift é a constante de Δy; a inflação média não é zero.

	Especificação	Justificativa pelo correlograma
C1	SARIMA(1,1,0)$(1,0,0)_{12}$	FACP trunca em 1; sazonal lida como decaimento em s, $2s$ (SAR)
C2	SARIMA(1,1,0)$(0,0,1)_{12}$	FACP trunca em 1; sazonal lida como truncamento em s (SMA)
C3	SARIMA(2,1,0)$(1,0,0)_{12}$	FACP em 2 no limite da banda e FAC que decai mais devagar que um AR(1): AR(2) regular, com SAR

Questão 4. Estimação e seleção

Tabela 10: Coeficientes (MV exata). Convenção do R: $\phi(B) = 1 - \phi_1 B$, $\Theta(B^{12}) = 1 + \Theta_1 B^{12}$.

Modelo	Termo	Coeficiente	Erro-padrão	t
C1	ar1	0,5064	0,0672	7,5350
C1	sar1	0,1783	0,0778	2,2927
C1	drift	0,4533	0,0651	6,9600
C2	ar1	0,5035	0,0677	7,4383
C2	sma1	0,1660	0,0740	2,2424
C2	drift	0,4537	0,0624	7,2661
C3	ar1	0,4415	0,0781	5,6547
C3	ar2	0,1258	0,0790	1,5917
C3	sar1	0,1654	0,0786	2,1061
C3	drift	0,4530	0,0724	6,2530

Tabela 11: Ajuste, critérios de informação e amostra efetiva ($n = T - d - sD$).

Modelo	Especificação	n efetivo	k	$\hat{\sigma}_a^2$	log-ver.	AIC	BIC
C1	SARIMA(1,1,0)(1,0,0)[12]	164	4	0,126	-58,809	125,618	138,017
C2	SARIMA(1,1,0)(0,0,1)[12]	164	4	0,126	-58,983	125,966	138,366
C3	SARIMA(2,1,0)(1,0,0)[12]	164	5	0,125	-57,552	125,104	140,603

(a) e (b). Nos três candidatos, o AR(1) e o drift são significativos a 1%, e os termos sazonais (SAR ou SMA) a 5%. O AR(2) do C3 não é significativo ($p = 0{,}111$). A amostra efetiva é $n = T - d - sD = 165 - 1 - 0 = 164$ nos três modelos. O drift estimado, cerca de 0,45 % a.m., é a inflação média.

(c) A comparação é válida. Os três modelos têm a mesma variável dependente (y), o mesmo $d = 1$ e o mesmo $D = 0$. A verossimilhança, portanto, é a de Δy nas mesmas 164 observações. Se um candidato tivesse $d = 2$, a verossimilhança passaria a ser a de $\Delta^2 y$, outra variável, e com $n = 163$: o AIC deixaria de ser comparável. Nesse caso há três alternativas: decidir d antes, por teste (Q2); comparar fora da amostra, com a mesma variável-alvo (Q7); ou comparar verossimilhanças na mesma escala de y. Pela mesma razão, um modelo em P_t e outro em $\ln P_t$ só seriam comparáveis com o jacobiano da transformação.

(d) Convenção de contagem. O `forecast::Arima`, assim como o `stats::arima`, inclui $\hat{\sigma}_a^2$ em k:

$$k = \#\{\text{coeficientes livres}\} + 1, \qquad AIC = -2\ln L + 2k, \qquad BIC = -2\ln L + k\ln n.$$

No código do `forecast` isso aparece como `npar <- length(coef[mask]) + 1`; a documentação de `?arima` acrescenta que o AIC só é válido com `method = "ML"`. A conferência numérica bate: recalculando com o "+1", o AIC reproduz o do software em todos os modelos (confere; tabela `q4_convencao.csv`). Ainda há três diferenças de convenção que importam ao comparar com outros textos:

- a aula (AU02, slides 98–99) divide os critérios por T, e o R não divide; com T comum, a ordenação é a mesma;
- a aula conta $k = p + q + 1$ num ARMA com média, sem $\hat{\sigma}_a^2$; o R soma a variância. O acréscimo é o mesmo em todos os modelos, e a escolha não muda;
- o BIC usa o n efetivo, e não T.

(e) AIC e BIC divergem.

Tabela 12: Seleção entre os três candidatos.

Modelo	AIC	ΔAIC	BIC	ΔBIC
C1	125,618	0,514	138,017	0,000
C2	125,966	0,862	138,366	0,348
C3	125,104	0,000	140,603	2,586

O AIC escolhe **C3**, e o BIC escolhe **C1**. O C1 é o C3 sem o ϕ_2, e o AR(2) do C3 não é significativo ($t = 1{,}59$, $p = 0{,}111$). O AIC aceita esse parâmetro porque cobra 2 por ele, e o BIC o recusa porque cobra $\ln 164 = 5{,}10$. É o dilema da aula 02:

- O **BIC é consistente**: se o modelo verdadeiro está entre os candidatos, ele é escolhido com probabilidade que tende a 1.
- O **AIC é eficiente**: minimiza assintoticamente o EQM de previsão de um passo quando o processo verdadeiro não está entre os candidatos (Shibata, 1980).

O objetivo deste trabalho é prever (Questão 7), o que favorece o AIC. Mas a vantagem do C3 no AIC é de só 0,51 ponto e vem de um coeficiente não significativo. A regra fixada antes de olhar a validação segue o princípio da parcimônia da aula 02: quando AIC e BIC divergem, fica o modelo menor se o parâmetro extra do maior não for significativo a 5%. **O modelo selecionado é o C1 = SARIMA(1,1,0)(1,0,0)[12]**, com todos os coeficientes significativos.

(f) Raízes.

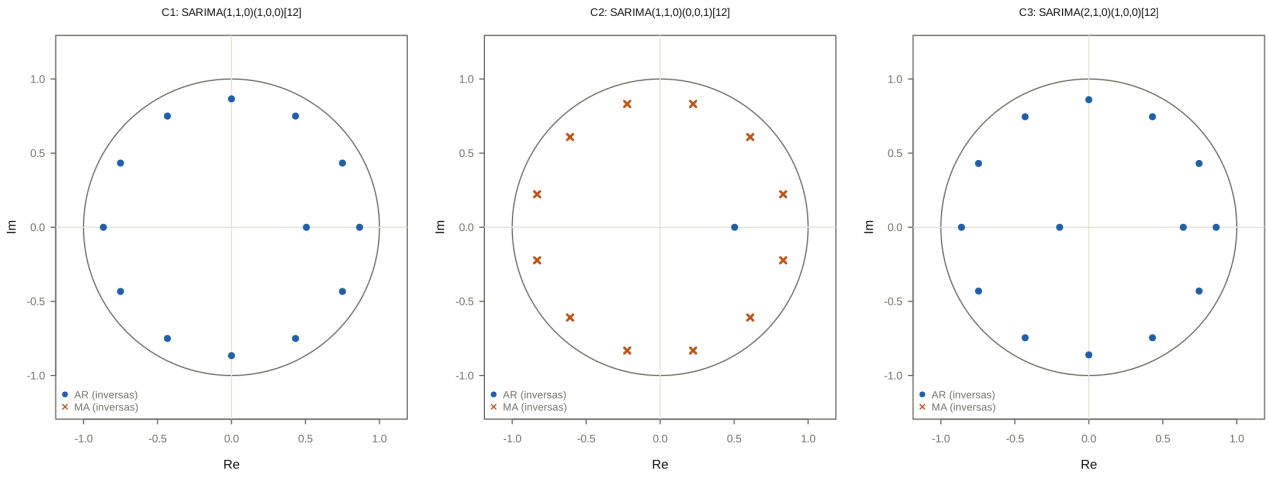


Figura 5: Raízes inversas dos polinômios AR (pontos) e MA (×) completos, regular × sazonal, no círculo unitário.

Tabela 13: Módulo máximo das raízes inversas (precisa ser menor que 1).

Modelo	nº raízes AR	máx. |inv. AR|	nº raízes MA	máx. |inv. MA|
C1	13	0,866	0	NA
C2	1	0,504	12	0,861
C3	14	0,861	0	NA

Todas as raízes inversas estão **dentro** do círculo unitário; equivalentemente, as raízes estão fora. Os modelos são estacionários (em Δy) e invertíveis. No C1, a raiz inversa regular é $\hat{\phi}_1 = 0{,}506$, e as 12 sazonais têm módulo

$\hat{\Phi}_1^{1/12} = 0{,}866$: um $\hat{\Phi}_1$ pequeno vira 12 raízes inversas de módulo alto, mas ainda longe do círculo. Não há fatores AR e MA parecidos, logo não há quase-cancelamento.

Questão 5. Diagnóstico

(a) O painel de resíduos do modelo selecionado (SARIMA(1,1,0)(1,0,0)[12]):

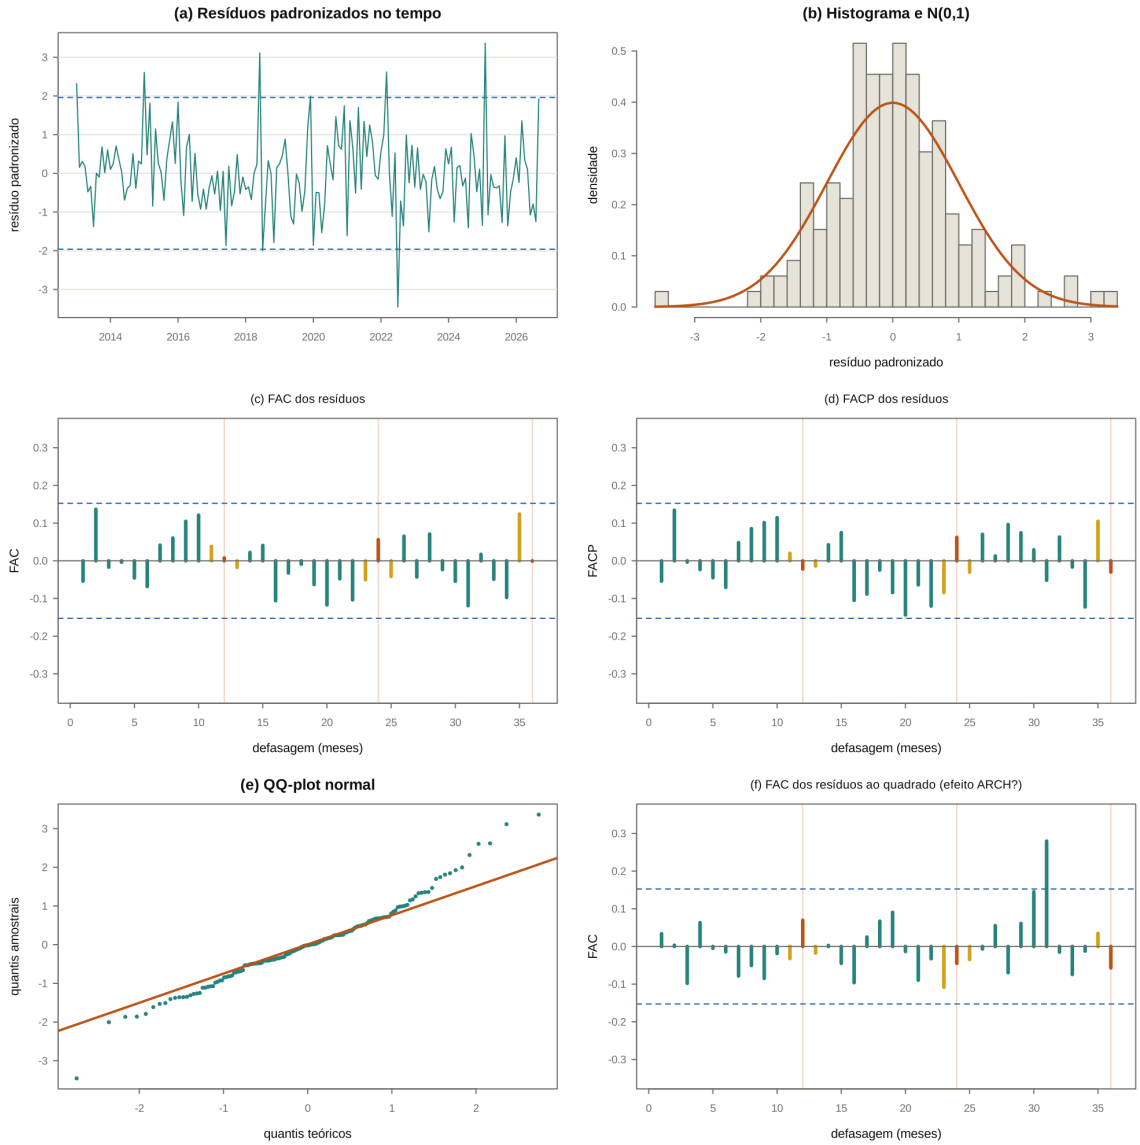


Figura 6: Resíduos do modelo selecionado: no tempo (a), histograma com a densidade normal (b), FAC (c), FACP (d), QQ-plot (e) e FAC dos resíduos ao quadrado (f).

(b) e (c) Testes. No Ljung-Box, os graus de liberdade são $v = K - (p + q + P + Q) = K - 2$. O drift não entra na correção: ela vem dos parâmetros ARMA estimados.

Tabela 14: Diagnóstico dos resíduos.

Teste	K	gl	Estatística	Crítico 5%	p-valor	Decisão
Ljung-Box	12	10	10,625	18,307	0,387	não rejeita H0
Ljung-Box	24	22	20,318	33,924	0,563	não rejeita H0
Ljung-Box	36	34	32,321	48,602	0,550	não rejeita H0
Jarque-Bera	—	2	18,121	5,991	0,000	rejeita H0
ARCH-LM (12 defasagens)	12	12	5,953	21,026	0,918	não rejeita H0
McLeod-Li (Q de e^2, 24)	24	24	15,515	36,415	0,905	não rejeita H0

- **Autocorrelação.** O Ljung-Box não rejeita em $K = 12, 24, 36$. Com $K = 24$, $Q = 20{,}32$ com $v = 22$ e $p = 0{,}563$. Os resíduos são compatíveis com ruído branco: o modelo capturou a dependência linear.
- **Normalidade.** O Jarque-Bera rejeita com força: $JB = 18{,}1$. A assimetria é 0,38 e a curtose 4,44, e a causa são as caudas: os resíduos padronizados acima de 3 em módulo estão em jun/2018, jul/2022, fev/2025.
- **Heterocedasticidade condicional.** O ARCH-LM com 12 defasagens não rejeita ($p = 0{,}918$), e o McLeod-Li também não. A variância condicional é constante: não há motivo para um GARCH.

(d) O caminho percorrido. A Q4 estimou uma grade completa, SARIMA$(p,1,q)(P,0,Q)_{12}$ com $p, q \leq 3$, $P, Q \leq 1$ e drift, e cada modelo foi classificado como na tabela abaixo.

Tabela 15: Grade de 64 modelos e o motivo de cada descarte (lista completa em saidas/tabelas/q5_caminho.csv).

Destino	nº de modelos
adequado, mas dominado em AIC e BIC	53
autocorrelação residual (Ljung-Box 24, 5%)	8
raiz MA na fronteira (não invertível)	2
SELECIONADO	1

Tabela 16: Exemplos de descarte por autocorrelação residual: todos sem o AR(1), que a FACP exige.

Modelo descartado	AIC	BIC	p Ljung-Box(24)
SARIMA(0,1,1)(0,0,1)	141,307	153,706	0,0007
SARIMA(0,1,1)(1,0,0)	141,397	153,797	0,0005
SARIMA(0,1,1)(1,0,1)	143,255	158,754	0,0004
SARIMA(0,1,1)(0,0,0)	146,266	155,565	0,0001
SARIMA(0,1,0)(0,0,1)	170,944	180,244	0,0000
SARIMA(0,1,0)(1,0,0)	172,041	181,340	0,0000

São descartados os modelos com autocorrelação residual (todos sem o AR regular) e os que têm raiz MA na fronteira. Também saem os modelos adequados, mas dominados em AIC e BIC, como os sobreajustes do item (e). A falha no JB não é corrigida mudando a estrutura ARMA: ela vem de três meses de choque, e a sua consequência prática, intervalos gaussianos estreitos demais nesses meses, é avaliada na cobertura da Questão 7.

Estabilidade dos parâmetros (aula 03). Uma janela de 13 anos só serve se os parâmetros forem estáveis nela. O teste de Chow exige uma data de quebra escolhida *antes* de olhar os dados; a candidata natural é mar/2020, o início da pandemia. Ele é aplicado à versão de MQO do modelo, $\Delta y_t = c + \phi\,\Delta y_{t-1} + \Phi\,\Delta y_{t-12} - \phi\Phi\,\Delta y_{t-13} + e_t$, estimada sem a restrição multiplicativa. A análise recursiva usa o CUSUM e o CUSUM-Q dos resíduos recursivos.

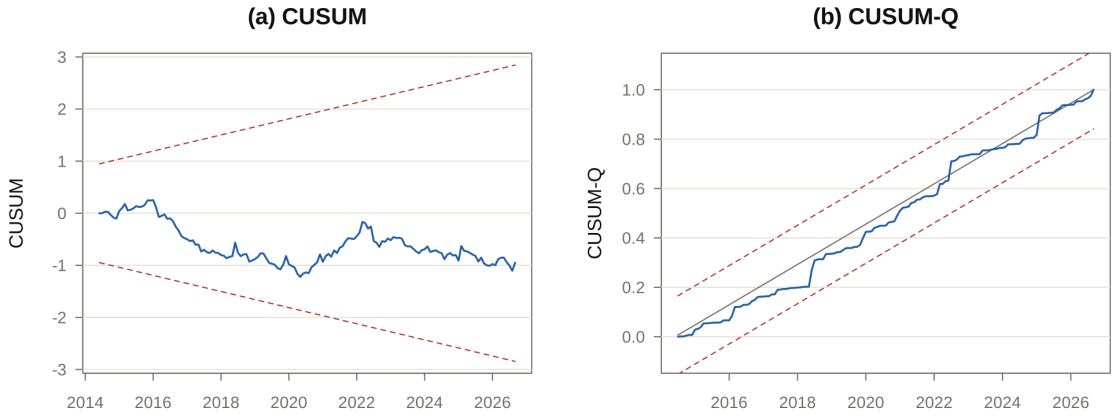


Figura 7: CUSUM (a) e CUSUM-Q (b) dos resíduos recursivos, com as bandas de 5%.

- **Chow (mar/2020).** $F = 0{,}457$, $p = 0{,}767$: não se rejeita a igualdade dos coeficientes antes e depois da pandemia.
- **CUSUM.** A estatística é 0,623 ($p = 0{,}372$): a soma acumulada não sai das bandas, logo não há mudança sistemática nos coeficientes.
- **CUSUM-Q.** O maior desvio em relação à reta esperada é 0,117, abaixo do crítico de 0,159: a variância dos erros também é estável.

Os parâmetros são estáveis na janela de jan/2013 a set/2026. Isso sustenta o uso desta amostra, e não da longa, no item (d) da Questão 2.

(e) Sobreajuste deliberado.

Tabela 17: Sobreajuste: um AR e um MA a mais no modelo selecionado.

Modelo	Termo extra	Coef.	Erro-padrão	t	p	ΔAIC
SARIMA(2,1,0)(1,0,0)[12]	ar2	0,126	0,079	1,592	0,111	-0,514
SARIMA(1,1,1)(1,0,0)[12]	ma1	-0,173	0,126	-1,377	0,169	0,206

Nenhum dos dois coeficientes extras é significativo (p de 0,11 e 0,17). O AR extra é o candidato C3 da Q4: melhora o AIC em menos de 1 ponto. O MA extra desloca o AR(1) em 1,9 erros-padrão, o efeito típico de um par AR-MA redundante, e piora o AIC. A especificação selecionada é **adequada**: não falta dinâmica regular.

O MA acrescentado vale -0,173, longe de -1. Isso confirma que Δy não foi sobrediferenciada, o argumento 3 da Q2(d).

Questão 6. Sobrediferenciação

Reestima-se o modelo com $d^* + 1 = 2$ de duas formas:

- **(A)** com as mesmas ordens: SARIMA(1,2,0)(1,0,0)[12];
- **(B)** com o MA(1) regular que a teoria prevê para $\Delta^2 y$: SARIMA(1,2,1)(1,0,0)[12].

Se $y \sim \text{ARIMA}(p,1,q)$, então $\Delta^2 y$ tem o fator $(1 - B)$ no polinômio MA. O R não estima drift com $d = 2$.

Tabela 18: Mesmo modelo com $d = 1$ e $d = 2$.

Modelo	d	$\hat{\sigma}_a^2$	log-ver.	n	$\hat{\rho}_1$ dos resíduos
SARIMA(1,1,0)(1,0,0)[12]	1	0,1259	-58,8089	164	-0,0539
SARIMA(1,2,0)(1,0,0)[12]	2	0,1509	-71,6503	163	-0,0494
SARIMA(1,2,1)(1,0,0)[12]	2	0,1309	-60,6086	163	-0,0899

Tabela 19: Coeficientes de SARIMA(1,2,1)(1,0,0)[12] (convenção do R: $1 + \theta B$).

Termo	Coeficiente	Erro-padrão	t	p
ar1	0,5153	0,0681	7,5700	0,0000
ma1	-1,0000	0,0220	-45,4079	0,0000
sar1	0,1843	0,0783	2,3544	0,0186

(a) Coeficiente MA. $\hat{\theta} = -1{,}0000$, com erro-padrão 0,0220. Na convenção do R ($1 + \theta B$), isso é $\theta = -1$; na de Box-Jenkins ($1 - \theta B$), é $\theta = 1$. A soma dos coeficientes MA regulares vale -1,0000. A raiz de $1 + \hat{\theta} z = 0$ é $z = 1{,}0000$: **exatamente sobre o círculo unitário**. O estimador "encosta" na fronteira, o fenômeno de acúmulo em $|\theta| = 1$ (*pile-up*). O erro-padrão pequeno não é confiável, porque a distribuição assintótica usual não vale nessa fronteira.

(b) Variância residual. Com $d = 1$, $\hat{\sigma}_a^2 = 0{,}1259$. Com $d = 2$:

- **(A)**, mesmas ordens: 0,1509, um aumento de **19,9%**;
- **(B)**, com o MA extra: 0,1309, um aumento de 4,0%.

Mesmo deixando o MA absorver a diferença extra, o ajuste piora: a log-verossimilhança cai de -58,8 para -60,6. As log-verossimilhanças são de variáveis diferentes e por isso não são diretamente comparáveis; a perda aparece de forma comparável em $\hat{\sigma}_a^2$.

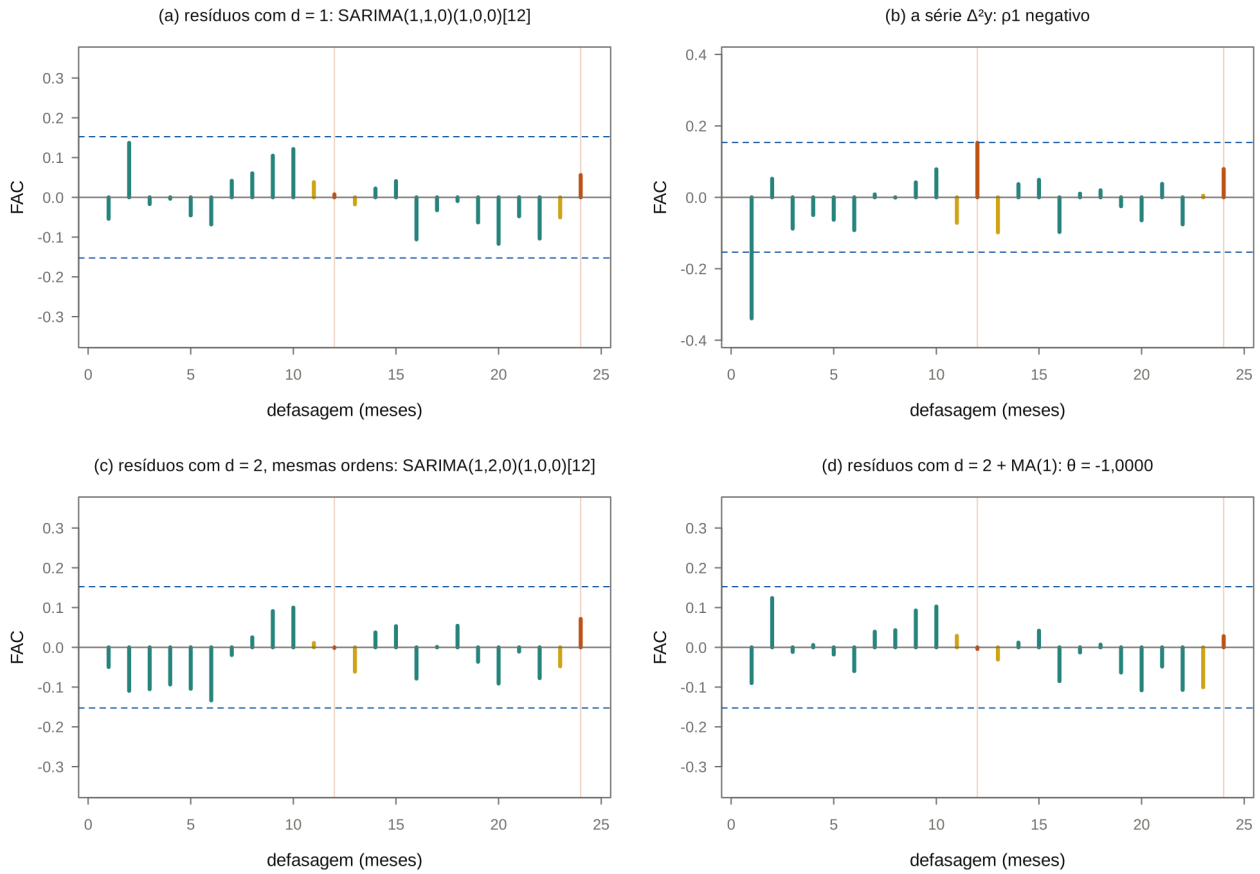


Figura 8: FAC dos resíduos com $d = 1$ (a), da série $\Delta^2 y$ (b), dos resíduos com $d = 2$ e mesmas ordens (c) e com $d = 2$ mais um MA(1) (d).

(c) FAC dos resíduos.

- **A série** $\Delta^2 y$ tem $\hat{\rho}_1 = -0{,}339$, na direção e na ordem de grandeza do valor teórico $-(1 - \hat{\phi}_1)/2 = -0{,}247$ de um AR(1) diferenciado uma vez a mais (lista teórica, Q9).
- **Nos resíduos de (A)**, o $\hat{\rho}_1$ é pequeno (-0,049): o AR(1) muda de sinal, para $\hat{\phi}_1 = -0{,}345$, e absorve a defasagem 1. Sobram autocorrelações negativas nas defasagens 2 e 3 (-0,109 e -0,105); o Ljung-Box(24) fica em $p = 0{,}473$, contra 0,563 com $d = 1$.
- **Em (B)**, o MA unitário "desfaz" a diferença extra, e os resíduos voltam a ser os de $d = 1$.

A autocorrelação negativa pronunciada em $\Delta^2 y$ existe. Num modelo estimado, ela aparece deslocada para os coeficientes, e não necessariamente no $\hat{\rho}_1$ dos resíduos.

(d) Sinais práticos de sobrediferenciação numa saída típica, sem conhecer a ordem verdadeira:

1. um coeficiente MA estimado perto de -1 (ou a soma dos MA perto de -1), com raiz MA no círculo unitário e erro-padrão "pequeno demais" ou não convergência;
2. um AR(1) estimado **negativo** onde a série original tinha persistência positiva;
3. $\hat{\rho}_1$ da série diferenciada perto de $-0{,}5$ e FAC negativa nas primeiras defasagens;
4. $\hat{\sigma}_a^2$ (ou a variância da própria série) que **aumenta** com a diferença extra, em vez de cair — o princípio da diferença de variáveis de Tintner;
5. intervalos de previsão do nível muito largos e previsões que ignoram a reversão à média.

Questão 7. Previsão fora da amostra

(a) A amostra de validação são as últimas $H = 24$ observações (out/2024 a set/2026). O treino vai até $T_0 = T - H = 141$ (set/2024). O modelo SARIMA(1,1,0)(1,0,0)[12] é reestimado no treino:

Tabela 20: Coeficientes estimados só com o treino (fixos nos dois esquemas).

Termo	Coeficiente	Erro-padrão	t
ar1	0,5651	0,0694	8,1437
sar1	0,1065	0,0841	1,2665
drift	0,4638	0,0717	6,4683

O modelo prevê $y = 100 \ln P$, e as previsões são levadas ao índice por $\exp(\hat{y}/100)$. Isso dá a mediana de P; a correção para a média, $\exp(\sigma_h^2/2 \cdot 10^{-4})$, é desprezível. As métricas são calculadas no **índice em nível**.

(b) Esquema 1: origem fixa, múltiplos passos.

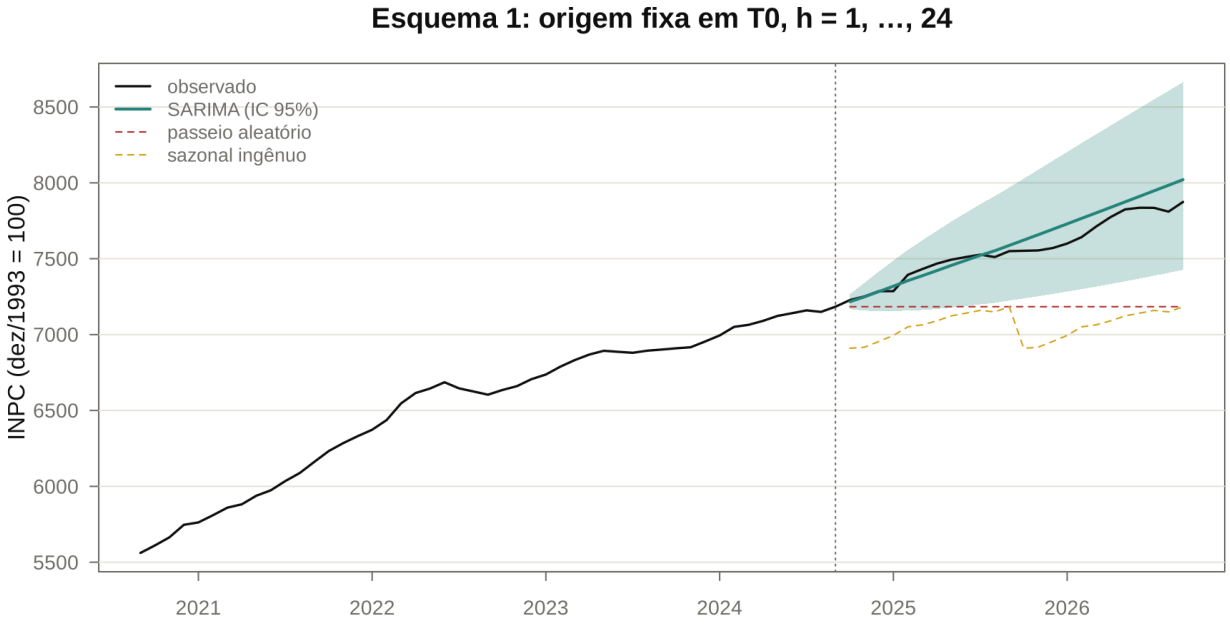


Figura 9: Esquema 1: previsões de $h = 1, \ldots, 24$ a partir de T_0 com IC de 95%, e os dois benchmarks.

(c) Esquema 2: origem móvel, um passo, sem reestimar. Os coeficientes da tabela acima ficam fixos (`Arima(y, model = ajuste_treino)`). Em cada $t = T_0, \ldots, T-1$, o filtro de Kalman atualiza o estado com o dado observado em t e gera $\hat{y}_{t+1|t}$.

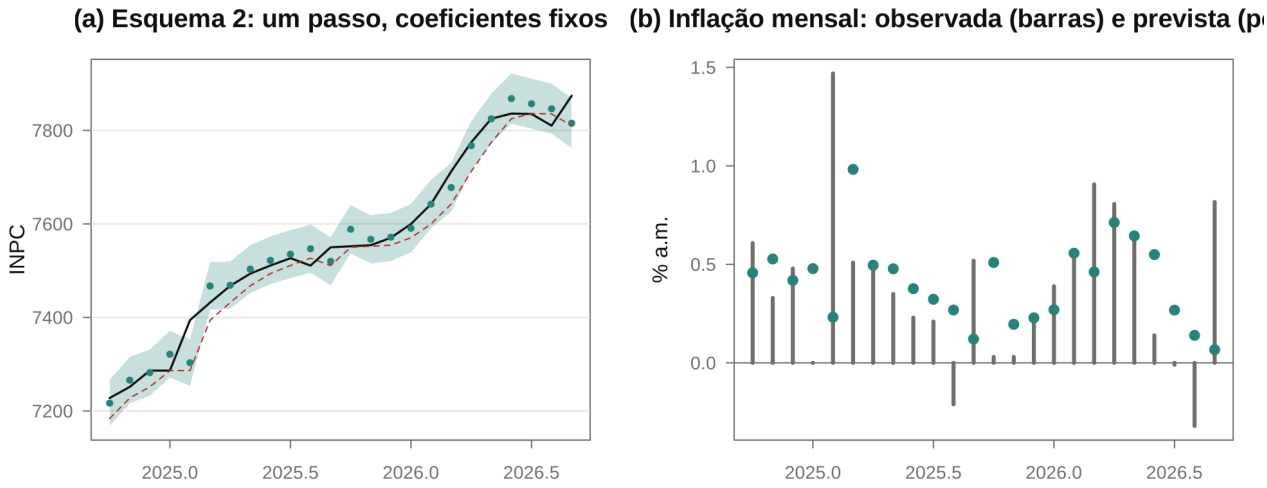


Figura 10: Esquema 2: previsões de um passo com coeficientes fixos, no índice (a) e em inflação mensal implícita (b).

(d) e (e) Métricas. Os dois benchmarks pedidos são o passeio aleatório, $\hat{y}_{t+h} = y_t$, e o sazonal ingênuo, $\hat{y}_{t+h} = y_{t+h-s}$; no Esquema 1, este último é $y_{T_0+h-s\lceil h/s \rceil}$.

Tabela 21: Métricas no INPC em nível (pontos de índice; MAPE em %). Esquema 1: origem fixa, $h = 1, \ldots, 24$. Esquema 2: um passo, coeficientes fixos.

	Esquema 1			Esquema 2		
Modelo	RMSE	MAE	MAPE (%)	RMSE	MAE	MAPE (%)
SARIMA selecionado	81,54	65,95	0,86	30,69	22,38	0,30
Passeio aleatório	425,14	379,63	4,96	40,88	32,23	0,43
Sazonal ingênuo	525,34	501,93	6,59	328,65	326,97	4,33

(f) O modelo superou os benchmarks? Sim, contra os dois pedidos, nos dois esquemas e nas três métricas.

- **Esquema 1.** A razão de RMSE (U de Theil) do modelo é 0,19 contra o passeio aleatório e 0,16 contra o sazonal ingênuo.
- **Esquema 2.** As razões são 0,75 e 0,09.
- **Diebold-Mariano** (Esquema 2, perda quadrática, correção de Harvey, Leybourne e Newbold):

Tabela 22: Diebold-Mariano, Esquema 2. DM negativo favorece o modelo.

Comparação	DM	p
modelo vs passeio aleatório	-2,405	0,025
modelo vs sazonal ingênuo	-24,017	0,000

O ganho sobre os dois benchmarks é **significativo** a 5%. Contra o passeio aleatório, porém, ele é bem menor no Esquema 2 do que no Esquema 1: a um passo, o passeio aleatório erra só a inflação de um mês, enquanto a 24 passos acumula 24 meses de inflação esquecida. Quase toda a vantagem do modelo vem de prever a *tendência* (a inflação média, o drift). Conforme o enunciado, o modelo **não** foi alterado para melhorar o resultado.

(g) Cobertura. No Esquema 1, 24 das 24 observações (100,0%) caíram dentro do intervalo de 95%. O teste de cobertura incondicional de Christoffersen da aula 03 (LR_{uc}, que compara a proporção de violações com 5%) não rejeita a cobertura nominal ($LR_{uc} = 2{,}46$, $p = 0{,}12$). A cobertura empírica é **maior** que a nominal, e há dois motivos para isso:

- os intervalos de h passos se abrem com $\sum_{j<h} \psi_j^2$, e num modelo integrado essa soma cresce sem limite: em $h = 24$ o intervalo é largo;
- com uma única origem, as 24 "tentativas" são fortemente correlacionadas, de modo que 24 acertos valem bem menos que 24 testes independentes.

No Esquema 2, de um passo, a cobertura é 91,7%, com 2 violações, compatível com 95% ($p = 0{,}49$).

Síntese

O log do INPC, de jan/2013 a set/2026, foi tratado como diferença estacionária (tendência determinística mais tendência estocástica, I(1) na definição ampla), com $D = 0$: nenhum teste de raiz unitária rejeita no nível, com ou sem dummies sazonais, e todos rejeitam na diferença. A inflação mensal segue um AR(1) com um componente sazonal fraco; o selecionado foi o SARIMA(1,1,0)(1,0,0)[12] com drift. Os resíduos são ruído branco sem ARCH, e os parâmetros são estáveis (Chow, CUSUM e CUSUM-Q); a falta de normalidade vem de três choques. A sobrediferenciação produz a raiz MA unitária que a teoria prevê. Fora da amostra, o modelo bate o passeio aleatório e o sazonal ingênuo, com ganho significativo no Diebold-Mariano.

Referências. Box, Jenkins, Reinsel e Ljung (2015); Brown, Durbin e Evans (1975); Chow (1960); Christoffersen (1998); Culver e Papell (1997); Dickey e Fuller (1981); Diebold e Mariano (1995); Elliott, Rothenberg e Stock (1996); Kwiatkowski, Phillips, Schmidt e Shin (1992); MacKinnon (1996); Maia e Cribari-Neto (2006); Mattos (2019); Phillips e Perron (1988); Shibata (1980). Slides das aulas 01 a 03 da disciplina.